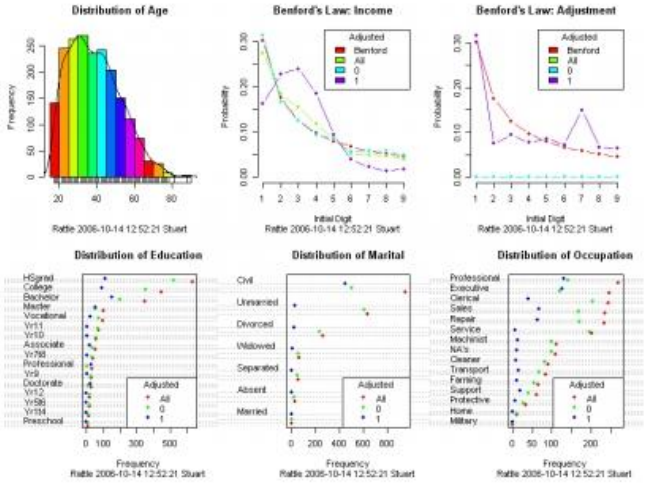
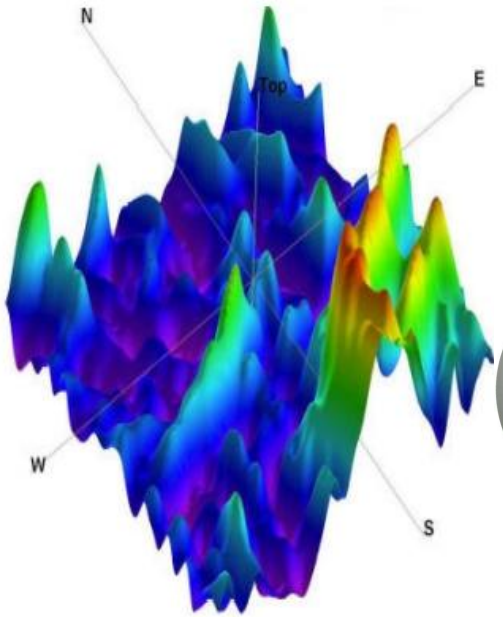
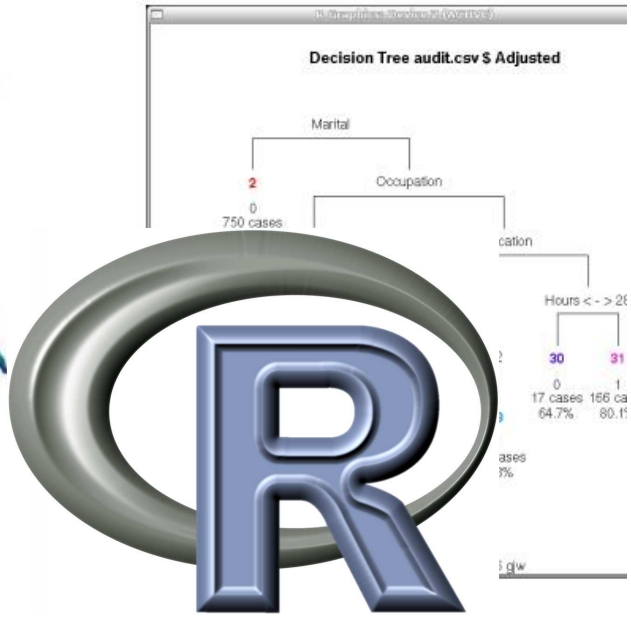
Reinforce BUSINESS INTELLIGENCE™

www.reinforcebi.com

# Introduction to R Data Mining.(Rattle)




The national institute of development administration (NIDA)

M.S.Applied Management (Honors)

Naresuan University

B.Eng Mechanical

Mr.Amornthep Thongchiw

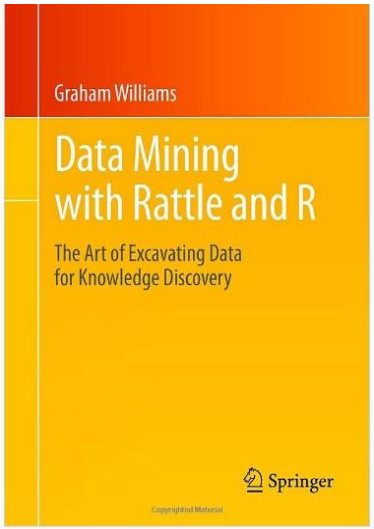
# แนวคิดในการอบรม Analytic Open Source.

- 1.เราแนะนำส่งเสริม Open Source เพื่องดใช้โปรแกรมเถื่อนในการทำงาน (***แต่ส่งเสริมให้ใช้โปรแกรมลิขสิทธิ์***)
- 2.เรากำลังแนะนำความสามารถพื้นฐาน Open Source (ประมาณ 5-10%) อย่าเพิ่งไปเทียบกับ 100% Commercial ที่ใช้มานับ 10 ปี
- 3.เรากำลังแนะนำการใช้โปรแกรมสถิติและดาต้าไมนิ่ง ซึ่งล้วนแต่มีทฤษฎีอยู่เบื้องหลัง
- 4. Open Source Not Always Free ;
  Time & Learning will be need.
- 5. โปรแกรมนี้คือ R data Miner [Rattle] ซึ่งออกแบบมาให้ง่ายต่อการใช้

# 1.Introduction to Data Mining & CRISP-DM

**Becoming an educated buyer and user of Business Analytics software**

Stephen Samild
stephen@presciient.com
Presciient

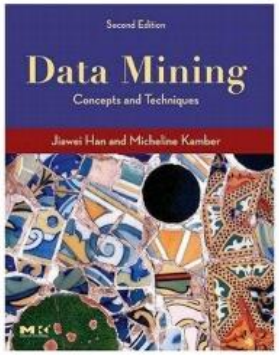



*Data Mining Algorithms*

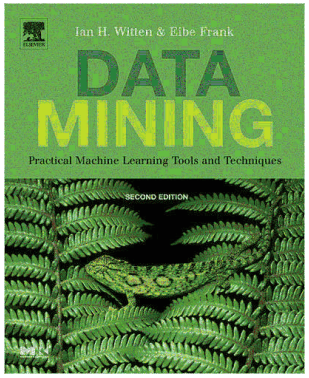
Graham Williams

Principal Data Miner, ATO
Adjunct Associate Professor, ANU

Ian H.Witten & Eibe Frank
Data Mining : Practical machine Learning Tools and Techniques




**Data Mining: Concepts and Techniques**
*Jiawei Han, Micheline Kamber*
2006, Morgan Kaufmann Publishers
ISBN: 1558609016.



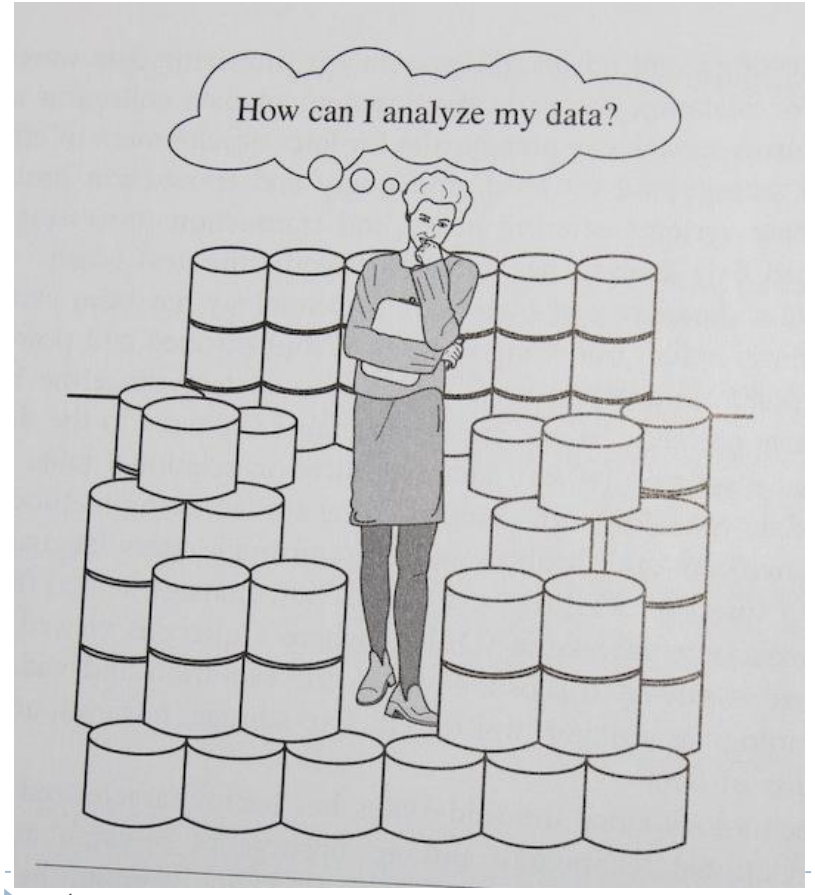

**<u>เอกสารประกอบการสอน การทำเหมืองข้อมูลด้วยโปรแกรม Weka</u>**

1.ผศ.ดร. กรุง สินอภิรมย์สราญ ภาควิชาคณิตศาสตร์ คณะวิทยาศาสตร์ จุฬาลงกรณ์มหาวิทยาลัย (2551)

2.ดร.อนันตพร ศรีสวัสดิ์ สาขาวิชาสถิติประยุกต์ คณะวิทยาศาสตร์ ม.พระจอมเกล้าเจ้าคุณทหารลาดกระบัง (2553)

# Why Data mining?

การใช้ข้อมูลเป็นสิ่งจำเป็น ผู้ที่สามารถนำข้อมูลมาใช้ได้อย่างชาญฉลาดกว่า รวดเร็วกว่า ก็จะสร้างข้อได้เปรียบทางการแข่งขันเหนือผู้อื่น




แล้วเราจะมีวิธีการวิเคราะห์ข้อมูลอย่างไร ?

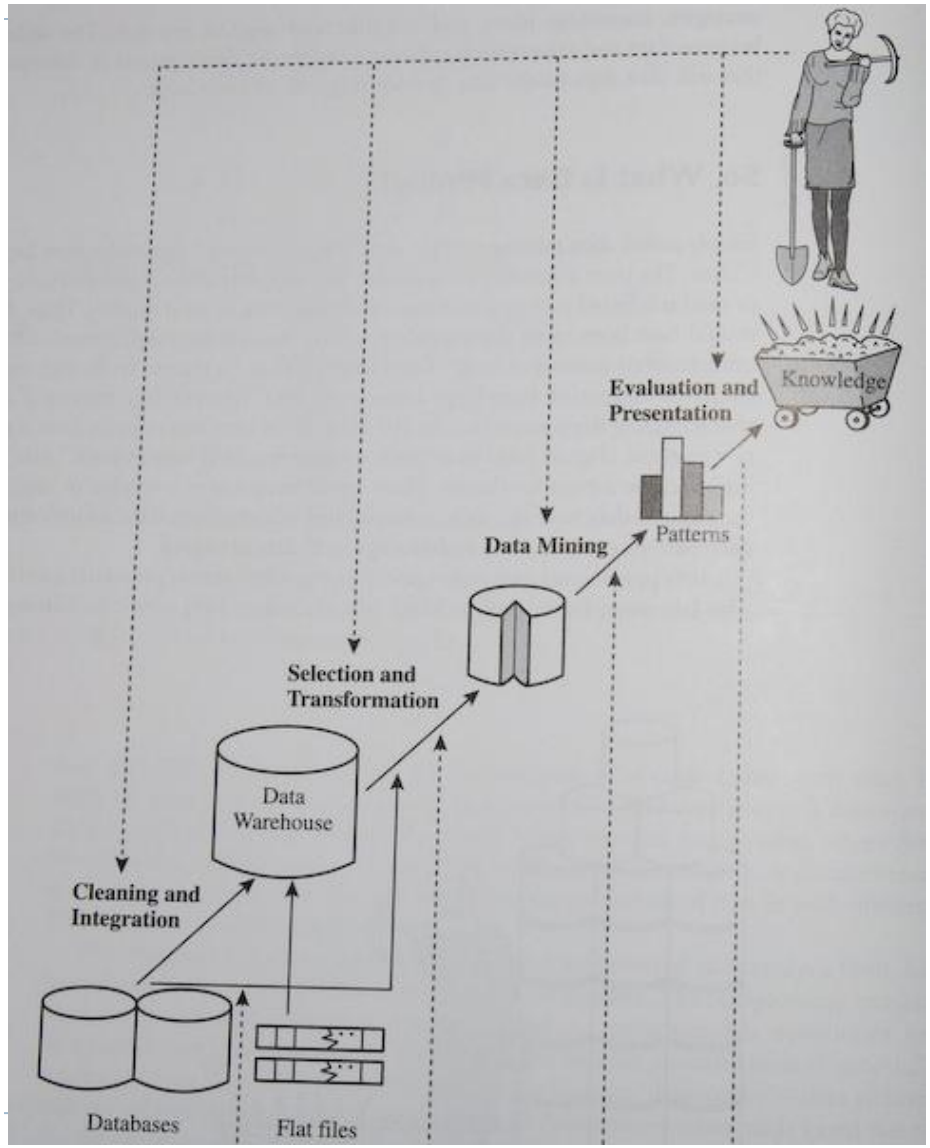
We are drowning in data,
but starving for knowledge!

# Why Data mining?

การวิเคราะห์ข้อมูลสถิติและ **Data mining** ช่วยในการตัดสินใจได้เป็นอย่างดี ด้วยวิทยาศาสตร์ในการวิเคราะห์ข้อมูลสมัยใหม่ เฉกเช่นเดียวกับองค์กรระดับโลก อาทิ **Amazon ,Ebay ,google, facebook ,etc.** ที่มีระบบการวิเคราะห์ข้อมูลเพื่อนำเสนอการให้บริการแบบ **Mass-customization**

ซึ่งสร้างความประทับใจให้กับลูกค้าได้มากกว่า

ไม่ว่าคุณจะเป็นนักการตลาด ผู้จัดการฝ่ายขาย นักวิเคราะห์ข้อมูล นักวางกลยุทธ์ แพทย์ วิศวกร ฯลฯ คุณก็สามารถใช้เทคนิคการวิเคราะห์ข้อมูลทางสถิติและ **Data mining** ได้ทุกวัน



# Data mining คืออะไร?

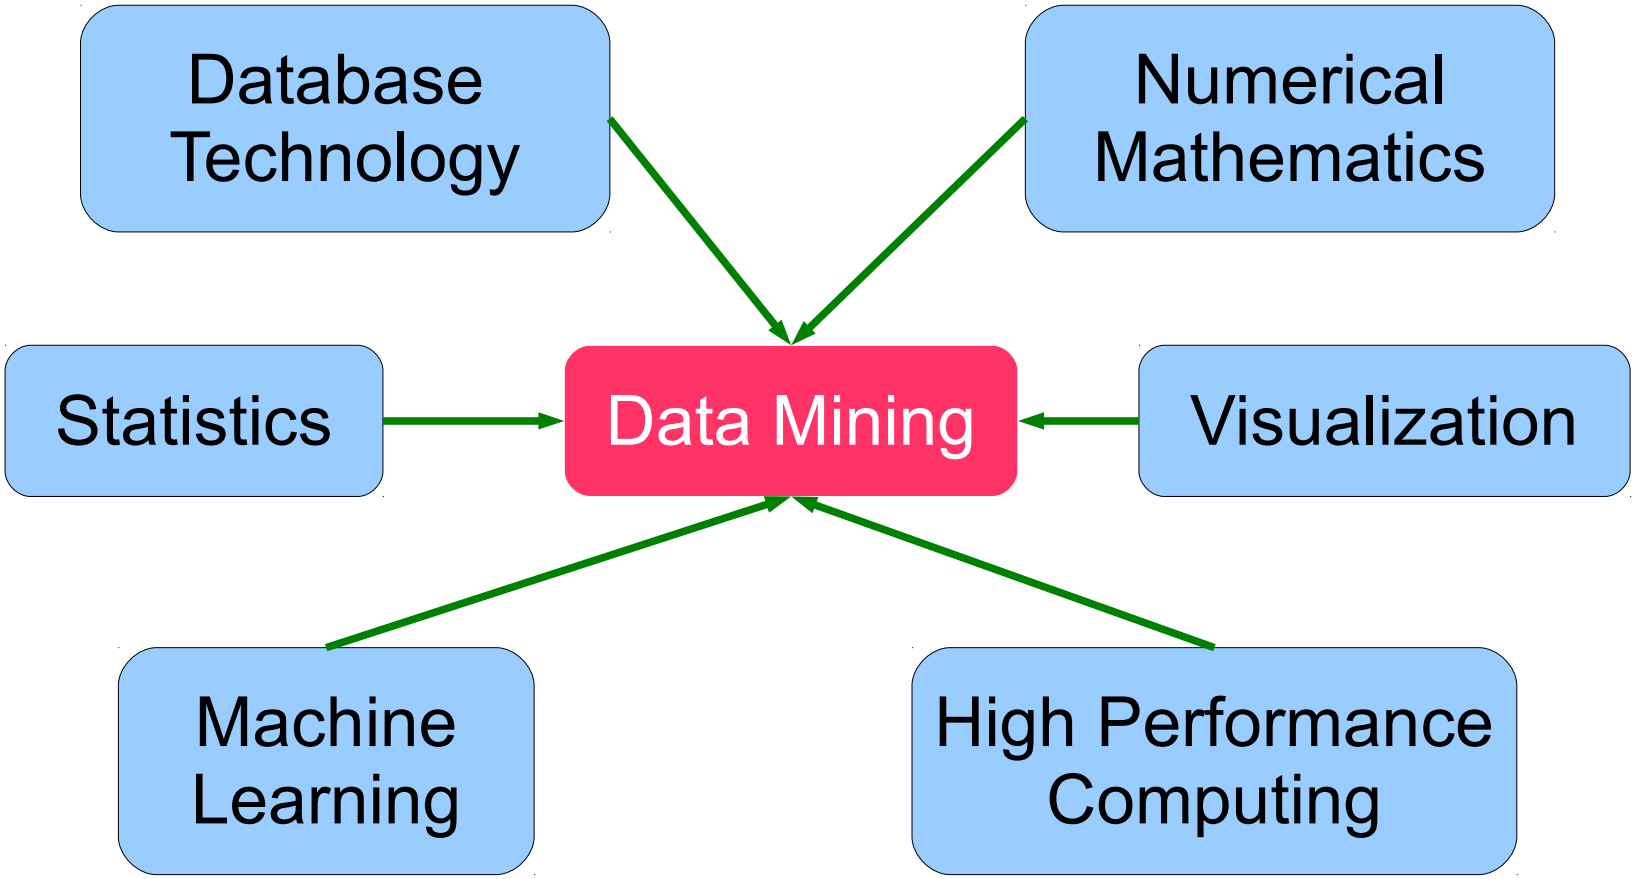
- **Knowledge discovery in database** is the non-trivial process of identifying valid, novel, potentially useful, and ultimately understandable patterns in data.
  (Fayyad, Piatetsky-Shapiro and Smyth, 1996)
- An information extraction activity whose goal is to discover hidden facts contained in databases. Using a combination of machine learning, statistical analysis, modeling techniques and database technology, data mining finds patterns and subtle relationships in data and infers rules that allow the prediction of future results. Typical applications include market segmentation, customer profiling, fraud detection, evaluation of retail promotions, and credit risk analysis.
  (http: //www.twocrows.com/glossary.htm)
  - Try also on www.google.com "data mining"

# Data mining คืออะไร?

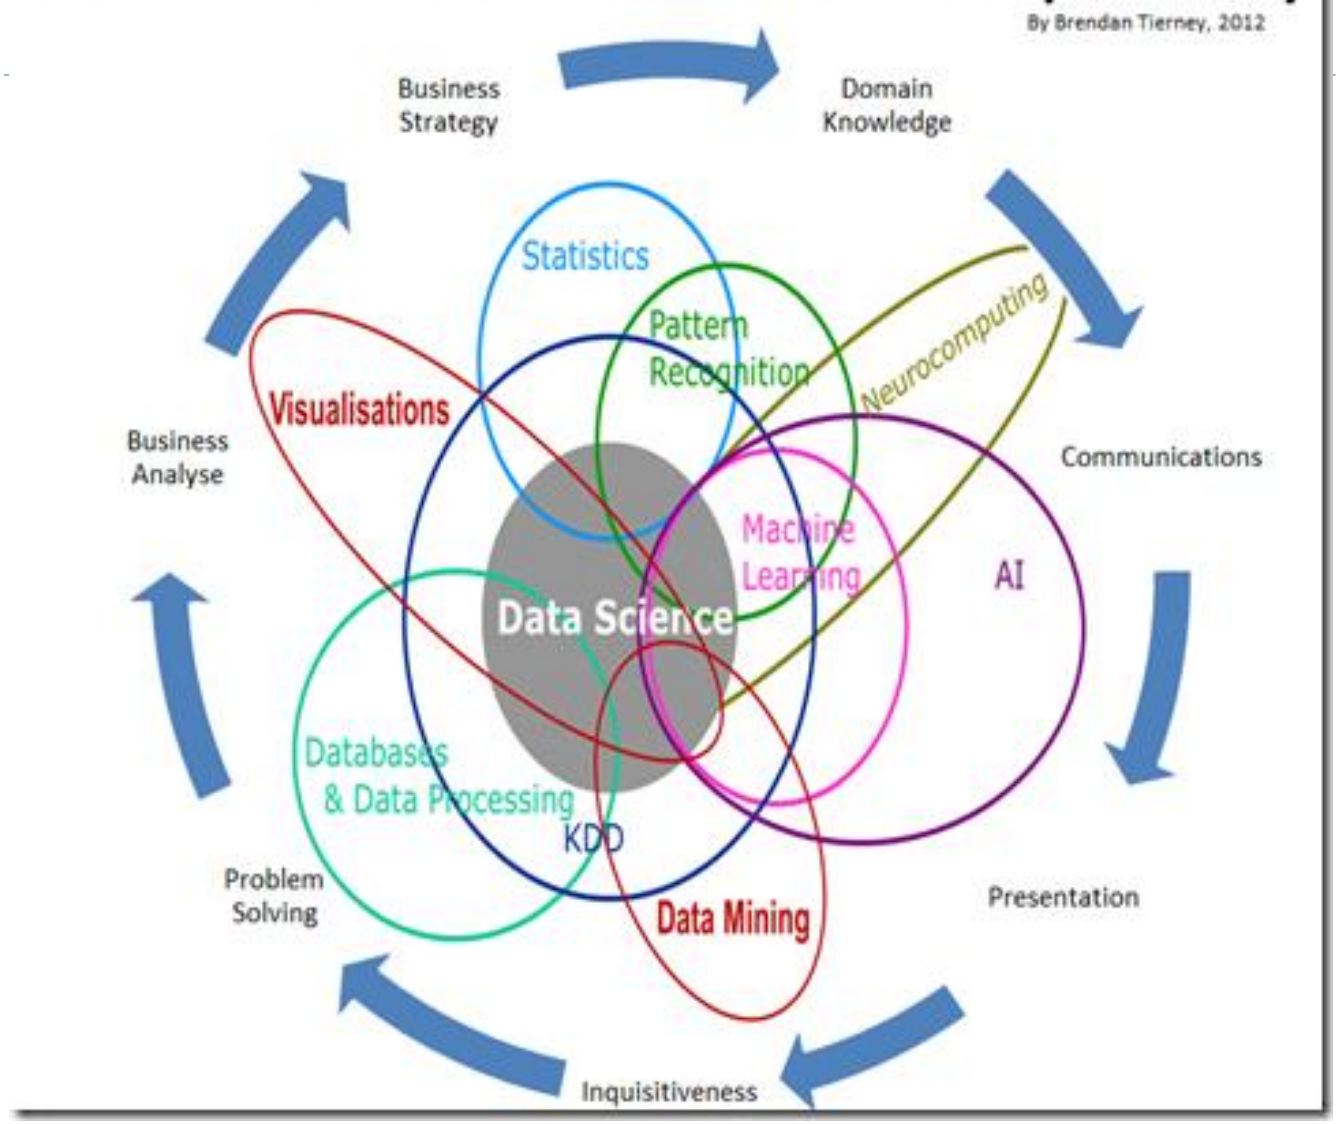
- Data mining
  - Extraction of interesting information or patterns from data in large databases
  - Data mining เป็นการค้นหาความรู้ที่เป็นประโยชน์และน่าสนใจบนฐานข้อมูลขนาดใหญ่ (Knowledge discovery from very large Databases : KDD)
  - Data mining เป็นเทคนิคที่ใช้จัดการกับข้อมูลขนาดใหญ่ เพื่อดึงความรู้ที่สำคัญออกมา



# Data mining is multi disciplinary



# Data Science Is Multidisciplinary



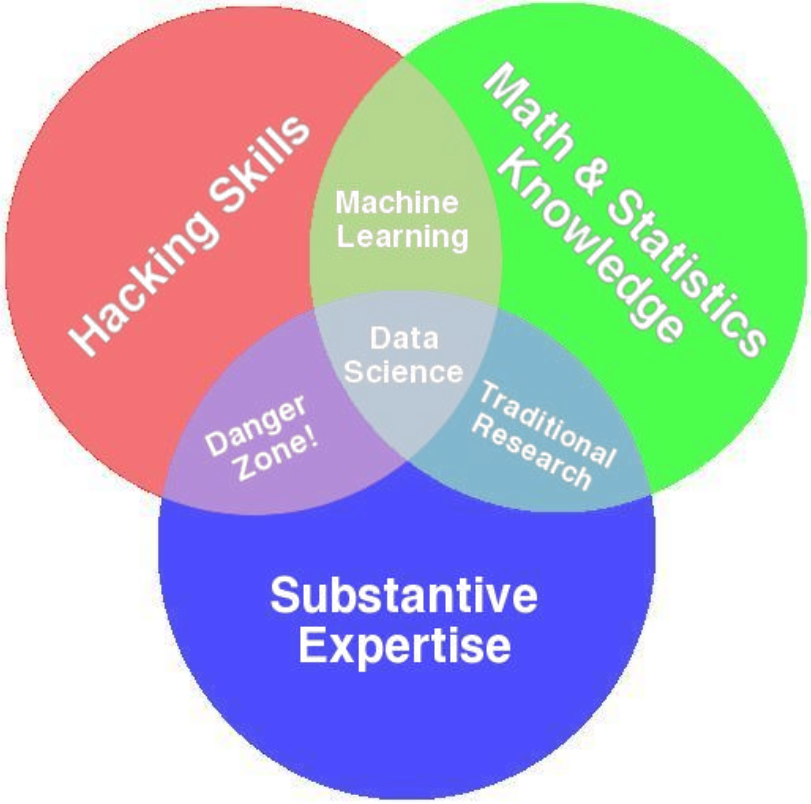

http://www.oralytics.com/2012/06/data-science-is-multidisciplinary.html

# ขยายความ Data mining

เทคโนโลยี **Data mining & Analytic** นี้นิยมใช้กันมากในองค์กรชั้นนำต่างๆ บ่อยครั้งเราจะรู้จักกันในนาม **Business Intelligence** หรือ **BI Tools.** ซึ่งมีส่วนประกอบสำคัญ 2 ประการ คือ

1. ความรู้ทาง Data Science และ
2. Data analytic Software.




source : http://www.dataists.com/2010/09/the-data-science-venn-diagram/

# ขยายความ Data mining

- Data Science ต้องใช้ความรู้ 3 ด้าน

  1. Hacking คือ ความรู้ด้านคอมพิวเตอร์ ฐานข้อมูล เพียงแค่รู้จักนำเข้าข้อมูล / ใช้ Filter /ใช้ Query ที่มีจาก Excel ,Accessโปรแกรมบัญชี ,SQL,Oracle ฯลฯ ก็ใช้ได้แล้ว

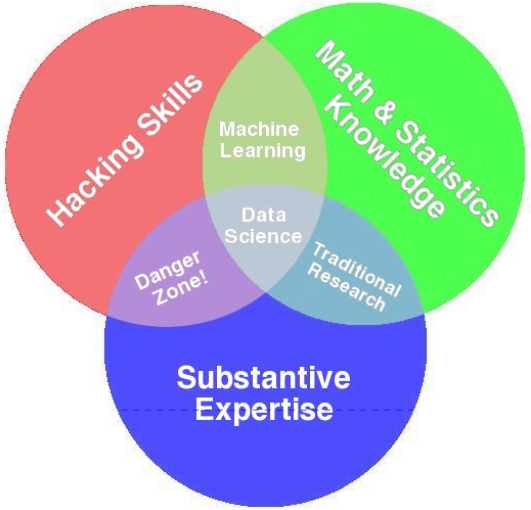
  2. Math & Statistic knowledge คือ ความรู้ด้านคณิตศาสตร์และสถิติ เพียงแค่สามารถ Run multiple regression ออกมาตีความหมายได้ก็เพียงพอแล้ว

  3. Substantive expertise คือความรู้ด้านการตีความ ความเข้าใจในปรากฏการณ์ในแบบ Real life Real world ถ้าเราอยู่กับธุรกิจหรือหน่วยงานใดๆ มาเกิน 5 ปี เราจะพบว่าตัวเรามีความชำนาญ

# ขยายความ Data mining

จาก Venn diagram นี้เราจะสังเกตเห็นส่วนซ้อนทับ (Intersection) 4 ส่วน คือ

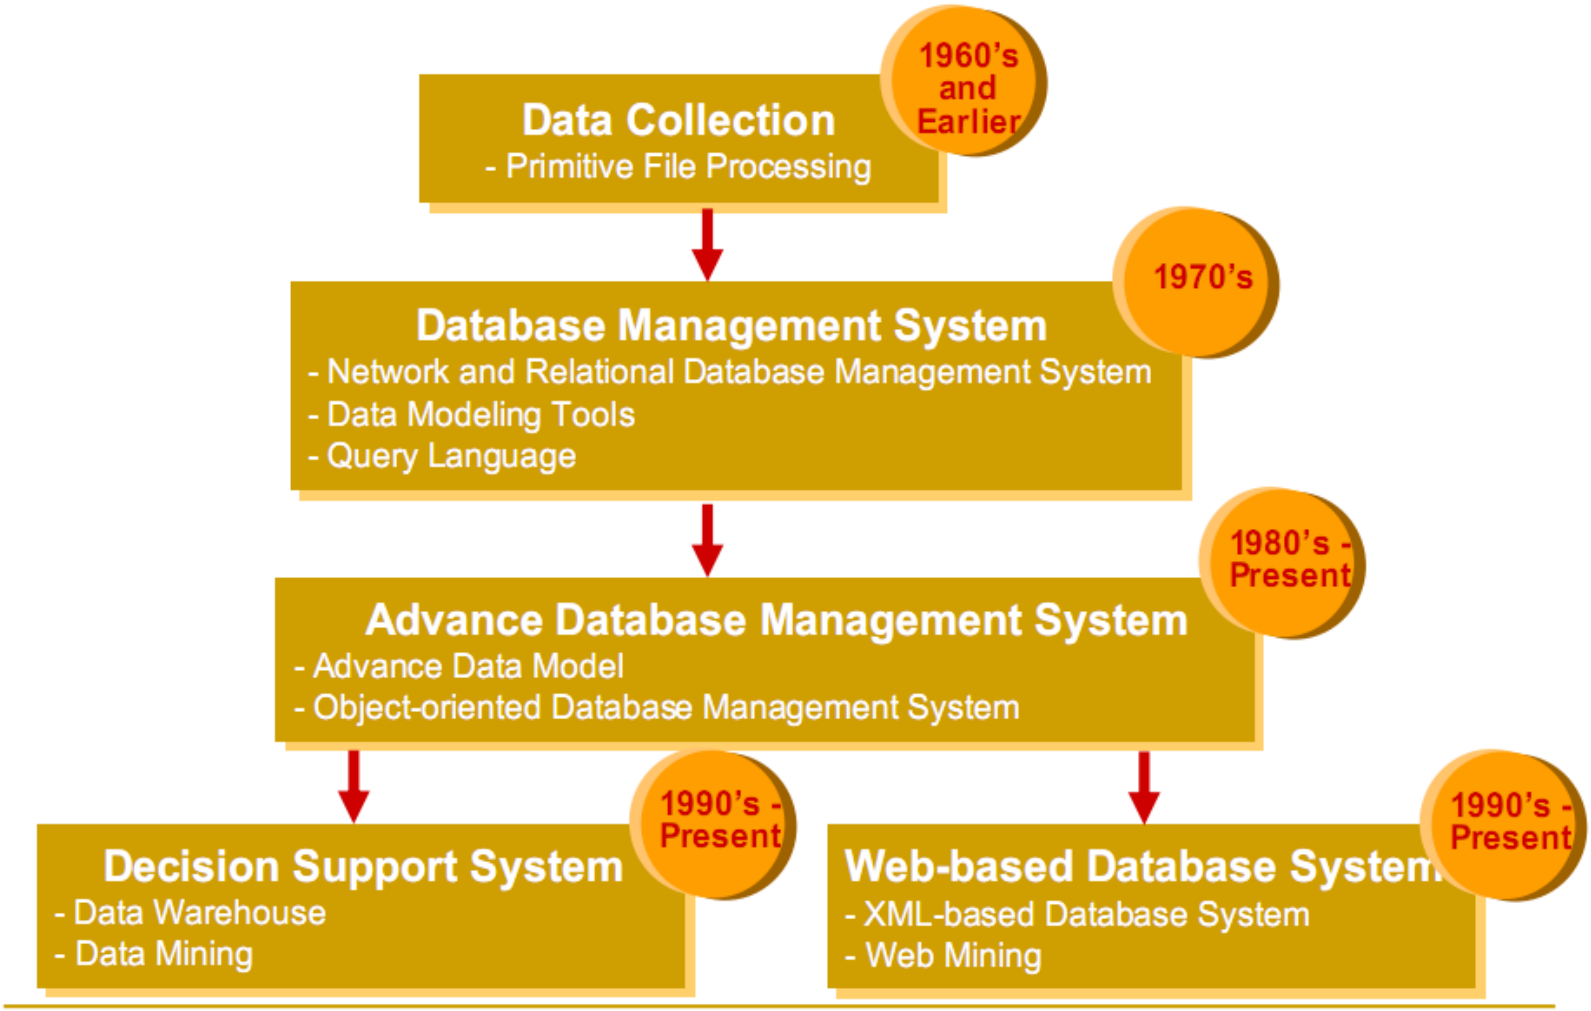
1. Machine learning คือส่วนของ Hacking กับ Math & Statistic knowledge
2. Traditional Research คือส่วนของ Math & Statistic knowledge กับ Substantive expertise
3. Danger Zone คือส่วนของ Substantive expertise กับ Hacking ผู้ที่มีความรู้แค่ 2 ด้านนี้ตกอยู่ในโซนอันตราย
4. Data science ต้องการความรู้ทั้ง 3 ด้าน คือ Hacking ,Math & Statistic knowledge & Substantive expertise



# สิ่งที่ได้จาก Data mining.

- The non-trivial extraction of novel, implicit, and actionable knowledge from large databases and in a timely manner.
- Anytime Data Mining – give me the answer now.
  - Data exploration
  - Data visualization
  - Very large data extractions
  - Data analysis
  - Hypothesis generation
  - Model building
- Knowledge.

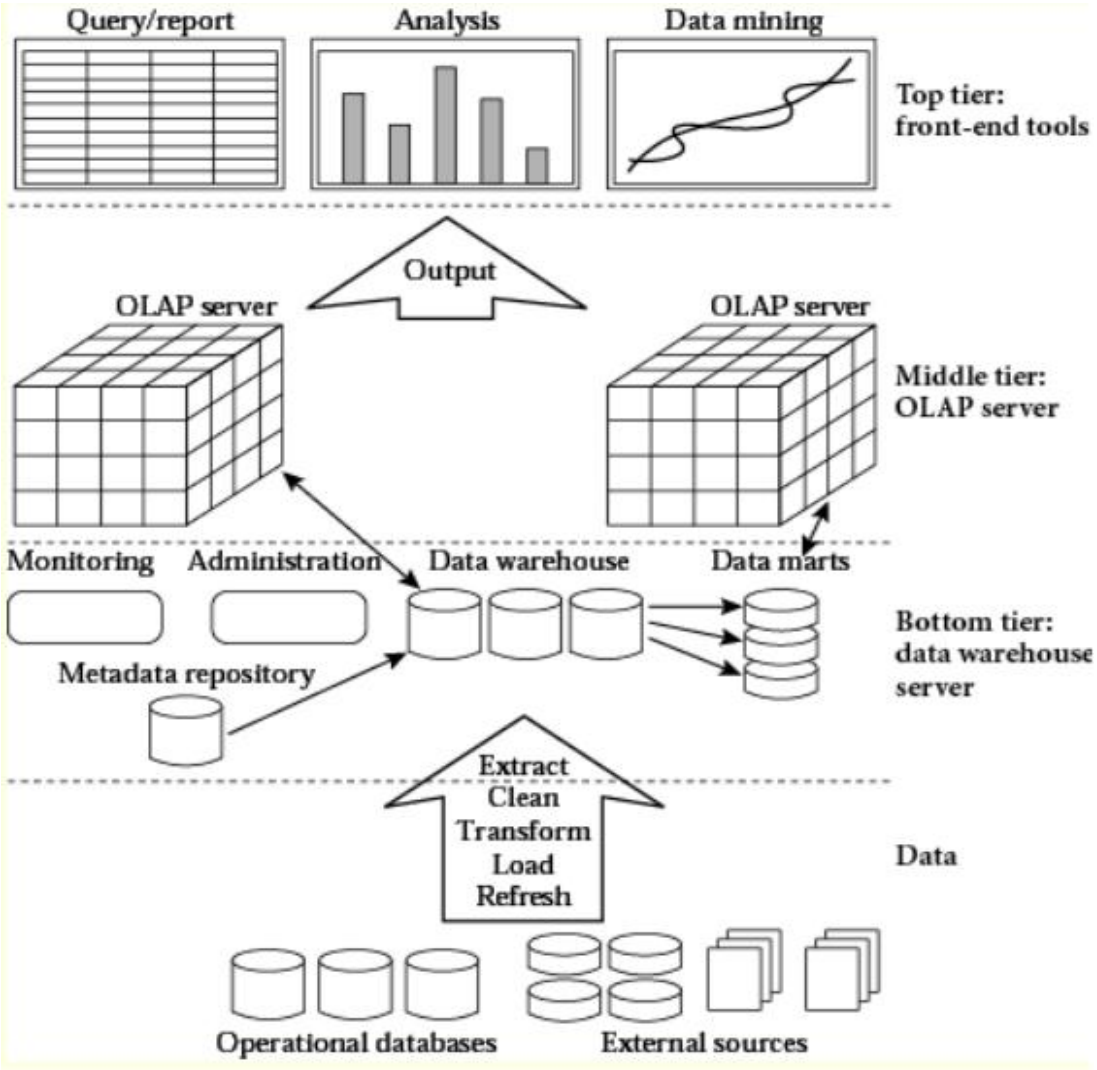
# วิวัฒนาการของการวิเคราะห์ข้อมูล บนฐานข้อมูล



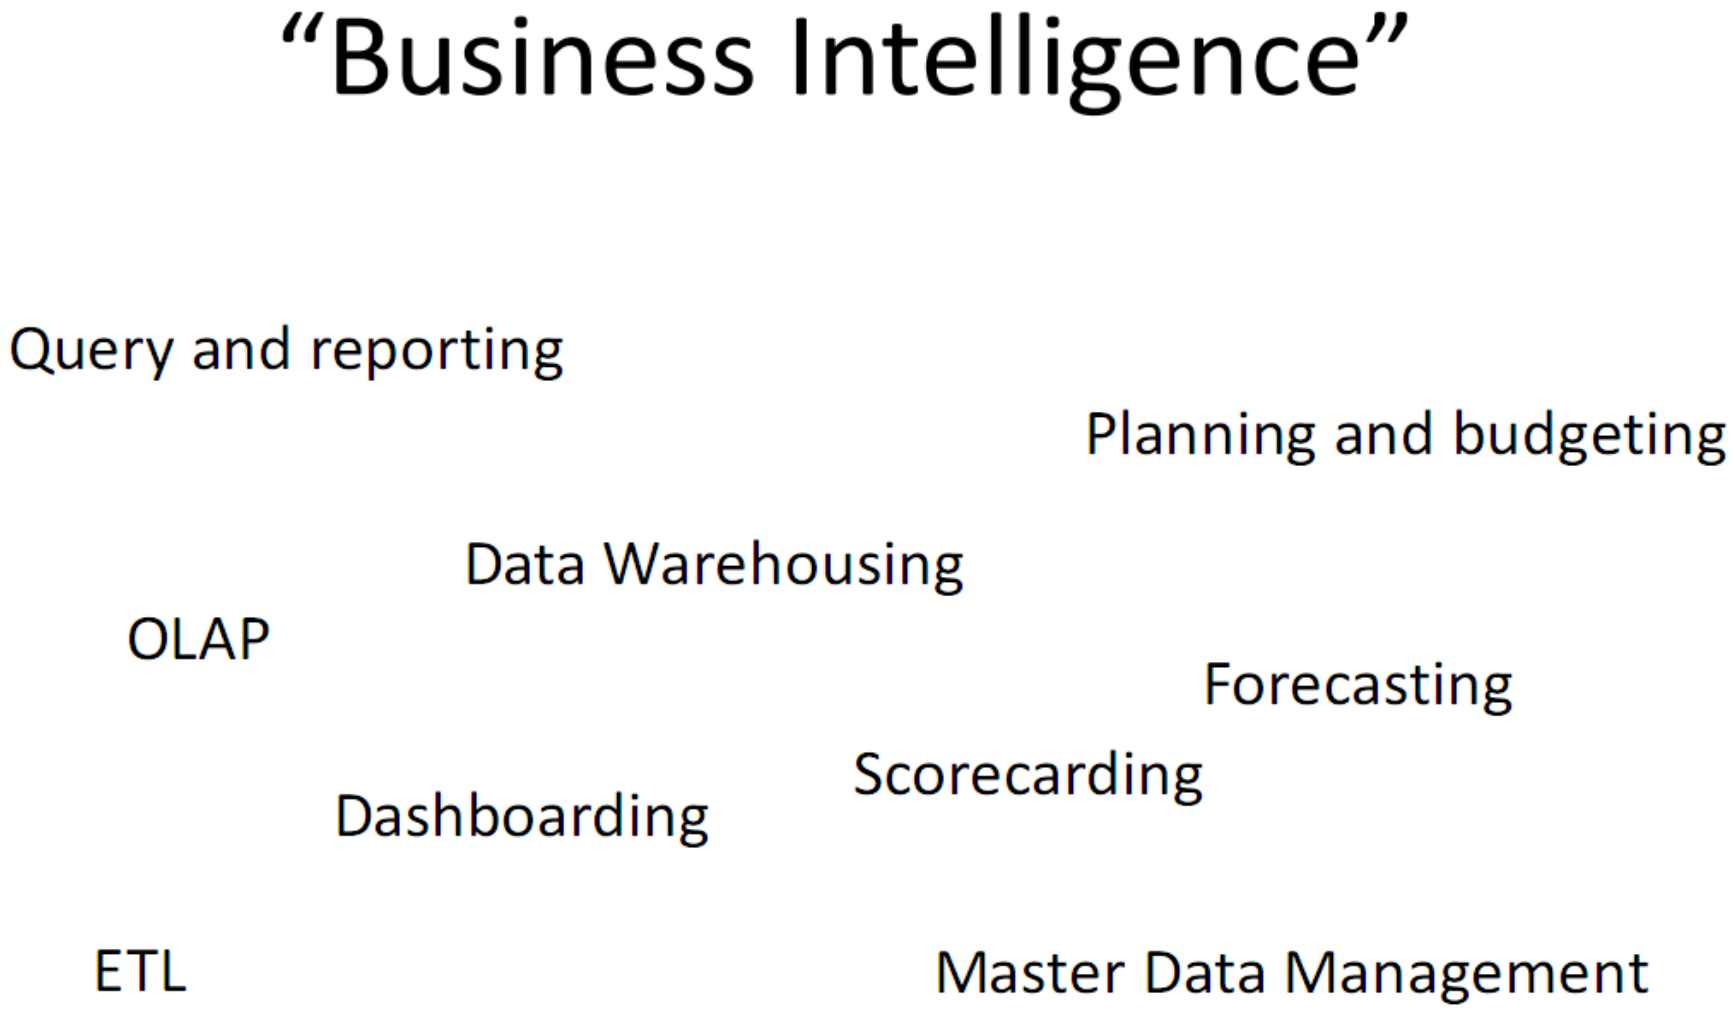



Source: refer to slide of Dr.Anantaporn Srisawat
Reinforce business intelligence Co.,Ltd.

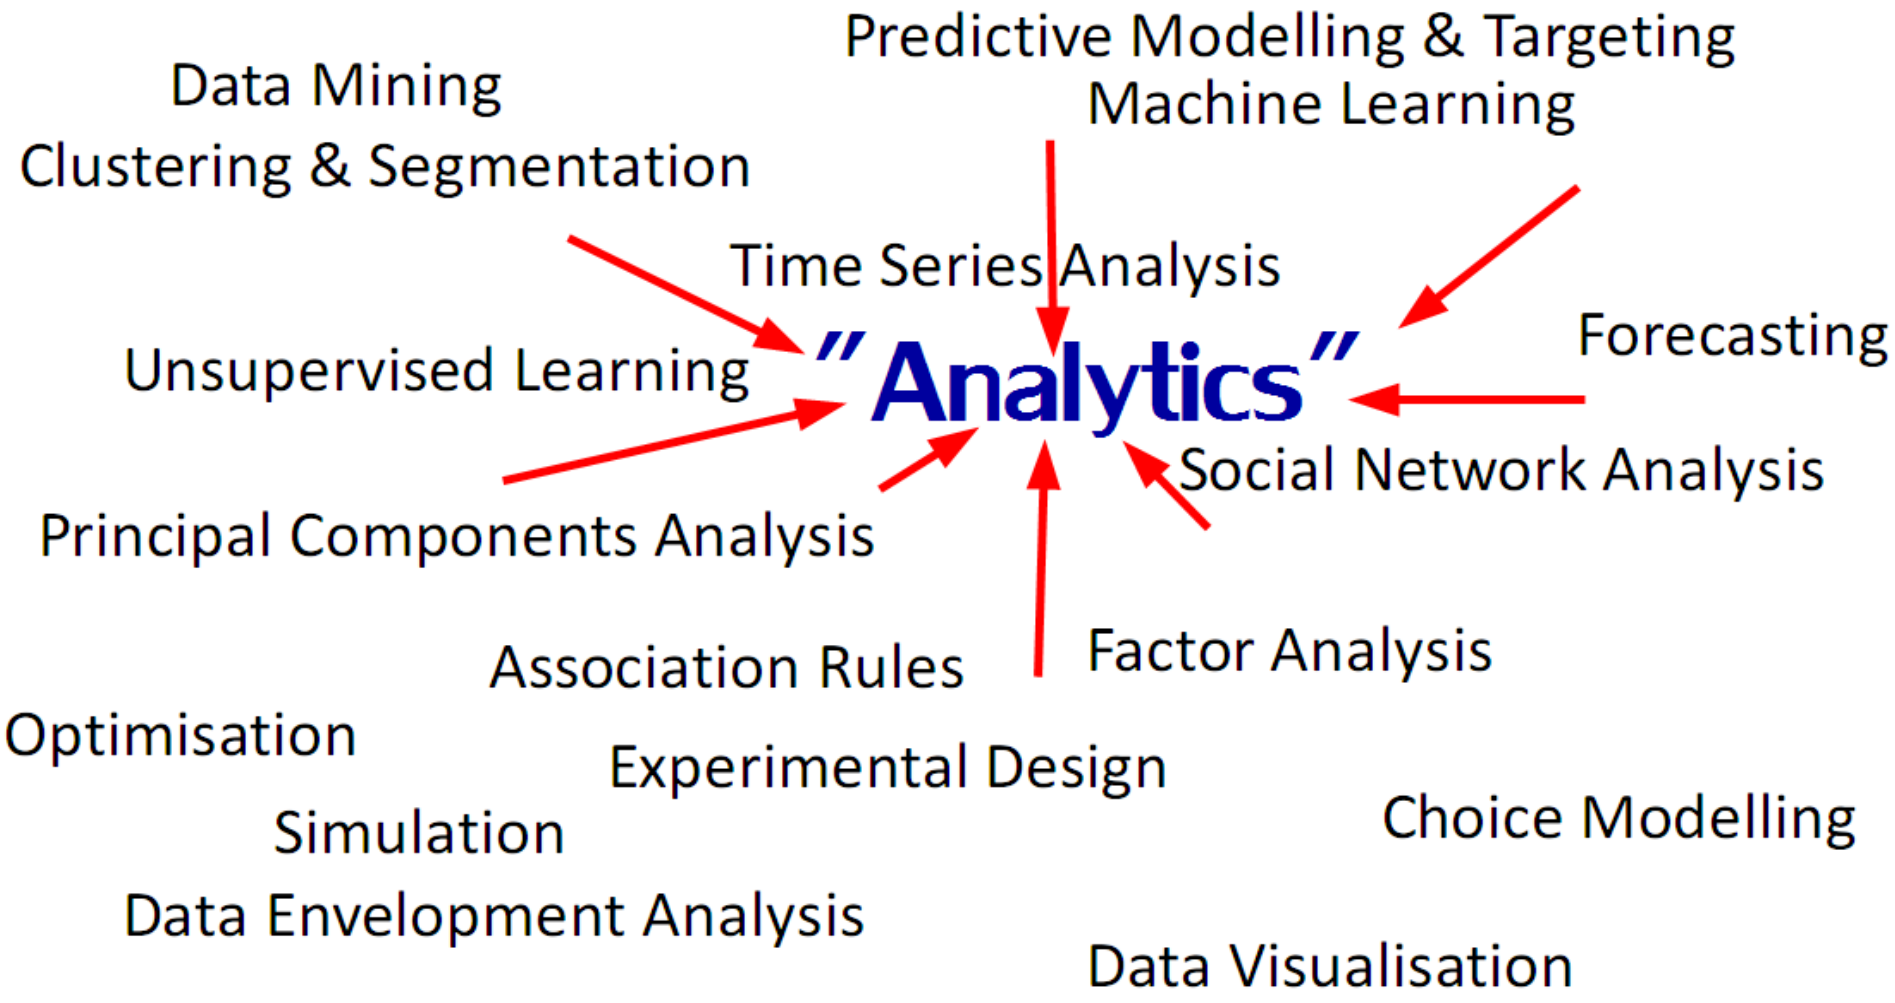
# สถาปัตยกรรมของการวิเคราะห์แบบ BI.



# Data mining and Business Intelligence.



# Data mining and Analytics.



# Data mining Algorithms.

The CRISP-DM Model

- Cross Industry Standard Process for Data Mining

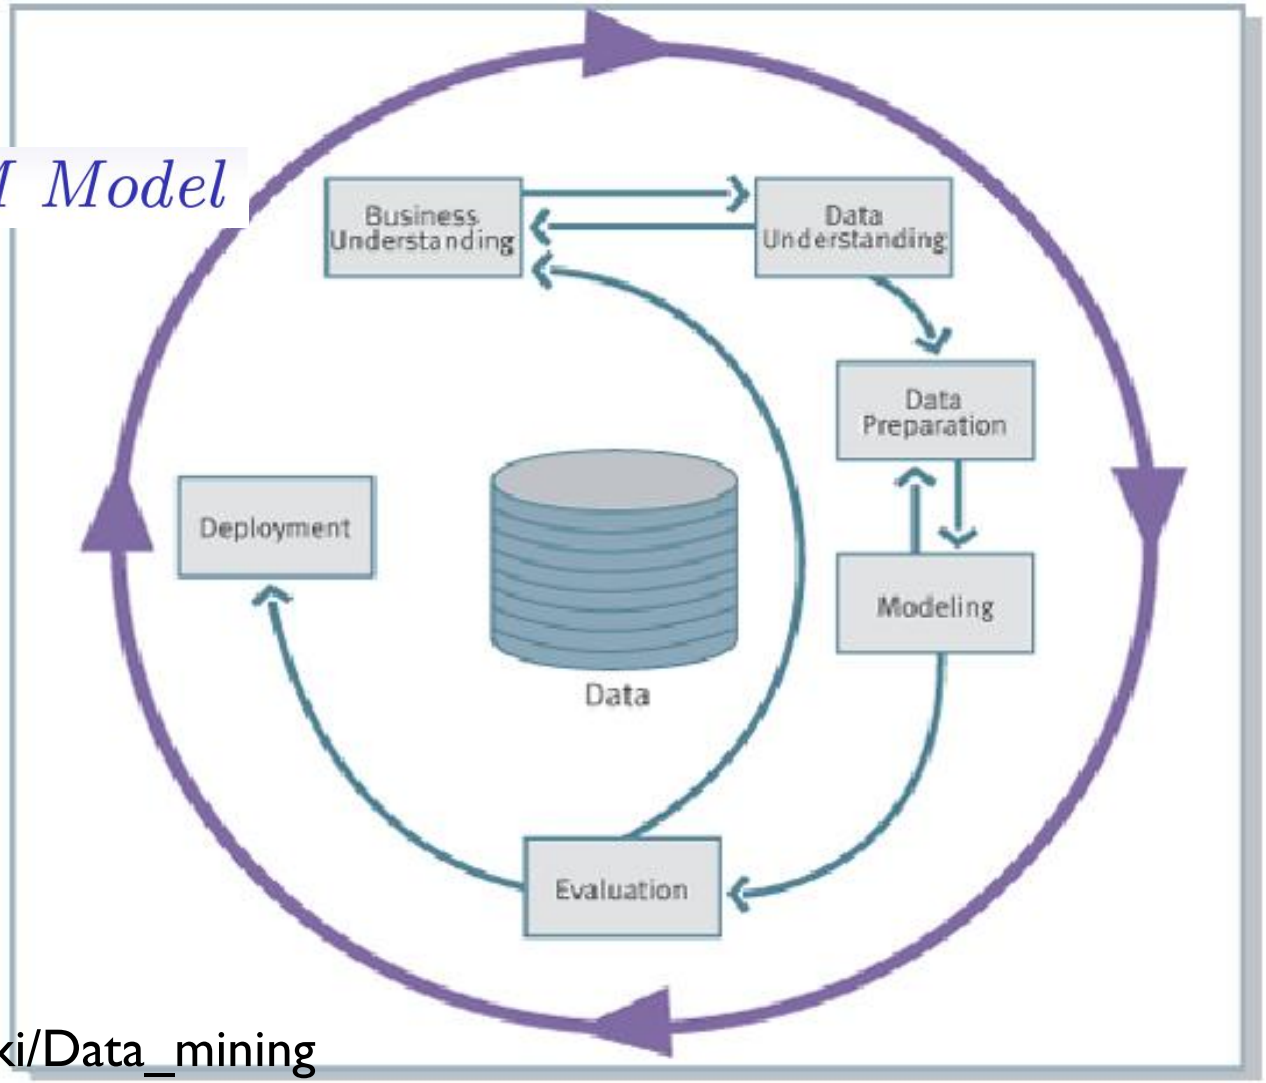
http://www.crisp-dm.org/

- Developed by NCR, Daimler-Benz, ISL, OHRA
- Define and validate a Data Mining Process Model.
  - Applicable in diverse industry sectors
  - Industry and tool neutral
  - Large data mining projects executed faster, cheaper, more reliably and more manageably
- Life cycle of six (iterative) phases.

Source: togaware

# Cyclic nature of data mining.

*The CRISP-DM Model*

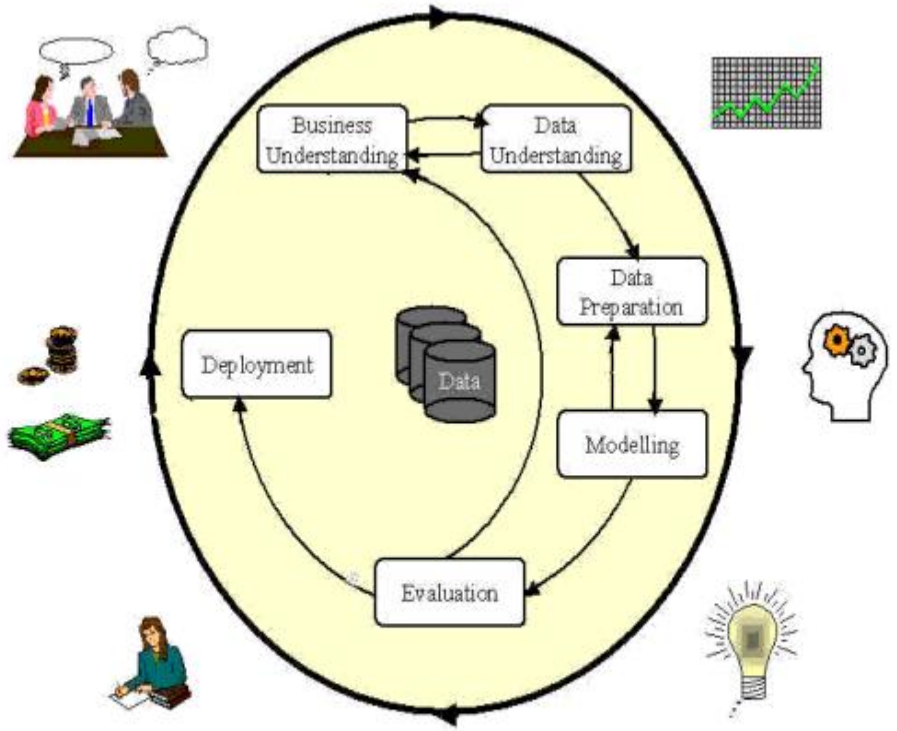



http://en.wikipedia.org/wiki/Data_mining

# Cyclic nature of data mining.

Every step of a data mining process can lead to revisiting any one of the previous steps.

A DM process continues after a solution has been deployed. The lessons learnt can trigger new, often more focused business questions. Subsequent data mining processes benefit from experiences of previous ones.




Source: togaware

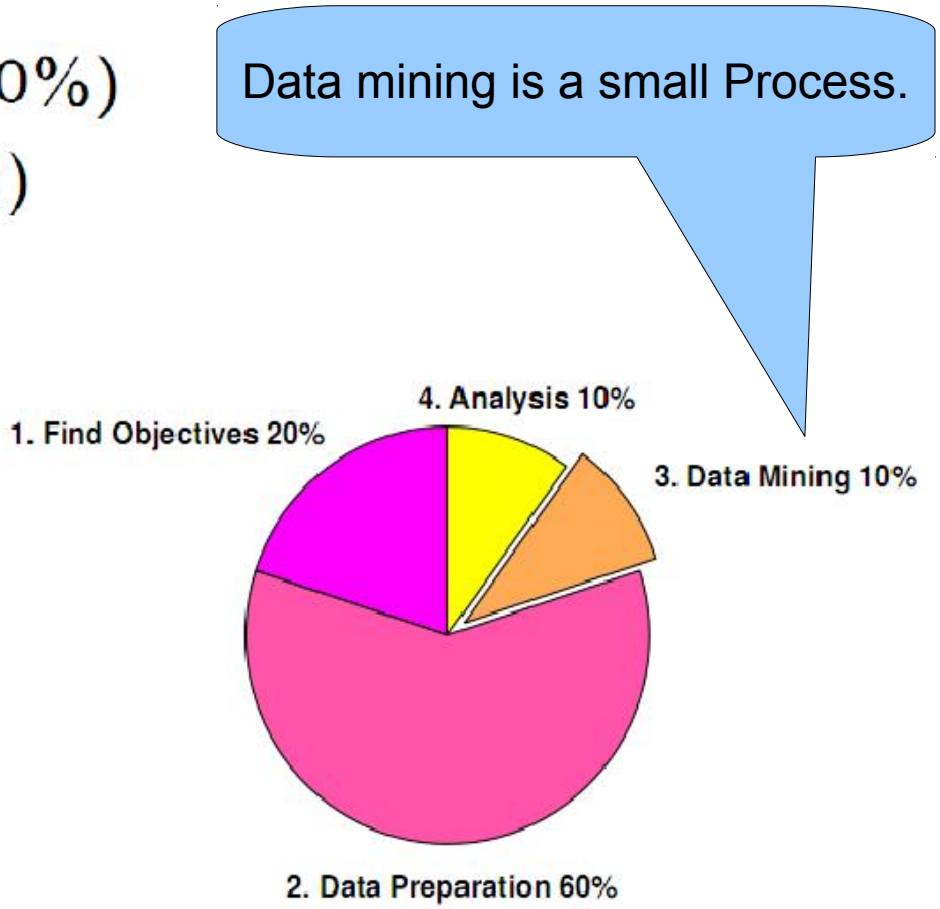
# Six steps of CRISP-DM

1. Business Understanding (25%)
2. Data Understanding (20%)
3. Data Preparation (25%)
4. Modelling (10%)
5. Evaluation (20%)
6. Deployment

Graham Williams

Principal Data Miner, ATO
Adjunct Associate Professor, ANU

## Source: togaware



# Six steps of CRISP-DM

## 1.Business Understanding

- We had better make sure we are addressing a real business problem.
  - Initial phase focuses on understanding project objectives and requirements from a business perspective.
  - This knowledge is converted into a data mining problem definition.
  - Develop a preliminary plan designed to achieve the objectives.

Source: togaware

# Six steps of CRISP-DM

## 2. Data Understanding

- Understand what data is available and its semantics.
  - Initial data collection
  - Familiarisation with the data
    - Identify data quality problems.
    - Discover first insights into the data
    - Detect interesting subsets to from hypotheses for hidden information

Source: togaware

# Six steps of CRISP-DM

## 3. Data Preparation.

- Bring together the data – get it into shape for mining.
  - Construct the mining dataset
  - Derived from the initial raw datasets
  - Data preparation tasks:
    - Table, record, and attribute selection
    - Generation of derived features
    - Data transformation
    - Data cleaning

Source: togaware

# Six steps of CRISP-DM

## 3. Data Preparation (con't)

- Issues to be dealt with include:
  - Data Quality
    - Missing data
    - Noisy data
    - Lead to inconsistent or too general / specific discoveries.
  - Data Cleaning
    - Duplicates
    - Inconsistencies
    - Identify and merge the same entities. Source: togaware

# Six steps of CRISP-DM

## 4. Modeling

- Now the "data mining" begins!!
  - Select various modeling techniques
  - Apply and calibrate modeling techniques
  - Typically there are several techniques for the same data mining problem
  - Some techniques have specific requirements on the form of data and require stepping back to the data preparation phase

Source: togaware

# Six steps of CRISP-DM

## 5. Evaluation

- How do we know we have a useful outcome?
  - Evaluate the model and review the steps executed to construct the model
  - Does the model properly achieve the business objectives?
  - Is there some important business issue that has not been sufficiently considered?
  - Decide on the use of the data mining results

Source: togaware

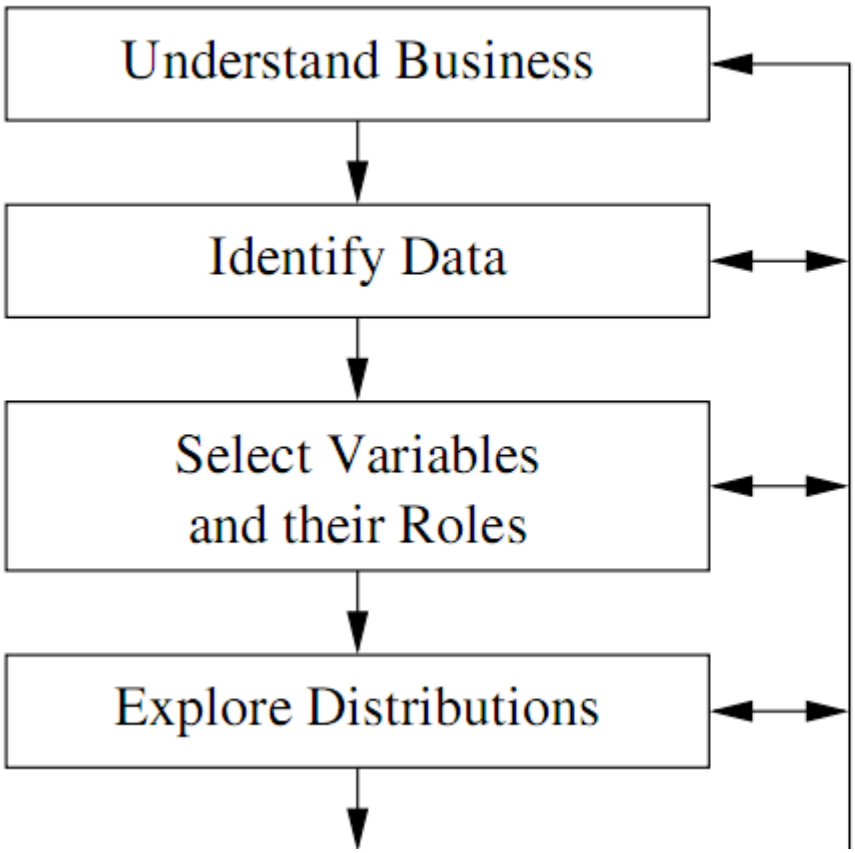
# Six steps of CRISP-DM

6. Deployment

- No point to data mining unless we action the outcomes.
  - Deployment may be:
    - Generate a report of the discoveries made
    - Implement changes in the processes of the organization
    - Implement  a repeatable data mining process
  - For successful deployment the customer must understand the actions to be carried out in order to actually make use of the created models.

Source: togaware

# Six steps of CRISP-DM (application1-2)



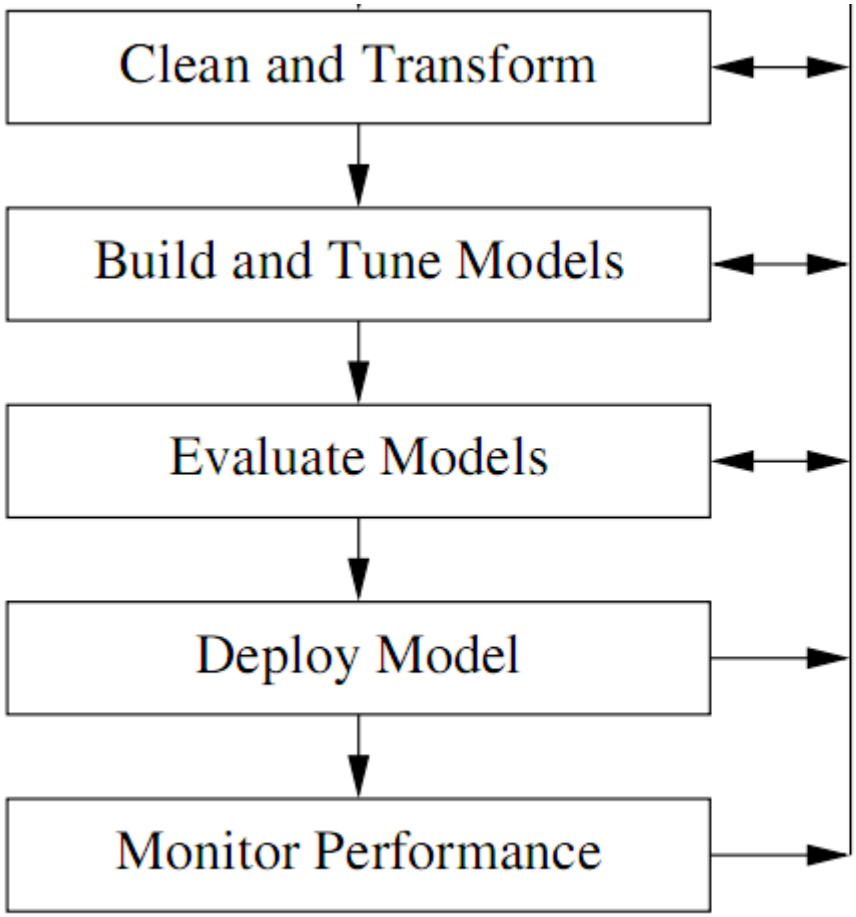

Understaning the business may itself entail a mini data mining project of a few days.

Start with getting as much data as you can and then cull.

Exploring data is important for us to understand its shape, size, and content.

Source: togaware

# Six steps of CRISP-DM (application2-2)




We may loop around here many times as we clean, transform, then build and tune our model.

Evaluate performance, structure, complexity, and deployability.

Is the model run manually on demand or automatic schedule? Is it deployed standalone or integrated into current systems?

Source: togaware

# Data Mining Strategies

- Supervised Learning
  - Process of building classification models using data instances of known origin to learning with predefined classes
  - Build models by using input attributes (independent variables) to predict output or dependent variables (class label)

- Unsupervised Learning
  - To discover natural grouping or concept structures in data
  - Without a dependent variable to guide learning process
  - Rather, it builds knowledge structures by using some measures of cluster quality to group instances into classes

# Data mining techniques

- Supervised Learning (มีการระบุค่าการทำนาย เช่น ยอดขาย (บาท) ,ซื้อ ไม่ซื้อ)
  - Classification: response is categorical
  - Regression: response is continuous
  - Time Series: dealing with observations across time
  - Optimization: minimize or maximize some characteristic

- Unsupervised Learning (ไม่มีการระบุค่าของผลลัพธ์ เช่น ลักษณะของดอกไม้)
  - Principal Component Analysis : feature reduction
  - Clustering: grouping like objects together
  - Association and link Analysis: descriptive approach to exploring data that helps identify relationships among values in a database, e.g. Market basket analysis, those customers that buy hammers also buy nails. Examine conditional probabilities.

# A machine learning perspective

- Artificial Intelligence to model the world
- Unsupervised Learning
  - Cluster Analysis
  - Association Analysis
- Supervised Learning
  - Decision Trees
  - Random forest, Ensembles
  - Support Vector Machines
  - Neural Networks

# Data mining Applications (1 of 3)

- Database analysis and decision support
  - Market analysis and management
    - Target marketing
      - Find clusters of "model" customers who share the same characteristics: interest, income level, spending habits, etc.
    - Market basket analysis
      - Find the relationship between product sales
    - Customer profiling
      - Data mining can tell you what types of customers buy what products (clustering or classification)
    - Identifying customer requirements
      - Identifying the best products for different customers
      - Use prediction to find what factors will attract new customers

# Data mining Applications (2 of 3)

- Database analysis and decision support
  - Risk analysis and management
    - Resource planning
    - Competition
      - Monitor competitors and market directions
      - Set pricing strategy in a highly competitive market
    - Finance planning and asset evaluation
      - Time series analysis
  - Fraud detection and management
    - Auto insurance
    - Money laundering
    - Medical insurance
    - Credit card fraud
    - Detecting telephone fraud

# Data mining Applications (3 of 3)

- Other Applications
  - Text mining (news group, email, documents) and Web analysis.
  - Medicine: disease outcome, effectiveness of treatments
    - Analyze patient disease history: find relationship between diseases
  - Sports
    - IBM Advanced Scout analyzed NBA game statistics (shots blocked, assists, and fouls) to gain competitive advantage for New York Knicks and Miami Heat
  - Astronomy
    - JPL and the Palomar Observatory discovered 22 quasars with the help of data mining
  - Web site/store design and promotion
    - Find affinity of visitor to pages and modify layout
  - Molecular/Pharmaceutical
    - Identify new drugs

# Data mining/analytic tools.

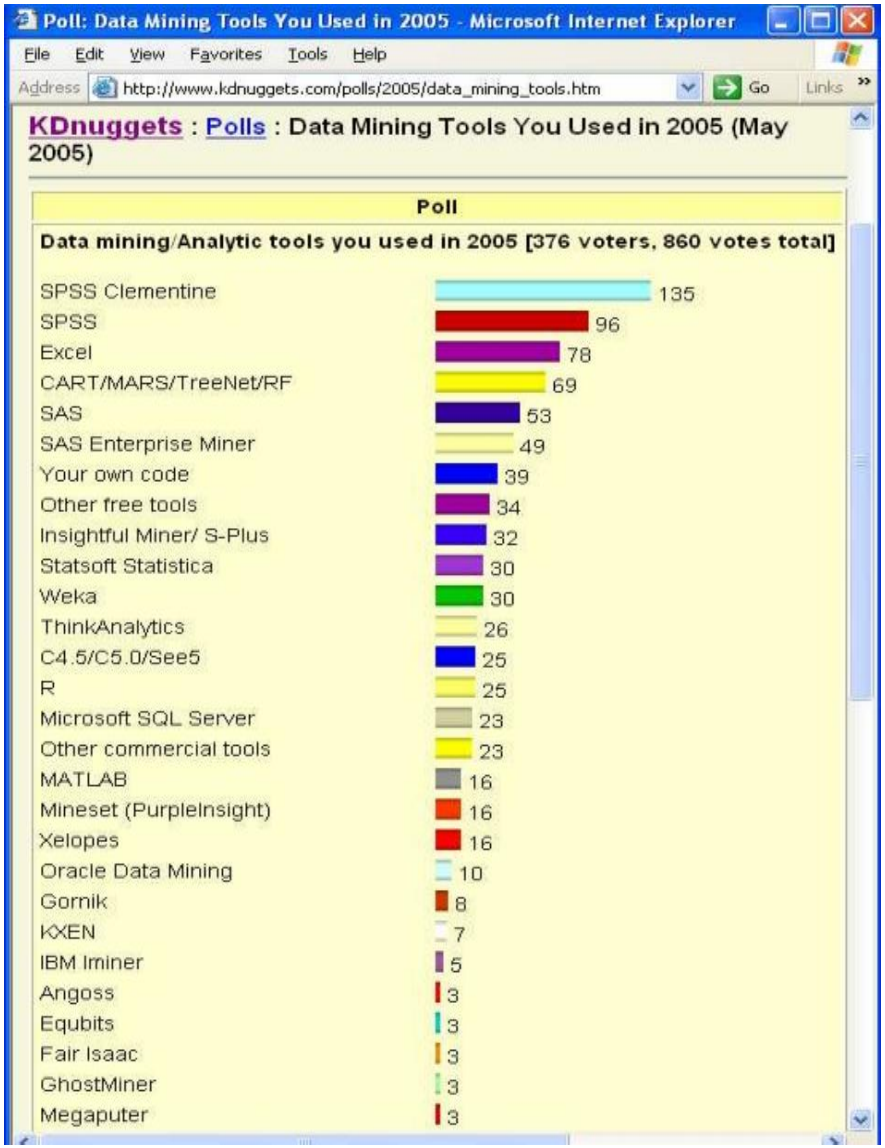


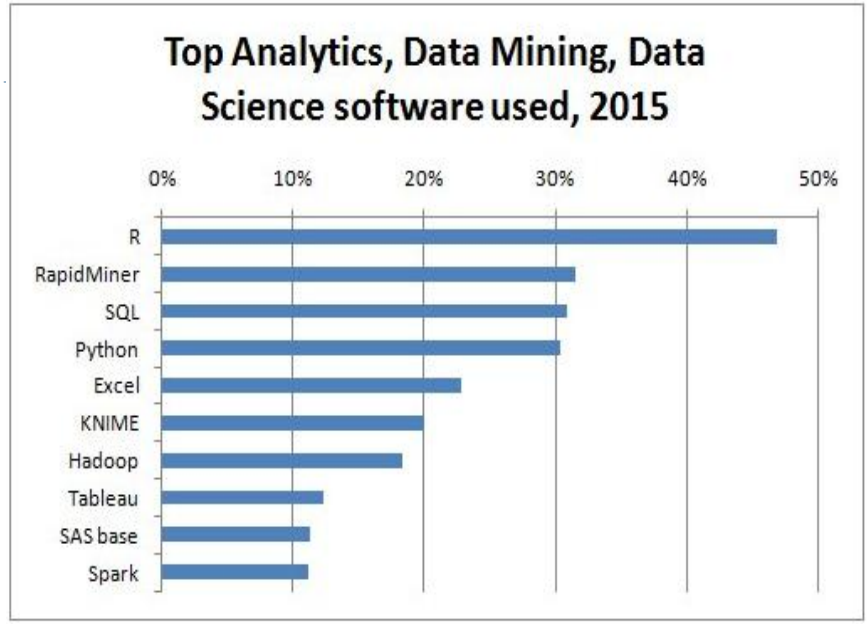

The little known Open Source.



# Data mining/analytic tools at 2015





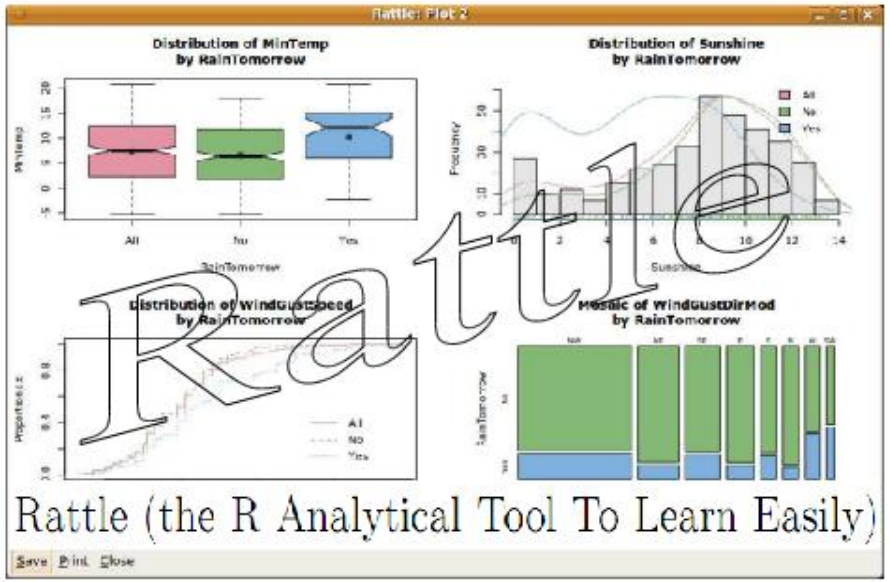

**The top 10 tools by share of users were**

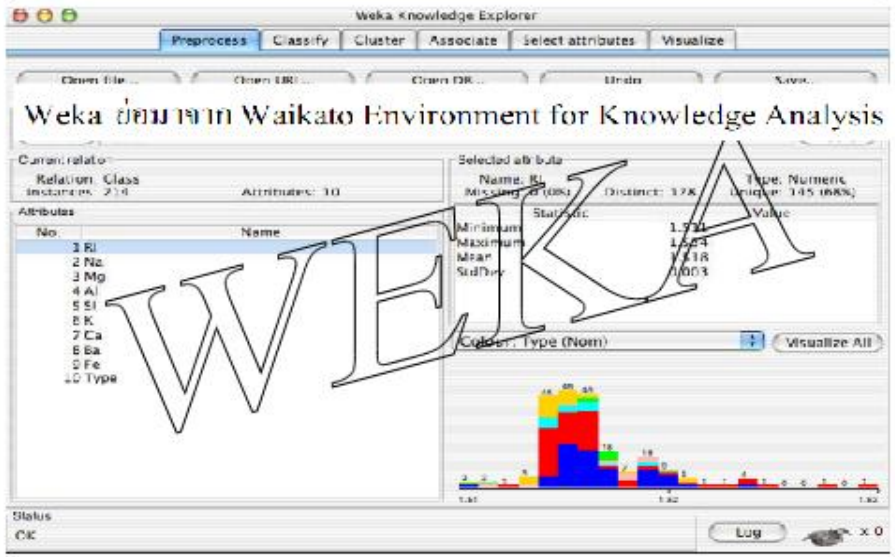
1. **R**, 46.9% share ( 38.5% in 2014)
2. **RapidMiner**, 31.5% ( 44.2% in 2014)
3. **SQL**, 30.9% ( 25.3% in 2014)
4. **Python**, 30.3% ( 19.5% in 2014)
5. **Excel**, 22.9% ( 25.8% in 2014)
6. **KNIME**, 20.0% ( 15.0% in 2014)
7. **Hadoop**, 18.4% ( 12.7% in 2014)
8. **Tableau**, 12.4% ( 9.1% in 2014)
9. **SAS**, 11.3 (10.9% in 2014)
10. **Spark**, 11.3% ( 2.6% in 2014)

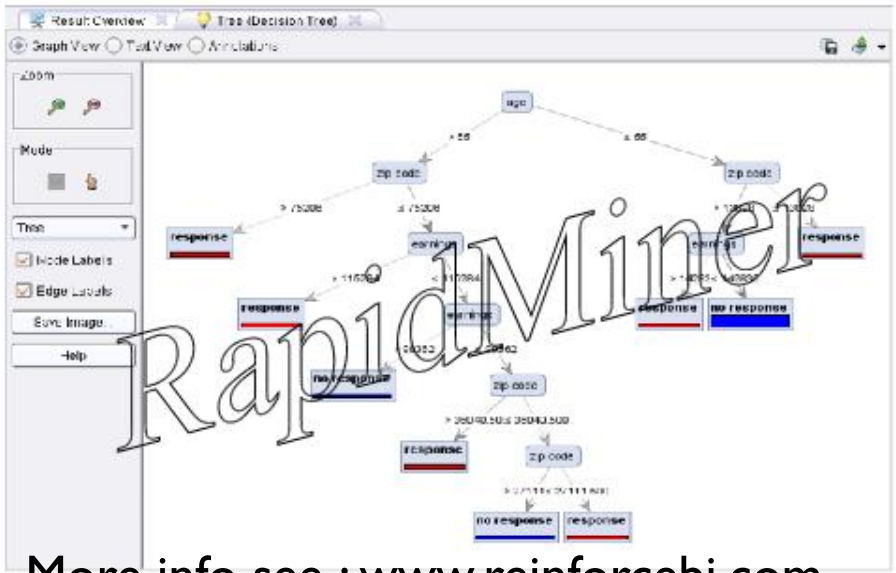
http://www.kdnuggets.com/polls/2015/analytics-data-mining-data-science-software-used.html

# Data mining/analytic tools. (Open source)

Reinforce BUSINESS INTELLIGENCE™
www.reinforcebi.com




More info see : www.reinforcebi.com

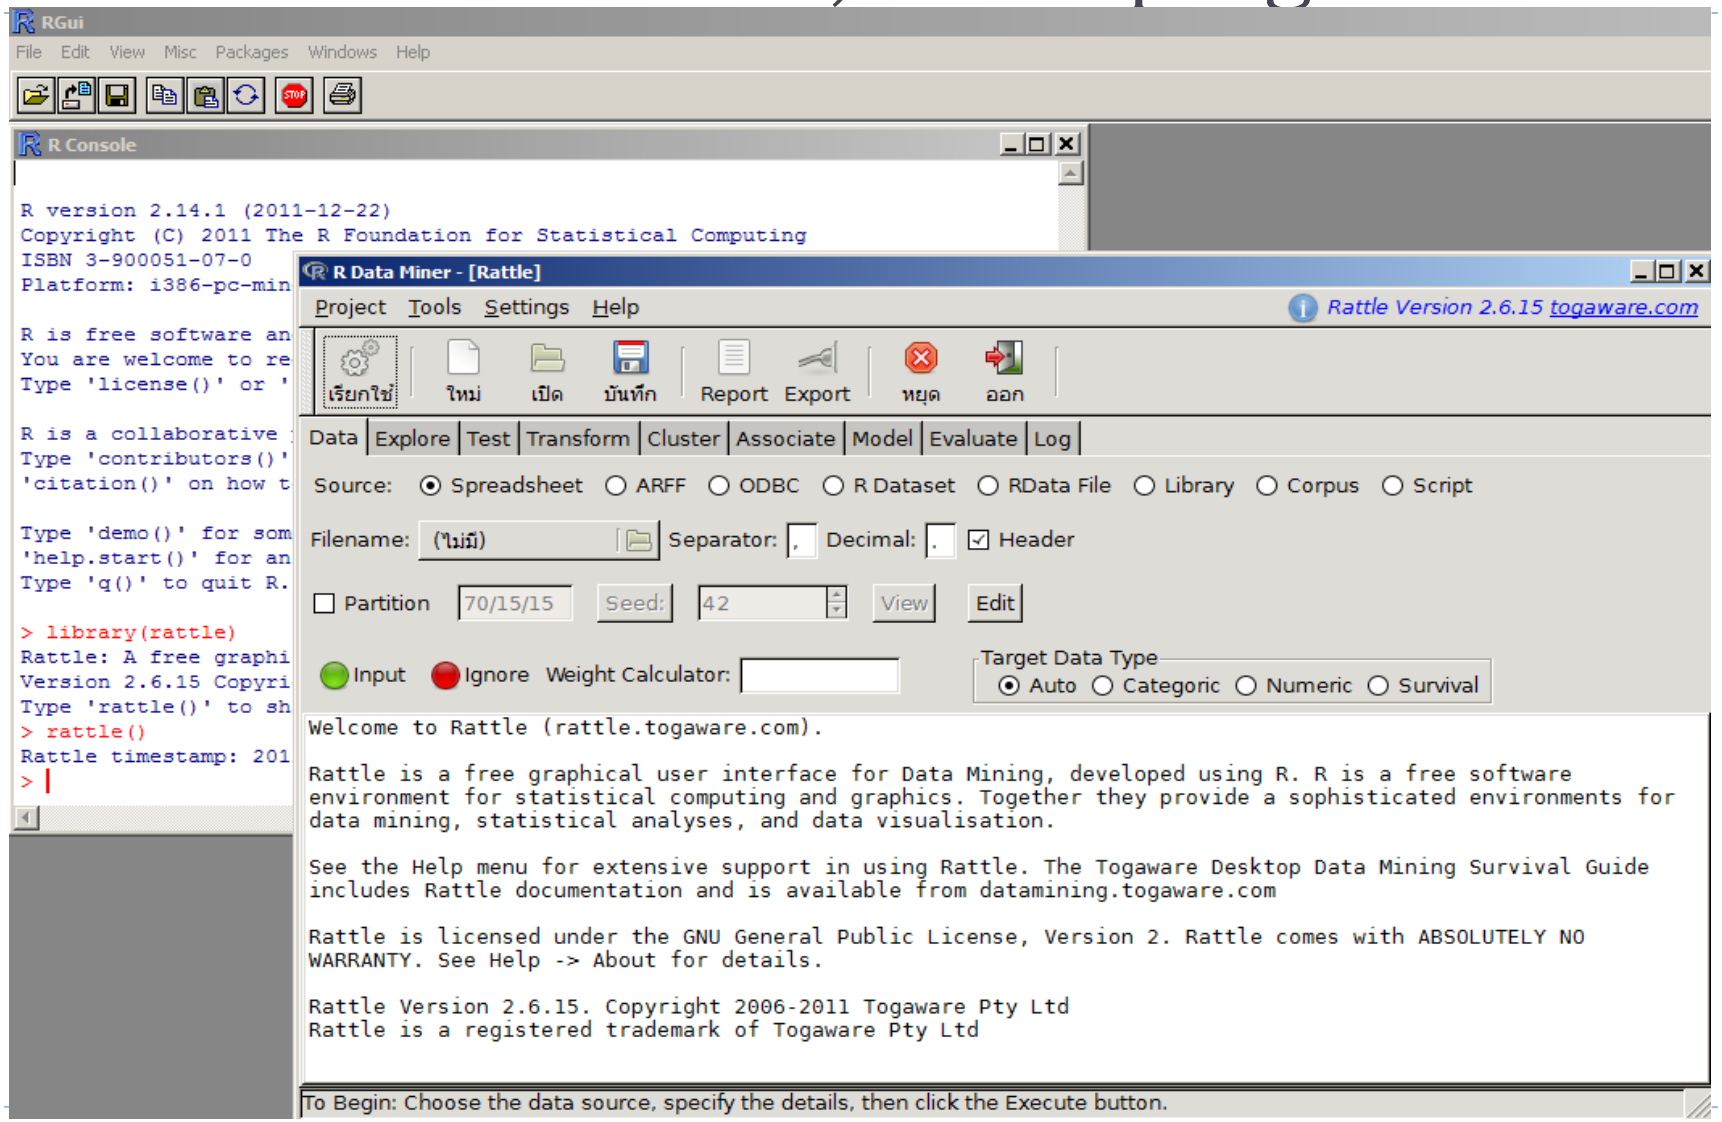


# Why you learn Data Mining?.

Data Mining is now one of the most important core technologies being developed today, along with medical research, energy research, and environmental research.

(source: togaware)

# 2.Introduction to R ,Rattle program.



# 2.Introduction to R ,Rattle program.

- **R** is the most sophisticated statistical software available, easily installed ,instructional, state-of-the-art, and it is free and open source.

- **Rattle** is a graphical data mining application built upon the statistical language R.

- **Rattle** is simple to use, quick to deploy, and allows us to rapidly work through the data processing , modeling ,and evaluation phases of a data mining project.

# 2.Introduction to R ,Rattle program.

## Technology.



- Originally tooled up with commercial, expensive, data mining tools (SAS/EM, Teradata Warehouse Miner) and hardware (Big Iron MS/Windows 32 bit).
- But data mining needs skilled people, not off the shelf solutions (yet).
- Also data mining technology is rapidly developing, and commercial vendors have difficulty keeping up.

# 2.Introduction to R ,Rattle program.

## Technology.

- Originally tooled up with commercial, expensive, data mining tools (SAS/EM, Teradata Warehouse Miner) and hardware (Big Iron MS/Windows 32 bit).
- But data mining needs skilled people, not off the shelf solutions (yet).
- Also data mining technology is rapidly developing, and commercial vendors have difficulty keeping up.



# 2.Introduction to R ,Rattle program.

## New Approaches Ensembles.

Commercial software is lagging behind advances in Data Mining

- Current best off the shelf technology includes random forests, boosting and support vector machines - SAS/EM?
- Open source solutions allow investment in people, not software.



# 2.Introduction to R ,Rattle program.

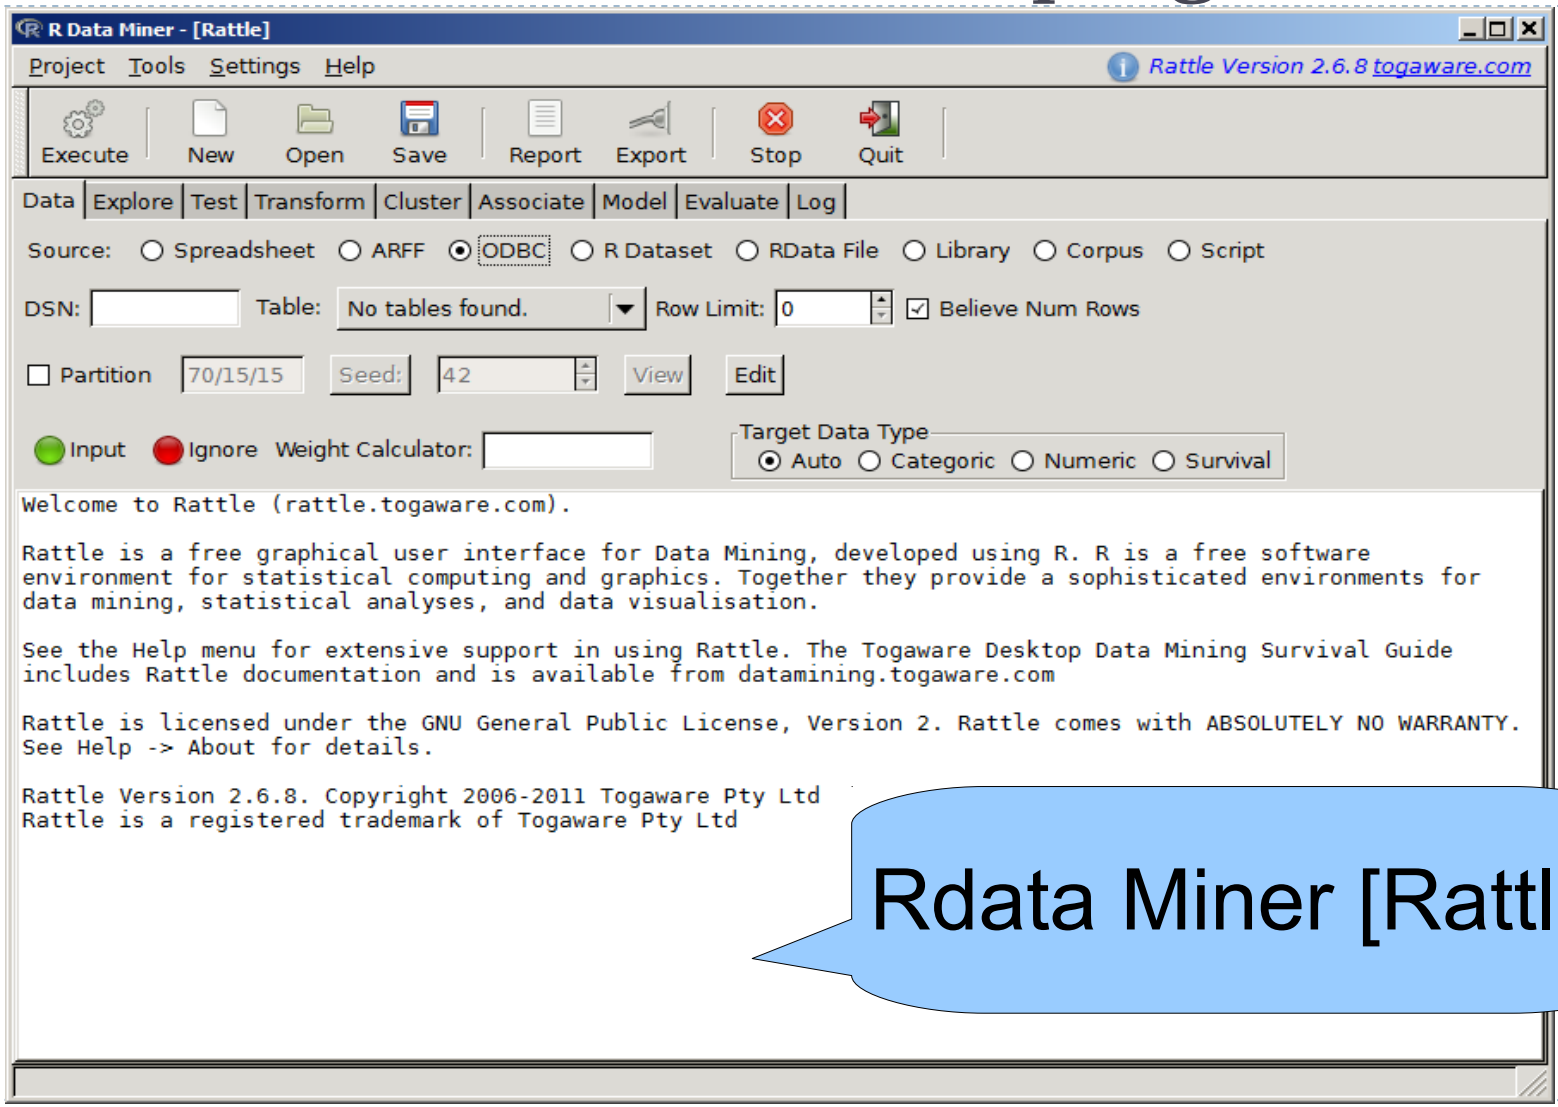
Build a network of DataMining Nodes:

- 1 CPU (2 Cores), AMD64, 16GB RAM, 300GB Disk
- 4 CPU (8 Cores), AMD64, 32GB RAM, 1TB Disk (Optimal)
- 8 CPU (16 Cores), AMD64, 128GB RAM, 10TB Disk (Near Term)



- Best of class open source operating system (Debian GNU/Linux)
- Open Source data mining tools R, Rattle, Weka, AlphaMiner
- Open Source does deliver quality software

# 2.Introduction to R ,Rattle program.




Rdata Miner [Rattle]

# 2.Introduction to R ,Rattle program.

A self contained tool for data mining

1. Start Rattle
2. Explore the interface
3. Load sample audit dataset
4. Explore the data: Summary, Plots, GGobi, Correlations
5. Transform the data: Rescale, Impute, Remap
6. Cluster, Associate
7. Predictive Model
8. Evaluate and Score
9. Log

Rdata Miner [Rattle]

# 2.Introduction to R ,Rattle program.

- Togaware
  http://datamining.togaware.com

Other Data Mining Open Source.

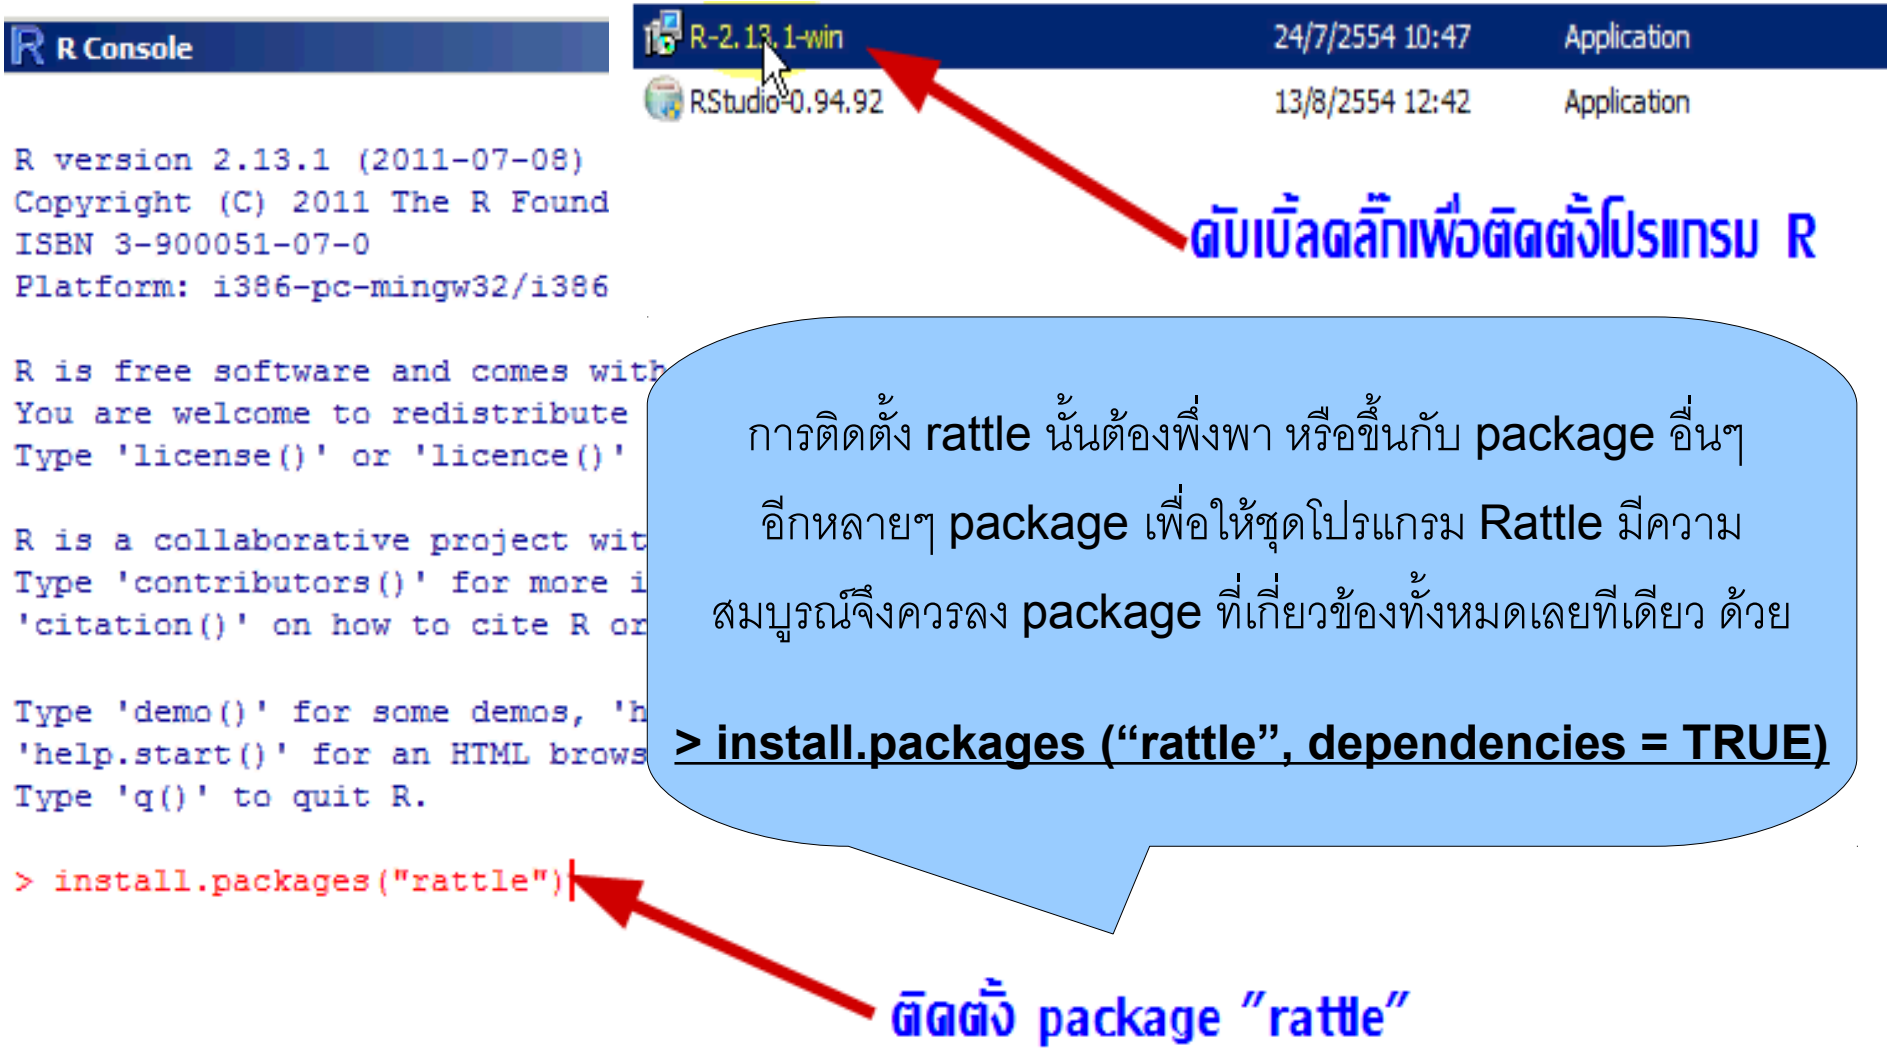
- Tools:
  - rattle.togaware.com
  - www.cs.waikato.ac.nz/ml/weka/
  - www.knime.org
  - rapid-i.com

Reinforce BI.
เปิดอบรมทุกโปรแกรม
08 1491 0909

# Rattle Training

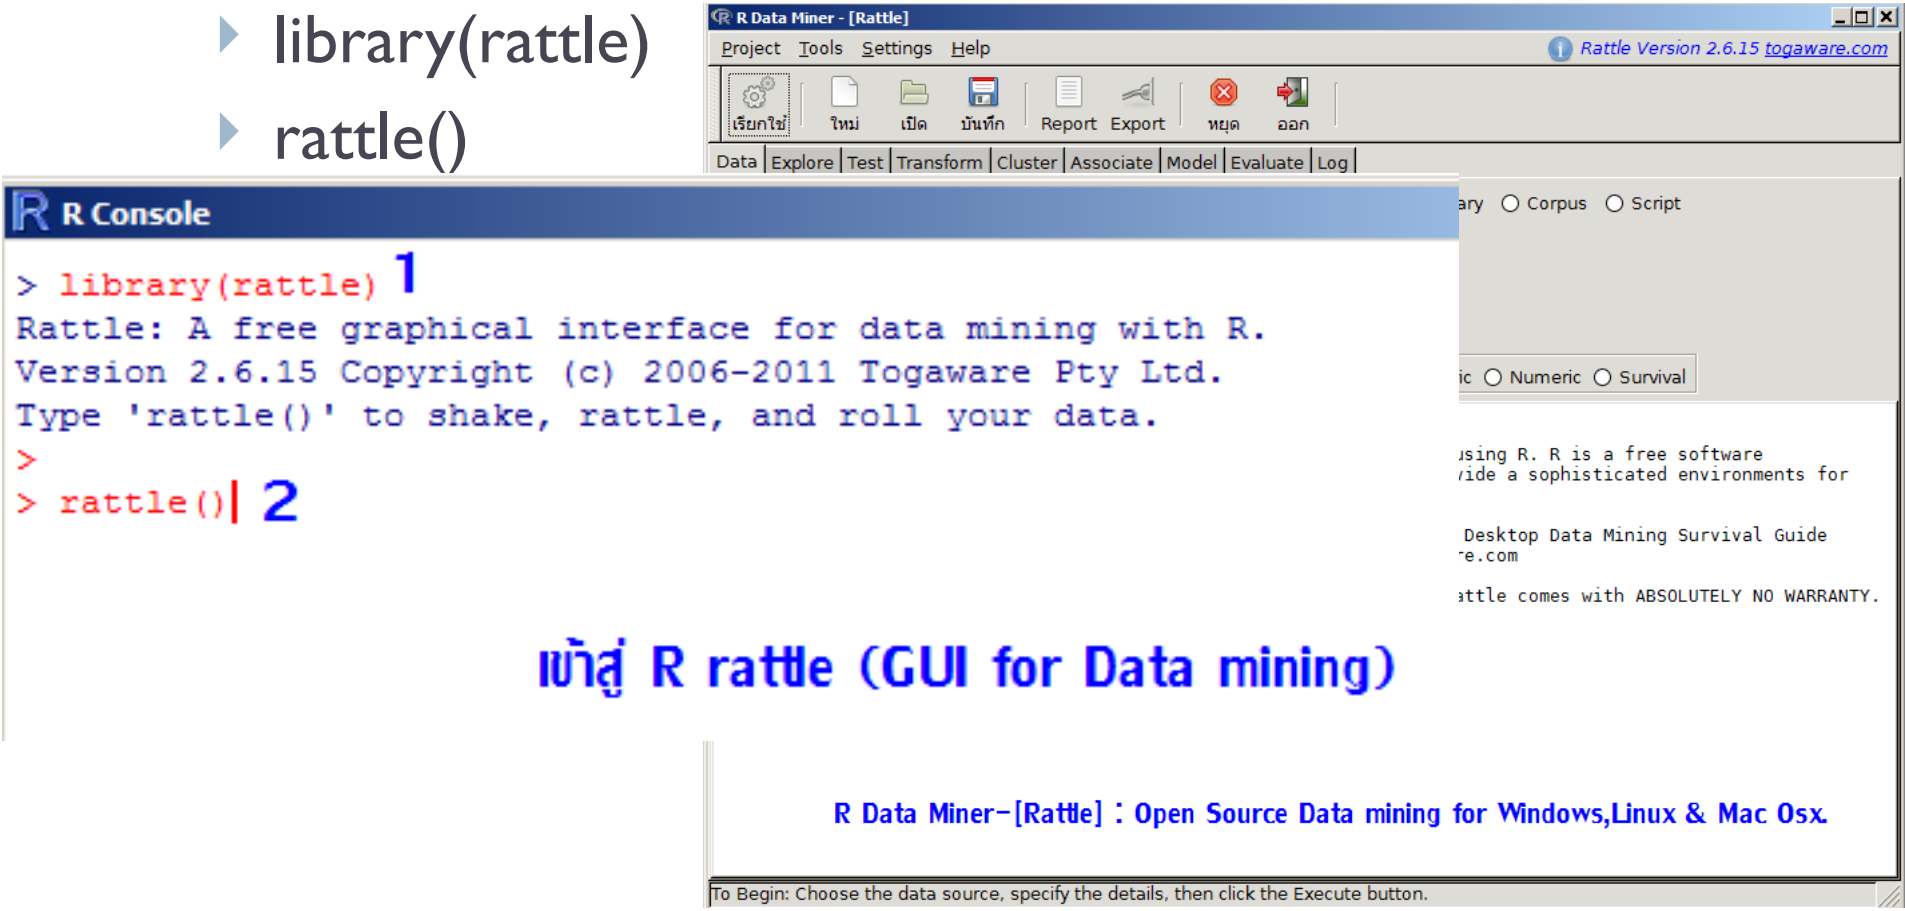
- 1. Getting Started with Rattle
- 2. Working with Data
- 3. Loading Data
- 4. Exploring Data
  - 4.1 Summarizing Data
  - 4.2 Visualizing Distributions
  - 4.3 Correlation Analysis
- 5. Testing Data
- 6. Transforming Data
- 7. Cluster Analysis
- 8. Association Analysis
- 9. Classifier Models
- 10. Model Performance Evaluation.

# Rattle Training 1. Getting Started with Rattle

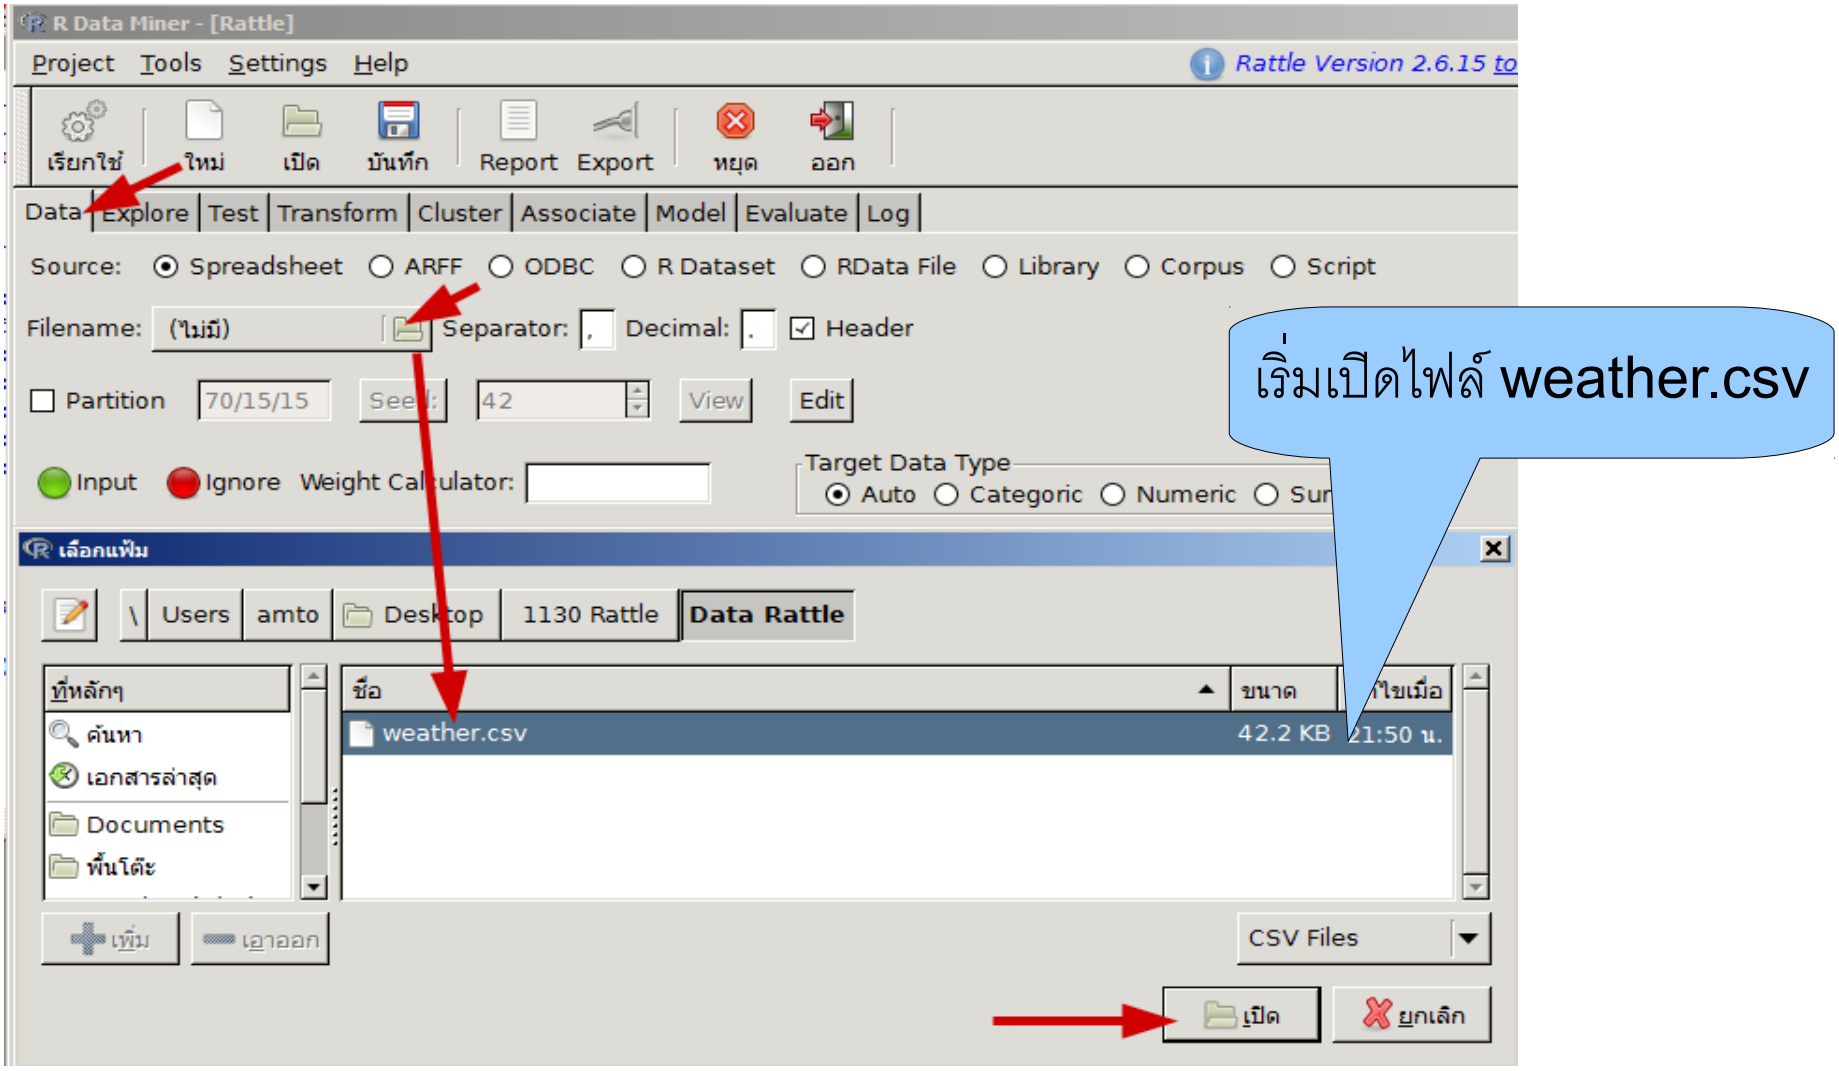


# Rattle Training 1. Getting Started with Rattle

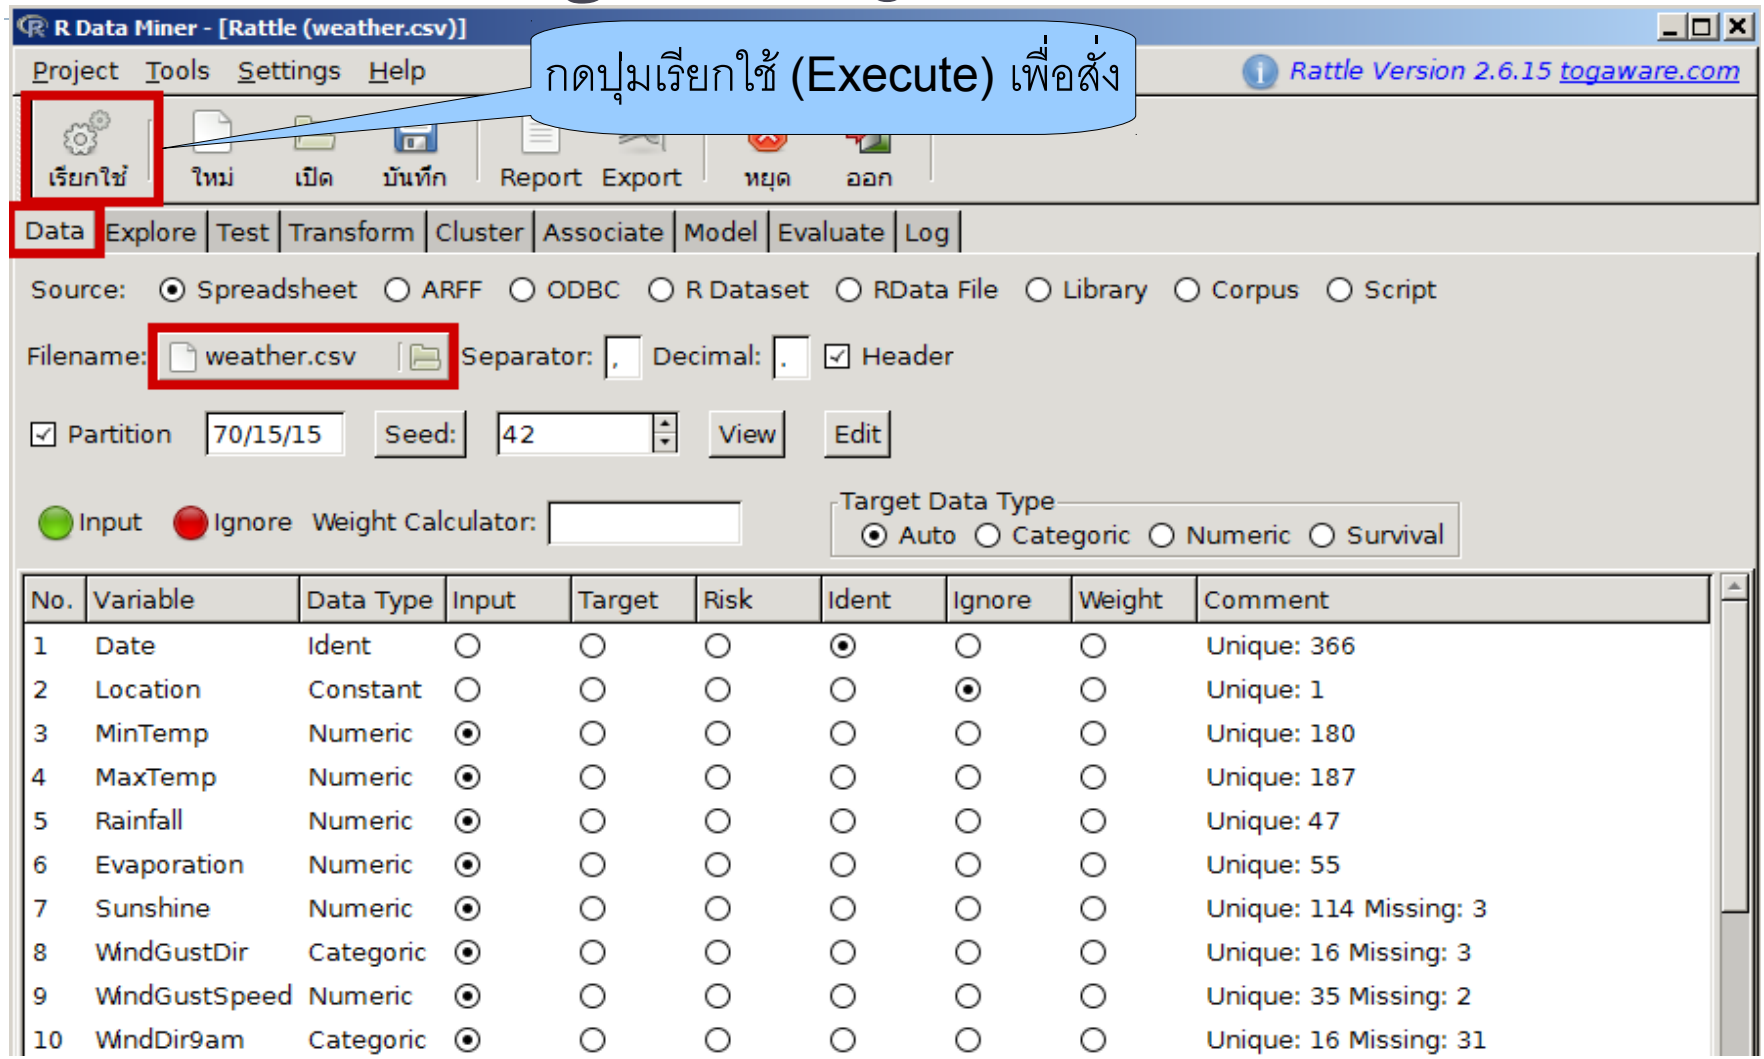
- เมื่อติดตั้ง **Packages** ต่างๆ เรียบร้อยแล้วก็เข้าสู่ **Rattle** ด้วย
- library(rattle)
- rattle()



# Rattle Training 1. Getting Started with Rattle

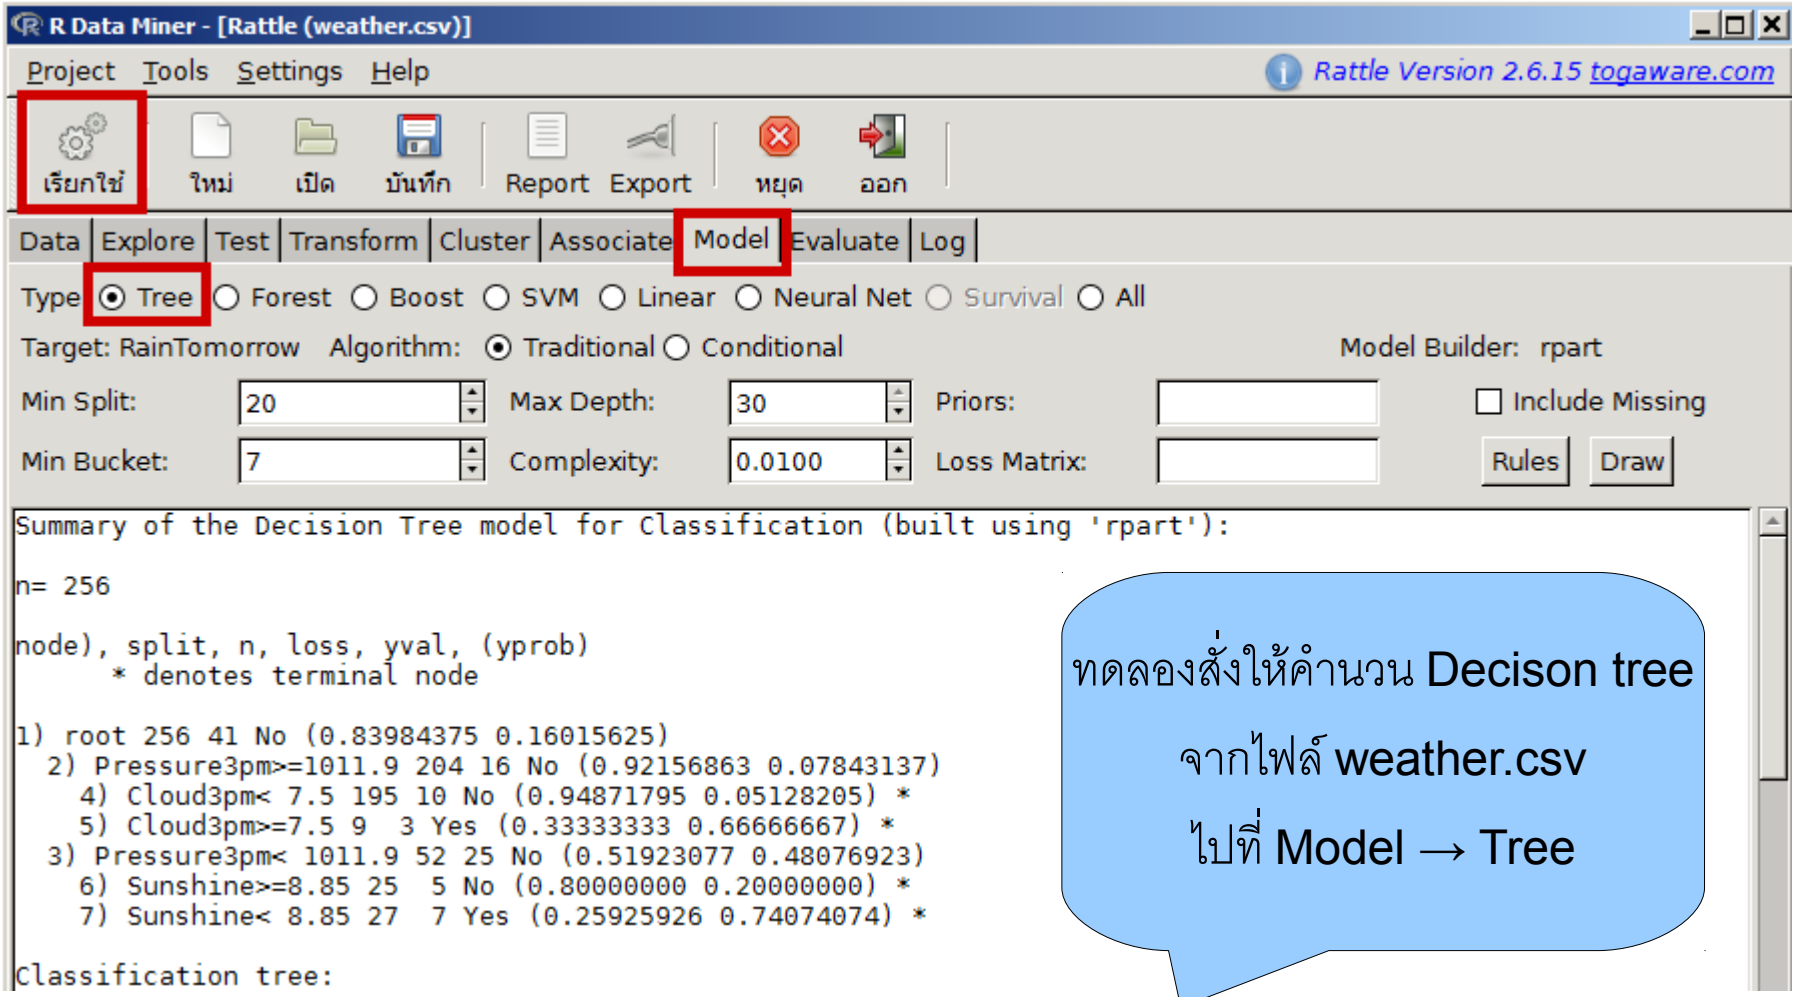


# Rattle Training 1. Getting Started with Rattle



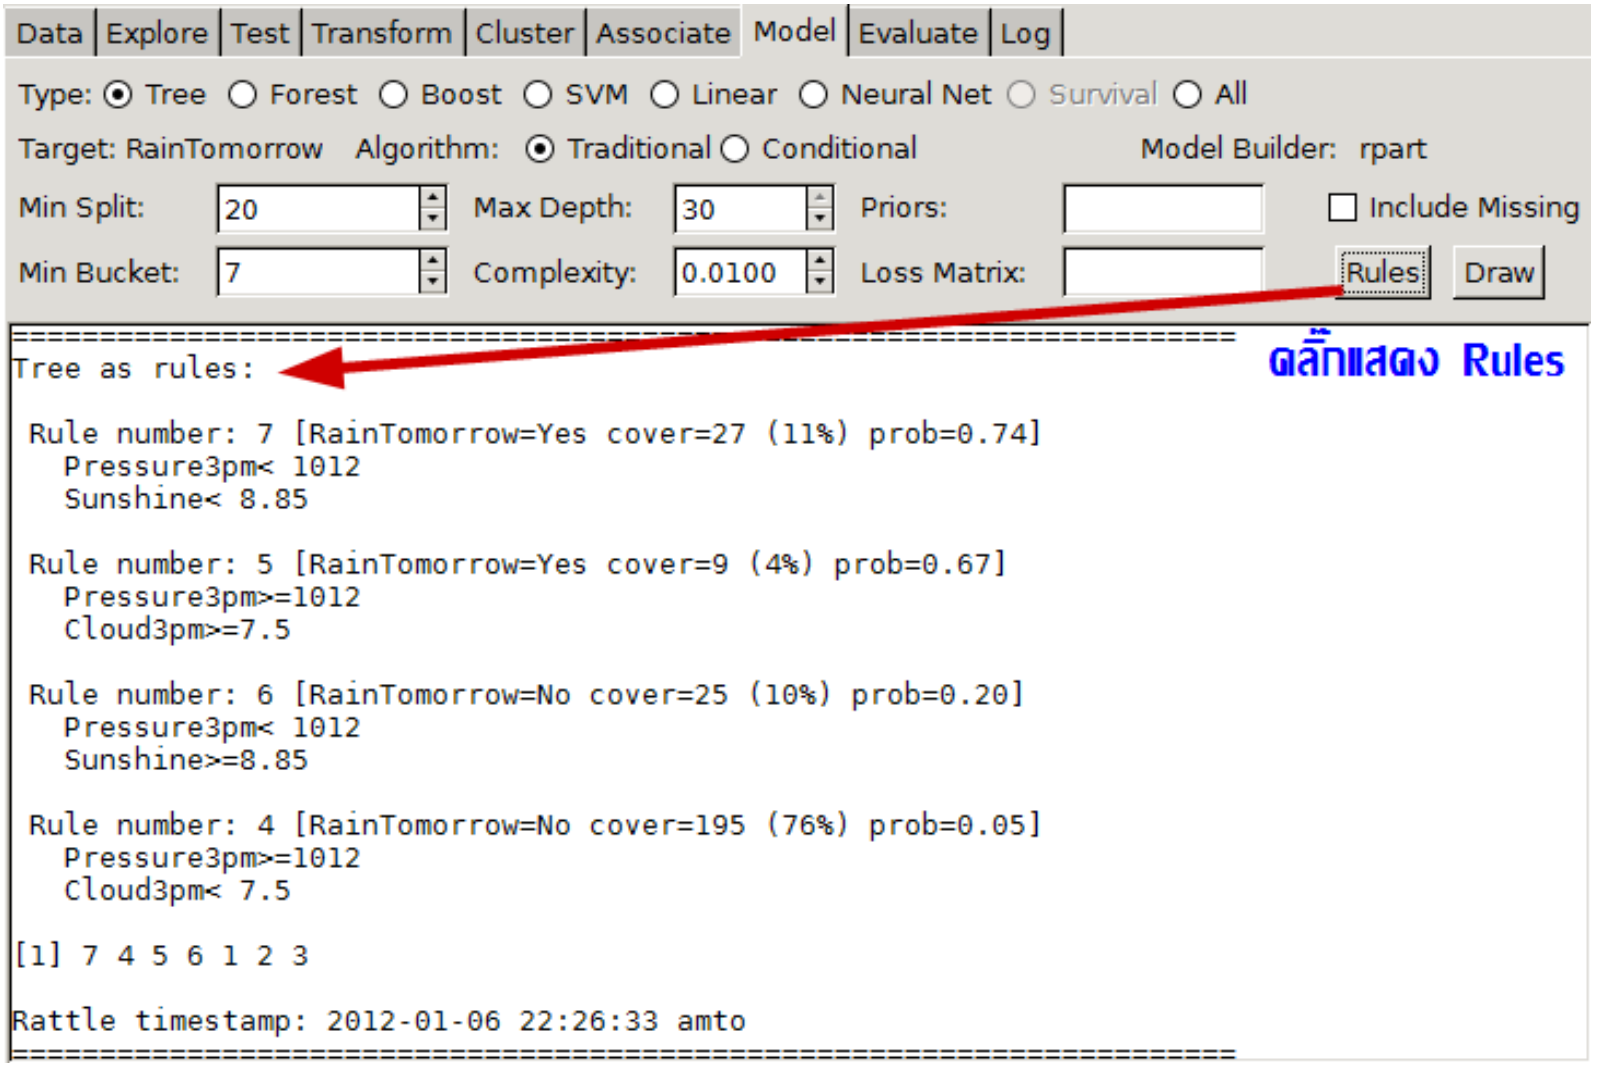

| No. | Variable | Data Type | Input | Target | Risk | Ident | Ignore | Weight | Comment |
|---|---|---|---|---|---|---|---|---|---|
| 1 | Date | Ident | ○ | ○ | ○ | ◉ | ○ | ○ | Unique: 366 |
| 2 | Location | Constant | ○ | ○ | ○ | ○ | ◉ | ○ | Unique: 1 |
| 3 | MinTemp | Numeric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 180 |
| 4 | MaxTemp | Numeric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 187 |
| 5 | Rainfall | Numeric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 47 |
| 6 | Evaporation | Numeric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 55 |
| 7 | Sunshine | Numeric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 114 Missing: 3 |
| 8 | WindGustDir | Categoric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 16 Missing: 3 |
| 9 | WindGustSpeed | Numeric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 35 Missing: 2 |
| 10 | WindDir9am | Categoric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 16 Missing: 31 |

# Rattle Training 1. Getting Started with Rattle

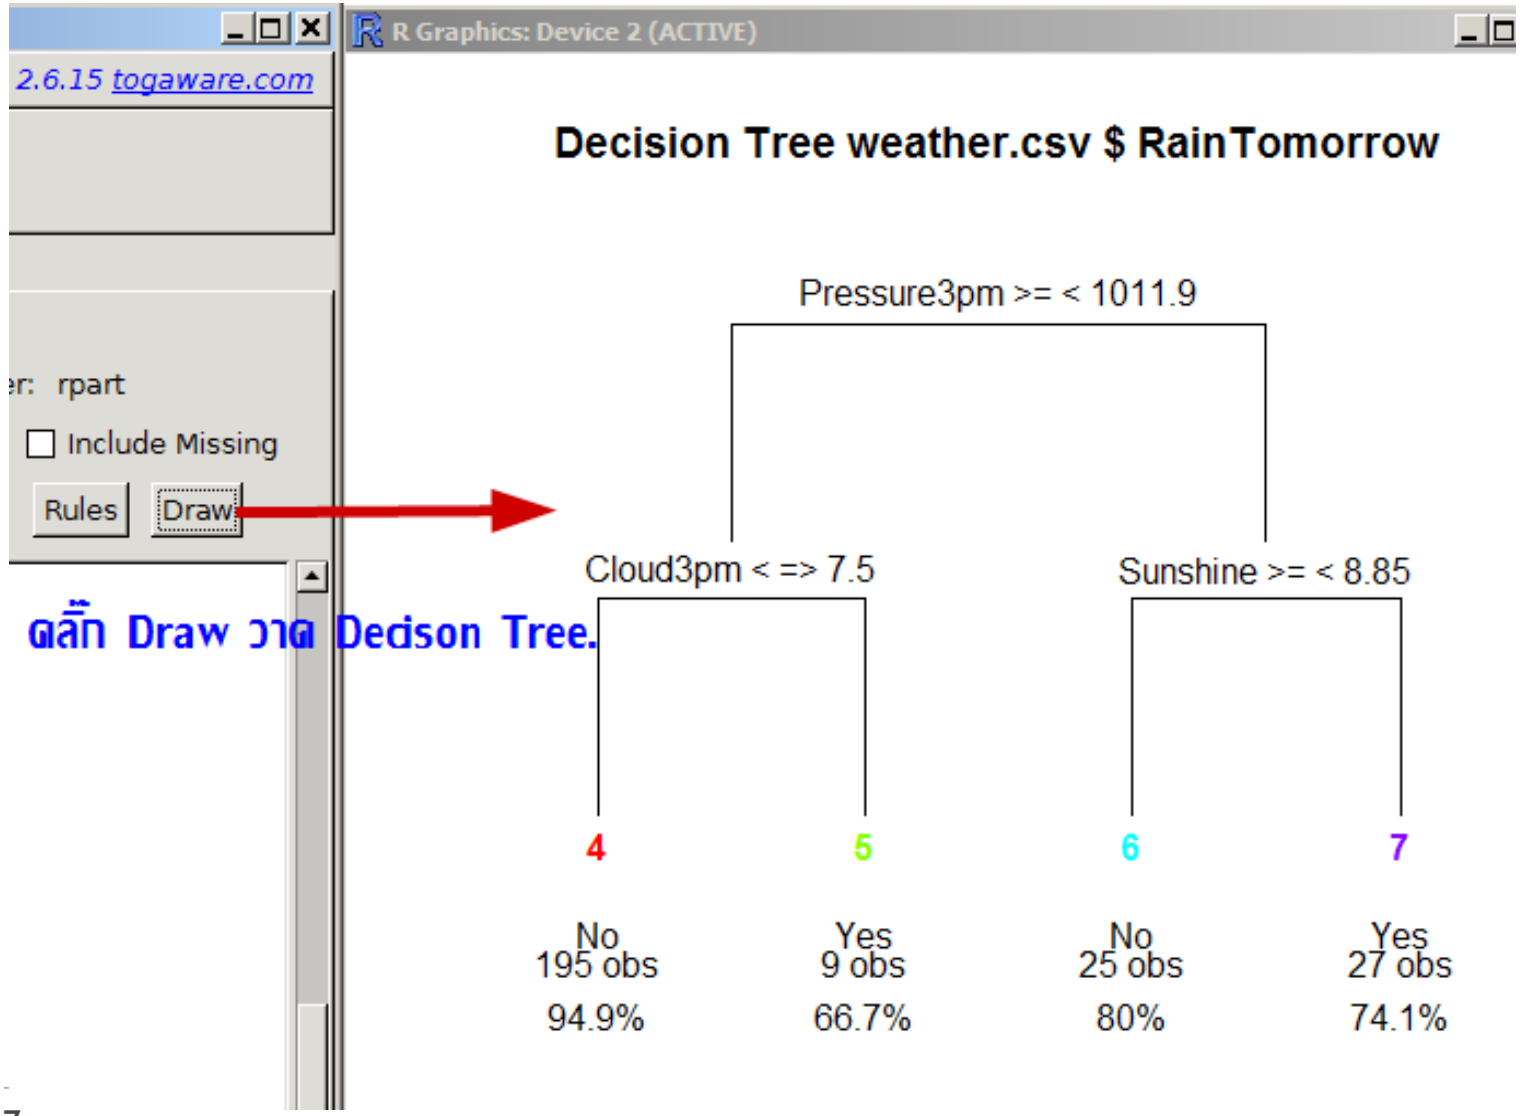



ทดลองสั่งให้คำนวน Decison tree จากไฟล์ weather.csv ไปที่ Model → Tree

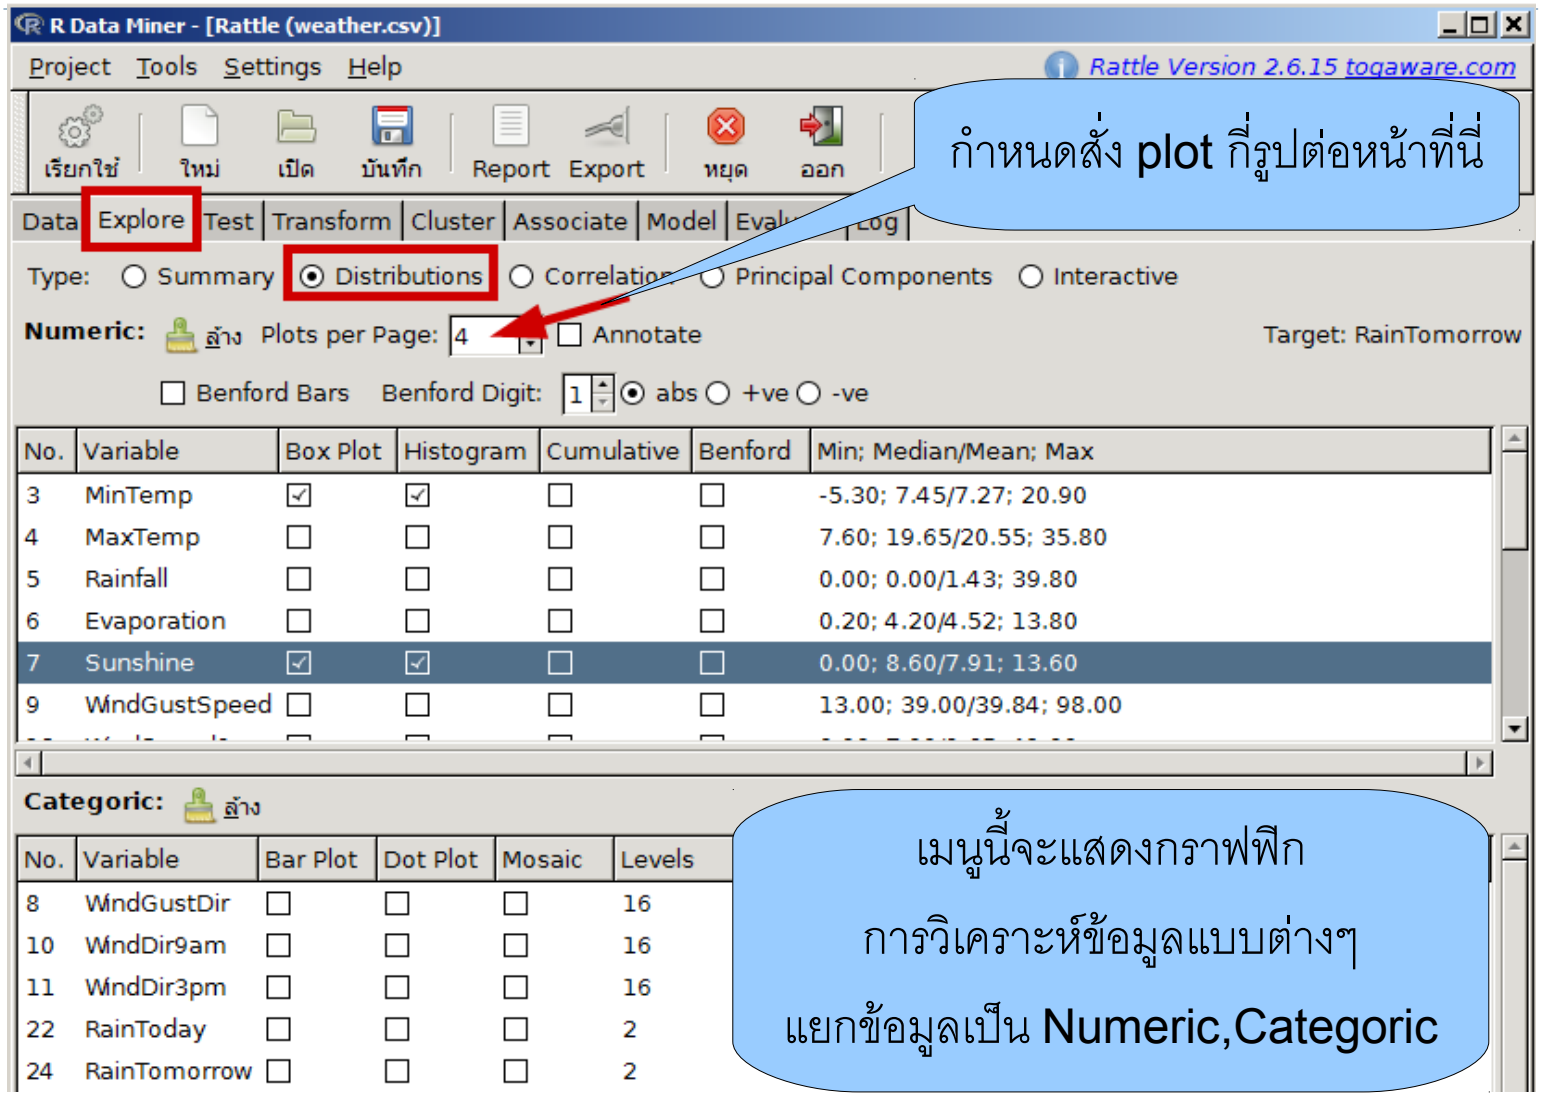
# Rattle Training 1. Getting Started with Rattle



# Rattle Training 1. Getting Started with Rattle

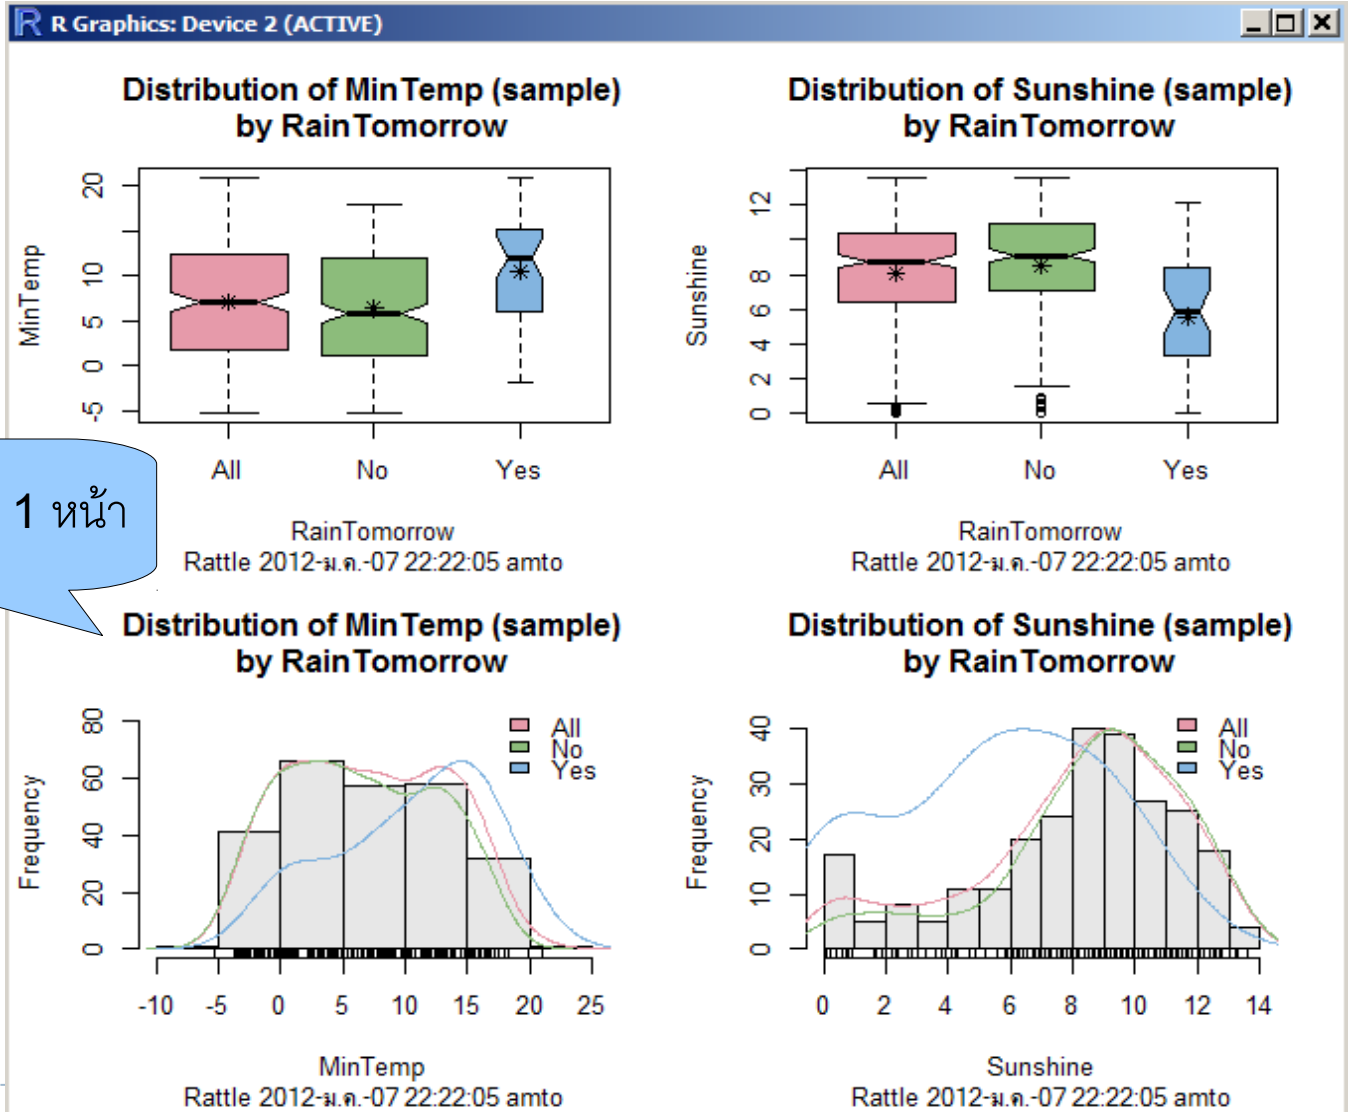


# Rattle Training 1. Getting Started with Rattle

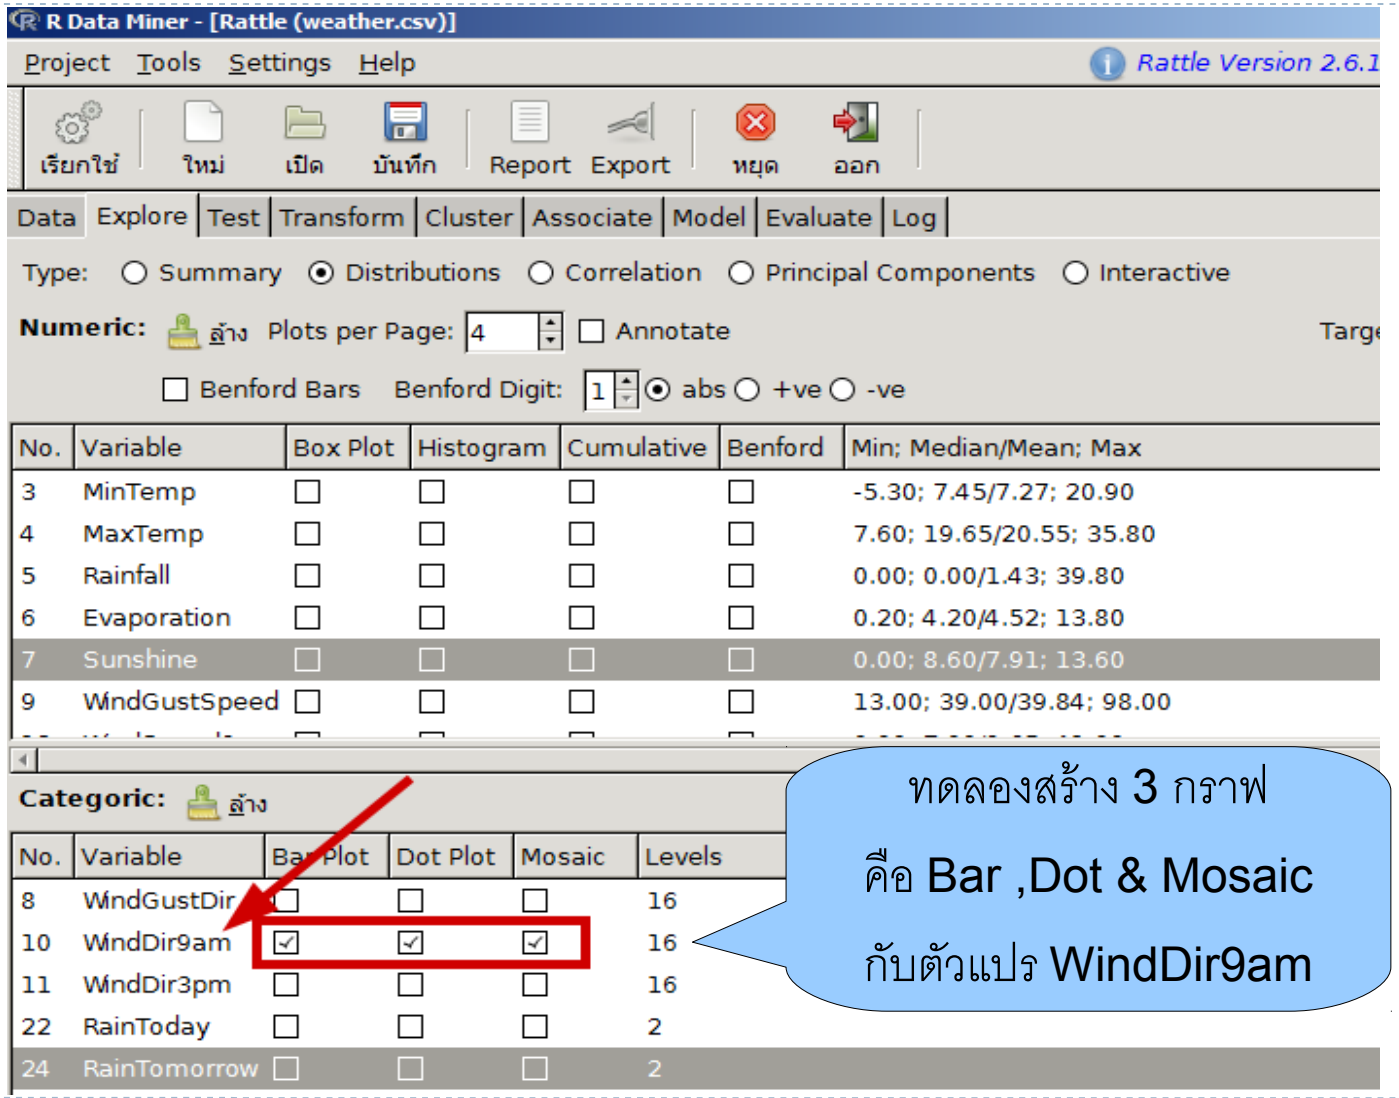


# Rattle Training 1. Getting Started with Rattle

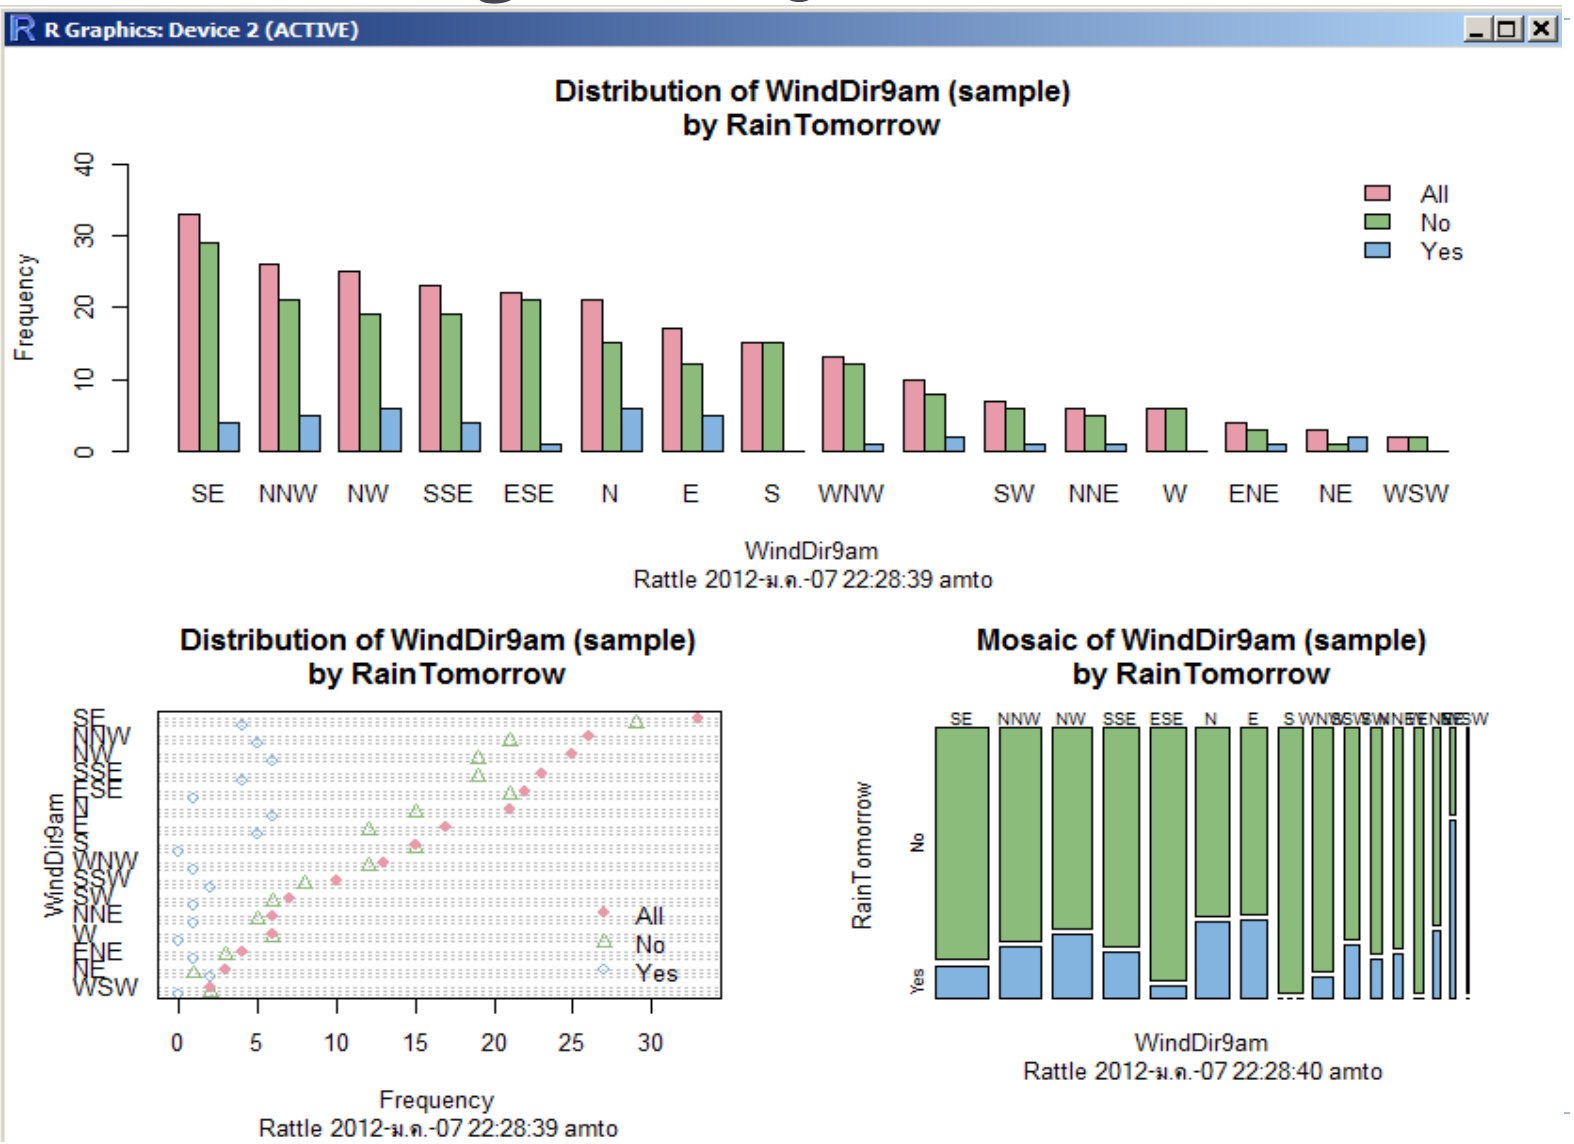
แสดงกราฟ 4 รูปต่อ 1 หน้า



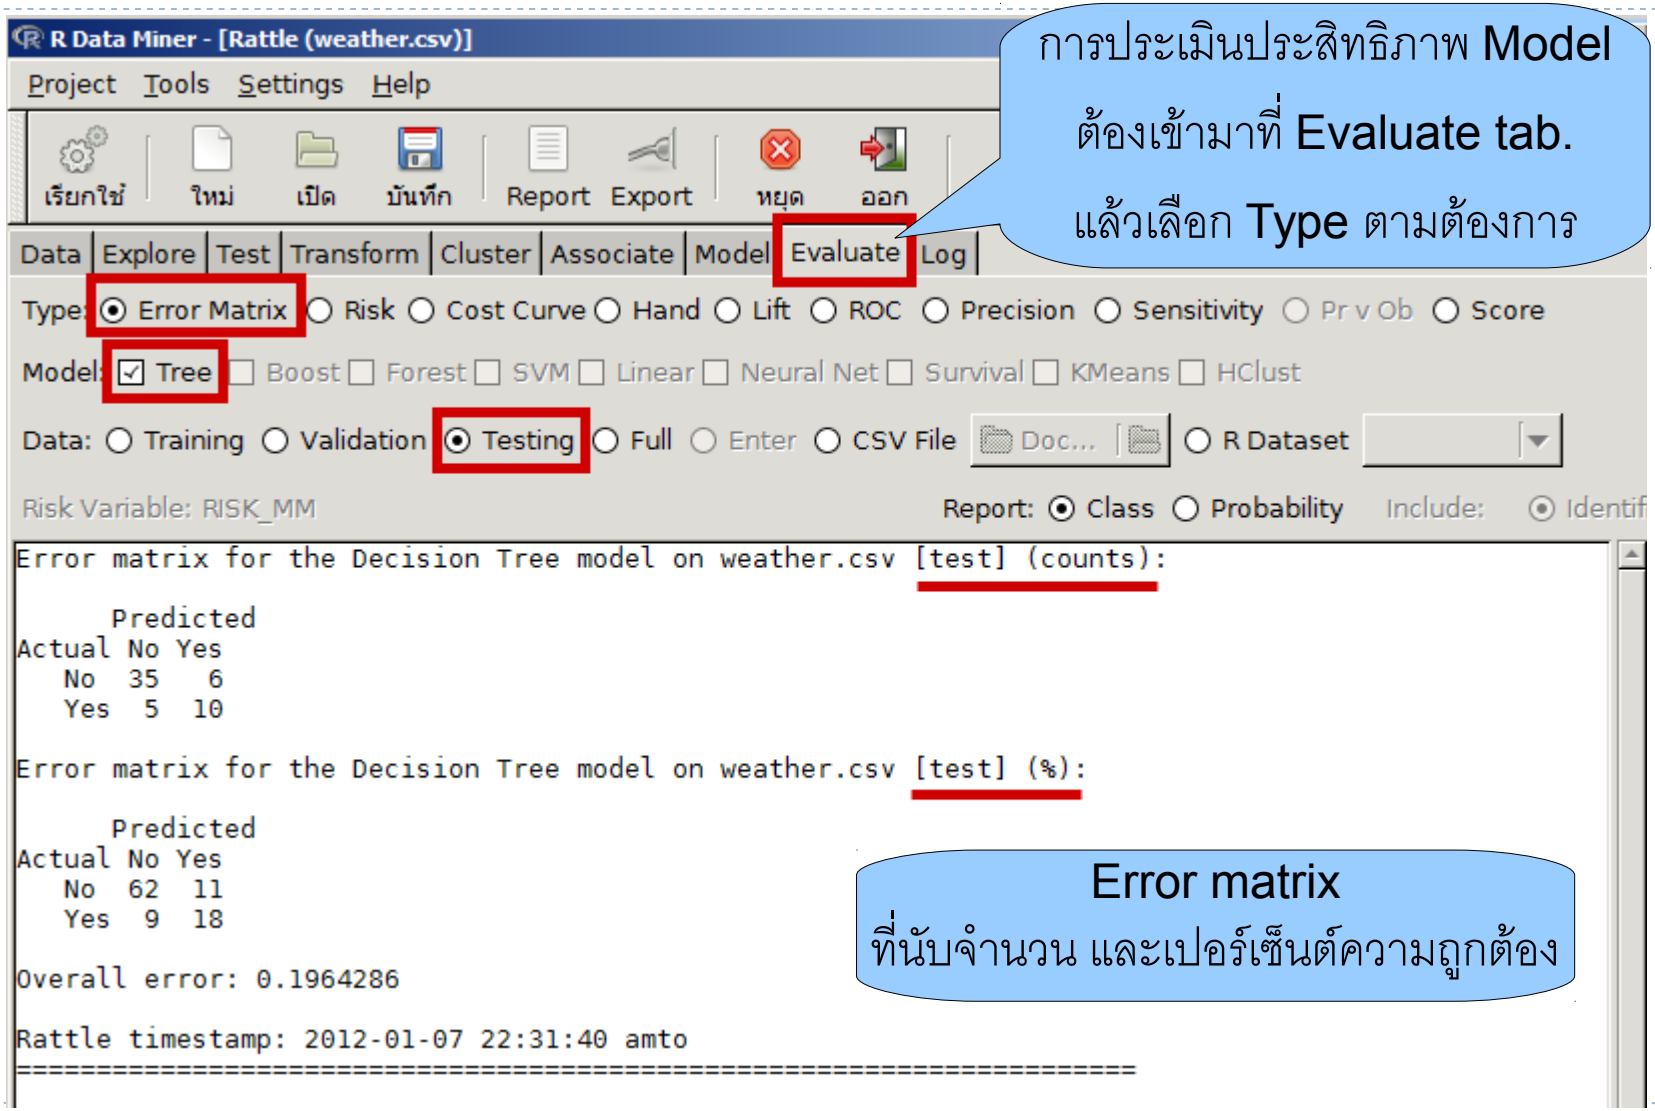
# Rattle Training 1. Getting Started with Rattle



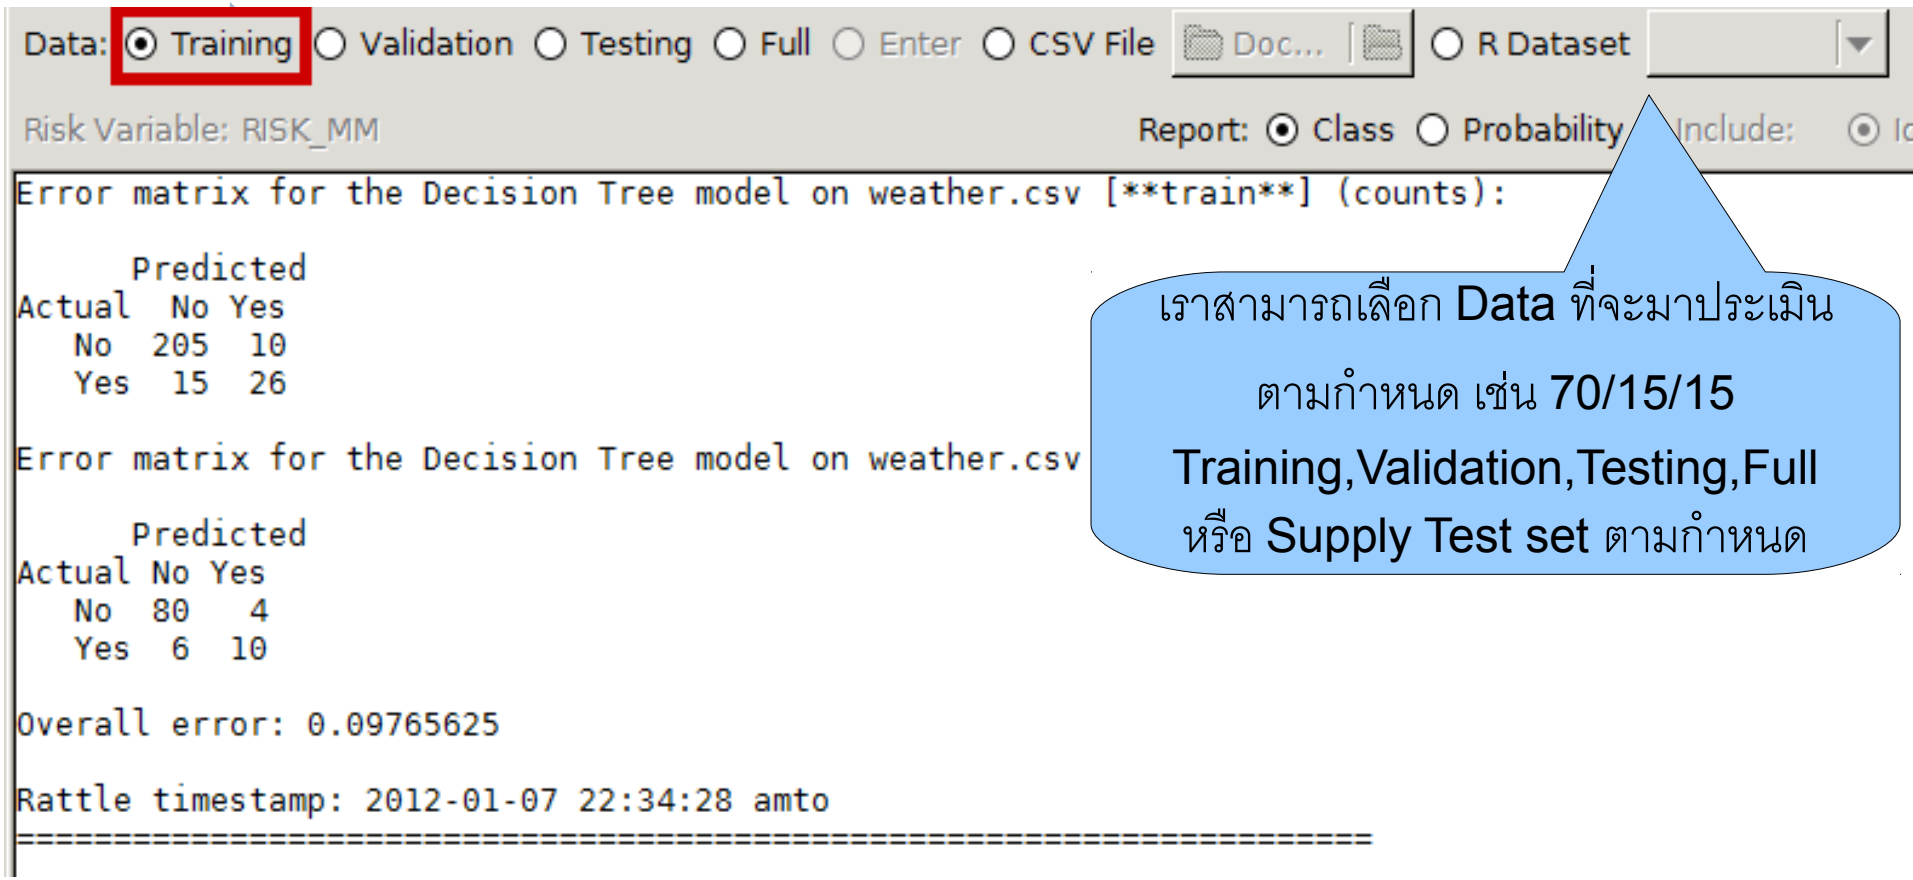
# Rattle Training 1. Getting Started with Rattle



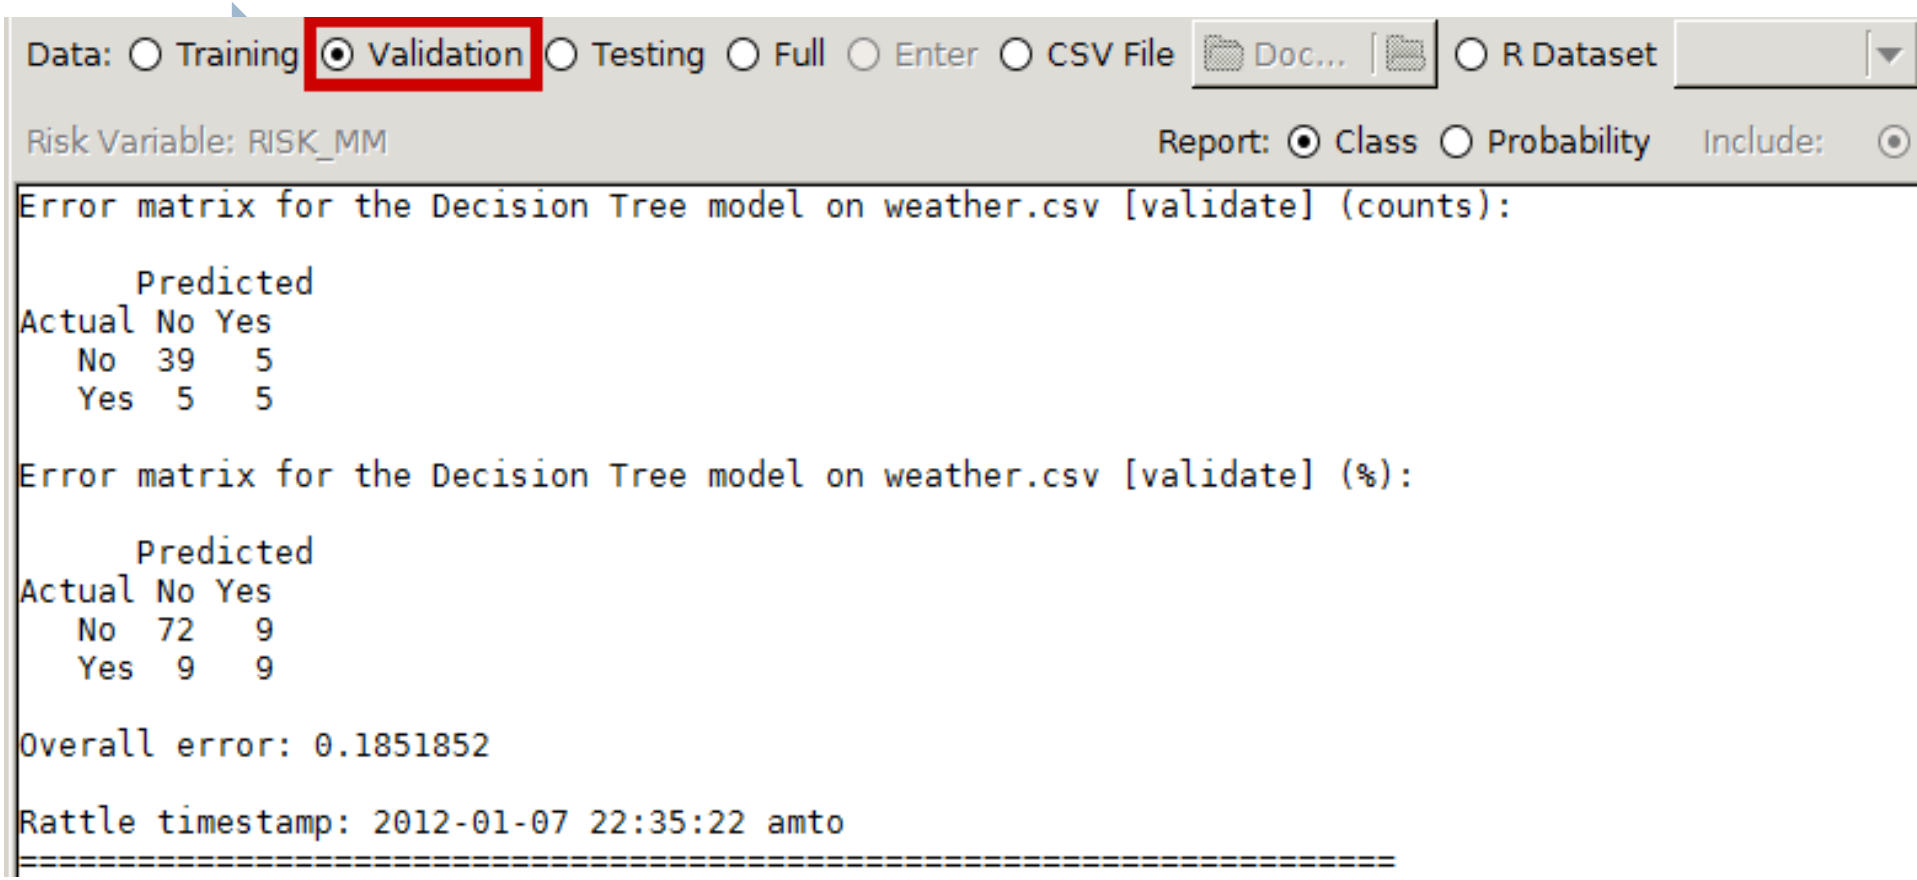
# Rattle Training 1. Getting Started with Rattle



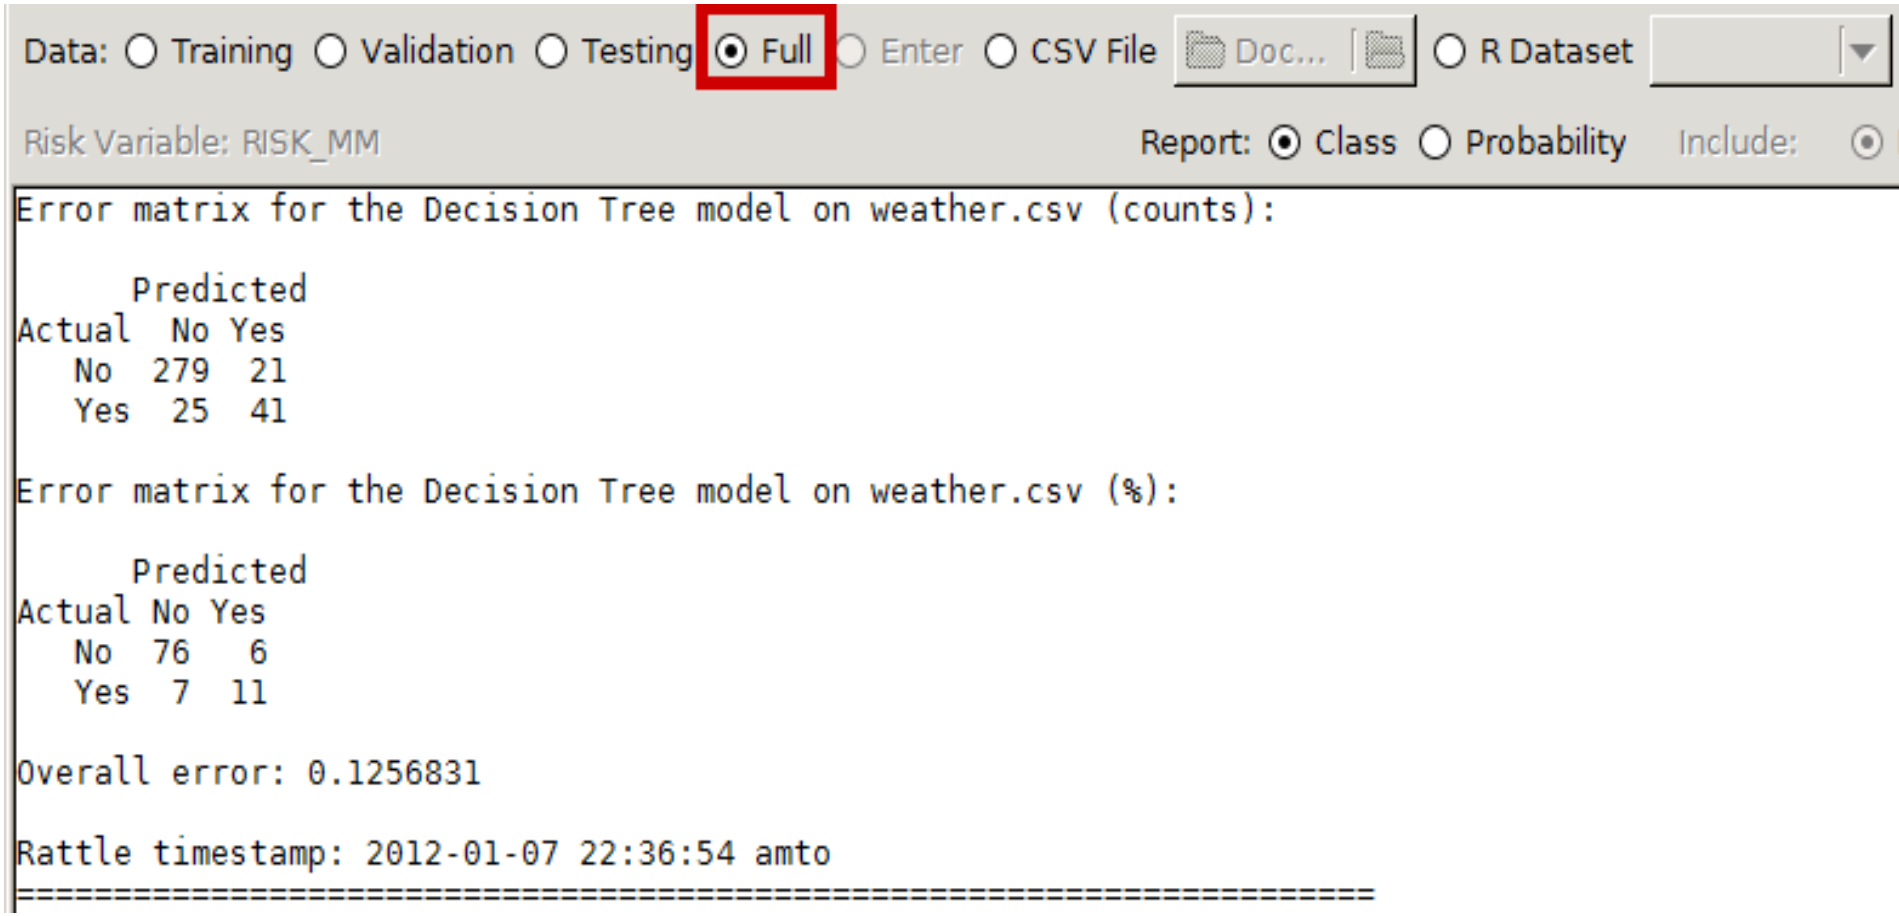
# Rattle Training 1. Getting Started with Rattle



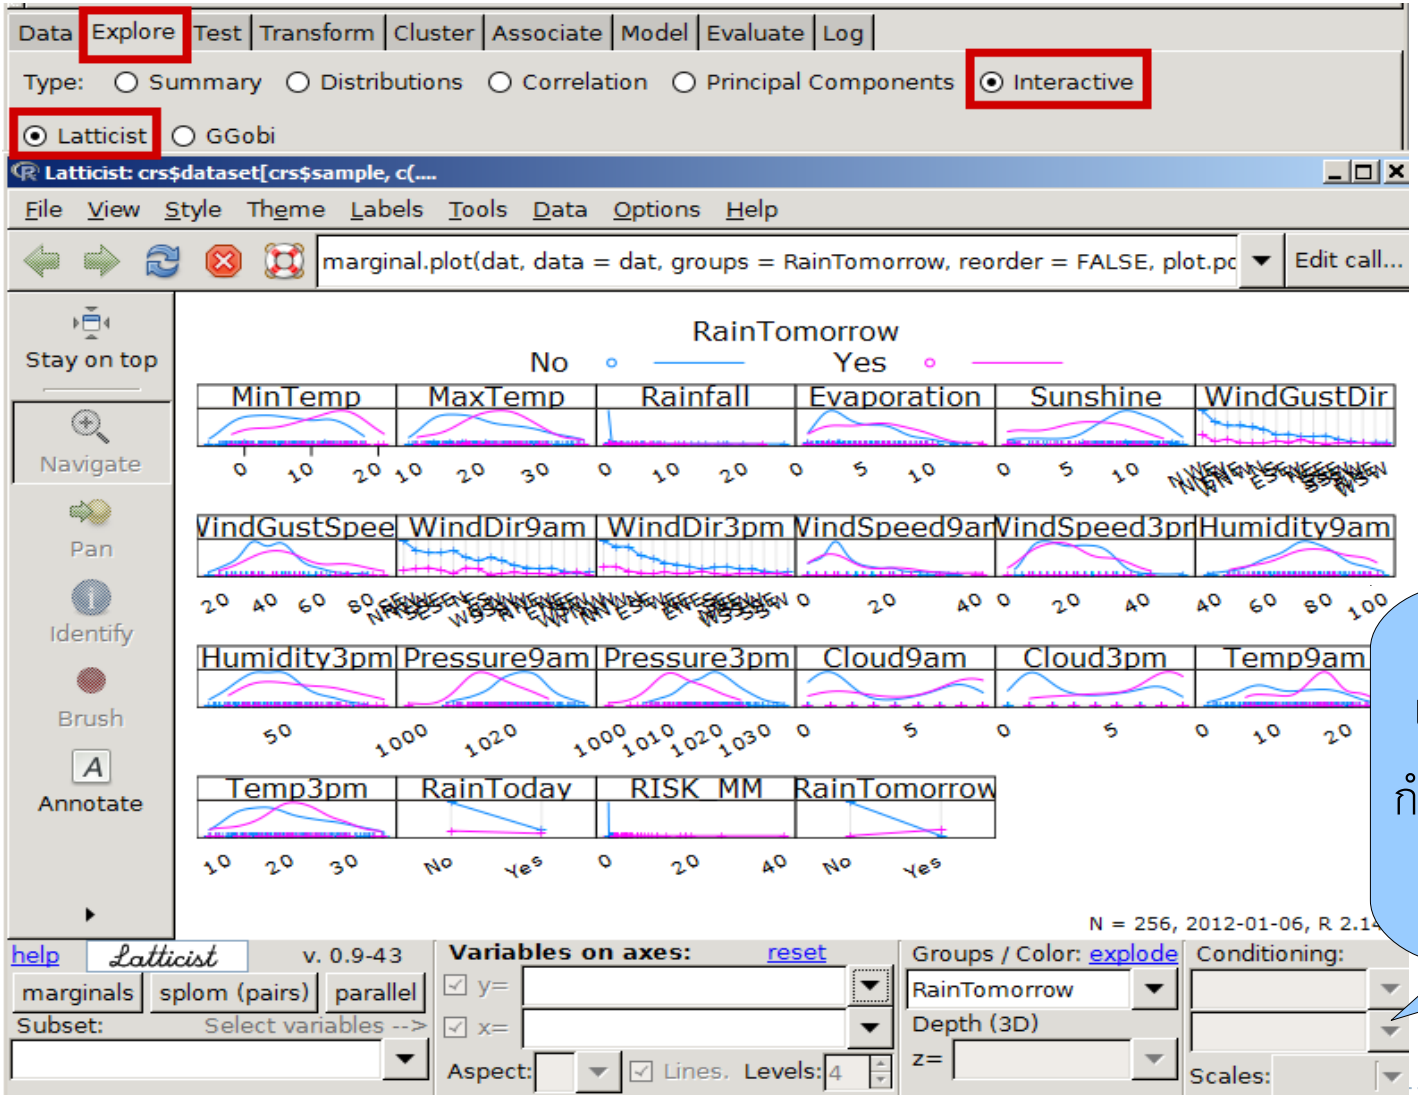
# Rattle Training 1. Getting Started with Rattle



# Rattle Training 1. Getting Started with Rattle

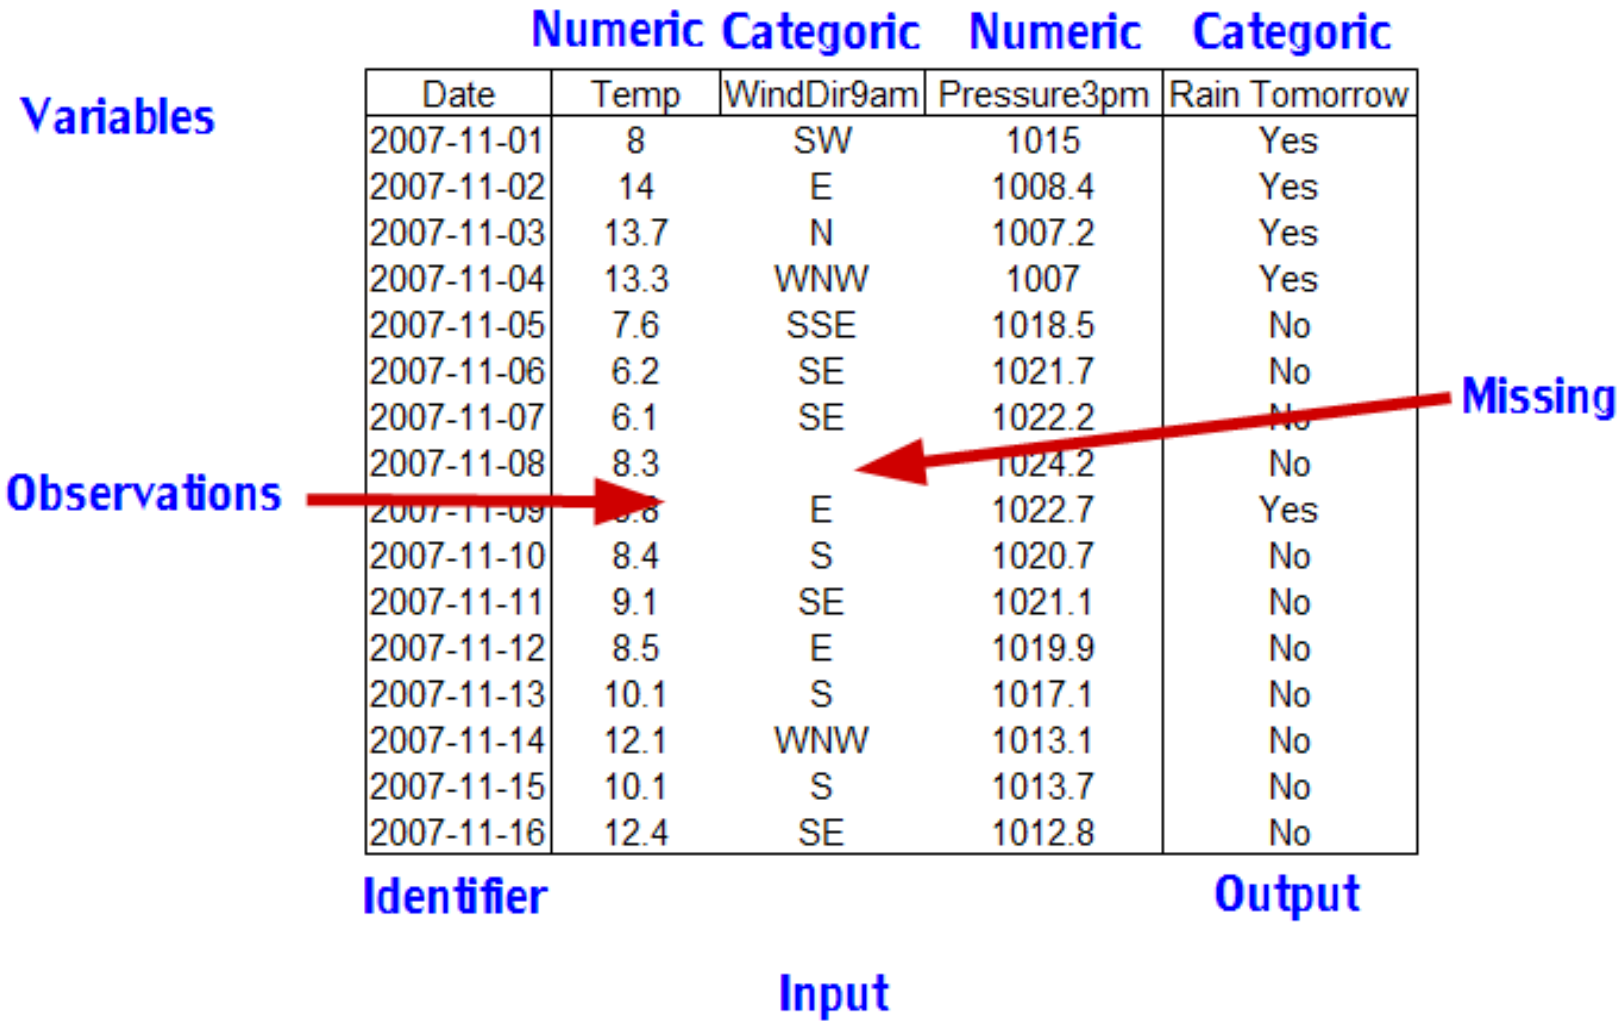


# Rattle Training 1. Getting Started with Rattle




Interactive graphic เป็นรูปแบบที่เราสามารถกำหนดตัวแปร และเงื่อนไขตัวแปรเชิงกลุ่มเข้าไปได้

# Rattle Training 2. Working with Data




| Date | Temp | WindDir9am | Pressure3pm | Rain Tomorrow |
|---|---|---|---|---|
| 2007-11-01 | 8 | SW | 1015 | Yes |
| 2007-11-02 | 14 | E | 1008.4 | Yes |
| 2007-11-03 | 13.7 | N | 1007.2 | Yes |
| 2007-11-04 | 13.3 | WNW | 1007 | Yes |
| 2007-11-05 | 7.6 | SSE | 1018.5 | No |
| 2007-11-06 | 6.2 | SE | 1021.7 | No |
| 2007-11-07 | 6.1 | SE | 1022.2 | No |
| 2007-11-08 | 8.3 | | 1024.2 | No |
| 2007-11-09 | 9.8 | E | 1022.7 | Yes |
| 2007-11-10 | 8.4 | S | 1020.7 | No |
| 2007-11-11 | 9.1 | SE | 1021.1 | No |
| 2007-11-12 | 8.5 | E | 1019.9 | No |
| 2007-11-13 | 10.1 | S | 1017.1 | No |
| 2007-11-14 | 12.1 | WNW | 1013.1 | No |
| 2007-11-15 | 10.1 | S | 1013.7 | No |
| 2007-11-16 | 12.4 | SE | 1012.8 | No |

# Rattle Training 2. Working with Data

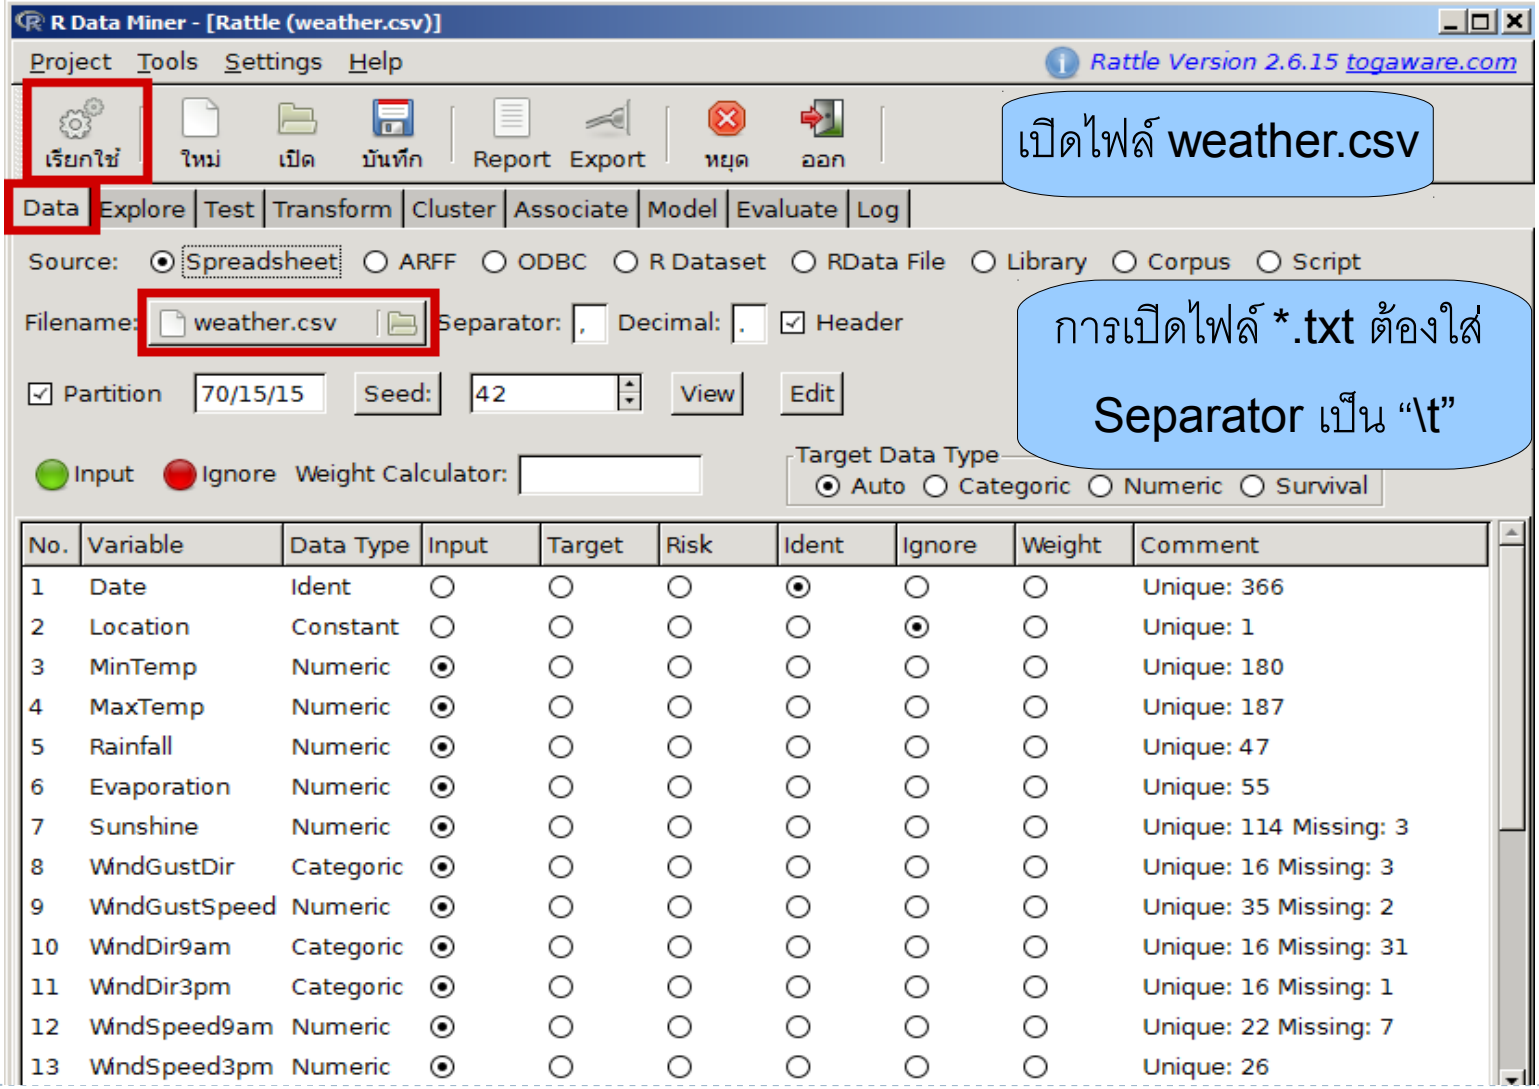
- R Command-line คือพื้นฐานสำคัญที่ควรจะต้องรู้ควบคู่ไปกับ GUI.

R Console

```
> head(names(weather))
[1] "Date"         "Location"     "MinTemp"      "MaxTemp"      "Rainfall"
[6] "Evaporation"
> names(weather)[1:6]
[1] "Date"         "Location"     "MinTemp"      "MaxTemp"      "Rainfall"
[6] "Evaporation"
> head(weather[2])
  Location
1 Canberra
2 Canberra
3 Canberra
4 Canberra
5 Canberra
6 Canberra
> head(weather$MinTemp)
[1]  8.0 14.0 13.7 13.3  7.6  6.2
>
```

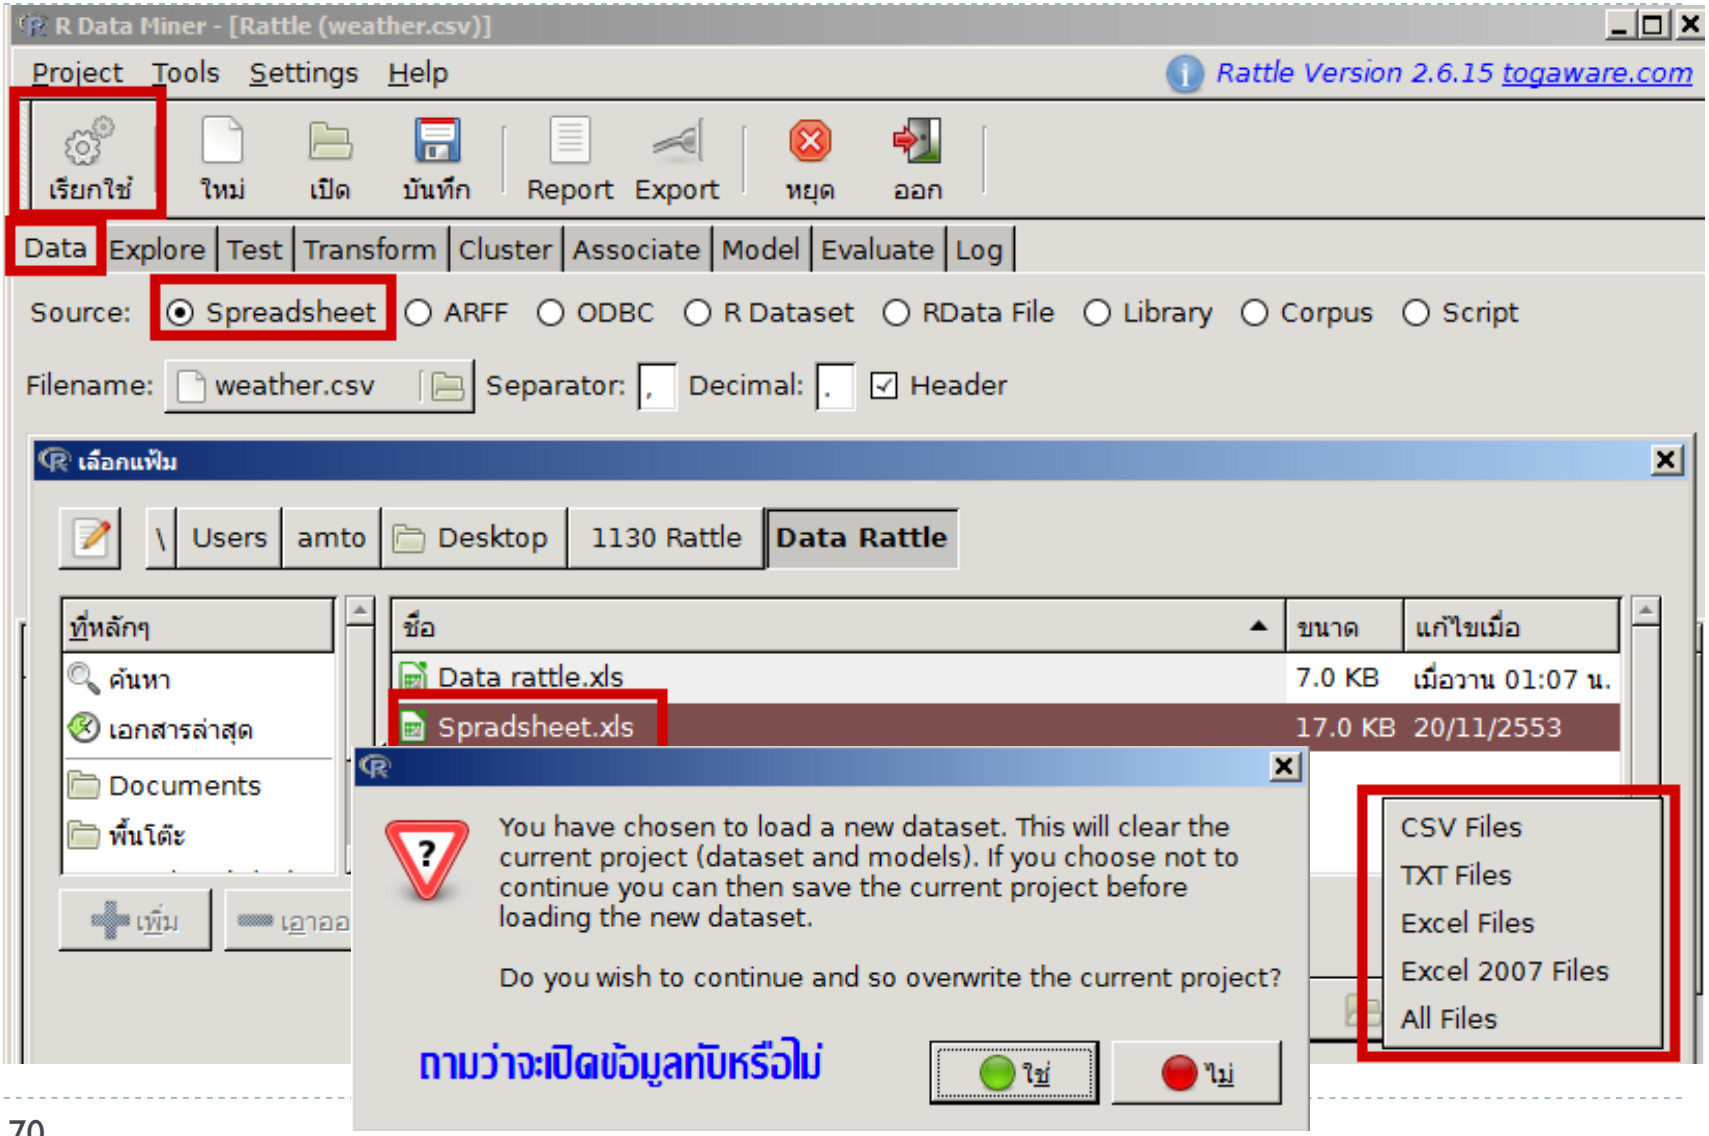
สำรวจข้อมูลเบื้องต้นด้วย R command-line

# Rattle Training 3. Loading Data

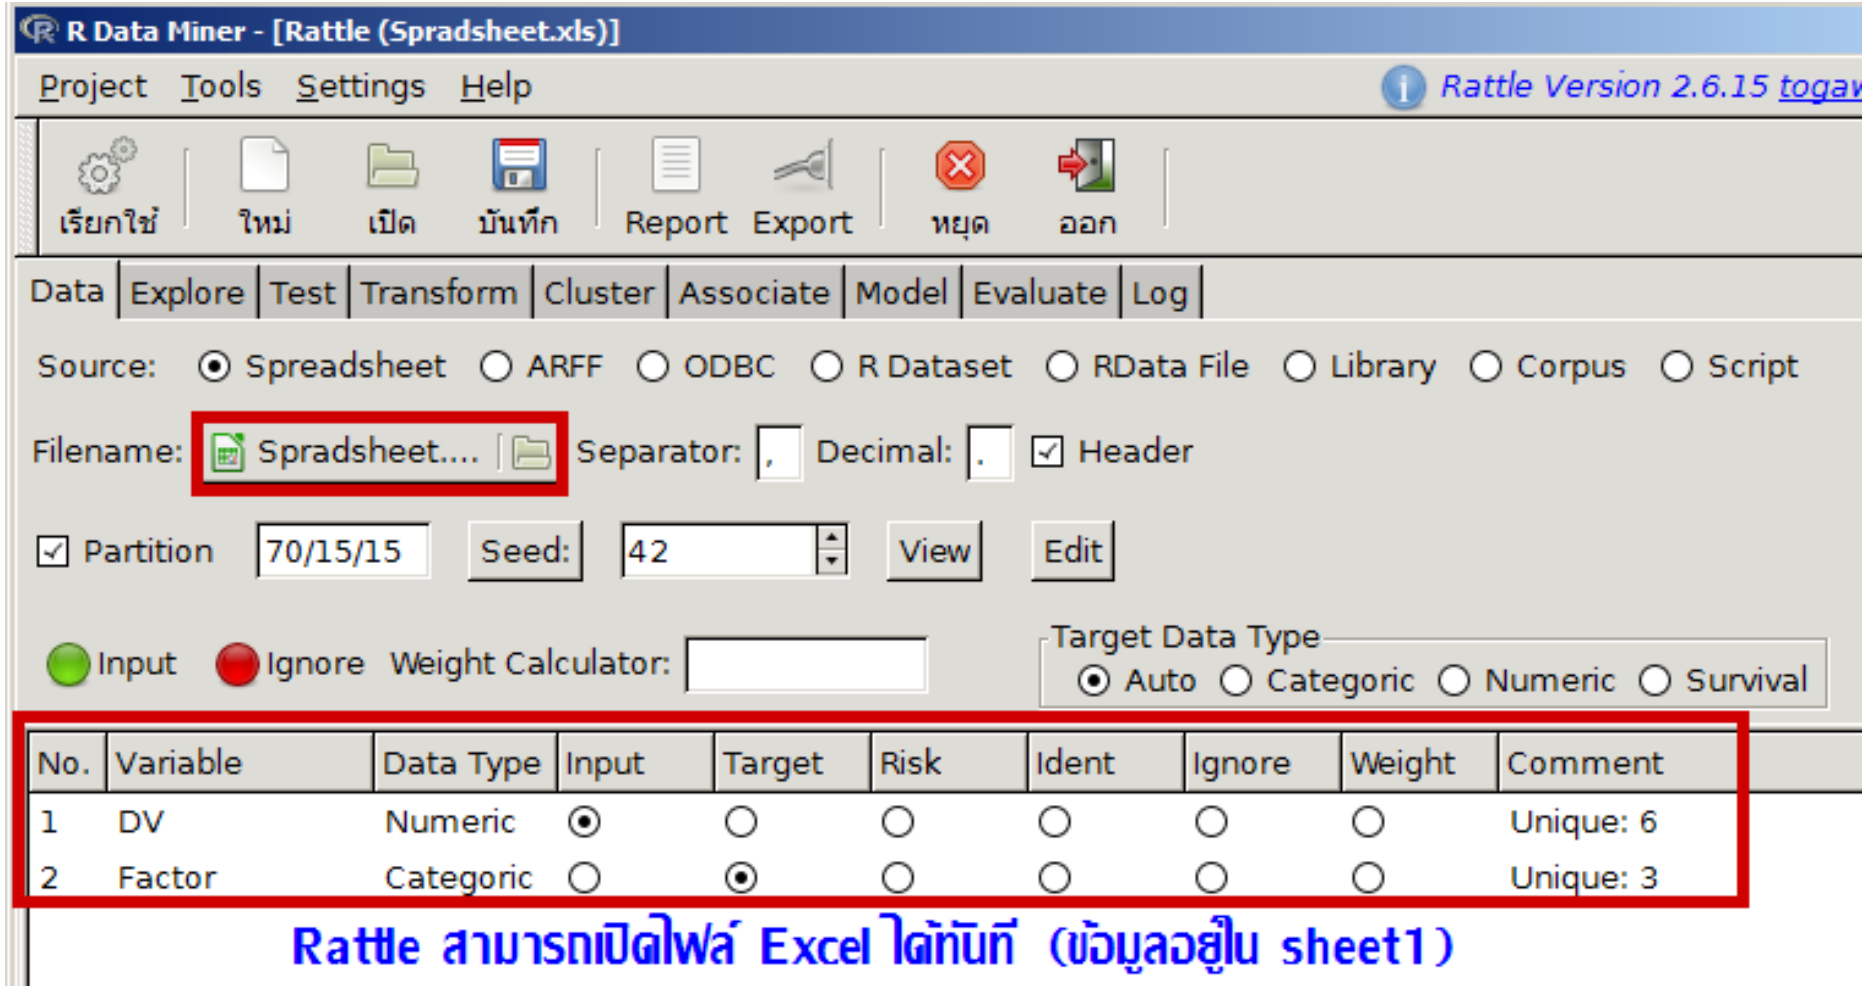



| No. | Variable | Data Type | Input | Target | Risk | Ident | Ignore | Weight | Comment |
|---|---|---|---|---|---|---|---|---|---|
| 1 | Date | Ident | ○ | ○ | ○ | ◉ | ○ | ○ | Unique: 366 |
| 2 | Location | Constant | ○ | ○ | ○ | ○ | ◉ | ○ | Unique: 1 |
| 3 | MinTemp | Numeric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 180 |
| 4 | MaxTemp | Numeric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 187 |
| 5 | Rainfall | Numeric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 47 |
| 6 | Evaporation | Numeric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 55 |
| 7 | Sunshine | Numeric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 114 Missing: 3 |
| 8 | WindGustDir | Categoric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 16 Missing: 3 |
| 9 | WindGustSpeed | Numeric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 35 Missing: 2 |
| 10 | WindDir9am | Categoric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 16 Missing: 31 |
| 11 | WindDir3pm | Categoric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 16 Missing: 1 |
| 12 | WindSpeed9am | Numeric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 22 Missing: 7 |
| 13 | WindSpeed3pm | Numeric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 26 |

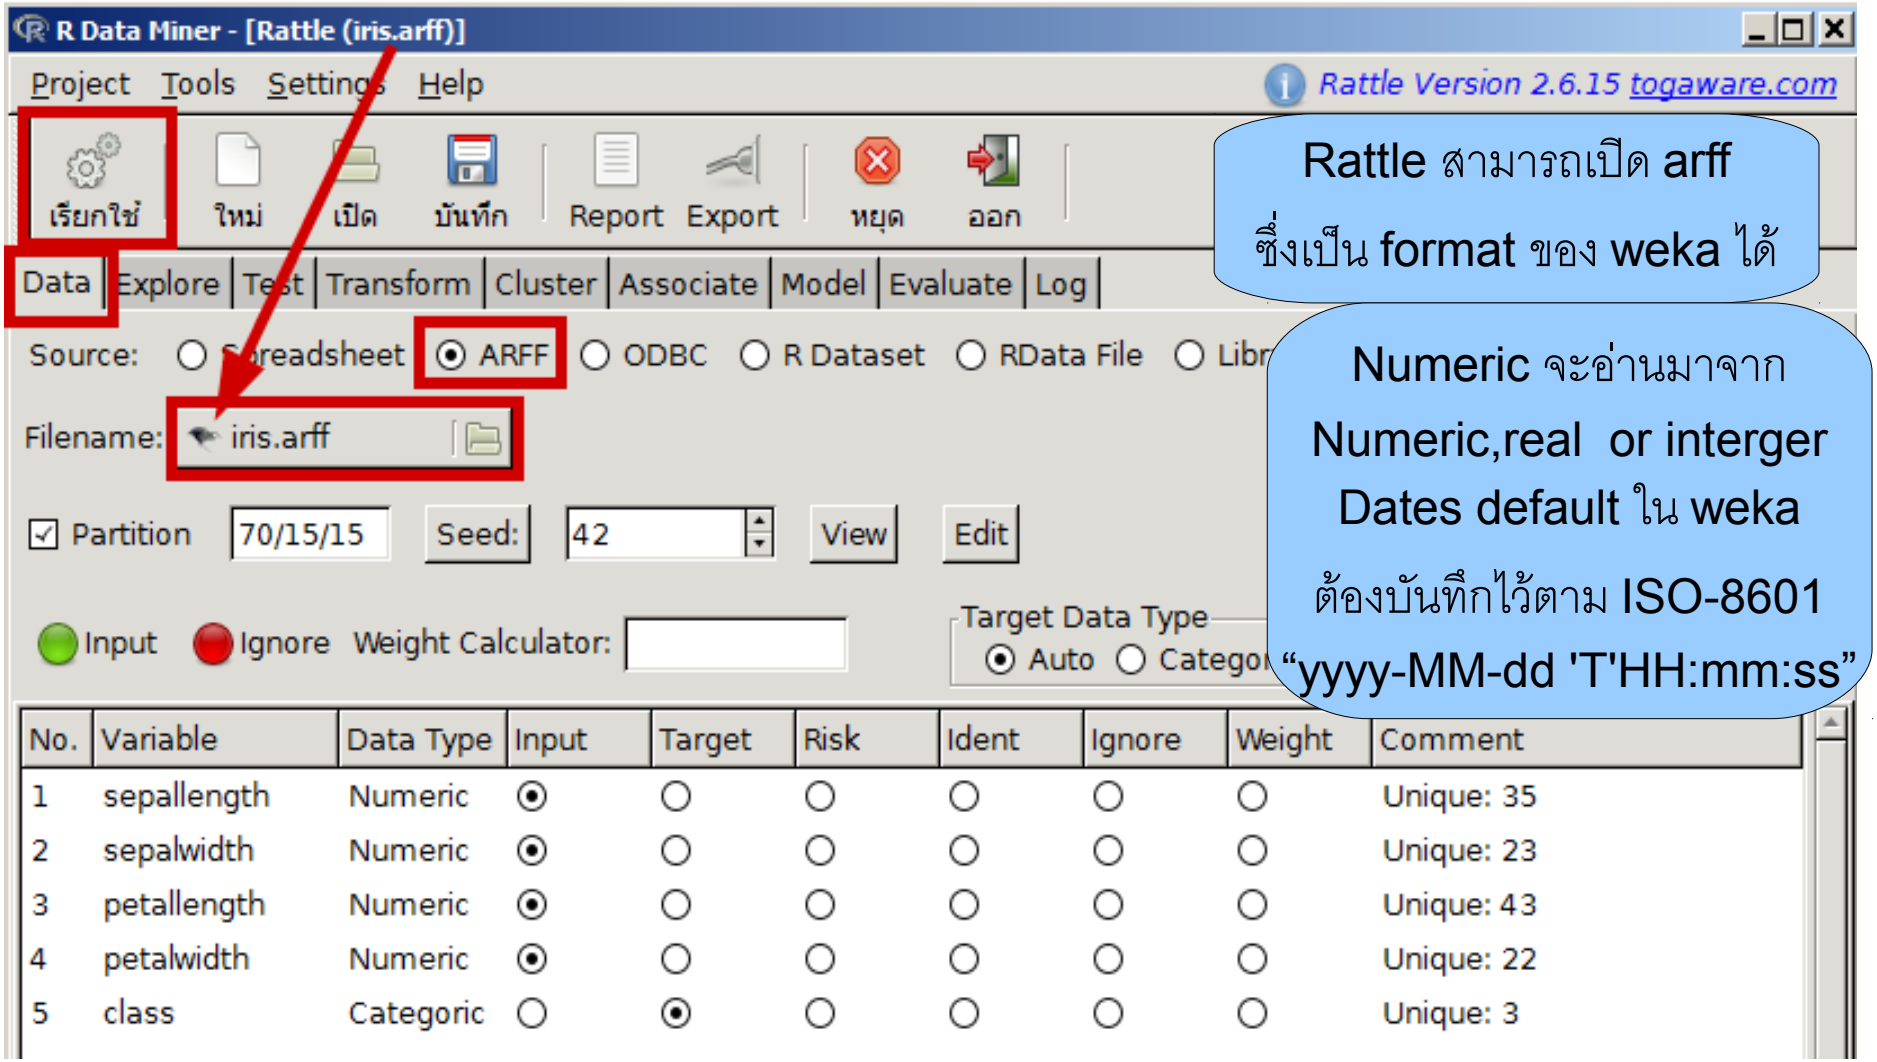
# Rattle Training 3. Loading Data



# Rattle Training 3. Loading Data



# Rattle Training 3. Loading Data



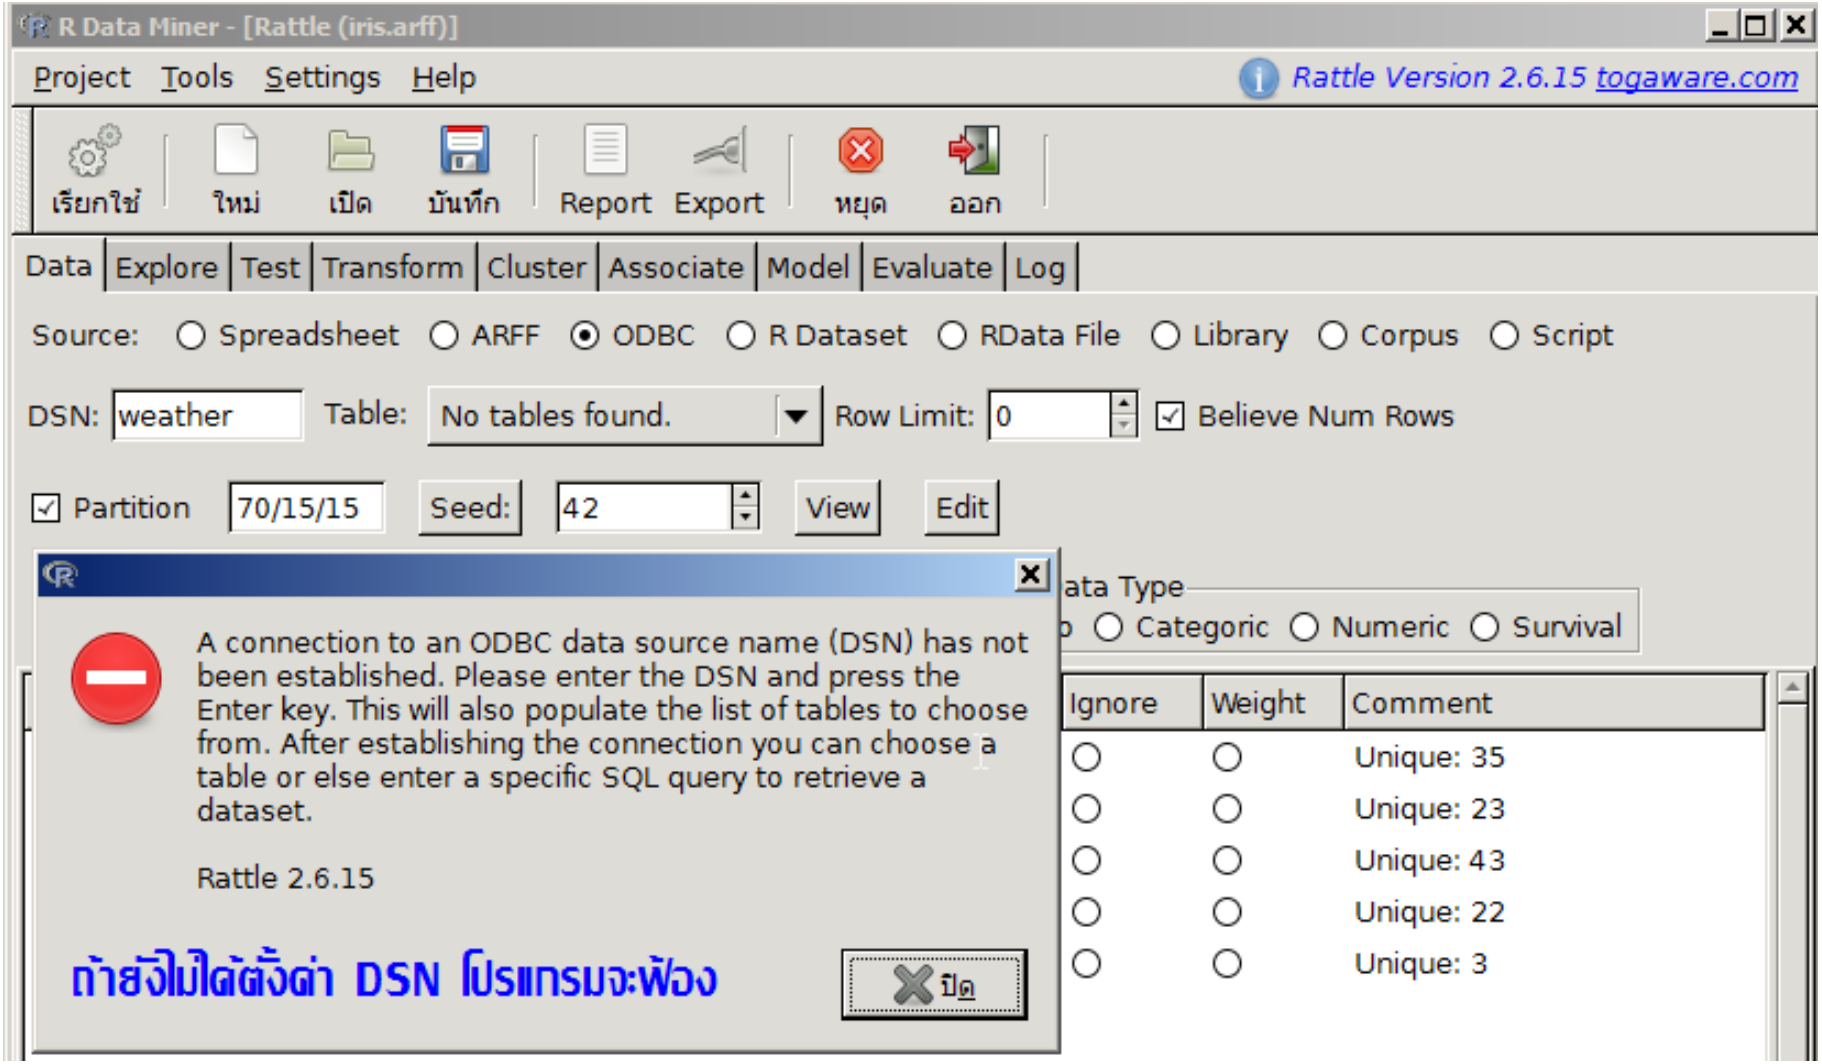

Rattle สามารถเปิด arff ซึ่งเป็น format ของ weka ได้

Numeric จะอ่านมาจาก Numeric,real or interger Dates default ใน weka ต้องบันทึกไว้ตาม ISO-8601 “yyyy-MM-dd 'T'HH:mm:ss”

# Rattle Training 3. Loading Data

- Databases & data warehouse. (SQL,Oracle,MySQL..)
- ต้องเปิดจาก The Open Database Connectivity (ODBC)
- พัฒนามาจาก Structured Query Language (SQL) technology
- R & Rattle use RODBC (Ripley and Lapsley,2010)
  - ตัวอย่างคำสั่งบน R
  - library(RODBC)
  - Channel ←odbcConnect("x", uid="xx",pwd="xxxx")
  - tables <- sqlColumns(channel ,"clients")
  - query <- "SELECT * FROM clients WHERE cost > 5000"
  - myds <- sqlQuery (channel, query)

# Rattle Training 3. Loading Data



# Rattle Training 3. Loading Data

- การเชื่อมต่อกับ Microsoft SQL Server จะต้อง Download SQL ODBC มาติดตั้งเสียก่อน จึงจะสามารถใช้ R เชื่อมต่อได้
- เข้าไปที่ http://www.microsoft.com/download

**Microsoft SQL Server 2008 Native Client**

Microsoft SQL Server 2008 Native Client (SQL Native Client) is a single dynamic-link library (DLL) containing both the SQL OLE DB provider and SQL ODBC driver. It contains run-time support for applications using native-code APIs (ODBC, OLE DB and ADO) to connect to Microsoft SQL Server 2000, 2005, or 2008. SQL Native Client should be used to create new applications or enhance existing applications that need to take advantage of new SQL Server 2008 features. This redistributable installer for SQL Native Client installs the client components needed during run time to take advantage of new SQL Server 2008 features, and optionally installs the header files needed to develop an application that uses the SQL Native Client API.

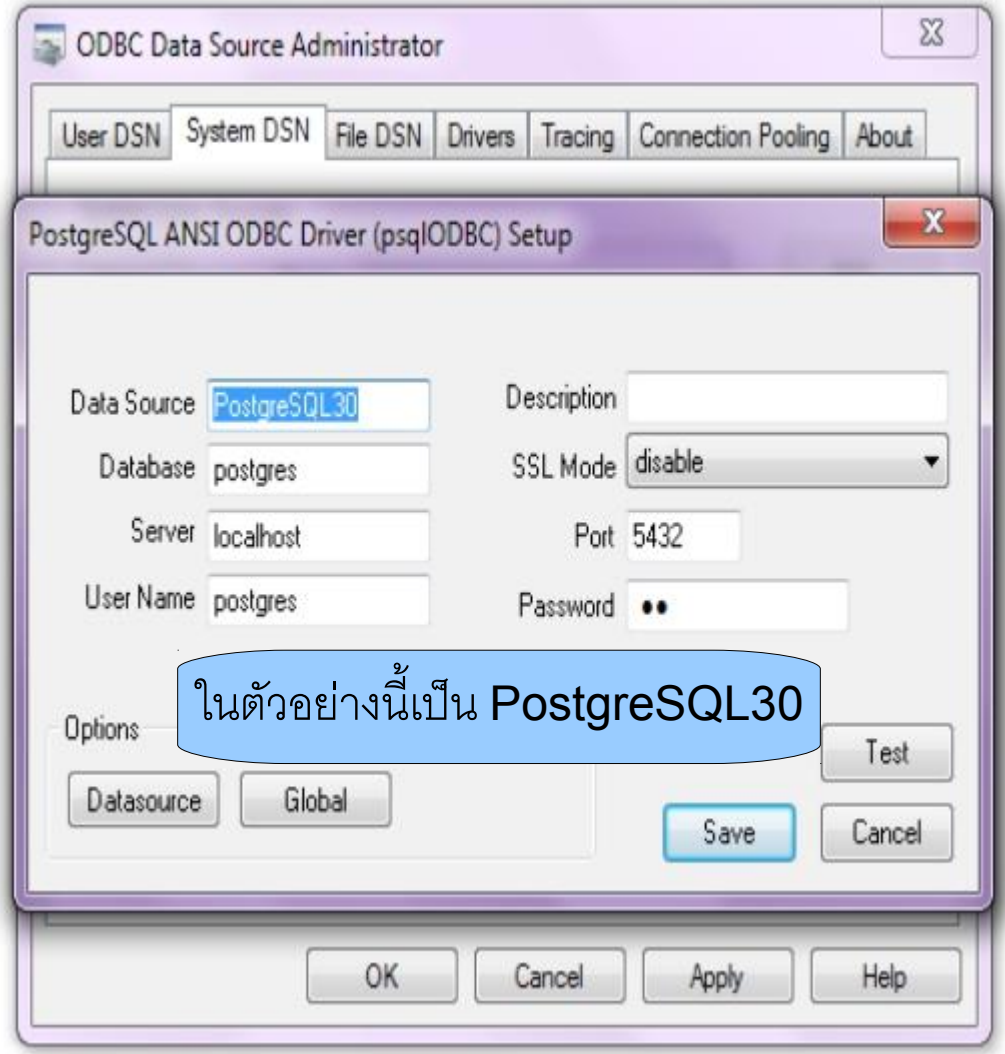
Audience(s): **Customer, Partner, Developer**

**X86 Package** (sqlncli.msi) - 4549 KB
**X64 Package** (sqlncli.msi) - 7963 KB
**IA64 Package** (sqlncli.msi) - 11112 KB

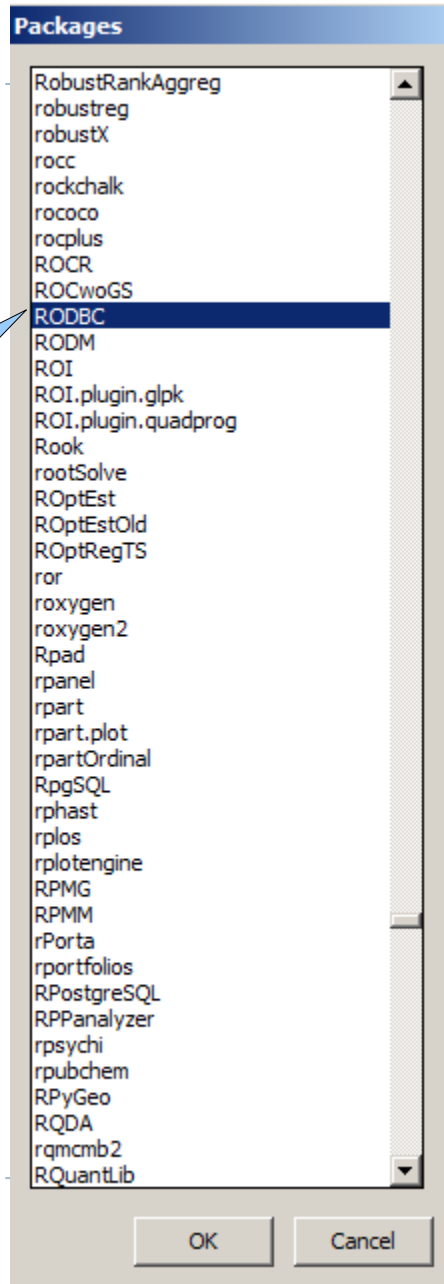
รายละเอียดการตั้งค่าดูหน้าถัดไป

http://www.microsoft.com/download

# Rattle Training 3. Loading Data

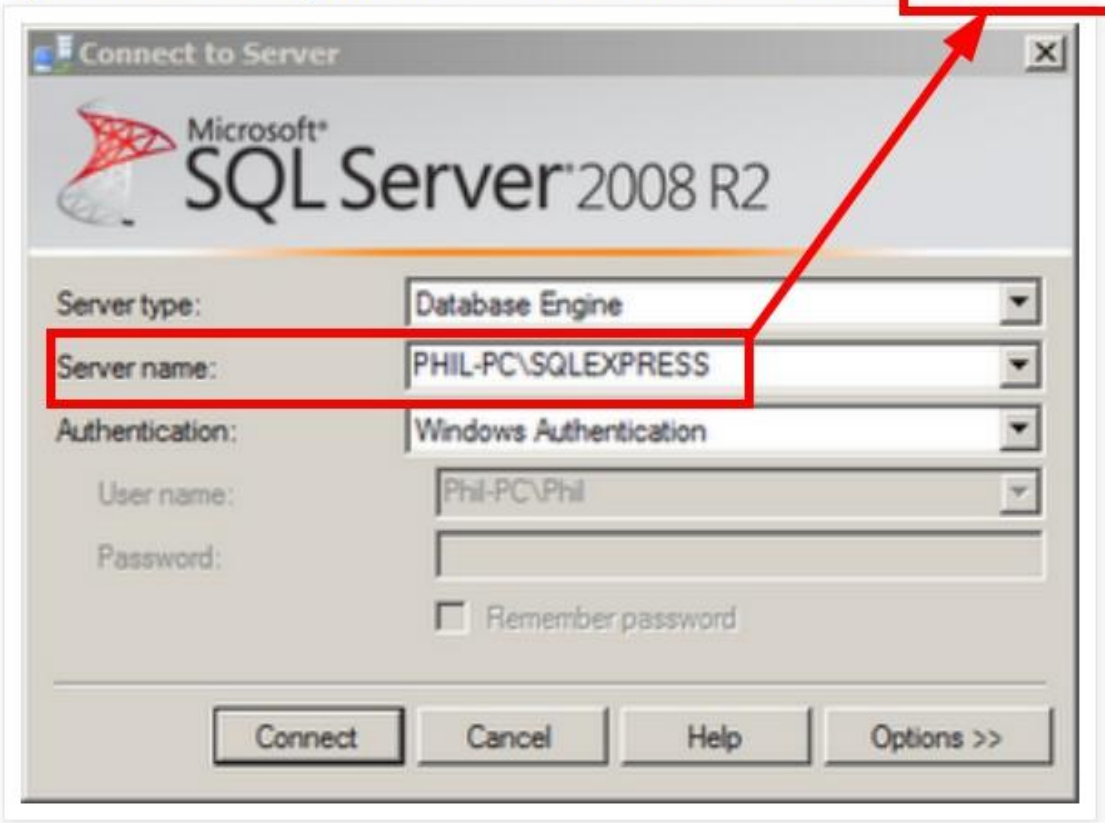



ใน R ให้ติดตั้ง RODBC



# Rattle Training 3. Loading Data

1. the driver name (**SQL Server** in our case)
2. the database server name. This can be tricky to remember. For SQL Server the easiest way to find it is when you start up the SQL Server Management Studio. In the picture below you will see the server name is PHIL-PC\SQLEXPRESS.



# Rattle Training 3. Loading Data

- ระวังในเรื่อง **R script** เฉพาะเช่น '\' ที่เกี่ยวข้องกับ **Path** ที่อ้างฐานข้อมูล

There is one *gotcha* here. You will notice in the R script we have an extra '\'

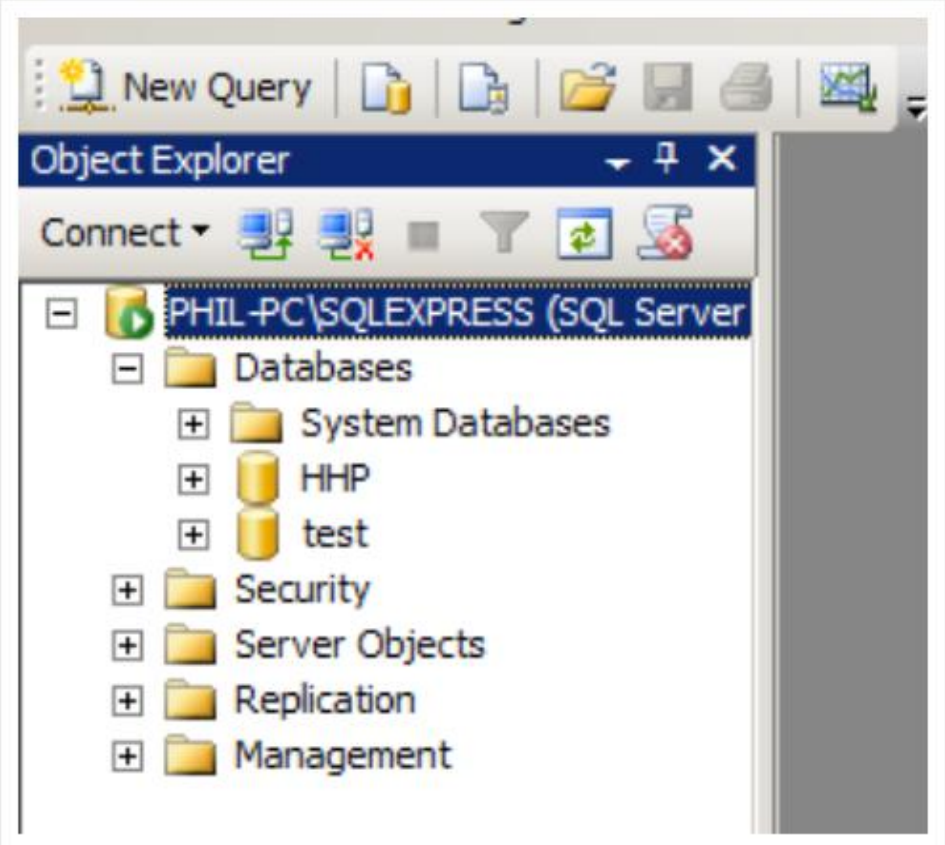
*server=PHIL-PC\\SQLEXPRESS*

This is because '\' is a special charater in R, so you need to put two of them together to tell it that you really do mean '\'. This is useful to know when you have paths of files etc.

Another thing to note above, we are in Windows Authentication mode, which means we won't have to worry with passwords.

# Rattle Training 3. Loading Data

3. The name of the database in the database server that you want to connect to. You can discover your options from within the Management Studio. Here we have *HHP* and *test*



# Rattle Training 3. Loading Data

- การเชื่อมต่ออาจจะใช้คำสั่ง odbcDriverConnect (“....”)

So when we string all this together we get,

```
conn <- odbcDriverConnect("driver=SQL Server;database=HHP;server=PHIL-PC\\SQLEXPRESS;")
```

- หรือ sqlFetch (“...”)

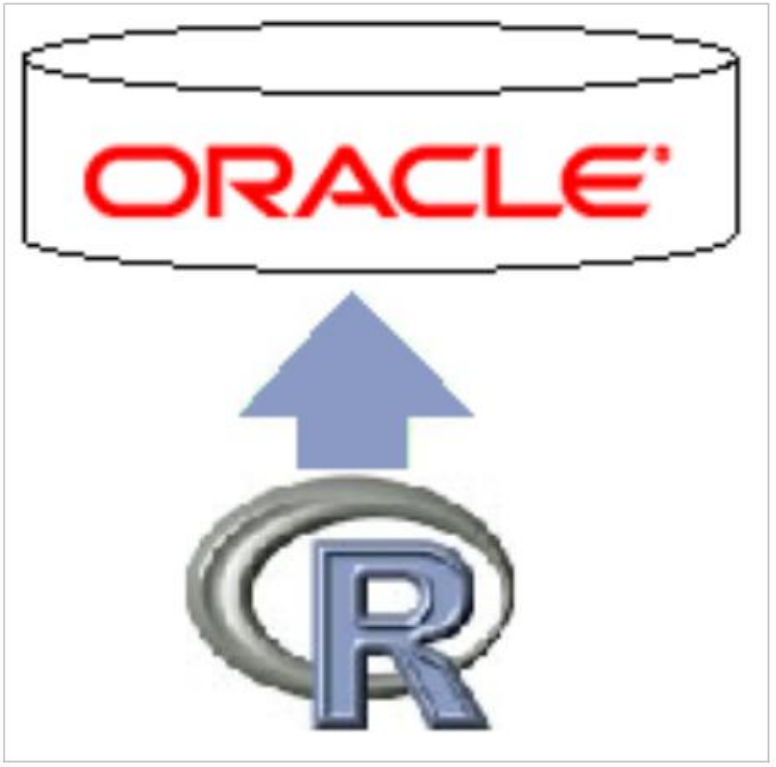
Once the channel is created, I can load the data from the table via the sqlFetch command in R as follows:

```
> loanstatus <- sqlFetch(ch,"tblElPasoCountyLoanStatus")
```

# Rattle Training 3. Loading Data

- R connect ORACLE.
- Must use ODBC too.
- มีให้เลือก Windows,Linux

**R and Oracle HR Part I - Set Up and Connect**




There has been recent interest in the attention that Oracle has been giving to R. This has been related to the use of Oracle Data Mining which is a paid option to Oracle. This is the first in a series of posts that can be run using the Oracle HR Schema which is available in various versions or Oracle including its free Oracle XE version.

# Rattle Training 3. Loading Data



( Sign In/Register for Account | Help ) United States Communities I am a... I want to...

**Products and Services** | **Solutions** | **Downloads** | **Store** | **Support** | **Training** | **Partners** | **About**

Oracle Technology Network › Database › Windows › Downloads

- Database 11g
- Database Focus Areas
- Database Options
- Database Express Edition
- Database Upgrade
- Berkeley DB
- NoSQL Database
- TimesTen In-Memory Database
- Exadata
- Database Mobile Server
- RDB
- Audit Vault
- Secure Backup
- Real Application Clusters
- Clusterware
- Cloud Storage

What's New | For Beginners | Products | Technical Information | **Downloads**

OracleODBC Drivers for Windows (32bit) Download Page

NOTE: The following ODBC Drivers are ODBC Version 3.52, Level 2 compatible drivers.

- Oracle ODBCDrivers for Oracle 10.2

| Version | Date | Size | |
|---|---|---|---|
| 10.2.0.3.0 | 12-Dec-2006 | 340 KB | New |
| 10.2.0.2.0 | 08-Sep-2006 | 2.3 MB | |

- Oracle ODBC Drivers for Oracle 10.1

| Version | Date | Size |
|---|---|---|
| 10.1.0.5.0 | 25-Apr-2006 | 2.1 MB |

- Oracle ODBC Drivers for Oracle 9.2.0

| Version | Date | Size |
|---|---|---|
| 9.2.0.8.0 | 20-Dec-2006 | 280 KB |

More Downloads

- 64-bit Oracle Data Access Components (ODAC)
- ODBCInstant Client Driver for
  - Windows 32-bit
  - Windows x86-64bit
  - Linux x86-32bit
  - Solaris SPARC 64bit
  - Solaris SPARC 32bit

Oracle ODBC DriverResources

- Documentation
- Discussion Forum

http://www.oracle.com/technetwork/database/windows/downloads/

# Rattle Training 3. Loading Data

## Installation and Configuration

1) Install Oracle XE (or get access to another Oracle database). There is a fair amount of documentation, but in practice the installation is pretty straightforward on Windows with a user with Admin rights.

2) Install the sample schema if needed. This would require a database user with special privileges - so you might need to get a DBA involved if you aren't using your own machine.

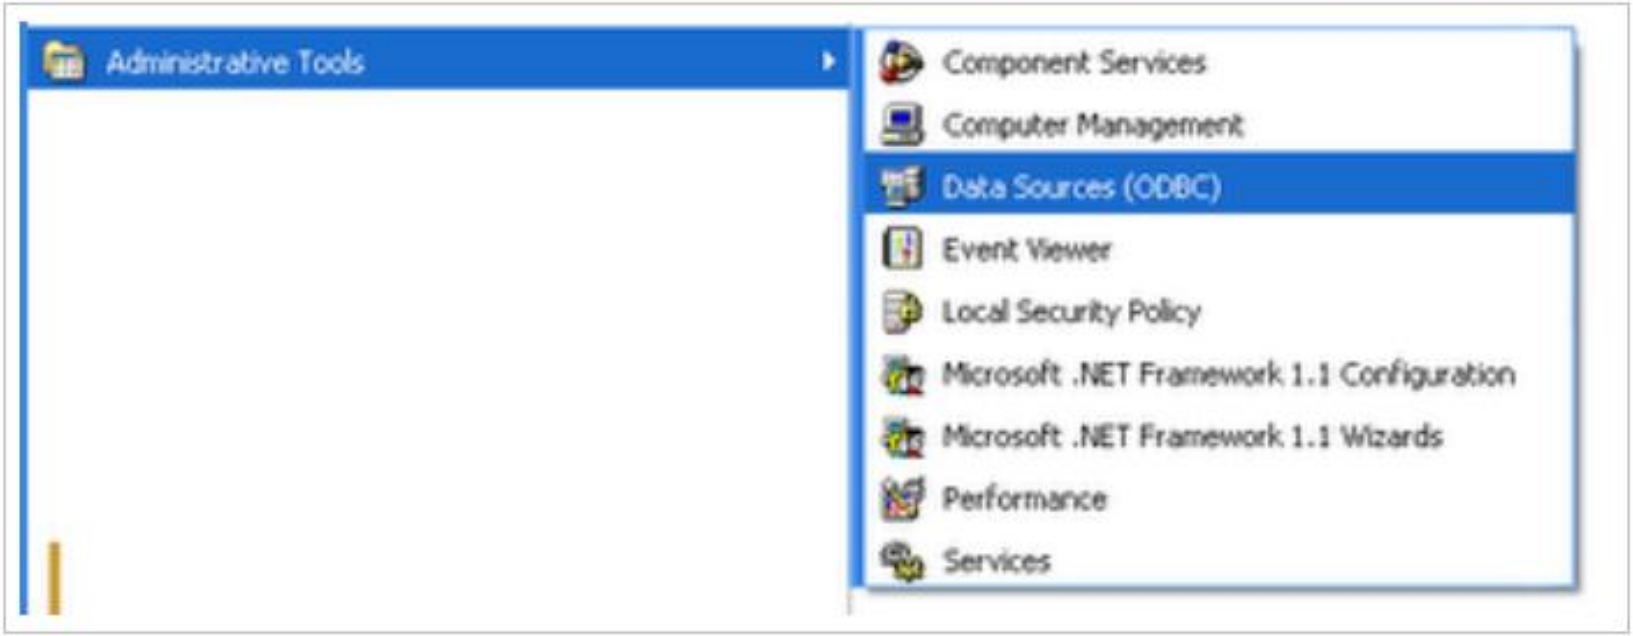
3) Unlock the HR user account. This can also be done by logging in as the system user at a SQL*Plus command prompt and executing

# Rattle Training 3. Loading Data

## Configure ODBC Connection

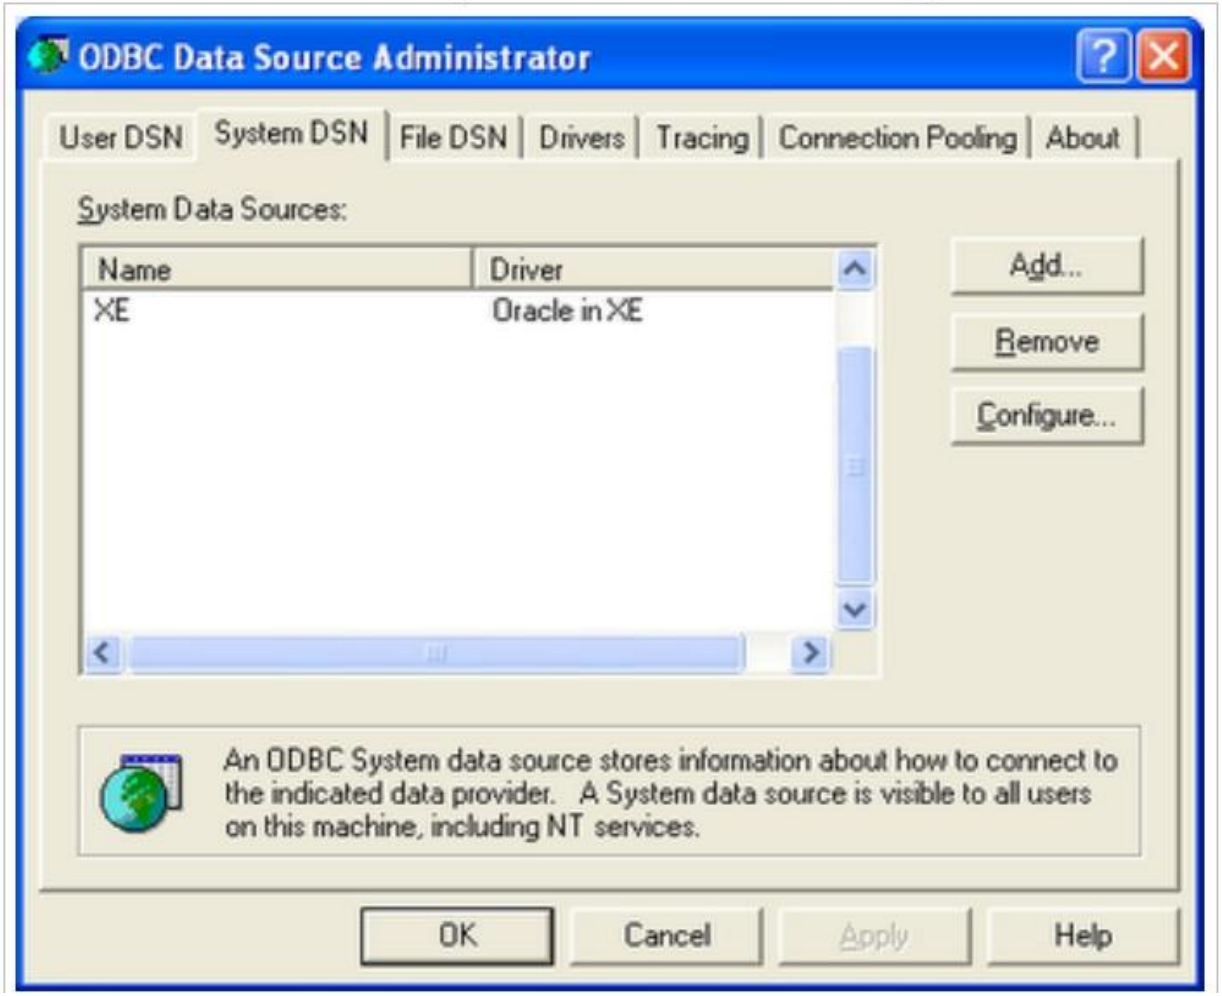
These examples will rely upon the RODBC package.

1) Find the Data Sources (ODBC) option under Administrative Tools.



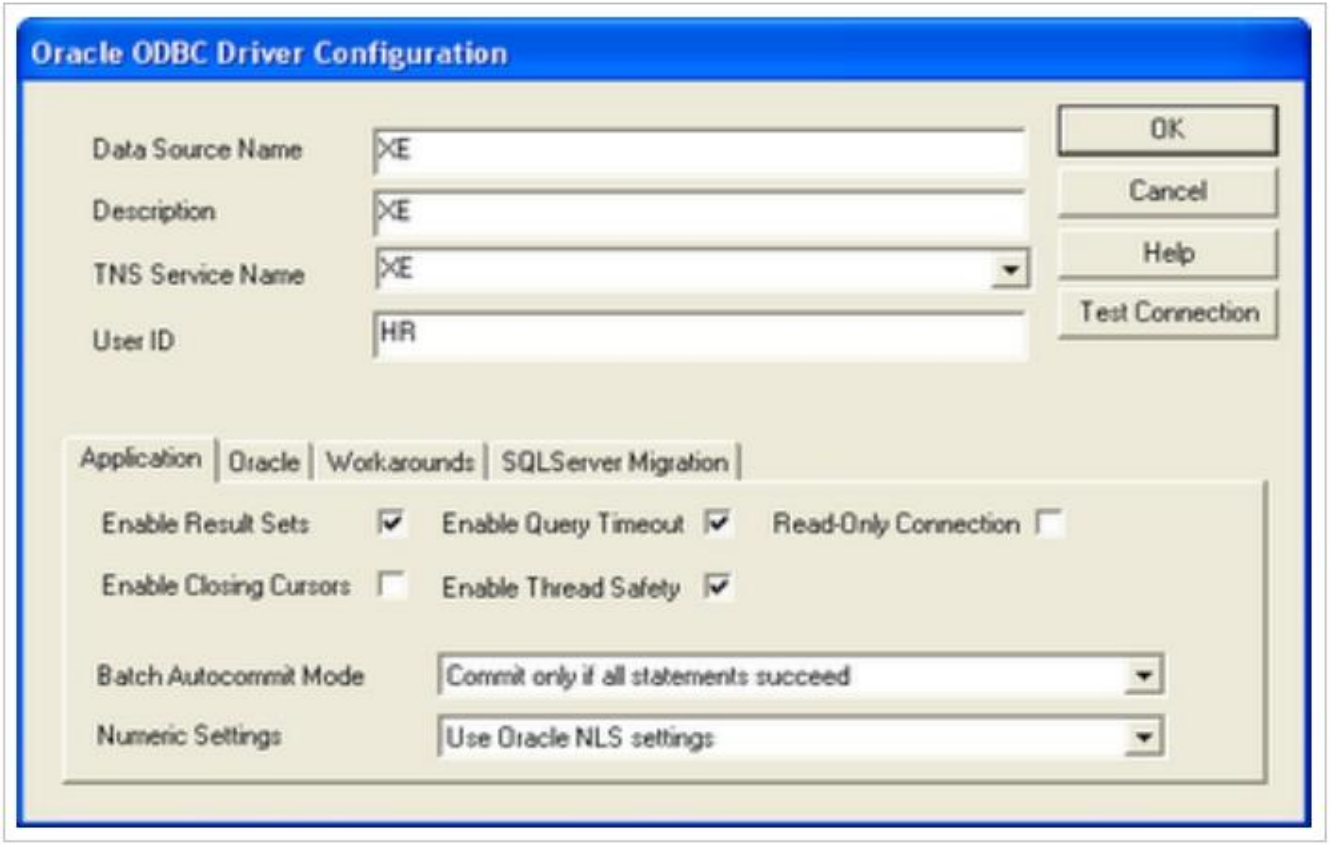
# Rattle Training 3. Loading Data

2) Add a connection to your database if needed. In the case of Oracle XE, choose the add button if you do not have an XE configured.



# Rattle Training 3. Loading Data

Configure the details in the popup window. You probably will only need to enter the Data Source Name, Description, TNS Service Name and User ID. Just leave other settings as defaulted.



# Rattle Training 3. Loading Data

## Test R connection with Oracle

Install RODBC if you have not already done so. Run the following program from R.

```
library(RODBC)
ch <- odbcConnect("XE",uid="HR",pwd="HR")

sqlTables(ch,schema='HR')
```

You can execute queries using the connection as well.

```
sqlQuery(ch, "select
sys_context('USERENV','DB_NAME') db from dual")
```

# Rattle Training 3. Loading Data

- R Connect MySQL.

การเชื่อมต่อ R กับ MySQL.

1. Install ODBC Driver for MySQL at:
http://dev.mysql.com/downloads/connector/odbc/5.1.html

2. Open Microsoft Windows Control Panel and then double-click the **Administrative Tools** icon. Double-click on the **Data Sources (ODBC)** icon. Add a new User DSN called pfx with a MySQL ODBC 5.1 Diver.

3. Once a new User DSN is created, select it and press Configure

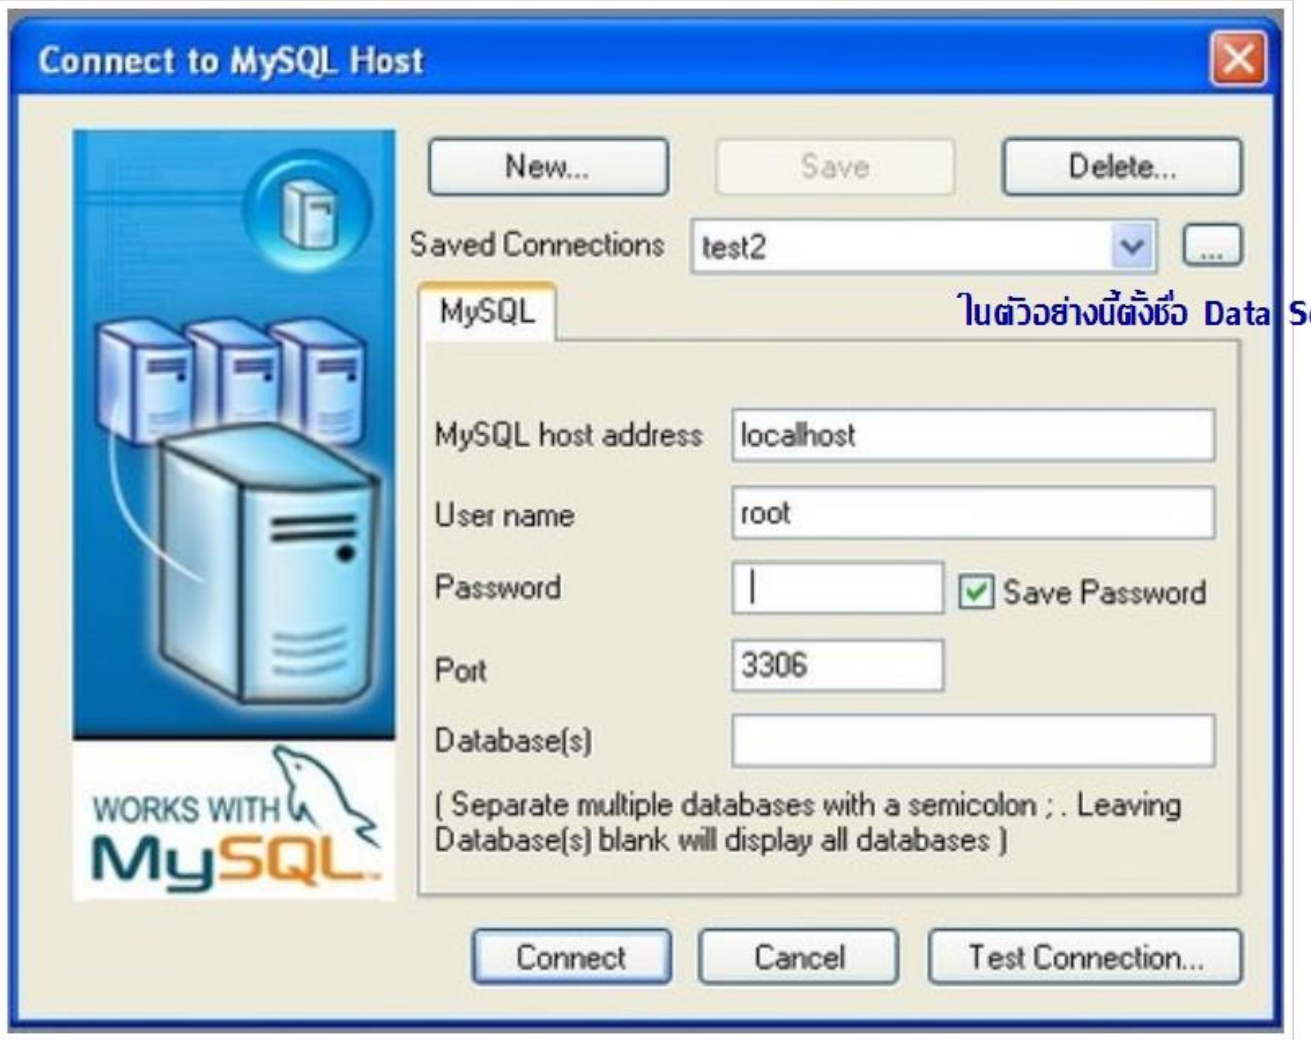
Set the following values (I am not 100% sure these are the same for all Window machines)
Server: localhost
port: 3306
user: root
Database: php2

These are the same as the ones on the SQLyog login and the Pitch F/X dataset installed

# Rattle Training 3. Loading Data



# Rattle Training 3. Loading Data



# Rattle Training 3. Loading Data

- ใช้ library(RODBC) และคำสั่งข้างล่าง

**4.** Open R again

In the R console run:

```
library(RODBC)
channel <- odbcConnect('pfx')
odbcGetInfo(channel)
sqlTables(channel)
```

All 4 lines can be copy and paste at once. These will connect R to database and let you know that they are connect. No errors should be seen and the Pitch FX tables should be listed.

# Rattle Training 3. Loading Data

- การกรองข้อมูลแบบ SQL สามารถทำได้ด้วยคำสั่ง sqlQuery (“...”)

**5.** Running a query. First you need to tell R that you are plotting a query.

Here is the query for Joe Mauer's home runs. I was having some problems, so I added "as x" and "as y" to describe the px and pz coordinates. Note, the entire query needs to be on a single line.

```
query <- sqlQuery(channel, "select p.px as x, p.pz as y from atbats a join pitches p on p.ab_id = a.ab_id
join games g on g.game_id = a.game_id join players pl on pl.eliasid = a.batter where pl.last = 'Mauer' and
pl.first = 'Joe' and g.date like '2009%' and a.event = 'Home Run' and p.type = 'X';")
```

Also the extents of data can be set at this time with the xlim and ylim commands

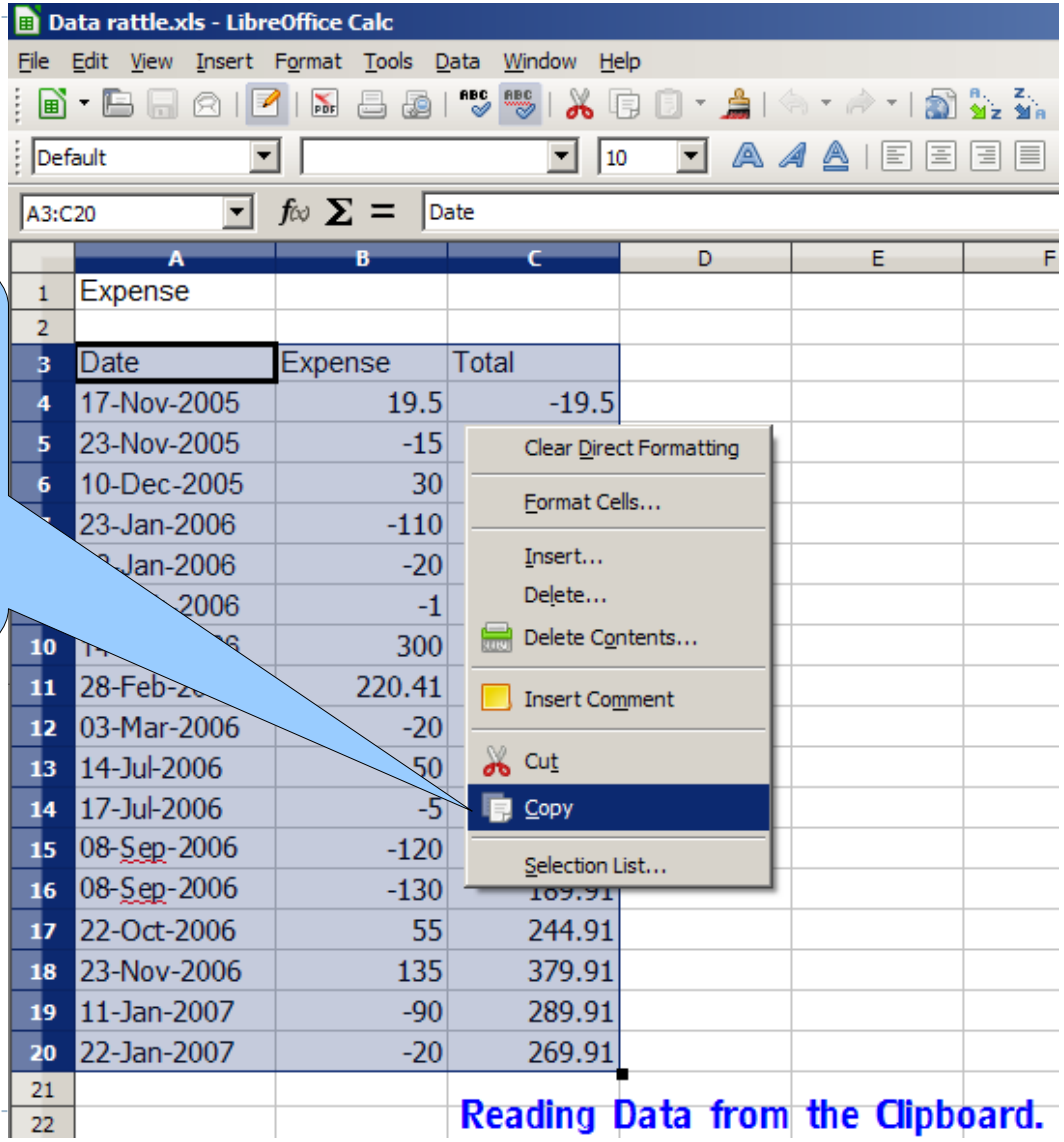
# Rattle Training 3. Loading Data

- แหล่งความรู้เพิ่มเติมเกี่ยวกับการเชื่อมต่อ R กับ OBDC

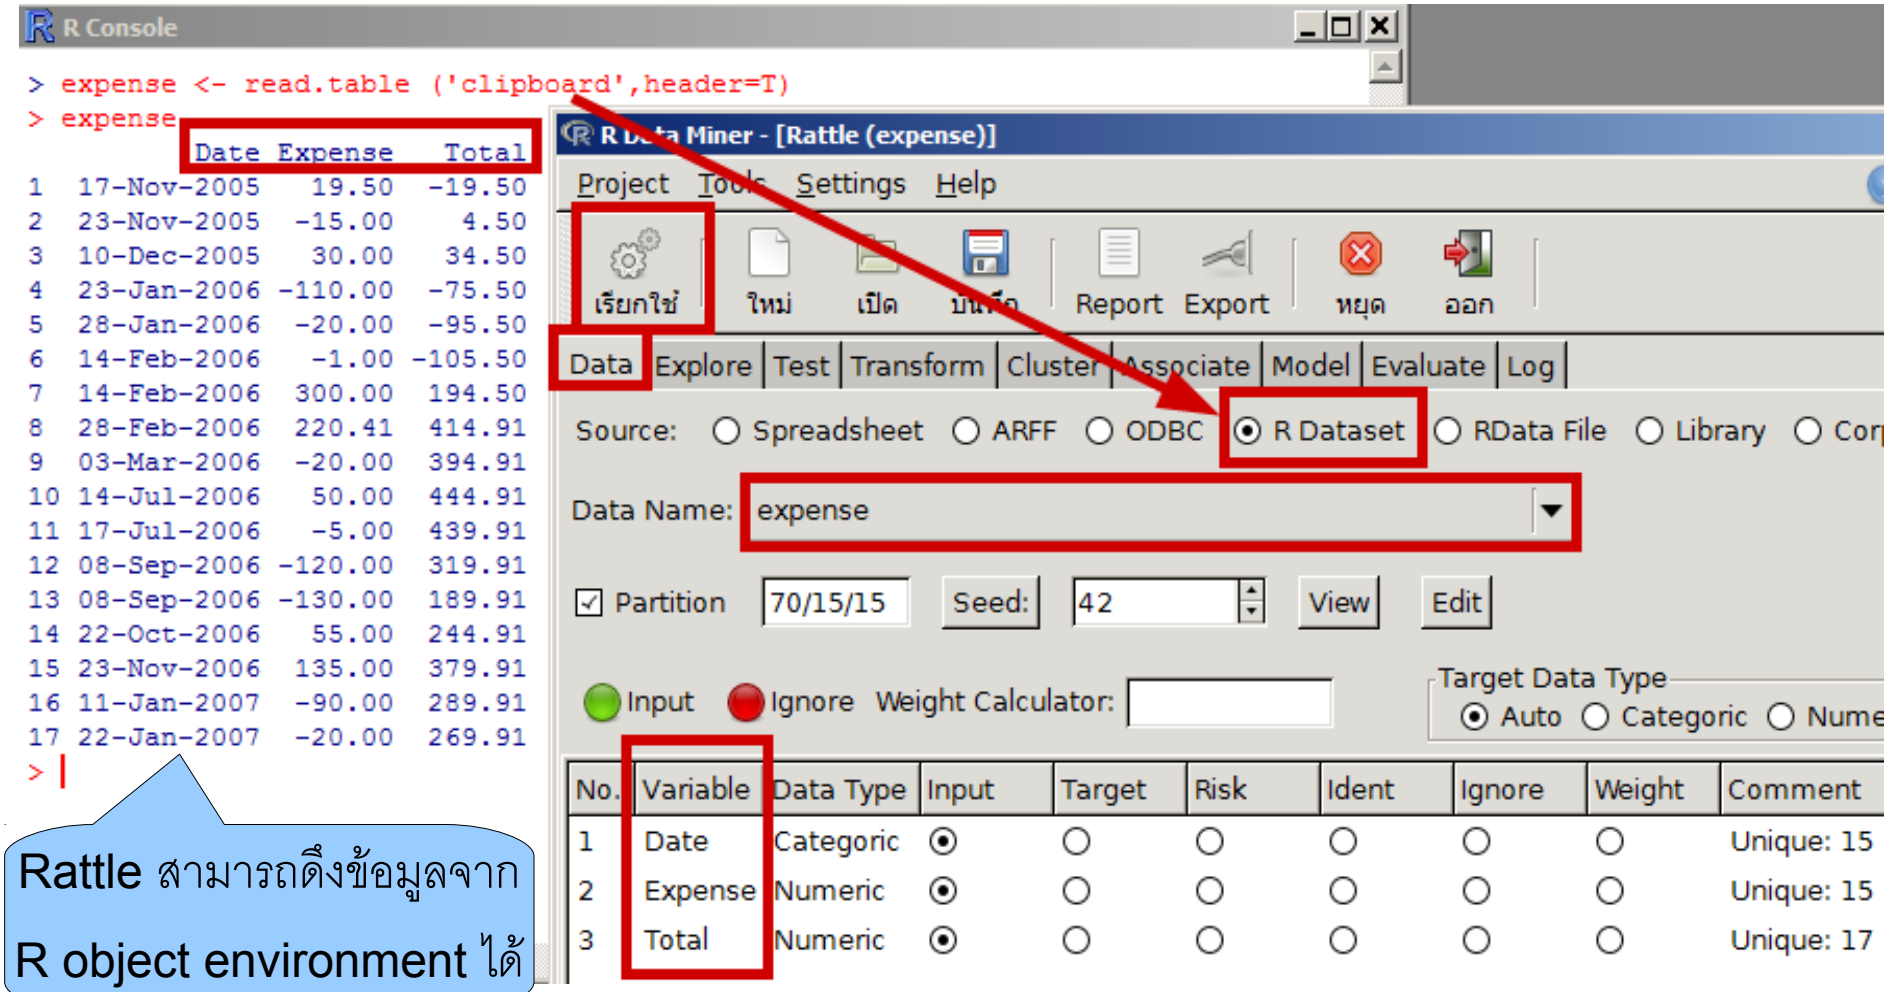
- R vs Microsoft SQL Server 2012
  - http://blog.sqltrainer.com/2011/12/statistical-analysis-with-r-and.html
- Fun with Decision Trees using R and SQL Server
  - http://blog.sqltrainer.com/
- Knowledge Discovery in Databases -KDD using PostgreSQL and #Rstats
  - http://www.decisionstats.com/tag/knowledge-discovery/
- R and Oracle HR Part I - Set Up and Connect
  - http://www.r-chart.com/2010/07/r-and-oracle-hr-part-i-set-up-and.html
- Using R with MySQL #rstats
  - http://www.decisionstats.com/using-r-with-mysql/

# Rattle Training 3. Loading Data

เปิดไฟล์ spreadsheet ขึ้นมา แล้ว Copy ไว้ข้อมูลก็จะถูกเก็บไว้ที่หน่วยความจำ Clipboard ซึ่ง R สามารถนำมาใช้ได้

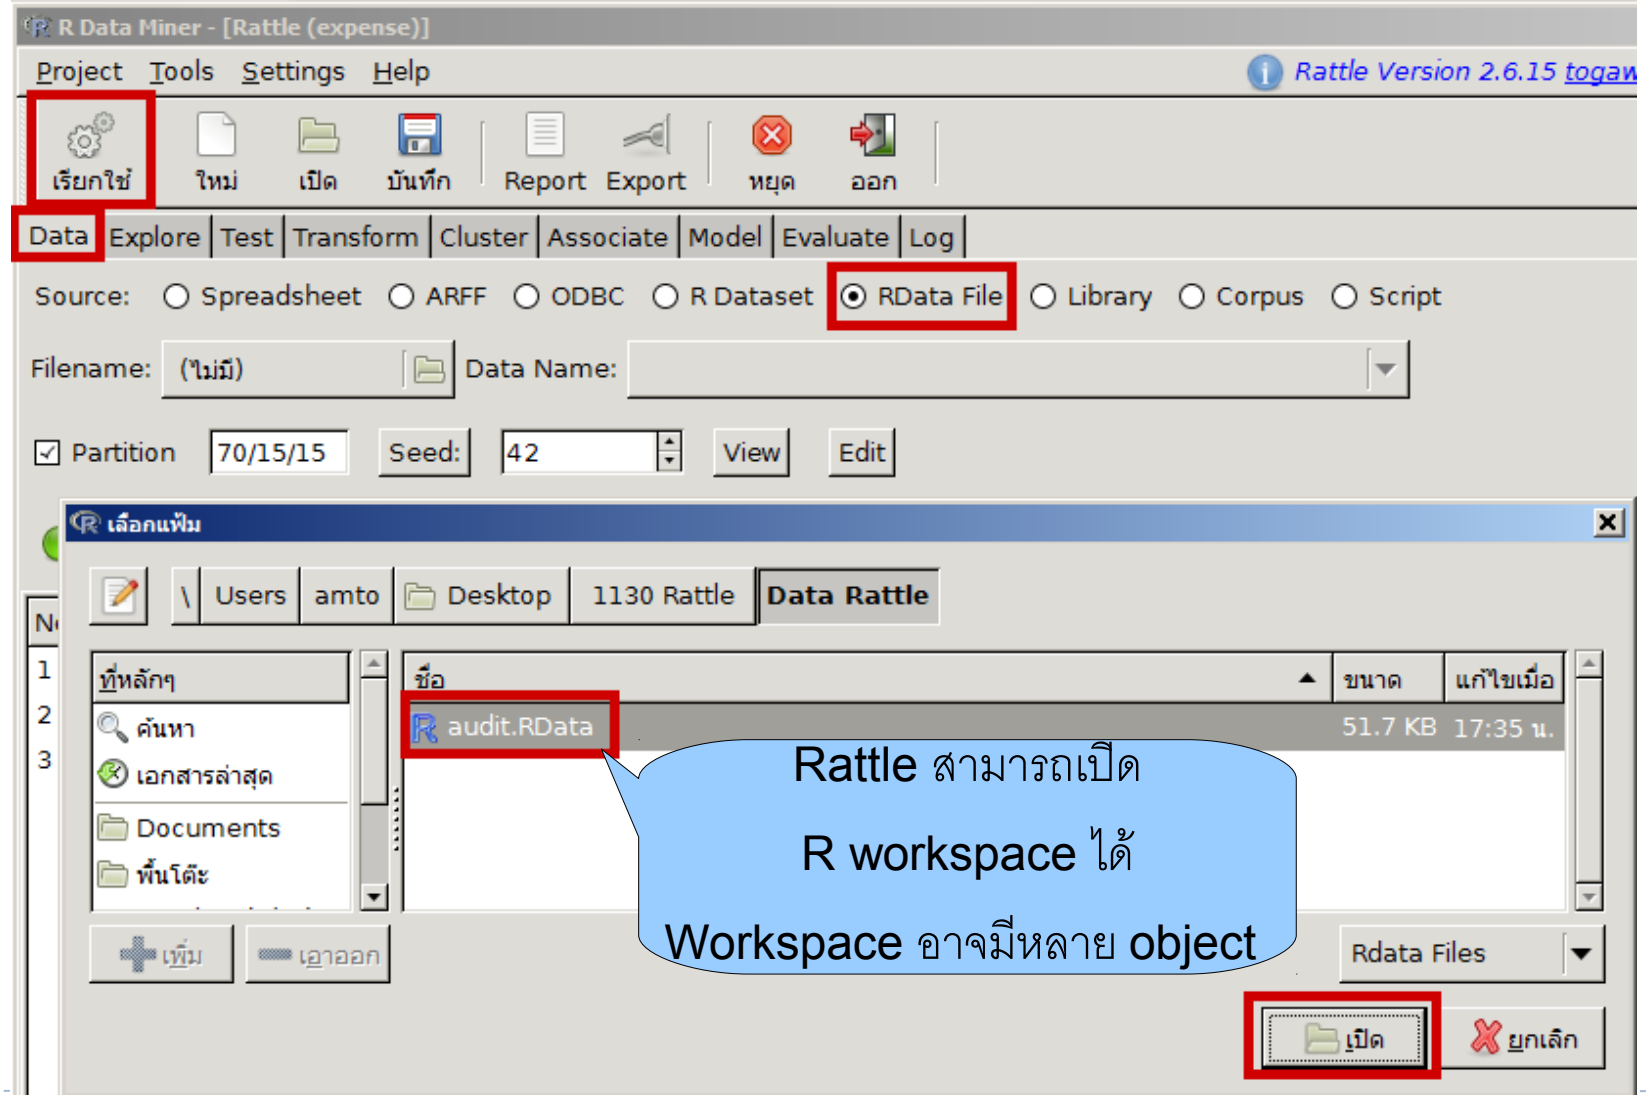


# Rattle Training 3. Loading Data

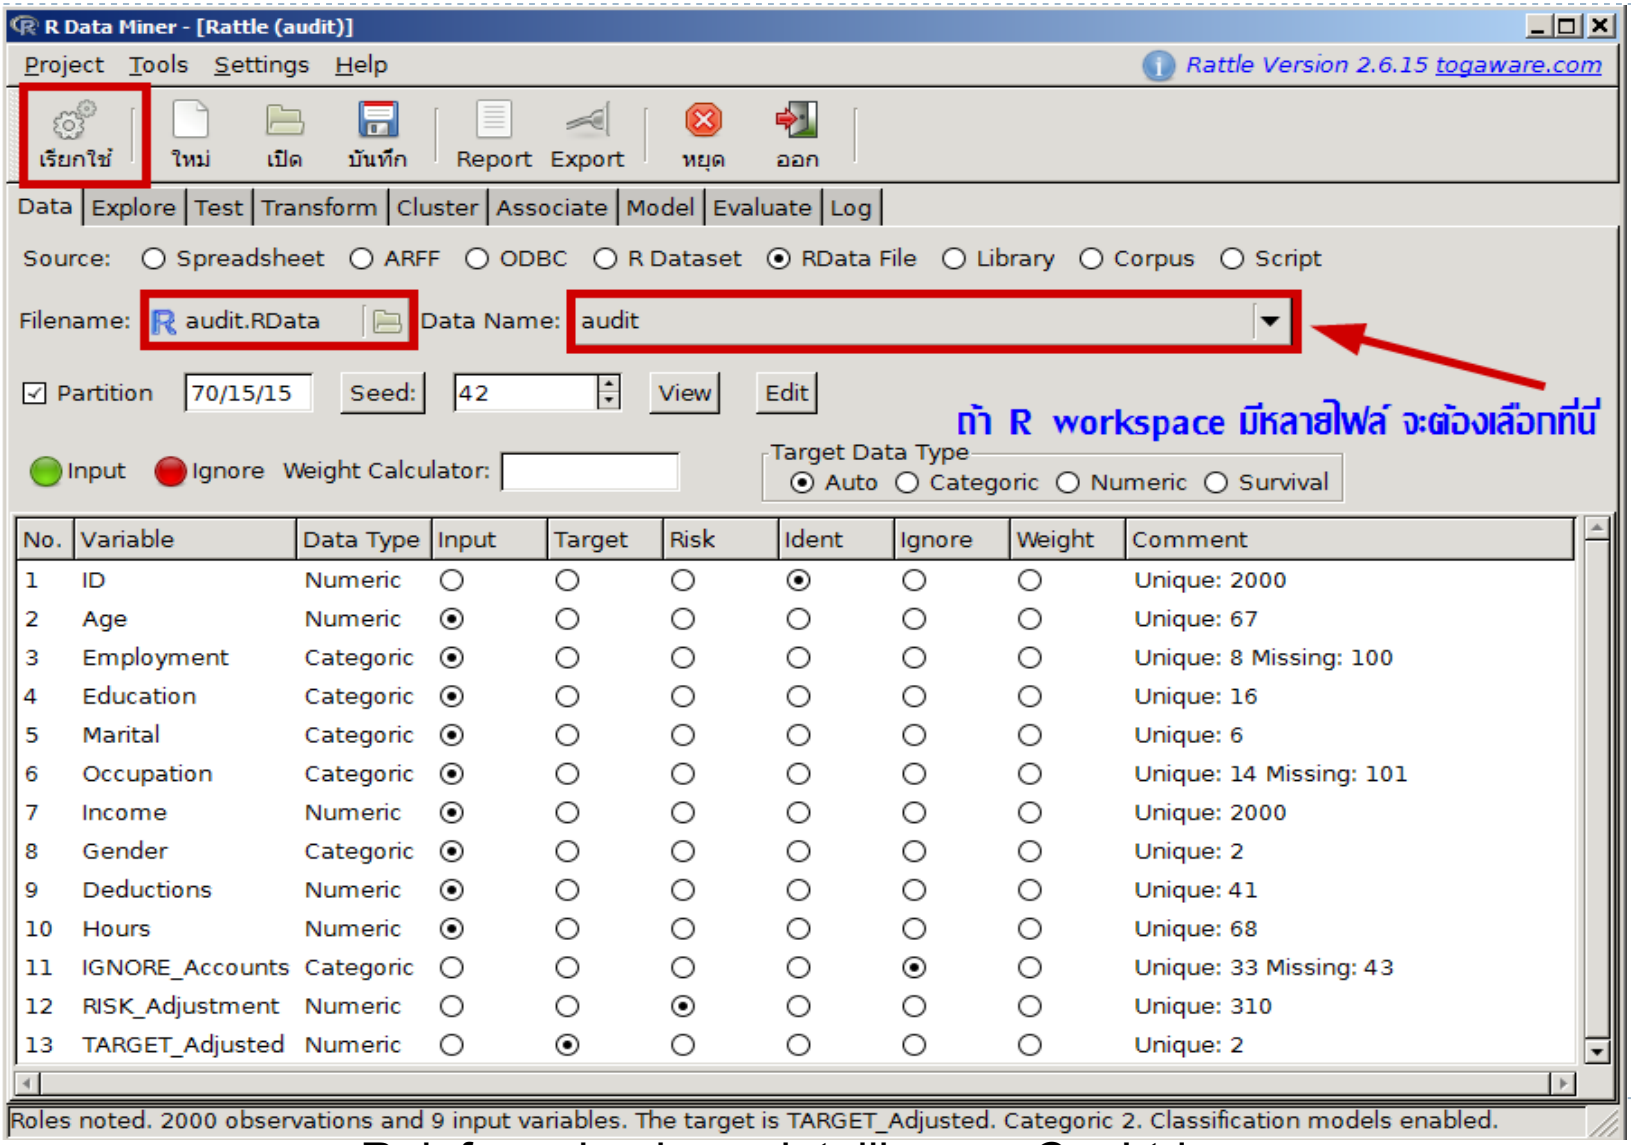



Rattle สามารถดึงข้อมูลจาก R object environment ได้

# Rattle Training 3. Loading Data



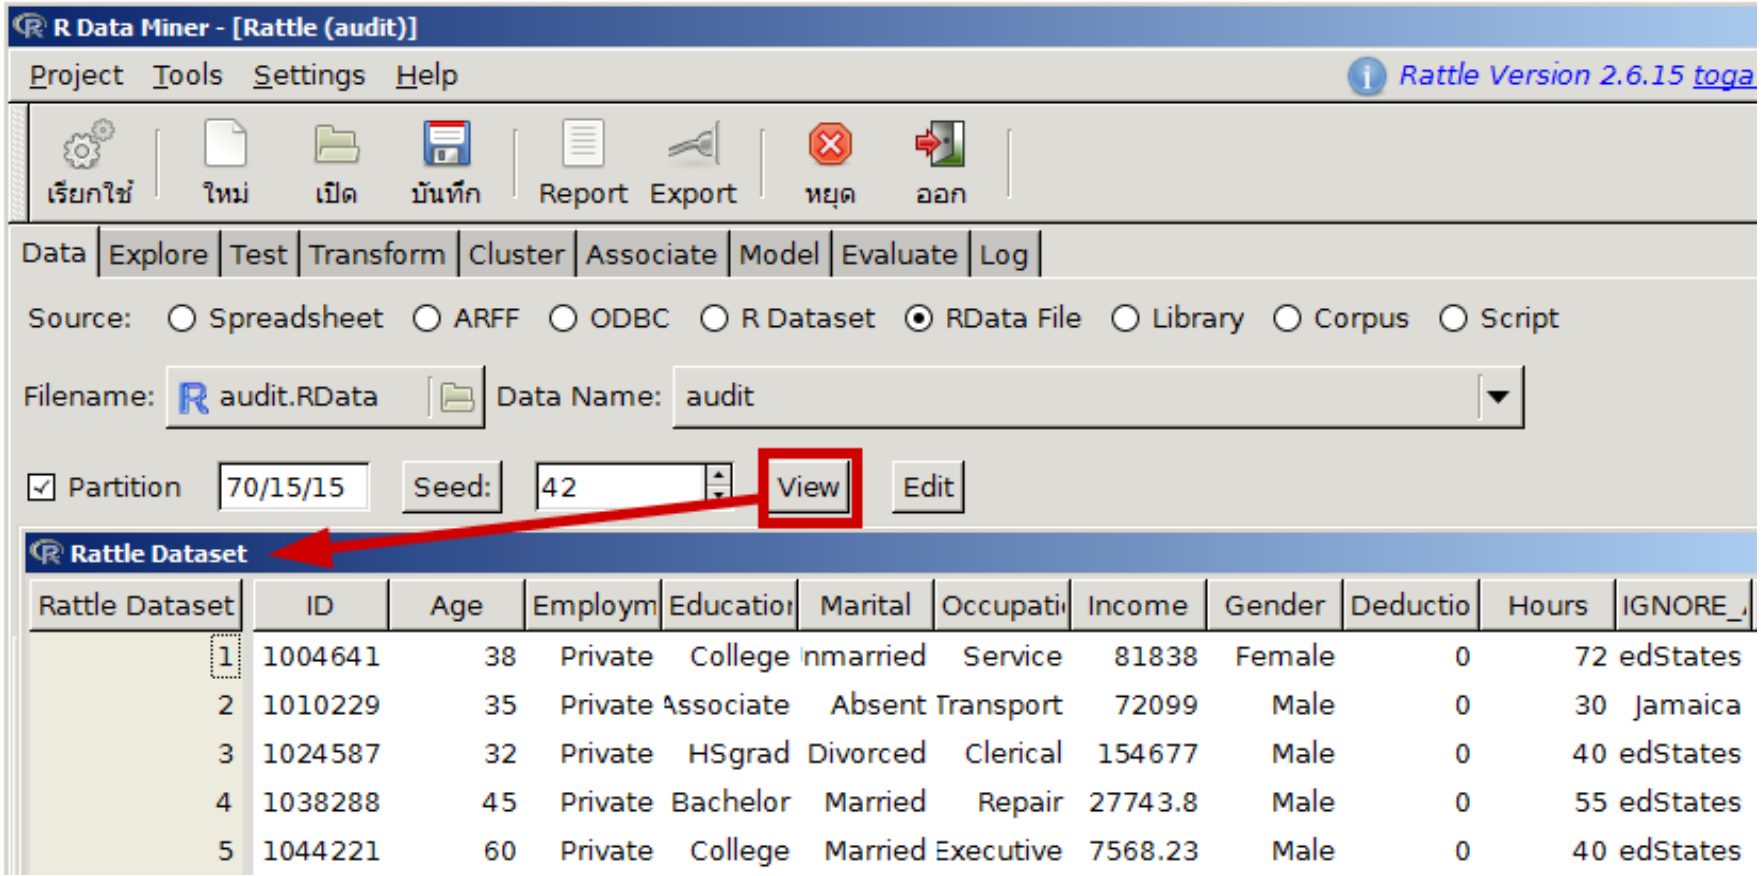
# Rattle Training 3. Loading Data




| No. | Variable | Data Type | Input | Target | Risk | Ident | Ignore | Weight | Comment |
|---|---|---|---|---|---|---|---|---|---|
| 1 | ID | Numeric | ○ | ○ | ○ | ◉ | ○ | ○ | Unique: 2000 |
| 2 | Age | Numeric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 67 |
| 3 | Employment | Categoric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 8 Missing: 100 |
| 4 | Education | Categoric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 16 |
| 5 | Marital | Categoric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 6 |
| 6 | Occupation | Categoric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 14 Missing: 101 |
| 7 | Income | Numeric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 2000 |
| 8 | Gender | Categoric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 2 |
| 9 | Deductions | Numeric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 41 |
| 10 | Hours | Numeric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 68 |
| 11 | IGNORE_Accounts | Categoric | ○ | ○ | ○ | ○ | ◉ | ○ | Unique: 33 Missing: 43 |
| 12 | RISK_Adjustment | Numeric | ○ | ○ | ◉ | ○ | ○ | ○ | Unique: 310 |
| 13 | TARGET_Adjusted | Numeric | ○ | ◉ | ○ | ○ | ○ | ○ | Unique: 2 |

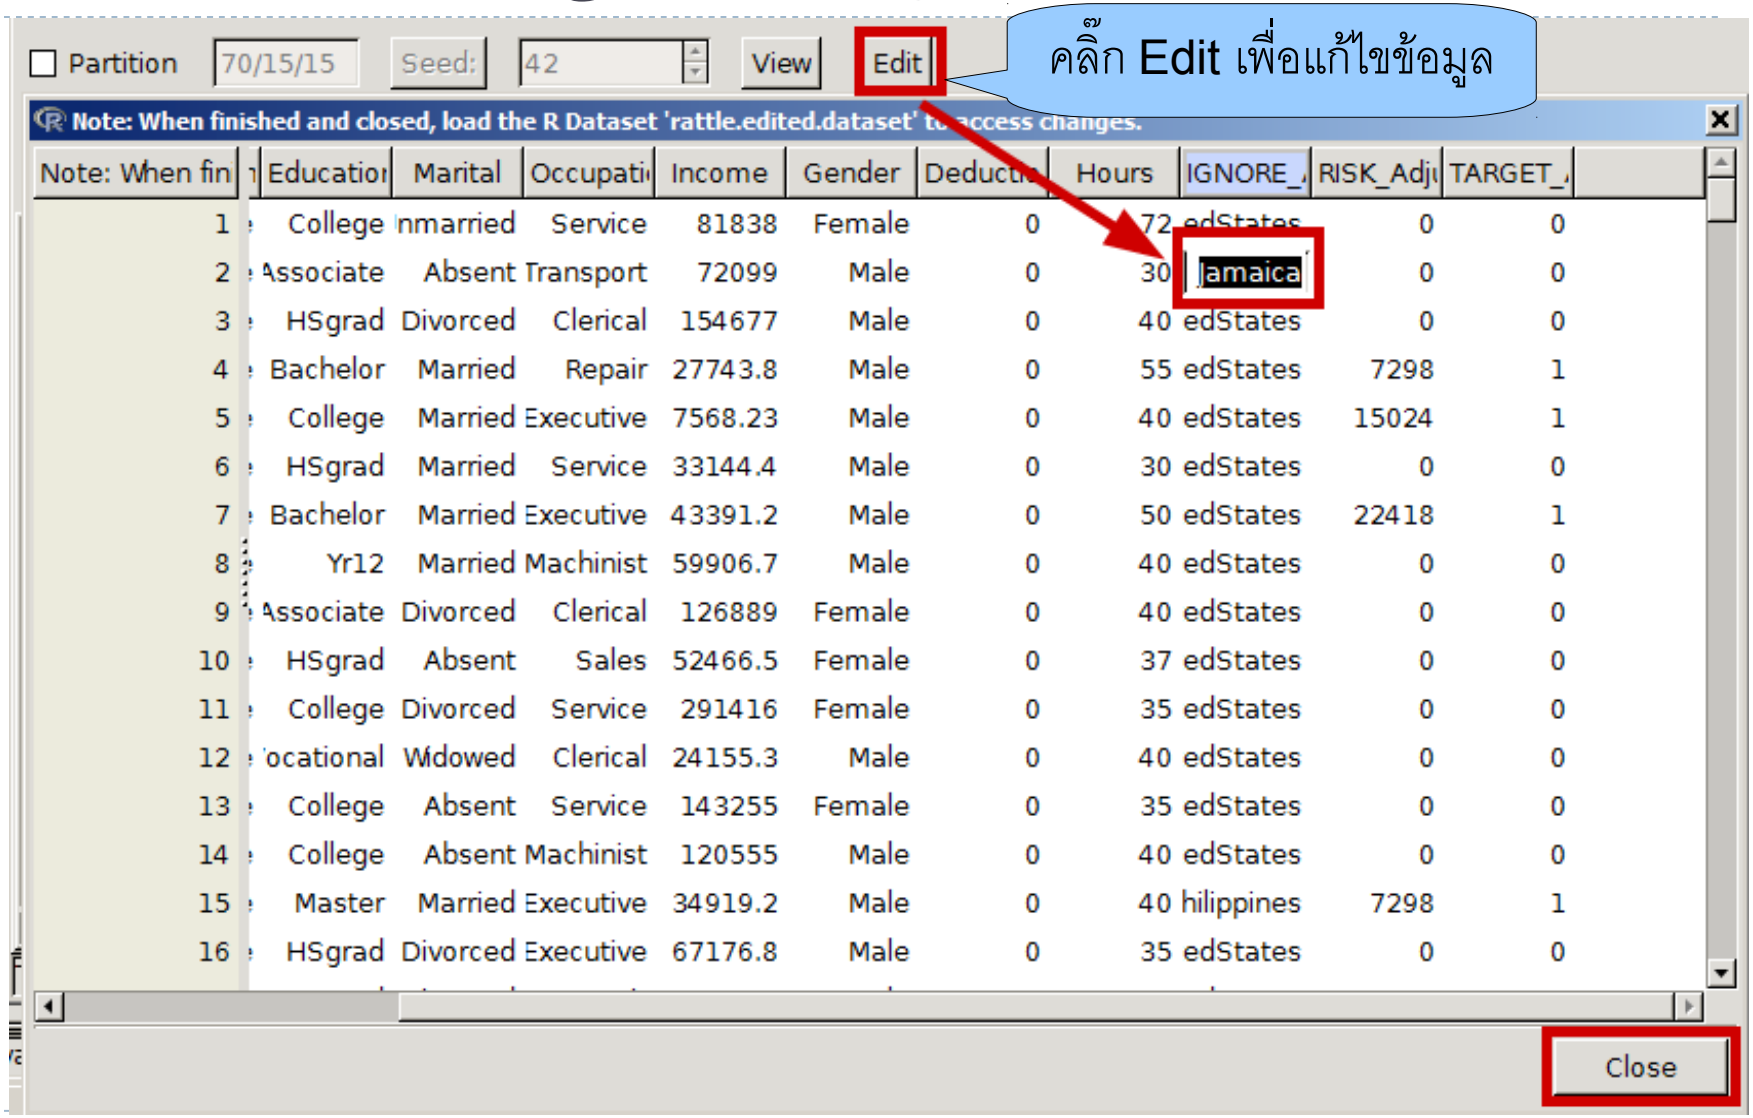
# Rattle Training 3. Loading Data

- กดปุ่ม **View** เพื่อดูข้อมูลในรูปของตาราง



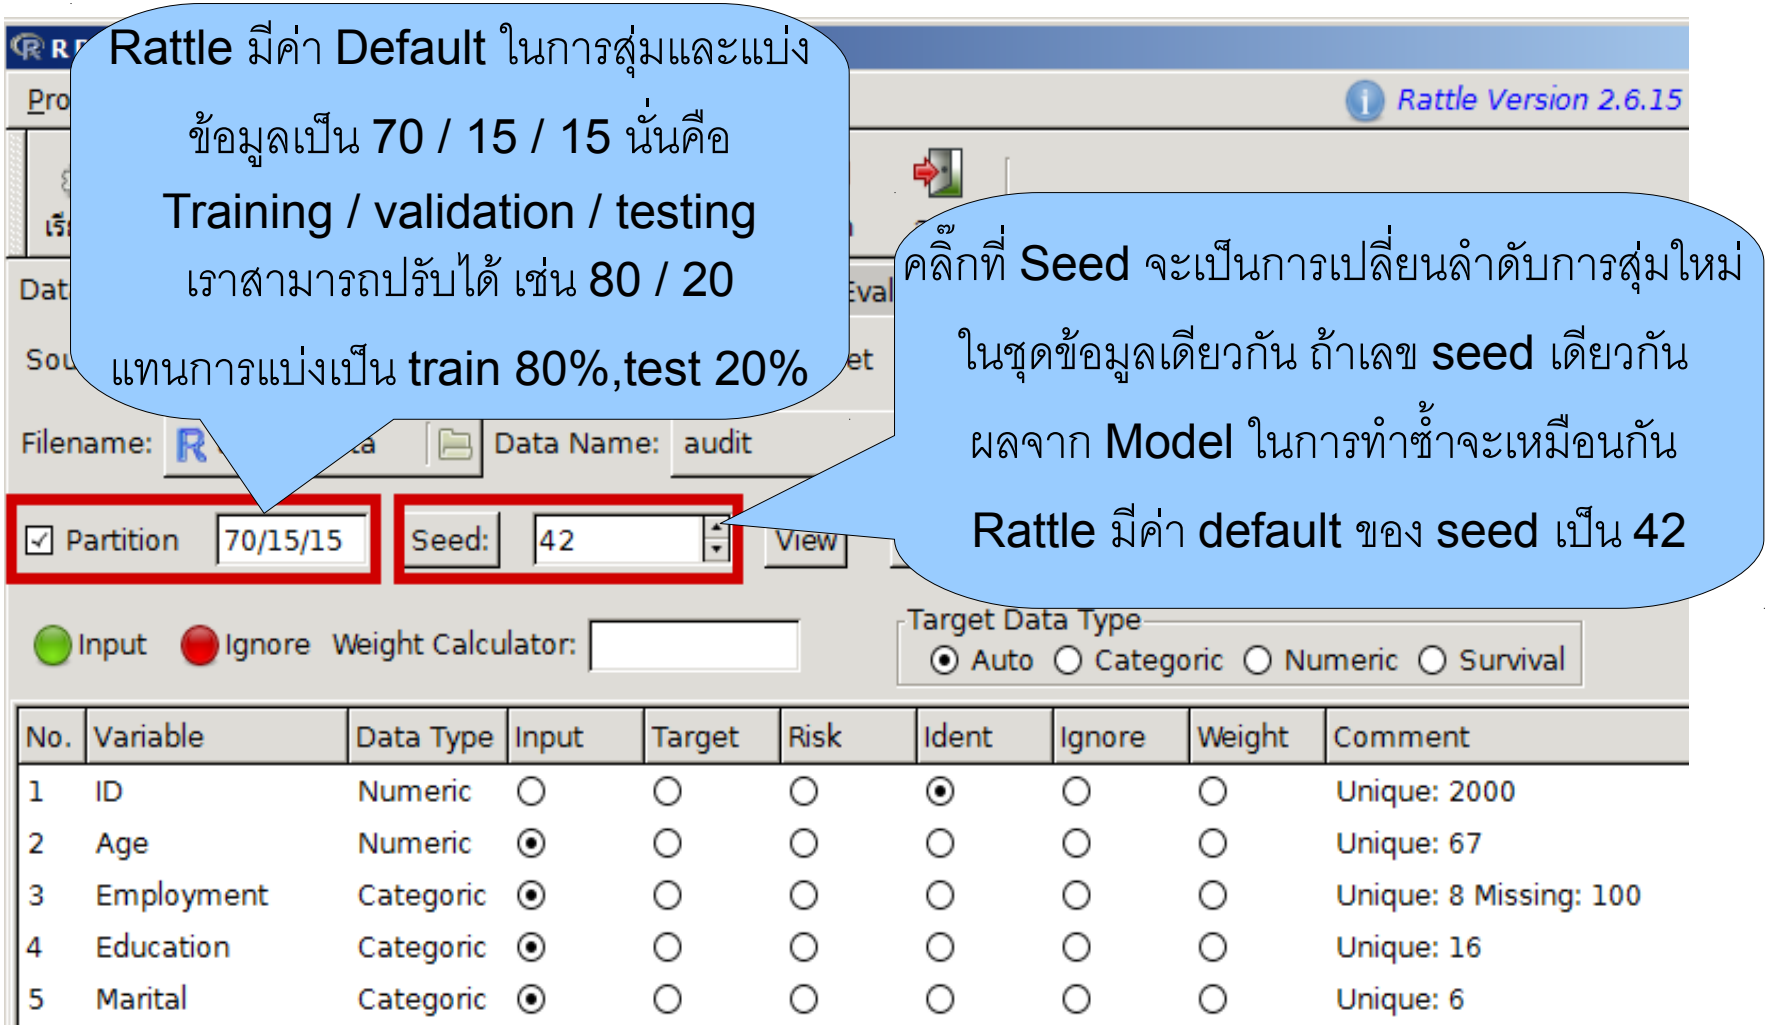

| Rattle Dataset | ID | Age | Employm | Educatio | Marital | Occupati | Income | Gender | Deductio | Hours | IGNORE_ |
|---|---|---|---|---|---|---|---|---|---|---|---|
| 1 | 1004641 | 38 | Private | College | nmarried | Service | 81838 | Female | 0 | 72 | edStates |
| 2 | 1010229 | 35 | Private | Associate | Absent | Transport | 72099 | Male | 0 | 30 | Jamaica |
| 3 | 1024587 | 32 | Private | HSgrad | Divorced | Clerical | 154677 | Male | 0 | 40 | edStates |
| 4 | 1038288 | 45 | Private | Bachelor | Married | Repair | 27743.8 | Male | 0 | 55 | edStates |
| 5 | 1044221 | 60 | Private | College | Married | Executive | 7568.23 | Male | 0 | 40 | edStates |

# Rattle Training 3. Loading Data




| | Note: When fin | Educatio | Marital | Occupati | Income | Gender | Deducti | Hours | IGNORE_ | RISK_Adj | TARGET_ |
|---|---|---|---|---|---|---|---|---|---|---|---|
| 1 | | College | nmarried | Service | 81838 | Female | 0 | 72 | edStates | 0 | 0 |
| 2 | | Associate | Absent | Transport | 72099 | Male | 0 | 30 | Jamaica | 0 | 0 |
| 3 | | HSgrad | Divorced | Clerical | 154677 | Male | 0 | 40 | edStates | 0 | 0 |
| 4 | | Bachelor | Married | Repair | 27743.8 | Male | 0 | 55 | edStates | 7298 | 1 |
| 5 | | College | Married | Executive | 7568.23 | Male | 0 | 40 | edStates | 15024 | 1 |
| 6 | | HSgrad | Married | Service | 33144.4 | Male | 0 | 30 | edStates | 0 | 0 |
| 7 | | Bachelor | Married | Executive | 43391.2 | Male | 0 | 50 | edStates | 22418 | 1 |
| 8 | | Yr12 | Married | Machinist | 59906.7 | Male | 0 | 40 | edStates | 0 | 0 |
| 9 | | Associate | Divorced | Clerical | 126889 | Female | 0 | 40 | edStates | 0 | 0 |
| 10 | | HSgrad | Absent | Sales | 52466.5 | Female | 0 | 37 | edStates | 0 | 0 |
| 11 | | College | Divorced | Service | 291416 | Female | 0 | 35 | edStates | 0 | 0 |
| 12 | | ocational | Widowed | Clerical | 24155.3 | Male | 0 | 40 | edStates | 0 | 0 |
| 13 | | College | Absent | Service | 143255 | Female | 0 | 35 | edStates | 0 | 0 |
| 14 | | College | Absent | Machinist | 120555 | Male | 0 | 40 | edStates | 0 | 0 |
| 15 | | Master | Married | Executive | 34919.2 | Male | 0 | 40 | hilippines | 7298 | 1 |
| 16 | | HSgrad | Divorced | Executive | 67176.8 | Male | 0 | 35 | edStates | 0 | 0 |

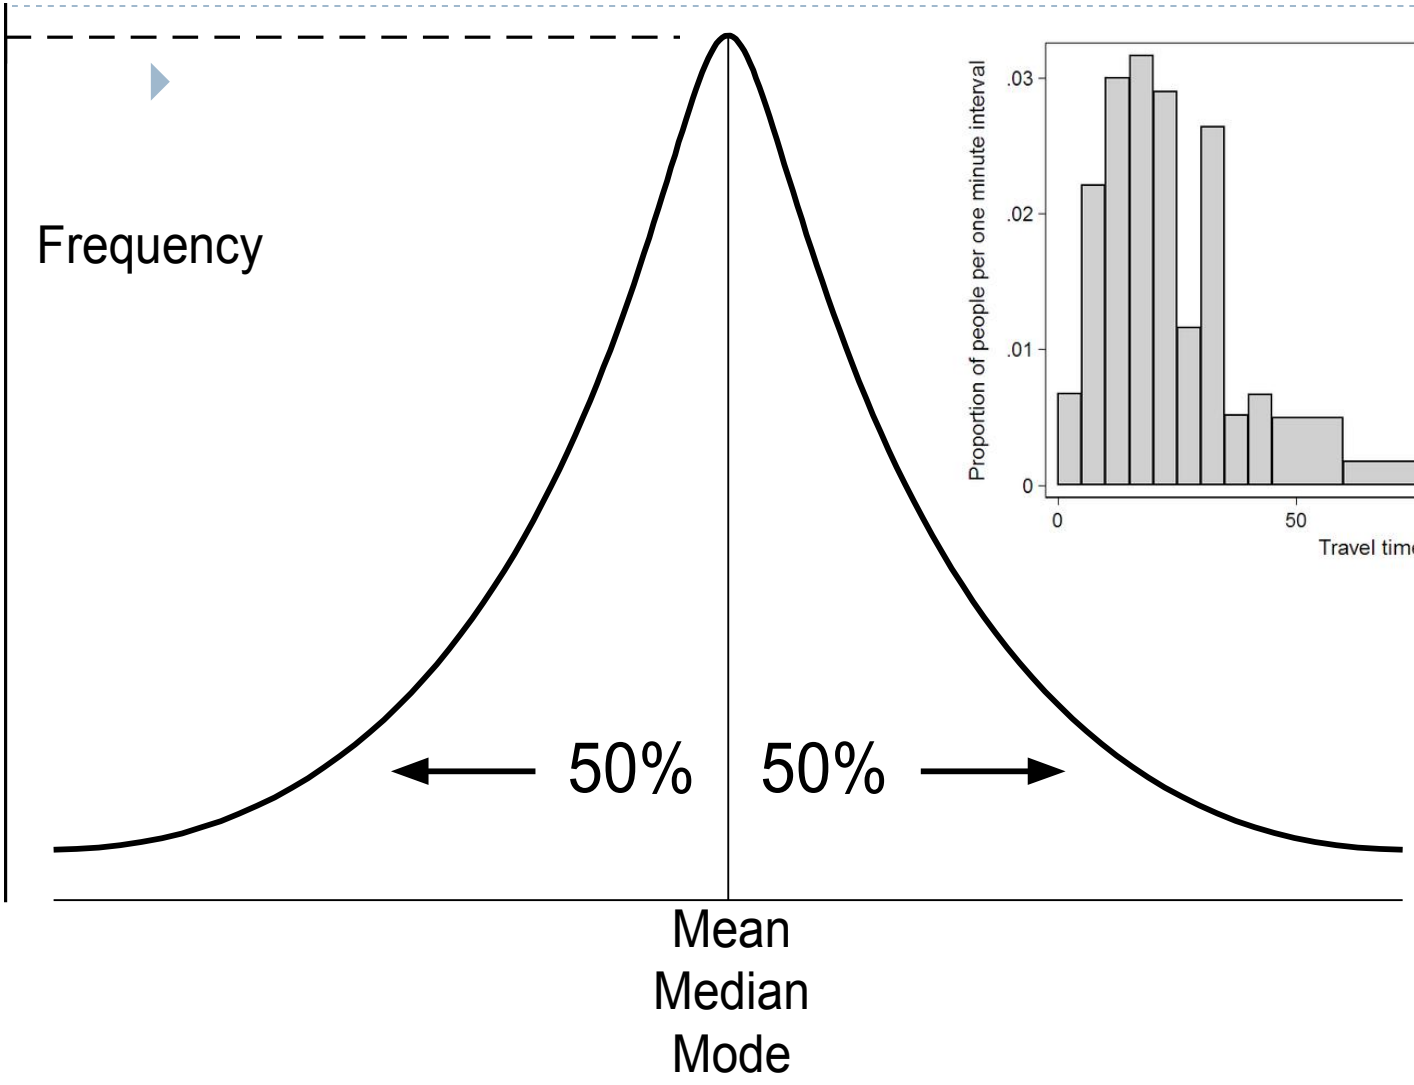
# Rattle Training 3. Loading Data : (Data Option)

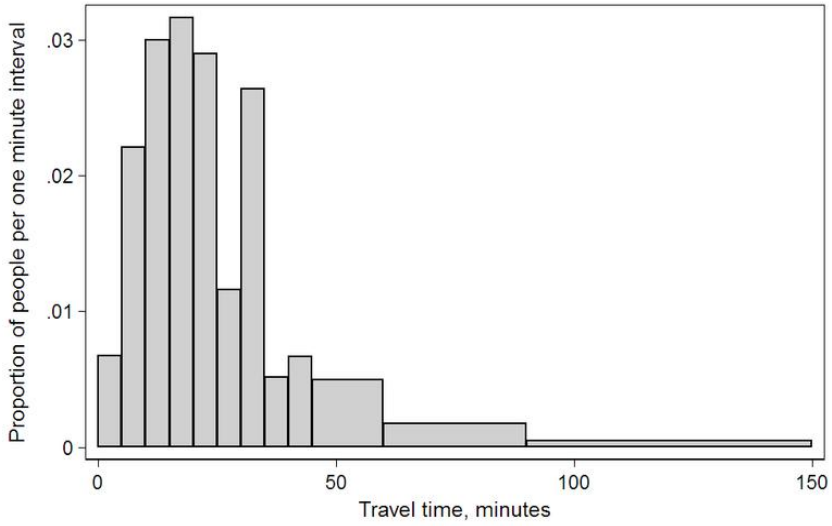


# Rattle Training 3. Loading Data : (Variable Roles)

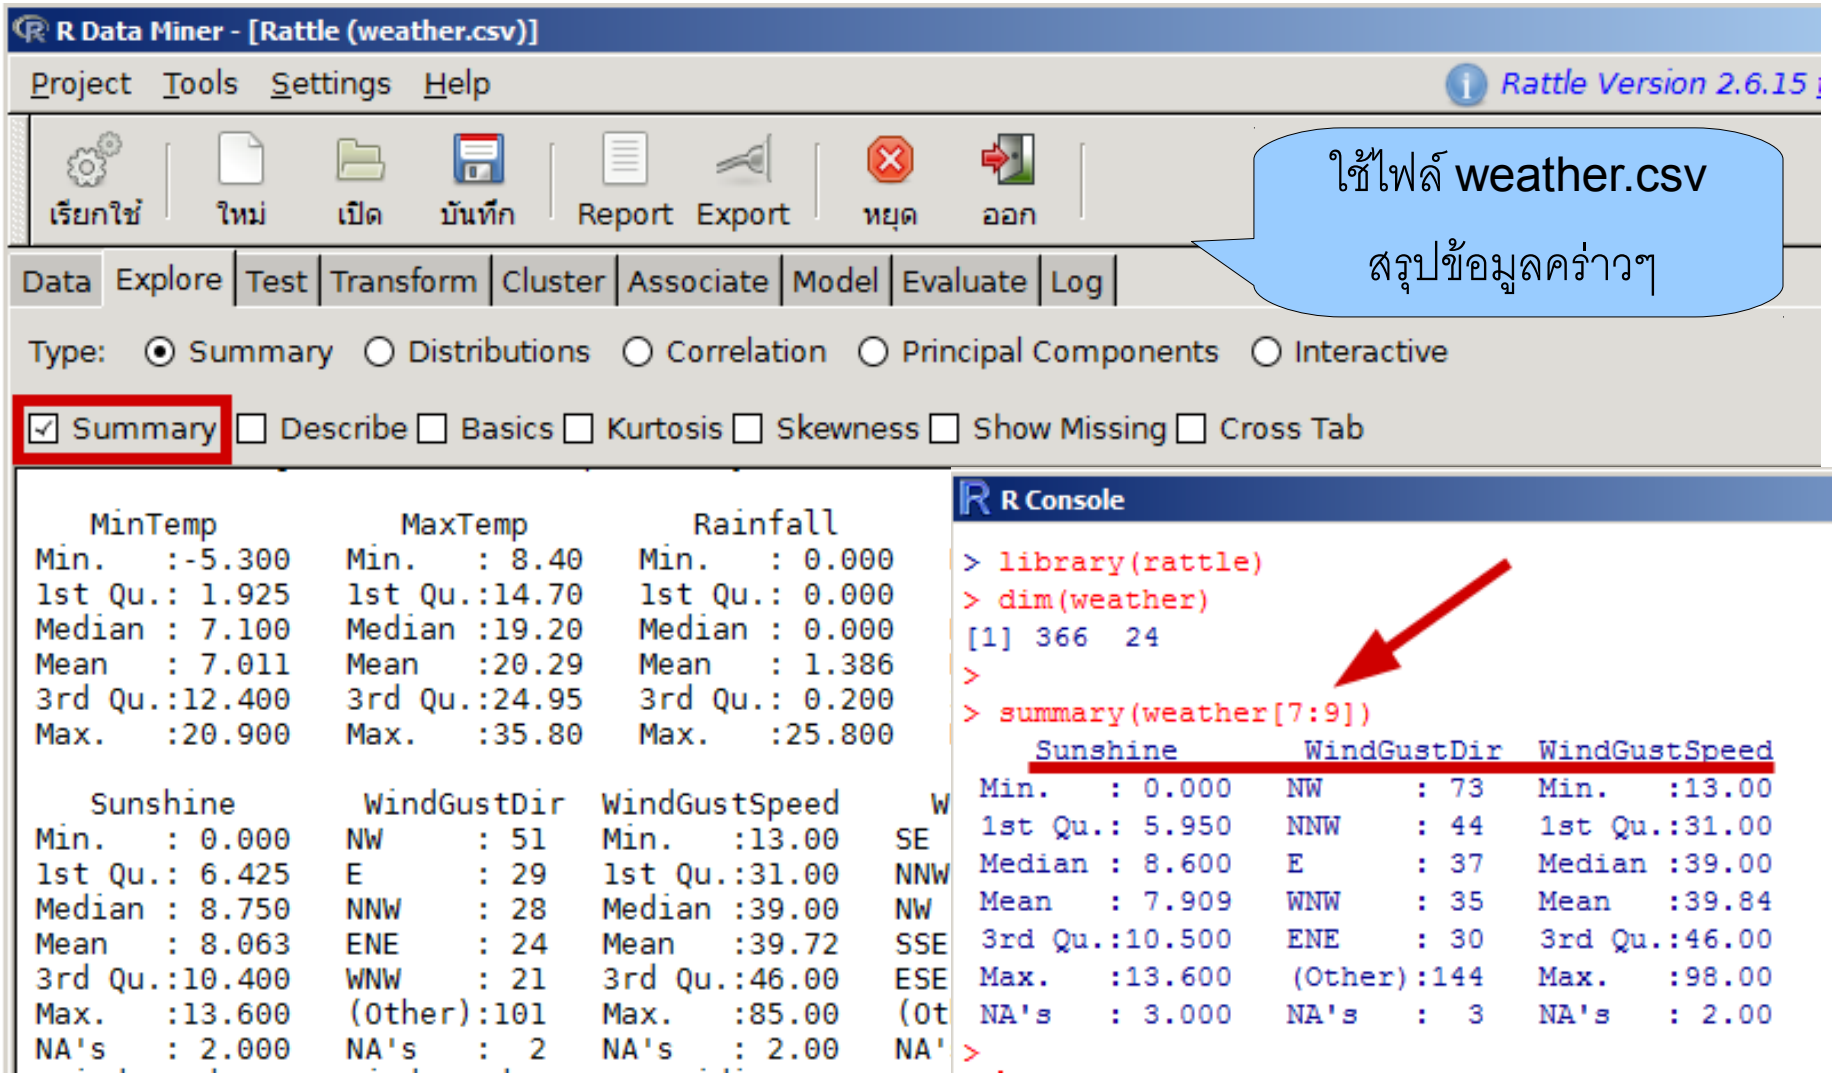
- Data Type (Rattle จะเดาประเภทของข้อมูลที่นำเข้าโดยอัตโนมัติ)
  - Ident : แทนข้อมูลที่เป็น Unique ไม่ซ้ำกันเลยทั้งชุดข้อมูล
  - Constant : แทนข้อมูลที่มี Unique : 1 (และจะเปลงเป็น Ignore โดยอัตโนมัติ)
  - Numeric: แทนข้อมุลเชิงปริมาณ
  - Categoric : แทนข้อมูลเชิงกลุ่ม
- Input :ข้อมูลที่สามารถนำเข้าไปวิเคราะห์ใน rattle ได้
- Target : ข้อมูลที่เป็น Class
- Risk : ข้อมูลที่บันทึกขนาดความเสี่ยงของแต่ละ case ไว้ (แปรตาม class)
- Ident : ระบุประเภทข้อมูลที่ไม่ซ้ำกันเลย
- Ignore : ใช้ระบุเมื่อไม่ต้องการนำตัวแปรนั้นๆ มาวิเคราะห์
- Weight : ใช้ถ่วงน้ำหนักกรณีที่แต่ละ case สำคัญไม่เท่ากัน
- Comment : เป็นข้อสรุปข้อมูลเบื้องต้น เช่น Unique & Missing

# Rattle Training 4. Exploring Data 4.1 Summarizing Data

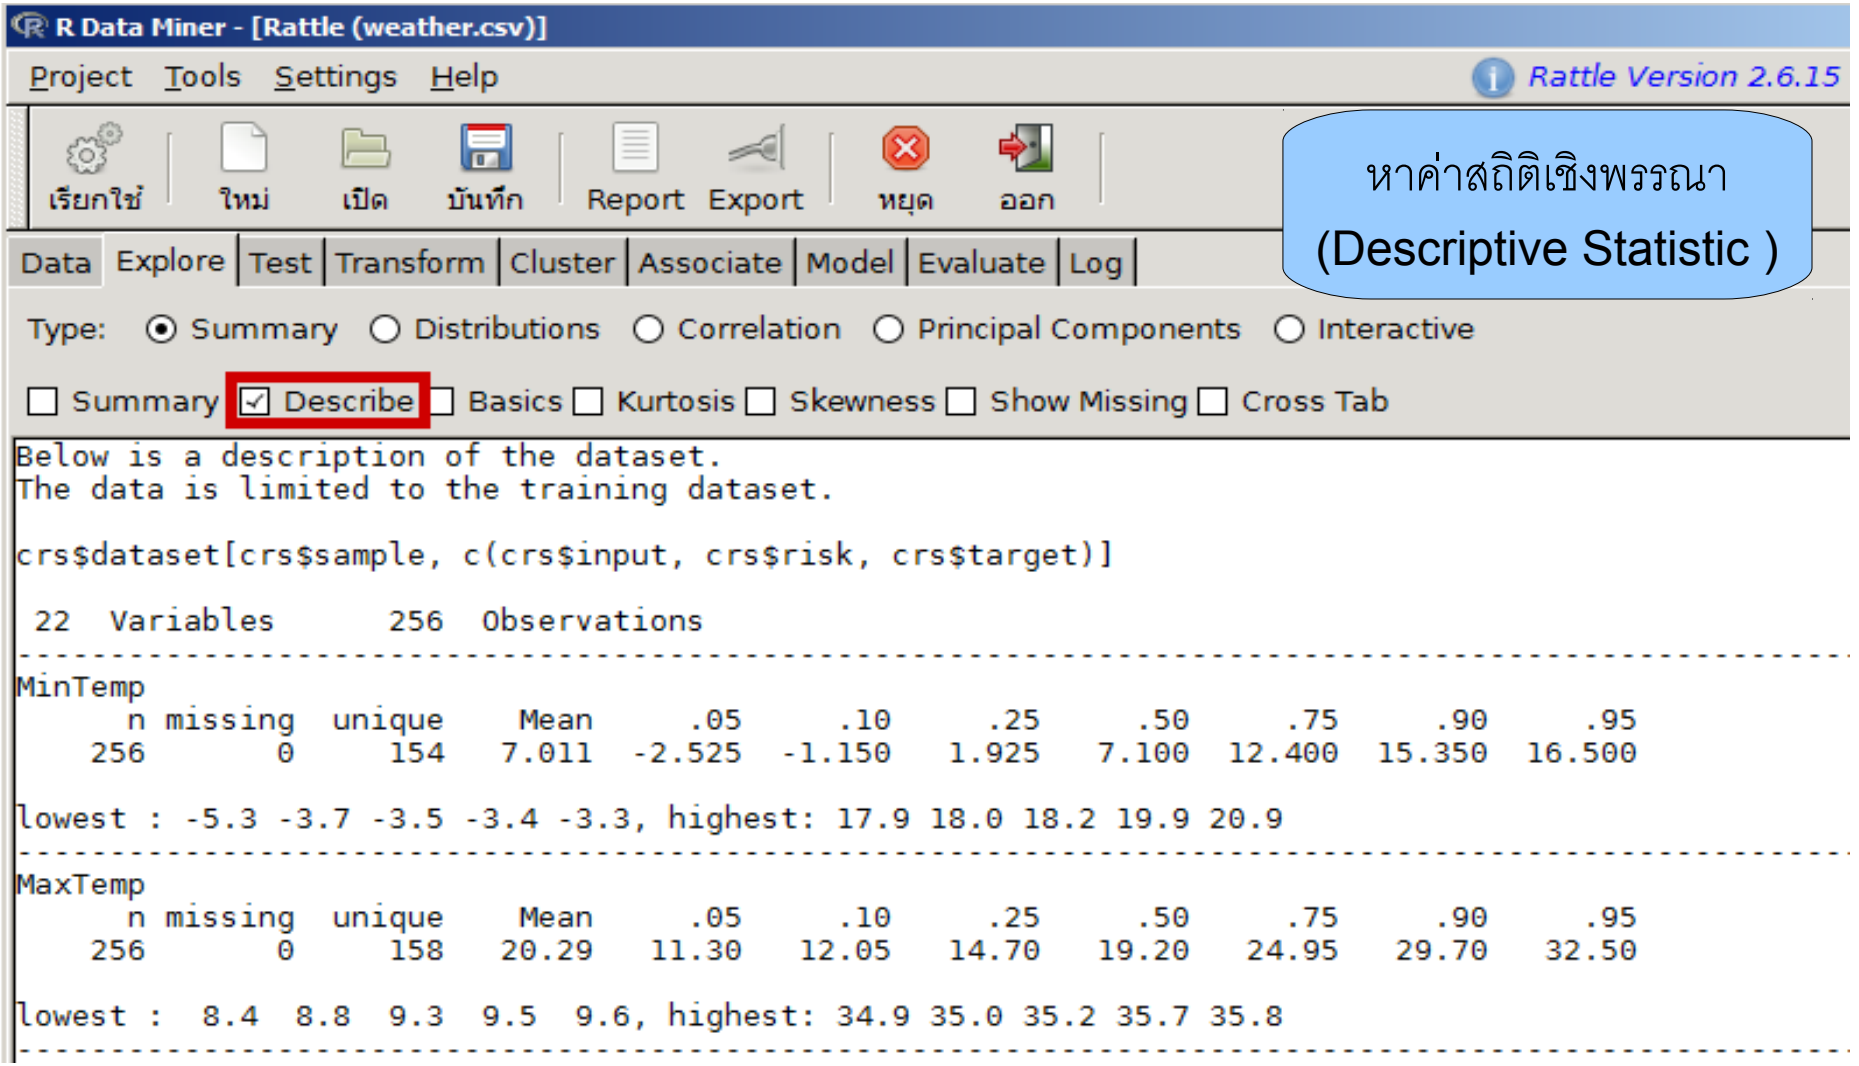


# Rattle Training 4. Exploring Data 4.1 Summarizing Data



# Rattle Training 4. Exploring Data 4.1 Summarizing Data



# Rattle Training 4. Exploring Data 4.1 Summarizing Data

R Console

```
> library(Hmisc)
Loading required package: survival
Loading required package: splines

Attaching package: 'Hmisc'

The following object(s) are masked from 'package:survival':

    untangle.specials

The following object(s) are masked from 'package:base':

    format.pval, round.POSIXt, trunc.POSIXt, units

> describe(weather[7])
weather[7]

 1  Variables      366  Observations
--------------------------------------------------------------------------------
Sunshine
      n missing  unique    Mean     .05     .10     .25     .50     .75     .90
    363       3     114   7.909    0.60    2.04    5.95    8.60   10.50   11.80
    .95
  12.60

lowest :  0.0  0.1  0.2  0.3  0.4, highest: 13.1 13.2 13.3 13.5 13.6
--------------------------------------------------------------------------------
```

**For numeric variables.**

ตัวอย่างการวิเคราะห์ข้อมูลที่เป็นตัวเลขเชิงปริมาณใน R

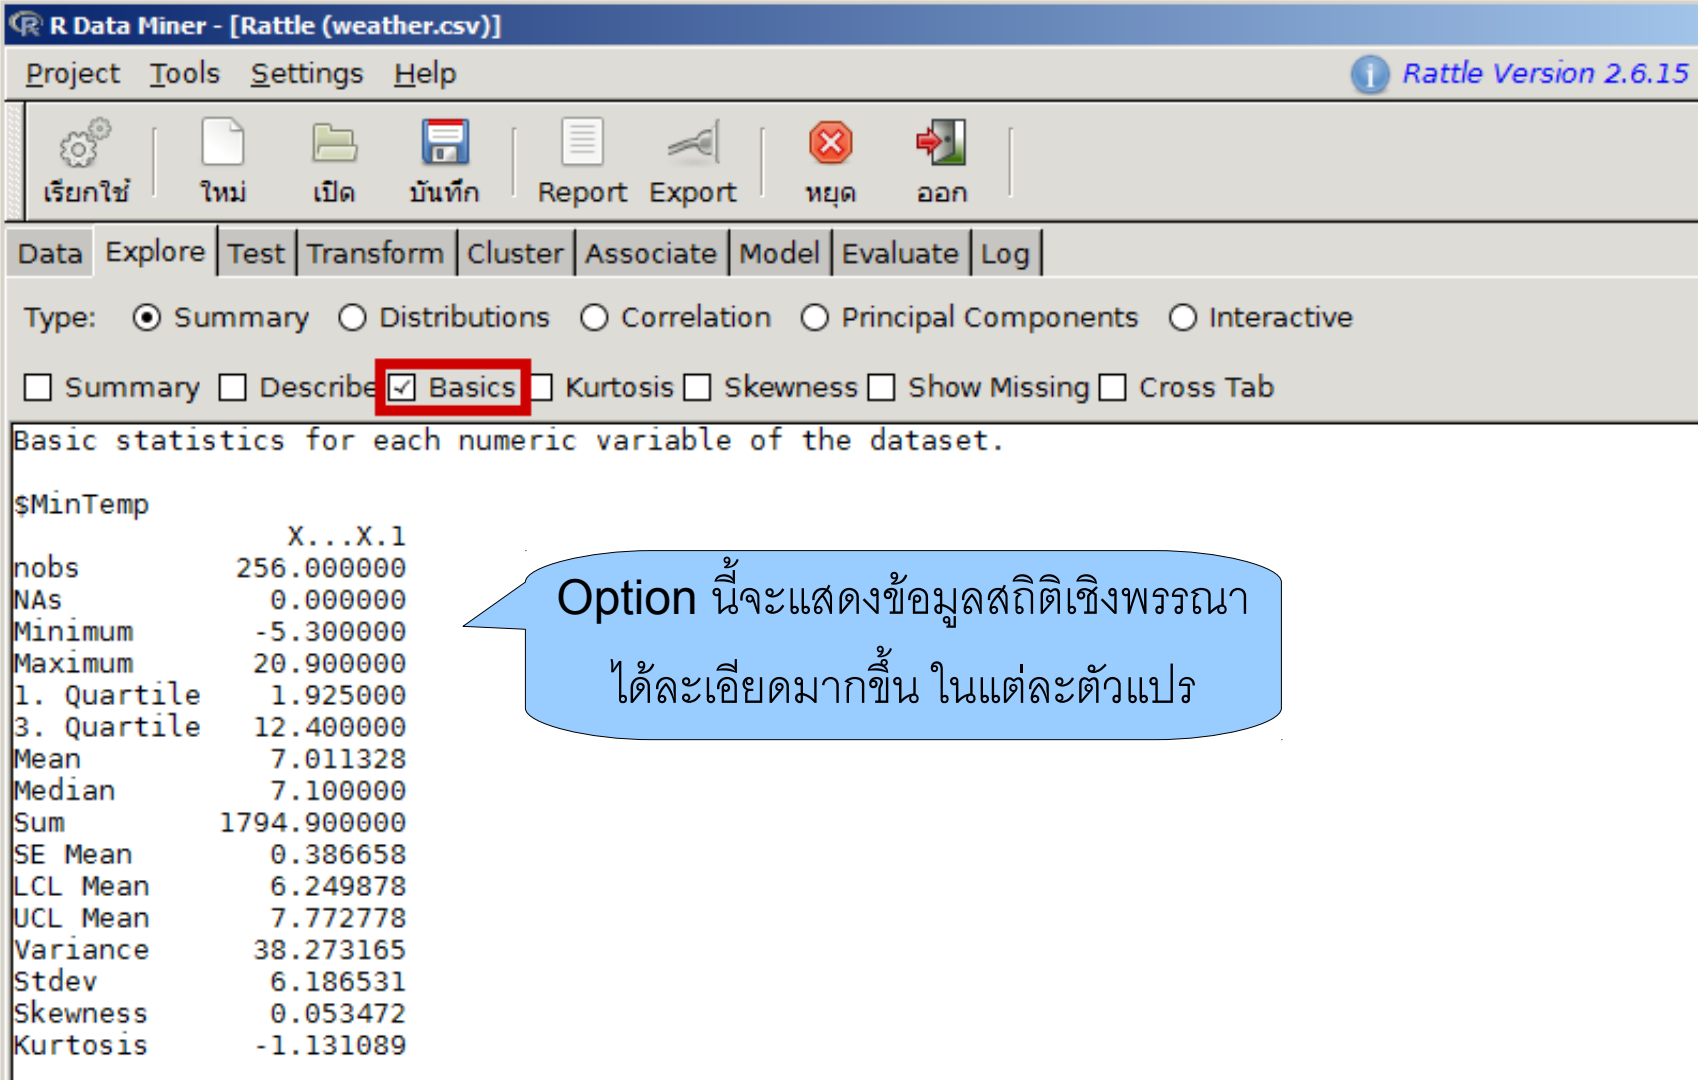
# Rattle Training 4. Exploring Data 4.1 Summarizing Data

R Console

```
> library(fBasics)
> basicStats(weather$Sunshine)
             X..weather.Sunshine
nobs                  366.000000
NAs                     3.000000
Minimum                 0.000000
Maximum                13.600000
1. Quartile             5.950000
3. Quartile            10.500000
Mean                    7.909366
Median                  8.600000
Sum                  2871.100000
SE Mean                 0.182732
LCL Mean                7.550016
UCL Mean                8.268716
Variance               12.120962
Stdev                   3.481517
Skewness               -0.723454
Kurtosis               -0.270625
```

library (fBasics) ใน R

# Rattle Training 4. Exploring Data 4.1 Summarizing Data




Option นี้จะแสดงข้อมูลสถิติเชิงพรรณา ได้ละเอียดมากขึ้น ในแต่ละตัวแปร

# Rattle Training 4. Exploring Data 4.1 Summarizing Data

R Console

```
> describe(weather[8])
weather[8]

 1  Variables      366  Observations
--------------------------------------------------------------------------------
WindGustDir
       n missing  unique
     363       3      16

            N NNE NE ENE  E ESE SE SSE  S SSW SW WSW  W WNW NW NNW
Frequency 21   8 16  30 37  23 12  12 22   5  3   2 20  35 73  44
%          6   2  4   8 10   6  3   3  6   1  1   1  6  10 20  12
--------------------------------------------------------------------------------
> fix(weather)
```

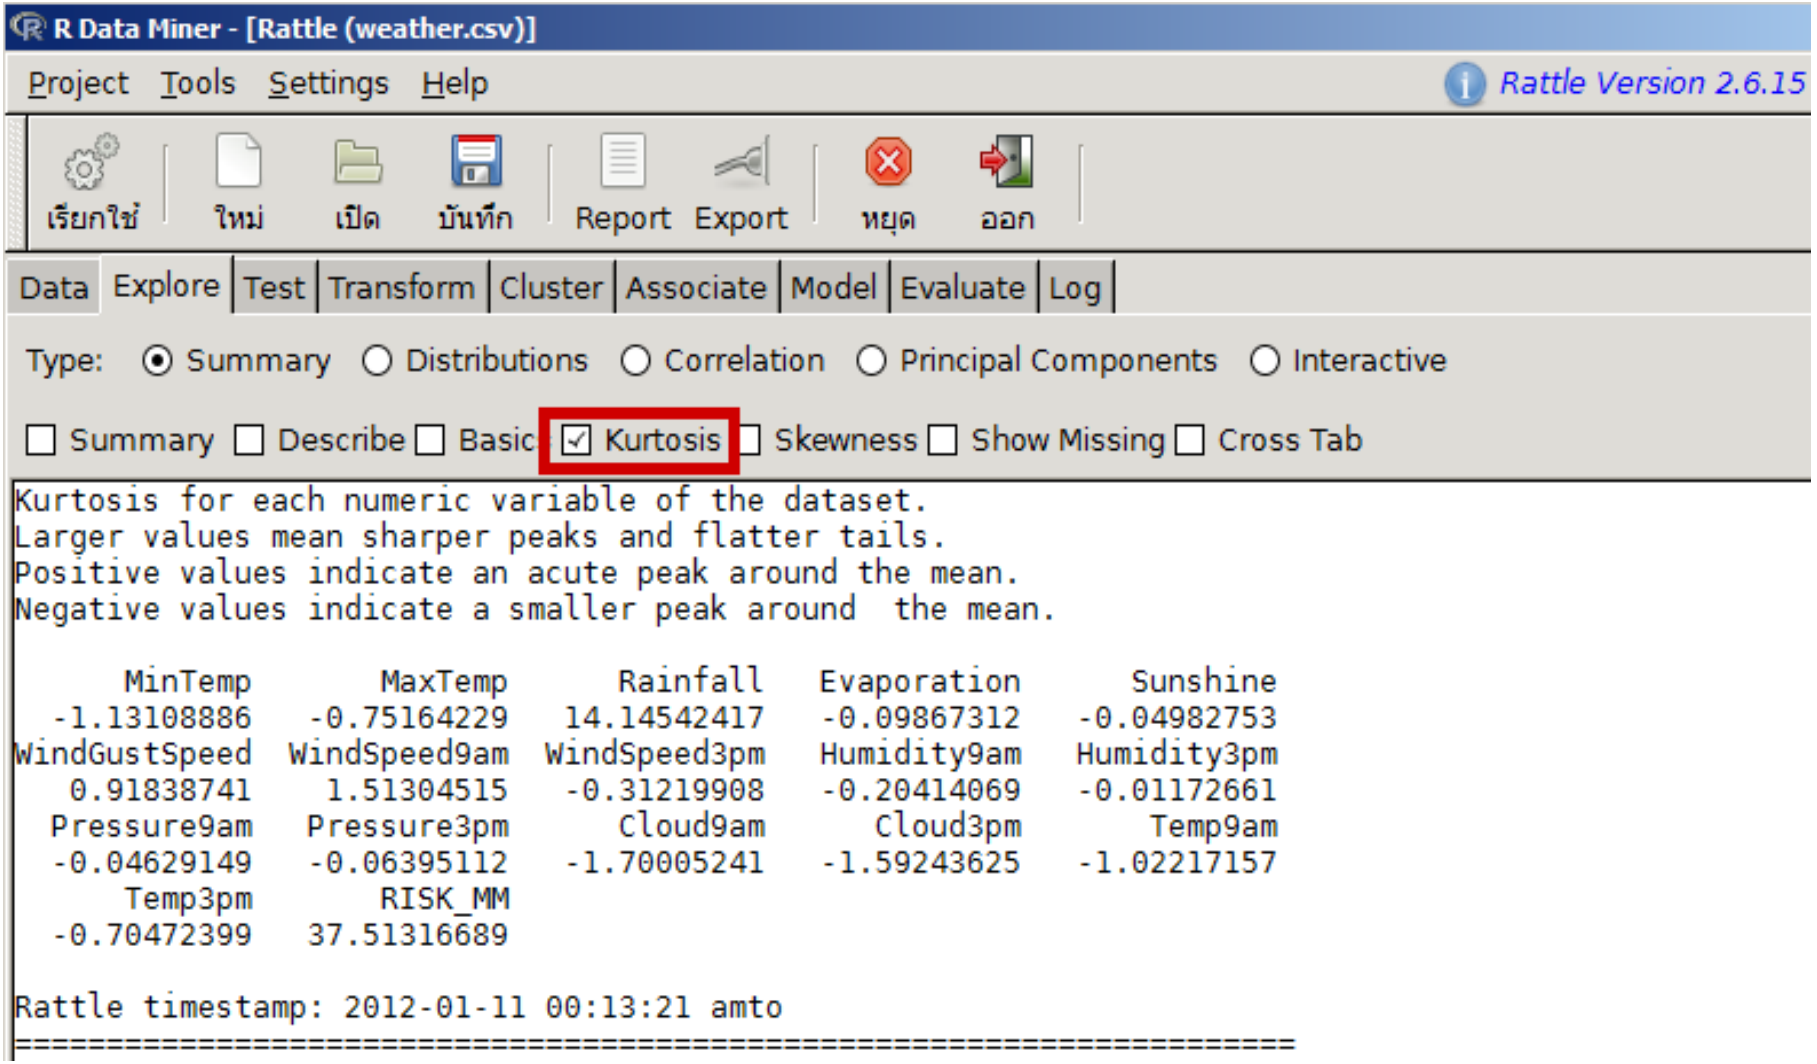
**For categoric variables**

ตัวอย่างการวิเคราะห์เชิงกลุ่มใน R

Data Editor

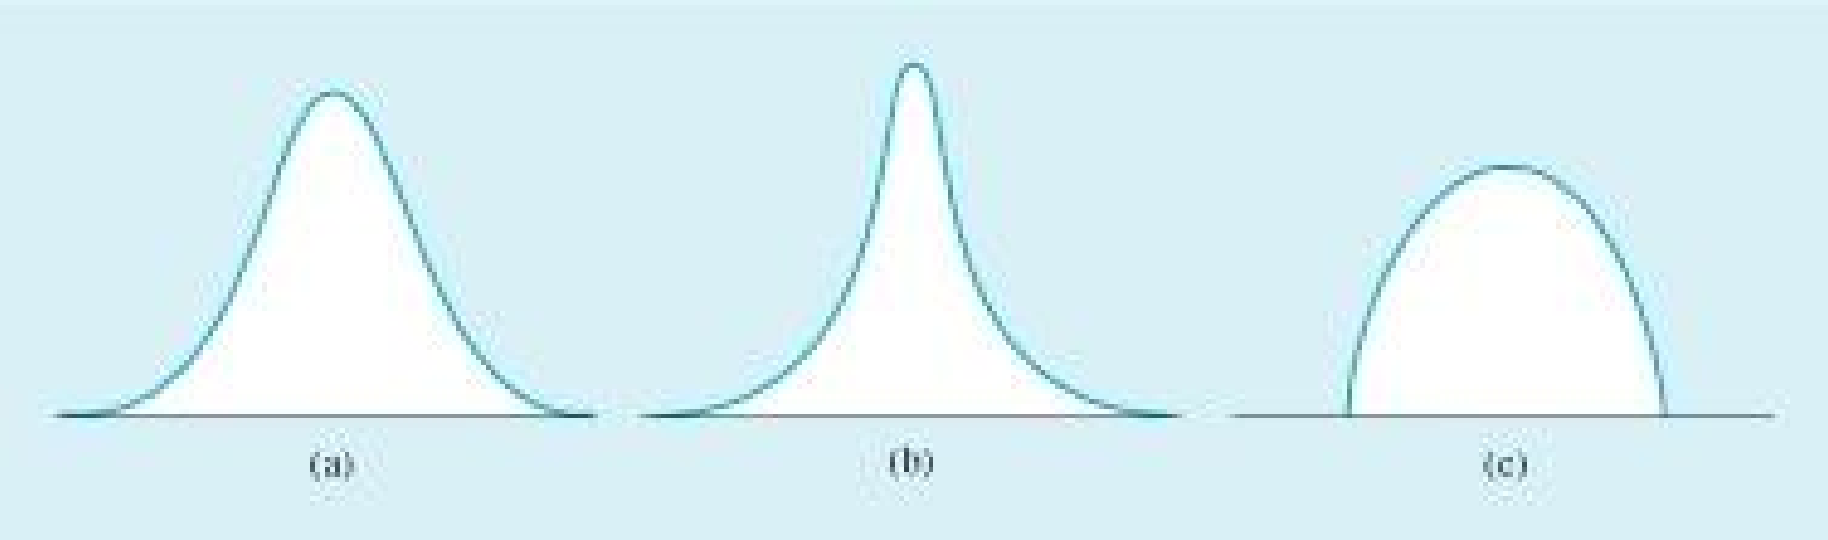
| | Date | Location | MinTemp | MaxTemp | Rainfall | Evaporation | Sunshine (7) | WindGustDir (8) |
|---|---|---|---|---|---|---|---|---|
| 1 | 2007-11-01 | Canberra | 8 | 24.3 | 0 | 3.4 | 6.3 | NW |
| 2 | 2007-11-02 | Canberra | 14 | 26.9 | 3.6 | 4.4 | 9.7 | ENE |
| 3 | 2007-11-03 | Canberra | 13.7 | 23.4 | 3.6 | 5.8 | 3.3 | NW |
| 4 | 2007-11-04 | Canberra | 13.3 | 15.5 | 39.8 | 7.2 | 9.1 | NW |

# Rattle Training 4. Exploring Data 4.1 Summarizing Data

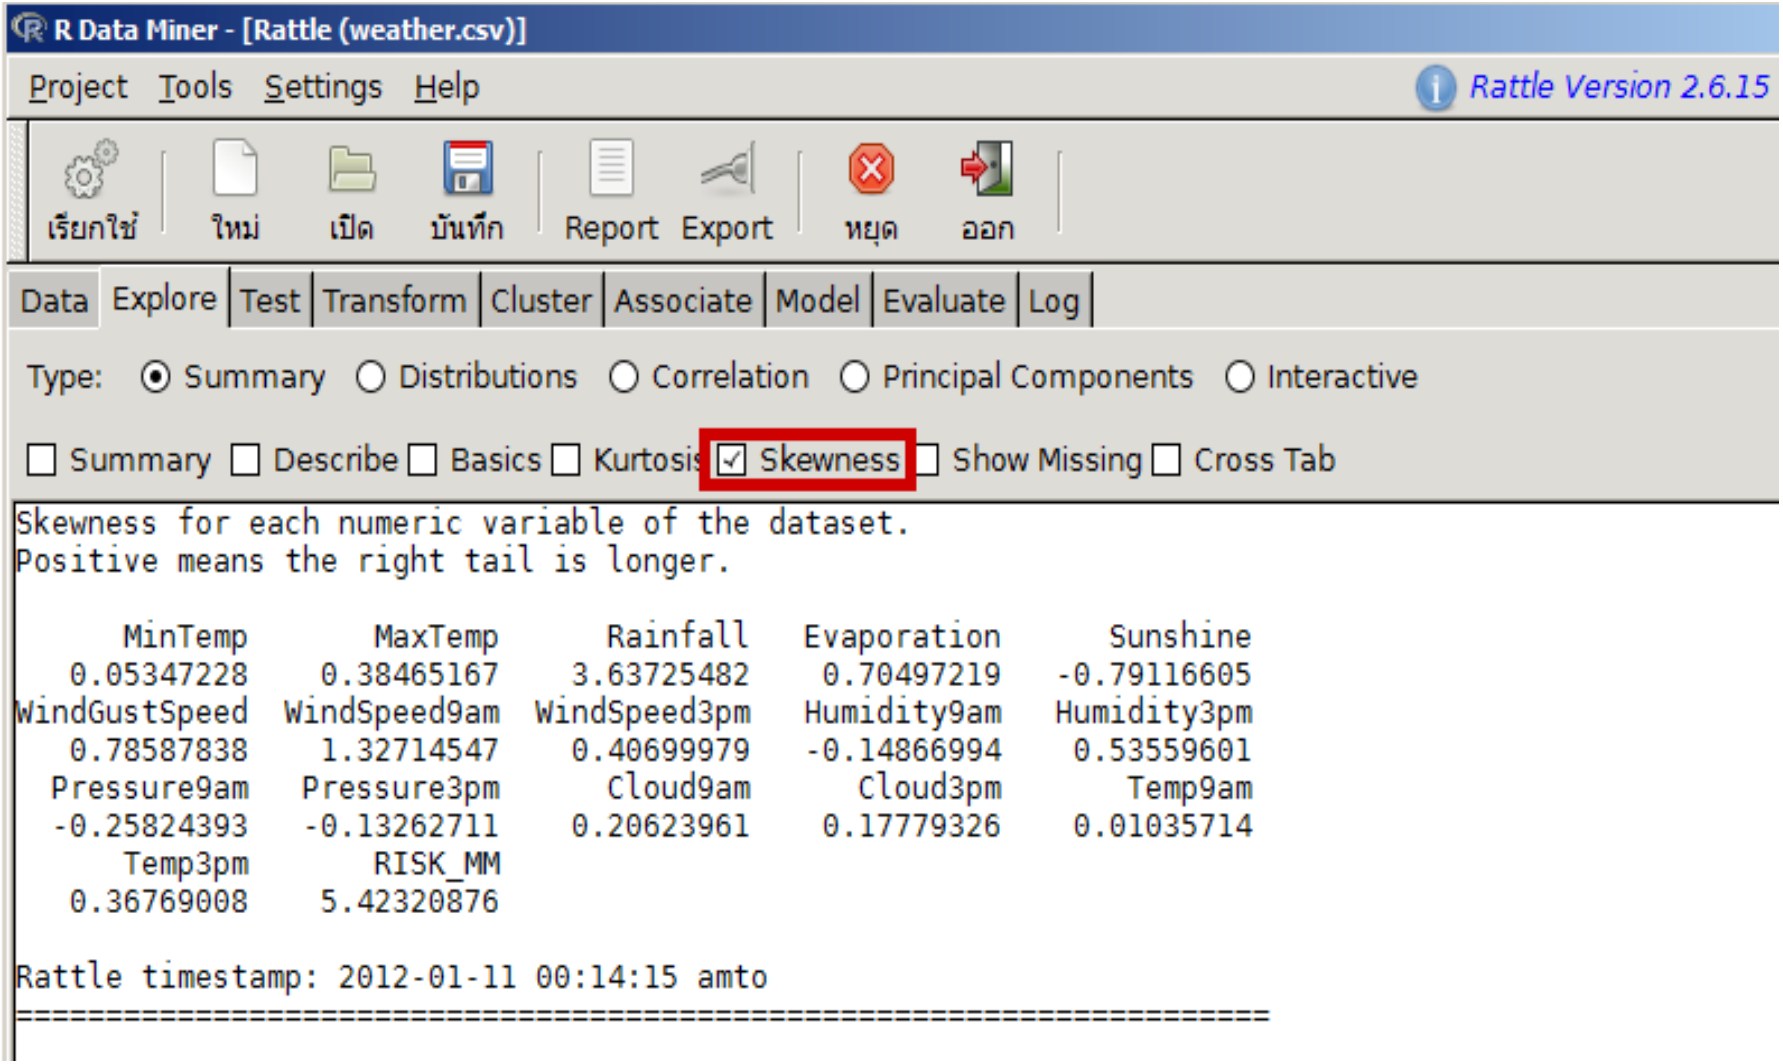


# Rattle Training 4. Exploring Data 4.1 Summarizing Data

- Degree to which tails of the distribution are "heavy" or "light"
  - heavy tails = higher Kurtosis(b)
  - Light tails = lower Kurtosis(c)
  - Normal distribution= Zero Kurtosis (a)

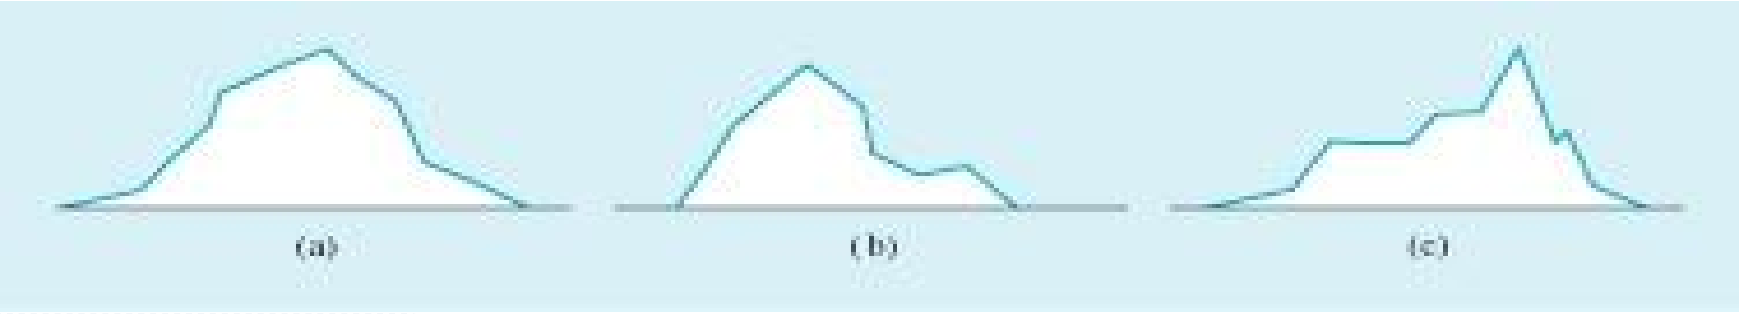


# Rattle Training 4. Exploring Data 4.1 Summarizing Data

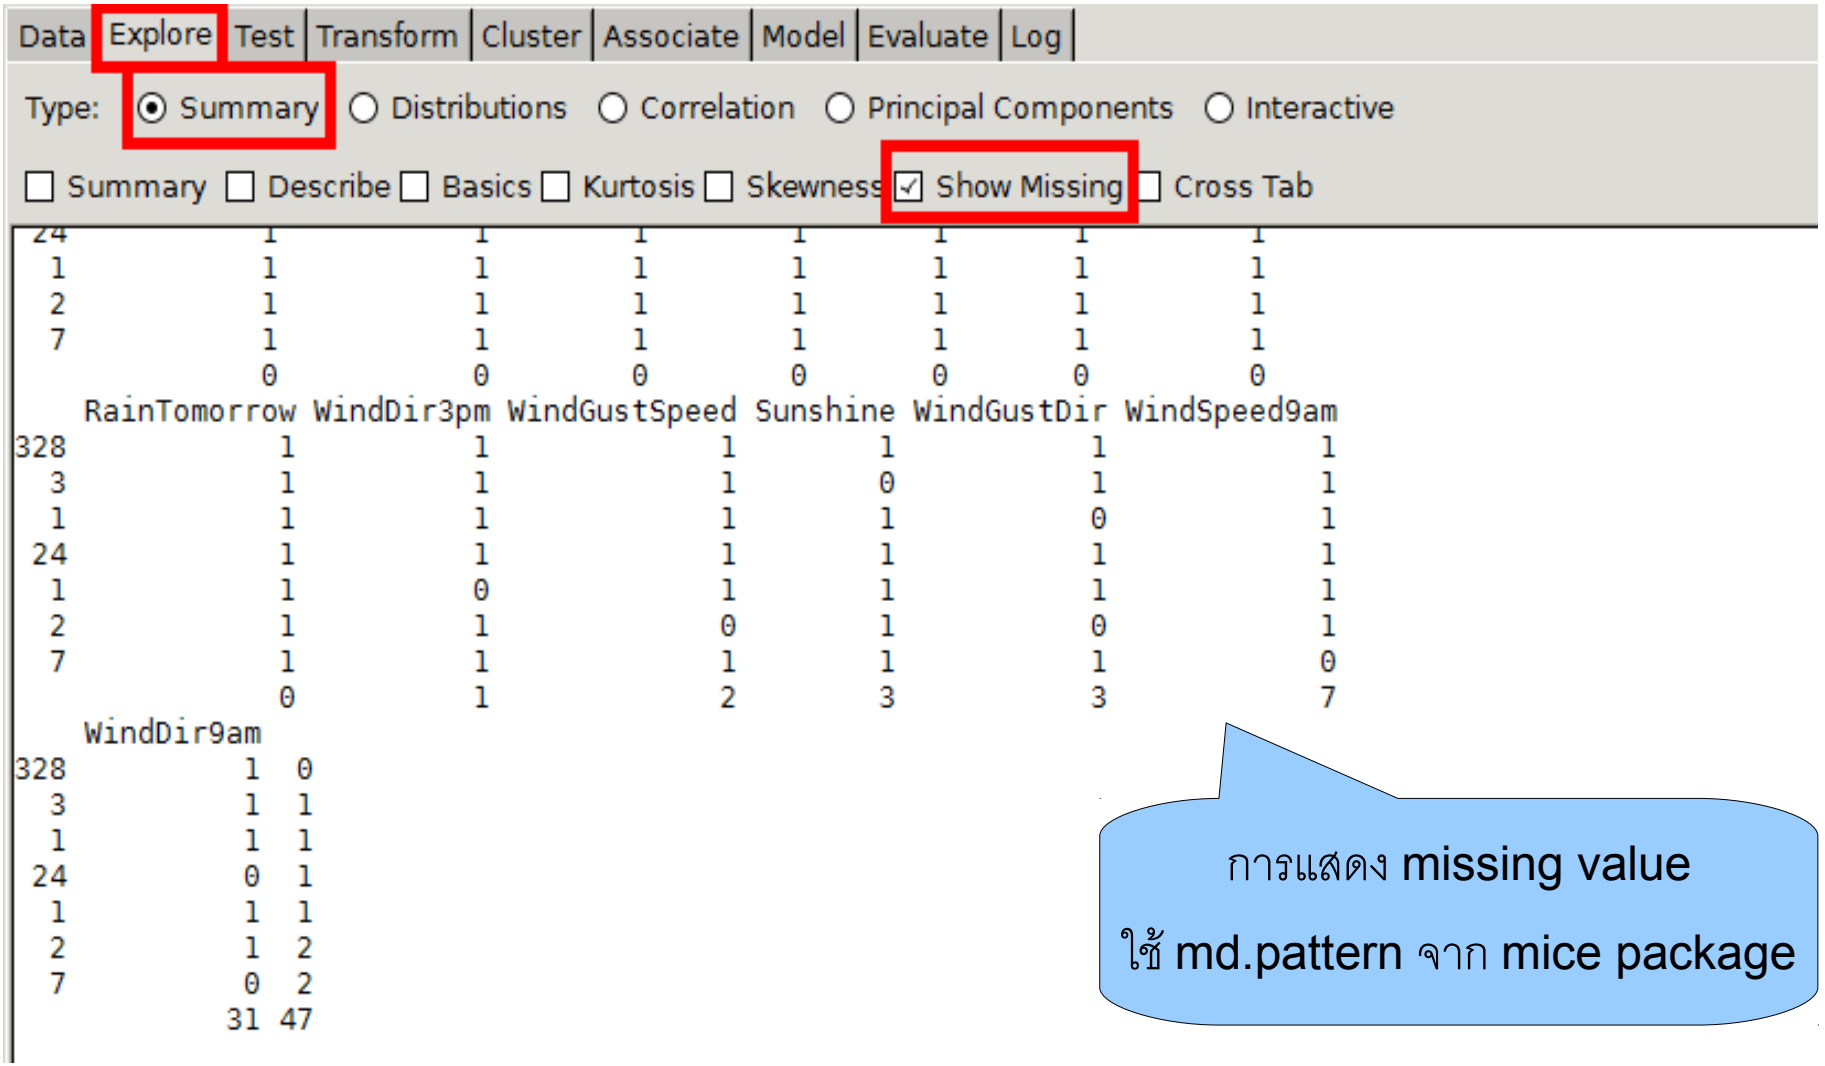


# Rattle Training 4. Exploring Data 4.1 Summarizing Data

- Skewed right (b)
  - Fewer scores right of the peak
  - Positively skewed
  - Can be caused by a floor effect
- Skewed left (c)
  - Fewer scores left of the peak
  - Negatively skewed
  - Can be caused by a ceiling effect



# Rattle Training 4. Exploring Data 4.1 Summarizing Data




การแสดง missing value

ใช้ md.pattern จาก mice package

# Rattle Training 4. Exploring Data 4.1 Summarizing Data

```
>
> library(mice)
Loading required package: nnet
Loading required package: lattice
mice 2.11 2011-11-21
> md.pattern(weather[,7:10])
     WindGustSpeed Sunshine WindGustDir WindDir9am
329              1        1           1          1  0
  3              1        0           1          1  1
  1              1        1           0          1  1
 31              1        1           1          0  1
  2              0        1           0          1  2
                 2        3           3         31 39
>
>
>
> |
```

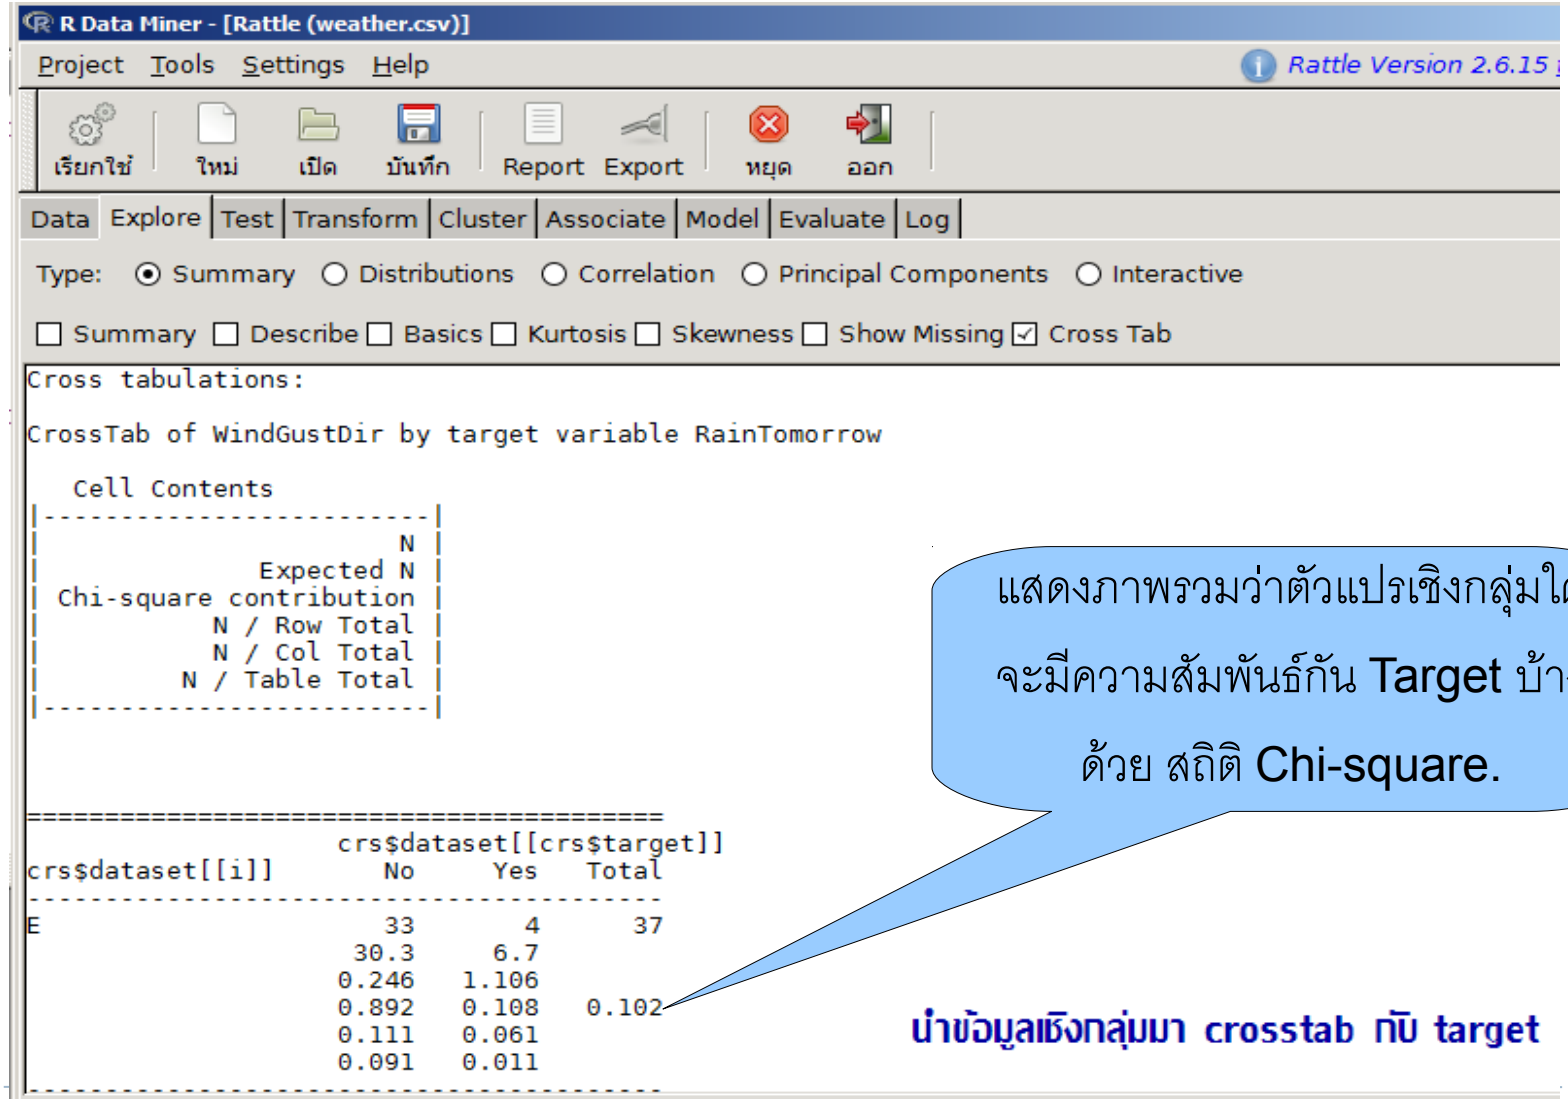
1 indicates a value is present.

0 indicates a value is missing.

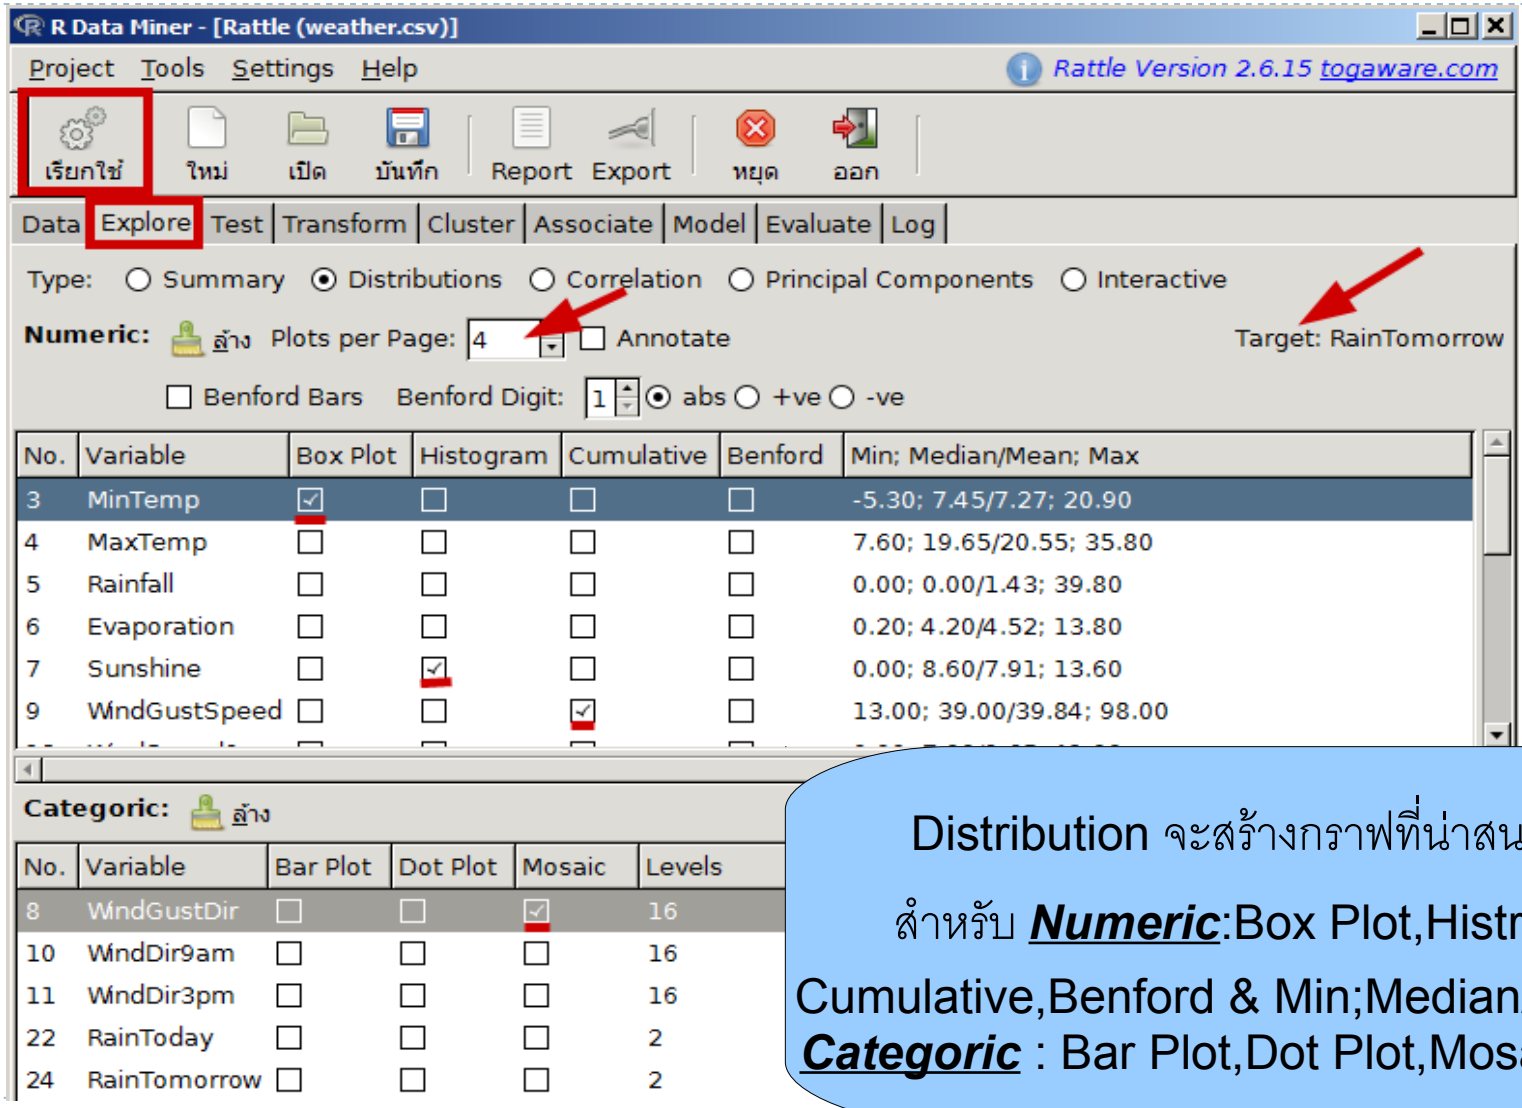
observations with no missing.

The number of missing values over all observations.

# Rattle Training 4. Exploring Data 4.1 Summarizing Data



# Rattle Training 4. Exploring Data 4.2 Visualizing Distributions

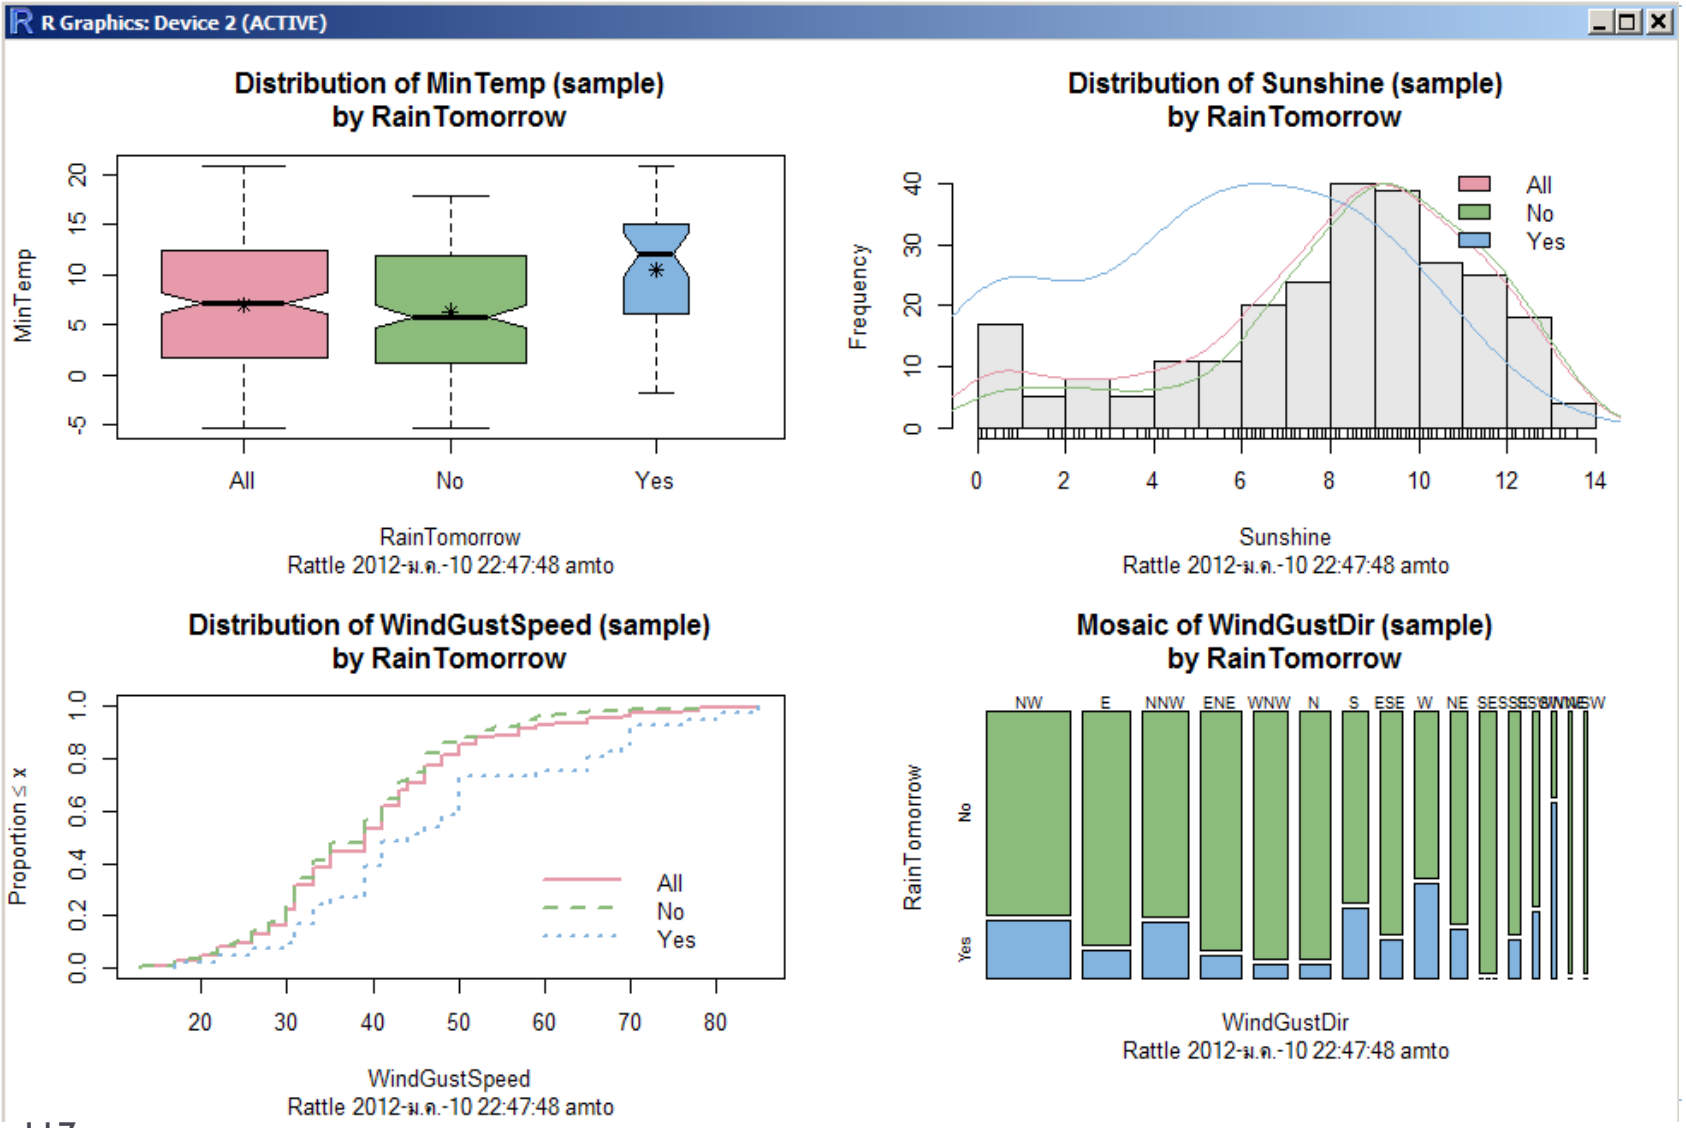



Distribution จะสร้างกราฟที่น่าสนใจดังนี้

สำหรับ ***Numeric***:Box Plot,Histrogram Cumulative,Benford & Min;Median/Mean;Max

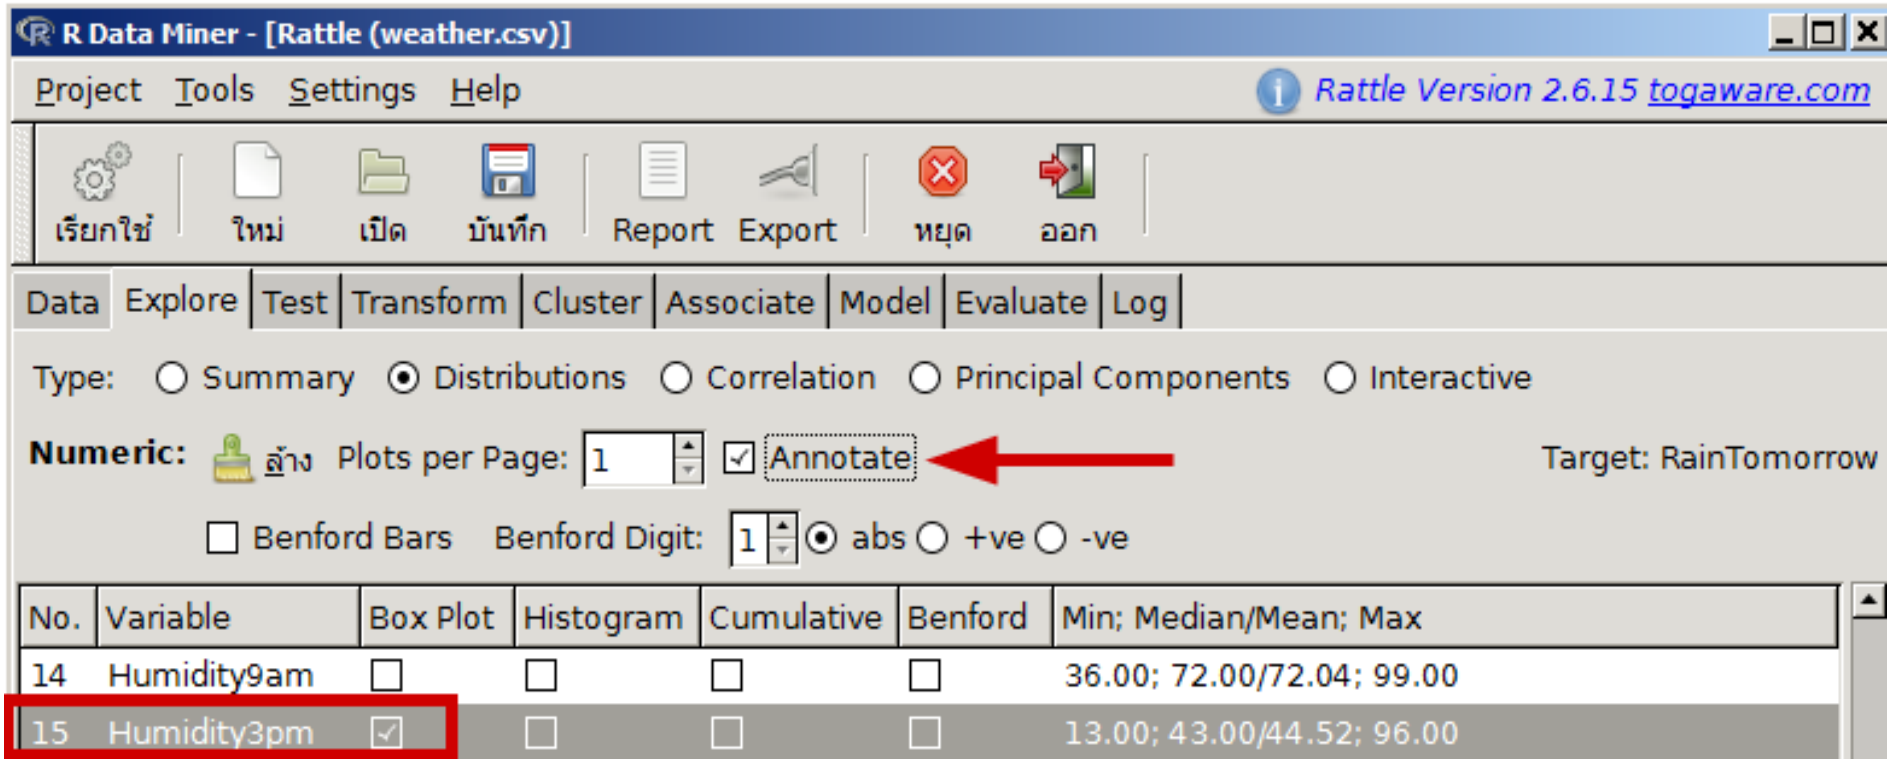
***Categoric*** : Bar Plot,Dot Plot,Mosaic & Level

# Rattle Training 4. Exploring Data 4.2 Visualizing Distributions



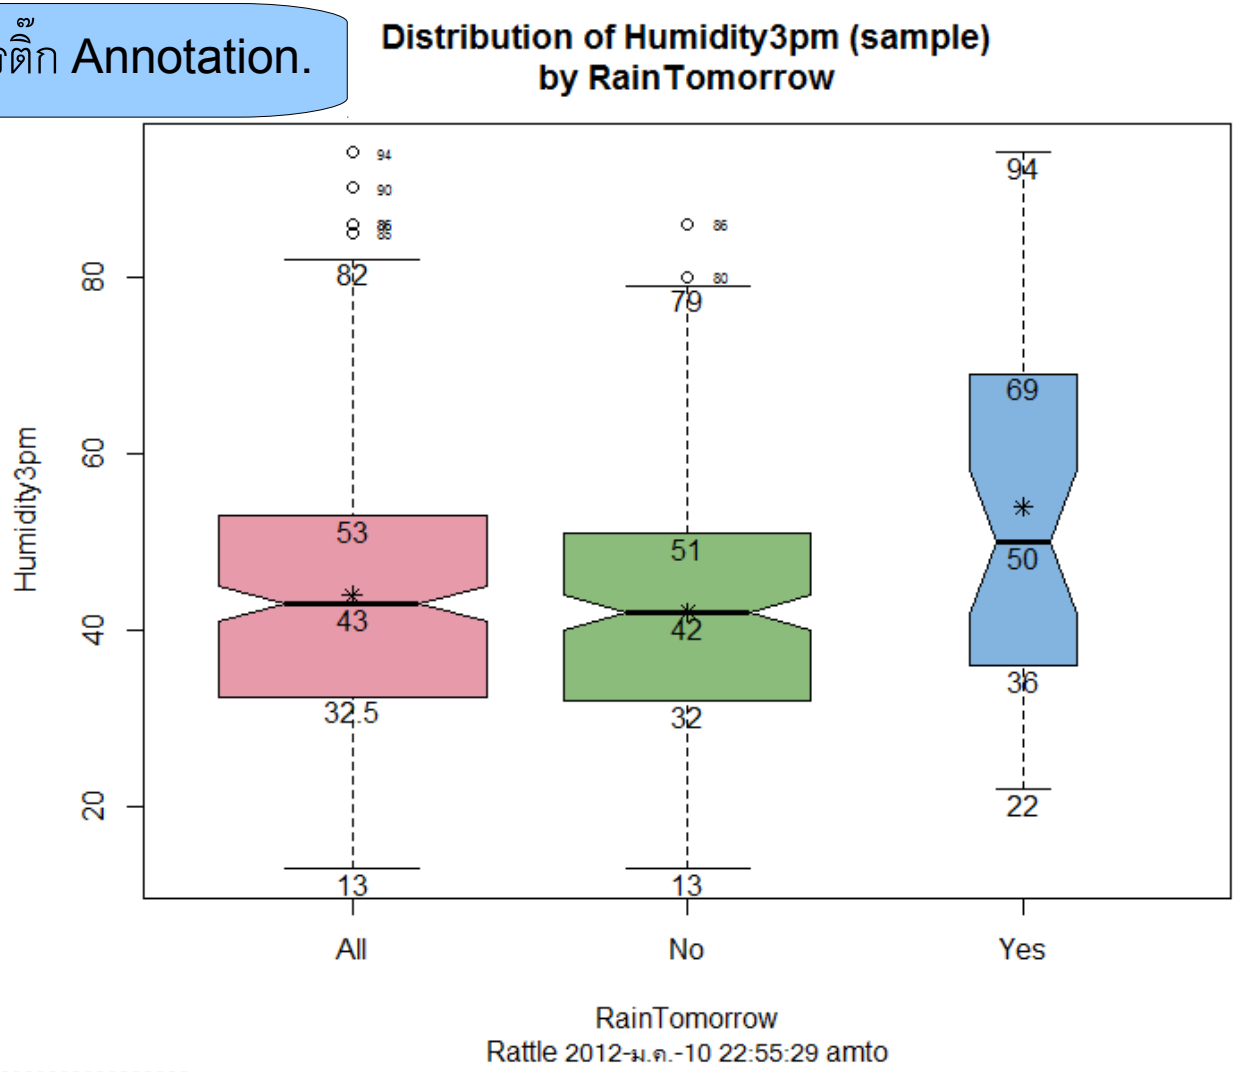
# Rattle Training 4. Exploring Data 4.2 Visualizing Distributions

- เราสามารถเลือกได้ว่าจะ **Plot** กี่รูปต่อ **Page** ที่ **Plots per Page**
- ถ้าต้องการให้แสดงค่าบนกราฟ ให้ติ๊ก **Annotate.**



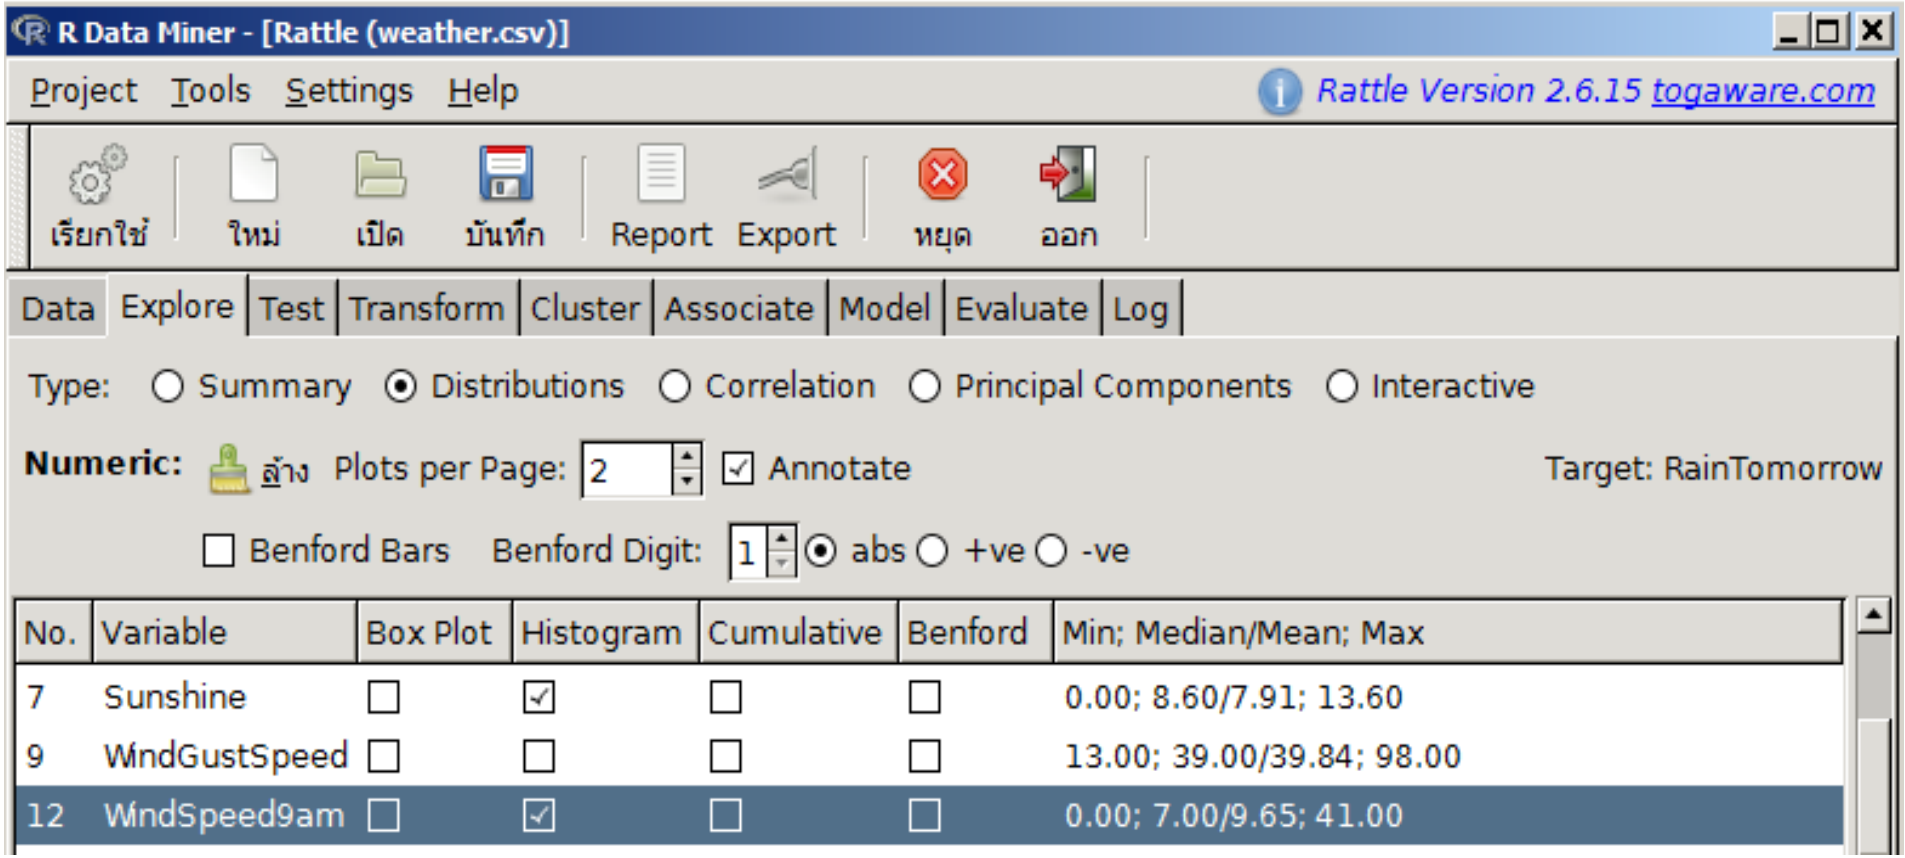
# Rattle Training 4. Exploring Data 4.2 Visualizing Distributions

ผลลัพธ์จากการติ๊ก Annotation.

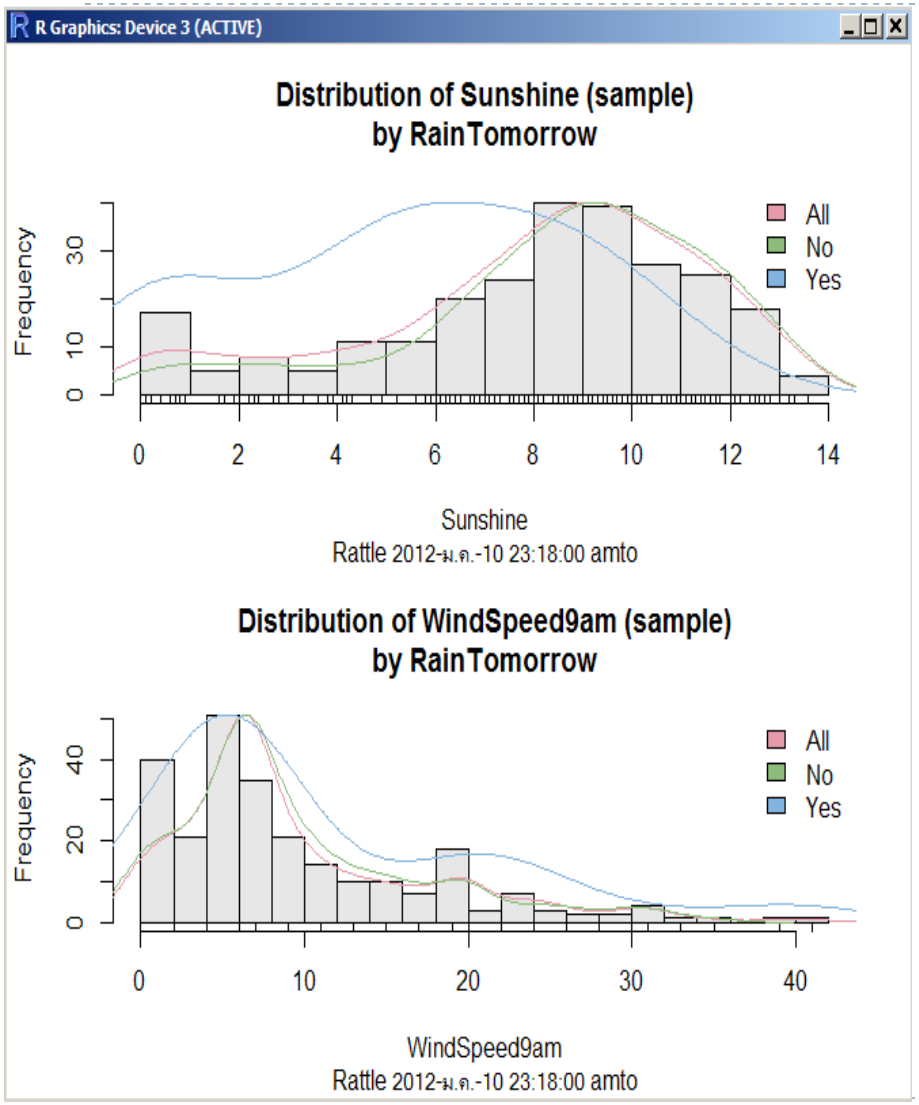


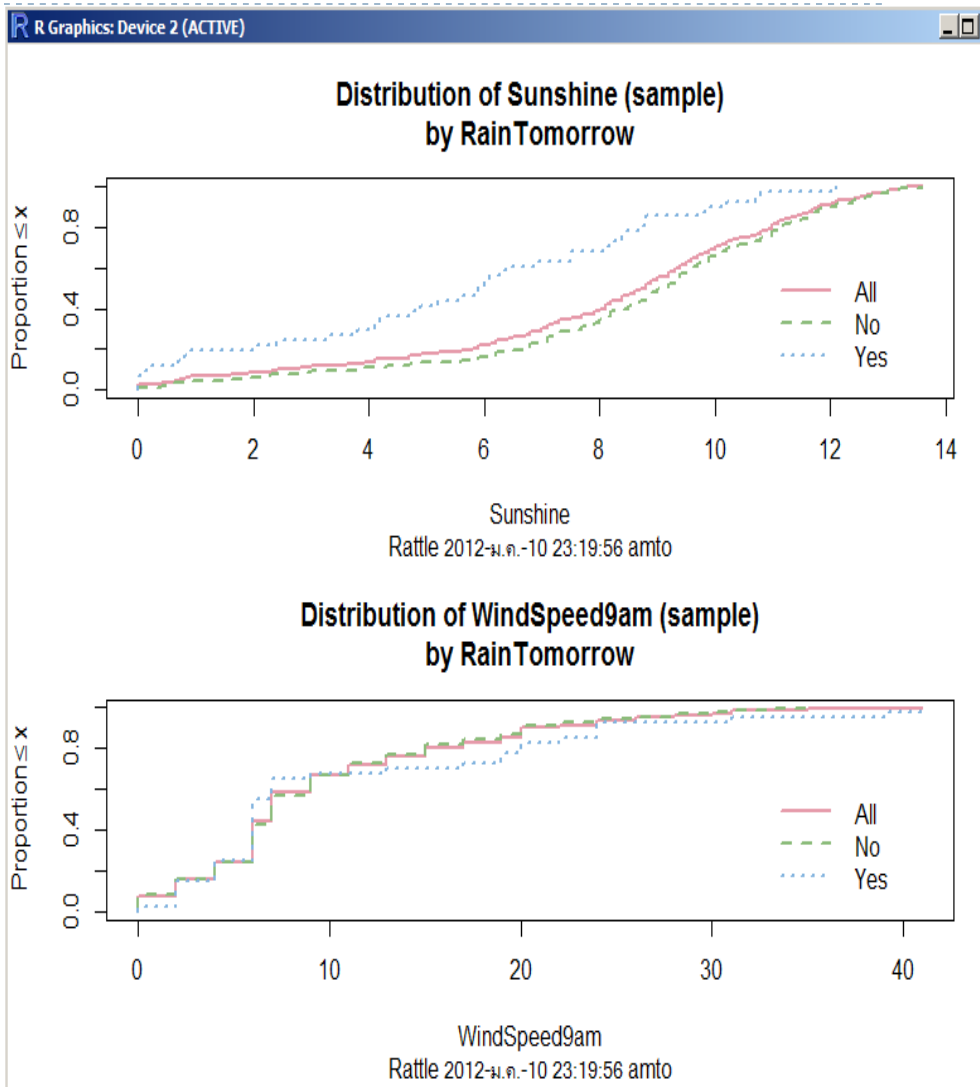
# Rattle Training 4. Exploring Data 4.2 Visualizing Distributions

- 1.ใช้ตัวแปร Sunshine & WindSpeed9am สร้าง Histogram.
- 2. ใช้ตัวแปร Sunshine & WindSpeed9am สร้าง Cumulative.



# Rattle Training 4. Exploring Data 4.2 Visualizing Distributions

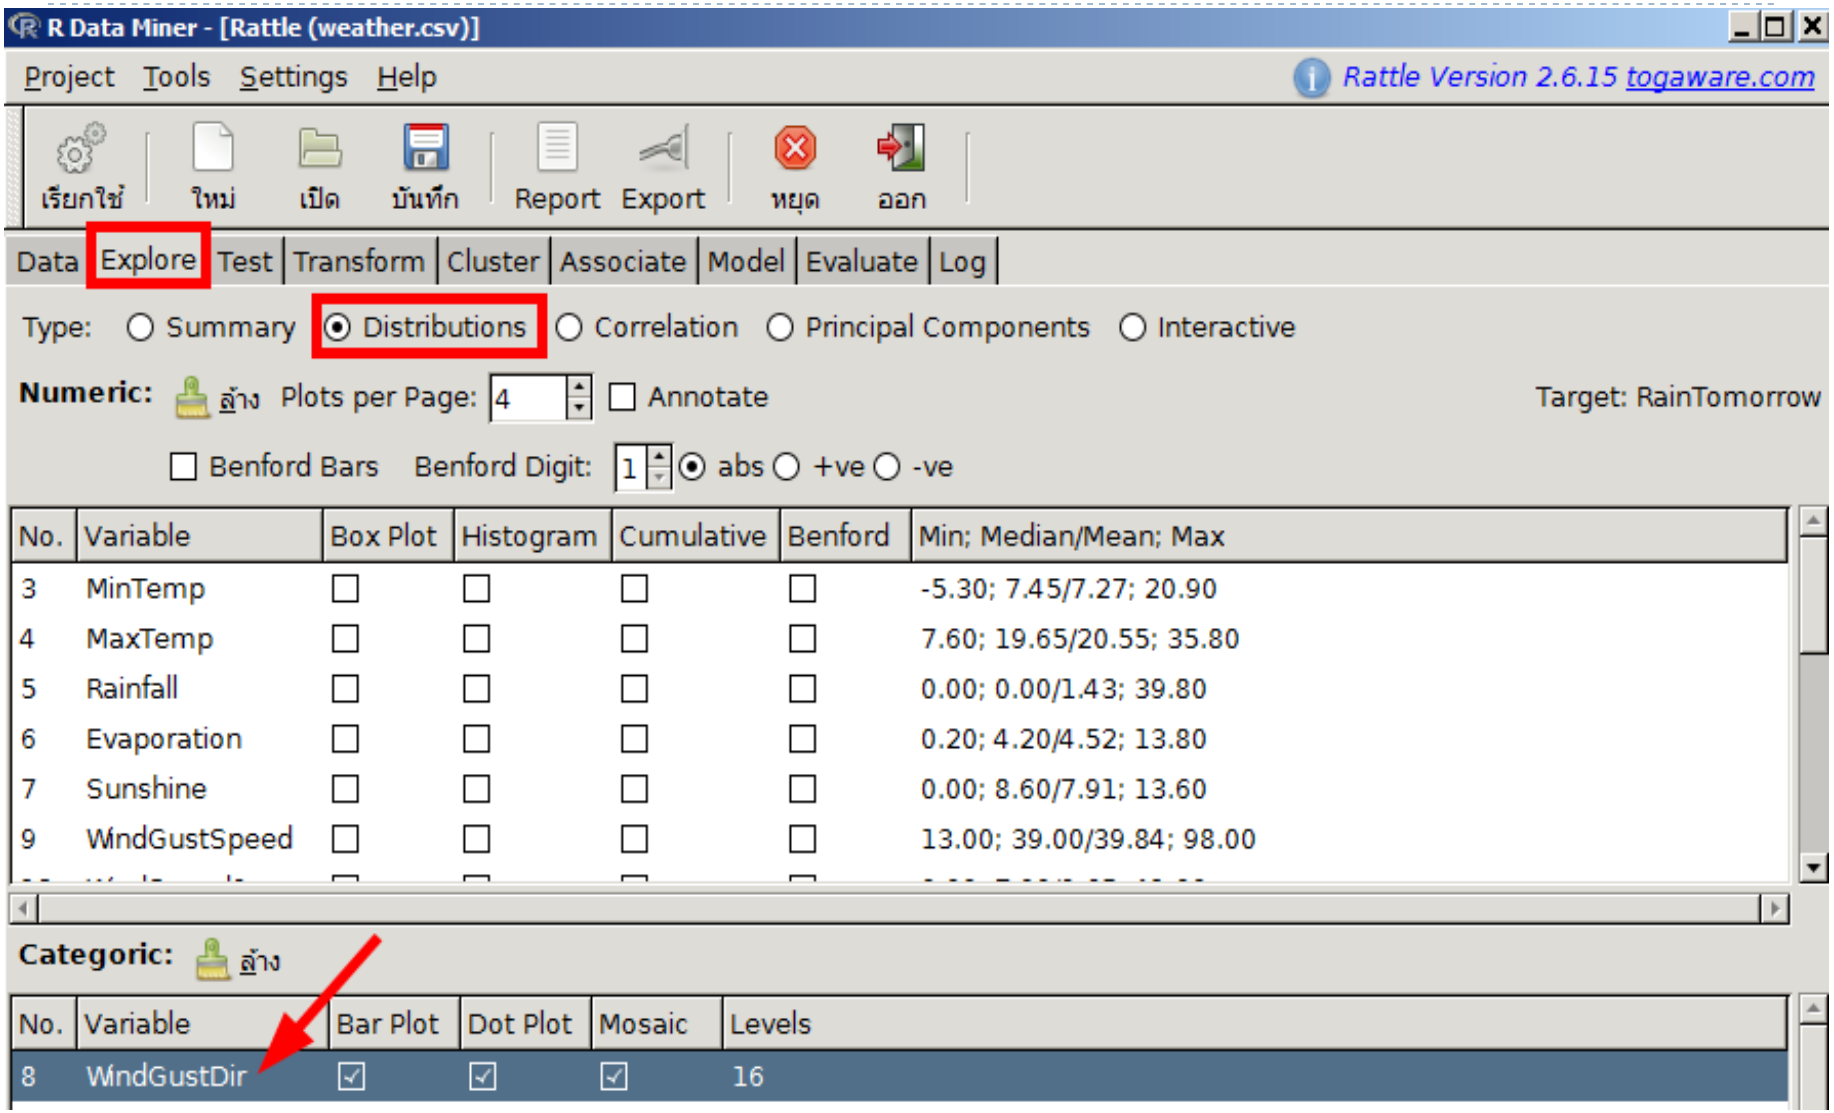


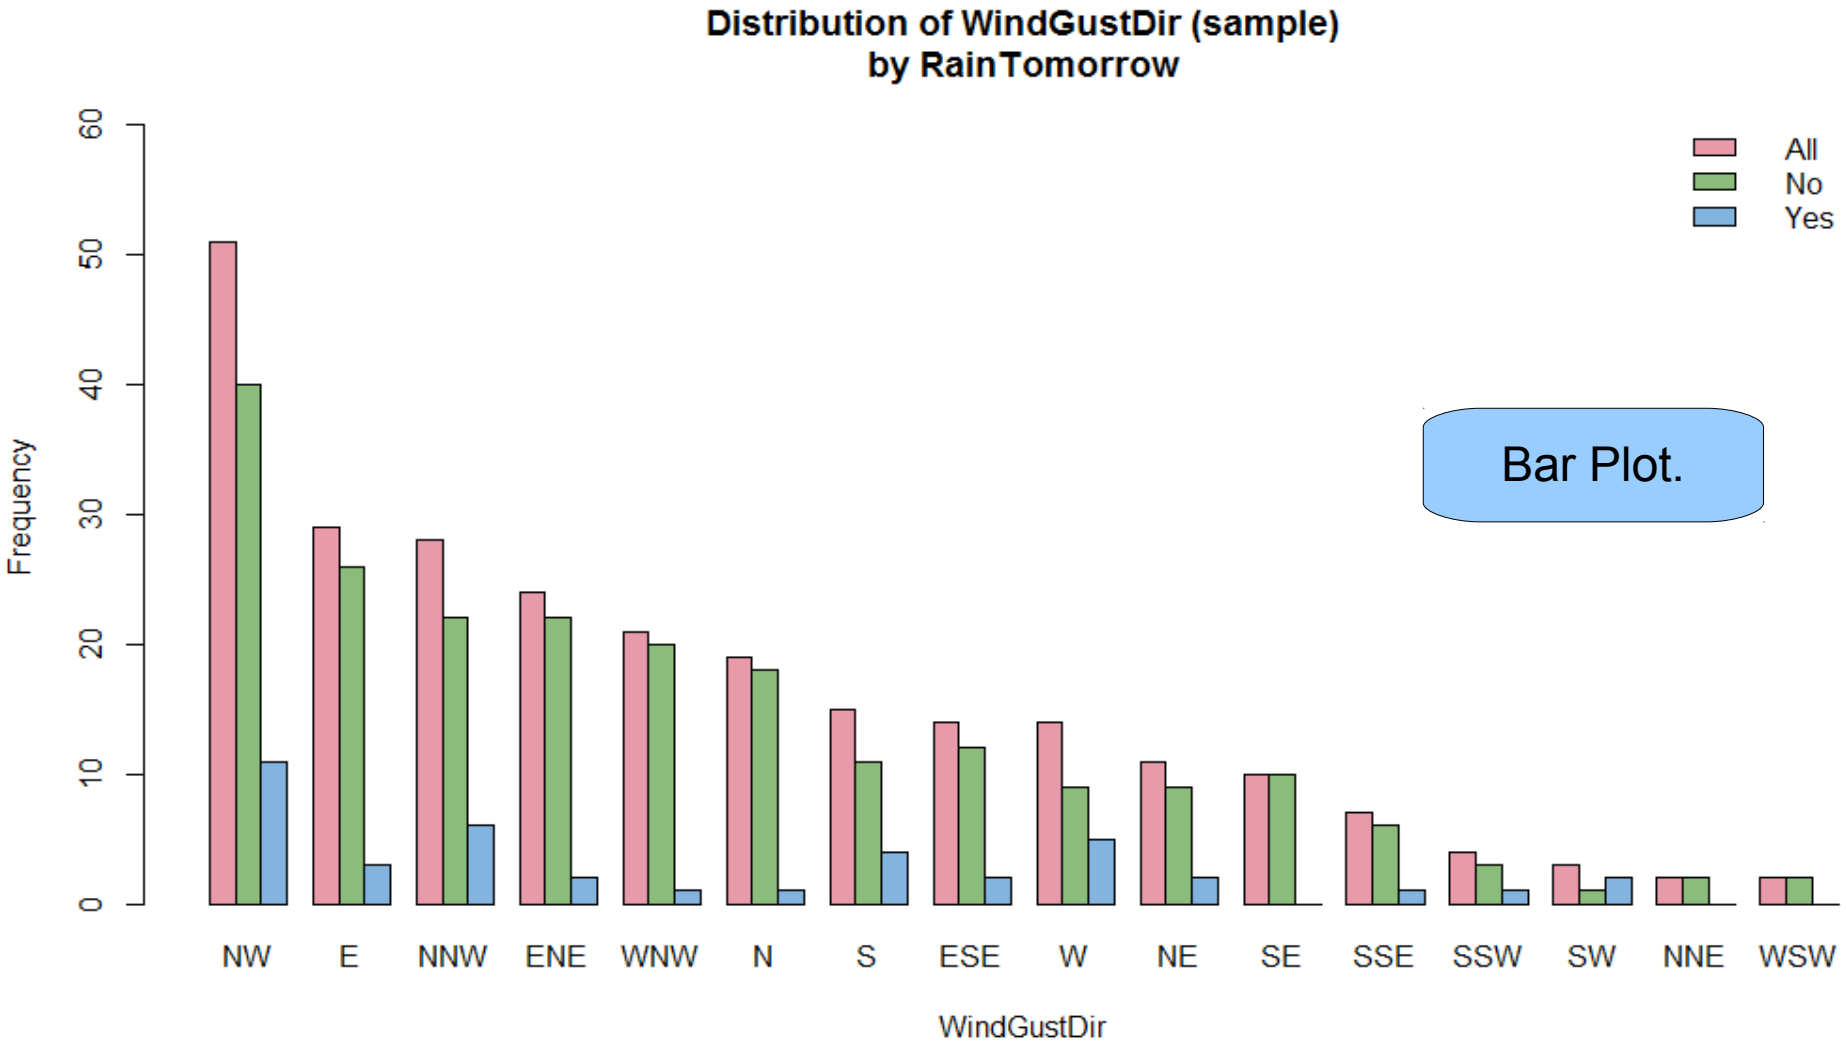
# Rattle Training 4. Exploring Data 4.2 Visualizing Distributions

- Histogram
  - จะให้ภาพการกระจายตัวของข้อมูลได้อย่างรวดเร็ว
  - พิจารณา shape ของข้อมูลซึ่งสะท้อนมาจาก skewness & kurtosis
  - Rattle มีเส้นการกระจายตัวของ Class ให้พิจารณาด้วย
- Cumulative Distribution Plot
  - แสดงสัดส่วนของข้อมูลที่มีค่าน้อยกว่าหรือเท่ากับค่าที่แสดงในแกน x
  - สำหรับ WindSpeed9am ข้อมูลส่วนใหญ่อยู่ในช่วง 0-10
  - ข้อมูลไม่ค่อยสะสมเพิ่มในค่าที่เกิน 10 แสดงว่าอาจมี outliers บ้าง
  - สำหรับ Sunshine ข้อมูลจำนวนมากอยู่ในช่วงกลางๆ (6-10)
  - มีความแตกต่างที่เห็นได้ชัดระหว่าง All & Yes observations
  - แสดงว่าที่ค่า Sunshine today ต่ำๆ สัมพันธ์กับ rains tomorrow

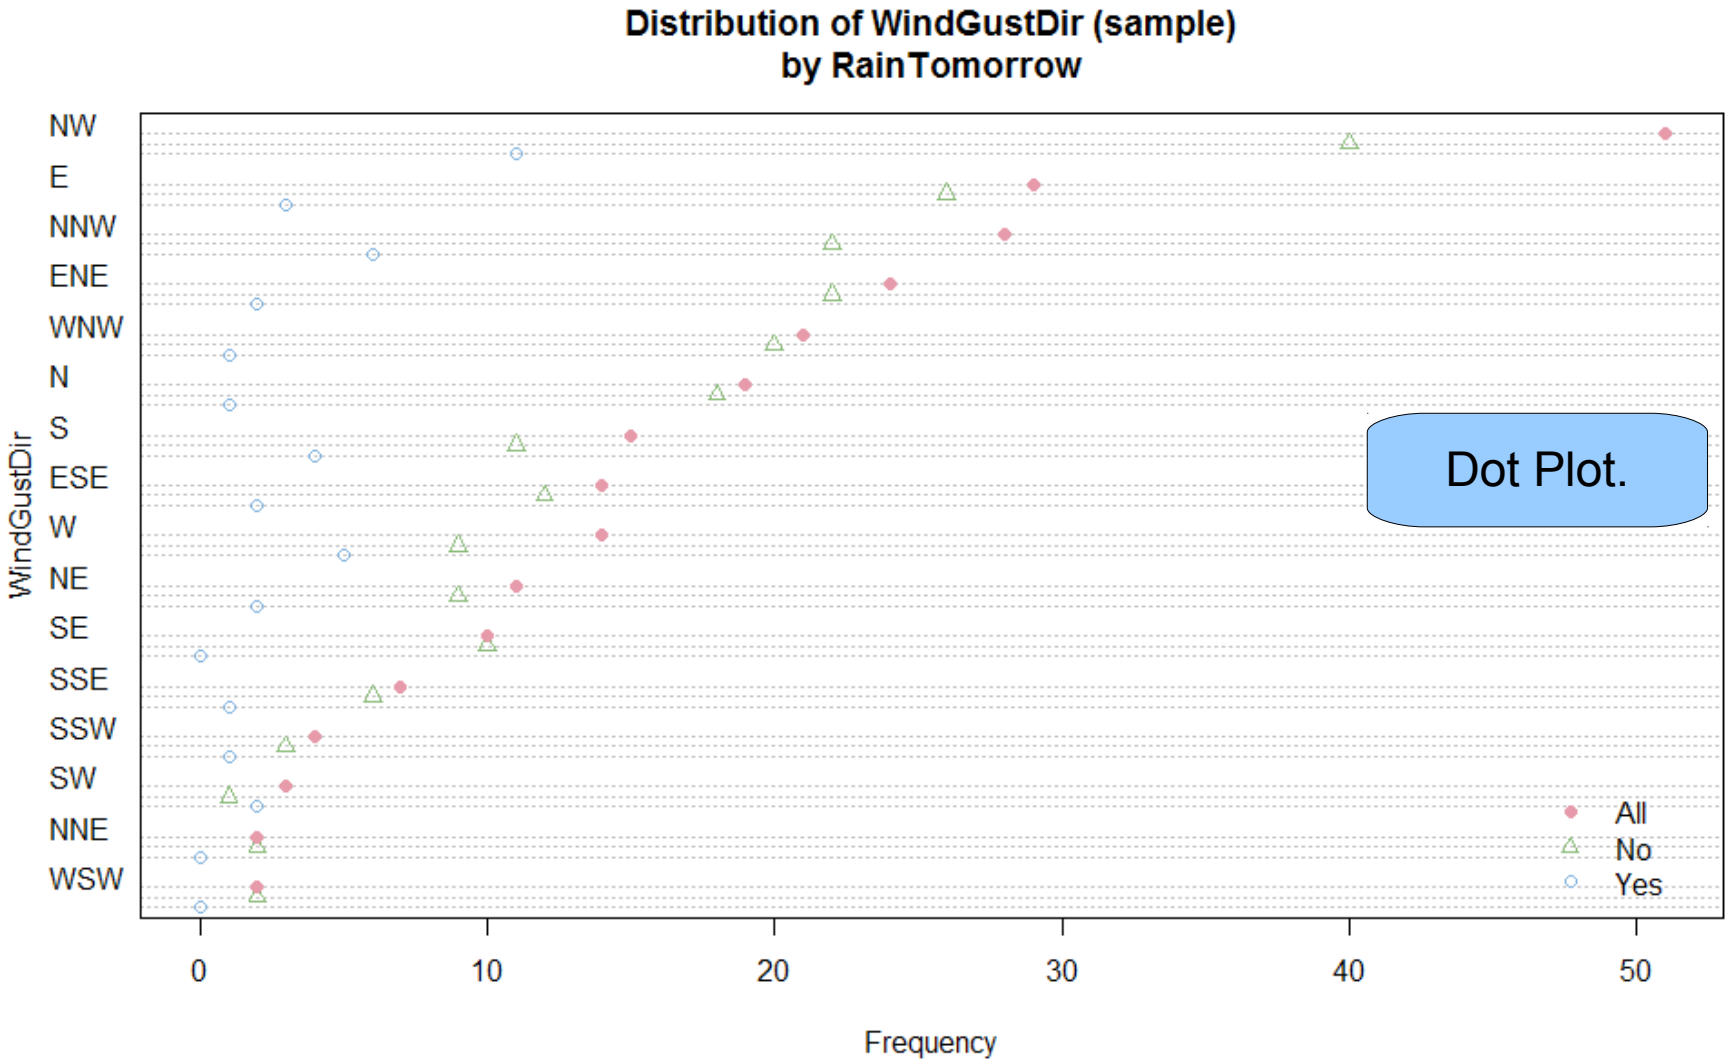
# Rattle Training 4. Exploring Data 4.2 Visualizing Distributions



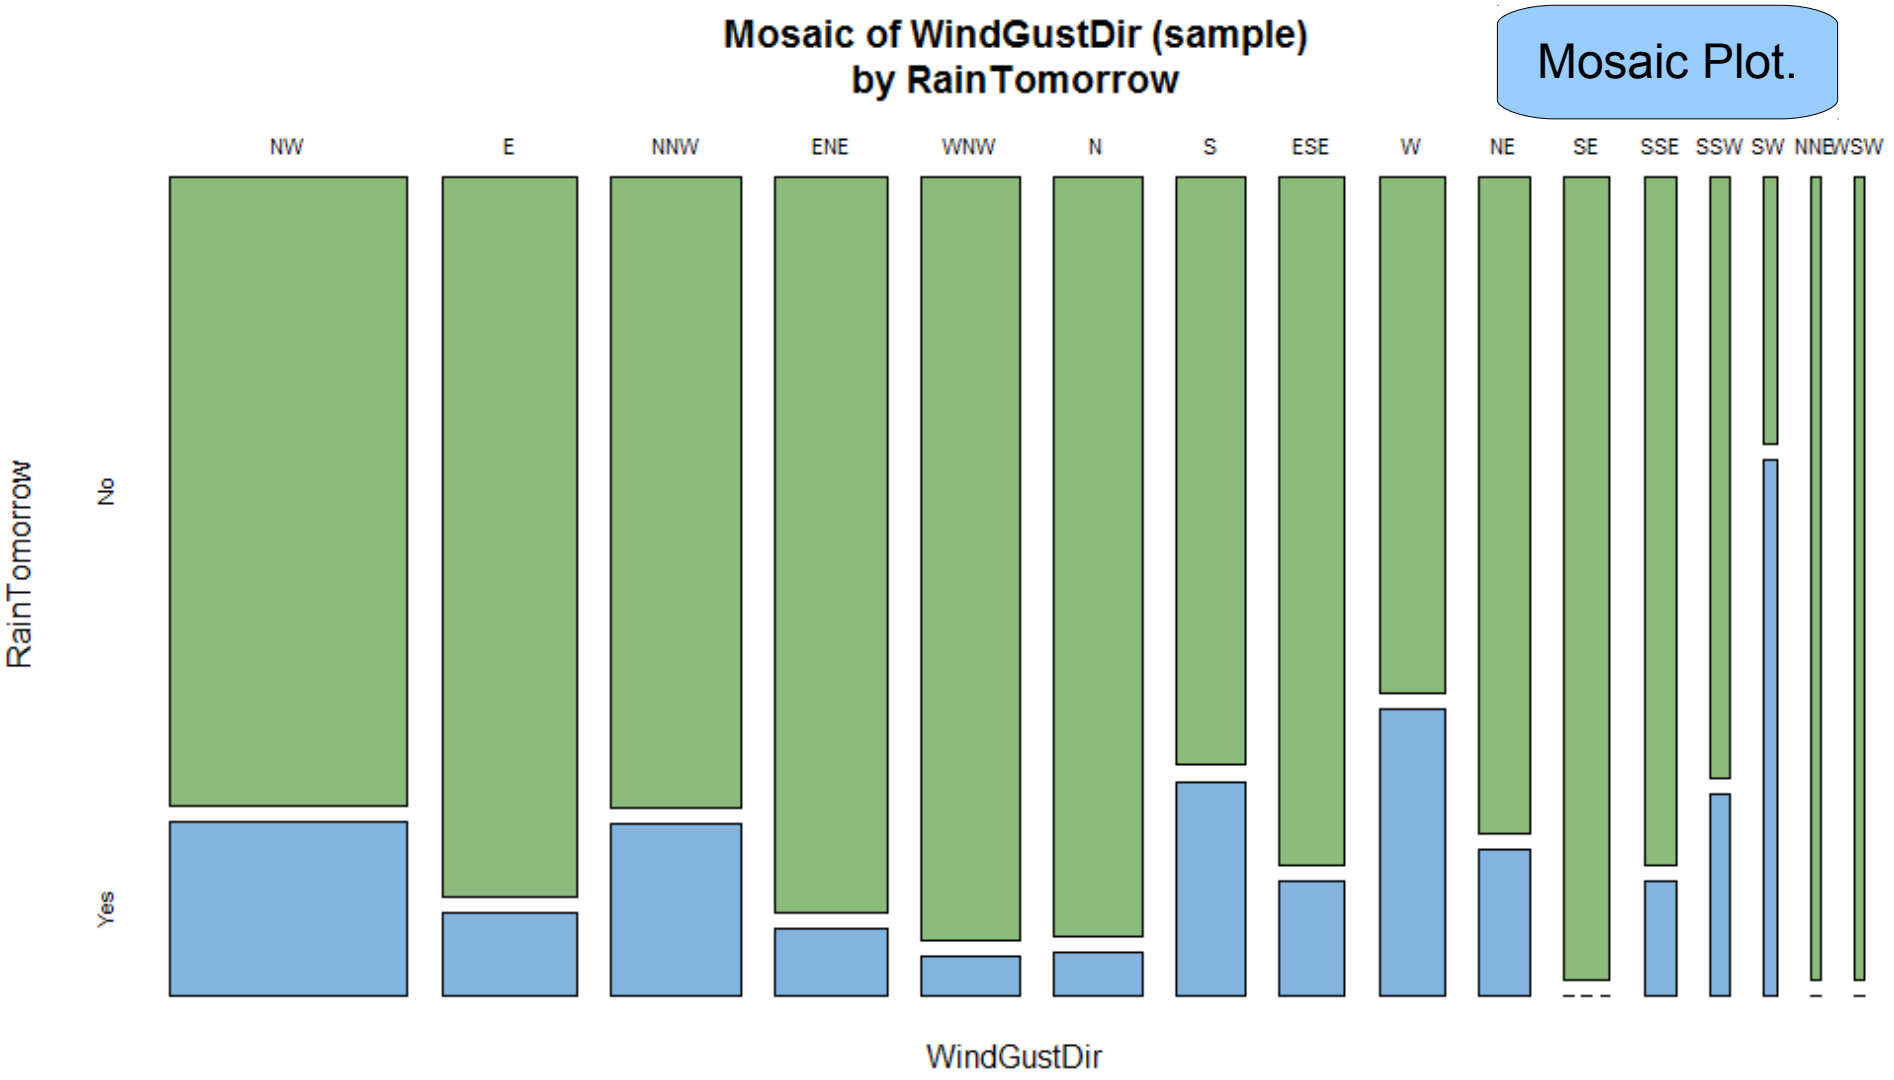
# Rattle Training 4. Exploring Data 4.2 Visualizing Distributions



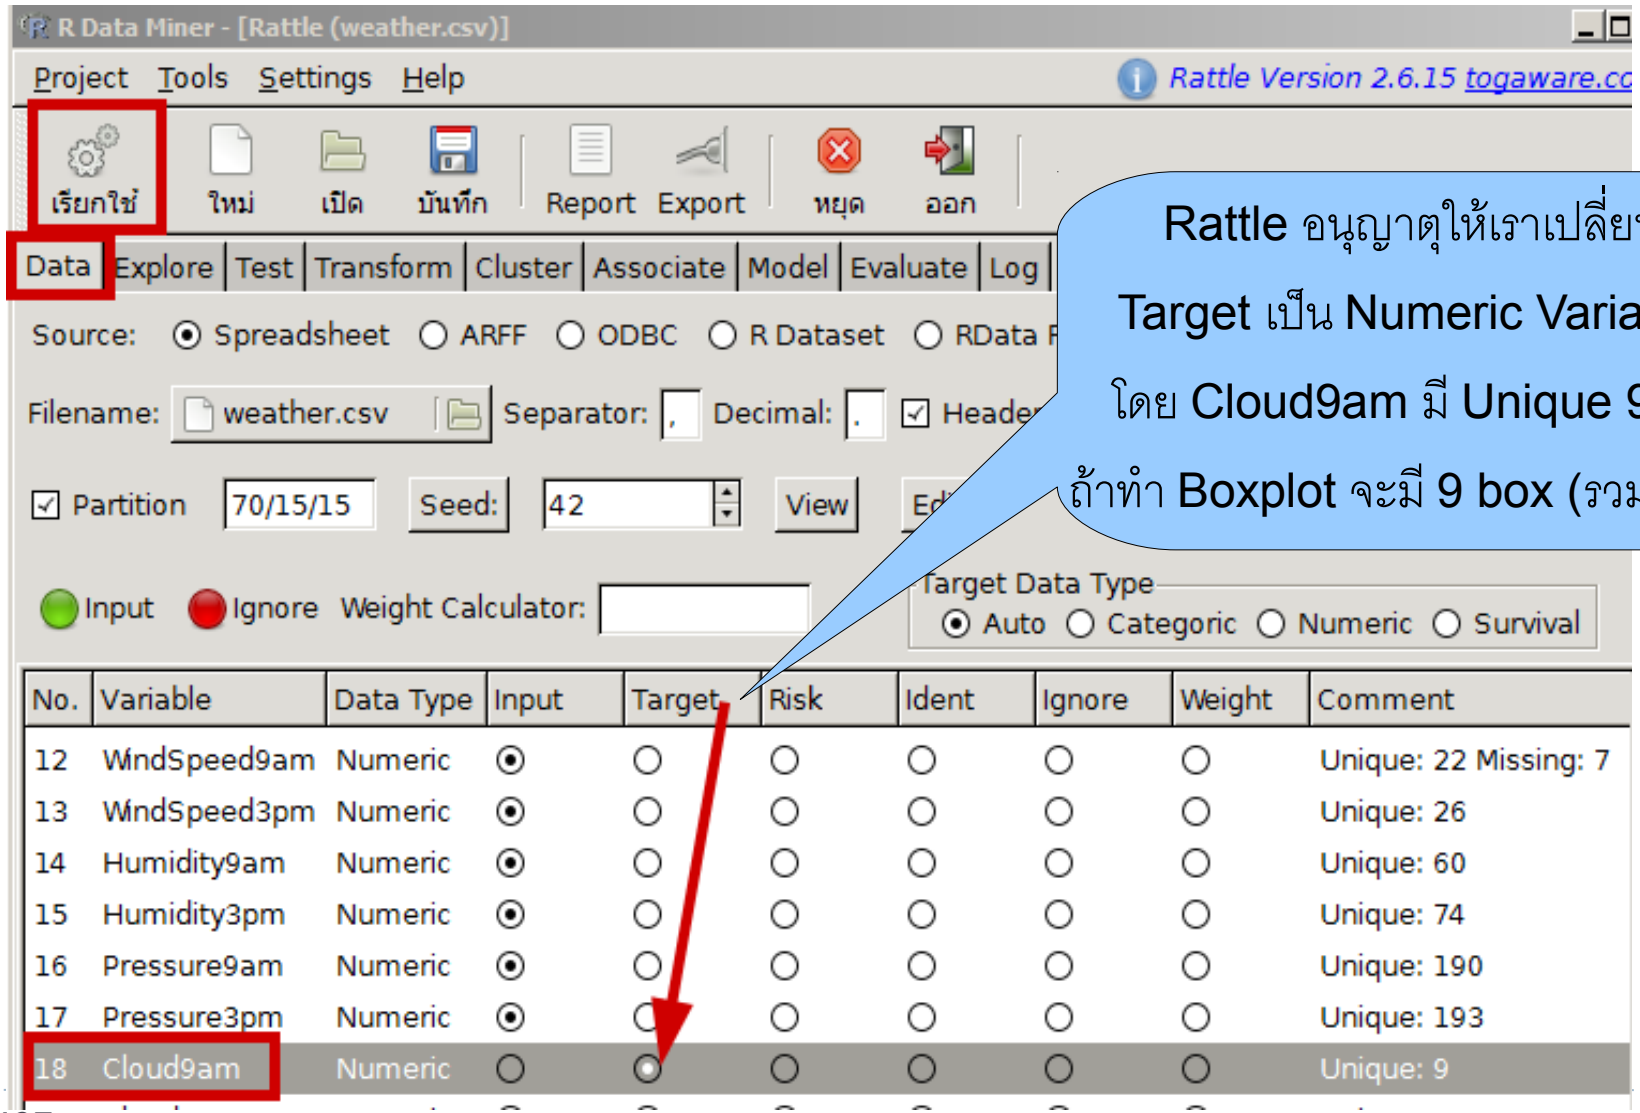
# Rattle Training 4. Exploring Data 4.2 Visualizing Distributions



# Rattle Training 4. Exploring Data 4.2 Visualizing Distributions

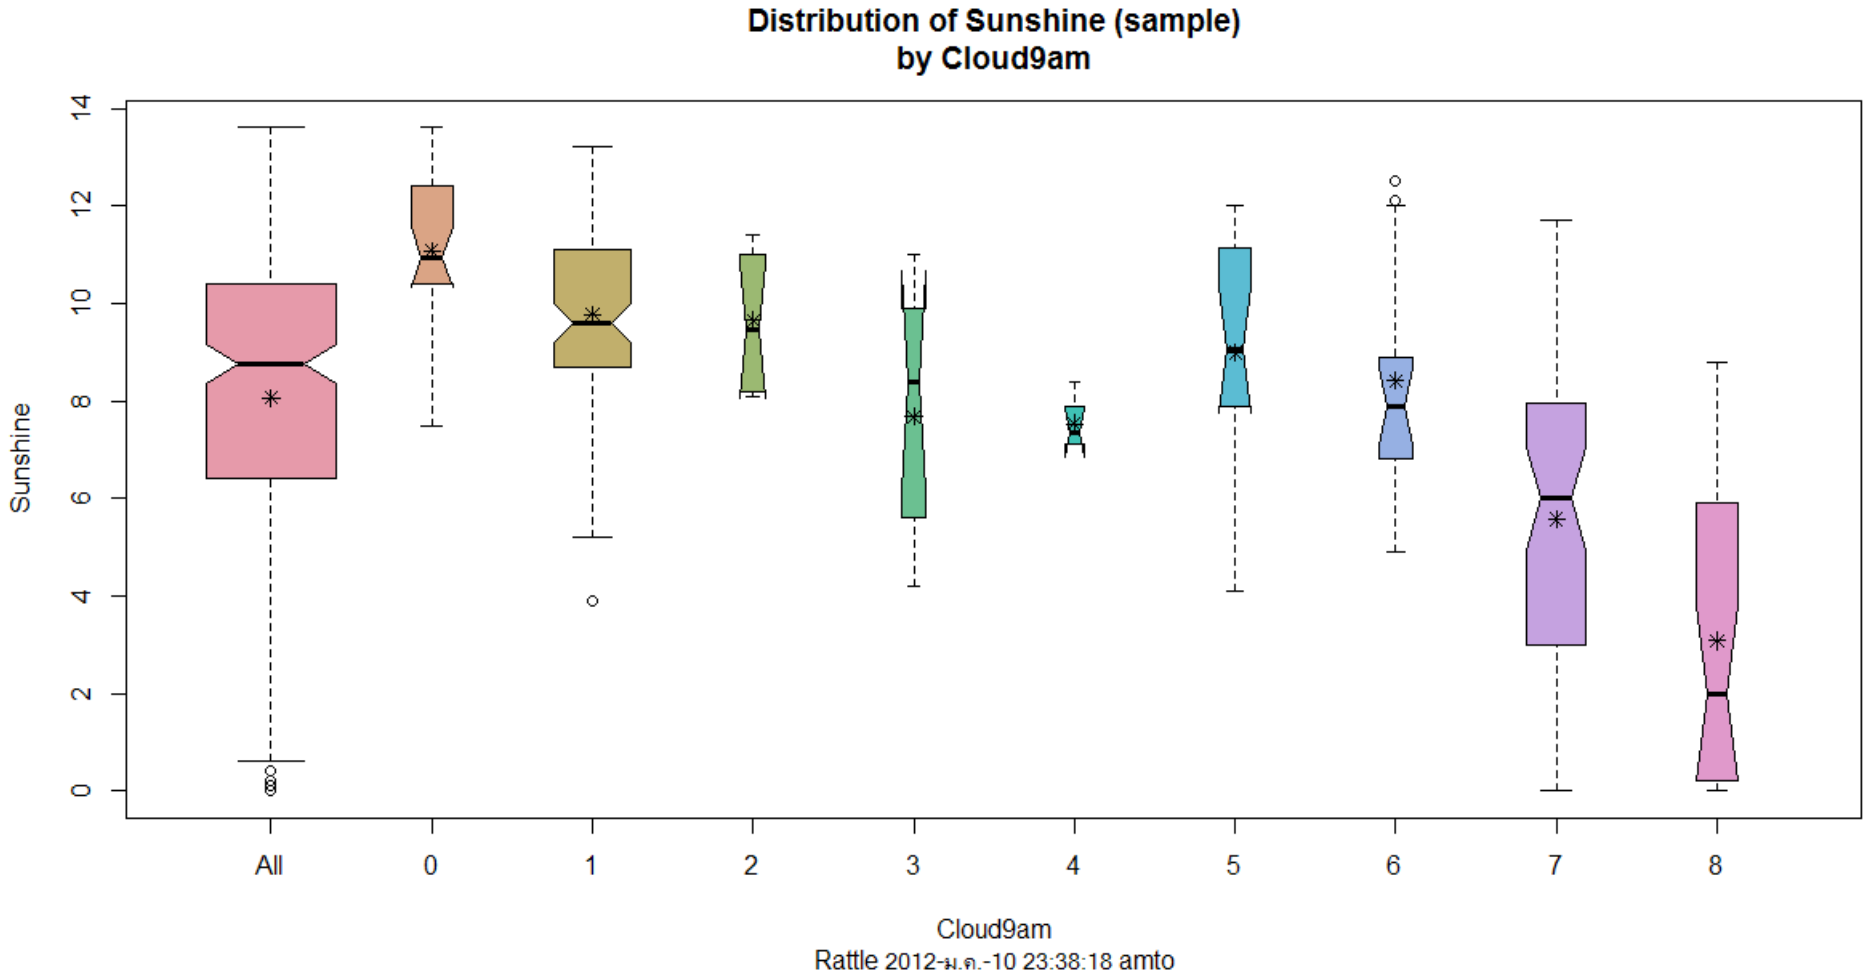


# Rattle Training 4. Exploring Data 4.2 Visualizing Distributions



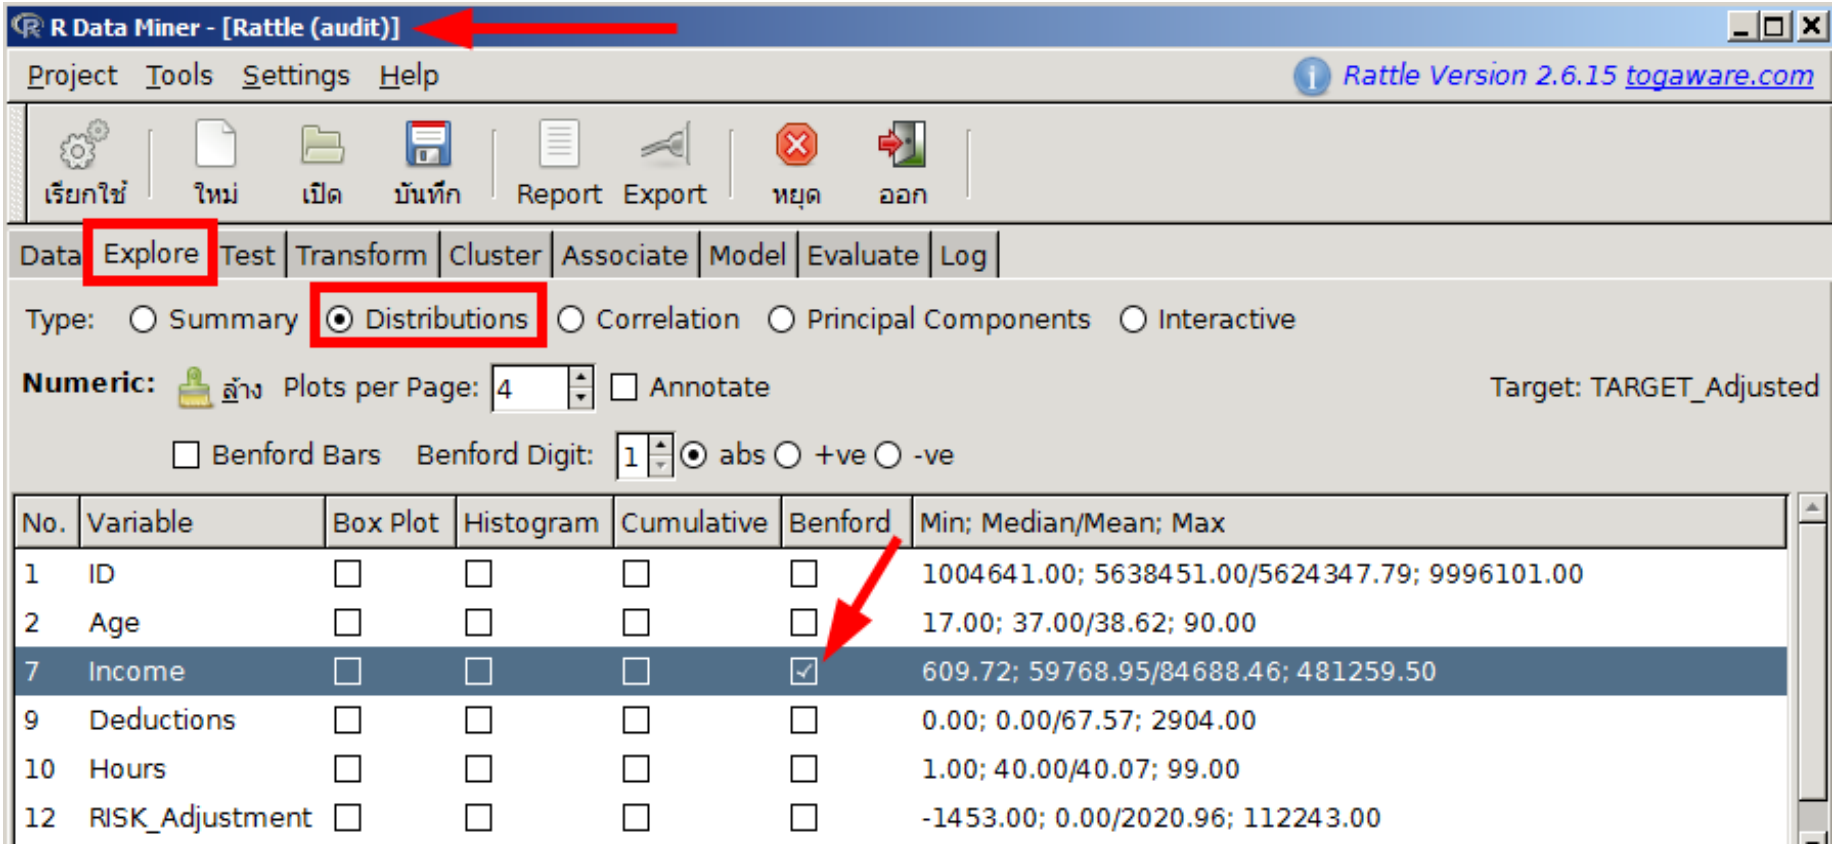

Rattle อนุญาตุให้เราเปลี่ยน Target เป็น Numeric Variable โดย Cloud9am มี Unique 9 ตัว ถ้าทำ Boxplot จะมี 9 box (รวมอีก 1)

# Rattle Training 4. Exploring Data 4.2 Visualizing Distributions



# Rattle Training 4. Exploring Data 4.2 Visualizing Distributions

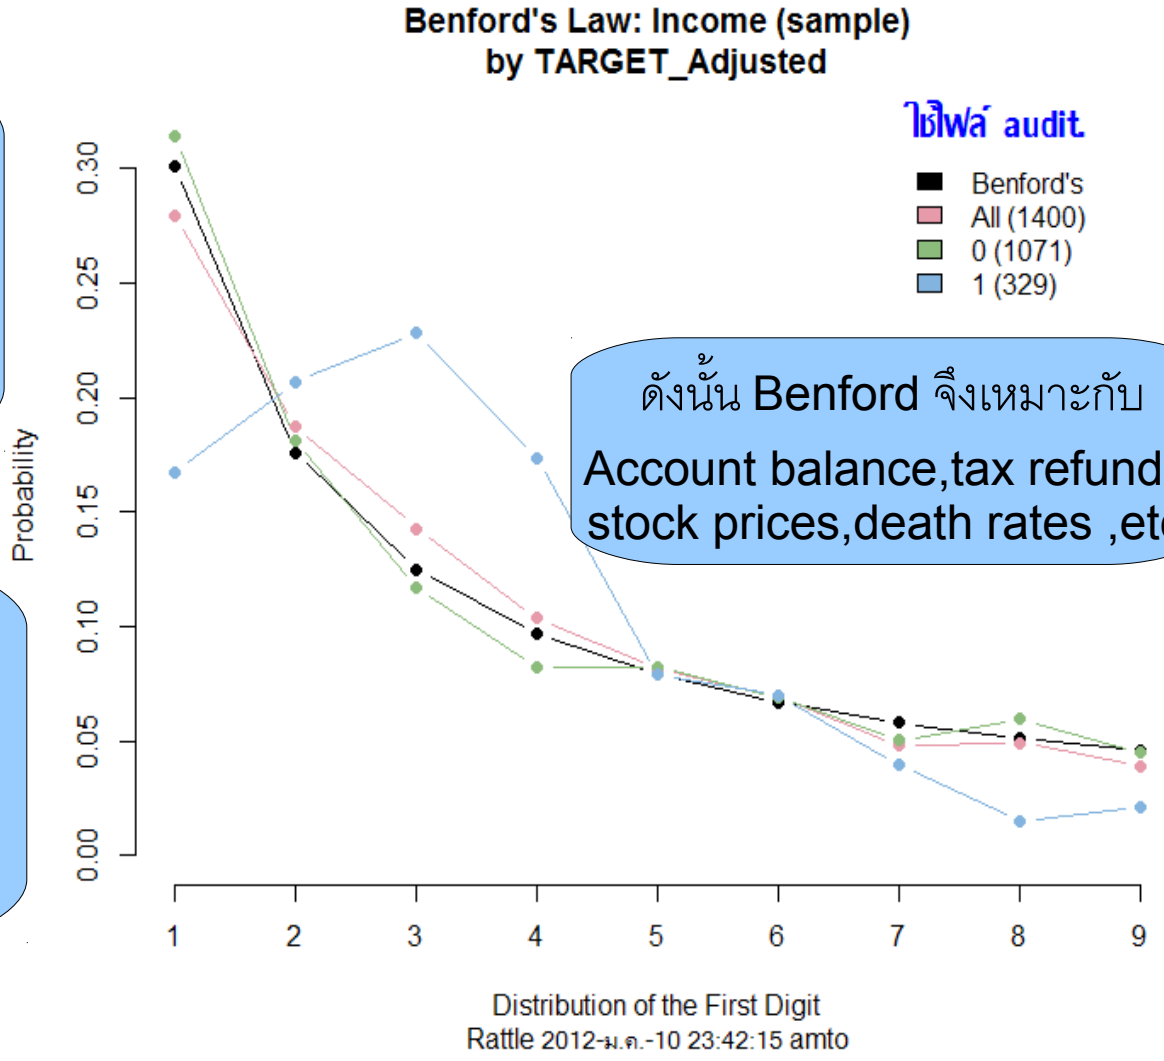
- ใช้ไฟล์ audit.RData สร้าง Benford graph กับตัวแปร Income



# Rattle Training 4. Exploring Data 4.2 Visualizing Distributions

Benford's Law ใช้ในการตรวจสอบข้อมูลแปลกๆ หรือโกง หรือสิ่งน่าสนใจ โดยนำค่าตัวเลขตัวหน้า เช่น หลัก 1 10,100,1000... มา Plot

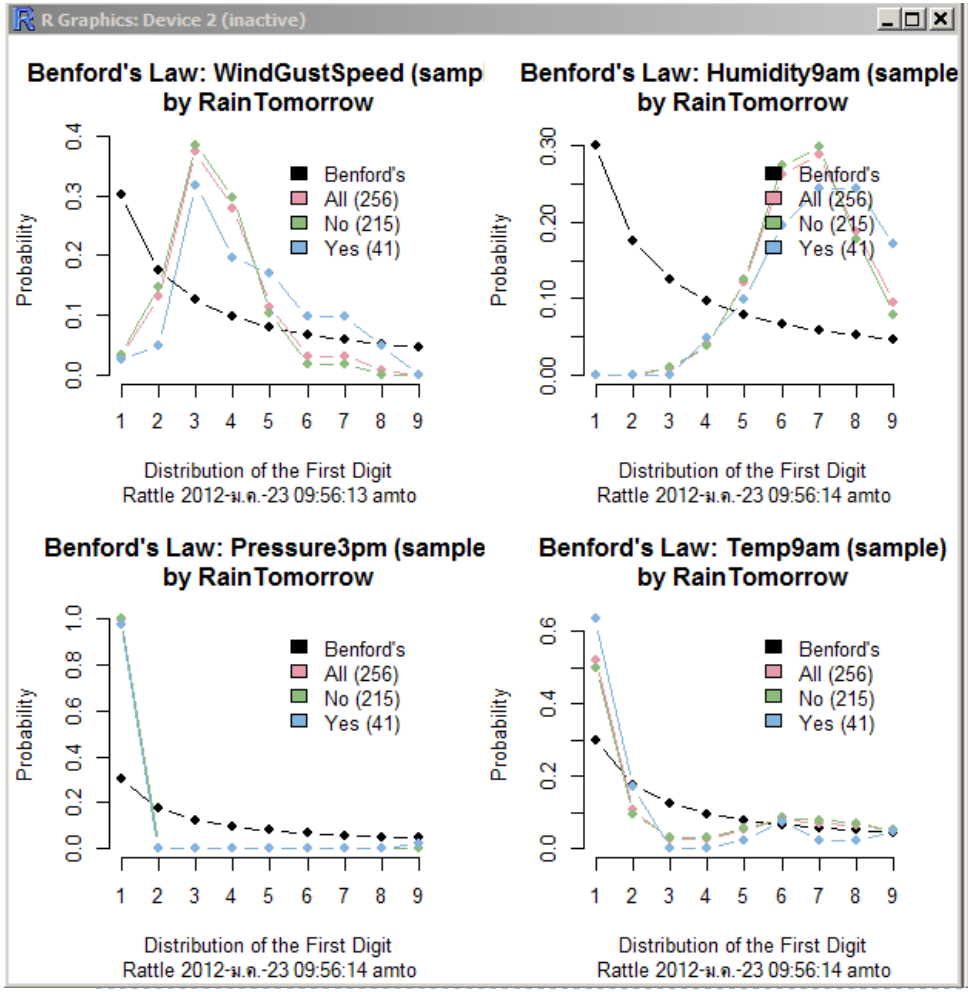
กฎนี้เริ่มจากเลข 1 มีค่า prob 30% ไล่ไปจนถึงเลข 9 มีค่า prob 5% ช่วงใดที่กราฟมีความแตกต่างไปจากกฎ แสดงว่าข้อมูลมีอยู่มากในช่วงนั้น

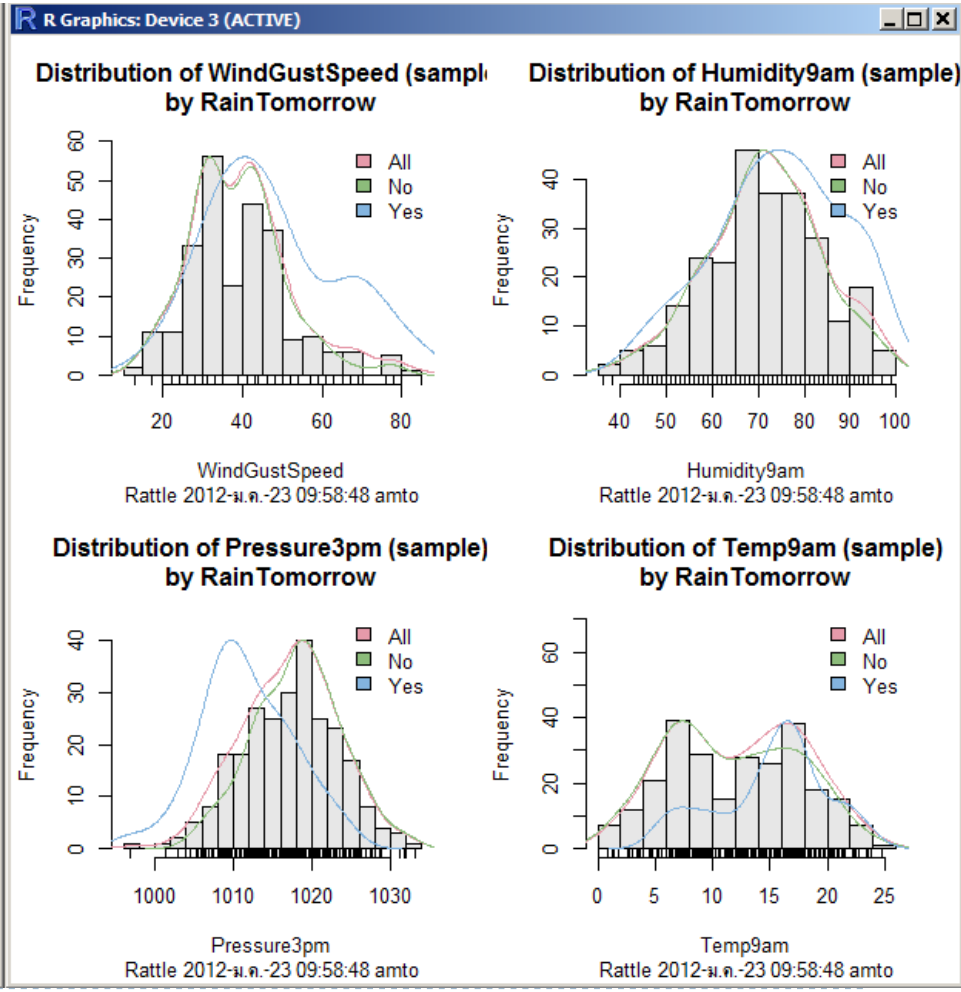



ดังนั้น Benford จึงเหมาะกับ Account balance,tax refunds, stock prices,death rates ,etc.

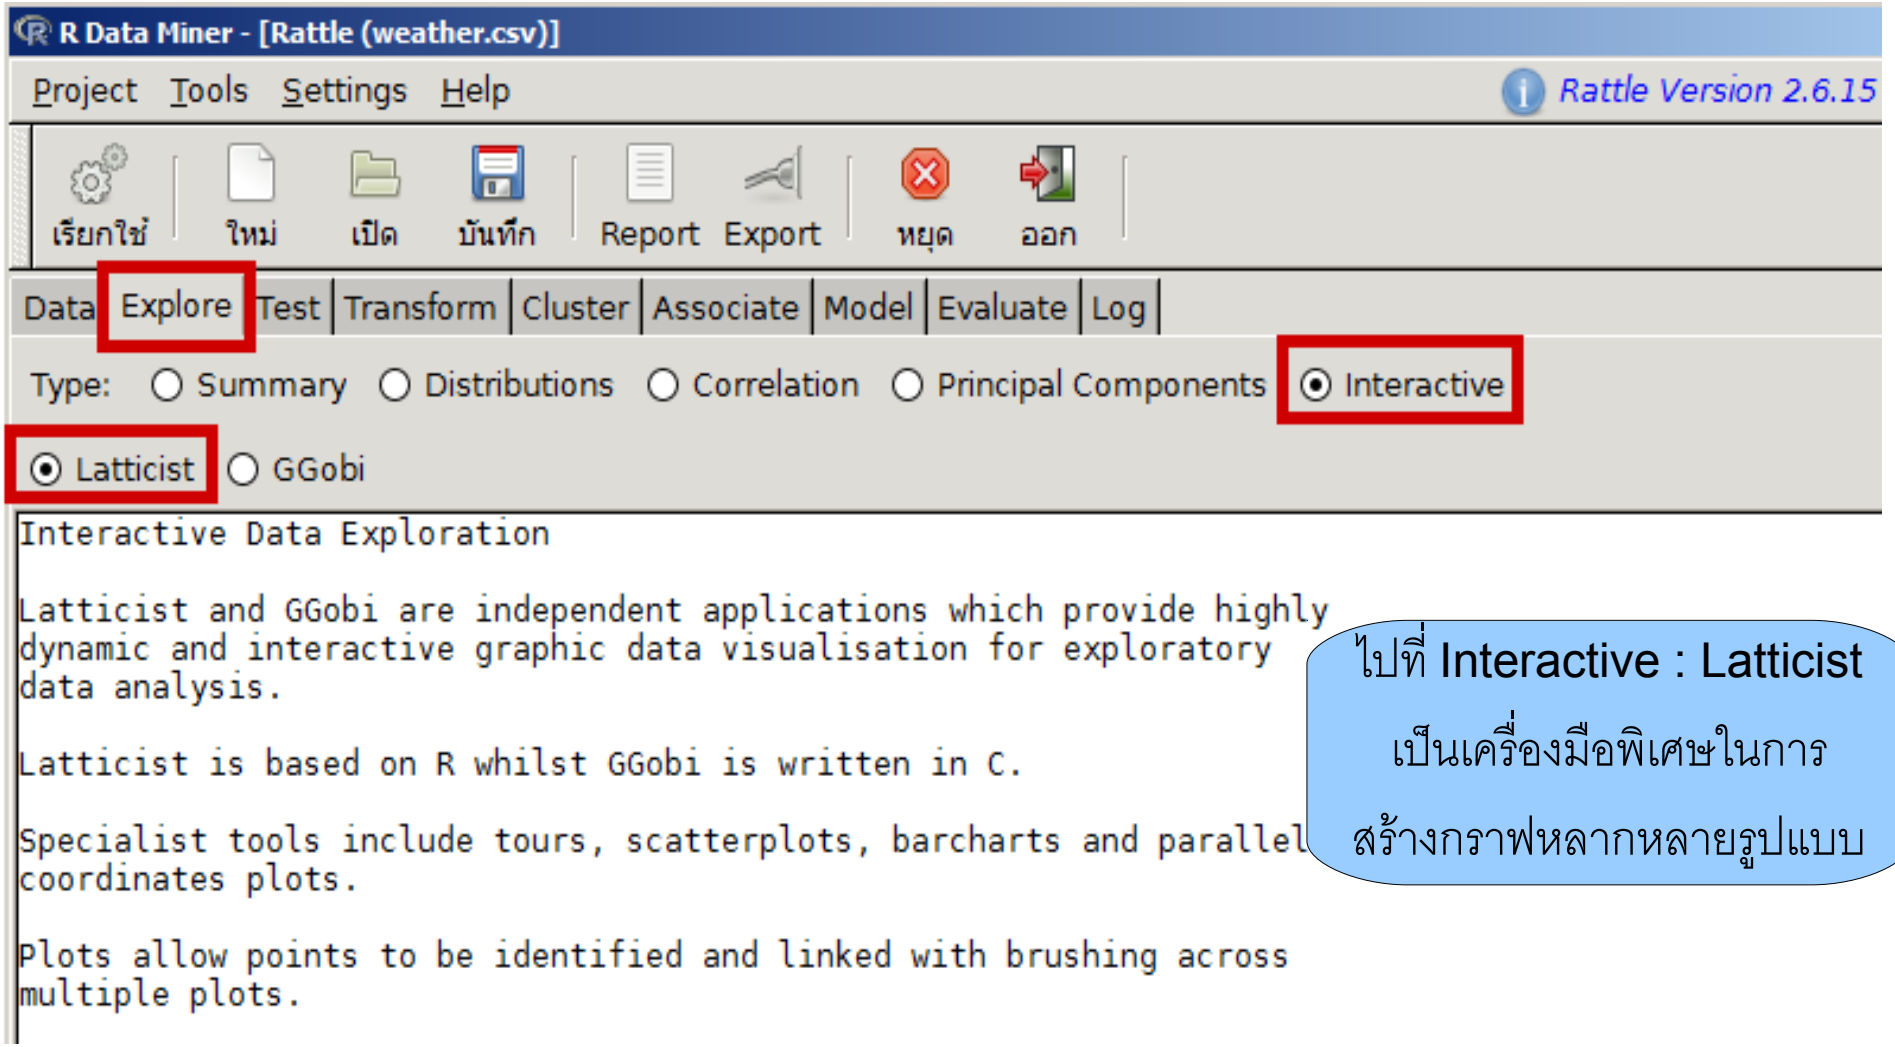
# Rattle Training 4. Exploring Data 4.2 Visualizing Distributions

- Benford's Law ไม่เหมาะกับบางข้อมูล เช่น อายุ,เบอร์โทร ลองดู ตย.ข้างล่าง



# Rattle Training 4. Exploring Data 4.2 Visualizing Distributions

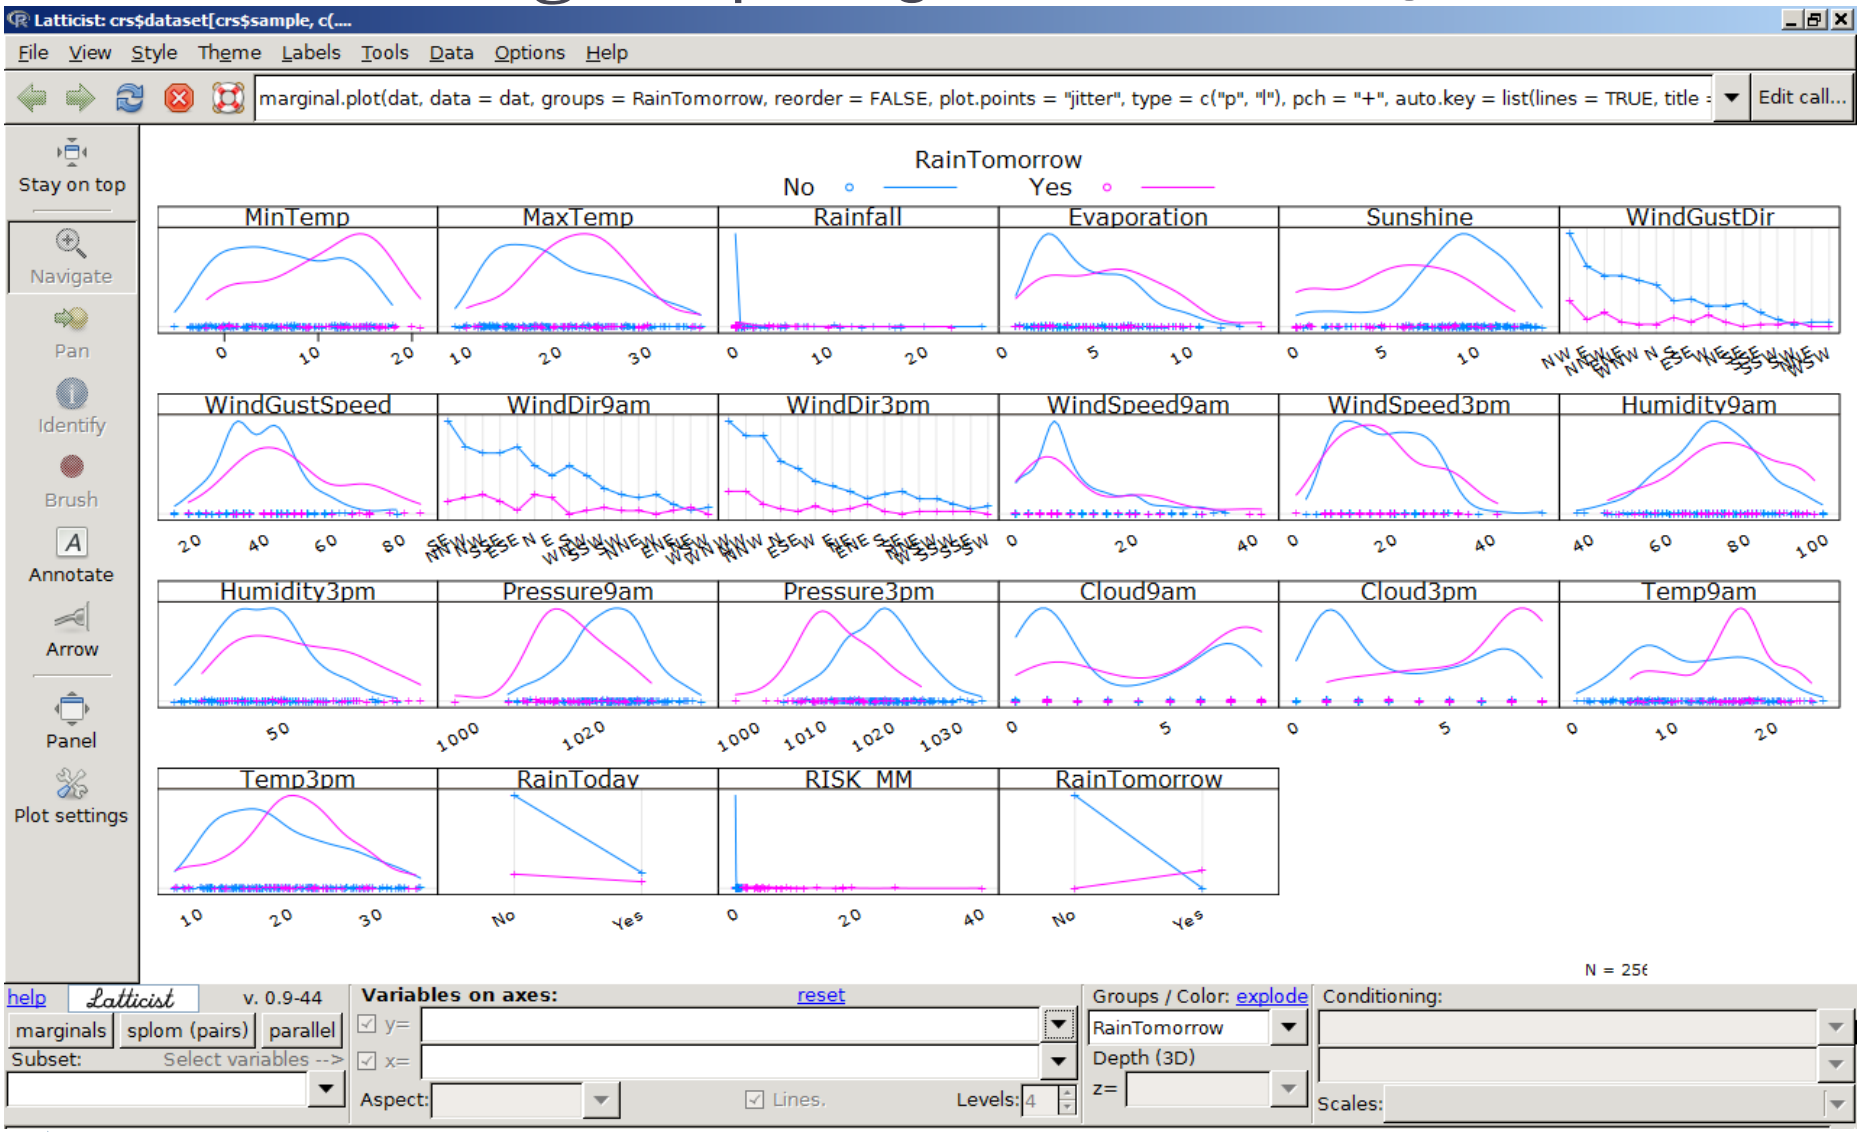



ไปที่ Interactive : Latticist

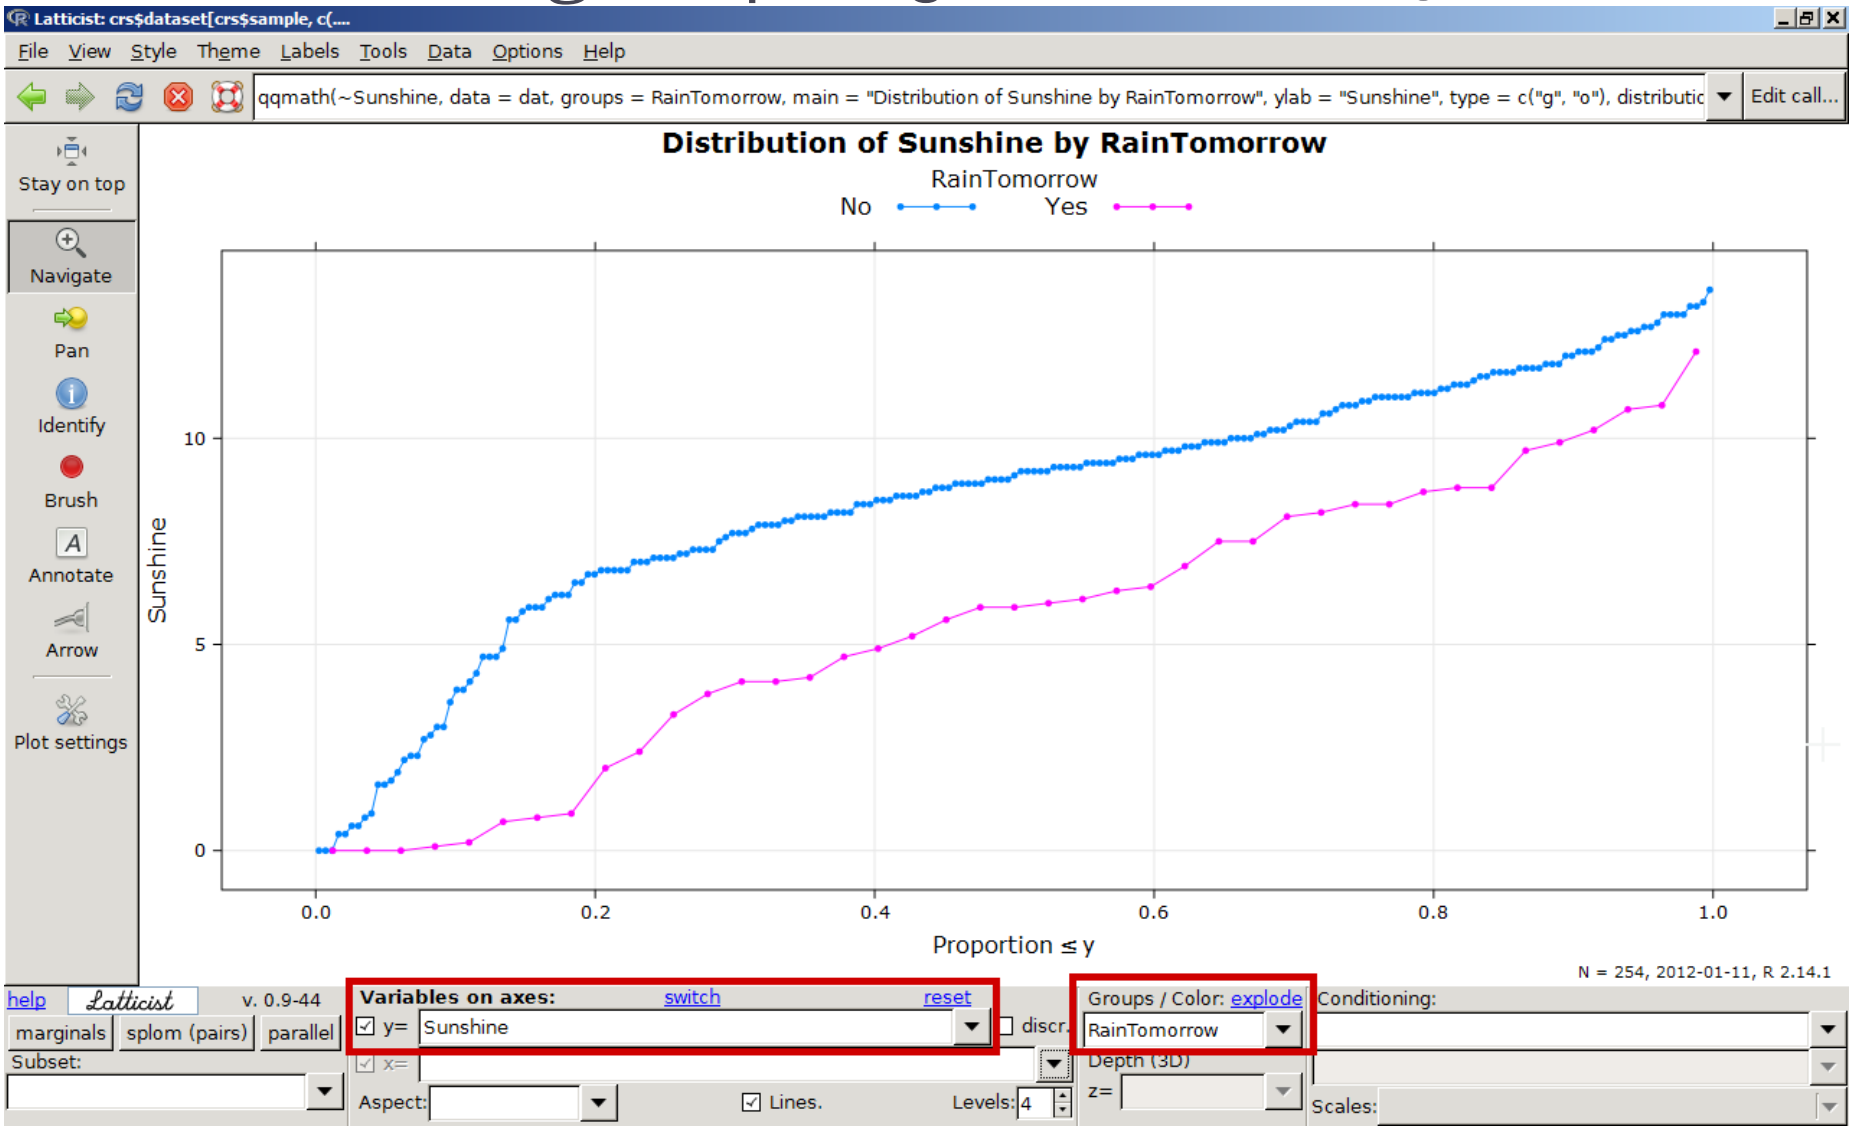
เป็นเครื่องมือพิเศษในการ

สร้างกราฟหลากหลายรูปแบบ

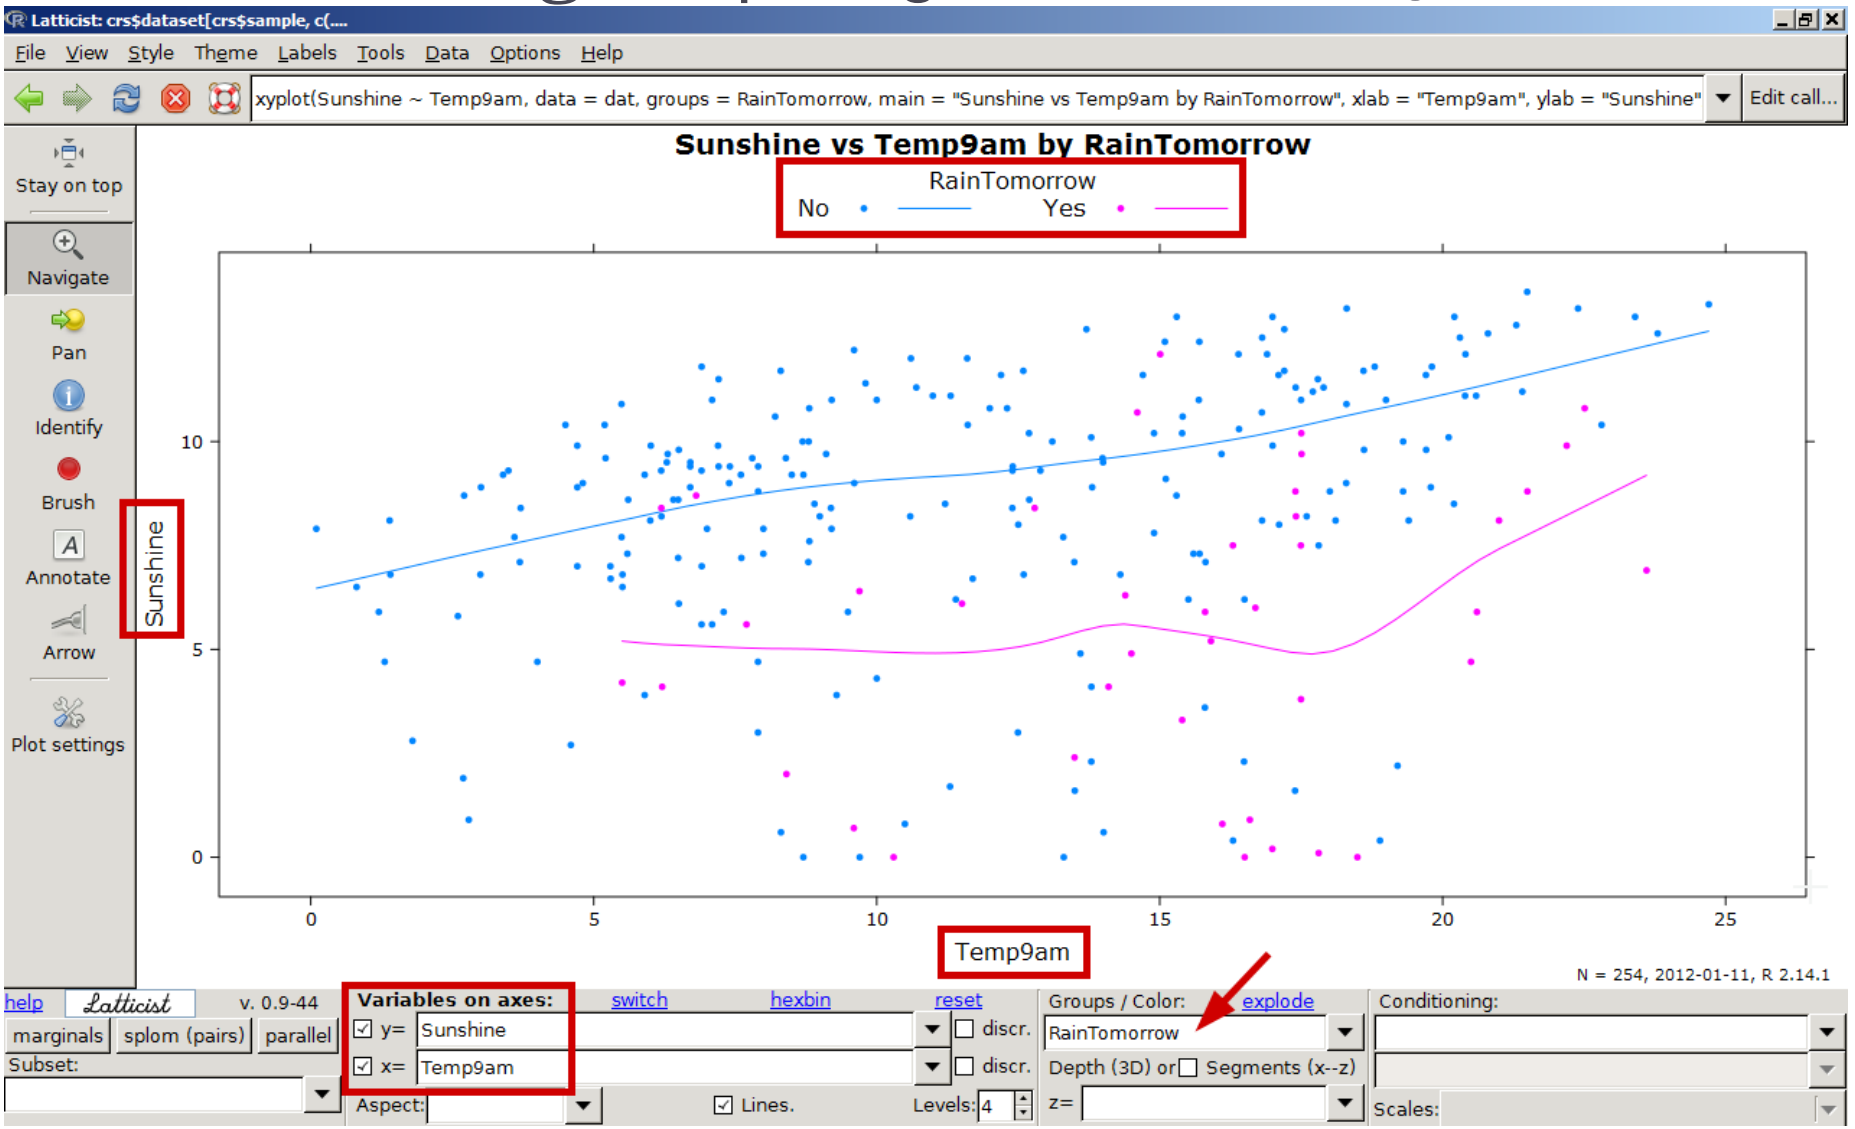
# Rattle Training 4. Exploring Data 4.2 Visualizing Distributions



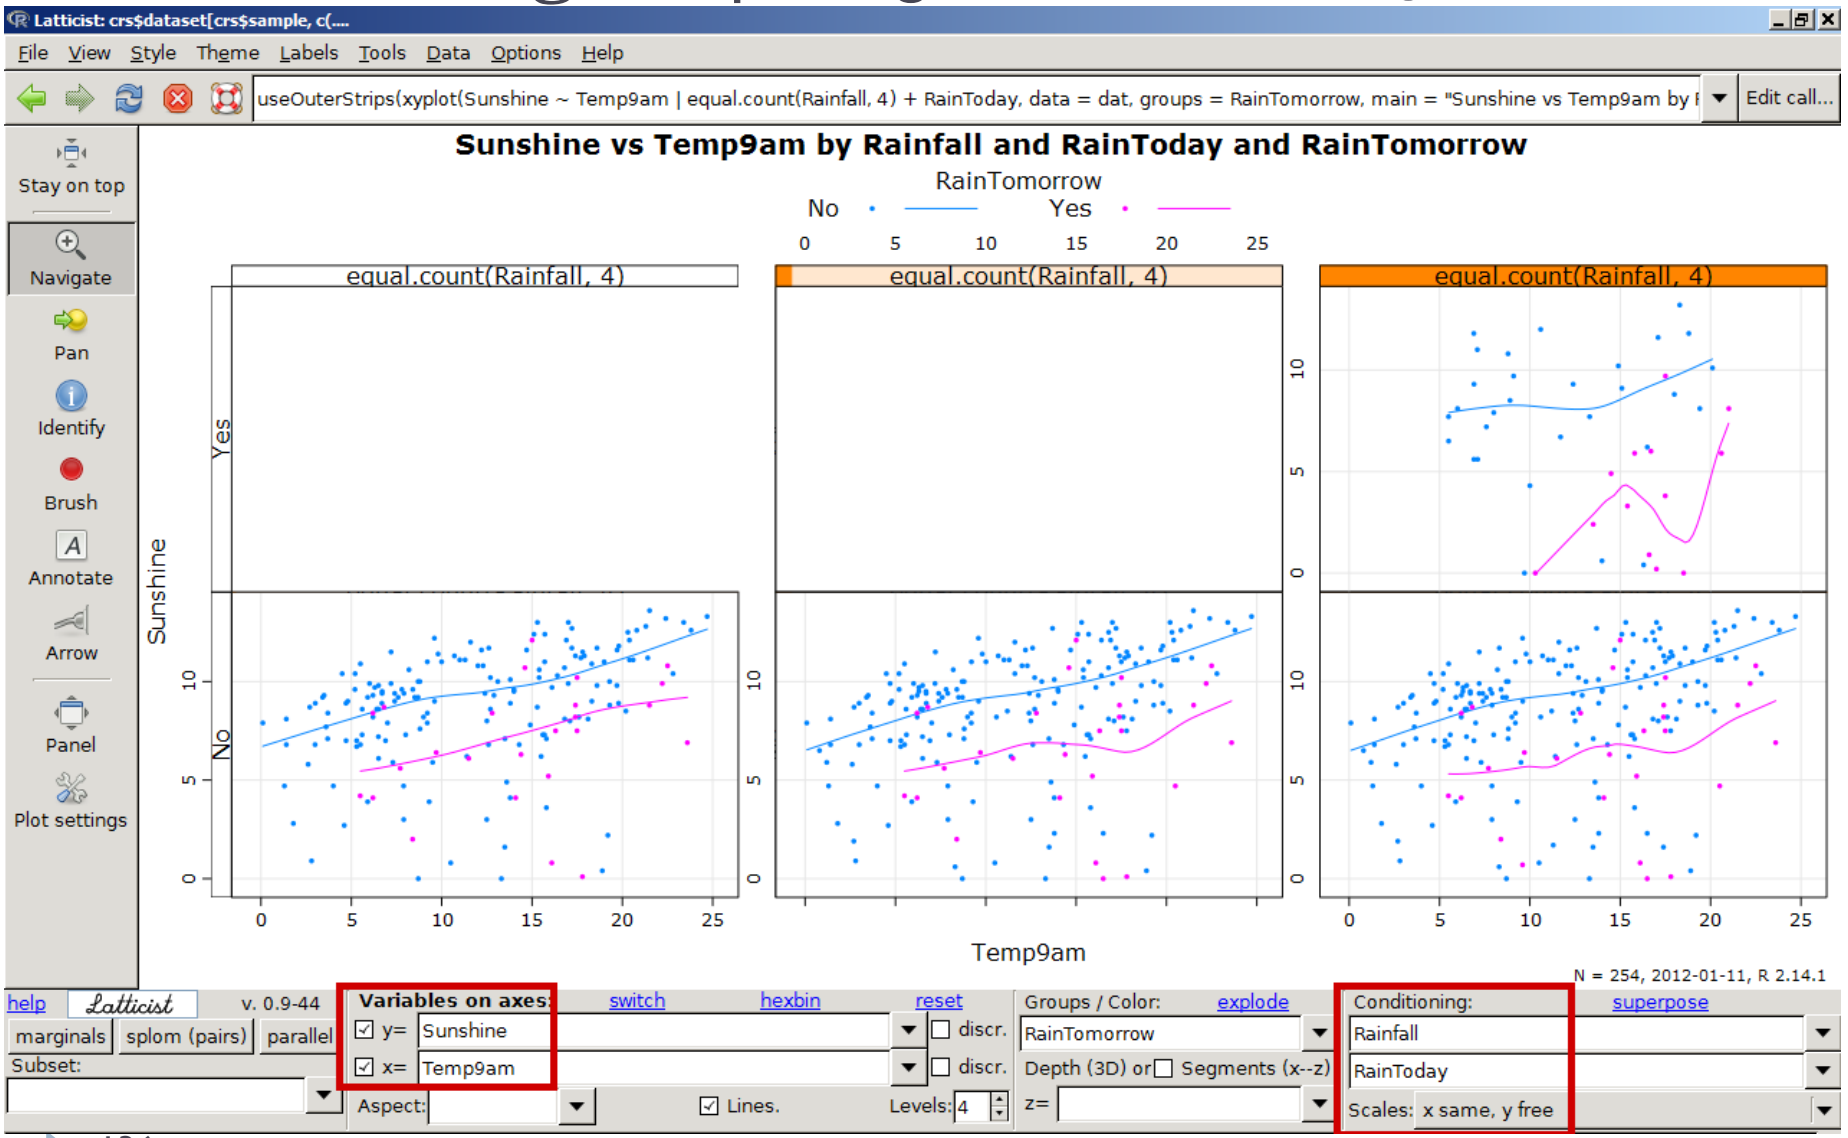
# Rattle Training 4. Exploring Data 4.2 Visualizing Distributions



# Rattle Training 4. Exploring Data 4.2 Visualizing Distributions

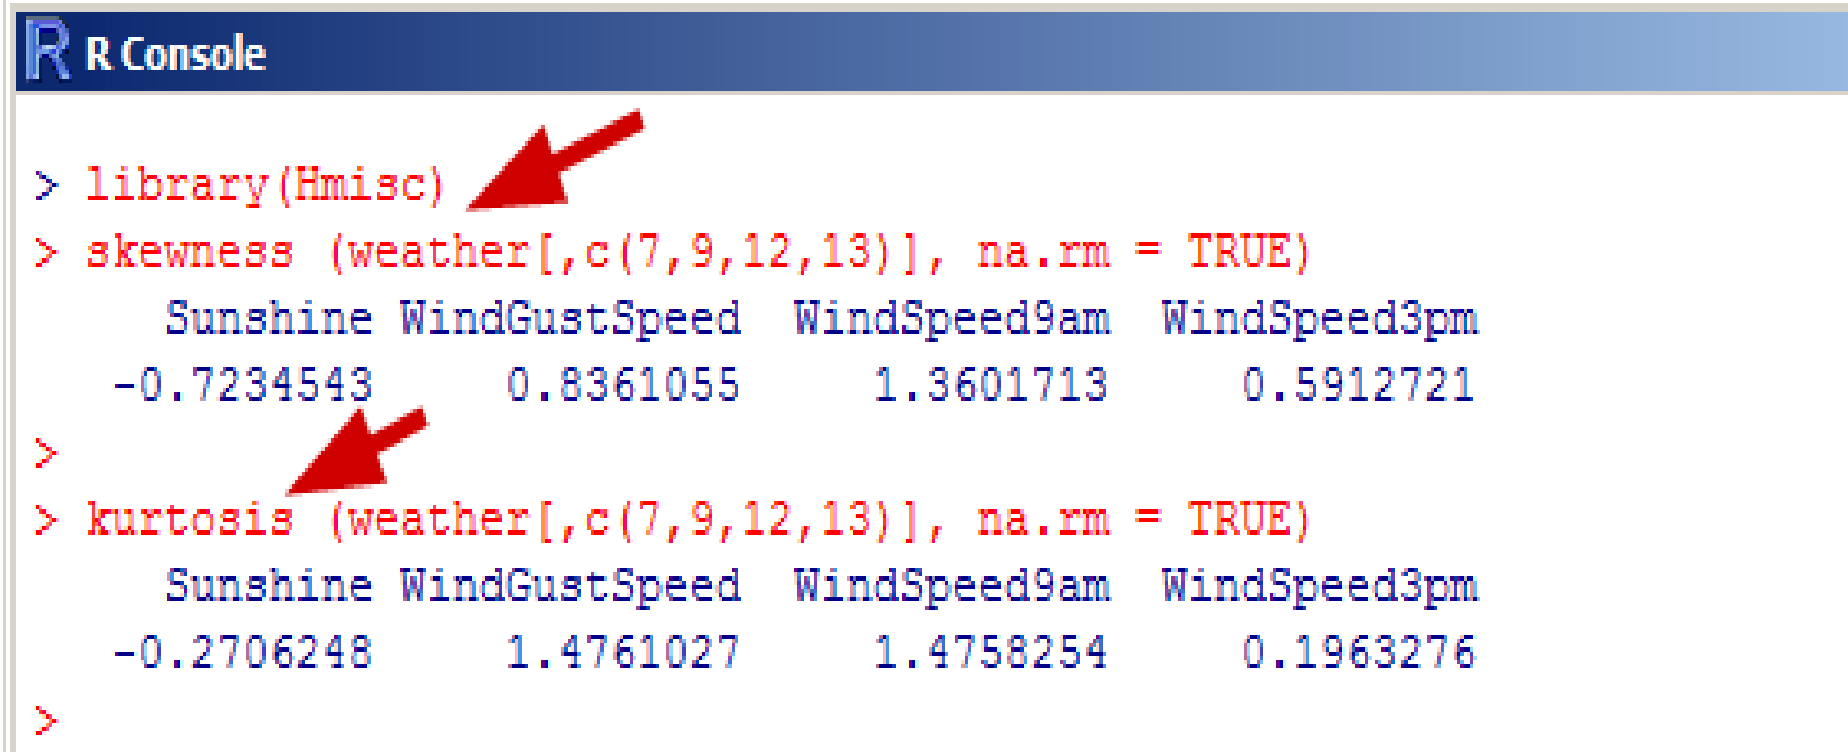


# Rattle Training 4. Exploring Data 4.2 Visualizing Distributions

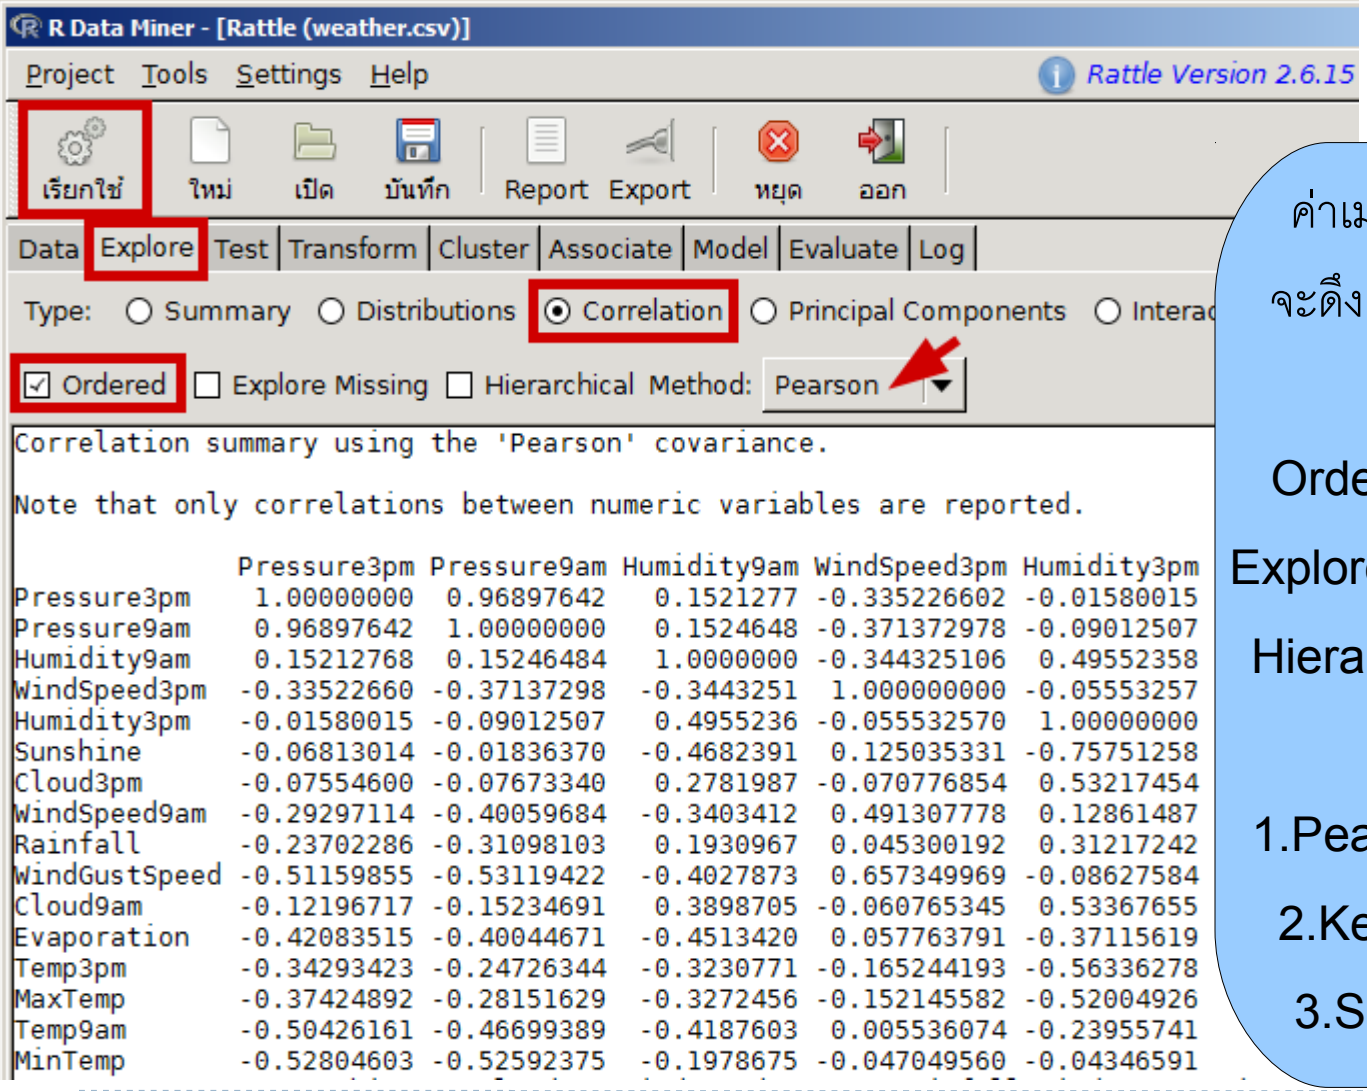


# Rattle Training 4. Exploring Data

- Workshop 1: ให้สร้าง Histogram แยกค่า Skewness กับ Kurtosis ตามชื่อตัวแปรข้างล่างนี้



# Rattle Training 4. Exploring Data 4.3 Correlation Analysis




| | Pressure3pm | Pressure9am | Humidity9am | WindSpeed3pm | Humidity3pm |
|---|---|---|---|---|---|
| Pressure3pm | 1.00000000 | 0.96897642 | 0.1521277 | -0.335226602 | -0.01580015 |
| Pressure9am | 0.96897642 | 1.00000000 | 0.1524648 | -0.371372978 | -0.09012507 |
| Humidity9am | 0.15212768 | 0.15246484 | 1.0000000 | -0.344325106 | 0.49552358 |
| WindSpeed3pm | -0.33522660 | -0.37137298 | -0.3443251 | 1.000000000 | -0.05553257 |
| Humidity3pm | -0.01580015 | -0.09012507 | 0.4955236 | -0.055532570 | 1.00000000 |
| Sunshine | -0.06813014 | -0.01836370 | -0.4682391 | 0.125035331 | -0.75751258 |
| Cloud3pm | -0.07554600 | -0.07673340 | 0.2781987 | -0.070776854 | 0.53217454 |
| WindSpeed9am | -0.29297114 | -0.40059684 | -0.3403412 | 0.491307778 | 0.12861487 |
| Rainfall | -0.23702286 | -0.31098103 | 0.1930967 | 0.045300192 | 0.31217242 |
| WindGustSpeed | -0.51159855 | -0.53119422 | -0.4027873 | 0.657349969 | -0.08627584 |
| Cloud9am | -0.12196717 | -0.15234691 | 0.3898705 | -0.060765345 | 0.53367655 |
| Evaporation | -0.42083515 | -0.40044671 | -0.4513420 | 0.057763791 | -0.37115619 |
| Temp3pm | -0.34293423 | -0.24726344 | -0.3230771 | -0.165244193 | -0.56336278 |
| MaxTemp | -0.37424892 | -0.28151629 | -0.3272456 | -0.152145582 | -0.52004926 |
| Temp9am | -0.50426161 | -0.46699389 | -0.4187603 | 0.005536074 | -0.23955741 |
| MinTemp | -0.52804603 | -0.52592375 | -0.1978675 | -0.047049560 | -0.04346591 |

ค่าเมตริกสหสัมพันธ์ใน Rattle จะดึงเฉพาะ numeric variable มี option ต่างๆ ดังนี้

Ordered : ให้เรียงตามค่า corr.

Explore Missing: เฉพาะ missing

Hierarchical Method: ดูคู่ลำดับ

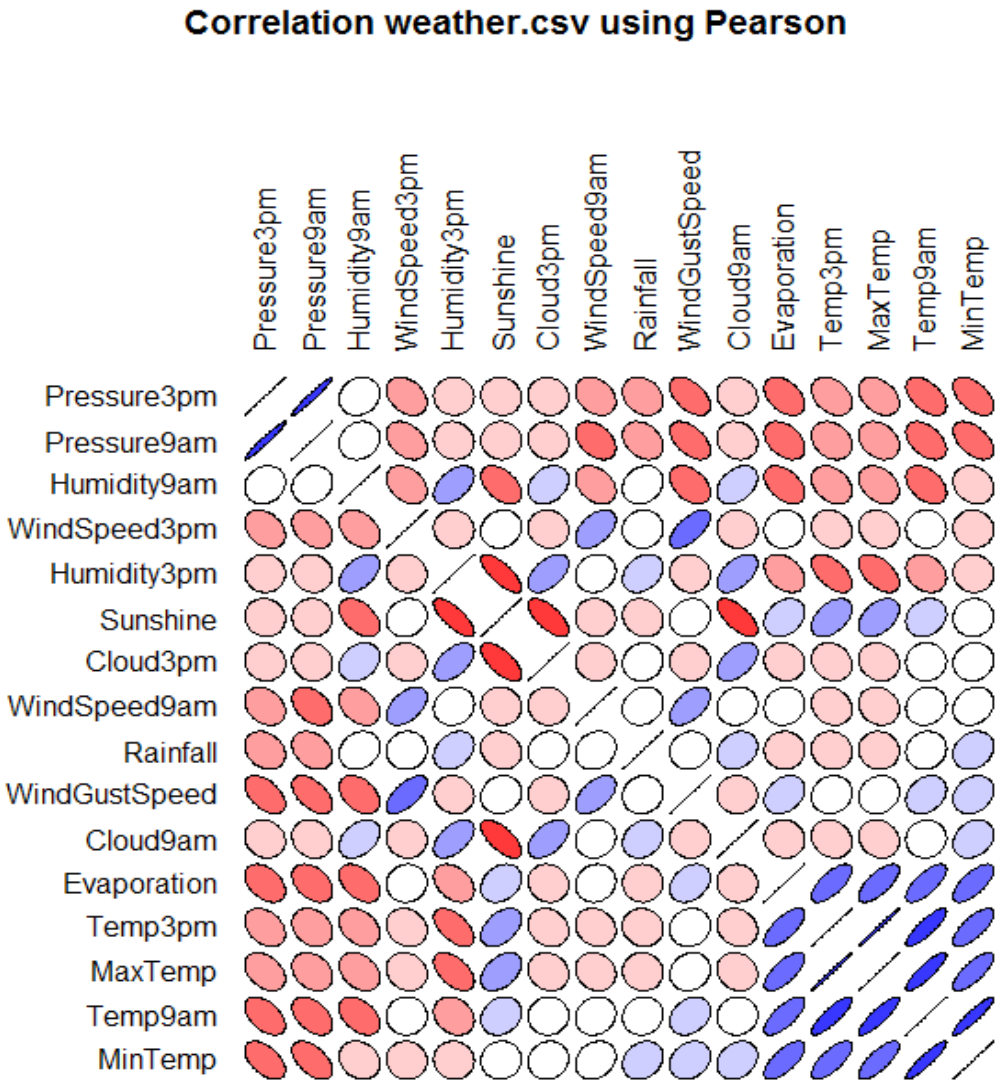
Method มี 3 วิธี

1.Pearson : ตัวเลข parametric

2.Kendall : ตัวเลข non-para

3.Spearman :ตัวเลข order

# Rattle Training 4. Exploring Data 4.3 Correlation Analysis




ยิ่งมีรูปร่างรี ยิ่งสัมพันธ์กัน

ยิ่งแดงเข้ม ยิ่งสัมพันธ์ทาง(-)
ยิ่งน้ำเงินเข้ม ยิ่งสัมพันธ์ทาง(+)

Analytic software today
Must shown Corr. Like this.

# Rattle Training 4. Exploring Data 4.3 Correlation Analysis

R Data Miner - [Rattle (weather.csv)]

Project Tools Settings Help — Rattle Version 2.6.15

เรียกใช้ ใหม่ เปิด บันทึก Report Export หยุด ออก

Data | Explore | Test | Transform | Cluster | Associate | Model | Evaluate | Log

Type: ○ Summary ○ Distributions ◉ Correlation ○ Principal Components ○ Interactive

☐ Ordered ☑ Explore Missing ☐ Hierarchical Method: Pearson

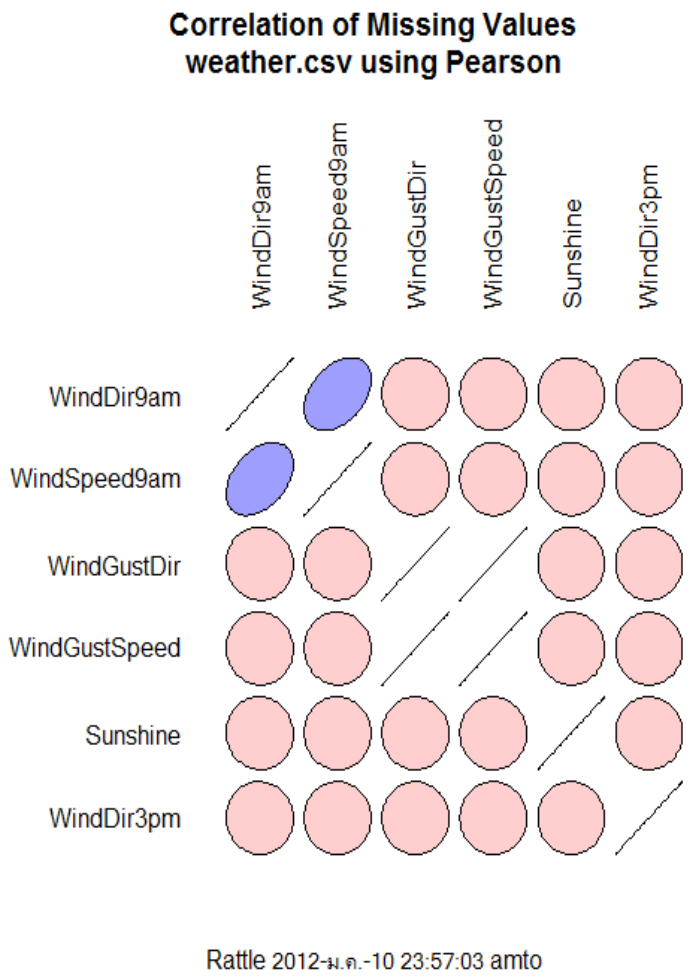
```
Missing values correlation summary using the 'Pearson' covariance.

Note that only correlations between numeric variables are reported.

               WindDir9am WindSpeed9am  WindGustDir WindGustSpeed     Sunshine
WindDir9am      1.00000000  0.400999442 -0.027879443  -0.027879443 -0.027879443
WindSpeed9am    0.40099944  1.000000000 -0.011179641  -0.011179641 -0.011179641
WindGustDir    -0.02787944 -0.011179641  1.000000000   1.000000000 -0.007874016
WindGustSpeed  -0.02787944 -0.011179641  1.000000000   1.000000000 -0.007874016
Sunshine       -0.02787944 -0.011179641 -0.007874016  -0.007874016  1.000000000
WindDir3pm     -0.01967505 -0.007889684 -0.005556842  -0.005556842 -0.005556842
                WindDir3pm
WindDir9am     -0.019675051
WindSpeed9am   -0.007889684
WindGustDir    -0.005556842
WindGustSpeed  -0.005556842
Sunshine       -0.005556842
WindDir3pm      1.000000000

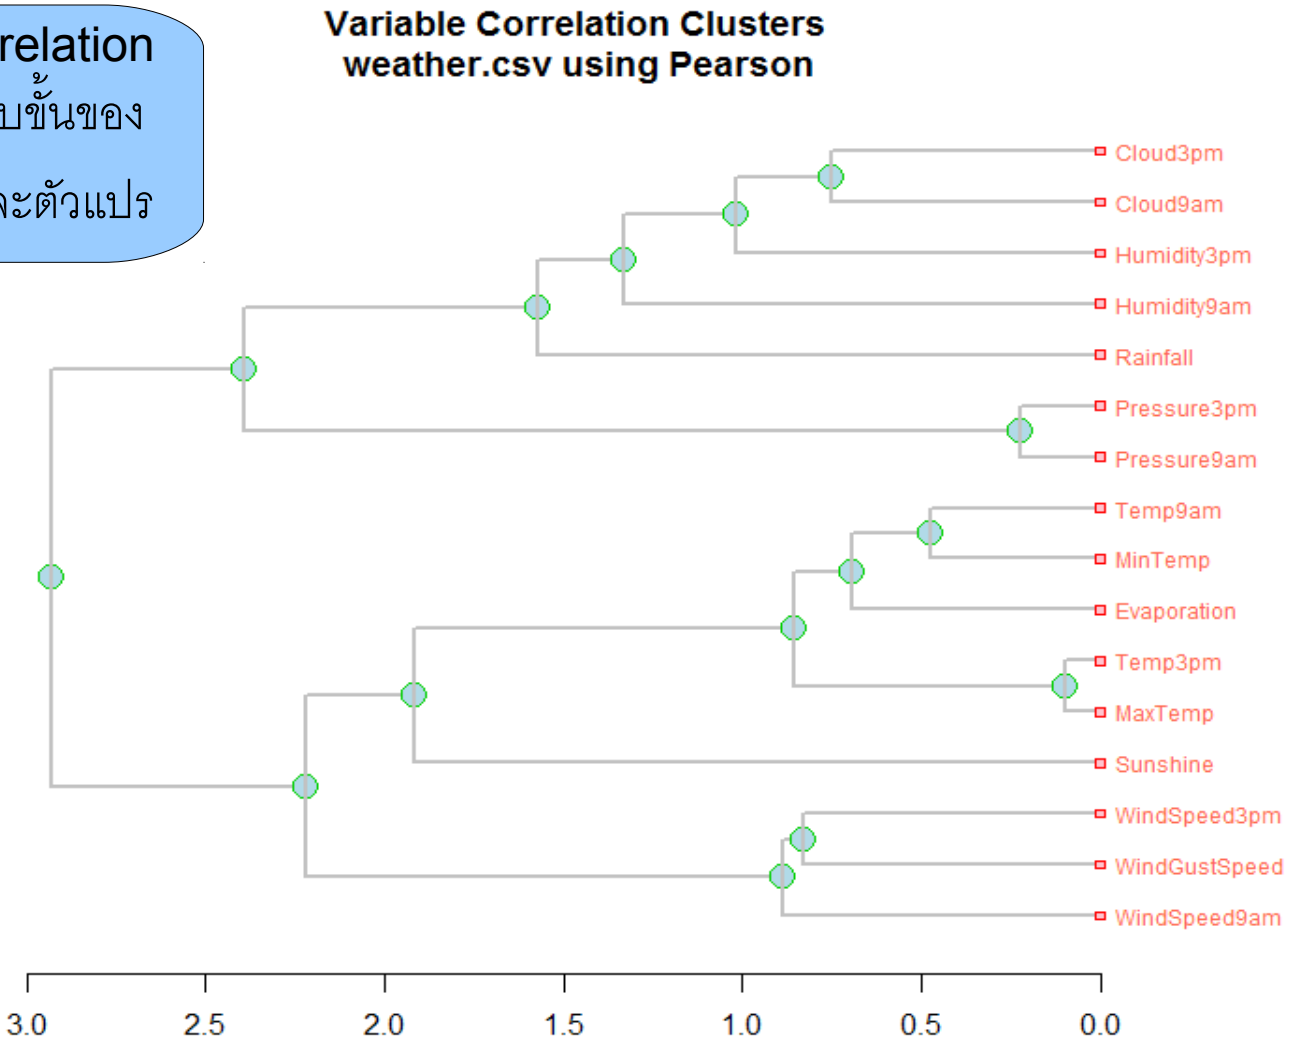
Count of missing values:
   WindDir9am  WindSpeed9am   WindGustDir WindGustSpeed      Sunshine
           23             4             2             2             2
   WindDir3pm
            1
```

Explore Missing:
จะเลือกเฉพาะตัวแปรที่มีค่า Missing มาหาค่าสหสัมพันธ์

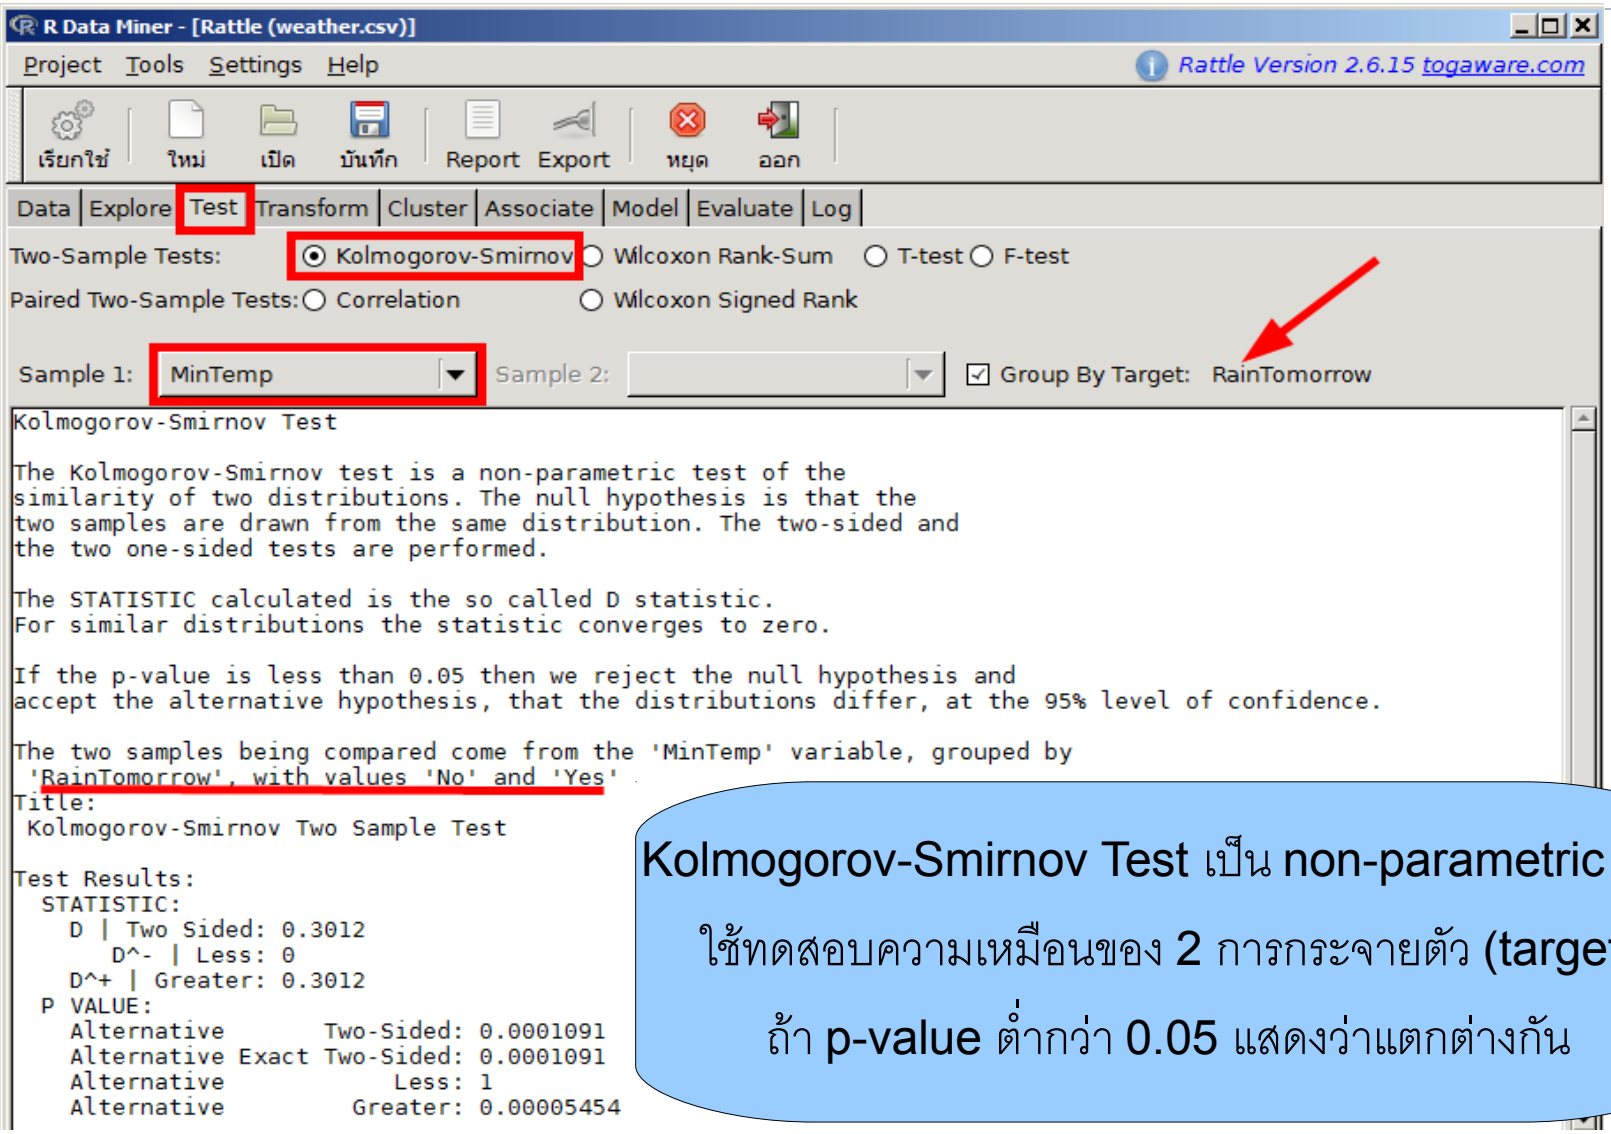


# Rattle Training 4. Exploring Data 4.3 Correlation Analysis

Hierarchical Correlation
จะแสดงให้เห็นลำดับขั้นของ
ความสัมพันธ์ในแต่ละตัวแปร



# Rattle Training 5.Testing Data

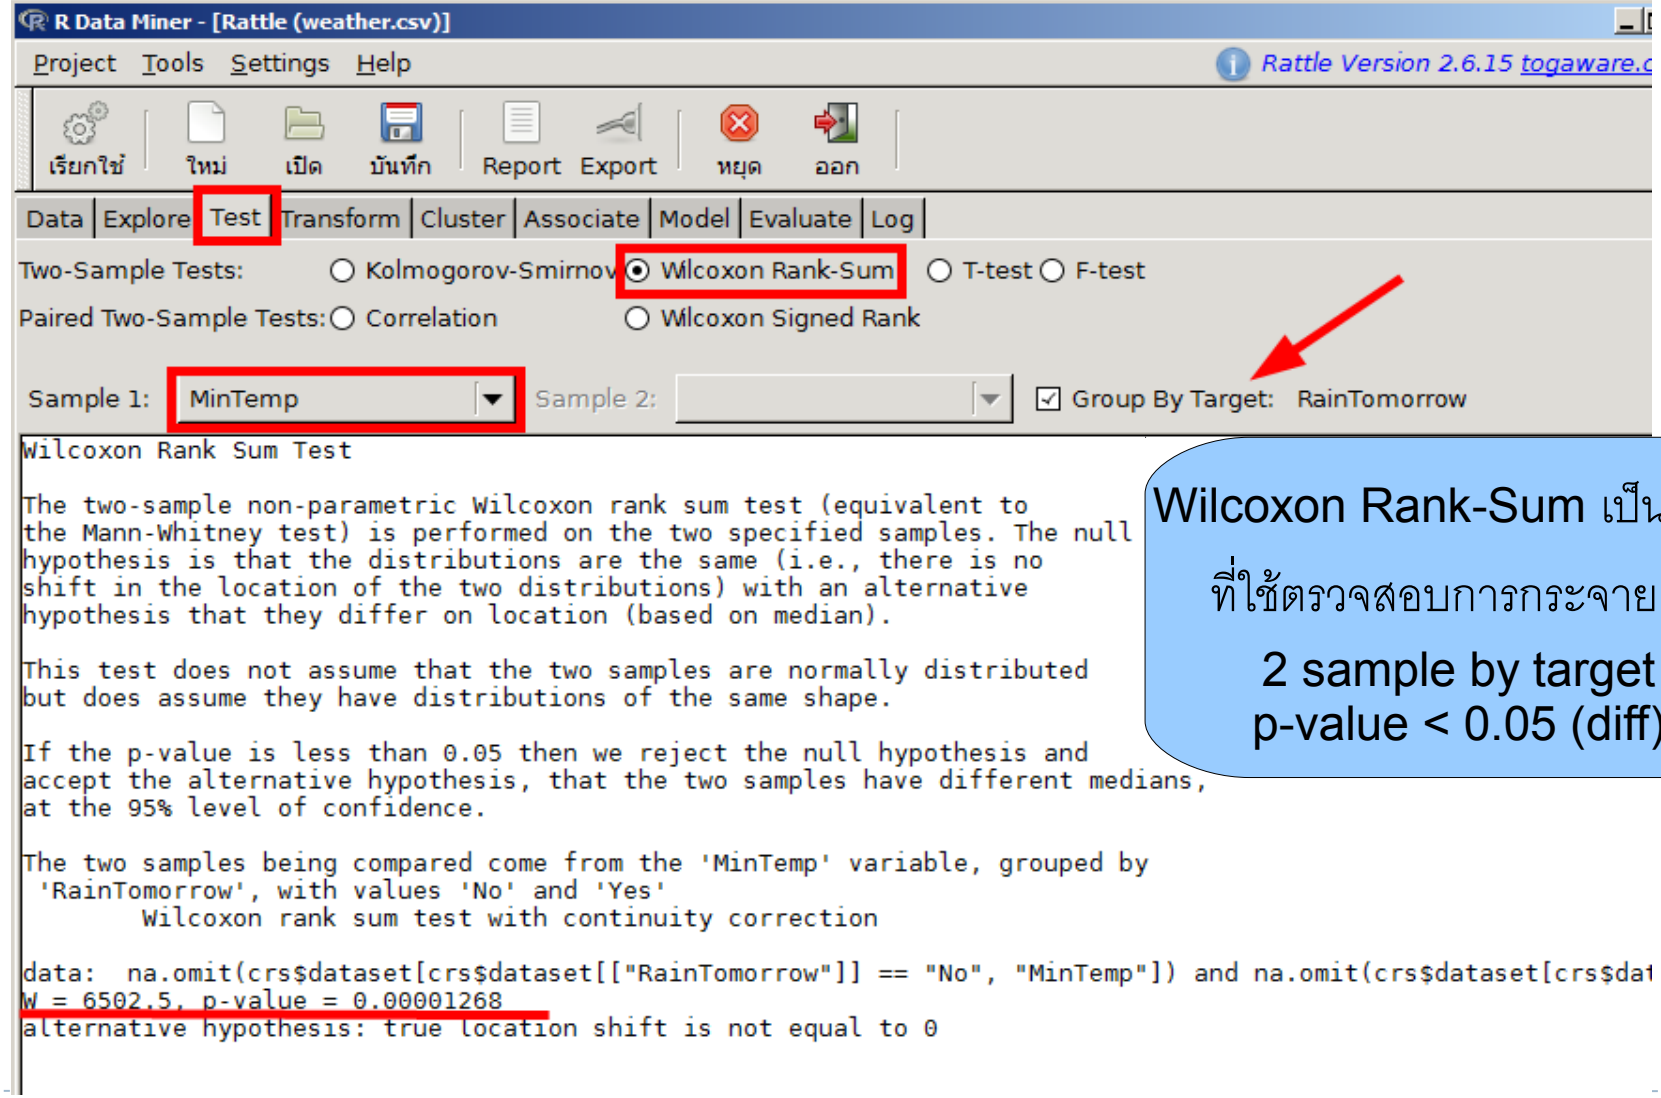



Kolmogorov-Smirnov Test เป็น non-parametric test

ใช้ทดสอบความเหมือนของ 2 การกระจายตัว (target)

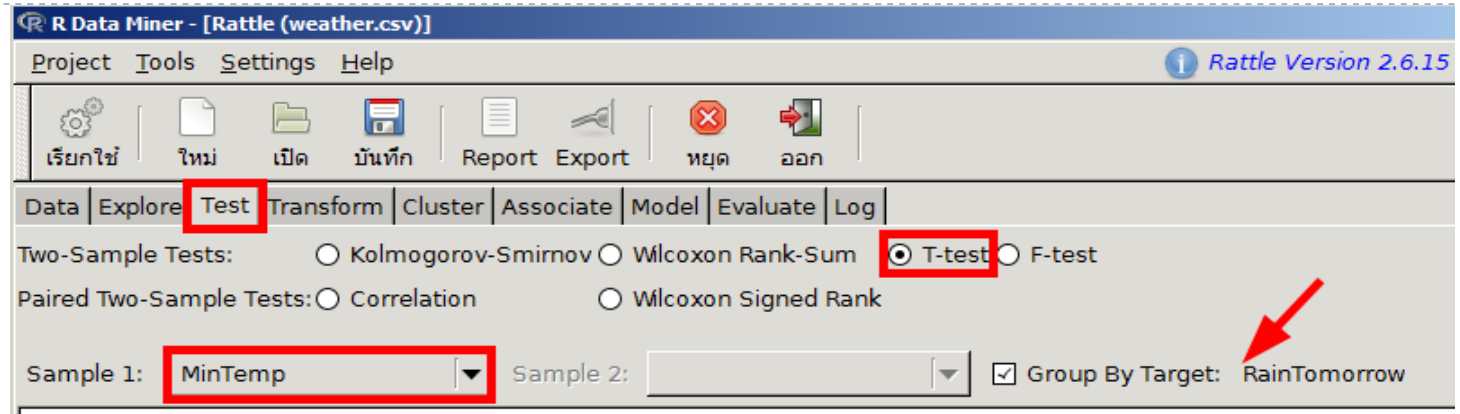
ถ้า p-value ต่ำกว่า 0.05 แสดงว่าแตกต่างกัน

# Rattle Training 5.Testing Data




Wilcoxon Rank-Sum เป็นอีกวิธี
ที่ใช้ตรวจสอบการกระจายตัว
2 sample by target
p-value < 0.05 (diff)

# Rattle Training 5.Testing Data



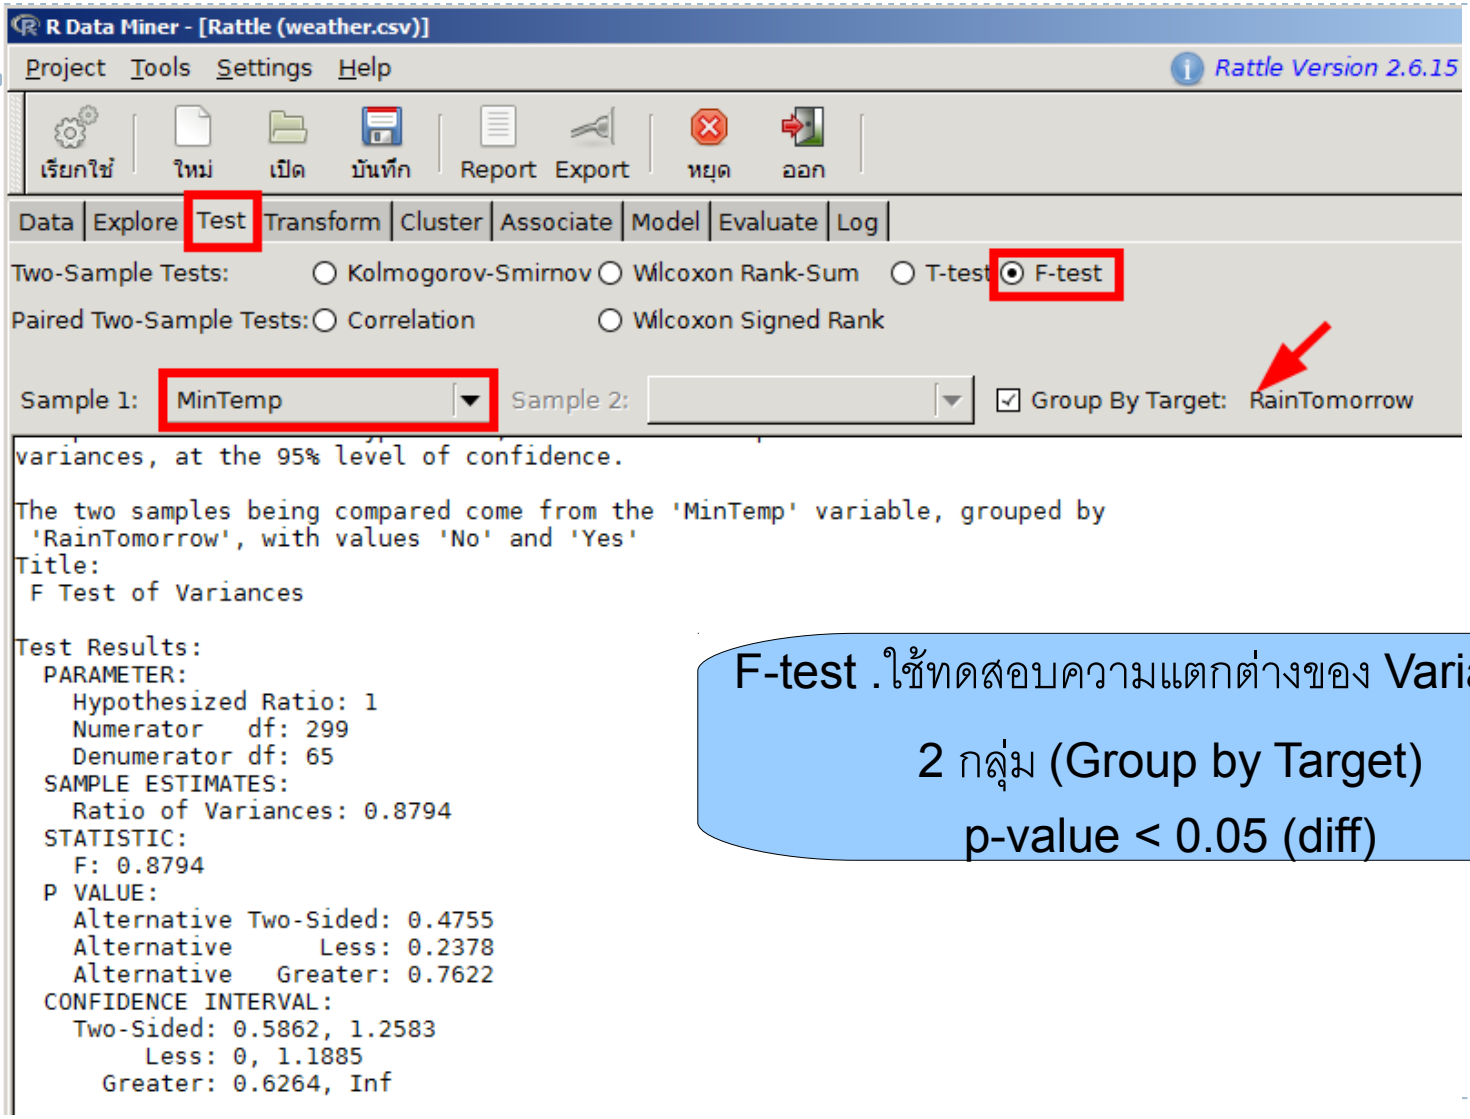

```
Test Results:
  PARAMETER:
    x Observations: 300
    y Observations: 66
    mu: 0
  SAMPLE ESTIMATES:
    Mean of x: 6.6073
    Mean of y: 10.2576
    Var  of x: 33.6066
    Var  of y: 38.216
  STATISTIC:
                T: -4.391
    T | Equal Var: -4.5756
  P VALUE:
    Alternative Two-Sided: 0.00003015
    Alternative      Less: 0.00001507
    Alternative   Greater: 1
    Alternative Two-Sided | Equal Var: 0.000006523
    Alternative      Less | Equal Var: 0.000003262
    Alternative   Greater | Equal Var: 1
  CONFIDENCE INTERVAL:
    Two-Sided: -5.3013, -1.9992
         Less: -Inf, -2.2689
      Greater: -5.0315, Inf
    Two-Sided | Equal Var: -5.219, -2.0814
         Less | Equal Var: -Inf, -2.3347
      Greater | Equal Var: -4.9658, Inf
```

T-test .ใช้ทดสอบความแตกต่างของค่า Mean.

2 กลุ่ม (Group by Target)

p-value < 0.05 (diff)

# Rattle Training 5.Testing Data

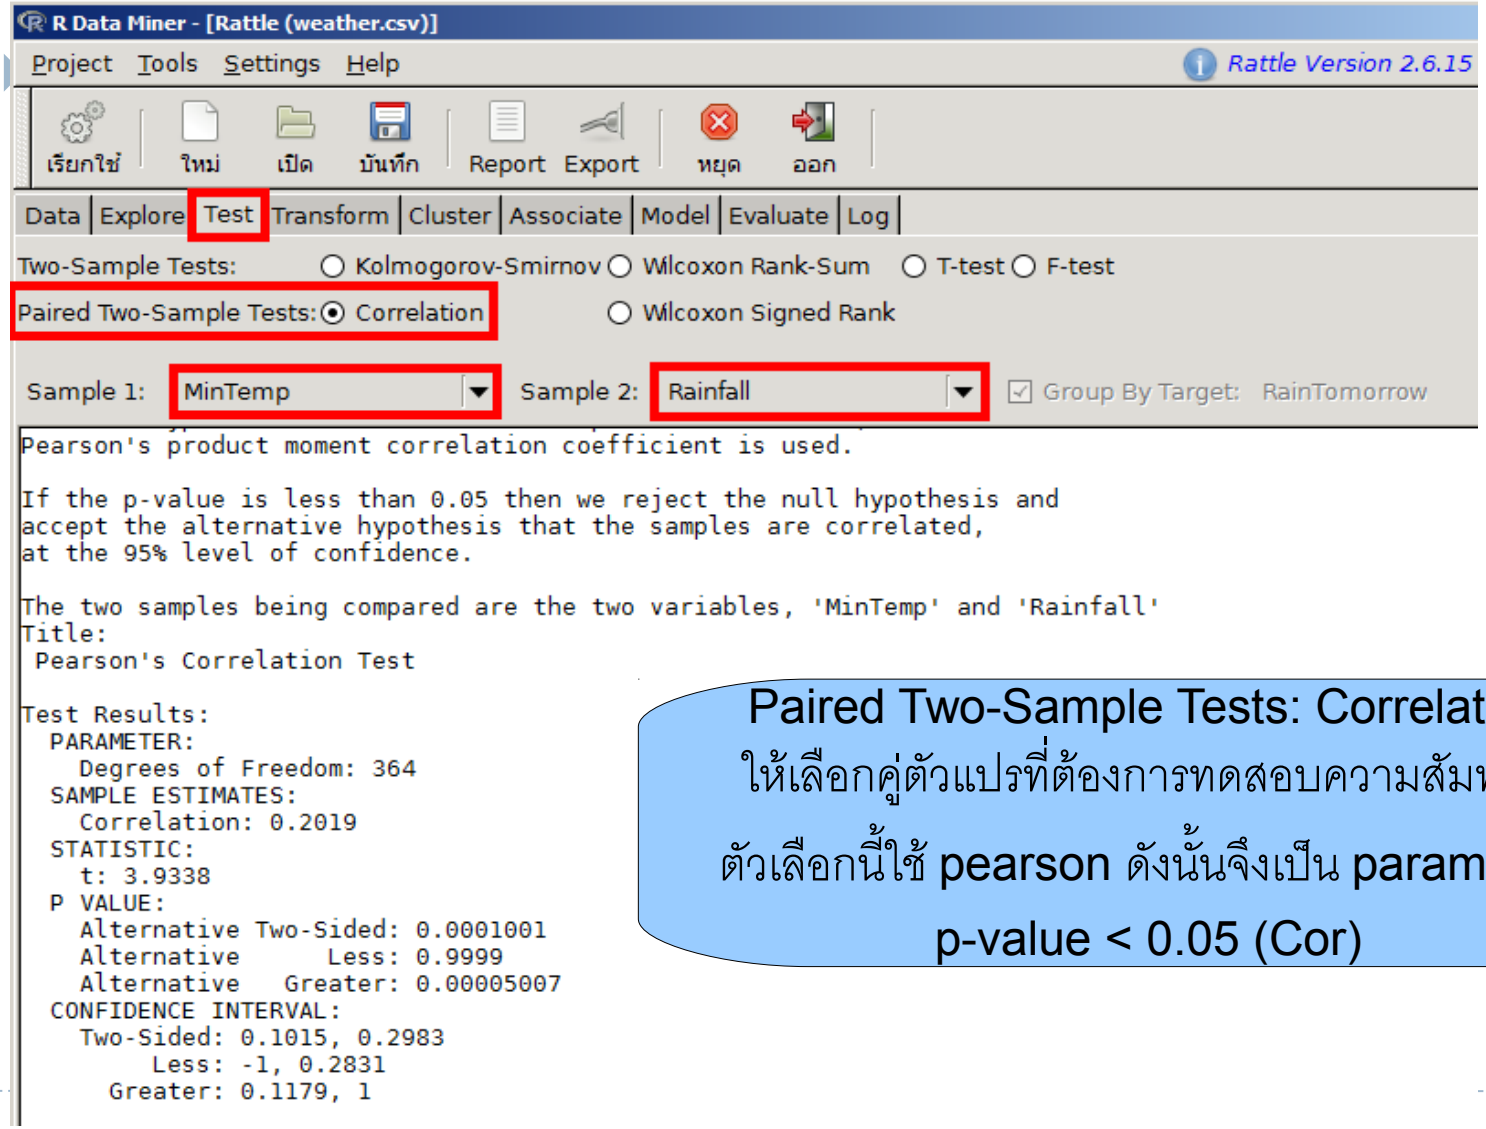



F-test .ใช้ทดสอบความแตกต่างของ Variances.

2 กลุ่ม (Group by Target)

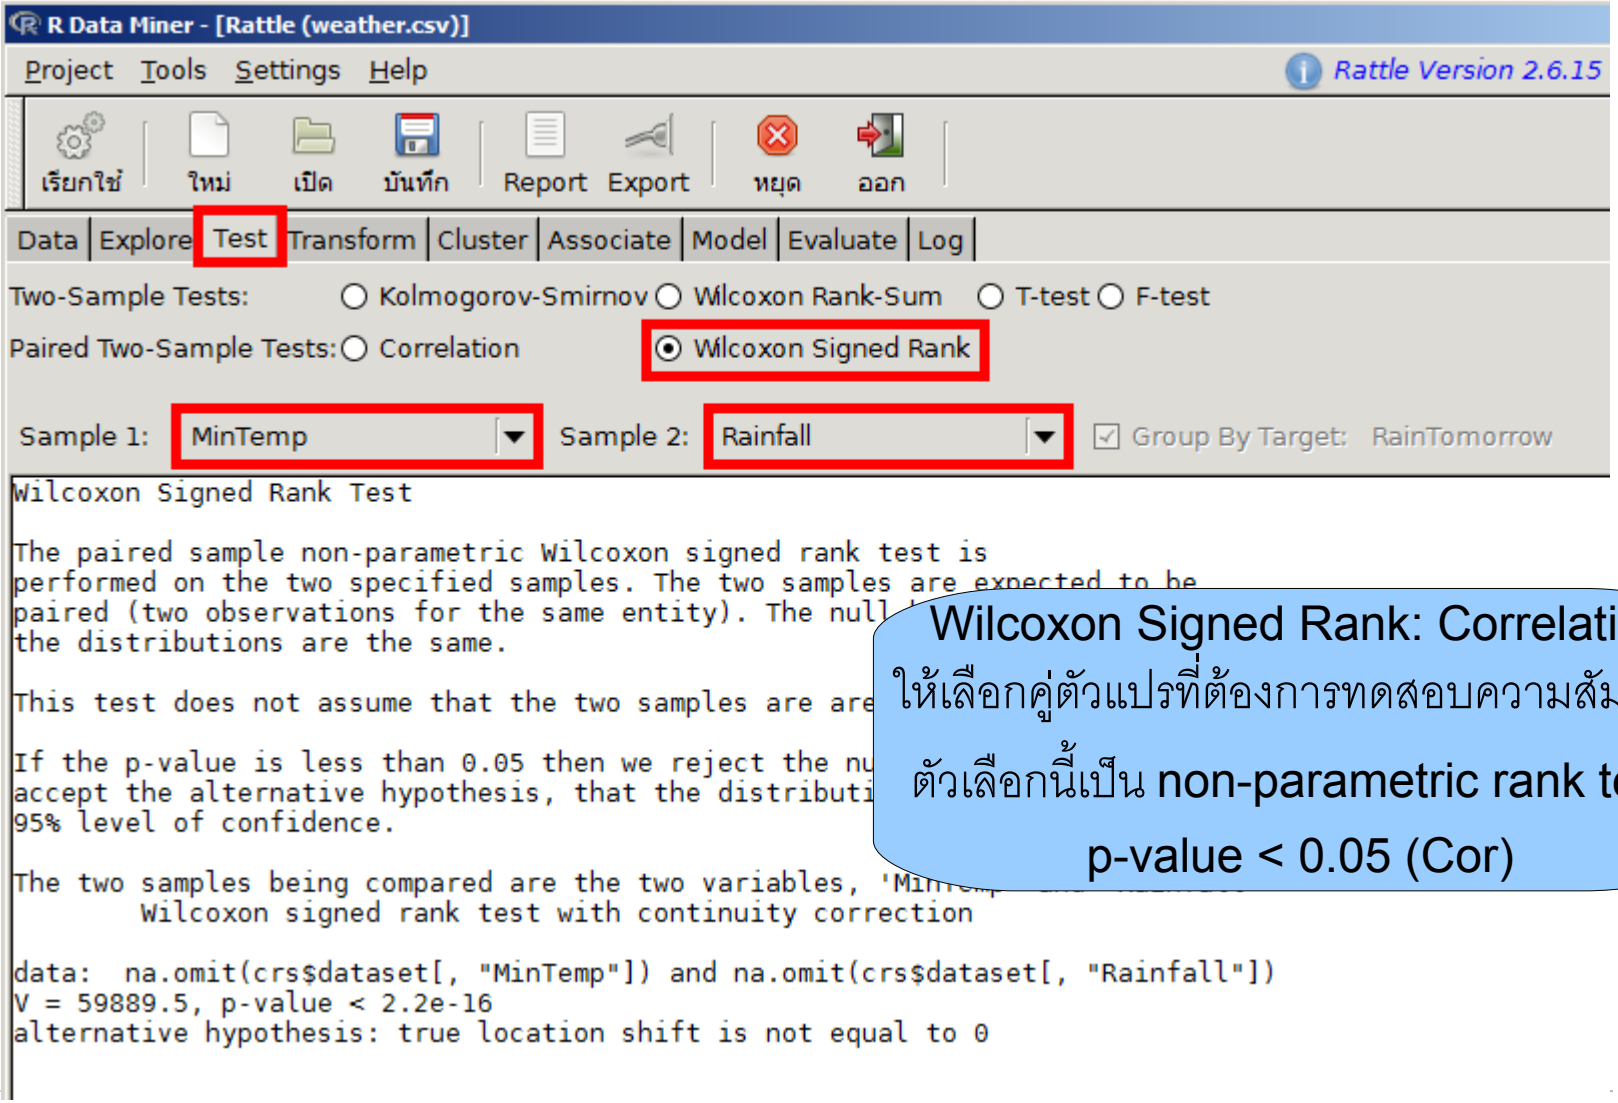
p-value < 0.05 (diff)

# Rattle Training 5.Testing Data




Paired Two-Sample Tests: Correlation
ให้เลือกคู่ตัวแปรที่ต้องการทดสอบความสัมพันธ์
ตัวเลือกนี้ใช้ pearson ดังนั้นจึงเป็น parametric
p-value < 0.05 (Cor)

# Rattle Training 5.Testing Data




Wilcoxon Signed Rank: Correlation

ให้เลือกคู่ตัวแปรที่ต้องการทดสอบความสัมพันธ์

ตัวเลือกนี้เป็น non-parametric rank test.

p-value < 0.05 (Cor)

# Data Preprocessing (6.Transforms data)

- Data preprocessing
- Data cleaning
- Data integration
- Data transformation
- Data reduction

# Why Data Preprocessing?

- Data in the real world is dirty
  - Incomplete: lacking attribute values, lacking certain attributes of interest, or containing only aggregate data
    - e.g., occupation = " "
  - Noisy: containing errors or outliers
    - e.g., salary = "-10 "
  - Inconsistent: containing discrepancies in codes or names
    - e.g., Age = "42" Birthday = "03/07/1997"
    - e.g., Was rating "1,2,3" , now rating "A, B , C"
    - e.g., discrepancy between duplicate records

# Why Is Data Dirty?

- Incomplete data may come from
  - "Not applicable" data value when collected
  - Different considerations between the time when the data was collected and when it is analyzed.
  - Human/ hardware/ software problems.
- Noisy data (incorrect values) may come from
  - Faulty data collection instruments
  - Human or computer error at data entry
  - Errors in data transmission
- Inconsistent data may come from
  - Different data sources
  - Functional dependency violation (e.g., modify some linked data)
- Duplicate records also need data cleaning

# Why Is Data Preprocessing Important?

- No quality data , no quality mining results!
  - Quality decisions must be based on quality data
    - e.g., duplicate or missing data may cause incorrect or even misleading statistics.
    - Data warehouse needs consistent integration of quality data
  - Data extraction, cleaning, and transformation comprises the majority of the work of building a data warehouse

# Major tasks in data preprocessing.

- Data cleaning
  - Fill in missing values, smooth noisy data, identify or remove outliers, and resolve inconsistencies
- Data integration
  - Integration of multiple databases, data cubes, of files
- Data transformation
  - Normalization and aggregation
- Data reduction
  - Obtains reduced representation in volume but produces the same or similar analytical results

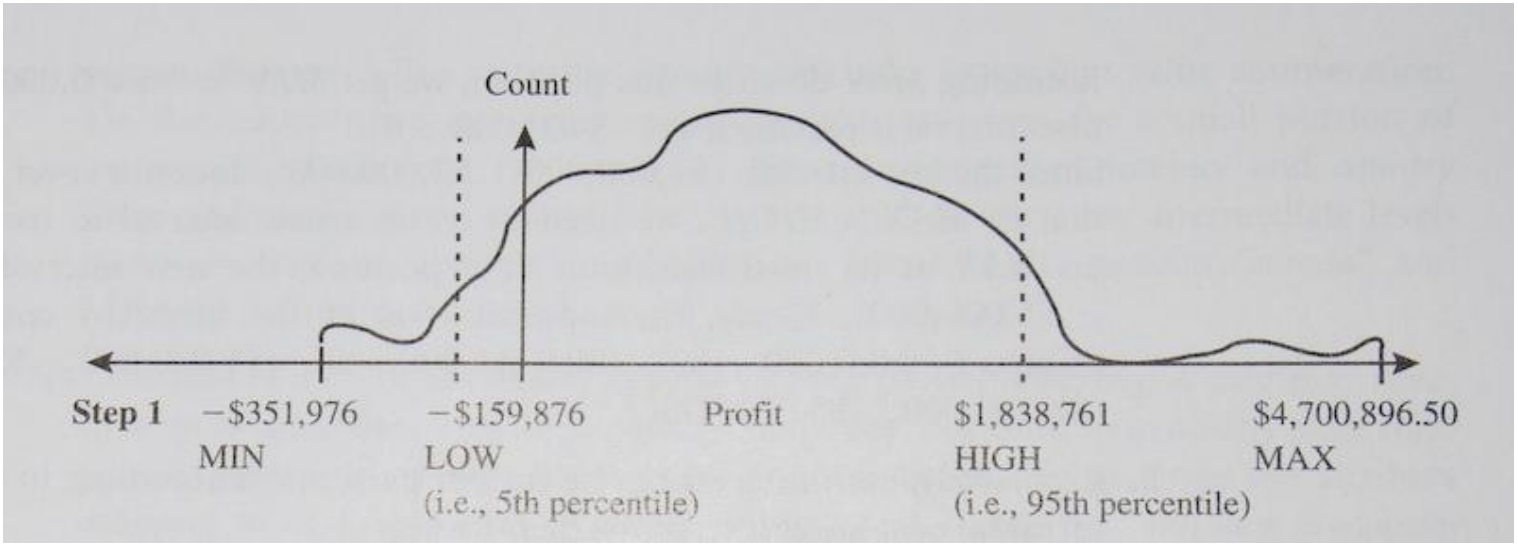
ผลที่ได้จาก **Postprocessing** กับ **PreProcessing** จะแตกต่างกันอย่างสิ้นเชิง

# เทคนิค การแปลงลักษณะประจำที่เป็นตัวเลข

- การแปลงค่าที่อยู่ในลักษณะประจำ ให้อยู่ในสเกลมาตรฐาน
  - ใช้วิธี max-min normalization
  - ใช้วิธี z-score normalization
  - ใช้วิธี decimal scaling
- การปรับค่า ไม่ให้เป็นค่าลบหรือศูนย์ เพื่อสามารถนำไปเป็นตัวหารได้
  - ใช้วิธีบวก 1 กับตัวแปร binary
  - ใช้วิธีบวก 1-min {A} กับตัวแปรที่มีค่าลบ แต่ต้องการให้มีค่าเป็นบวก
- การคูณด้วยค่าถ่วงน้ำหนักที่เหมาะสม ใช้เมื่อต้องการให้ลักษณะประจำใหม่มีความสำคัญกว่าลักษณะประจำอื่น

# เทคนิค การแปลงจำนวนให้เป็นค่าไม่ต่อเนื่อง

- การใช้กล่องชุดข้อมูล (Binning)
- การใช้ Histogram (เป็นกรรมวิธีทางสถิติ)
- การใช้ผลการจัดกลุ่มจากการวิเคราะห์ clustering
- การใช้ Entropy-based discretization (ใช้หลักการทาง Physic)
- การใช้ผลแบ่งกั้นที่ง่ายต่อความเข้าใจ (Natural partitioning)



# ข้อมูลที่ผ่าน Data cleaning คือ

- ประกอบด้วยสดมภ์และแถว
  - สดมภ์ คือ ลักษณะประจำ = ตัวแปรในทางสถิติ ซึ่งมีทั้งตัวแปรเชิงกลุ่ม และตัวแปรที่เป็นตัวเลข
  - แถว คือ **records** ที่เก็บข้อมูลที่กำหนดค่าในแต่ละลักษณะประจำ
- ไม่มี **missing value** หรือข้อมูลที่ผิดปกติ **(Outlier)**
- ในการทำ **data mining** ชนิดของลักษณะประจำและระเบียนต้องถูกปรับเปลี่ยนเพื่อความเหมาะสมสำหรับแต่ละเทคนิคการทำ **data mining**

  (ดูรายละเอียดในหัวข้อ **associate rule, classification & clustering.**)

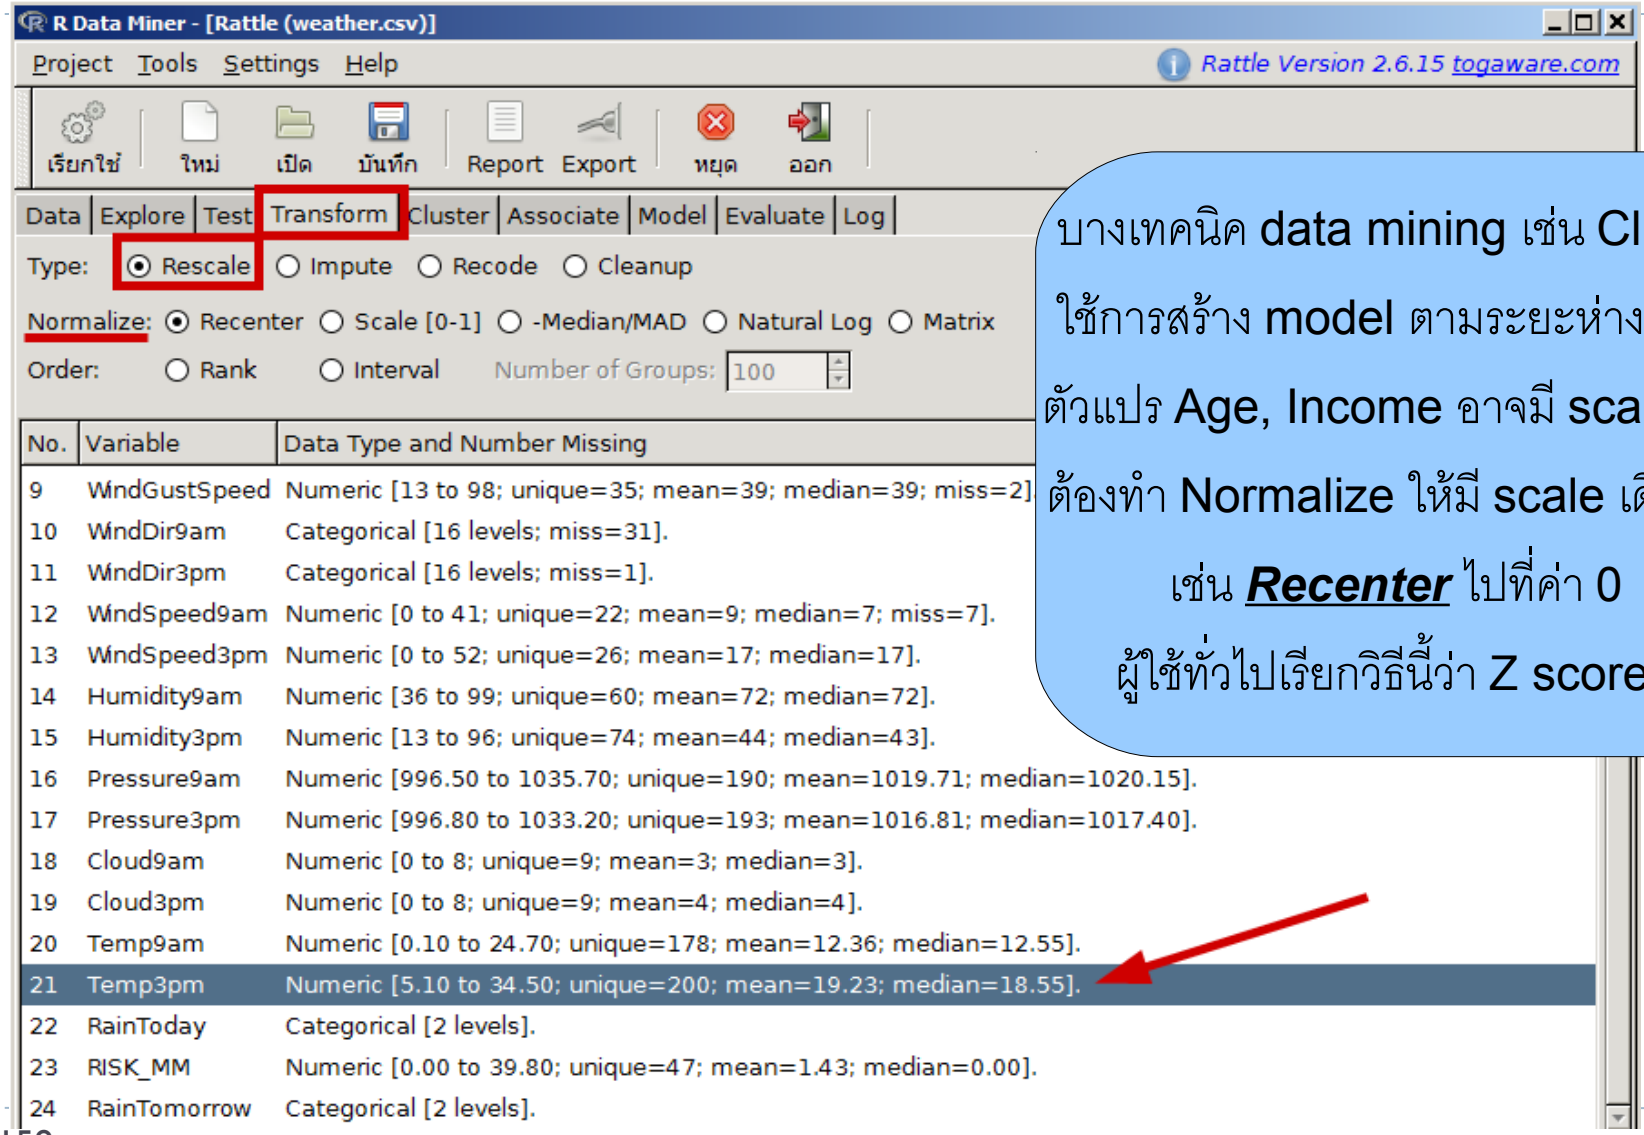
# ชนิดของลักษณะประจำ หรือตัวแปร (variables)

- ตัวแปรเชิงกลุ่ม **(nominal)** คือ ตัวแปรที่ไม่มีลำดับ ไม่มีค่าต่อเนื่องในแต่ละระเบียน เช่น เพศ เชื้อชาติ อาชีพ ฯลฯ
- ตัวแปรลำดับ **(ordinal)** คือ ตัวแปรที่มีลำดับที่มีค่าไม่ต่อเนื่อง แต่เป็นลักษณะประจำที่บ่งบอกถึงลำดับ เช่น กลุ่มอายุ {เด็ก,ผู้ใหญ่,คนชรา} การศึกษา {ประถม,มัธยม,ป.ตรี}
- ตัวแปรตัวเลข **Numerical (Continuous/Interval)** เป็นลักษณะประจำที่มีค่าต่อเนื่อง เช่น อายุ น้ำหนัก ส่วนสูง ระดับน้ำตาลในเลือด ราคา ฯลฯ

# Data mining vs. variables

- กรรมวิธีทาง **data mining** โจทย์ปัญหา วัตถุประสงค์และความรู้ที่ต้องการ ที่หลากหลาย ทำให้เราจำเป็นต้องใช้รูปแบบของข้อมูลที่แตกต่างกัน
- ผลลัพธ์ที่ได้จากการทำเหมืองข้อมูลแบบทำนาย **(Predicted)** แบ่งได้เป็น
  - กฎเชื่อมโยง **(Association rule)**
  - การจัดจำแนกประเภท **(Classifier)**
  - การวิเคราะห์การเกาะกลุ่ม **(Cluster)**
- ลักษณะของข้อมูลที่ต้องการจะมีความแตกต่างไปตามขั้นตอนวิธีและผลลัพธ์

# Rattle Training 6.Transforming Data




บางเทคนิค data mining เช่น Cluster ใช้การสร้าง model ตามระยะห่างข้อมูล ตัวแปร Age, Income อาจมี scale ห่าง ต้องทำ Normalize ให้มี scale เดียวกัน เช่น ***Recenter*** ไปที่ค่า 0 ผู้ใช้ทั่วไปเรียกวิธีนี้ว่า Z score.

# Rattle Training 6.Transforming Data

| | | |
|---|---|---|
| 19 | Cloud3pm | Numeric [0 to 8; unique=9; mean=4; median=4]. |
| 20 | Temp9am | Numeric [0.10 to 24.70; unique=178; mean=12.36; median=12.55]. |
| 21 | Temp3pm | Numeric [5.10 to 34.50; unique=200; mean=19.23; median=18.55; ignored]. |
| 22 | RainToday | Categorical [2 levels]. |
| 23 | RISK_MM | Numeric [0.00 to 39.80; unique=47; mean=1.43; median=0.00]. |
| 24 | RainTomorrow | Categorical [2 levels]. |
| 25 | RRC_Temp3pm | Numeric [-2.13 to 2.30; unique=200; mean=0.00; median=-0.10]. No code export. |

Data | Explore | Test | Transform | Cluster | Associate | Model | Evaluate | Log

Source: (•) Spreadsheet ( ) ARFF ( ) ODBC ( ) R Dataset ( ) RData File ( ) Library ( ) Corpus ( ) Script

Filename: weather.csv Separator: , Decimal: . [✓] Header

[✓] Partition 70/15/15 Seed: 42 View Edit

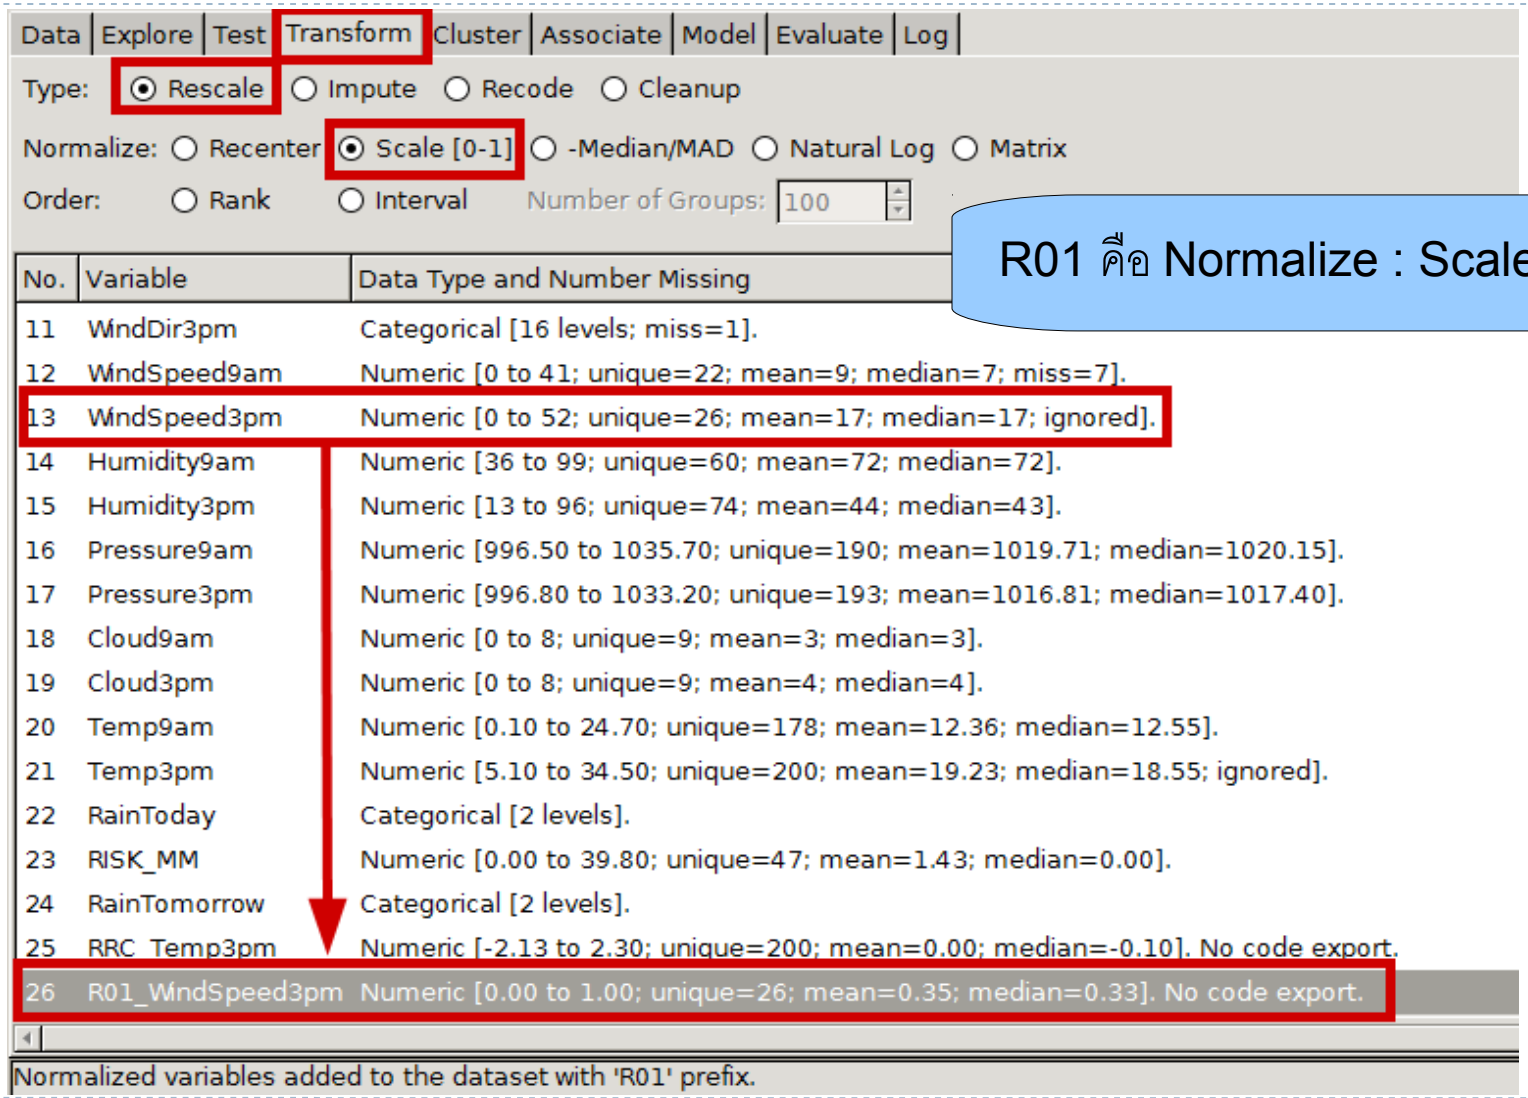
RRC คือ Recenter transformed

สามารถดูข้อมูลได้ที่ tab Data--> View

Rattle Dataset

| Rattle Dataset | Pressure | Cloud9am | Cloud3pm | Temp9am | Temp3pm | RainToday | RISK_MM | RainTomo | RRC_Temp3pm |
|---|---|---|---|---|---|---|---|---|---|
| 1 | 1015 | 7 | 7 | 14.4 | 23.6 | No | 3.6 | Yes | 0.657967 |
| 2 | 1008.4 | 5 | 3 | 17.5 | 25.7 | Yes | 3.6 | Yes | 0.974215 |
| 3 | 1007.2 | 8 | 7 | 15.4 | 20.2 | Yes | 39.8 | Yes | 0.145945 |
| 4 | 1007 | 2 | 7 | 13.5 | | Yes | 2.8 | Yes | |

# Rattle Training 6.Transforming Data




R01 คือ Normalize : Scale [0-1]

# Rattle Training 6.Transforming Data

Data | Explore | Test | Transform | Cluster | Associate | Model | Evaluate | Log

Type: (•) Rescale ( ) Impute ( ) Recode ( ) Cleanup

Normalize: ( ) Recenter ( ) Scale [0-1] (•) -Median/MAD ( ) Natural Log ( )

Order: ( ) Rank ( ) Interval Number of Groups: 100

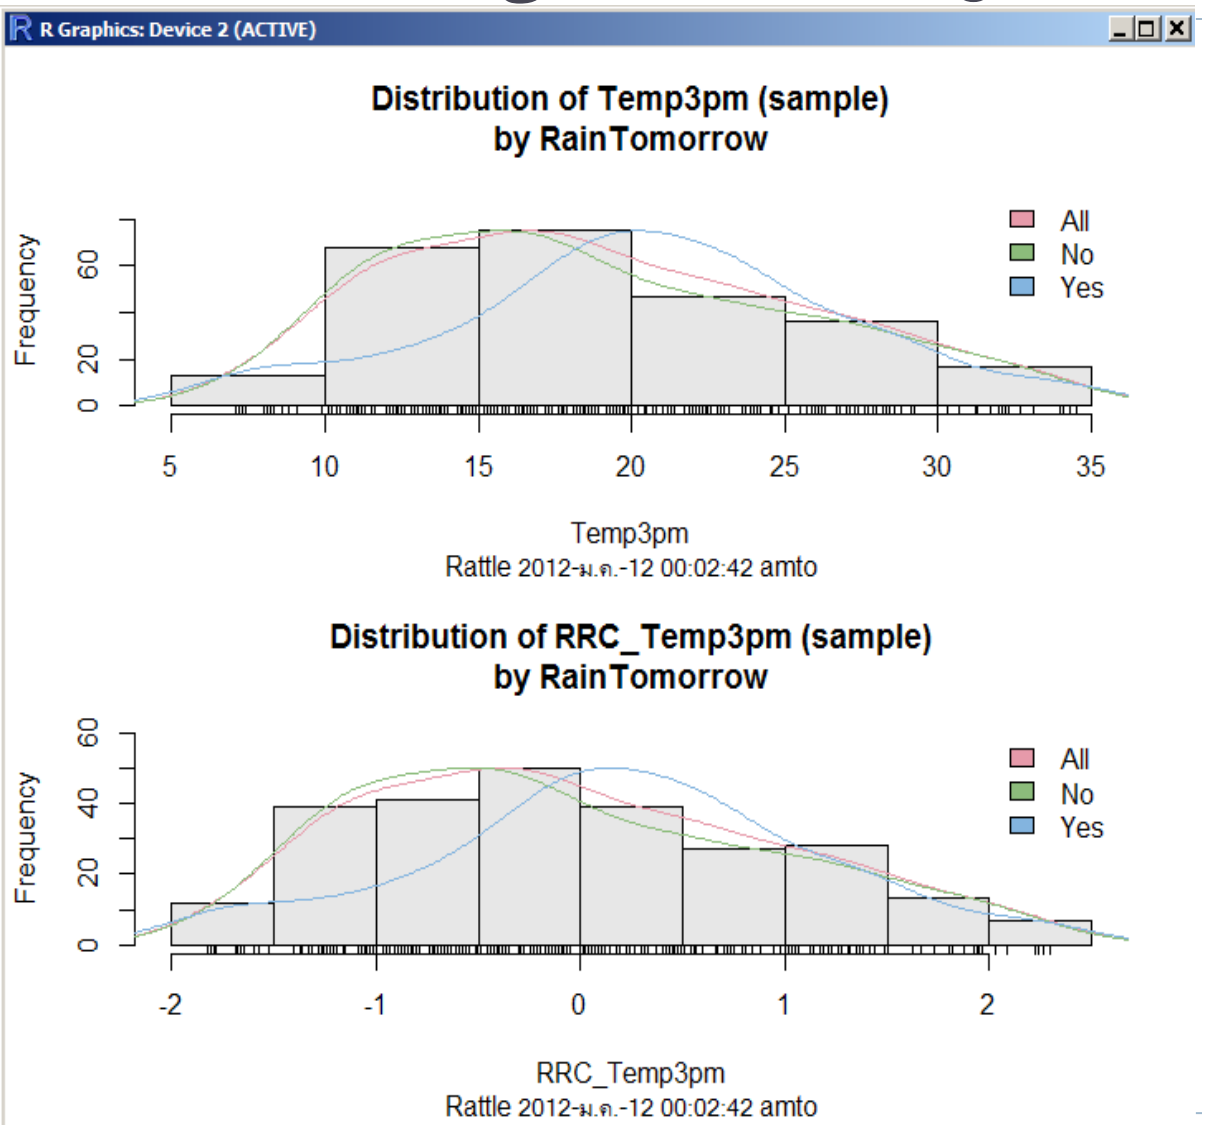
RMD คือ Normalize : Median/MAD

ข้อมูลในตัวแปรนั้นจะมีค่า Median = 0

| No. | Variable | Data Type and Number Missing |
|---|---|---|
| 12 | WindSpeed9am | Numeric [0 to 41; unique=22; mean=9; median=7; miss=7]. |
| 13 | WindSpeed3pm | Numeric [0 to 52; unique=26; mean=17; median=17; ignored]. |
| 14 | Humidity9am | Numeric [36 to 99; unique=60; mean=72; median=72]. |
| 15 | Humidity3pm | Numeric [13 to 96; unique=74; mean=44; median=43]. |
| 16 | Pressure9am | Numeric [996.50 to 1035.70; unique=190; mean=1019.71; median=1020.15]. |
| 17 | Pressure3pm | Numeric [996.80 to 1033.20; unique=193; mean=1016.81; median=1017.40]. |
| 18 | Cloud9am | Numeric [0 to 8; unique=9; mean=3; median=3]. |
| 19 | Cloud3pm | Numeric [0 to 8; unique=9; mean=4; median=4]. |
| 20 | Temp9am | Numeric [0.10 to 24.70; unique=178; mean=12.36; median=12.55]. |
| 21 | Temp3pm | Numeric [5.10 to 34.50; unique=200; mean=19.23; median=18.55; ignored]. |
| 22 | RainToday | Categorical [2 levels]. |
| 23 | RISK_MM | Numeric [0.00 to 39.80; unique=47; mean=1.43; median=0.00] |
| 24 | RainTomorrow | Categorical [2 levels]. |
| 25 | RRC_Temp3pm | Numeric [-2.13 to 2.30; unique=200; mean=0.00; median=-0.1[illegible]]. No code export. |
| 26 | R01_WindSpeed3pm | Numeric [0.00 to 1.00; unique=26; mean=0.35; median=0.33[illegible] No code export. |
| 27 | RMD_Temp3pm | Numeric [-1.87 to 2.22; unique=200; mean=0.09; median=0.00]. No code export. |

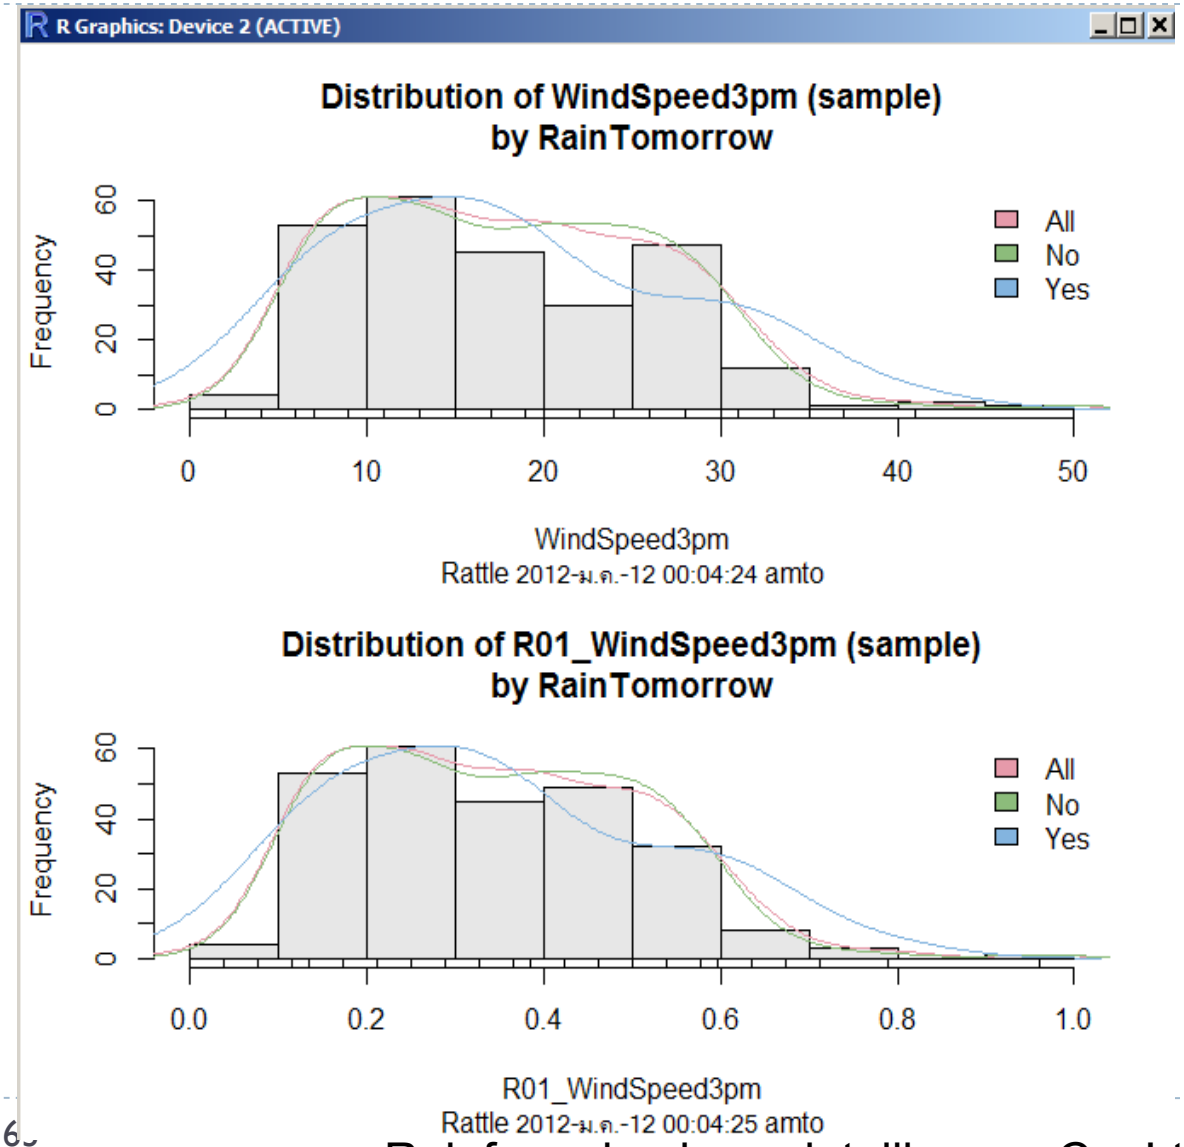
Normalized variables added to the dataset with 'RMD' prefix.

# Rattle Training 6.Transforming Data



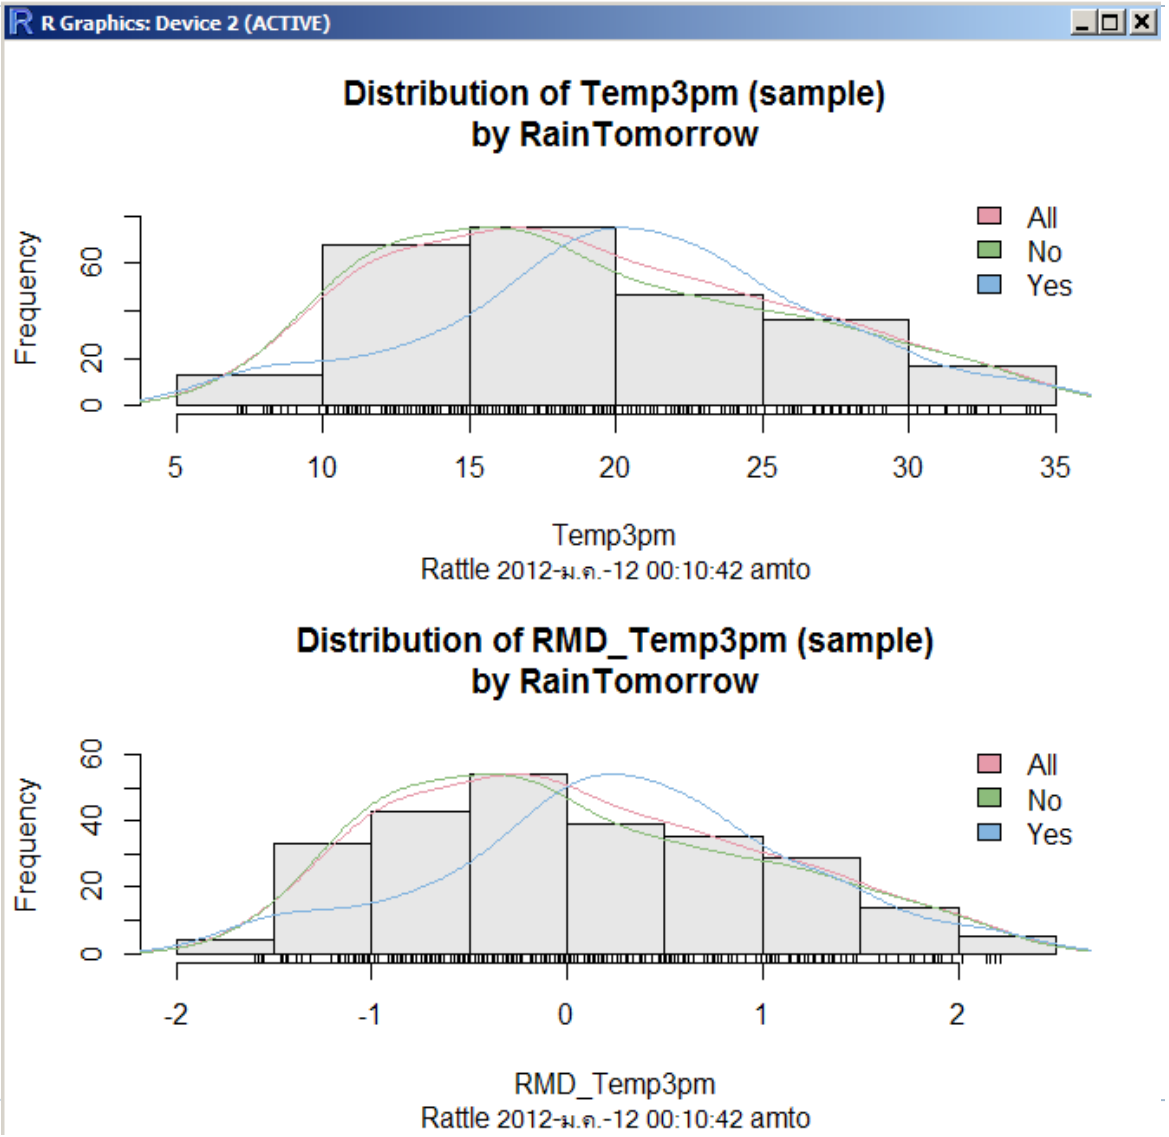

ทดลองสร้าง Histogram ระหว่างข้อมูลตัวแปร Temp3pm กับ RRC_Temp3pm

# Rattle Training 6.Transforming Data



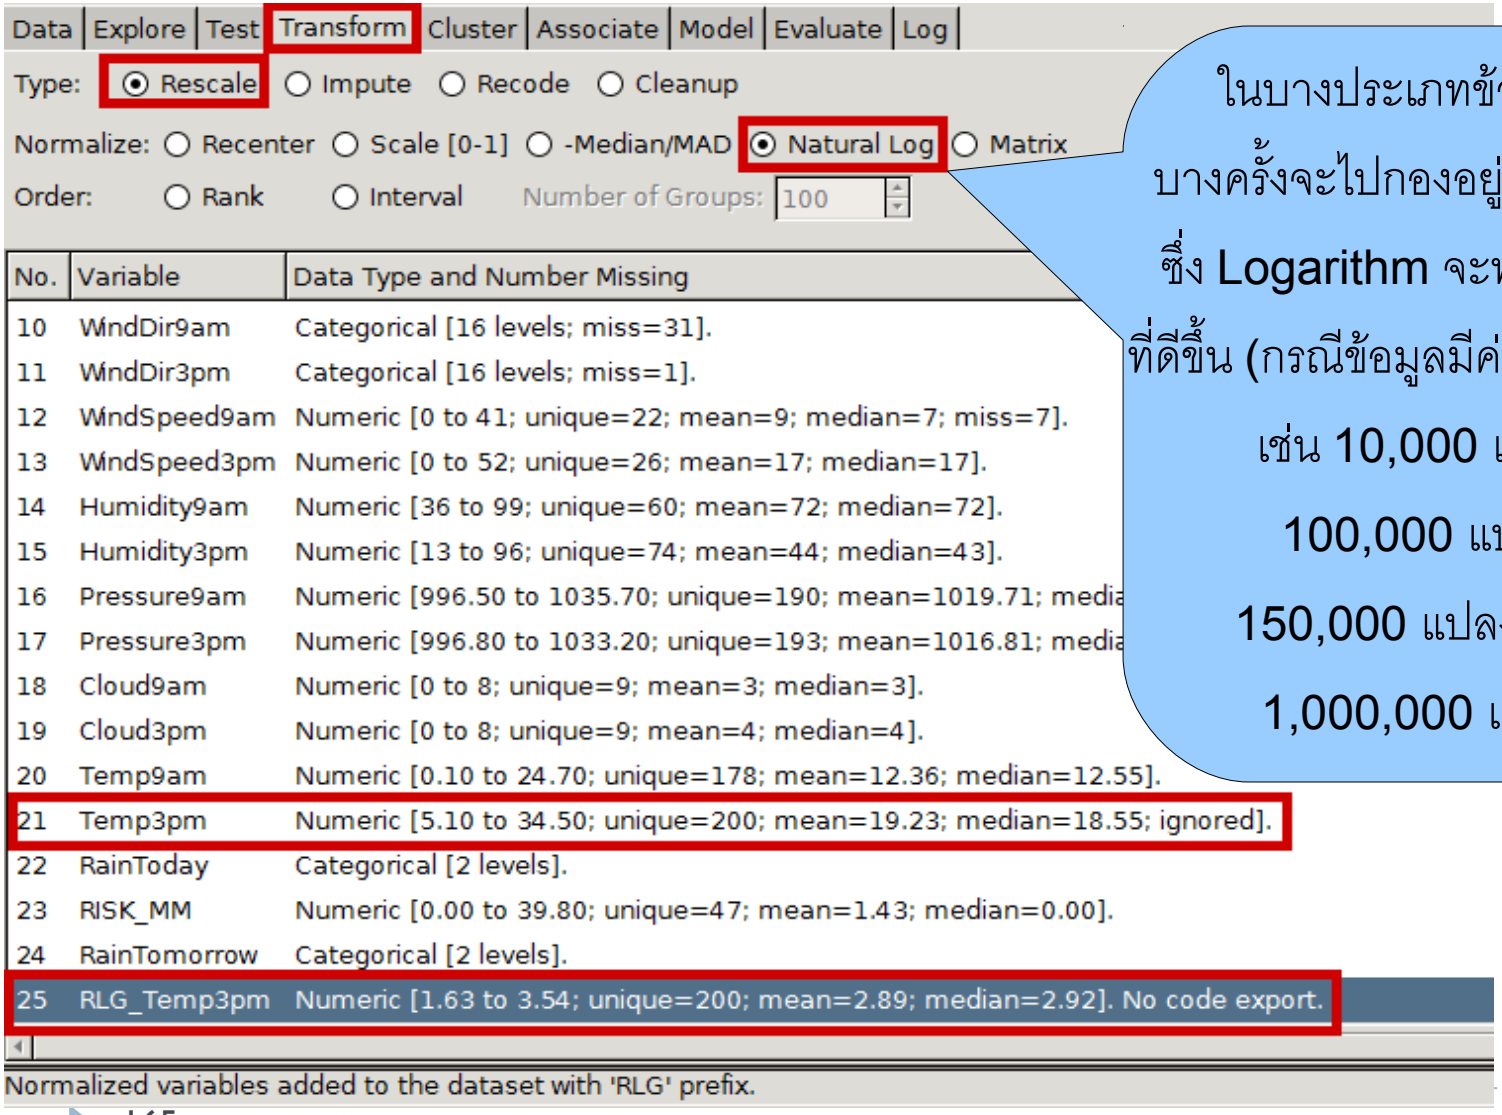

ทดลองสร้าง Histogram ระหว่างข้อมูลตัวแปร Temp3pm กับ R01_Temp3pm

# Rattle Training 6.Transforming Data




ทดลองสร้าง Histogram ระหว่างข้อมูลตัวแปร Temp3pm กับ RMD_Temp3pm

# Rattle Training 6.Transforming Data




ในบางประเภทข้อมูล เช่น รายได้ บางครั้งจะไปกองอยู่แถวๆ 15,000 บาท ซึ่ง Logarithm จะทำให้การกระจายตัวที่ดีขึ้น (กรณีข้อมูลมีค่าบวก) เมื่อ take log

เช่น 10,000 แปลงเป็นค่า 4

100,000 แปลงเป็นค่า 5

150,000 แปลงเป็นค่า 5.176

1,000,000 แปลงเป็นค่า 6

# Rattle Training 6.Transforming Data

Data | Explore | Test | Transform | Cluster | Associate | Model | Evaluate | Log

Type: (•) Rescale ( ) Impute ( ) Recode ( ) Cleanup

Normalize: ( ) Recenter ( ) Scale [0-1] ( ) -Median/MAD ( ) Natural Log (•) Matrix

Order: ( ) Rank ( ) Interval Number of Groups: 100

| No. | Variable | Data Type and Number Missing |
|---|---|---|
| 12 | WindSpeed9am | Numeric [0 to 41; unique=22; mean=9; median=7; miss=7]. |
| 13 | WindSpeed3pm | Numeric [0 to 52; unique=26; mean=17; median=17]. |
| 14 | Humidity9am | Numeric [36 to 99; unique=60; mean=72; median=72]. |
| 15 | Humidity3pm | Numeric [13 to 96; unique=74; mean=44; median=43]. |
| 16 | Pressure9am | Numeric [996.50 to 1035.70; unique=190; mean=1019.71; median=1020.15]. |
| 17 | Pressure3pm | Numeric [996.80 to 1033.20; unique=193; mean=1016.81; median=1017.40]. |
| 18 | Cloud9am | Numeric [0 to 8; unique=9; mean=3; median=3]. |
| 19 | Cloud3pm | Numeric [0 to 8; unique=9; mean=4; median=4]. |
| 20 | Temp9am | Numeric [0.10 to 24.70; unique=178; mean=12.36; median=12.55; ignored]. |
| 21 | Temp3pm | Numeric [5.10 to 34.50; unique=200; mean=19.23; median=18.55; ignored]. |
| 22 | RainToday | Categorical [2 levels]. |
| 23 | RISK_MM | Numeric [0.00 to 39.80; unique=47; mean=1.43; median=0.00]. |
| 24 | RainTomorrow | Categorical [2 levels]. |
| 25 | RLG_Temp3pm | Numeric [1.63 to 3.54; unique=200; mean=2.89; median=2.92]. No code export. |
| 26 | RMA_Temp3pm | Numeric [0.00 to 0.00; unique=200; mean=0.00; median=0.00]. No code export. |

RMA คือ Normalize : Matrix

# Rattle Training 6.Transforming Data

| Temp3pm | RainToda | RISK_MM | RainTomorrow | RRC_Temp3pm | R01_Temp3pm | RMD_Temp3pm | RLG_Temp3pm | RMA_Temp3pm |
|---|---|---|---|---|---|---|---|---|
| 23.6 | | | | 0.657967 | 0.629252 | 0.702305 | 3.16125 | 0.00335299 |
| 25.7 | | | | 0.974215 | 0.70068 | 0.994352 | 3.24649 | 0.00365135 |
| 20.2 | | | | 0.145945 | 0.513605 | 0.229466 | 3.00568 | 0.00286993 |
| 14.1 | | | | -0.772682 | 0.306122 | -0.618863 | 2.64617 | 0.00200327 |
| 15.4 | | | | -0.576909 | 0.35034 | -0.438071 | 2.73437 | 0.00218797 |
| 14.8 | | | | -0.667266 | 0.329932 | -0.521513 | 2.69463 | 0.00210272 |
| 17.3 | | | | -0.290779 | 0.414966 | -0.173838 | 2.85071 | 0.00245791 |
| 15.5 | | | | -0.561849 | 0.353741 | -0.424164 | 2.74084 | 0.00220217 |
| 18.9 | | | | -0.0498279 | 0.469388 | 0.0486746 | 2.93916 | 0.00268523 |
| 21.7 | | | | 0.371837 | 0.564626 | 0.438071 | 3.07731 | 0.00308304 |
| 24 | | | | 0.718204 | 0.642857 | 0.757933 | 3.17805 | 0.00340982 |
| 26 | | | | 1.01939 | 0.710884 | 1.03607 | 3.2581 | 0.00369397 |
| 27.1 | | | | 1.18505 | 0.748299 | 1.18905 | 3.29953 | 0.00385025 |
| 30.7 | | | | 1.72719 | 0.870748 | 1.6897 | 3.42426 | 0.00436172 |
| 30.4 | | | | 1.68201 | 0.860544 | 1.64798 | 3.41444 | 0.0043191 |
| 30.7 | | | | 1.72719 | 0.870748 | 1.6897 | 3.42426 | 0.00436172 |
| 29.8 | | | | 1.59165 | 0.840136 | 1.56454 | 3.39451 | 0.00423386 |
| 28.6 | | | | 1.41094 | 0.79932 | 1.39766 | 3.35341 | 0.00406337 |

R = Rescale

RRC = Recenter

R01= Scale [0-1]

RMD = Median/MAD

RLG = Natural Log

RMA = Matrix

# Rattle Training 6.Transforming Data

- ผลลัพธ์ของแปลงข้อมูลให้อยู่ในรูปของ Rank หรือแบ่งเป็น Group ตามกำหนด

Rattle Dataset

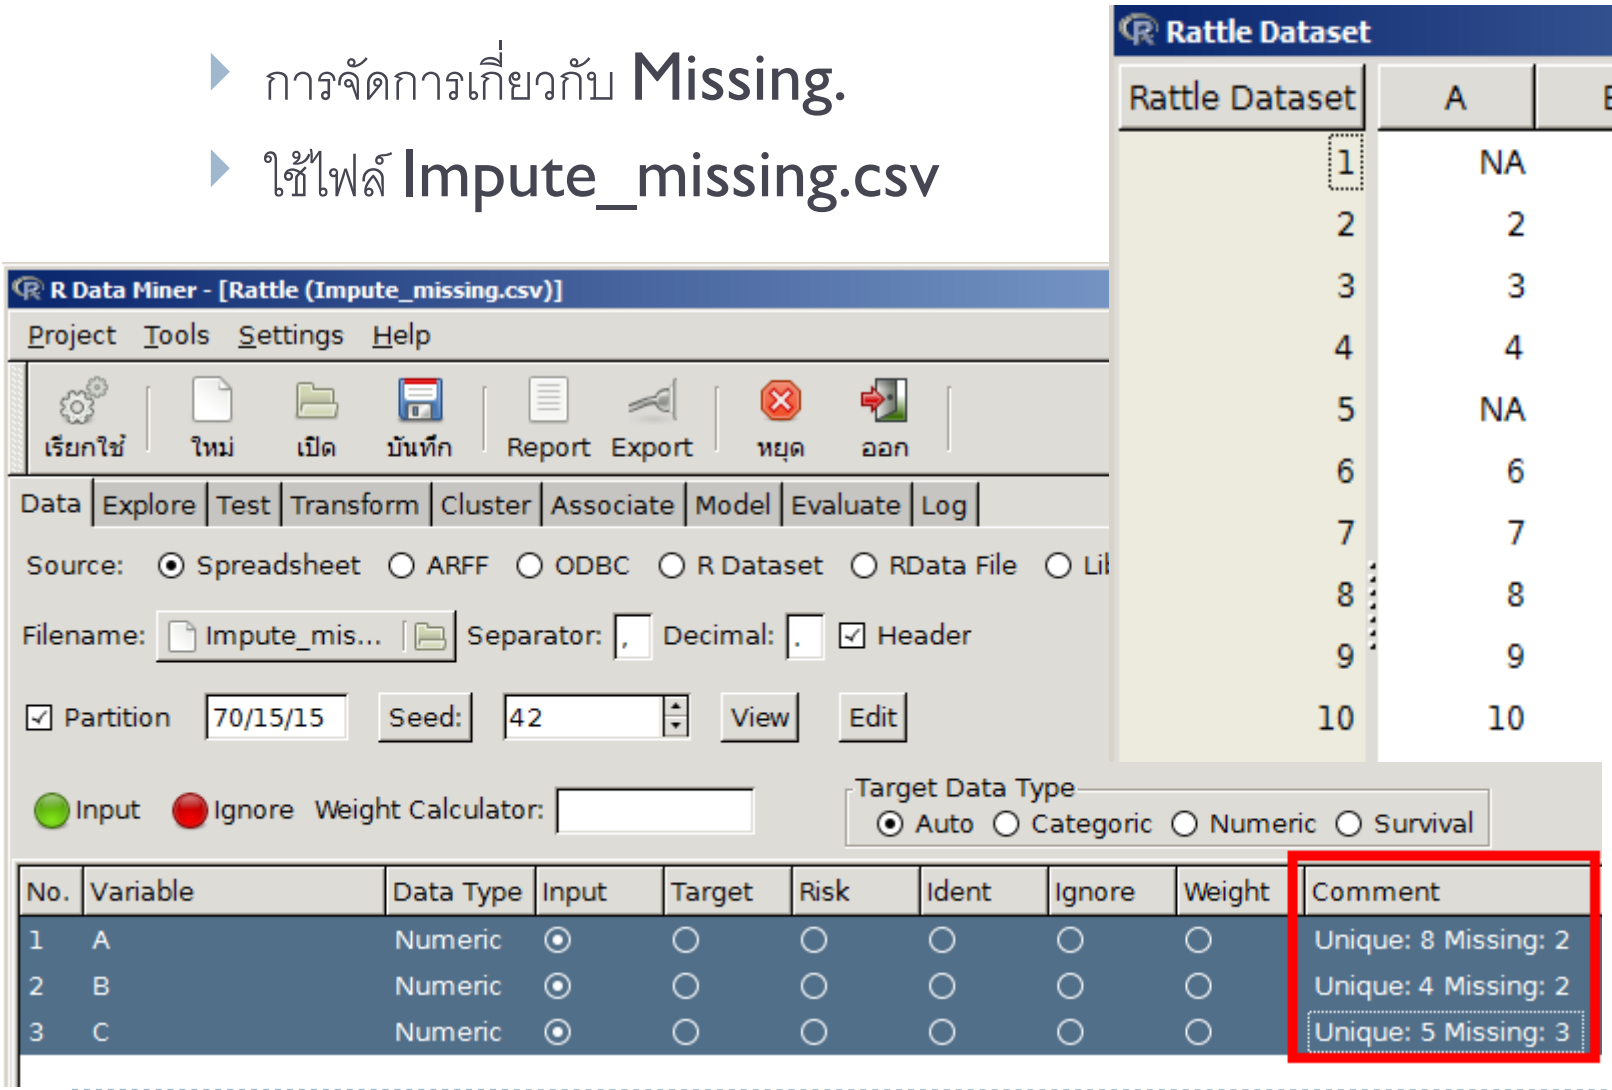
| Rattle Dataset | essure | Cloud9ar | Cloud3pr | Temp9ar | Temp3pm | RainToda | RISK_MM | RainTom | RRK_Temp3pm | RIN_Temp3pm_10 |
|---|---|---|---|---|---|---|---|---|---|---|
| 352 | 1020.7 | 6 | 1 | 11.6 | 21.9 | No | 0 | No | 243.5 | 5 |
| 353 | 1022.2 | 1 | 7 | 12.7 | 23.7 | No | 0 | No | 269.5 | 6 |
| 354 | 1019.8 | 1 | 6 | 16.8 | | | | | 317 | 7 |
| 355 | 1017.5 | 1 | 1 | 16.4 | | | | | 302.5 | 6 |
| 356 | 1018.6 | 7 | 5 | 11.4 | 18.5 | No | 0.8 | No | 182 | 4 |
| 357 | 1023.1 | 1 | 5 | 8.3 | 14.3 | No | 0 | No | 94 | 3 |
| 358 | 1022.8 | 1 | 2 | 9.1 | 16.3 | No | 0 | No | 136 | 3 |
| 359 | 1018.4 | 3 | | | | | | | | 4 |
| 360 | 1014.6 | 0 | | | | | | | | 6 |
| 361 | 1014.2 | 5 | 8 | 16.3 | 25.9 | No | 0 | No | 296.5 | 6 |
| 362 | 1010.8 | 1 | 3 | 20.4 | 30 | No | 0 | No | 336.5 | 8 |
| 363 | 1016.9 | 0 | 1 | 17.2 | 28.2 | No | 0 | No | 323.5 | 7 |
| 364 | 1022.8 | 3 | 2 | 14.5 | 18.3 | No | 0 | No | 178 | 4 |
| 365 | 1016.2 | 6 | 7 | 15.8 | 25.9 | No | 0 | No | 296.5 | 6 |
| 366 | 1009.2 | 1 | 1 | 23.8 | 28.6 | No | 0 | No | 328.5 | 7 |

RRK คือเรียง Order แบบ Rank.

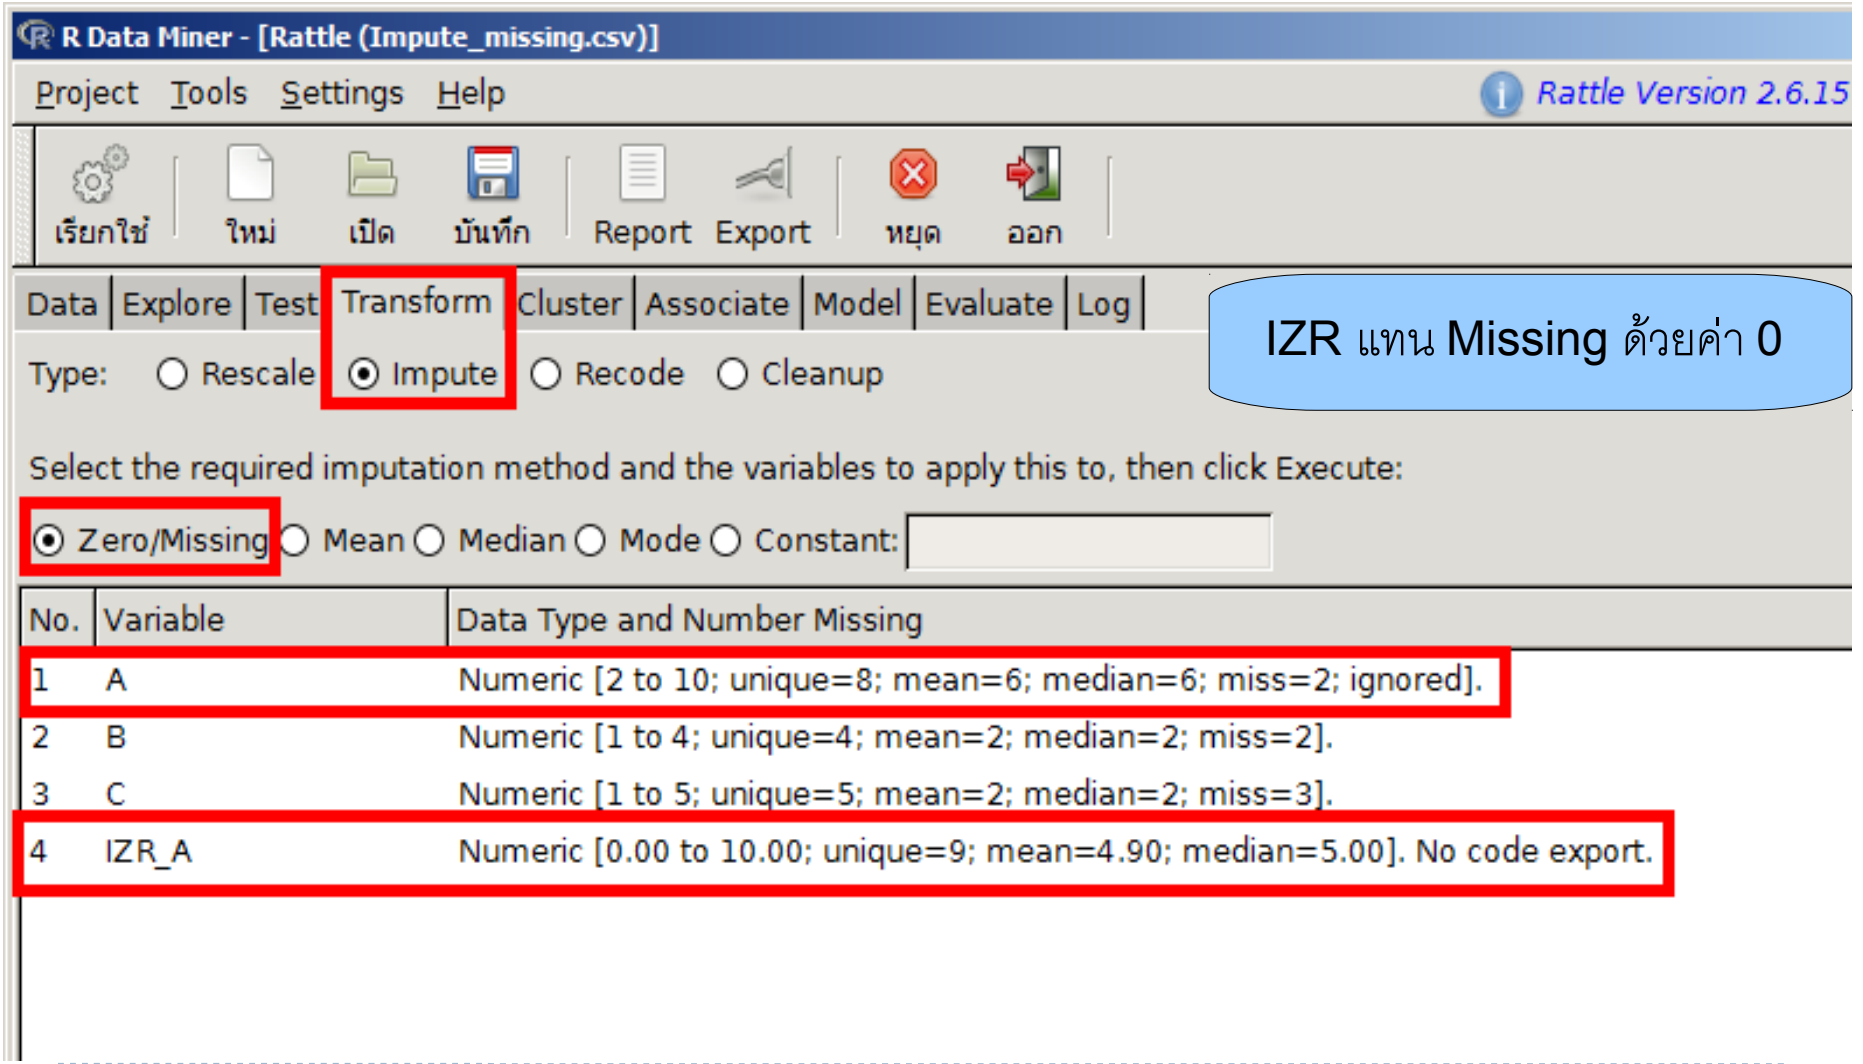
RIN คือเรียง Order แบบ Interval ในที่นี้ Number of Group = 10

# Rattle Training 6.Transforming Data

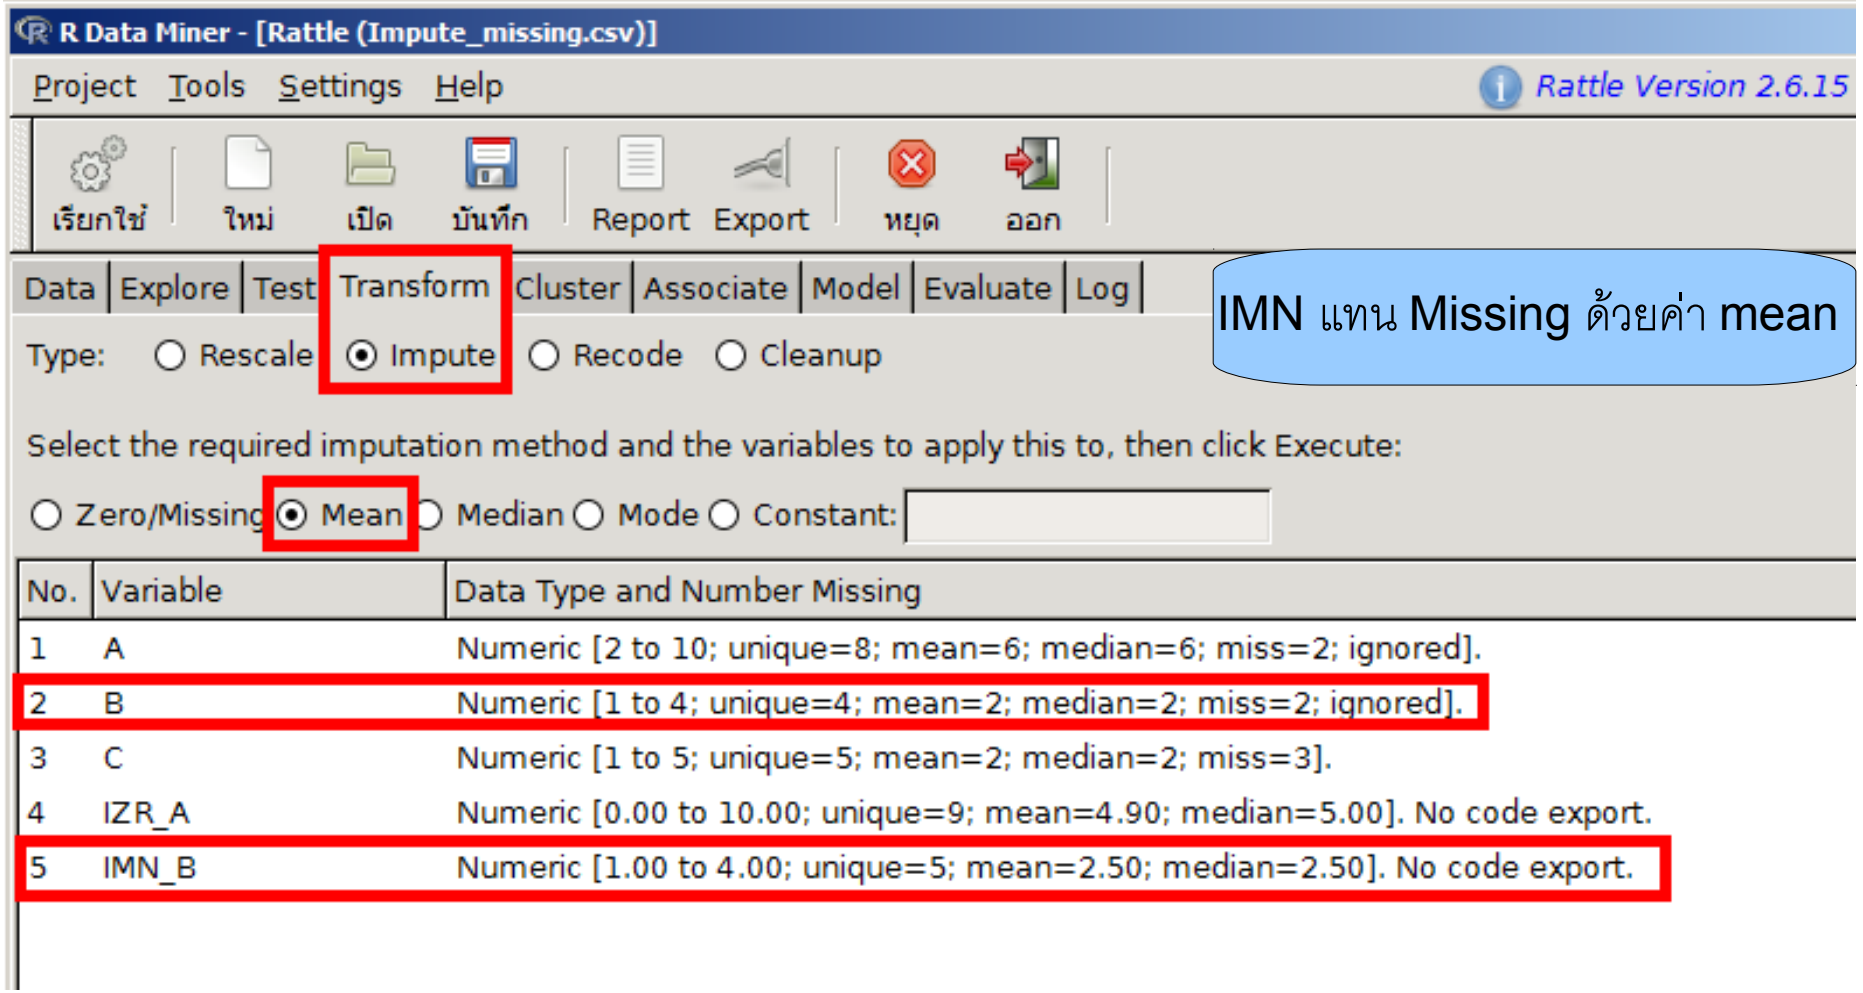
- การจัดการเกี่ยวกับ **Missing.**
- ใช้ไฟล์ **Impute_missing.csv**



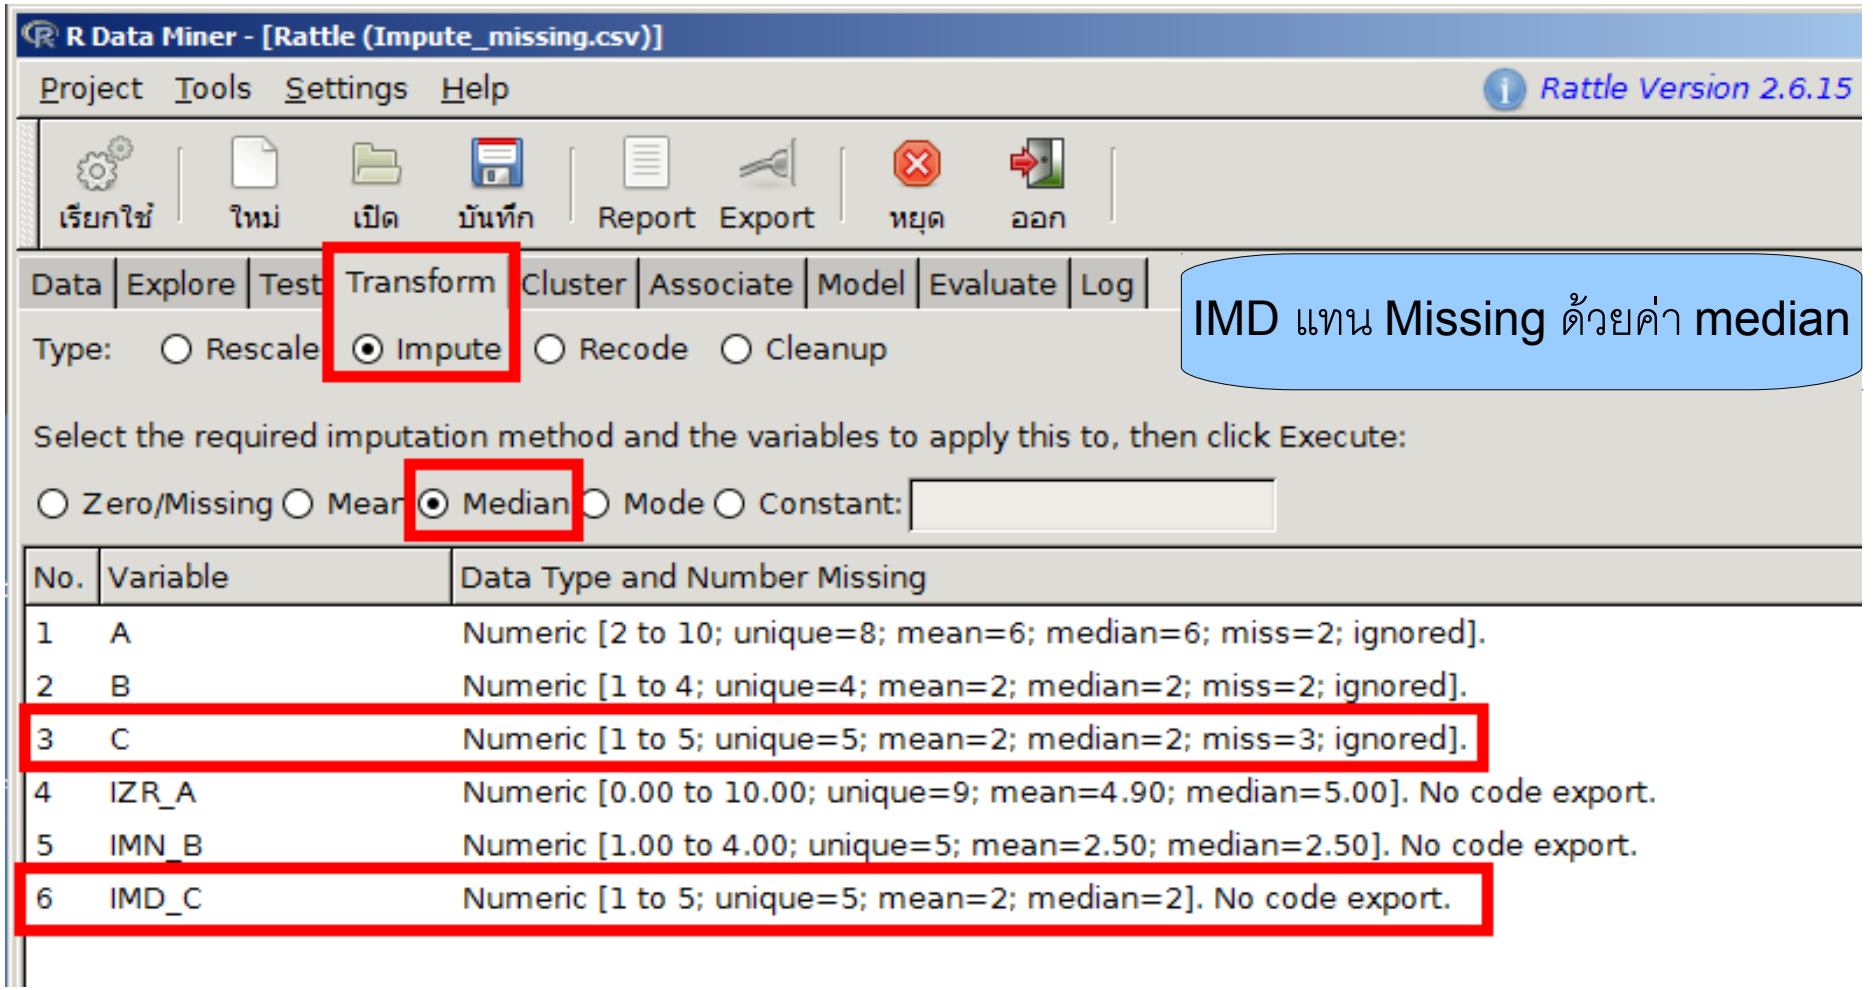
# Rattle Training 6.Transforming Data



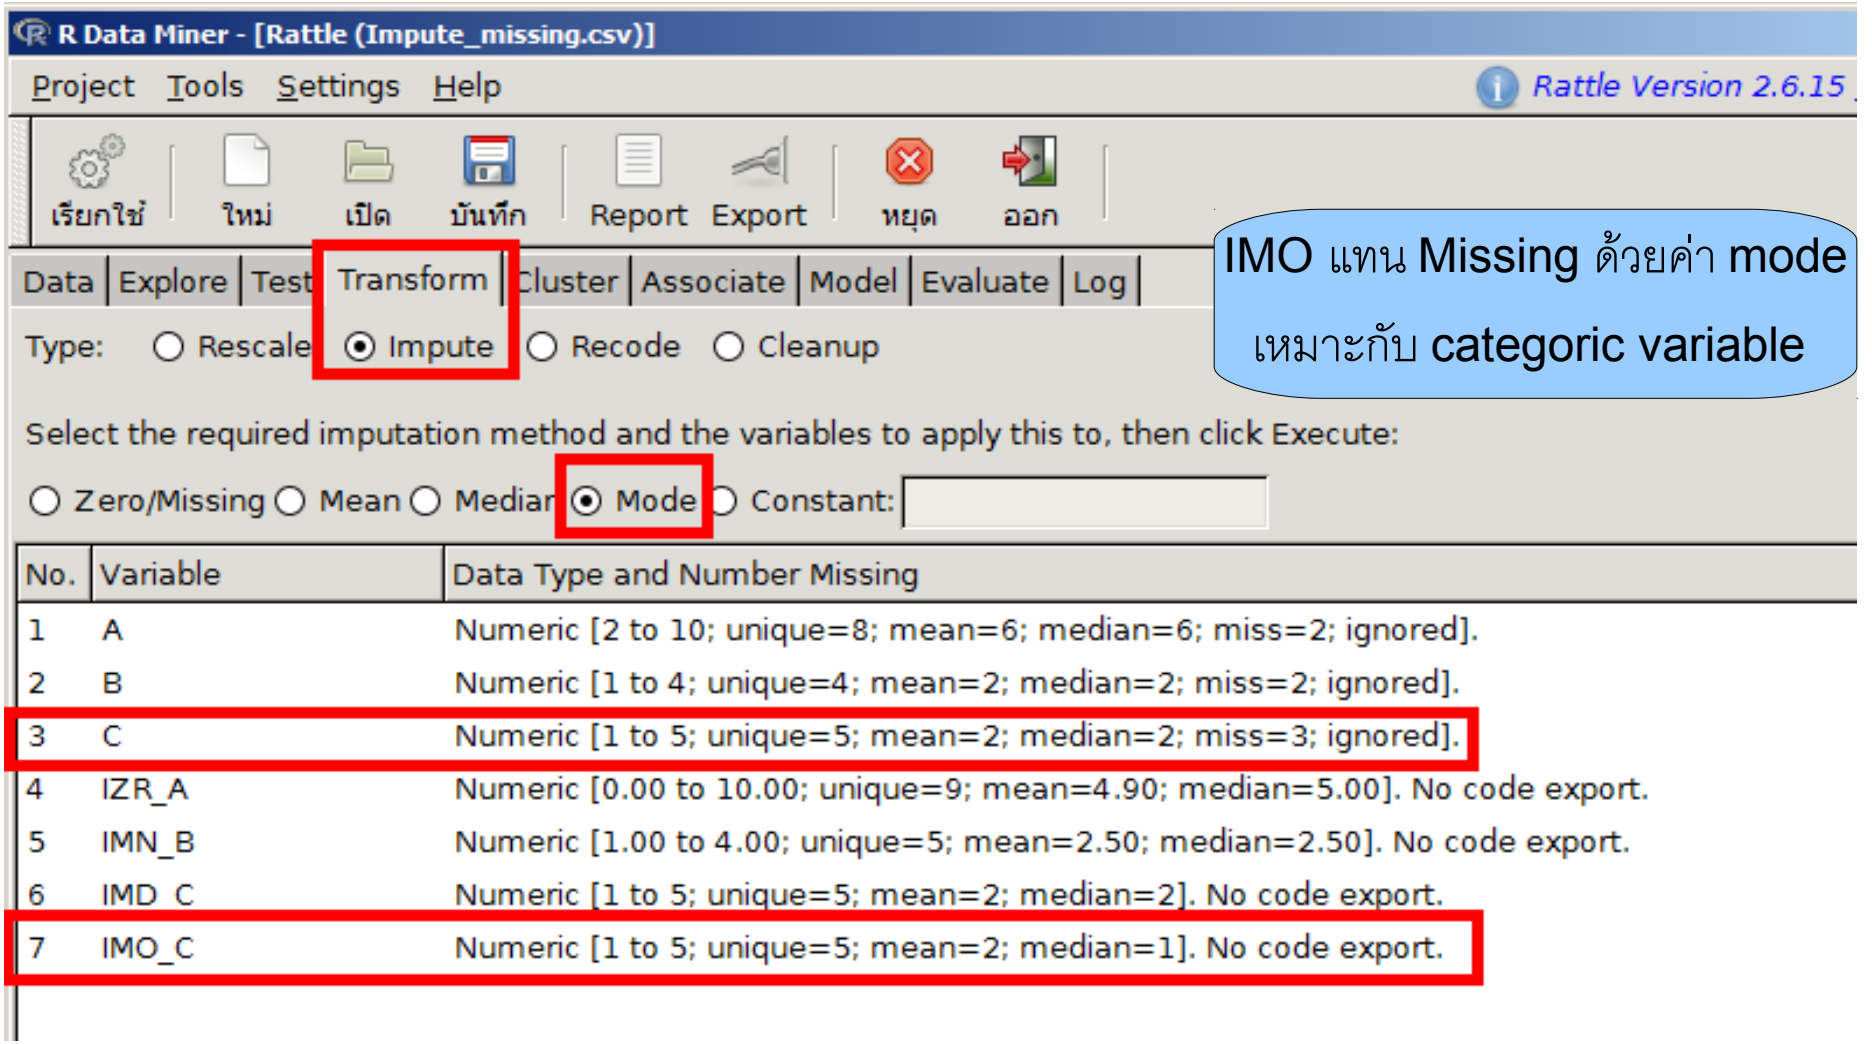
# Rattle Training 6.Transforming Data



# Rattle Training 6.Transforming Data

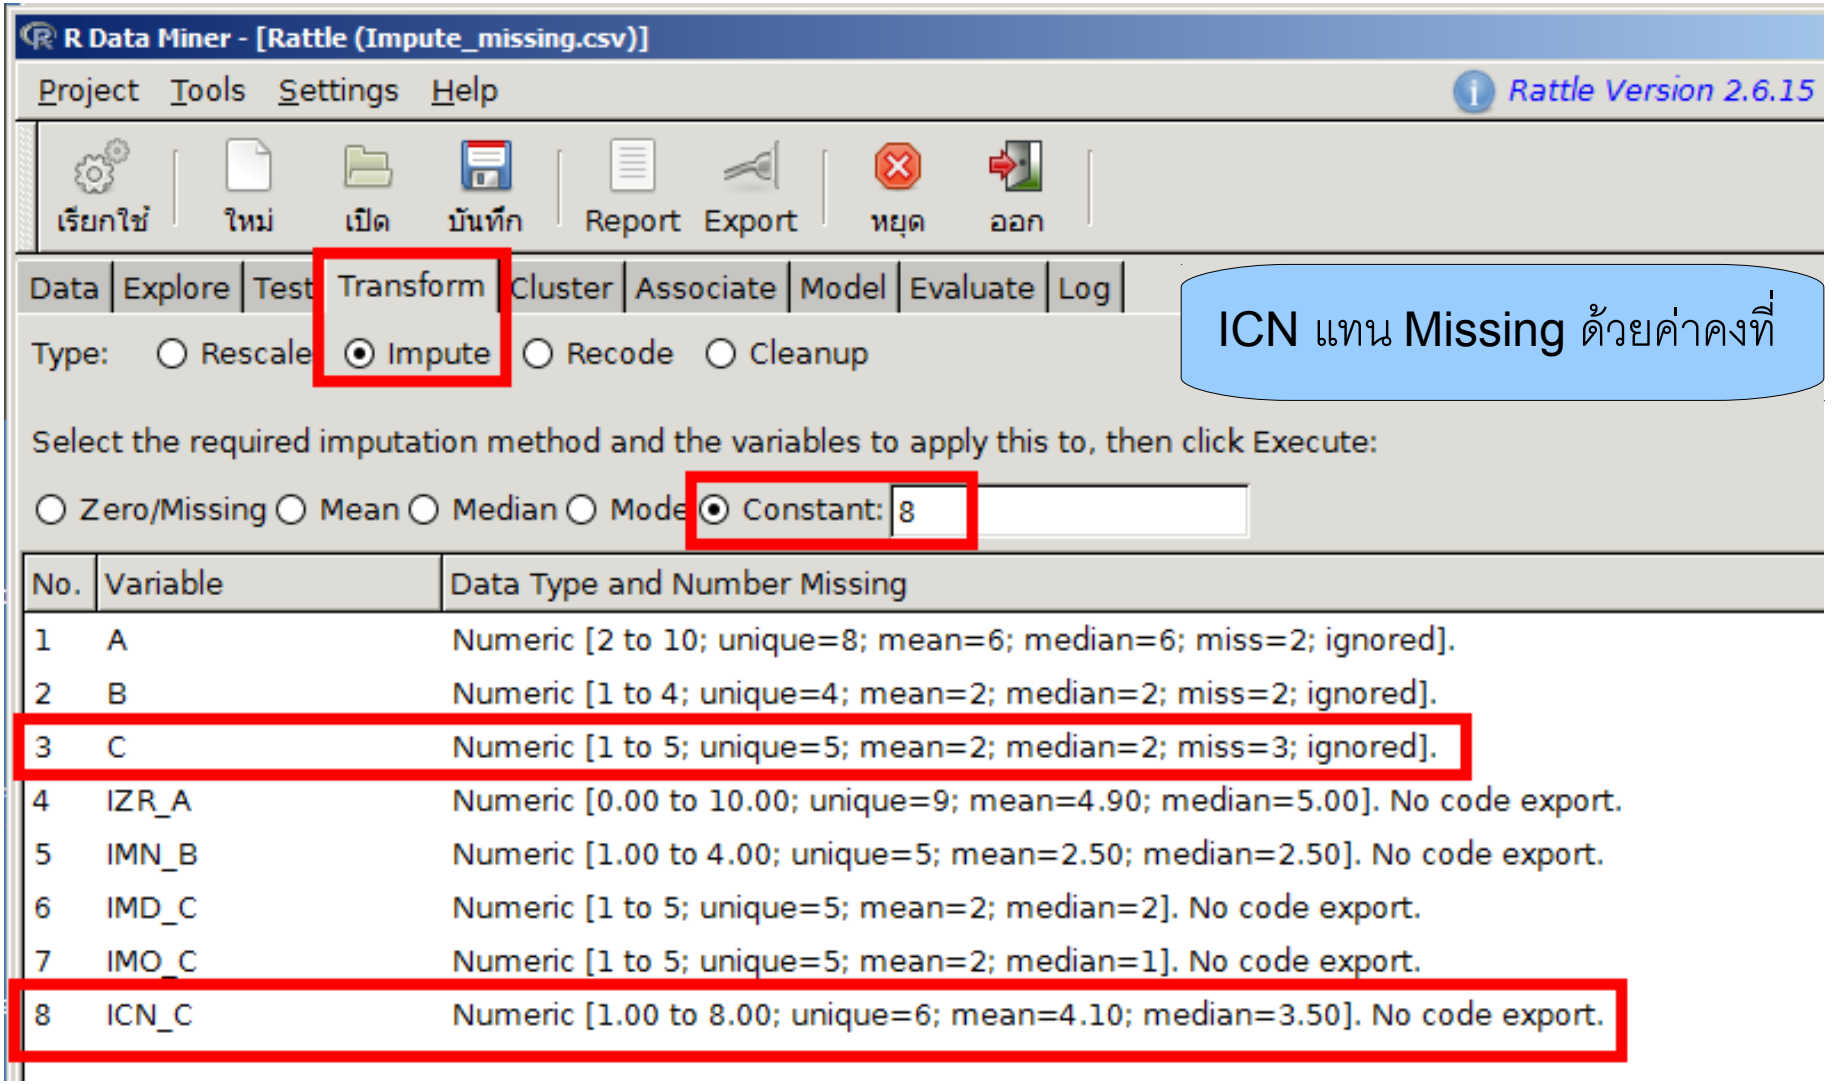


# Rattle Training 6.Transforming Data




| No. | Variable | Data Type and Number Missing |
|---|---|---|
| 1 | A | Numeric [2 to 10; unique=8; mean=6; median=6; miss=2; ignored]. |
| 2 | B | Numeric [1 to 4; unique=4; mean=2; median=2; miss=2; ignored]. |
| 3 | C | Numeric [1 to 5; unique=5; mean=2; median=2; miss=3; ignored]. |
| 4 | IZR_A | Numeric [0.00 to 10.00; unique=9; mean=4.90; median=5.00]. No code export. |
| 5 | IMN_B | Numeric [1.00 to 4.00; unique=5; mean=2.50; median=2.50]. No code export. |
| 6 | IMD_C | Numeric [1 to 5; unique=5; mean=2; median=2]. No code export. |
| 7 | IMO_C | Numeric [1 to 5; unique=5; mean=2; median=1]. No code export. |

# Rattle Training 6.Transforming Data




| No. | Variable | Data Type and Number Missing |
|---|---|---|
| 1 | A | Numeric [2 to 10; unique=8; mean=6; median=6; miss=2; ignored]. |
| 2 | B | Numeric [1 to 4; unique=4; mean=2; median=2; miss=2; ignored]. |
| 3 | C | Numeric [1 to 5; unique=5; mean=2; median=2; miss=3; ignored]. |
| 4 | IZR_A | Numeric [0.00 to 10.00; unique=9; mean=4.90; median=5.00]. No code export. |
| 5 | IMN_B | Numeric [1.00 to 4.00; unique=5; mean=2.50; median=2.50]. No code export. |
| 6 | IMD_C | Numeric [1 to 5; unique=5; mean=2; median=2]. No code export. |
| 7 | IMO_C | Numeric [1 to 5; unique=5; mean=2; median=1]. No code export. |
| 8 | ICN_C | Numeric [1.00 to 8.00; unique=6; mean=4.10; median=3.50]. No code export. |

# Rattle Training 6.Transforming Data

Rattle Dataset

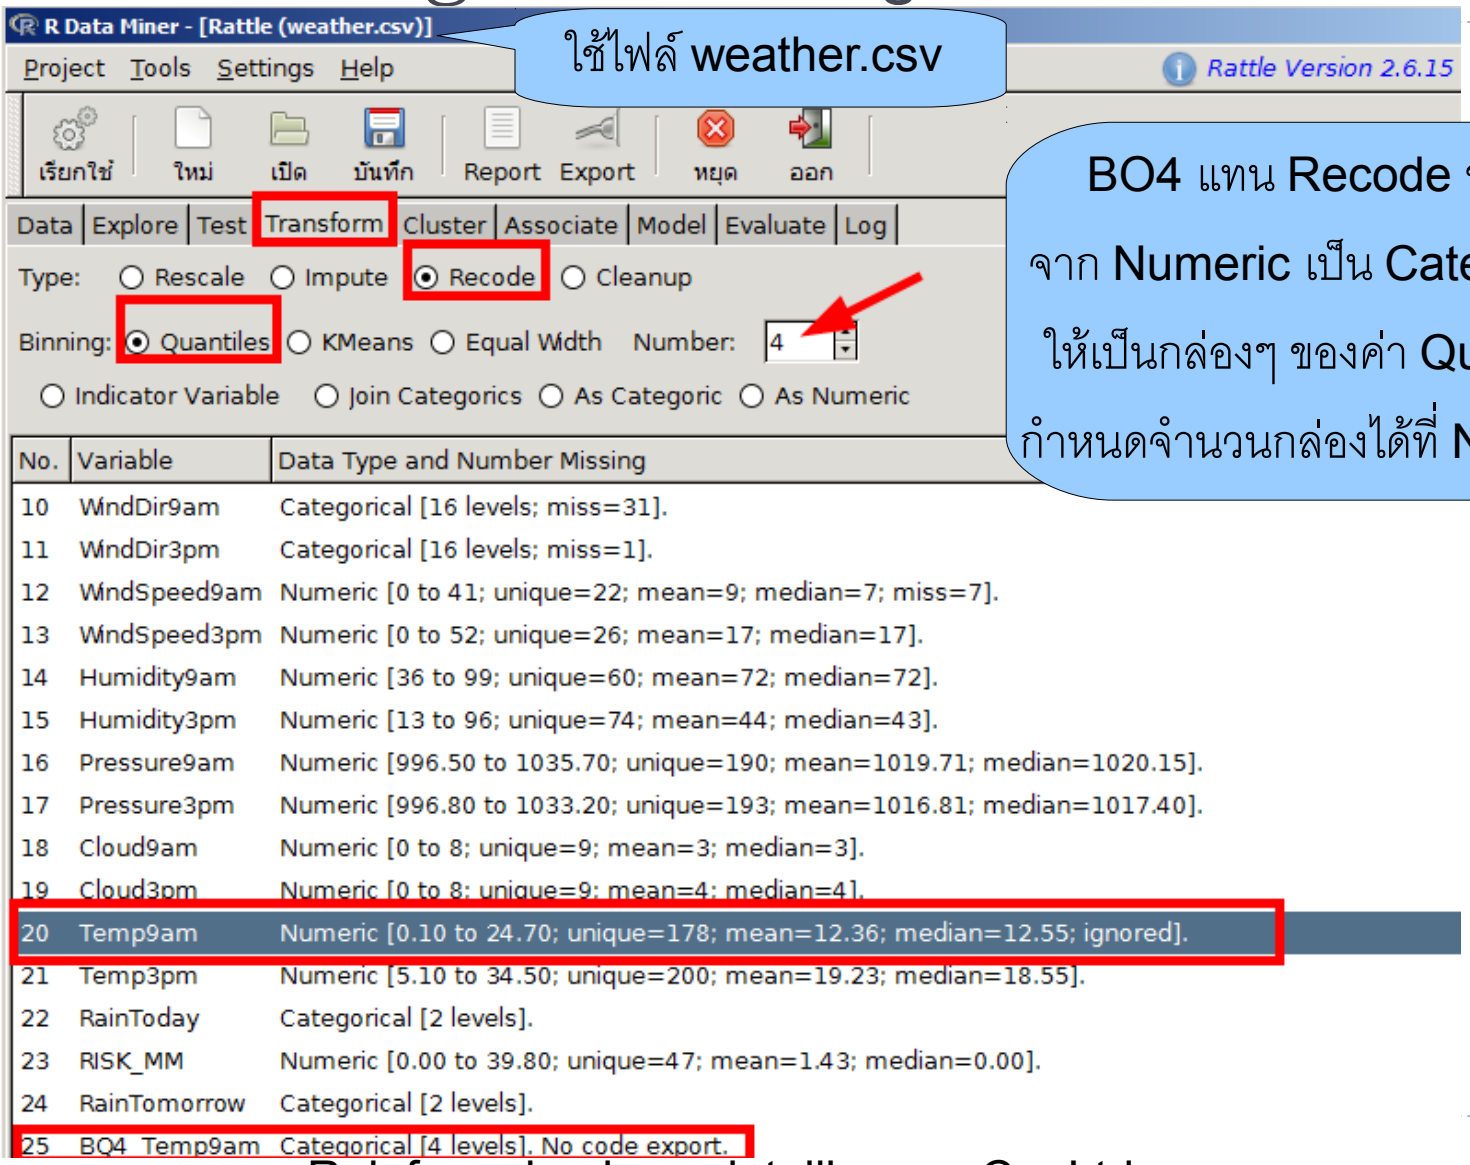
| Rattle Dataset | A | B | C | IZR_A | IMN_B | IMD_C | IMO_C | ICN_C |
|---|---|---|---|---|---|---|---|---|
| 1 | NA | 1 | NA | 0 | 1 | 2 | 1 | 8 |
| 2 | 2 | 1 | NA | 2 | 1 | 2 | 1 | 8 |
| 3 | 3 | 2 | NA | 3 | 2 | 2 | 1 | 8 |
| 4 | 4 | 2 | 1 | 4 | 2 | 1 | 1 | 1 |
| 5 | NA | NA | 1 | 0 | 2.5 | 1 | 1 | 1 |
| 6 | 6 | NA | 1 | 6 | 2.5 | 1 | 1 | 1 |
| 7 | 7 | 3 | 2 | 7 | 3 | 2 | 2 | 2 |
| 8 | 8 | 3 | 3 | 8 | 3 | 3 | 3 | 3 |
| 9 | 9 | 4 | 4 | 9 | 4 | 4 | 4 | 4 |
| 10 | 10 | 4 | 5 | 10 | 4 | 5 | 5 | 5 |
| | NA | NA | NA | NA | NA | NA | NA | NA |

IZR แทน missing ด้วย 0 ; IMN แทน missing ด้วย mean.

IMD แทน missing ด้วย median ; IMO แทน missing ด้วย mode

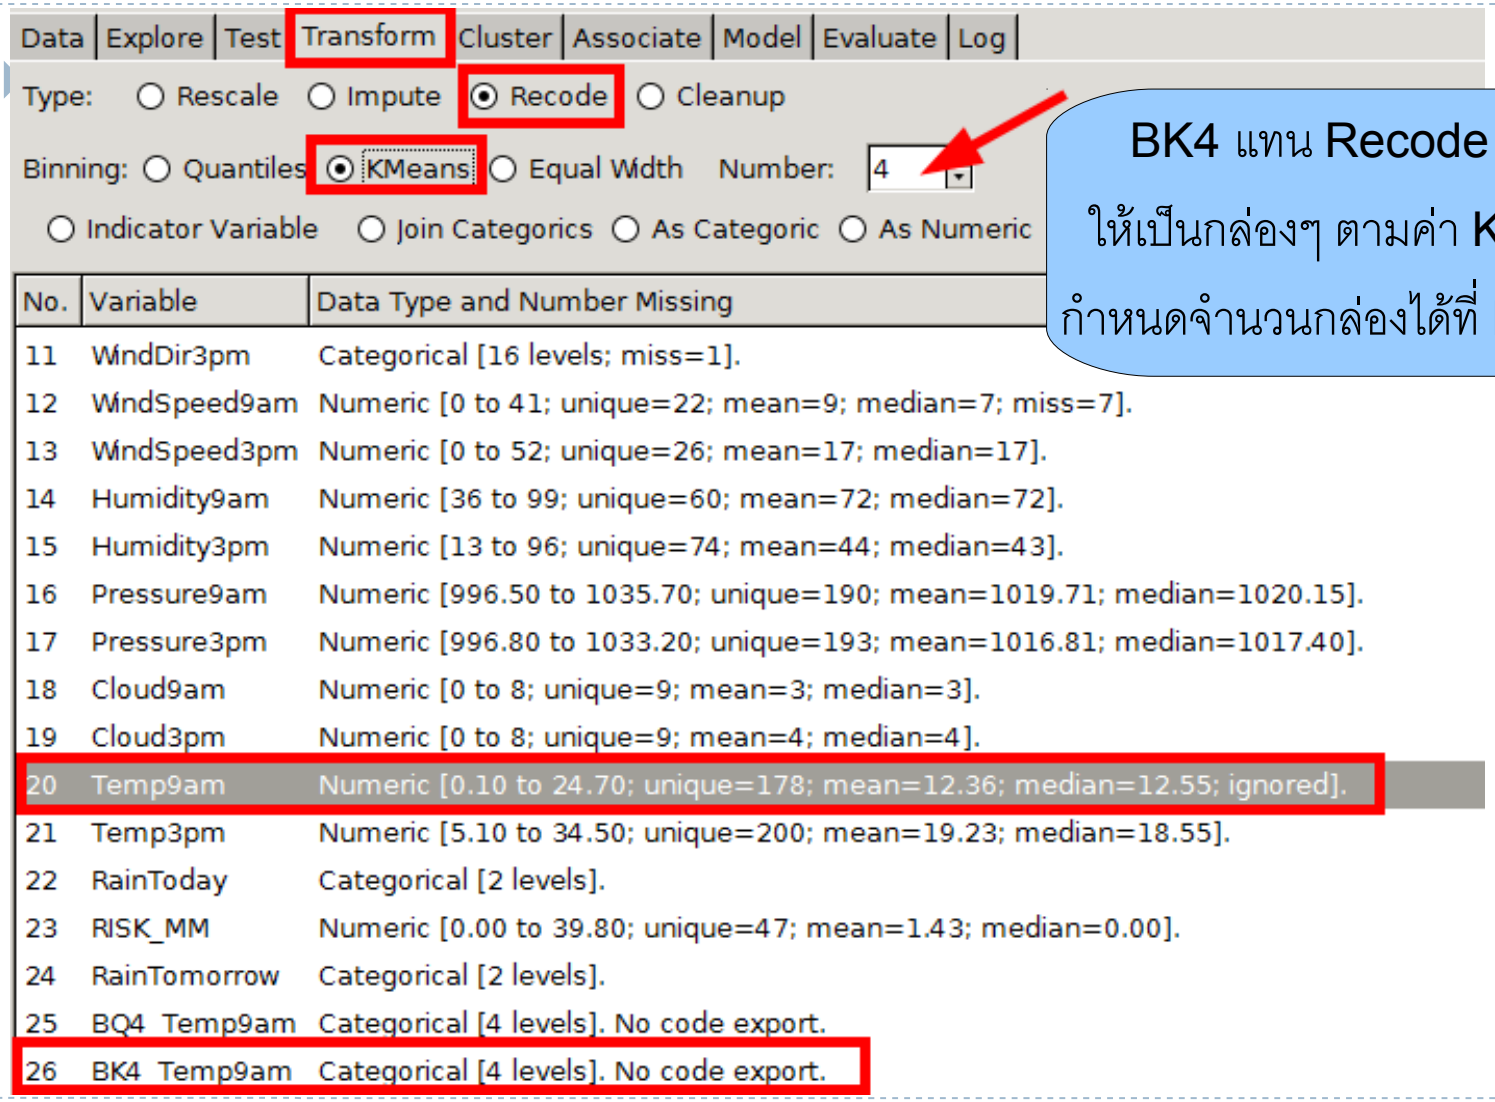
ICN แทน missing ด้วย constant (ค่าคงที่ใน ตย.นี้ คือ 8)

# Rattle Training 6.Transforming Data



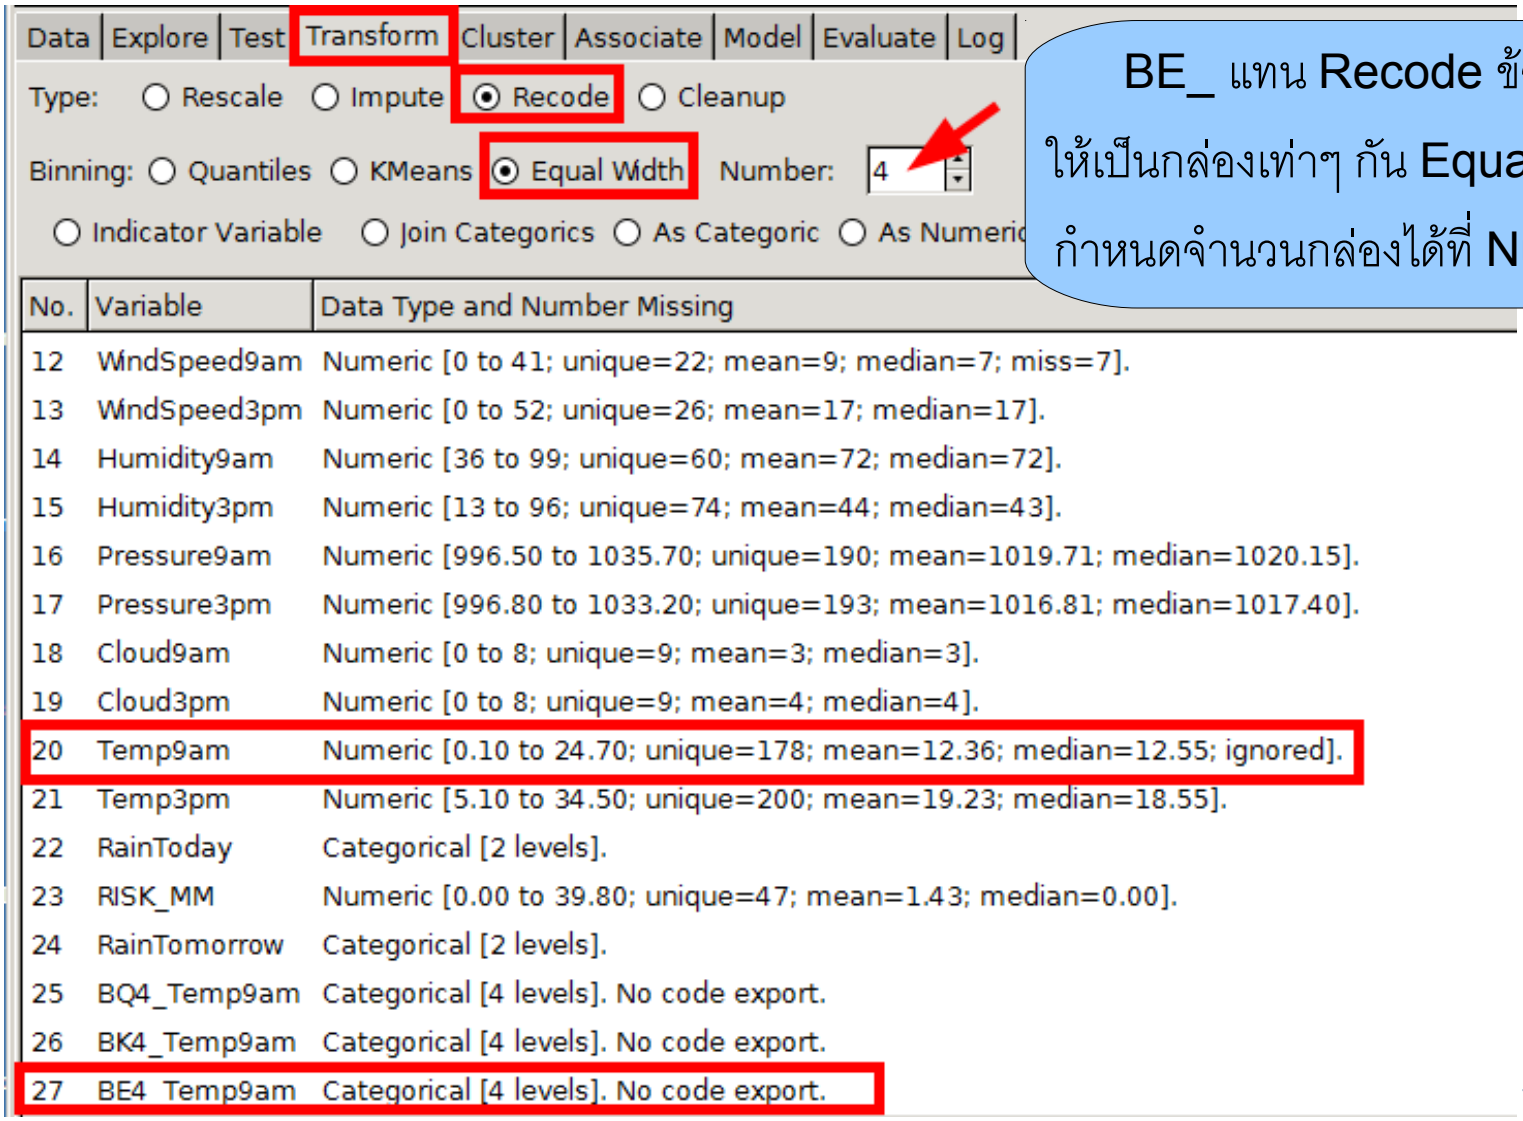

BO4 แทน Recode ข้อมูล จาก Numeric เป็น Categorical ให้เป็นกล่องๆ ของค่า Quartiles กำหนดจำนวนกล่องได้ที่ Number

# Rattle Training 6.Transforming Data




| No. | Variable | Data Type and Number Missing |
|---|---|---|
| 11 | WindDir3pm | Categorical [16 levels; miss=1]. |
| 12 | WindSpeed9am | Numeric [0 to 41; unique=22; mean=9; median=7; miss=7]. |
| 13 | WindSpeed3pm | Numeric [0 to 52; unique=26; mean=17; median=17]. |
| 14 | Humidity9am | Numeric [36 to 99; unique=60; mean=72; median=72]. |
| 15 | Humidity3pm | Numeric [13 to 96; unique=74; mean=44; median=43]. |
| 16 | Pressure9am | Numeric [996.50 to 1035.70; unique=190; mean=1019.71; median=1020.15]. |
| 17 | Pressure3pm | Numeric [996.80 to 1033.20; unique=193; mean=1016.81; median=1017.40]. |
| 18 | Cloud9am | Numeric [0 to 8; unique=9; mean=3; median=3]. |
| 19 | Cloud3pm | Numeric [0 to 8; unique=9; mean=4; median=4]. |
| 20 | Temp9am | Numeric [0.10 to 24.70; unique=178; mean=12.36; median=12.55; ignored]. |
| 21 | Temp3pm | Numeric [5.10 to 34.50; unique=200; mean=19.23; median=18.55]. |
| 22 | RainToday | Categorical [2 levels]. |
| 23 | RISK_MM | Numeric [0.00 to 39.80; unique=47; mean=1.43; median=0.00]. |
| 24 | RainTomorrow | Categorical [2 levels]. |
| 25 | BQ4_Temp9am | Categorical [4 levels]. No code export. |
| 26 | BK4_Temp9am | Categorical [4 levels]. No code export. |

# Rattle Training 6.Transforming Data




| No. | Variable | Data Type and Number Missing |
|---|---|---|
| 12 | WindSpeed9am | Numeric [0 to 41; unique=22; mean=9; median=7; miss=7]. |
| 13 | WindSpeed3pm | Numeric [0 to 52; unique=26; mean=17; median=17]. |
| 14 | Humidity9am | Numeric [36 to 99; unique=60; mean=72; median=72]. |
| 15 | Humidity3pm | Numeric [13 to 96; unique=74; mean=44; median=43]. |
| 16 | Pressure9am | Numeric [996.50 to 1035.70; unique=190; mean=1019.71; median=1020.15]. |
| 17 | Pressure3pm | Numeric [996.80 to 1033.20; unique=193; mean=1016.81; median=1017.40]. |
| 18 | Cloud9am | Numeric [0 to 8; unique=9; mean=3; median=3]. |
| 19 | Cloud3pm | Numeric [0 to 8; unique=9; mean=4; median=4]. |
| 20 | Temp9am | Numeric [0.10 to 24.70; unique=178; mean=12.36; median=12.55; ignored]. |
| 21 | Temp3pm | Numeric [5.10 to 34.50; unique=200; mean=19.23; median=18.55]. |
| 22 | RainToday | Categorical [2 levels]. |
| 23 | RISK_MM | Numeric [0.00 to 39.80; unique=47; mean=1.43; median=0.00]. |
| 24 | RainTomorrow | Categorical [2 levels]. |
| 25 | BQ4_Temp9am | Categorical [4 levels]. No code export. |
| 26 | BK4_Temp9am | Categorical [4 levels]. No code export. |
| 27 | BE4_Temp9am | Categorical [4 levels]. No code export. |

BE_ แทน Recode ข้อมูล ให้เป็นกล่องเท่าๆ กัน Equal Width กำหนดจำนวนกล่องได้ที่ Number

# Rattle Training 6.Transforming Data

Data | Explore | Test | Transform | Cluster | Associate | Model | Evaluate | Log

Type: ○ Rescale ○ Impute ◉ Recode ○ Cleanup

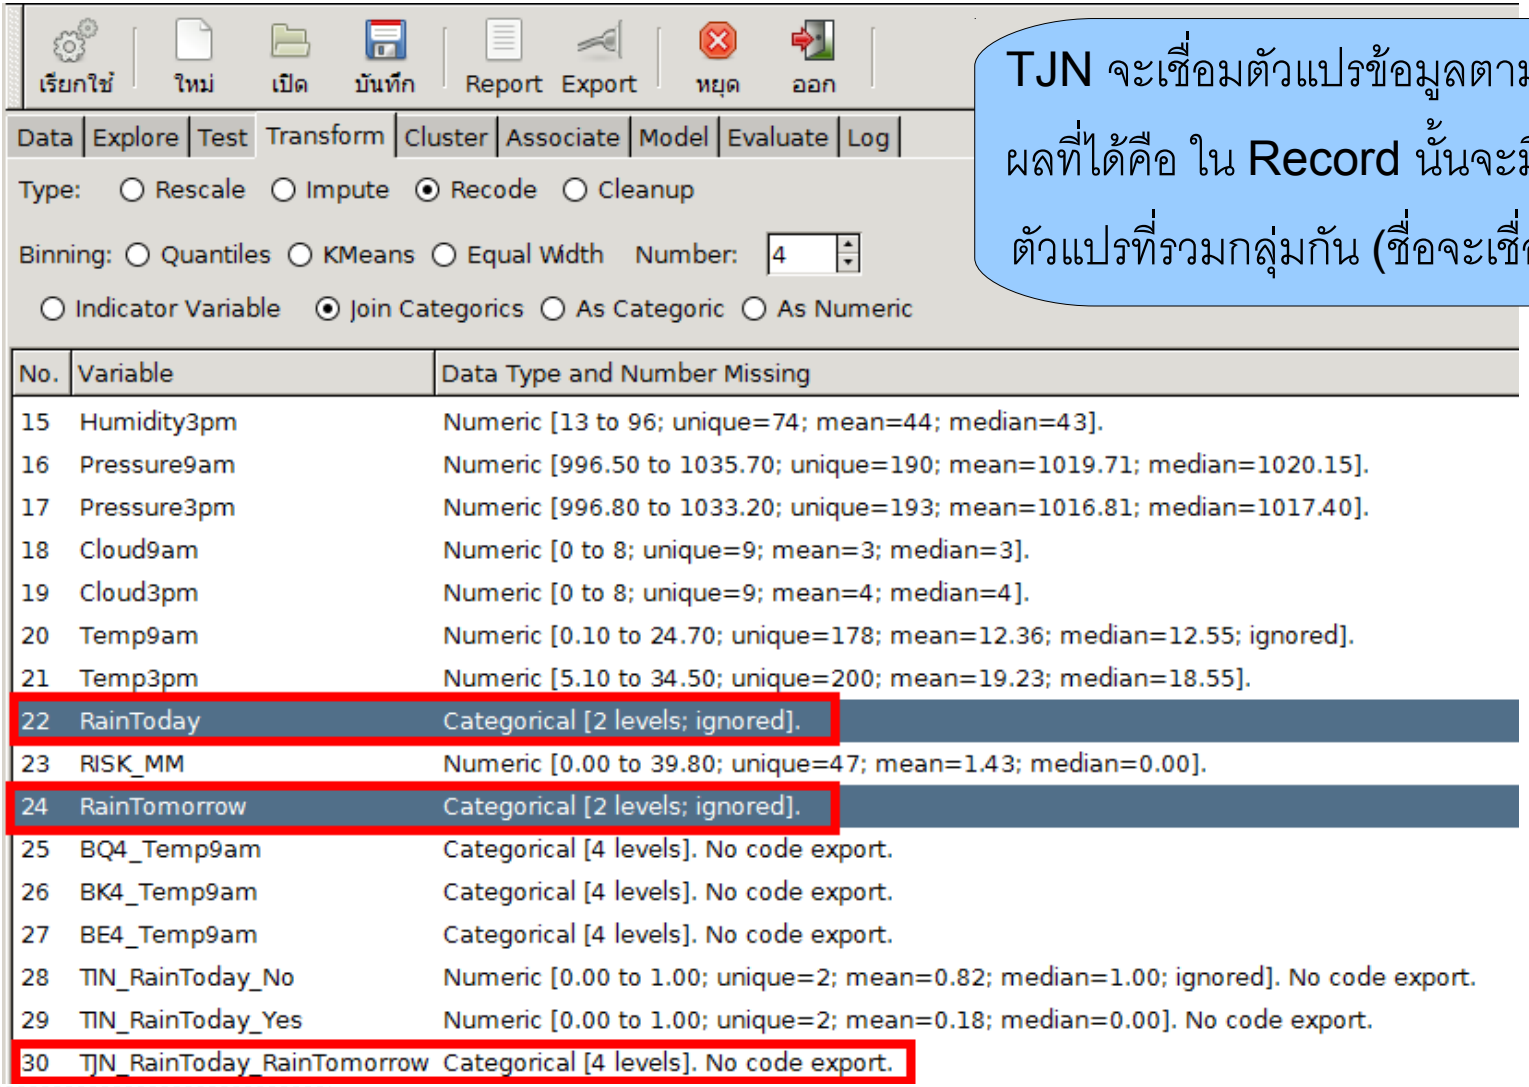
Binning: ○ Quantiles ○ KMeans ○ Equal Width Number: 4

◉ Indicator Variable ○ Join Categorics ○ As Categoric ○ As Numeric

TIN จะแปลงข้อมูล Categoric ไปเป็น Binary Numeric
ตัวแปรใหม่จะเพิ่มตามจำนวนเชิงกลุ่มที่มี

| No. | Variable | Data Type and Number Missing |
|---|---|---|
| 14 | Humidity9am | Numeric [36 to 99; unique=60; mean=72; median=72]. |
| 15 | Humidity3pm | Numeric [13 to 96; unique=74; mean=44; median=43]. |
| 16 | Pressure9am | Numeric [996.50 to 1035.70; unique=190; mean=1019.71; median=1020.15]. |
| 17 | Pressure3pm | Numeric [996.80 to 1033.20; unique=193; mean=1016.81; median=1017.40]. |
| 18 | Cloud9am | Numeric [0 to 8; unique=9; mean=3; median=3]. |
| 19 | Cloud3pm | Numeric [0 to 8; unique=9; mean=4; median=4]. |
| 20 | Temp9am | Numeric [0.10 to 24.70; unique=178; mean=12.36; median=12.55; ignored]. |
| 21 | Temp3pm | Numeric [5.10 to 34.50; unique=200; mean=19.23; median=18.55]. |
| 22 | RainToday | Categorical [2 levels; ignored]. |
| 23 | RISK_MM | Numeric [0.00 to 39.80; unique=47; mean=1.43; median=0.00]. |
| 24 | RainTomorrow | Categorical [2 levels]. |
| 25 | BQ4_Temp9am | Categorical [4 levels]. No code export. |
| 26 | BK4_Temp9am | Categorical [4 levels]. No code export. |
| 27 | BE4_Temp9am | Categorical [4 levels]. No code export. |
| 28 | TIN_RainToday_No | Numeric [0.00 to 1.00; unique=2; mean=0.82; median=1.00; ignored]. No code export. |
| 29 | TIN_RainToday_Yes | Numeric [0.00 to 1.00; unique=2; mean=0.18; median=0.00]. No code export. |

# Rattle Training 6.Transforming Data




| No. | Variable | Data Type and Number Missing |
|---|---|---|
| 15 | Humidity3pm | Numeric [13 to 96; unique=74; mean=44; median=43]. |
| 16 | Pressure9am | Numeric [996.50 to 1035.70; unique=190; mean=1019.71; median=1020.15]. |
| 17 | Pressure3pm | Numeric [996.80 to 1033.20; unique=193; mean=1016.81; median=1017.40]. |
| 18 | Cloud9am | Numeric [0 to 8; unique=9; mean=3; median=3]. |
| 19 | Cloud3pm | Numeric [0 to 8; unique=9; mean=4; median=4]. |
| 20 | Temp9am | Numeric [0.10 to 24.70; unique=178; mean=12.36; median=12.55; ignored]. |
| 21 | Temp3pm | Numeric [5.10 to 34.50; unique=200; mean=19.23; median=18.55]. |
| 22 | RainToday | Categorical [2 levels; ignored]. |
| 23 | RISK_MM | Numeric [0.00 to 39.80; unique=47; mean=1.43; median=0.00]. |
| 24 | RainTomorrow | Categorical [2 levels; ignored]. |
| 25 | BQ4_Temp9am | Categorical [4 levels]. No code export. |
| 26 | BK4_Temp9am | Categorical [4 levels]. No code export. |
| 27 | BE4_Temp9am | Categorical [4 levels]. No code export. |
| 28 | TIN_RainToday_No | Numeric [0.00 to 1.00; unique=2; mean=0.82; median=1.00; ignored]. No code export. |
| 29 | TIN_RainToday_Yes | Numeric [0.00 to 1.00; unique=2; mean=0.18; median=0.00]. No code export. |
| 30 | TJN_RainToday_RainTomorrow | Categorical [4 levels]. No code export. |

TJN จะเชื่อมตัวแปรข้อมูลตามที่เลือก ผลที่ได้คือ ใน Record นั้นจะมีค่าของตัวแปรที่รวมกลุ่มกัน (ชื่อจะเชื่อมกัน)

# Rattle Training 6.Transforming Data

Data | Explore | Test | Transform | Cluster | Associate | Model | Evaluate | Log

Type: ○ Rescale ○ Impute ◉ Recode ○ Cleanup

Binning: ○ Quantiles ○ KMeans ○ Equal Width Number: 4

○ Indicator Variable ○ Join Categorics ◉ As Categoric ○ As Numeric

TFC จะแปลงข้อมูล Numeric ไปเป็น Categorical ที่มี levels ตาม unique

| No. | Variable | Data Type and Number Missing |
|---|---|---|
| 16 | Pressure9am | Numeric [996.50 to 1035.70; unique=190; mean=1019.71; median=1020.15]. |
| 17 | Pressure3pm | Numeric [996.80 to 1033.20; unique=193; mean=1016.81; median=1017.40]. |
| 18 | Cloud9am | Numeric [0 to 8; unique=9; mean=3; median=3]. |
| 19 | Cloud3pm | Numeric [0 to 8; unique=9; mean=4; median=4; ignored]. |
| 20 | Temp9am | Numeric [0.10 to 24.70; unique=178; mean=12.36; median=12.55; ignored]. |
| 21 | Temp3pm | Numeric [5.10 to 34.50; unique=200; mean=19.23; median=18.55]. |
| 22 | RainToday | Categorical [2 levels; ignored]. |
| 23 | RISK_MM | Numeric [0.00 to 39.80; unique=47; mean=1.43; median=0.00]. |
| 24 | RainTomorrow | Categorical [2 levels; ignored]. |
| 25 | BQ4_Temp9am | Categorical [4 levels]. No code export. |
| 26 | BK4_Temp9am | Categorical [4 levels]. No code export. |
| 27 | BE4_Temp9am | Categorical [4 levels]. No code export. |
| 28 | TIN_RainToday_No | Numeric [0.00 to 1.00; unique=2; mean=0.82; median=1.00; ignored]. No code export. |
| 29 | TIN_RainToday_Yes | Numeric [0.00 to 1.00; unique=2; mean=0.18; median=0.00]. No code export. |
| 30 | TIN_RainToday_RainTomorrow | Categorical [4 levels]. No code export. |
| 31 | TFC_Cloud3pm | Categorical [9 levels]. No code export. |

# Rattle Training 6.Transforming Data

Data | Explore | Test | Transform | Cluster | Associate | Model | Evaluate | Log

Type: ○ Rescale ○ Impute ◉ Recode ○ Cleanup

Binning: ○ Quantiles ○ KMeans ○ Equal Width Number: 4

○ Indicator Variable ○ Join Categorics ○ As Categoric ◉ As Numeric

TNM จะแปลงข้อมูล Categorical ไปเป็น Numeric variable ค่าตัวเลขแปลงจาก levels เดิมที่มี

| No. | Variable | Data Type and Number Missing |
|---|---|---|
| 17 | Pressure3pm | Numeric [996.80 to 1033.20; unique=193; mean=1016.81; median=1017.40]. |
| 18 | Cloud9am | Numeric [0 to 8; unique=9; mean=3; median=3]. |
| 19 | Cloud3pm | Numeric [0 to 8; unique=9; mean=4; median=4; ignored]. |
| 20 | Temp9am | Numeric [0.10 to 24.70; unique=178; mean=12.36; median=12.55; ignored]. |
| 21 | Temp3pm | Numeric [5.10 to 34.50; unique=200; mean=19.23; median=18.55]. |
| 22 | RainToday | Categorical [2 levels; ignored]. |
| 23 | RISK_MM | Numeric [0.00 to 39.80; unique=47; mean=1.43; median=0.00]. |
| 24 | RainTomorrow | Categorical [2 levels; ignored]. |
| 25 | BQ4_Temp9am | Categorical [4 levels]. No code export. |
| 26 | BK4_Temp9am | Categorical [4 levels]. No code export. |
| 27 | BE4_Temp9am | Categorical [4 levels]. No code export. |
| 28 | TIN_RainToday_No | Numeric [0.00 to 1.00; unique=2; mean=0.82; median=1.00; ignored]. No code export. |
| 29 | TIN_RainToday_Yes | Numeric [0.00 to 1.00; unique=2; mean=0.18; median=0.00]. No code export. |
| 30 | TJN_RainToday_RainTomorrow | Categorical [4 levels]. No code export. |
| 31 | TFC_Cloud3pm | Categorical [9 levels]. No code export. |
| 32 | TNM_RainToday | Numeric [1.00 to 2.00; unique=2; mean=1.18; median=1.00]. No code export. |

# Rattle Training 6.Transforming Data

- สรุปรูปแบบการ **Recode** ข้อมูล (ลองพิจารณาข้อมูลในแถวที่ 1)
  - **BQ4** แปลงข้อมูลเป็นเชิงกลุ่ม 4 ช่วง ข้อมูลแรกอยู่ในช่วง 12.6-17
  - **BK4** แปลงข้อมูลด้วย k-means 4 กลุ่ม ข้อมูลแรกอยู่ในกลุ่ม 12.4-18.6
  - **TIN** แปลงข้อมูลเชิงกลุ่มไปเป็น Binary numeric (1,0)
  - **TJN** เชื่อมค่าตัวแปร categoric ของตัวแปรที่เลือก
    - ในที่นี้มาจากตัวแปร RainToday กับ RainTommorow เชื่อมเป็น No_Yes
  - **TFC** แปลง numeric ไปเป็น categoric [6.7]
  - **TNM** แปลง categoric ไปเป็น numeric (1)

Rattle Dataset

| Rattle Dataset | MM | RainTom | BQ4_Temp9am | BK4_Temp9am | BE4_Temp9am | TIN_RainToday_No | TIN_RainToday_Yes | TJN_RainToday_RainTomorrow | TFC_Cloud3pm | TNM_RainToday |
|---|---|---|---|---|---|---|---|---|---|---|
| 1 | 3.6 | Yes | (12.6,17] | (12.8,18] | (12.4,18.6] | 1 | 0 | No_Yes | (6,7] | 1 |
| 2 | 3.6 | Yes | (17,24.7] | (12.8,18] | (12.4,18.6] | 0 | 1 | Yes_Yes | (2,3] | 2 |
| 3 | 9.8 | Yes | (12.6,17] | (12.8,18] | (12.4,18.6] | 0 | 1 | Yes_Yes | (6,7] | 2 |
| 4 | 2.8 | Yes | (12.6,17] | (12.8,18] | (12.4,18.6] | 0 | 1 | Yes_Yes | (6,7] | 2 |
| 5 | 0 | No | (7.6,12.6] | (7.4,12.8] | (6.24,12.4] | 0 | 1 | Yes_No | (6,7] | 2 |
| 6 | 0.2 | No | (7.6,12.6] | (7.4,12.8] | (6.24,12.4] | 1 | 0 | No_No | (4,5] | 1 |

# Rattle Training 6.Transforming Data

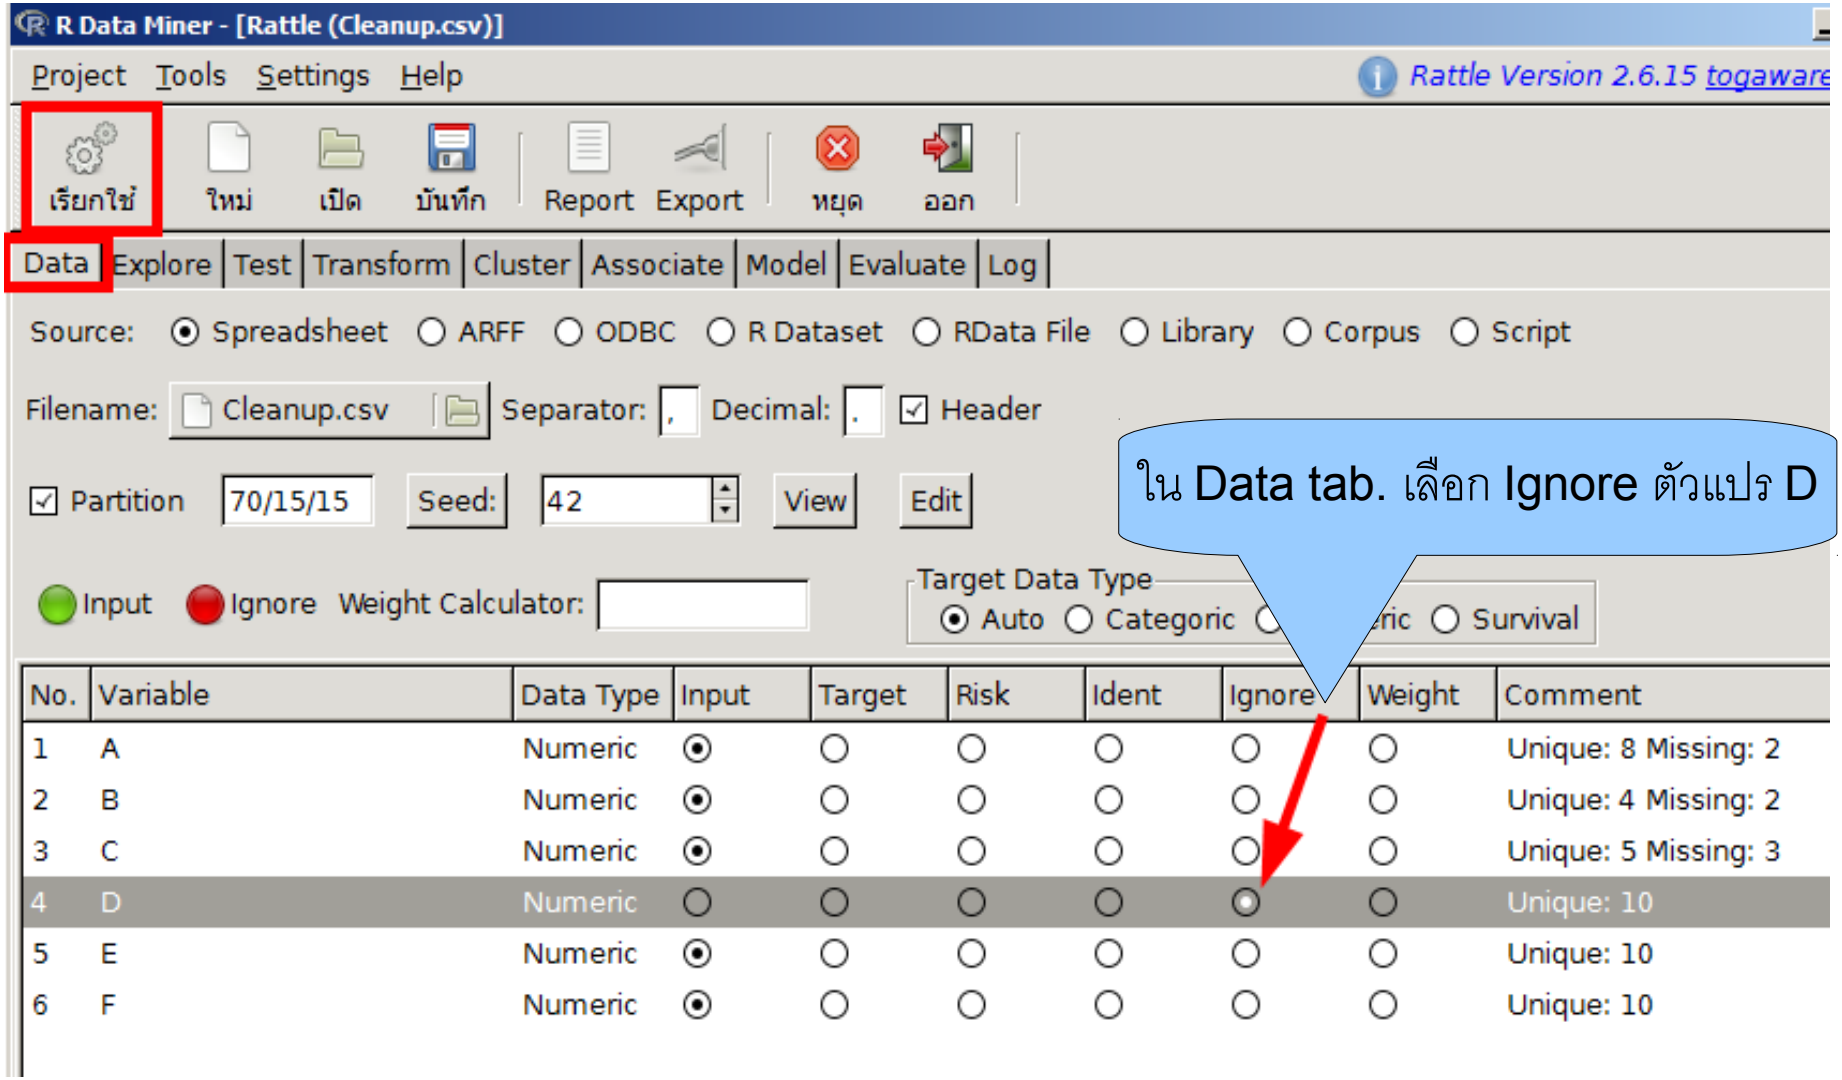
- การจัดการเกี่ยวกับ Cleaning missing
- ใช้ไฟล์ Cleanup.csv

Rattle Dataset

| Rattle Dataset | A | B | C | D | E | F |
|---|---|---|---|---|---|---|
| 1 | NA | 1 | NA | 1 | 11 | 10 |
| 2 | 2 | 1 | NA | 2 | 22 | 9 |
| 3 | 3 | 2 | NA | 3 | 33 | 8 |
| 4 | 4 | 2 | 1 | 4 | 44 | 7 |
| 5 | NA | NA | 1 | 5 | 55 | 6 |
| 6 | 6 | NA | 1 | 6 | 66 | 5 |
| 7 | 7 | 3 | 2 | 7 | 77 | 4 |
| 8 | 8 | 3 | 3 | 8 | 88 | 3 |
| 9 | 9 | 4 | 4 | 9 | 99 | 2 |
| 10 | 10 | 4 | 5 | 10 | 100 | 1 |

ใช้ไฟล์ Cleanup.csv

# Rattle Training 6.Transforming Data



# Rattle Training 6.Transforming Data

- ไปที่แท็บ **Transform** เลือก **Type** เป็น **Cleanup**
- เลือก **Delete Ignored** เพื่อลบตัวแปรดังกล่าว

Data | Explore | Test | Transform | Cluster | Associate | Model | Evaluate | Log

Type: ○ Rescale ○ Impute ○ Recode ◉ Cleanup

Select the type of cleanup you want and then Execute.

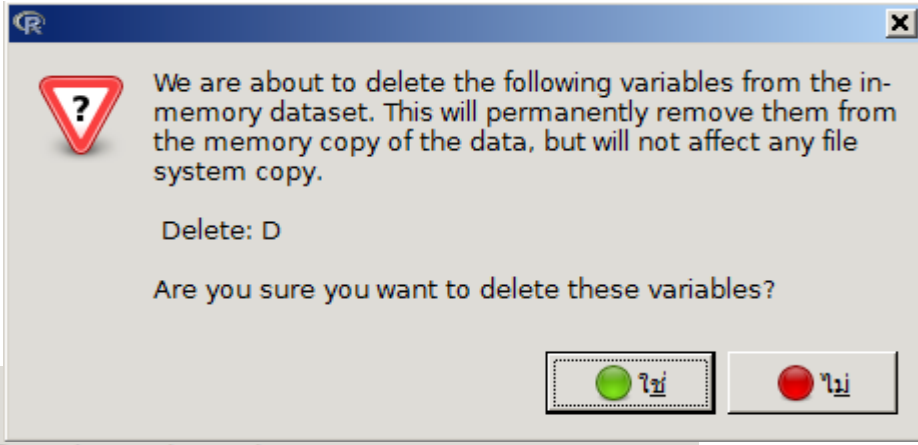
◉ Delete Ignored ○ Delete Selected ○ Delete Missing ○ Delete Obs with Missing

| No. | Variable | Data Type and Number Missing |
|---|---|---|
| 1 | A | Numeric [2 to 10; unique=8; mean=6; median=6; miss=2]. |
| 2 | B | Numeric [1 to 4; unique=4; mean=2; median=2; miss=2]. |
| 3 | C | Numeric [1 to 5; unique=5; mean=2; median=2; miss=3]. |
| 4 | D | Numeric [1 to 10; unique=10; mean=5; median=5]. |
| 5 | E | Numeric [11 to 100; unique=10; mean=59; median=60]. |
| 6 | F | Numeric [1 to 10; unique=10; mean=5; median=5]. |

Ignored

# Rattle Training 6.Transforming Data

- Rattle จะถามว่ายืนยันลบ D ?



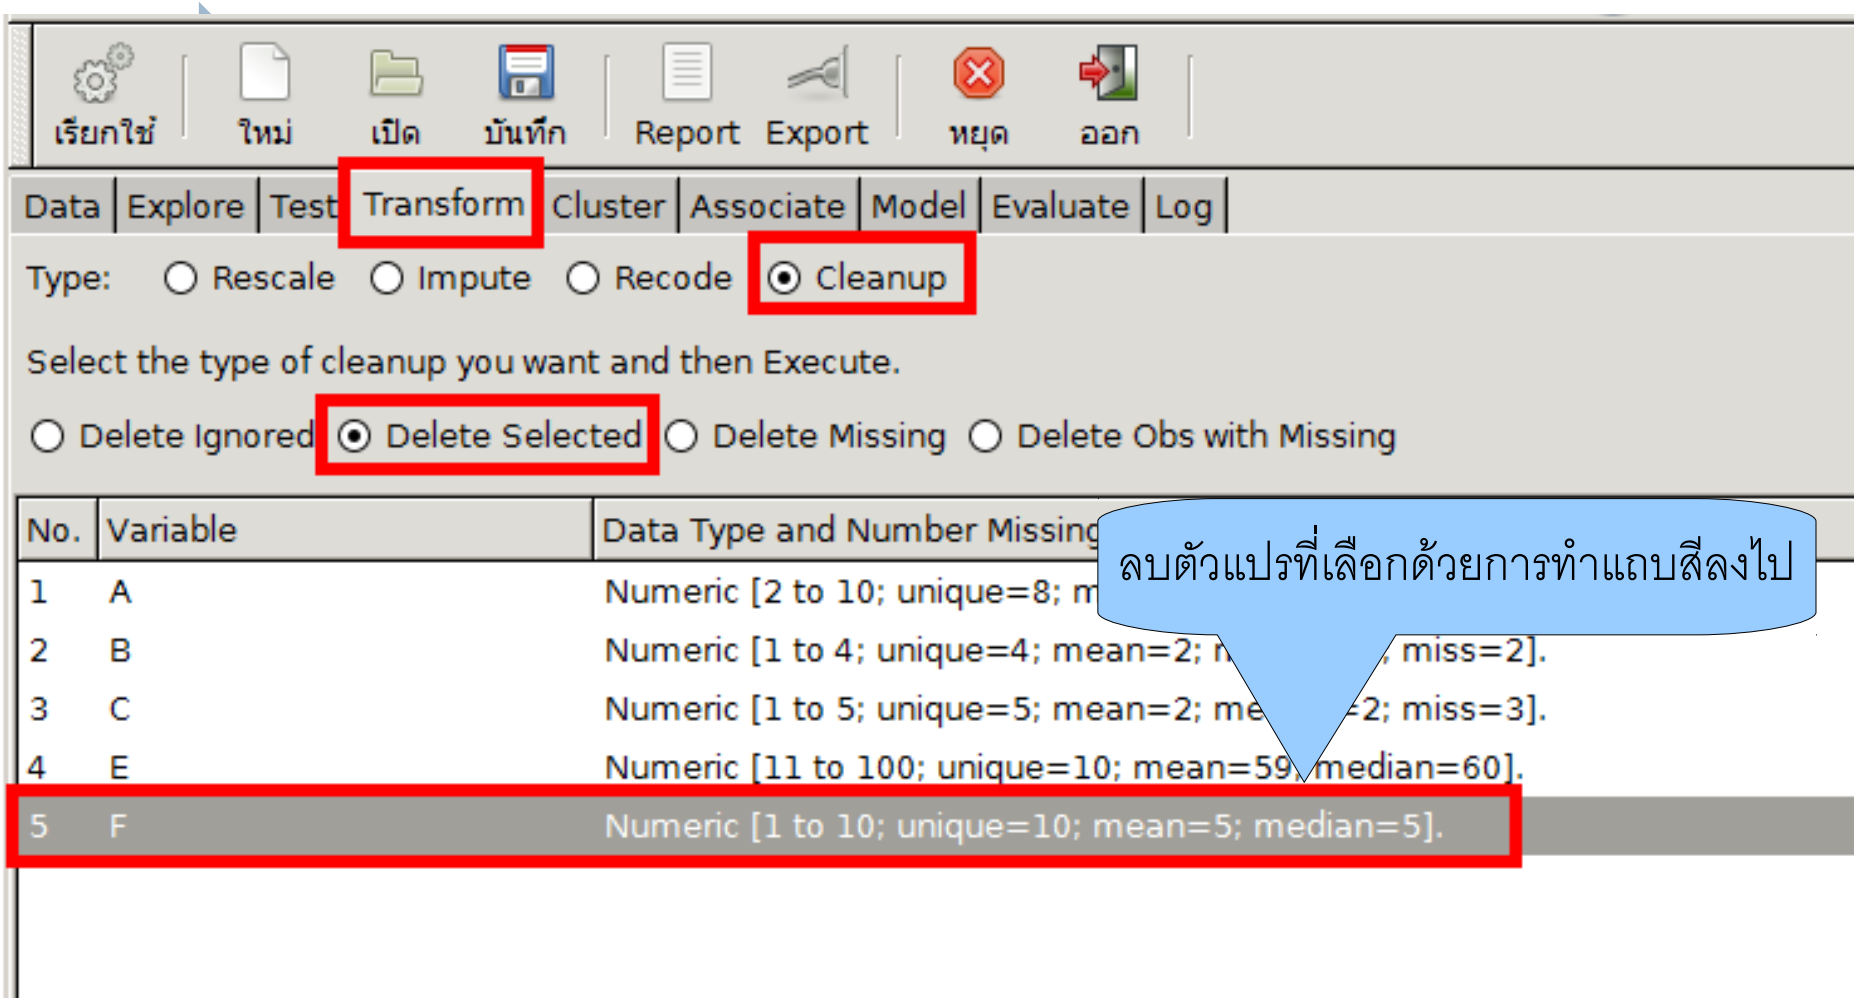

Select the type of cleanup you want and then Execute.

(•) Delete Ignored ( ) Delete Selected ( ) Delete Missing ( ) Delete Obs with Missing

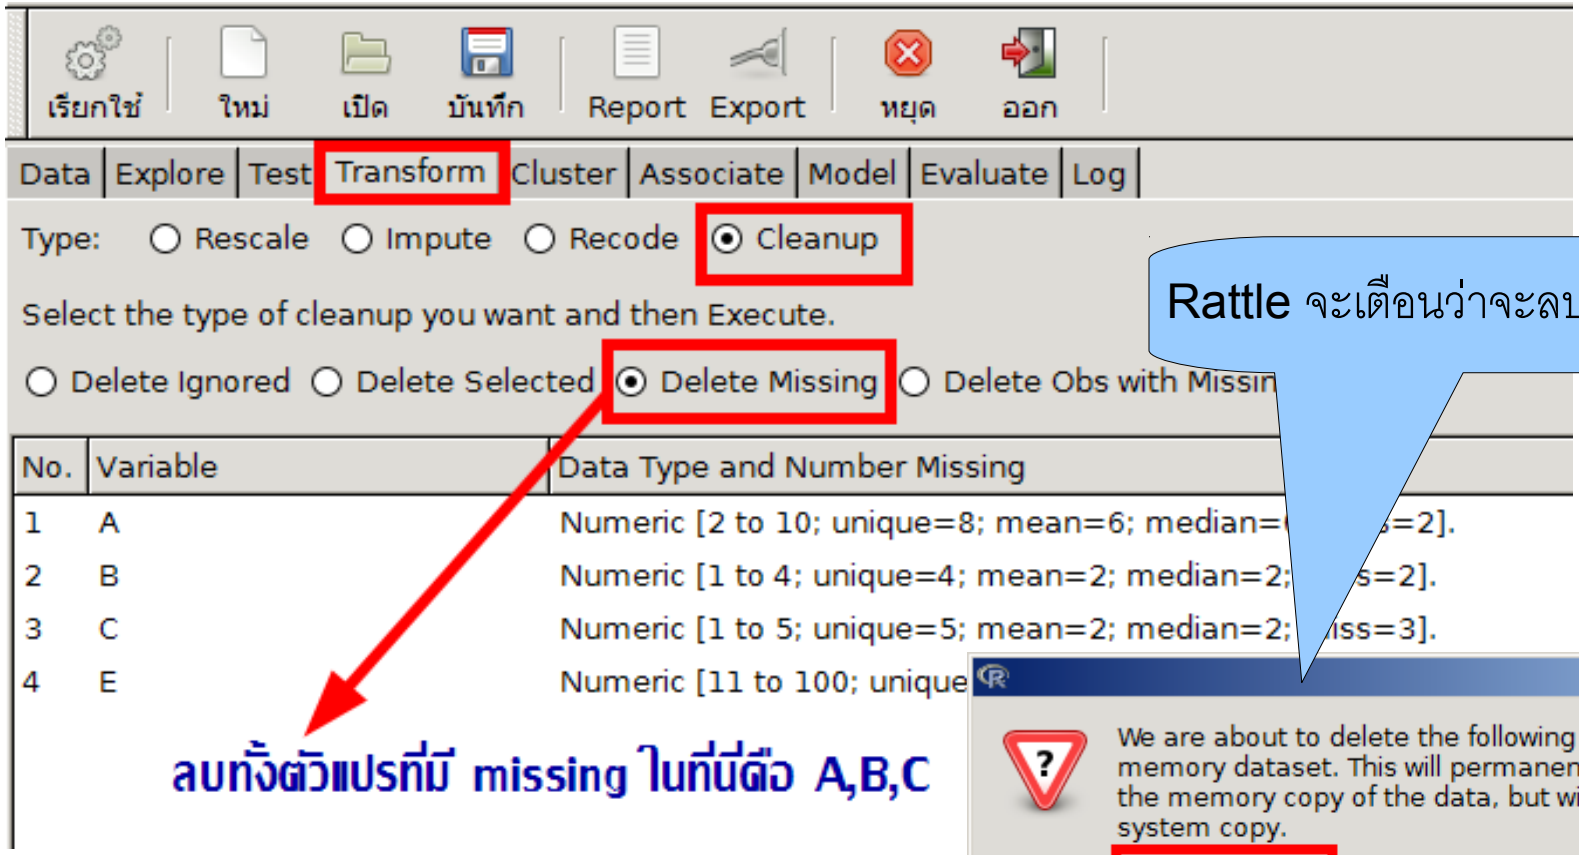
| No. | Variable | Data Type and Number Missing |
|---|---|---|
| 1 | A | Numeric [2 to 10; unique=8; mean=6; median=6; miss=2]. |
| 2 | B | Numeric [1 to 4; unique=4; mean=2; median=2; miss=2]. |
| 3 | C | Numeric [1 to 5; unique=5; mean=2; median=2; miss=3]. |
| 4 | E | Numeric [11 to 100; unique=10; mean=59; median=60]. |
| 5 | F | Numeric [1 to 10; unique=10; mean=5; median=5]. |

จากการลบ Ignored variable ทำให้ D หายไปจาก Dataset

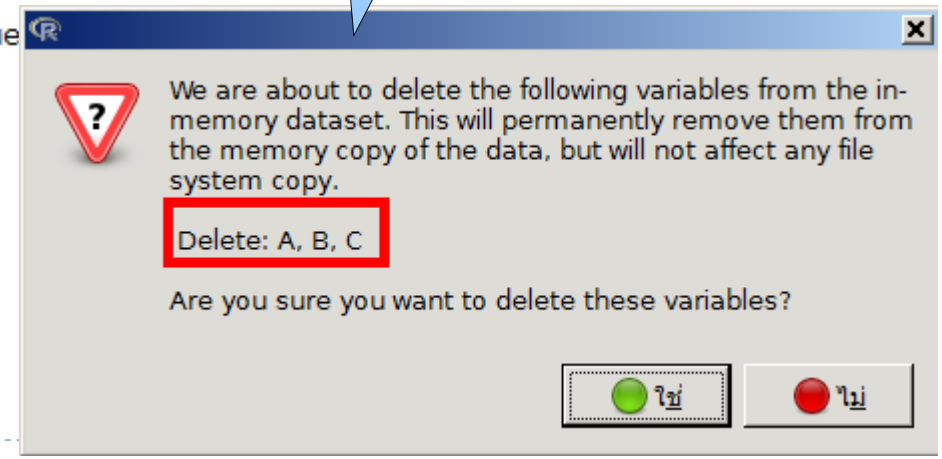
# Rattle Training 6.Transforming Data



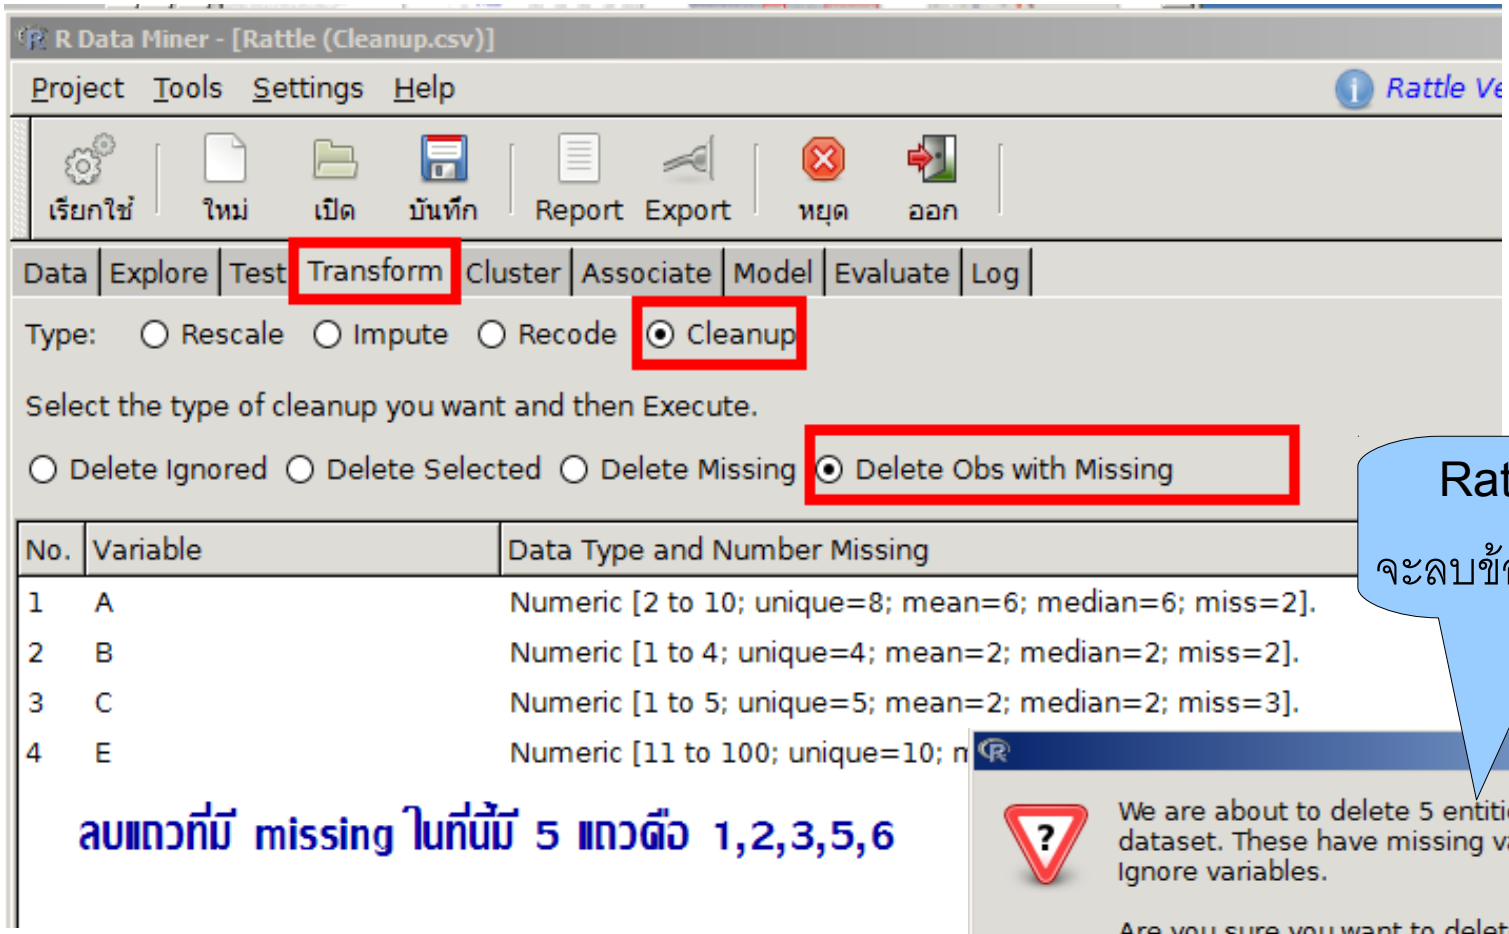
# Rattle Training 6.Transforming Data

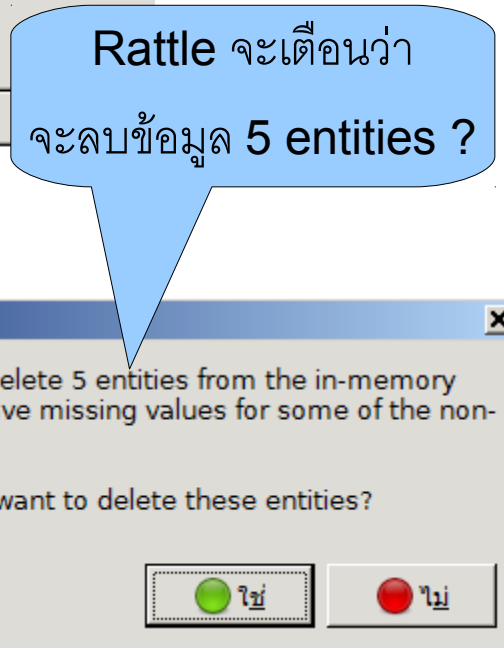



Rattle จะเตือนว่าจะลบตัวแปร A,B,C ?



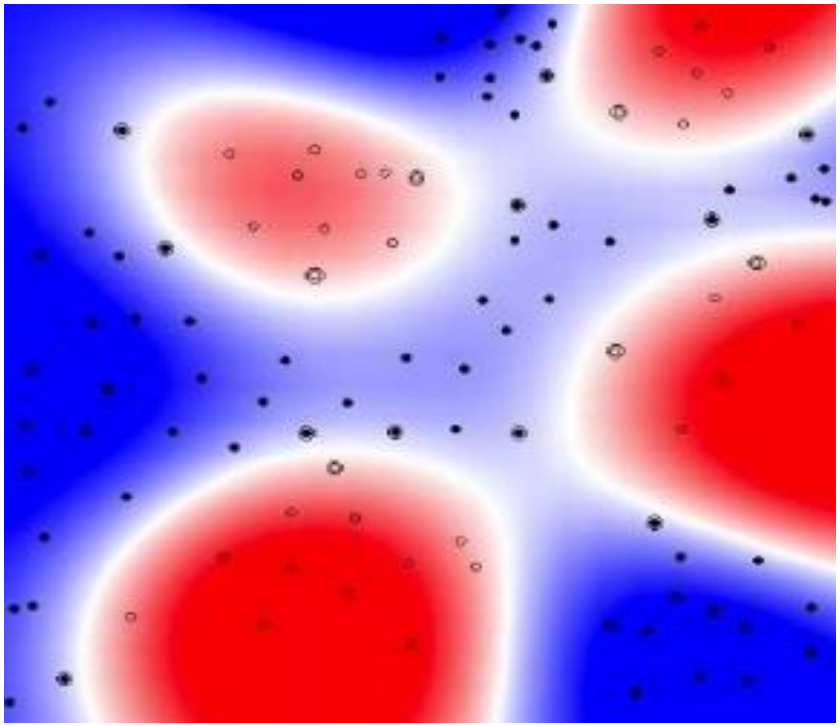
# Rattle Training 6.Transforming Data



# Clustering

- Type of data in cluster analysis
  - K-means clustering
  - Hierarchical clustering

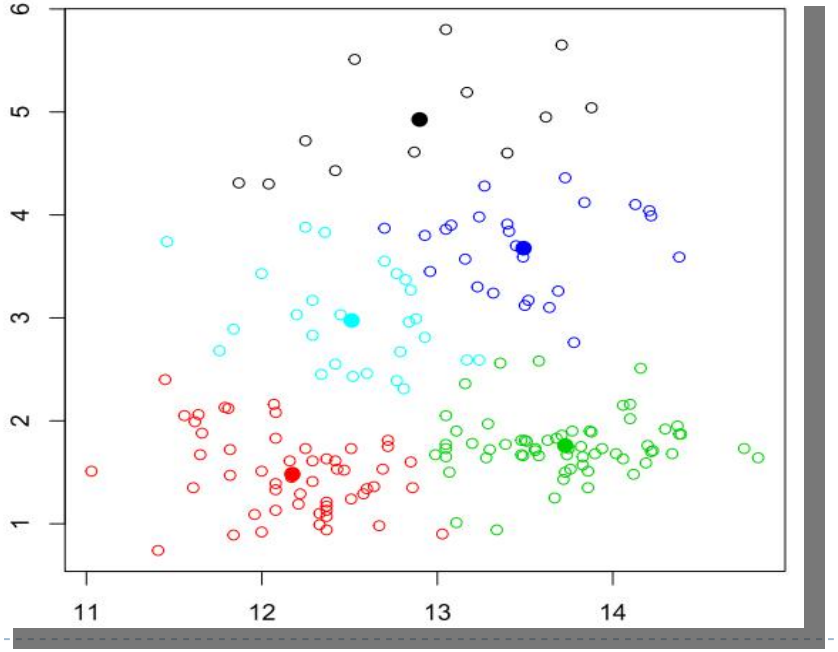


- Cluster Analysis
  - Analyze data without consulting a known class label
  - Maximizing the interclass similarity and minimizing the interclass similarity

# Clustering คืออะไร?

- เรานิยามแบ่งกลุ่มคนเป็น {คนชั่ว-คนดี} {คนรวย-คนจน}
- ในทางธุรกิจเราแบ่งกลุ่มลูกค้าเป็น {คนที่ซื้อ-คนที่ไม่ซื้อ} {พึงพอใจ-ไม่พึงพอใจ}
- อื่น ๆ เช่น {เครดิตดี-เครดิตแย่} {โกง-ไม่โกง} {เลือกพรรค ก.-เลือกพรรค ข.} เป็นต้น

โลกของเรามักจะแบ่งกลุ่มไว้ในธรรมชาติ อยู่ที่เราจะมองออกหรือไม่?



# Clustering คือ

- **Cluster :** คือการหาวิธีการแบ่งข้อมูลออกเป็นกลุ่มตามลักษณะประจำที่มีของแต่ละระเบียน โดยไม่มีลักษณะกลุ่ม แต่ใช้ระยะในการบ่งบอกความคล้ายและความแตกต่างของระเบียน
- ระยะห่างระหว่างระเบียนที่คล้ายกันจะมีน้อย ส่วนระยะห่างของระเบียนที่ต่างกันจะมีมากกว่า
- **Cluster** มีลักษณะเป็น **unsupervised classification**

# การประยุกต์ใช้ Clustering

- Pattern Recognition
- Spatial Data Analysis
  - Create thematic map in GIS by clustering feature spaces
  - Detect spatial cluster and explain them in spatial data mining
- Image Processing
- Economic Science (especially market research)
- www
  - Document (text) classification
  - Question Categorization
  - Weblog Access Patterns

# การประยุกต์ใช้ Clustering (ต่อ)

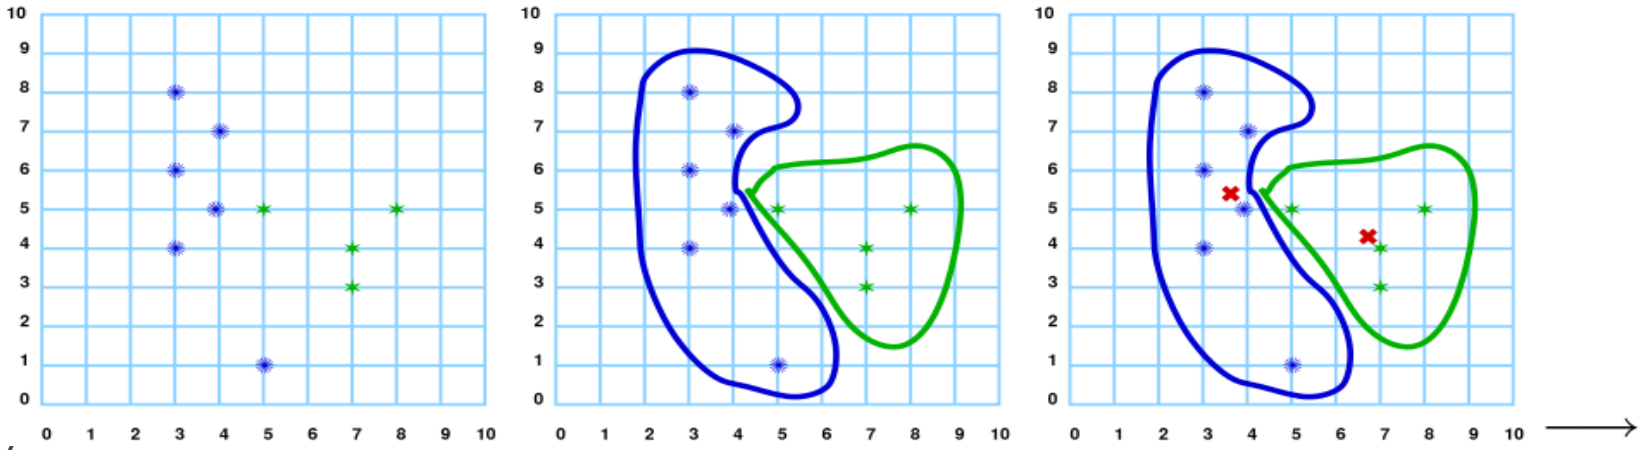
- **ด้านการตลาด : clustering** สามารถช่วยนักการตลาดค้นพบกลุ่มของลูกค้าใหม่ๆ แล้วนำความรู้นี้ไปพัฒนาสินค้ามาตอบสนองให้ตรงตามกลุ่ม อาจจะมองในแง่ของการบริหาร คือ จัดหน่วยงานขึ้นมาบริการกลุ่มลูกค้าแต่ละกลุ่ม ได้อย่างโดนใจก็ได้
- **ด้านประกันภัย : clustering** ช่วยระบุกลุ่มของผู้ถือกรมธรรม์ที่มีความเสี่ยงสูง หรือกลุ่มที่มีการเคลมประกันบ่อย (เอาไว้ออกกฎเกณฑ์หรือแนวปฏิบัติ)
- **ด้านการวางผังเมือง : clustering** ช่วยระบุกลุ่มของที่อยู่อาศัย ที่แบ่งตามลักษณะของบ้าน ,ราคา และที่ตั้งทางภูมิศาสตร์
- **ด้านวิทยาศาสตร์ : clustering** ช่วยให้นักวิทยาศาสตร์จัดกลุ่มของดอกไม้ ,ต้นไม้ สัตว์ โปรตีน ดีเอ็นเอ ตามลักษณะประจำของแต่ละระเบียนได้

# รูปแบบการวิเคราะห์ clustering

- วิธีแบ่งกั้น **(Partitioning)** : ระเบียนข้อมูลถูกแบ่งกั้นเป็นกลุ่มที่ไม่มีสมาชิกร่วมกันเลย โดยใช้การกั้นระหว่างกลุ่มด้วยระยะทาง
- ใช้ระดับชั้น **(Hierarchy)** : ระเบียนข้อมูลถูกรวมกลุ่มโดยการใช้ระดับชั้น **(hierarchical decomposition)** ที่ได้มาจากการคำนวนระยะห่างของแต่ละกลุ่มข้อมูล
- ใช้ความหนาแน่น **(Density-based)** : ระเบียนข้อมูลถูกรวมกันโดยใช้การเชื่อมกันและความหนาแน่น
- ใช้กริด **(Grid-based)** : ระเบียนข้อมูลถูกแบ่งตามกริด
- ใช้ตัวแบบ **(Model-based)** : เป็นการตั้งสมมติฐานของตัวแบบ แล้วเลือกตัวแบบที่แบ่งกั้นด้วยพารามิเตอร์ที่ดีที่สุด

# ขั้นตอนวิธีการ clustering ด้วยวิธีแบ่งกั้น

- วิธีการแบ่งกั้น : ข้อมูล **n** ระเบียนแบ่งเป็น **k** กลุ่มที่ไม่มีสมาชิกร่วมกัน
- ขั้นตอนวิธีการแบ่งกลุ่มตามค่าเฉลี่ย **k** ตัว **(k mean)**
  - แบ่งข้อมูลเป็น **k** กลุ่มที่ไม่ใช่เซตว่าง
  - คำนวณจุดกึ่งกลาง **(centroid)** ของกลุ่มโดยใช้ค่าเฉลี่ยเลขคณิต **(mean)**
  - สำหรับแต่ละระเบียน นำระเบียนเทียบกับจุดกึ่งกลางเพื่อกำหนดกลุ่มให้กับระเบียน โดยเลือกระยะจากระเบียนไปจุดกึ่งกลางที่ใกล้ที่สุด
  - วนซ้ำจนกระทั่งไม่มีการเปลี่ยนกลุ่มของระเบียน หรือครบจำนวนรอบสูงสุดที่กำหนดไว้

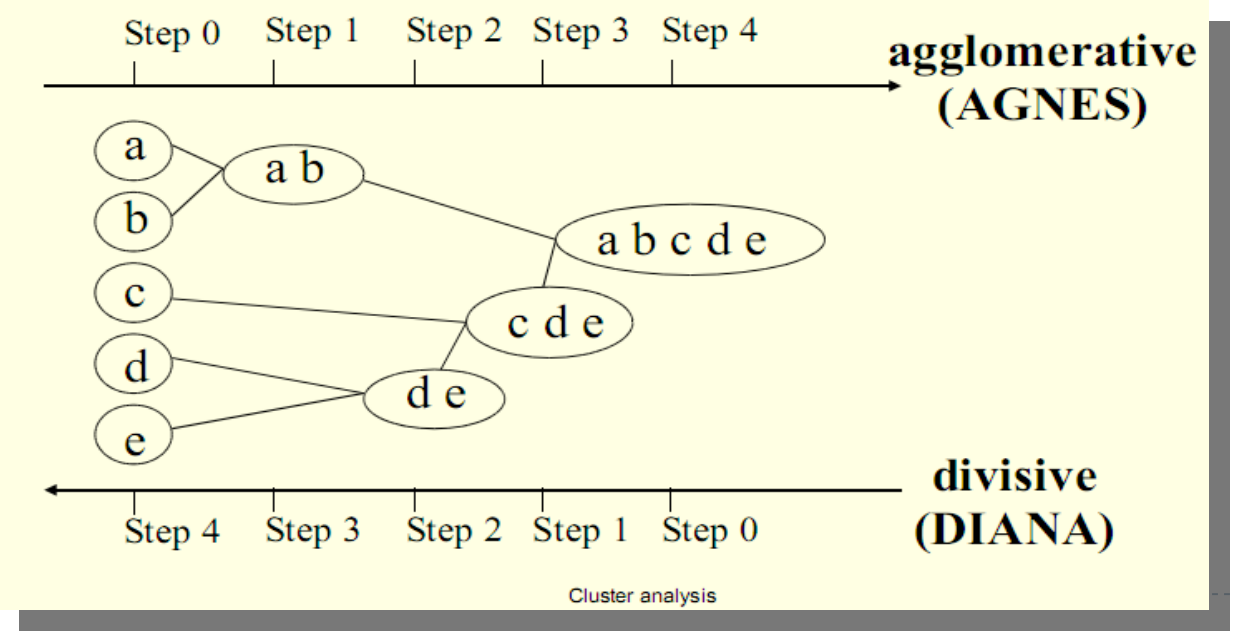


# K-means Clustering

- ผลลัพธ์ที่ได้จากการวิเคราะห์ **clustering** ได้มาจากโครงสร้างในข้อมูล ดังนั้นการ **clustering** จึงไม่มีลักษณะการบอกว่าการเกาะกลุ่มนั้นถูกหรือผิด
- ข้อดีของ **k-means**
  - เหมาะกับข้อมูลจำนวนมาก (200 ขึ้นไป)
  - มีประสิทธิภาพสูง ขั้นตอนใช้วิธี O(tkn), เมื่อ **n** คือจำนวนข้อมูล **k** คือจำนวนกลุ่ม และ **t** คือจำนวนรอบที่ต้องวนซ้ำโดยปกติแล้วค่า **k** และ **t** จะน้อยกว่า **n** มาก
- ข้อเสียของ **k-means**
  - ใช้ได้เฉพาะลักษณะประจำที่เป็นจำนวนต้องใช้ค่าเฉลี่ย
  - ต้องมีการกำหนดค่า **k** ก่อนเริ่มขั้นตอนวิธี
  - ข้อมูลที่ผิดปกติ (outlier) จะทำให้ค่าเฉลี่ยมีค่าที่มากหรือน้อยเกินไป
  - ไม่เหมาะกับ **non-convex clusters** (ข้อมูลที่กระจายกันทั่ว)

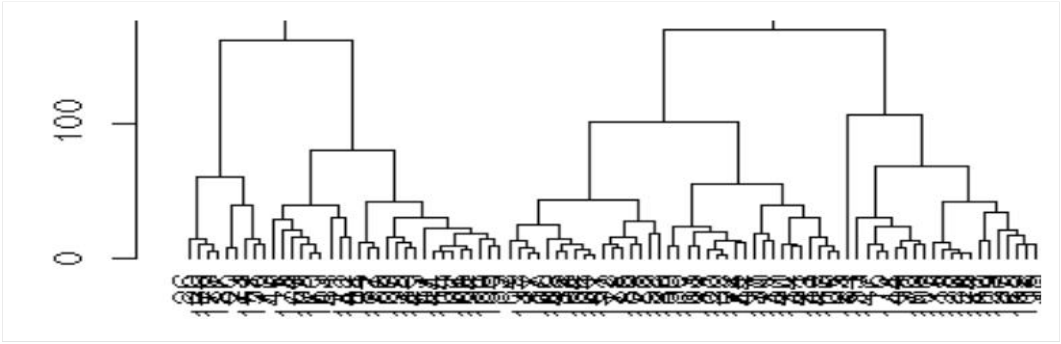
# ขั้นตอนวิธีการ clustering ด้วยวิธีระดับชั้น (Hierarchy)

- ใช้ **distance matrix** เป็นเงื่อนไขในการเกาะกลุ่ม วิธีการนี้ไม่ต้องการให้กำหนดค่า **k** แต่ต้องการกำหนดเงื่อนไขในการหยุด
- แยกกลุ่มข้อมูลเป็นระดับชั้นแบบต้นไม้ **(tree of clusters)** เรียกว่า **dendrogram**
- วิธีการเกาะกลุ่มของข้อมูลคือการตัดผัง **dendrogram** ตามระดับที่ต้องการ ส่วนประกอบที่เชื่อมกันแสดงถึงการเกาะกลุ่มที่เกิดขึ้น



# Hierarchical Cluster

- ข้อดี
  - ไม่จำเป็นต้องทราบจำนวนกลุ่มมาก่อน กรรมวิธีจัดกลุ่มให้
  - ใช้กับข้อมูลได้ทั้ง **Interval scale, ratio scale ,count data** หรือ **binary**
- ข้อเสีย
  - ไม่เหมาะกับข้อมูลปริมาณมาก ความซับซ้อนของเวลาคือ $O(n^2)$ เมื่อ **n** แทนจำนวนข้อมูลทั้งหมด
  - ไม่มีการแยกกลุ่มออกจากกัน เมื่อรวมแล้วข้อมูลจะอยู่ในกลุ่มนั้นตลอด



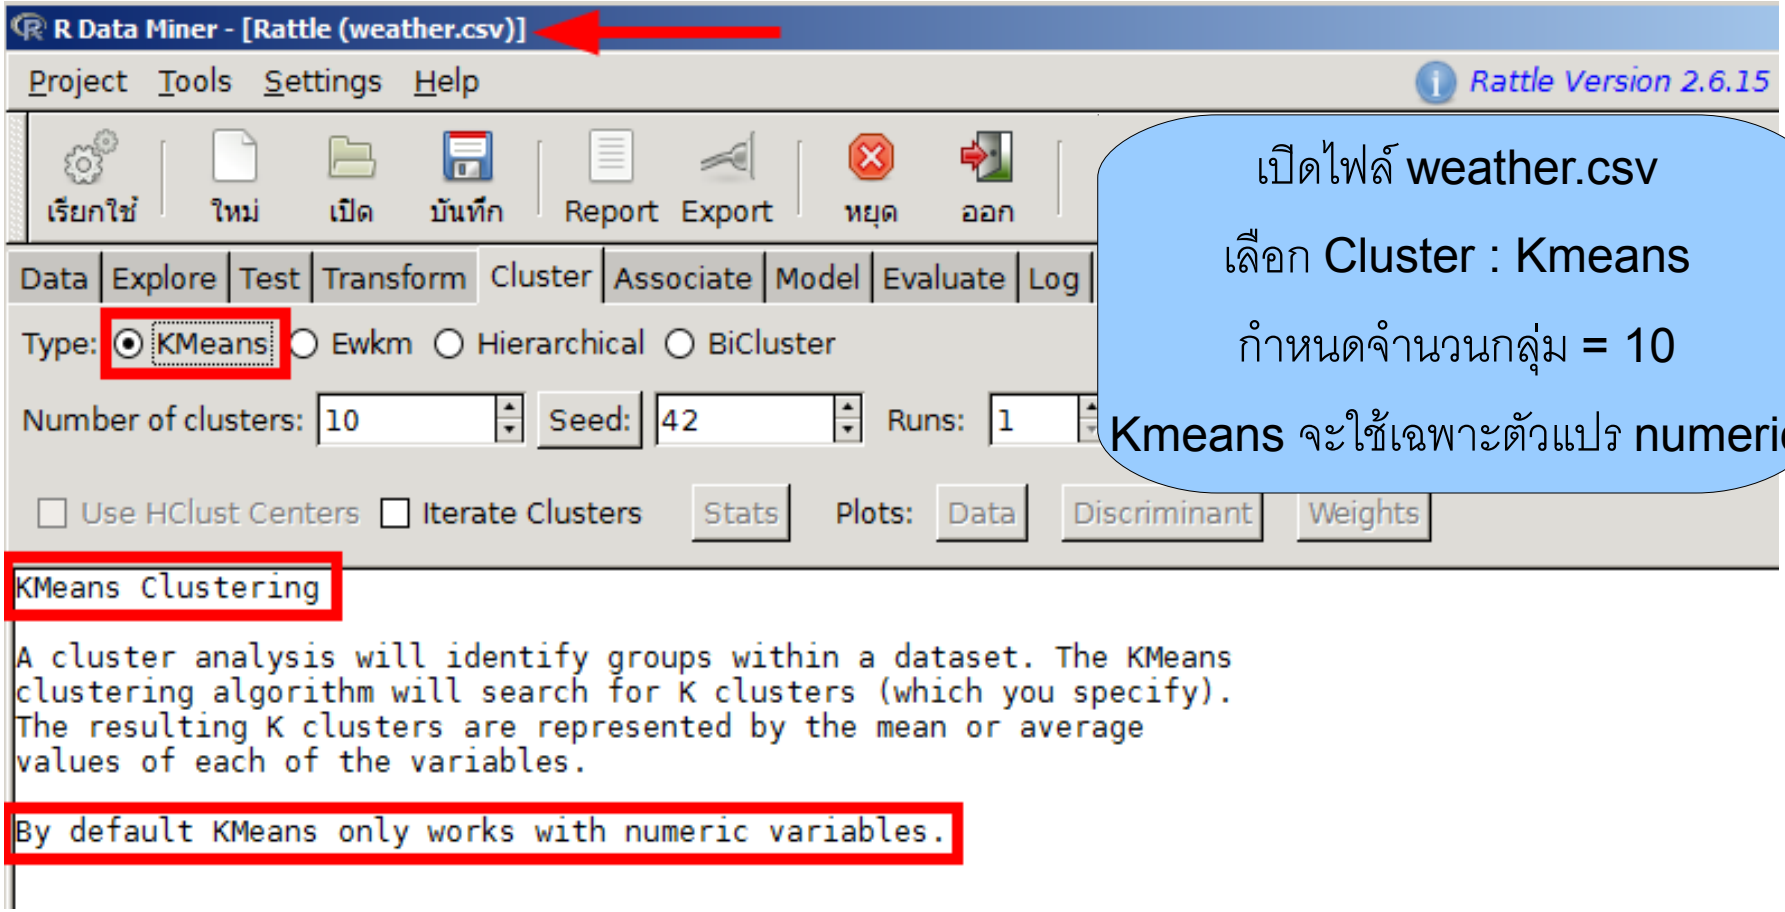
# ลักษณะข้อมูลที่ต้องการของ Clustering

- การวิเคราะห์การเกาะกลุ่ม **(Cluster analysis)** ต้องใช้ระยะห่างระหว่างแต่ละ **records (centroid distance)** เพื่อบ่งบอกความเหมือน หรือต่างกัน
- การวัดระยะระหว่างแต่ละ **records** ใช้ผลรวมของการคำนวณระยะระหว่างลักษณะประจำแต่ละตัว
  - ในกรณีที่ลักษณะประจำเป็นจำนวน เราสามารถใช้ค่ากำลังสองของผลต่าง
  - ในกรณีที่ลักษณะประจำเป็นค่าที่ไม่ต่อเนื่อง เราสามารถใช้การนับความแตกต่างระหว่างลักษณะประจำที่ต่างกันได้
  - ลักษณะประจำนำเข้าอาจเป็นค่าต่อเนื่องหรือค่าไม่ต่อเนื่องก็ได้ เพราะใช้วิธีการพิจารณาการแยกกลุ่ม จากการคำนวณระยะห่างด้วยสเกลที่เหมาะสม

# สรุป Clustering

- **Cluster analysis** เป็นวิธีการทำเหมืองข้อมูลแบบ **unsupervised**
- มีประโยชน์สำหรับการจัดกลุ่มประชากรขนาดใหญ่ อาจใช้ประโยชน์จากแต่ละ **sub-population** มาทำ **data mining** ด้วยวิธีอื่นอีกได้
- ชุดข้อมูลที่ต้องการเป็นเชิงกลุ่มหรือตัวเลข ,ลำดับ หรือ **Binary (0,1)**
- เนื่องจากต้องใช้ความเข้าใจด้านเทคนิคสูง ดังนั้นวิธีนี้จะมีประสิทธิภาพมากถ้ามีผู้ชำนาญการคอยให้คำแนะนำ

# Rattle Training 7. Cluster Analysis




เปิดไฟล์ weather.csv

เลือก Cluster : Kmeans

กำหนดจำนวนกลุ่ม = 10

Kmeans จะใช้เฉพาะตัวแปร numeric

# Rattle Training 7. Cluster Analysis

```
Cluster sizes:

[1] "23 17 22 22 17 36 23 34 22 32"

Data means:

      MinTemp       MaxTemp      Rainfall   Evaporation      Sunshine
     7.145565     20.372177      1.377419      4.544355      8.082661
WindGustSpeed  WindSpeed9am  WindSpeed3pm   Humidity9am   Humidity3pm
    39.943548      9.818548     18.056452     71.471774     43.858871
  Pressure9am   Pressure3pm      Cloud9am      Cloud3pm       Temp9am
  1019.748387   1016.978629      3.689516      3.850806     12.269355
     Temp3pm
    19.081048

Cluster centers:

      MinTemp  MaxTemp   Rainfall Evaporation  Sunshine WindGustSpeed
1   8.5000000 21.04783 1.27826087    6.330435 10.495652      57.95652
2  11.6058824 30.94706 0.11764706    7.647059 11.276471      43.64706
3  13.4136364 28.76818 1.02727273    6.200000  9.463636      45.22727
4   9.1818182 16.90000 4.94545455    3.800000  2.190909      30.90909
5   7.7411765 15.19412 3.58823529    3.305882  5.658824      61.47059
6   2.7666667 17.16389 0.66111111    2.655556  7.688889      25.47222
7  -0.7913043 13.70870 0.03478261    1.921739  7.495652      39.30435
8  11.3088235 26.37353 0.50000000    6.288235 10.258824      35.88235
9   1.5045455 17.55000 0.23636364    3.500000 10.222727      33.72727
10  7.8625000 17.59687 2.21875000    4.518750  6.121875      41.50000
```

สรุปค่าต่างๆ ที่ได้จาก Kmeans 10 กลุ่ม

# Rattle Training 7. Cluster Analysis

- Model Quality อาจจะประเมินจากค่าความแตกต่างกันของค่า means
- Tuning Option
  - Number of clusters ระบุเป็นตัวเลขที่มากกว่า 1 แต่ไม่มากกว่าจำนวน cases
  - Iterate Clusters จะแสดงค่า sum of within cluster sum of squares
  - Iterate Cluster จะคำนวน sum SS ไปจนถึง cluster สูงสุดเพื่อเลือกว่ากี่กลุ่มดี
  - Seed ใช้ปรับจุดเริ่มต้นในการสุ่ม (ถ้าแต่ละครั้งค่า seed ต่างกัน model มักจะต่างกัน)

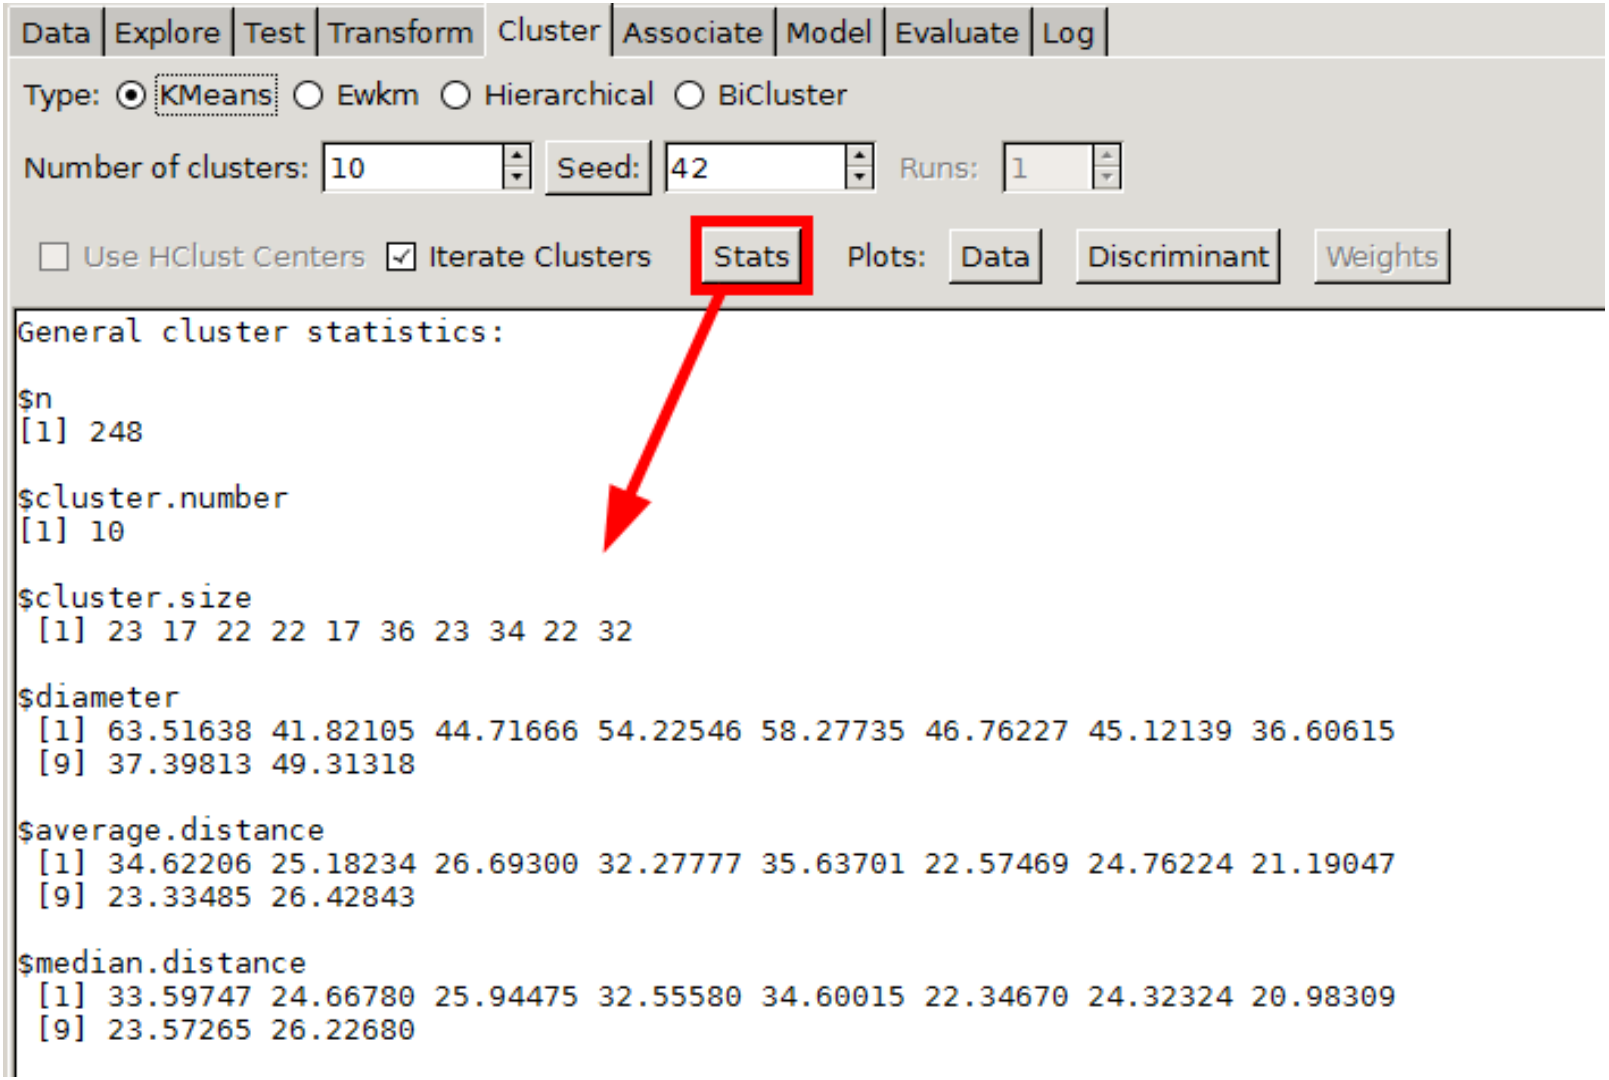
```
Within cluster sum of squares:

 [1] 14459.755  5469.311  8061.781 11733.534 11062.079  9582.717  7258.203
 [8]  7806.196  6146.200 11528.942

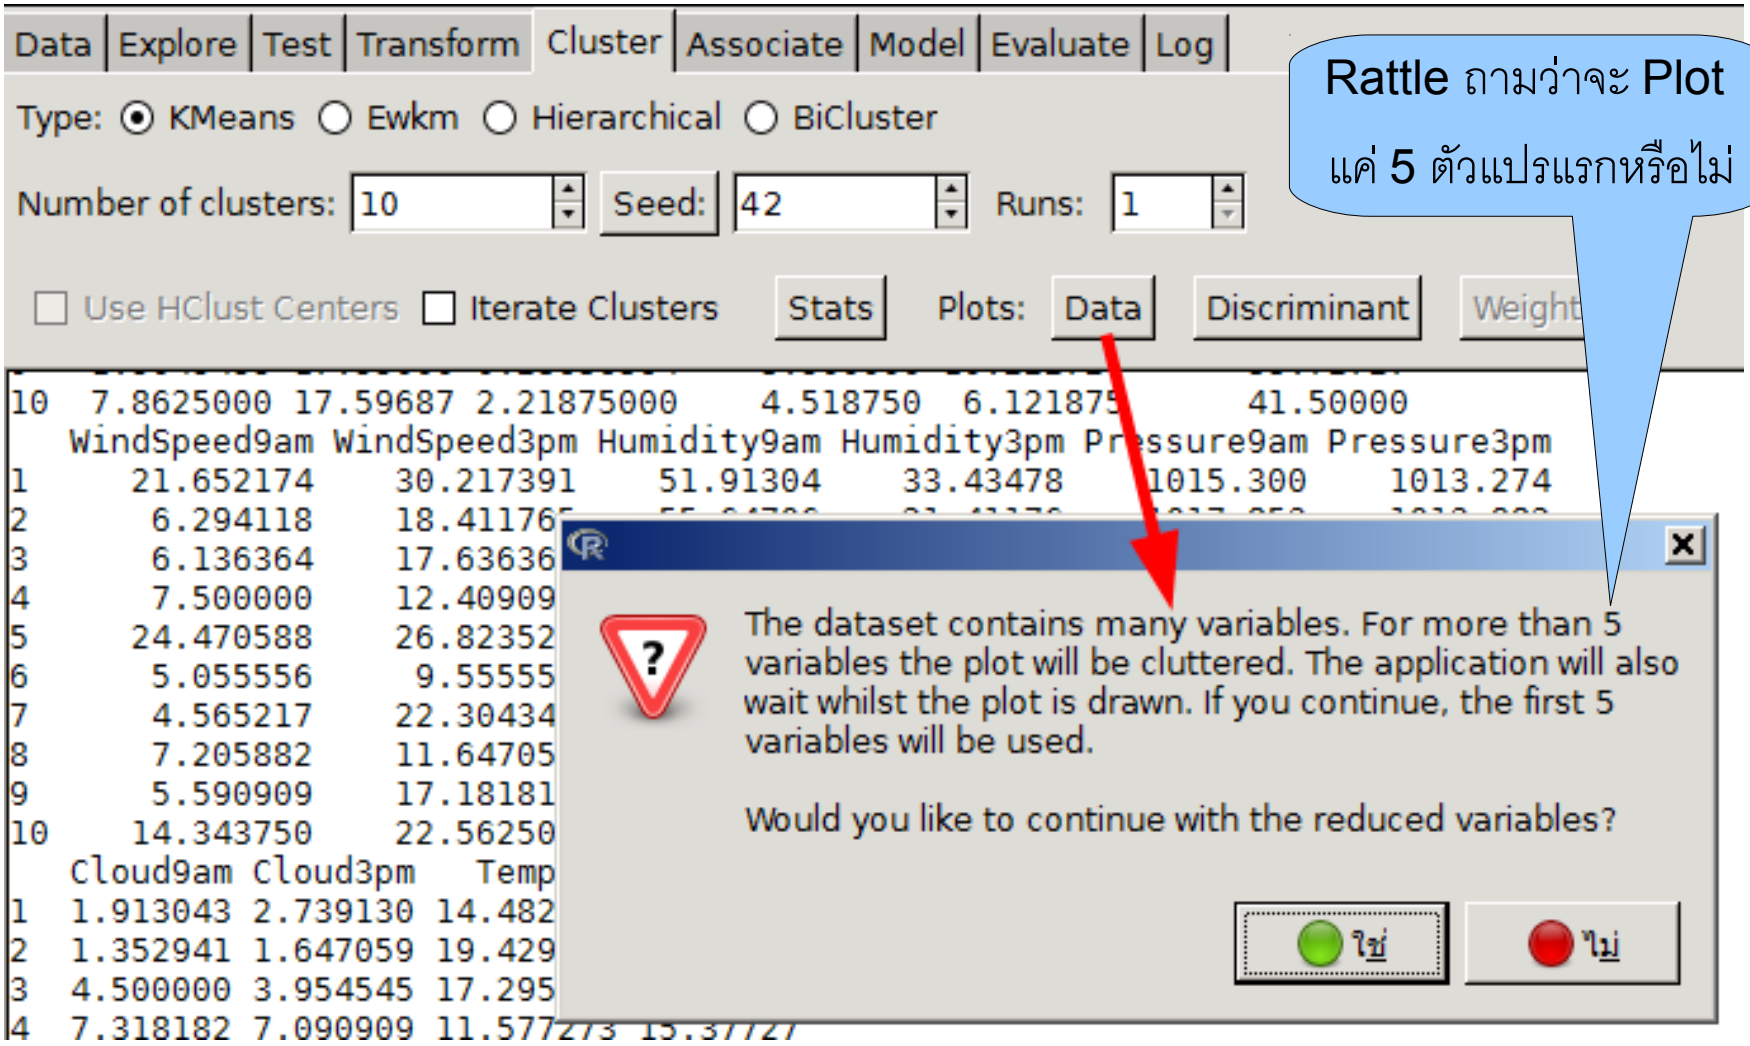
Time taken: 0.02 secs

Rattle timestamp: 2012-01-14 14:14:44 amto
================================================================
```

# Rattle Training 7. Cluster Analysis

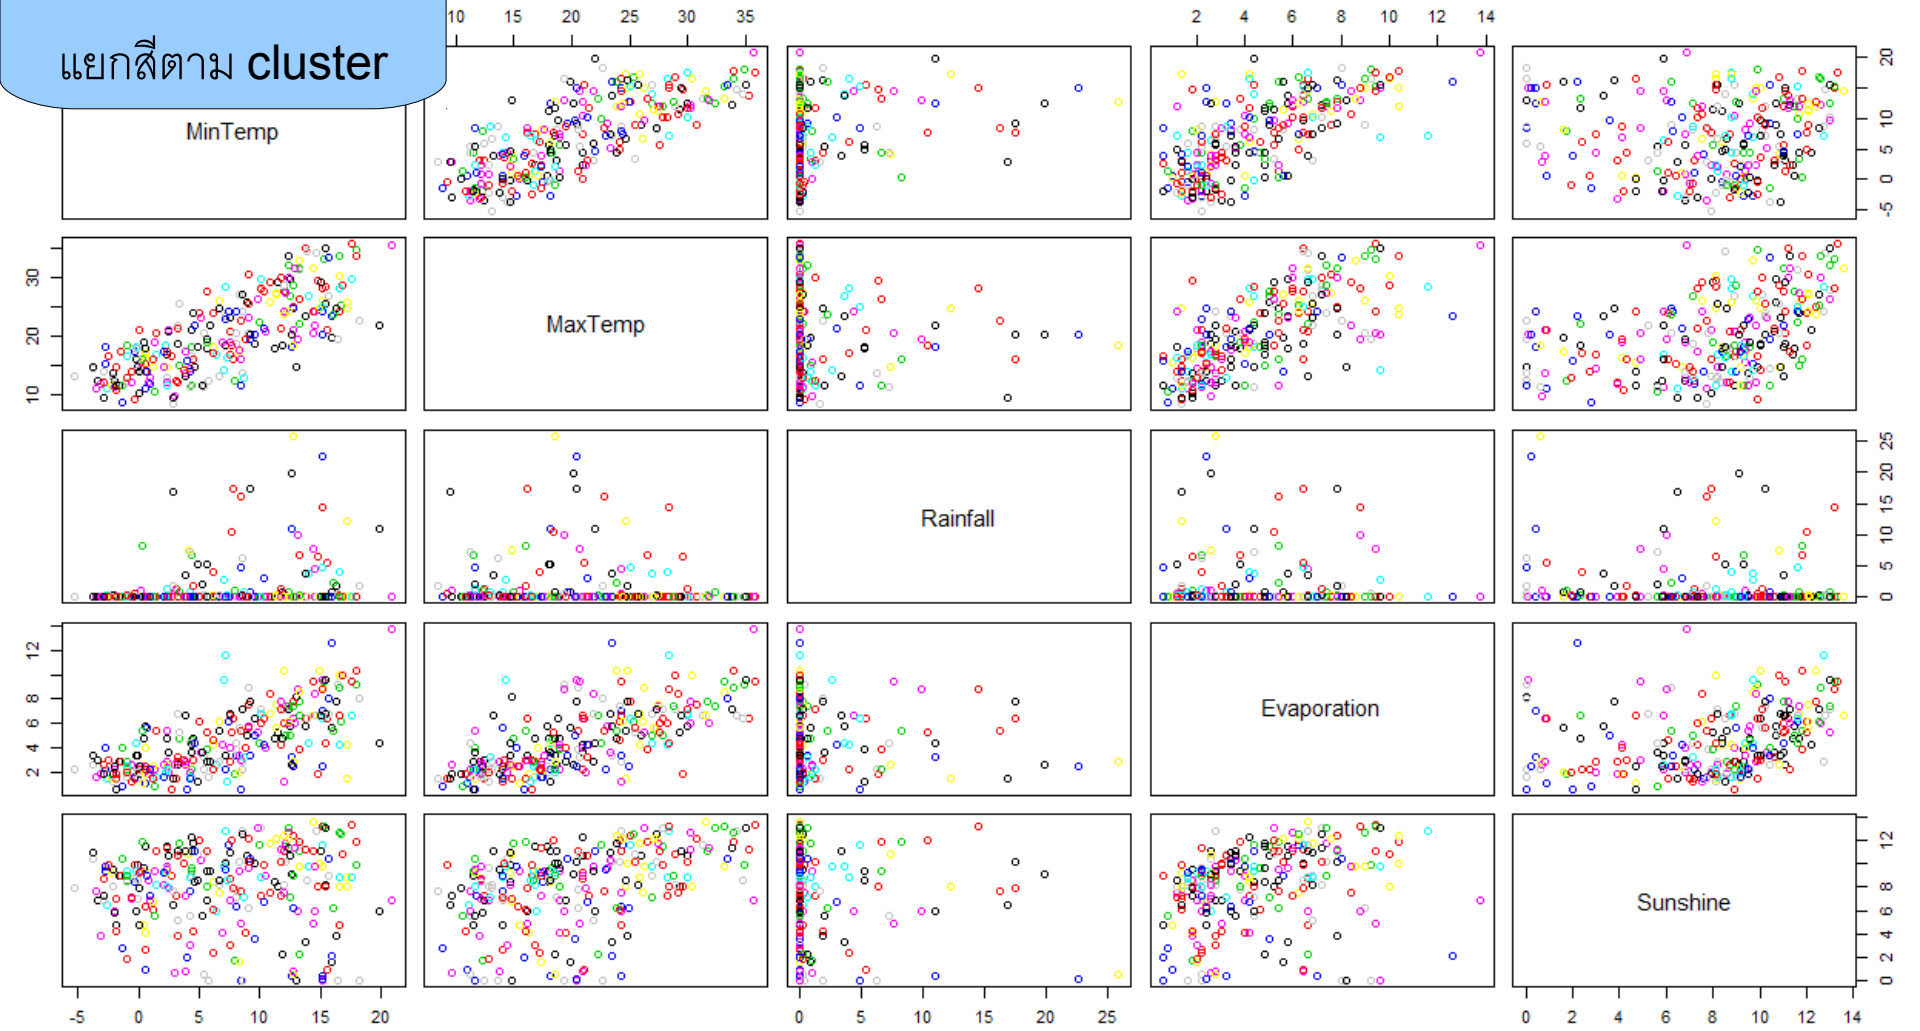


# Rattle Training 7. Cluster Analysis



# Rattle Training 7. Cluster Analysis

Scatter plot 5 ตัวแปร แยกสีตาม cluster



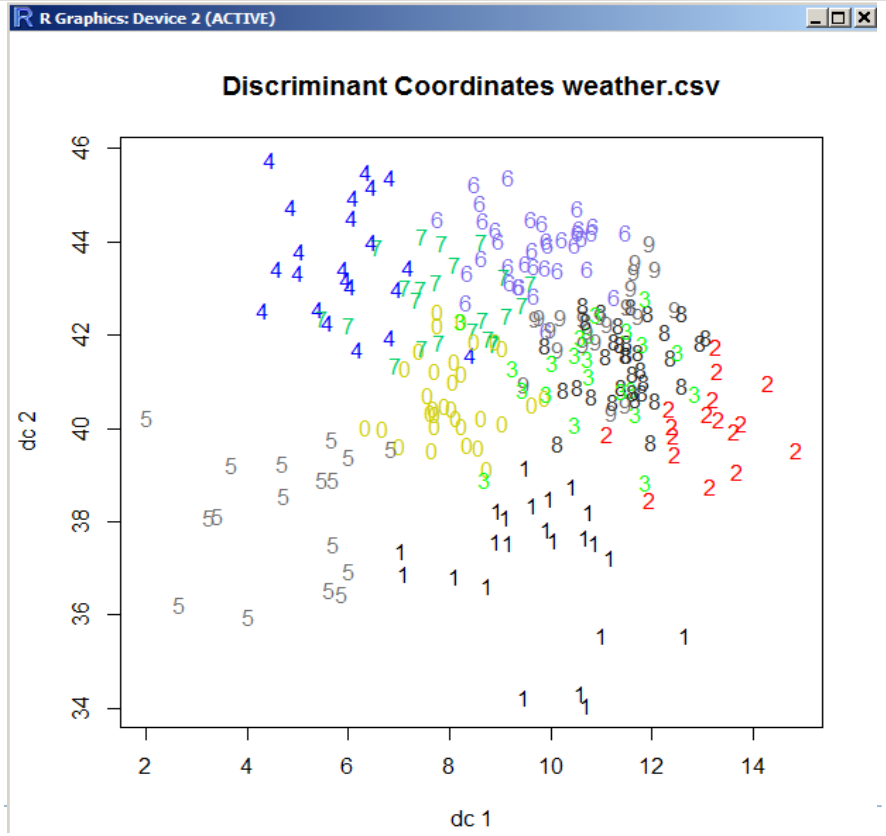
# Rattle Training 7. Cluster Analysis

Data | Explore | Test | Transform | Cluster | Associate | Model | Evaluate | Log

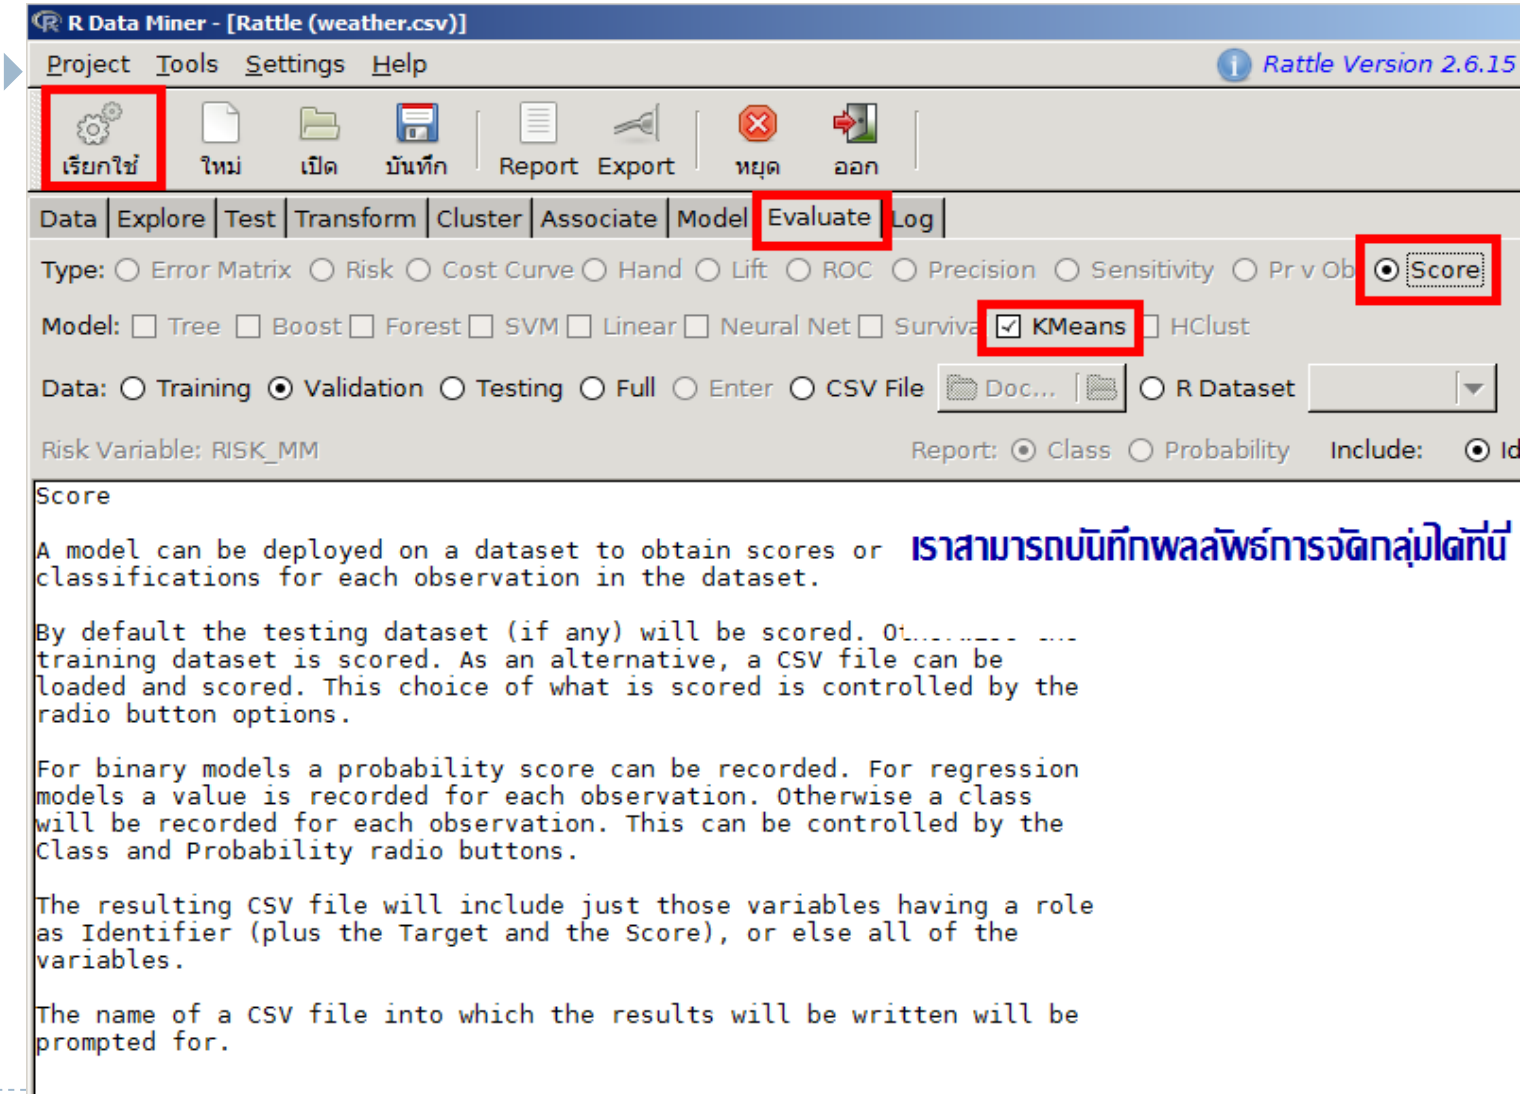
Type: (•) KMeans ( ) Ewkm ( ) Hierarchical ( ) BiCluster

Number of clusters: 10 Seed: 42 Runs: 1

[ ] Use HClust Centers [ ] Iterate Clusters Stats Plots: Data Discriminant Weights



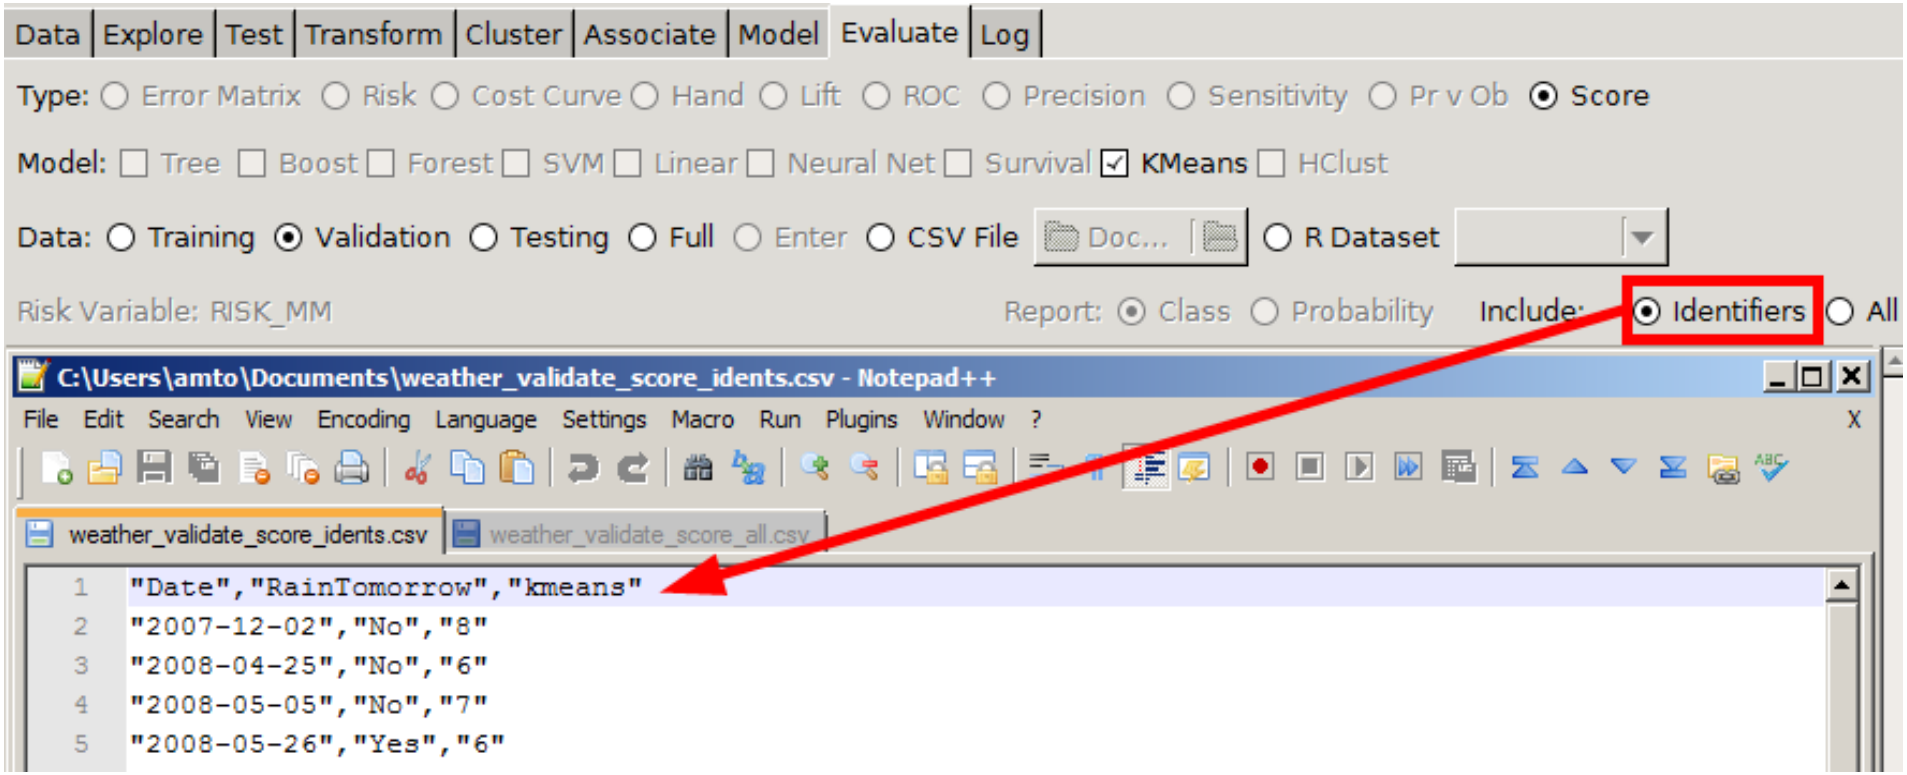
# Rattle Training 7. Cluster Analysis




เราสามารถบันทึกผลลัพธ์การจัดกลุ่มได้ที่นี่

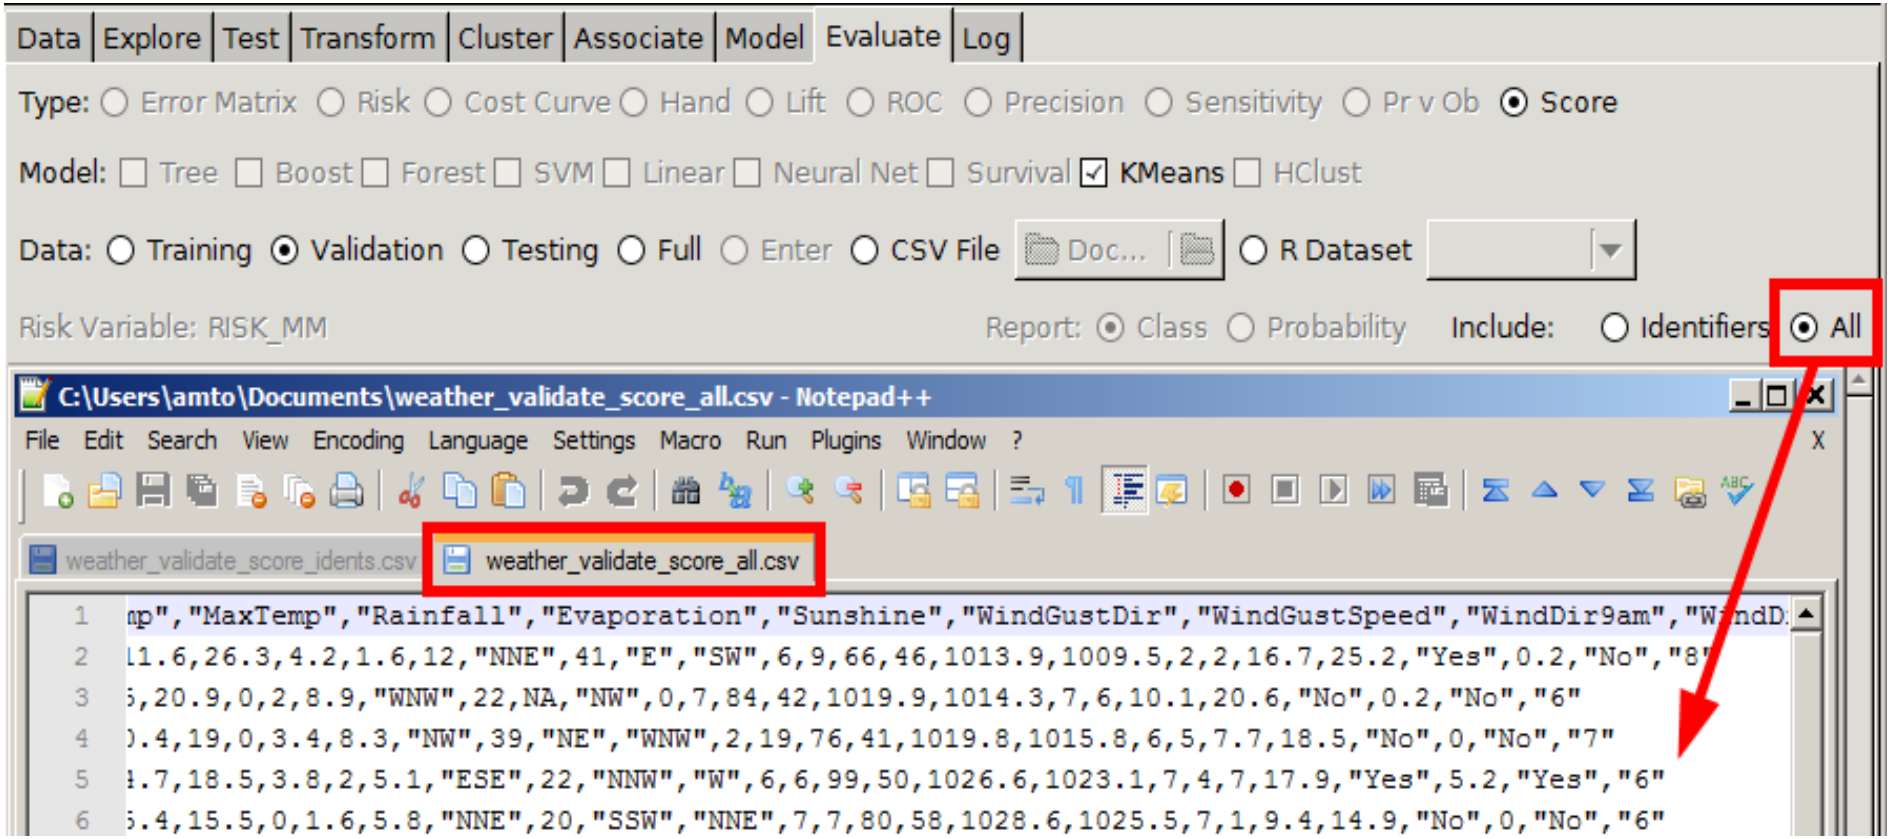
# Rattle Training 7. Cluster Analysis

- Rattle สามารถแสดงกลุ่มของข้อมูลในไฟล์ซึ่งสามารถบันทึกค่า score ออกมา
- Include : Identifiers จะแสดงแบบย่อ
  - คือ Identifiers (Date),Target (RainTomorrow) & kmeans.



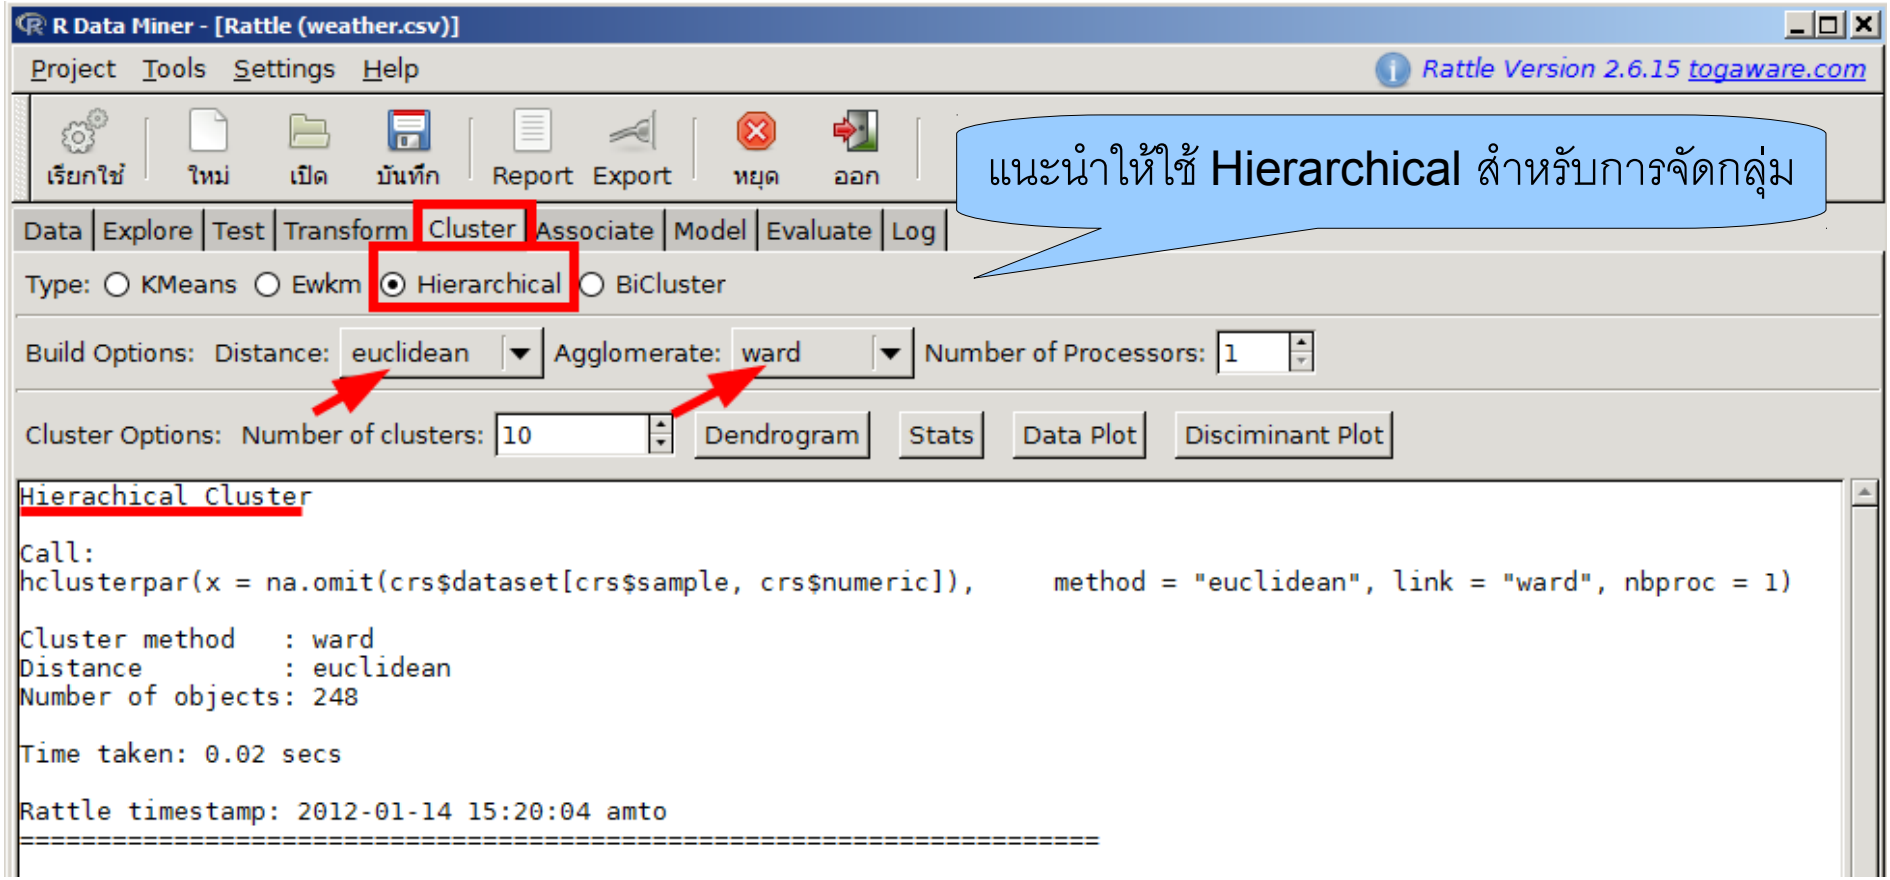
# Rattle Training 7. Cluster Analysis

- กรณีที่เลือก **Include** เป็น **All** จะบันทึกข้อมูลทั้งไฟล์พร้อมกับ **kmeans num.**



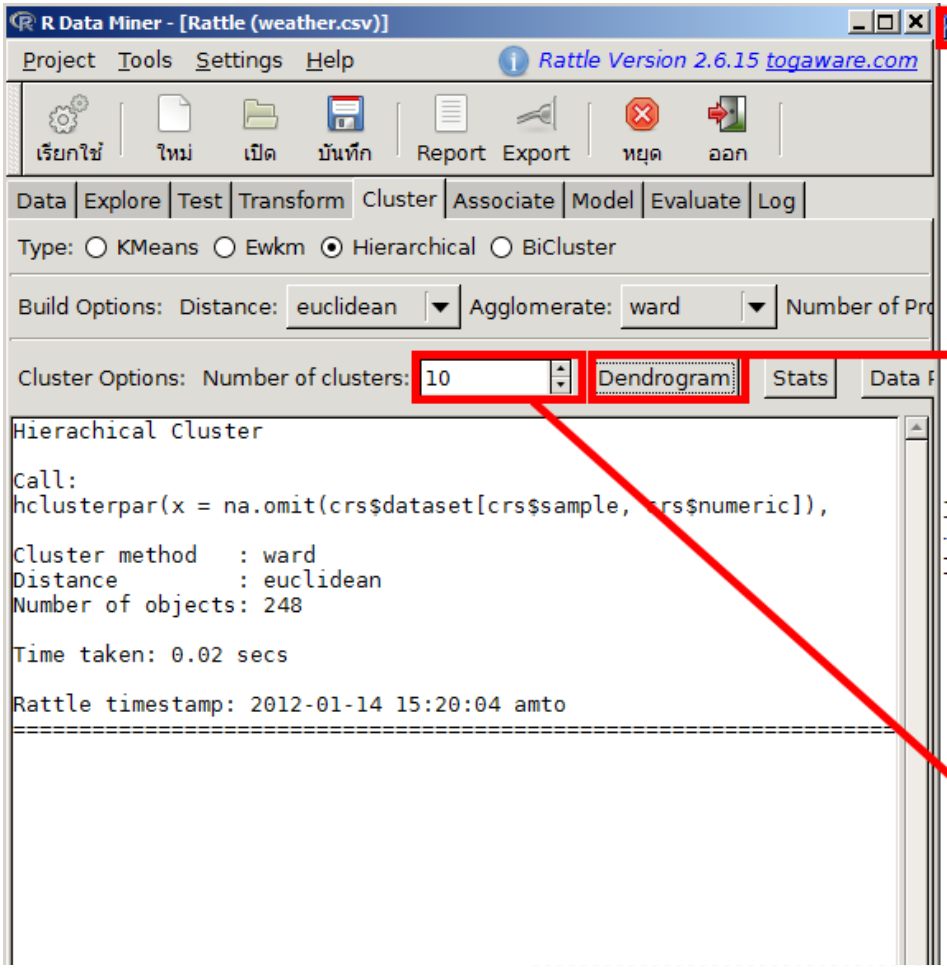
# Rattle Training 7. Cluster Analysis

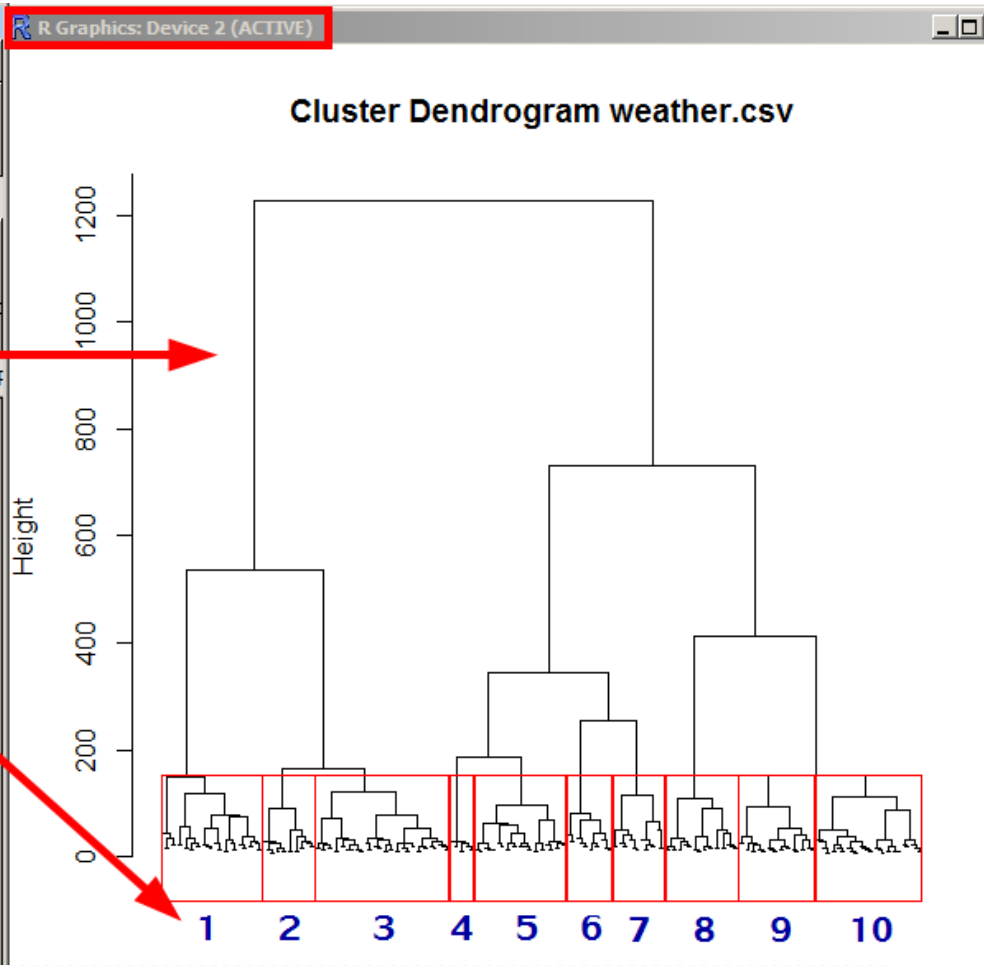
- วิธี Hierarchical จะมี option ในการเลือก Distance & Agglomerate
- นอกจากนี้ยังมีการสร้าง Dendrogram ให้เห็นลำดับขั้นความสัมพันธ์ของข้อมูลด้วย



# Rattle Training 7. Cluster Analysis

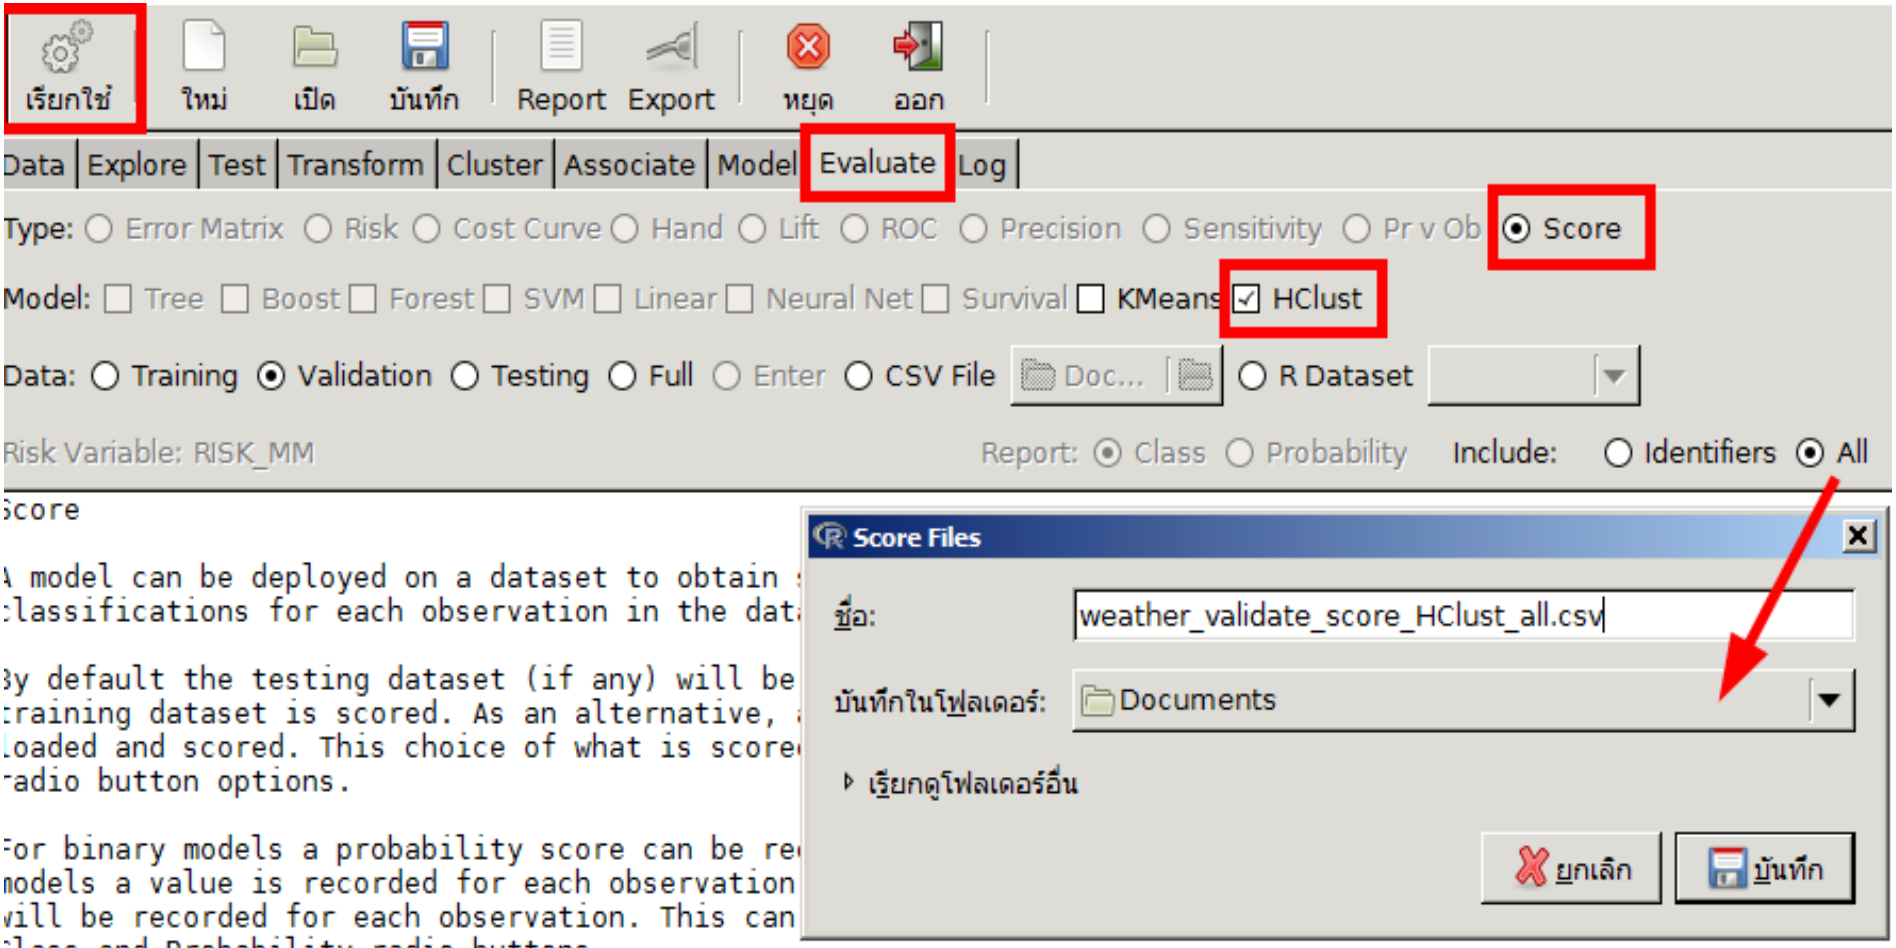
- กรอบสีแดงจะแบ่งกลุ่มตาม Number of clusters. (ในที่นี้คือ 10 กรอบ)



# Rattle Training 7. Cluster Analysis

- การบันทึก Score ในส่วนของ Hierarchical ให้เลือกที่ HClust

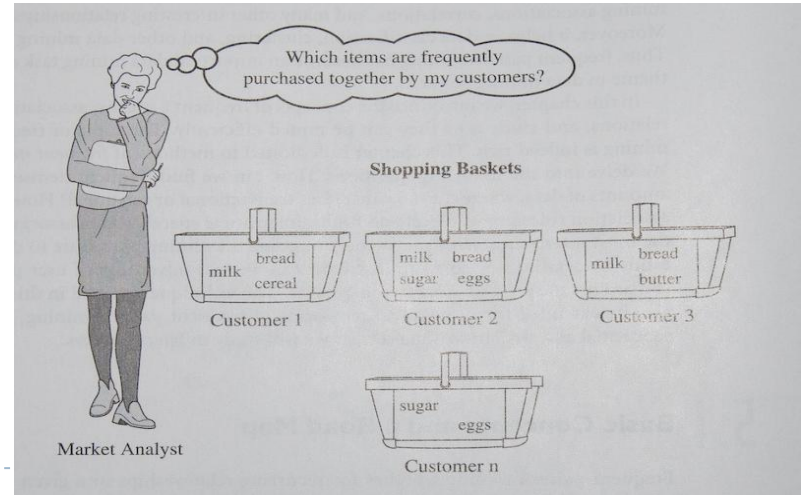


# Association Rule คือ

- การทำเหมืองข้อมูลแบบกฎเชื่อมโยง คือ การหารูปแบบที่เกิดบ่อย **(frequent pattern)** ความเชื่อมโยงที่เกิดขึ้น **(association)** หรือสหสัมพันธ์ **(correlation)** ของกลุ่ม **item** จากข้อมูลที่อยู่ในรูป **transaction**
- นำไปใช้กับ
  - การวิเคราะห์ตะกร้าการซื้อ **(Market basket analysis)** การทำตลาดข้ามสายผลิตภัณฑ์ **(cross-marketing)** การวางรูปแบบและออกแบบ **catalog** การทำรายการส่งเสริมการขาย การวางแผนผังภายในร้าน เป็นต้น
- ผลลัพธ์อยู่ในรูปแบบกฎ :**“Body → Head [support, confidence]”**
  - Friday ∩ Nappies → Beer [0.5% , 60%]
  - Age ∈ [20,30] ∩ Income ∈ [20k, 30k] → MP3Player [2% , 60%]
  - Gladiator ∩ Patriot → Sixth Sense [0.1% , 90%]

# คำถามของ Market basket

- ผู้ซื้อปฏิเสธหรือยอมรับการพยายามขายสินค้าต่างลักษณะหรือไม่?
- สินค้าใดที่ปรากฏร่วมกันบ่อยในหนึ่งใบเสร็จ?
- สินค้าใดที่ปรากฏร่วมกันบ่อยในกลุ่มสินค้าที่กำหนด?
- อะไรคือสินค้าที่พบว่าถูกขายบ่อยให้กับลูกค้าที่มารับบริการซ้ำๆ ?
- ลักษณะการขายของสินค้ามีการเปลี่ยนไปตามเวลาหรือไม่?
- ลักษณะการขายของสินค้ามีการเปลี่ยนไปตามที่อยู่ของลูกค้าหรือไม่ อย่างไร?



# Association rule concept

- กฎเชื่อมโยง คือการวัดค่าสิ่งที่น่าสนใจของ
  - **Support :** รายการเหล่านี้เกิดขึ้นด้วยกันบ่อยแค่ไหน (ซื้อ **x** แล้วซื้อ **y** ด้วย)
  - **Confidence :** เงื่อนไขเหล่านี้เกิดขึ้นบ่อยแค่ไหน (บางที่ซื้อ **x**แต่ซื้อ **m**,หรือ **b**หรือ **a** )
- $X \rightarrow Y$ [s% , c%]
  - กฎนี้จะต้องมี **s%** ทุก **transactions**
  - Support $(X \rightarrow Y) = P(X \cup Y)$
  - ถ้าหาก **X** อยู่ในตระกร้าซื้อ แล้วกรณีที่มี **Y** ด้วยมี **c%** อยู่เท่าไหร่เมื่อเทียบกับทั้งหมด
  - Confidence $(X \rightarrow Y) = P(Y|X) = P(X \cup Y) / P(X)$

# ตัวอย่างการหา association rule

- เซตของกลุ่มสินค้าที่มีค่าสนับสนุน **min support** เรียกว่า **frequent itemset**
- พิจารณากฎ A → C
- คุณ

| Transaction | Items |
|---|---|
| 12345 | A B C |
| 12346 | A C |
| 12347 | A D |
| 12348 | B E F |

⇒

| Itemset | Support |
|---|---|
| $A$ | 75% |
| $B$ | 50% |
| $C$ | 50% |
| $A, C$ | 50% |

iset

Parameters:
support = 50%
confidence = 50%

Rule $A \rightarrow C$

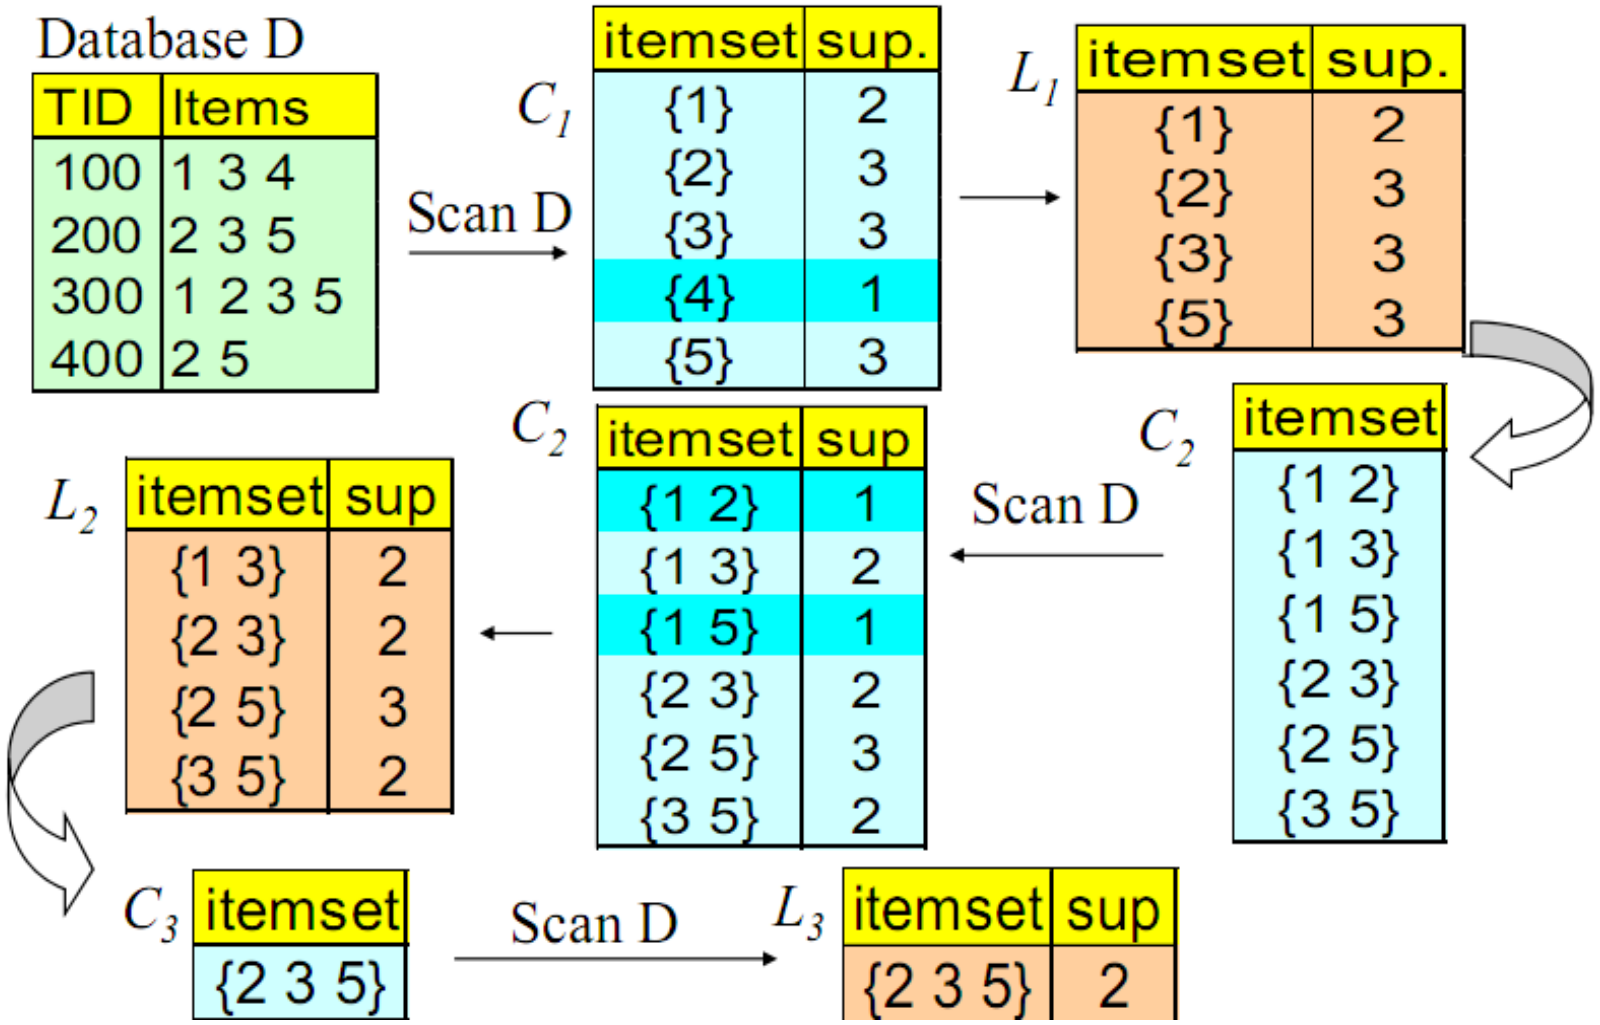
- $\text{support}(A, C) = 50\%$
- $\text{confidence}(A \rightarrow C)$ = $\text{support}(A, C)/\text{support}(A)$ = 66.6%

=50 / 75

# การหา frequent itemset

- **frequent itemset** คือกลุ่มของ **item** ที่มีค่าสนับสนุนมากกว่าหรือเท่ากับค่า **minimum support**
  - สับเซตของ **frequent itemset** เป็น **frequent itemset** คือ ถ้า **{A, B}** เป็น **frequent itemset** แล้ว **{A}** และ **{B}** ต้องเป็น **frequent itemset**
  - ดังนั้นการหา **frequent itemset** ที่มี **k** ตัวทำได้จากการพิจารณา **k-1** ตัว กล่าวคือเราหา **frequent itemset** จาก **1** ไปถึง **k (k-itemset)**
- หลังจากที่พิจารณาทุก **frequent itemset** ที่มีจำนวนมากที่สุดแล้ว เราสร้างกฎเชื่อมโยงจาก **frequent itemset** ทั้งหมดที่ได้
- ดูขั้นตอนของวิธี **Apriori** ในหน้าถัดไป

# การทำงานของขั้นตอนวิธี Apriori (ค่อยๆ ตัดออก)



# ลักษณะข้อมูลที่ต้องการของ Association rule

- กฎเชื่อมโยง (Association rule) เป็นการวิเคราะห์หาความสัมพันธ์ที่มากกว่าหนึ่งสิ่งที่มีการบันทึกร่วมกันในหนึ่งแถวของข้อมูล
- ข้อมูลที่นำมาใช้วิเคราะห์ มักจะเป็น **transaction** นั่นคือ **1 record** จะมีความสัมพันธ์ของลักษณะประจำ (ตัวแปร) หนึ่งรูปแบบ
- การวิเคราะห์รูปแบบนี้ไม่มีลักษณะประจำเป้าหมาย
- ลักษณะประจำ ต้องเป็นตัวแปร **binary** หรือตัวแปรที่มีค่าไม่ต่อเนื่อง
- ในกรณีที่ลักษณะประจำมีค่าที่ต่อเนื่อง จะต้องแปลงให้เป็นค่าไม่ต่อเนื่องก่อนการคำนวน อาจใช้คน หรือการจัดการข้อมูลด้วยโปรแกรมคอมพิวเตอร์อัตโนมัติก็ได้

# สรุป Associate rule

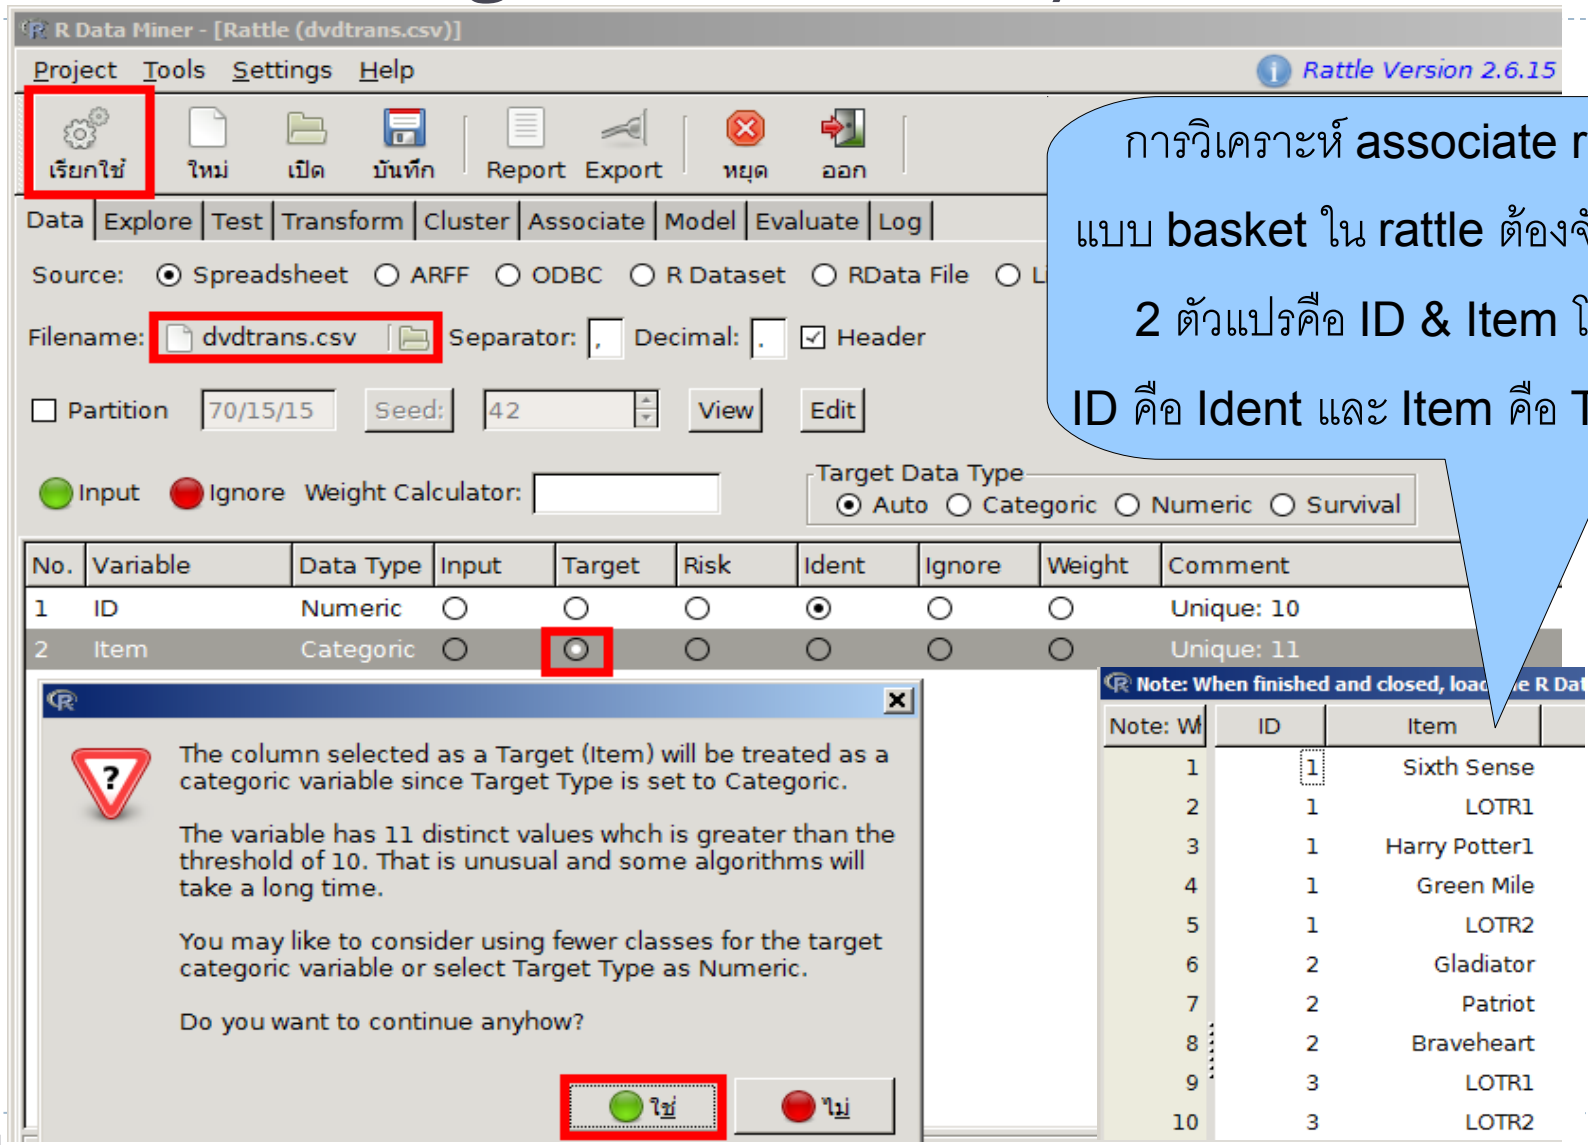
- **Associate rule** คือจุดเริ่มต้นการเกิดขึ้นของ **data mining algorithm!**
- ปรากฏในหมู่ของนักวิจัย KDD และมีการนำเสนองานส่วนนี้จำนวนมากที่สุด
- มีประโยชน์ในการหาความเชื่อมโยง บอกพฤติกรรมที่มีค่า ในฐานข้อมูลลูกค้าขนาดใหญ่
- ปกติใช้กับฐานข้อมูลเชิงสัมพันธ์ที่บันทึกเป็น **Transaction** โดยที่แต่ละระเบียนคือการซื้อสินค้าในหนึ่งครั้ง
- ผลลัพธ์ที่ได้คือกฎ กฎแสดงความสัมพันธ์ของการซื้อสินค้าต่างชนิดกันโดยไม่ขึ้นกับลูกค้า

| Transaction | Items |
|---|---|
| 12345 | A C D |
| 12346 | B C E |
| 12347 | A B C E |
| 12348 | B E |

$$BC \rightarrow E \ [50\%, 100\%]$$
$$BE \rightarrow C \ [50\%, 66\%]$$
$$C \rightarrow A \ [50\%, 66\%]$$

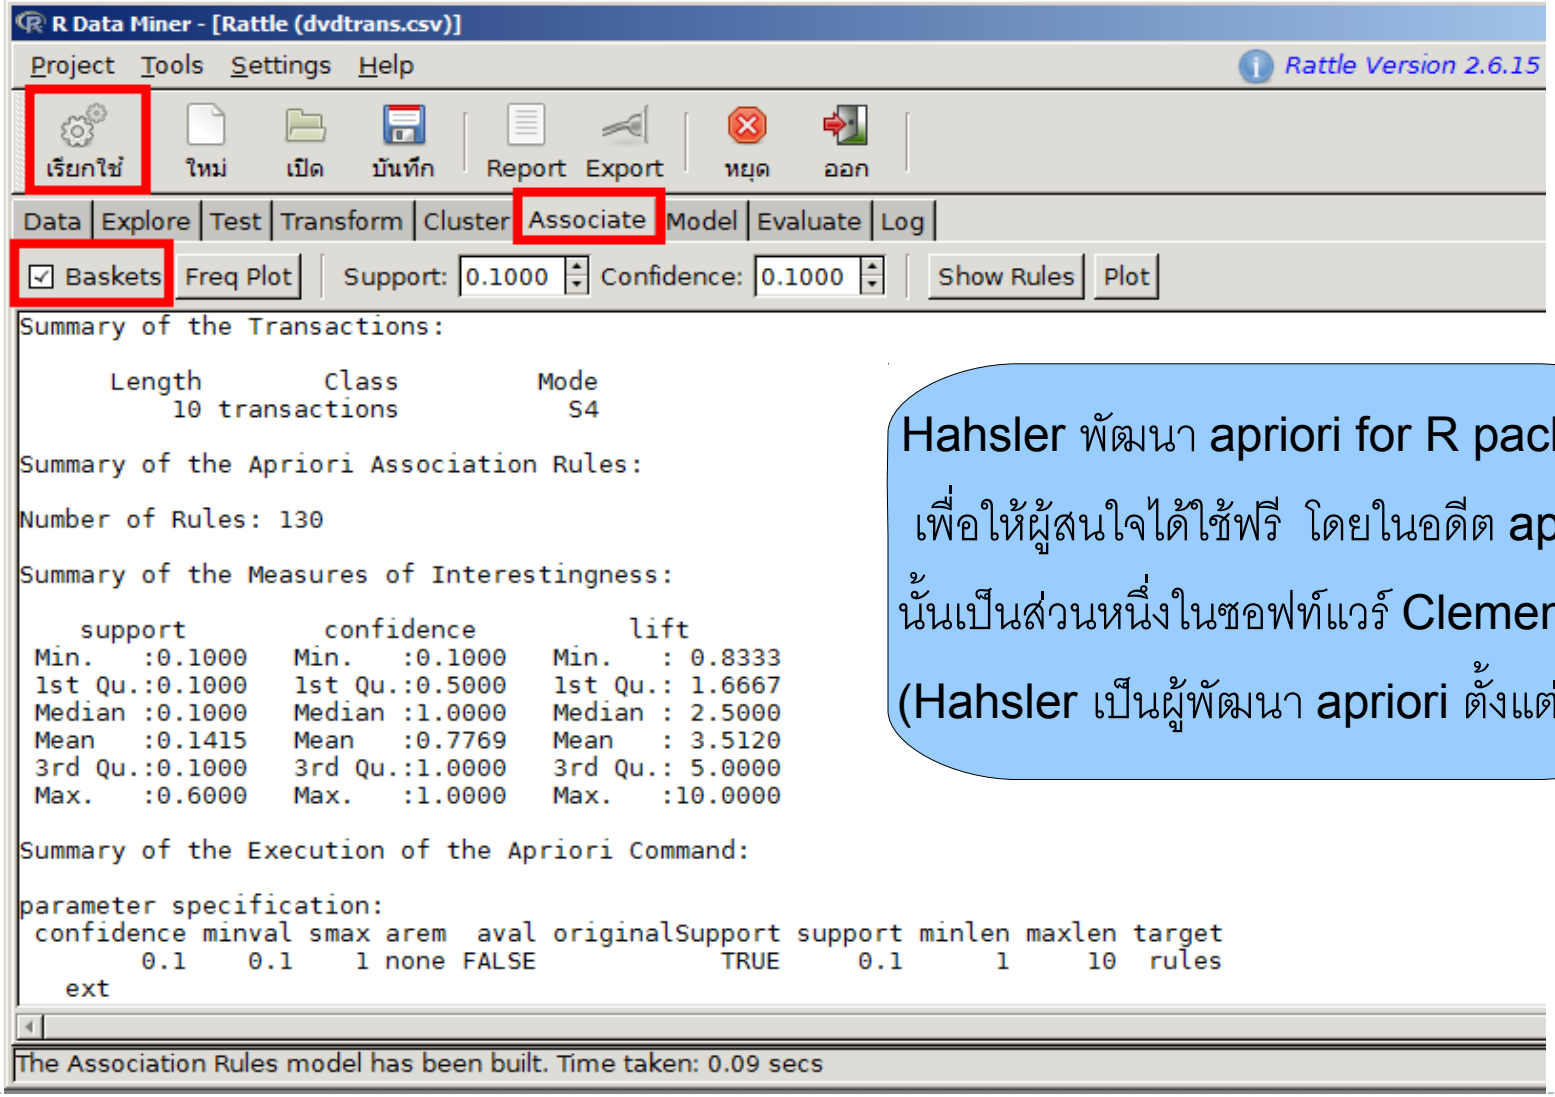
จงแสดงผลการคำนวน Support& confidence

# Rattle Training 8.Association Analysis




การวิเคราะห์ associate rule แบบ basket ใน rattle ต้องจัดเป็น 2 ตัวแปรคือ ID & Item โดย ID คือ Ident และ Item คือ Target

# Rattle Training 8.Association Analysis




Hahsler พัฒนา apriori for R package เพื่อให้ผู้สนใจได้ใช้ฟรี โดยในอดีต apriori นั้นเป็นส่วนหนึ่งในซอฟท์แวร์ Clementine. (Hahsler เป็นผู้พัฒนา apriori ตั้งแต่แรก)

# Rattle Training 8.Association Analysis

R Data Miner - [Rattle (dvdtrans.csv)]

Project Tools Settings Help — Rattle Version 2.6.15 togaware.com

เรียกใช้ ใหม่ เปิด บันทึก Report Export หยุด ออก

Data | Explore | Test | Transform | Cluster | Associate | Model | Evaluate | Log

☑ Baskets | Freq Plot | Support: 0.1000 | Confidence: 0.1000 | Show Rules | Plot

```
Summary of the Transactions:

      Length        Class         Mode
          10 transactions           S4

Summary of the Apriori Association Rules:

Number of Rules: 130

Summary of the Measures of Interestingness:

    support         confidence          lift
 Min.   :0.1000   Min.   :0.1000   Min.   : 0.8333
 1st Qu.:0.1000   1st Qu.:0.5000   1st Qu.: 1.6667
 Median :0.1000   Median :1.0000   Median : 2.5000
 Mean   :0.1415   Mean   :0.7769   Mean   : 3.5120
 3rd Qu.:0.1000   3rd Qu.:1.0000   3rd Qu.: 5.0000
 Max.   :0.6000   Max.   :1.0000   Max.   :10.0000

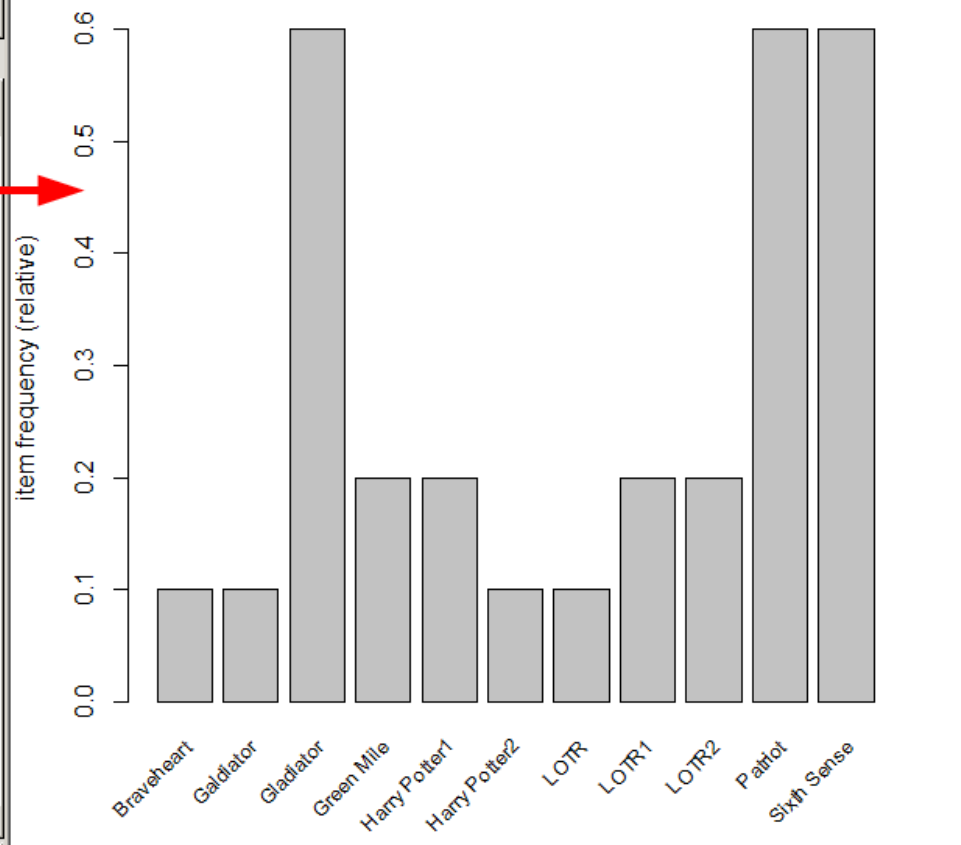
Summary of the Execution of the Apriori Command:

parameter specification:
 confidence minval smax arem  aval originalSupport support minlen maxlen
        0.1    0.1    1 none FALSE            TRUE     0.1      1     10
   ext
 FALSE

algorithmic control:
```

Generated the relative frequency plot.

R Graphics: Device 2 (ACTIVE)




เป็นการพิจารณาดูว่าข้อมูล **Item** มีจำนวนกลุ่มมากน้อยเพียงใด

# Rattle Training 8.Association Analysis

RGui - [R Console]

File Edit View Misc Packages Windows Help

```
> library(arules)     # attach package 'arules'
Loading required package: Matrix
Loading required package: lattice

Attaching package: 'Matrix'

The following object(s) are masked from 'package:base':

    det


Attaching package: 'arules'

The following object(s) are masked fr
```

**Building a Model Using R Command-Line**

**Arules (Hahsler et al.,2011) Provides apriori()**

**These R Packages are widely used, and freely**

**Its**

RGui - [R Console]

File Edit View Misc Packages Windows Help

```
> library(arulesViz)  # attach package 'arulesVis'
Loading required package: MASS
Loading required package: scatterplot3d
Loading required package: vcd
Loading required package: grid
Loading required package: colorspace
Loading required package: seriation
Loading required package: cluster
Loading required package: TSP
Loading required package: gclus

Attaching package: 'seriation'
```

associate rule ใน Command-line สามารถทำกราฟ ได้ดีกว่า Rattle เราจึงแนะนำให้ใช้วิธีดังต่อไปนี้

# Rattle Training 8.Association Analysis

dvd=read.transactions (file=”dvdtrans.csv”,rm.duplicates=FALSE, format=”single”,sep=”,”,cols=c(1,2))

```
> dvd = read.transactions (file="dvdtrans.csv", rm.duplicates= FALSE, format="single",sep=",",cols =c(1,2))
> dvd
transactions in sparse format with
 11 transactions (rows) and
 14 items (columns)
>
> # Run the apriori algorithm
> basket_market <- apriori(dvd, parameter = list (sup = 0.1, conf = 0.1, target="rules"))

parameter specification:
 confidence minval smax arem  aval originalSupport support minlen maxlen target   ext
        0.1    0.1    1 none FALSE            TRUE     0.1      1     10  rules FALSE

algorithmic control:
 filter tree heap memopt load sort verbose
    0.1 TRUE TRUE  FALSE TRUE    2    TRUE

Warning in apriori(dvd, parameter = list(sup = 0.1, conf = 0.1, target = "rules")) :
  You chose a very low absolute support count of 1. You might run out of memory! Increase minimum support.

apriori - find association rules with the apriori algorithm
version 4.21 (2004.05.09)        (c) 1996-2004   Christian Borgelt
set item appearances ...[0 item(s)] done [0.00s].
set transactions ...[14 item(s), 11 transaction(s)] done [0.00s].
sorting and recoding items ... [6 item(s)] done [0.00s].
creating transaction tree ... done [0.00s].
checking subsets of size 1 2 3 done [0.00s].
writing ... [17 rule(s)] done [0.00s].
creating S4 object  ... done [0.00s].
```

วิเคราะห์ aprori

ดึงข้อมูลเข้าหน่วยความจำของ R

basket_market <-apriori(dvd,parameter=list (sup=0.1, conf=0.1, target=”rules”))

อย่าลืม Change directory เพื่อความสะดวกในการ access ข้อมูลด้วย R Command-line.

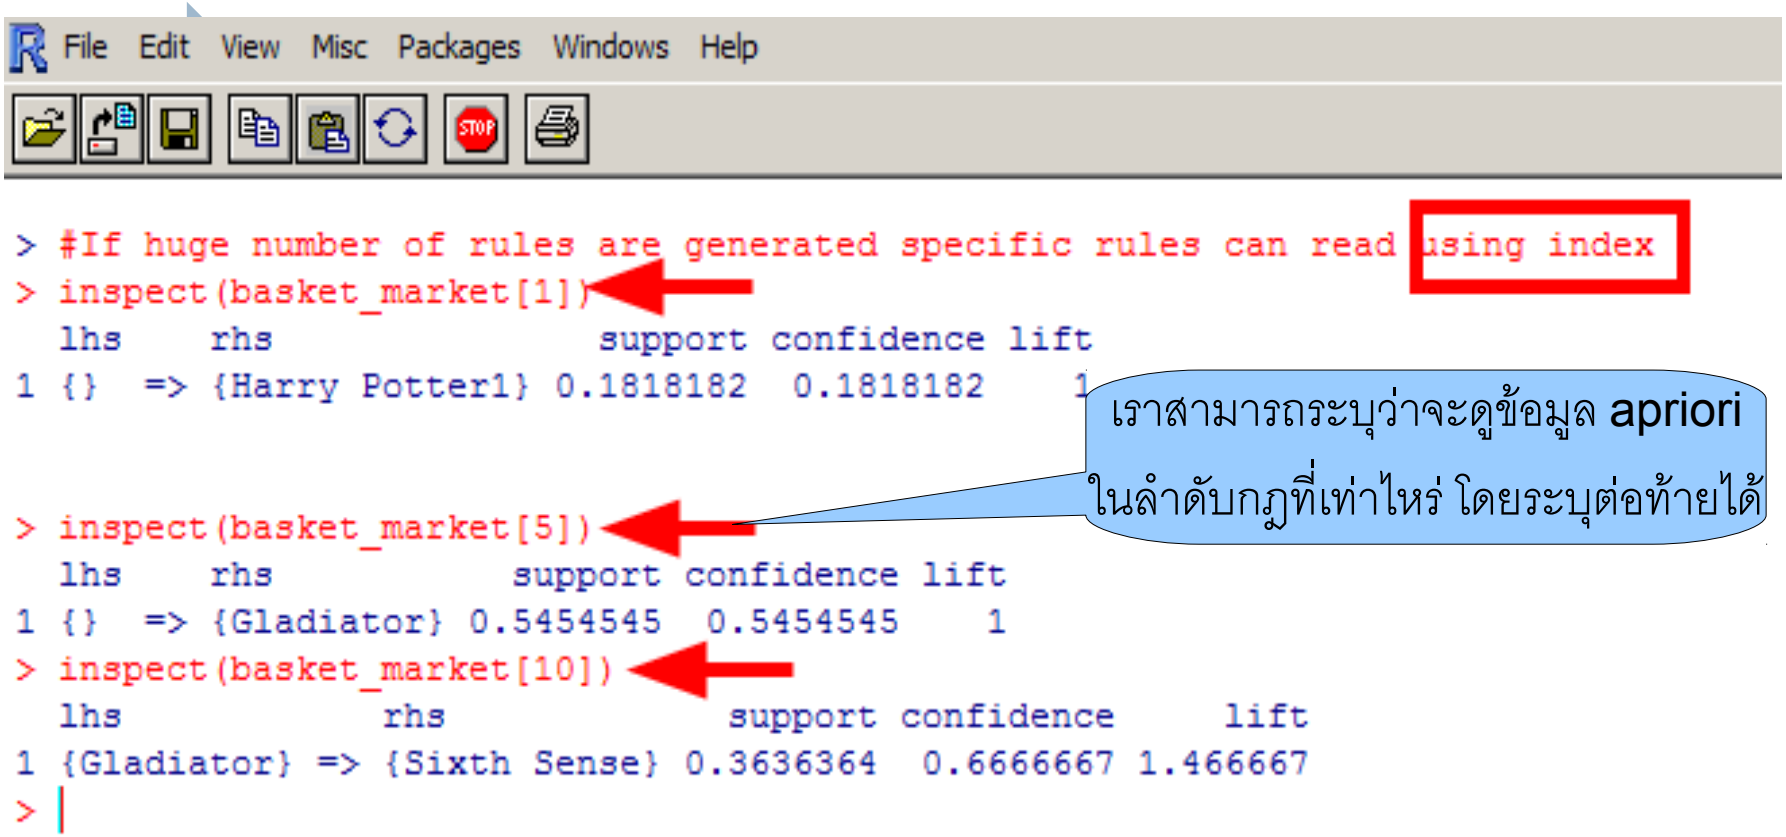
# Rattle Training 8.Association Analysis

- Inspect (...) จะแสดงกฎความรู้ทั้งหมดที่ค้นพบ

```
> # Check the generated rules using inspect
> inspect(basket_market)
   lhs                rhs                 support confidence     lift
1  {}              => {Harry Potter1} 0.1818182  0.1818182 1.000000
2  {}              => {LOTR1}         0.1818182  0.1818182 1.000000
3  {}              => {LOTR2}         0.1818182  0.1818182 1.000000
4  {}              => {Sixth Sense}   0.4545455  0.4545455 1.000000
5  {}              => {Gladiator}     0.5454545  0.5454545 1.000000
6  {}              => {Patriot}       0.5454545  0.5454545 1.000000
7  {LOTR1}         => {LOTR2}         0.1818182  1.0000000 5.500000
8  {LOTR2}         => {LOTR1}         0.1818182  1.0000000 5.500000
9  {Sixth Sense}   => {Gladiator}     0.3636364  0.8000000 1.466667
10 {Gladiator}     => {Sixth Sense}   0.3636364  0.6666667 1.466667
11 {Sixth Sense}   => {Patriot}       0.3636364  0.8000000 1.466667
12 {Patriot}       => {Sixth Sense}   0.3636364  0.6666667 1.466667
13 {Gladiator}     => {Patriot}       0.5454545  1.0000000 1.833333
14 {Patriot}       => {Gladiator}     0.5454545  1.0000000 1.833333
15 {Gladiator,
    Sixth Sense}   => {Patriot}       0.3636364  1.0000000 1.833333
16 {Patriot,
    Sixth Sense}   => {Gladiator}     0.3636364  1.0000000 1.833333
17 {Gladiator,
    Patriot}       => {Sixth Sense}   0.3636364  0.6666667 1.466667
>
```

```
> inspect(dvd)
   items                                transactionID
1  {Green Mile,
    Harry Potter1,
    LOTR1,
    LOTR2,
    Sixth Sense}                        1
2  { Galdiator,
     Green Mile,
     LOTR,
     Sixth Sense}                       10
3  {Braveheart,
    Gladiator,
    Patriot}                            2
4  {LOTR1,
    LOTR2}                              3
5  {Gladiator,
    Patriot,
    Sixth Sense}                        4
6  {Gladiator,
    Patriot,
    Sixth Sense}                        5
7  {Gladiator,
    Patriot,
    Sixth Sense}                        6
8  {Harry Potter1,
    Harry Potter2}                      7
9  {Gladiator,
    Patriot}                            8
10 {Gladiator,
    Patriot,
    Sixth Sense}                        9
11 {Item}                               ID
>
```

# Rattle Training 8.Association Analysis



# Rattle Training 8.Association Analysis

- คำสั่ง **sort** กฎที่ค้นพบตามค่า **lift** และคัดเลือกเฉพาะตัวแรกๆ เช่น **5** ลำดับแรก
- ทำให้กฎที่ได้ มีหน้าตาคล้ายกับการแสดงผลใน **Data mining software** ทั่วไป

```
> ## select and inspect rules with highest lift.
> rules_high <- head(sort(basket_market, by = "lift"),5)
> inspect(rules_high)
  lhs                 rhs              support confidence     lift
1 {LOTR1}          => {LOTR2}       0.1818182          1 5.500000
2 {LOTR2}          => {LOTR1}       0.1818182          1 5.500000
3 {Gladiator}      => {Patriot}     0.5454545          1 1.833333
4 {Patriot}        => {Gladiator}   0.5454545          1 1.833333
5 {Gladiator,
   Sixth Sense}    => {Patriot}     0.3636364          1 1.833333
>
>
```

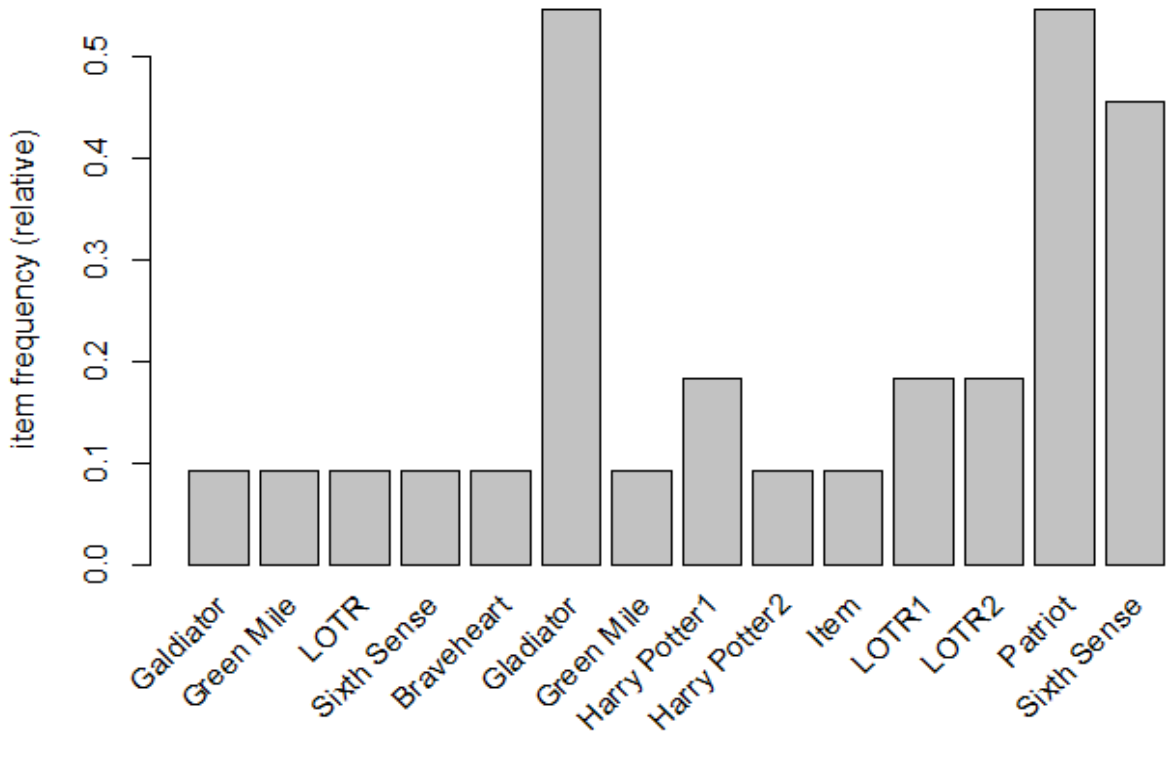
# Rattle Training 8. Association Analysis

R Console

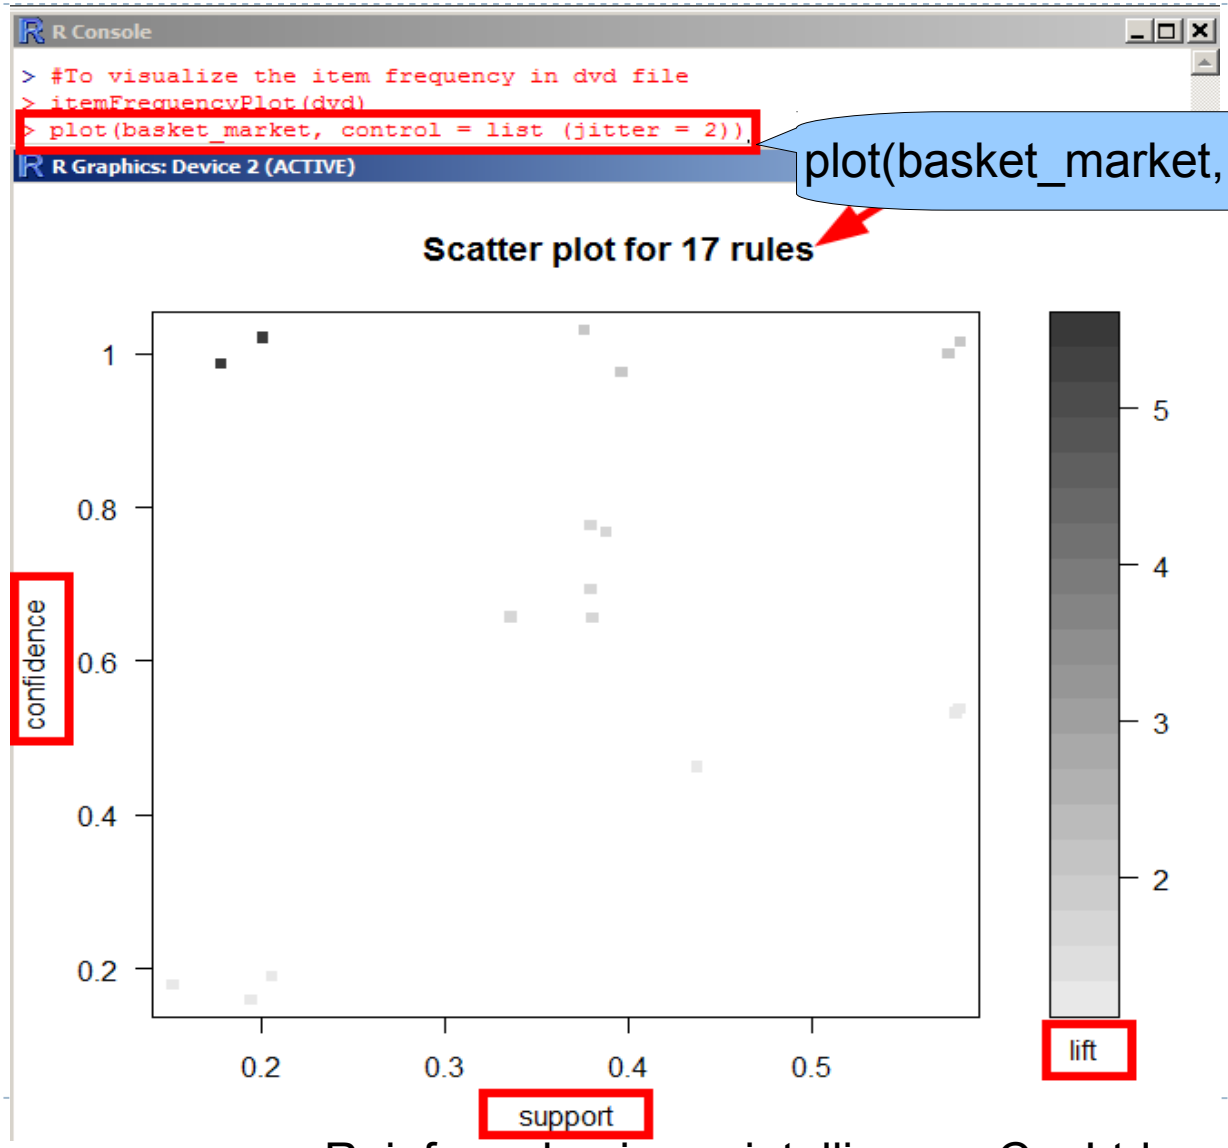
```
> #To visualize the item frequency in dvd file
> itemFrequencyPlot(dvd)
```

R Graphics: Device 2 (ACTIVE)

ItemFrequencyPlot (dvd)



# Rattle Training 8. Association Analysis

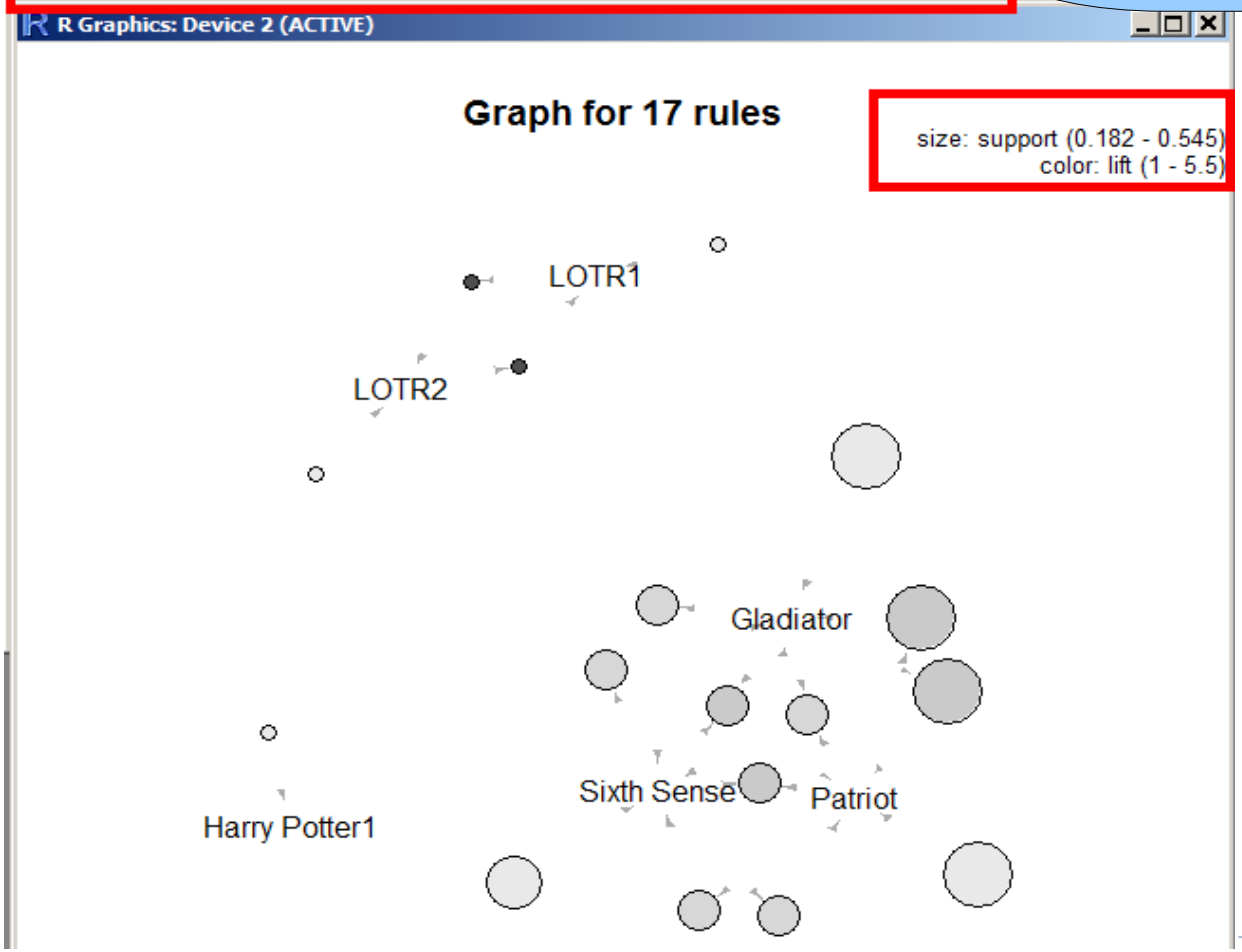



plot(basket_market, control = list (jiter=2))

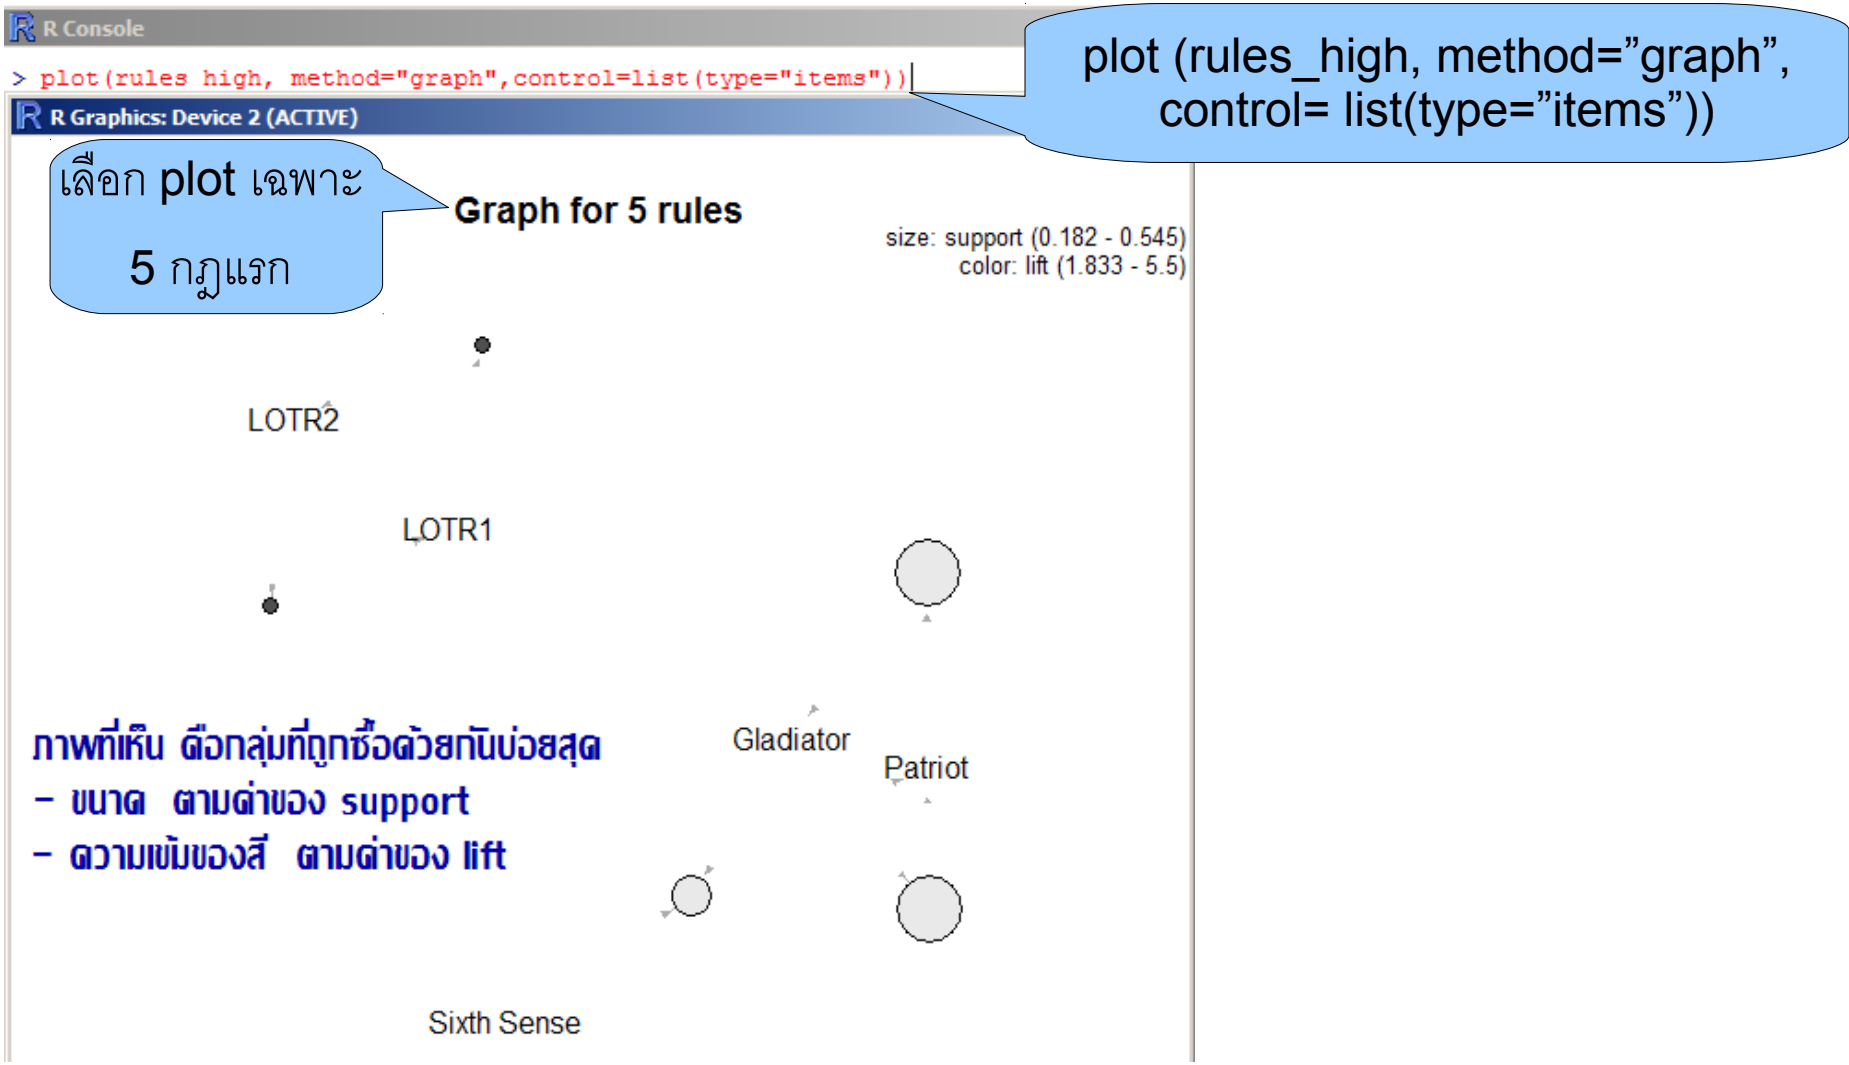
# Rattle Training 8.Association Analysis

```
R Console
> #To visualize the item frequency in dvd file
> itemFrequencyPlot(dvd)
> plot(basket_market, control = list (jitter = 2))
> plot(basket_market, method="graph",control=list(type="items"))
```

plot(basket_market, method=”graph”, control=list(type=”items”))



# Rattle Training 8.Association Analysis



# 9.Classification Model

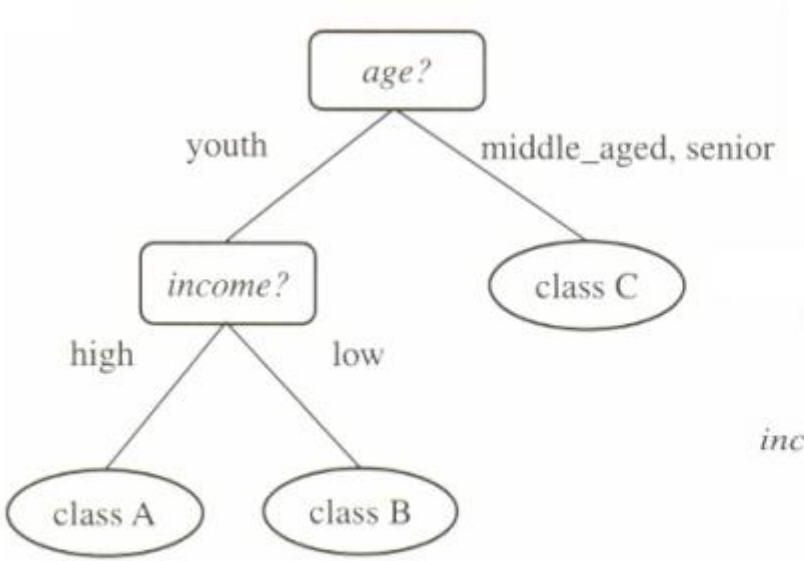
- Classification and Prediction
  - Finds a set of models to predict the class of objects
  - The models is based on a set of training data

age(X, "youth") AND income(X, "high") → class(X, "A")
age(X, "youth") AND income(X, "low") → class(X, "B")
age(X, "middle_aged") → class(X, "C")
age(X, "senior") → class(X, "C")

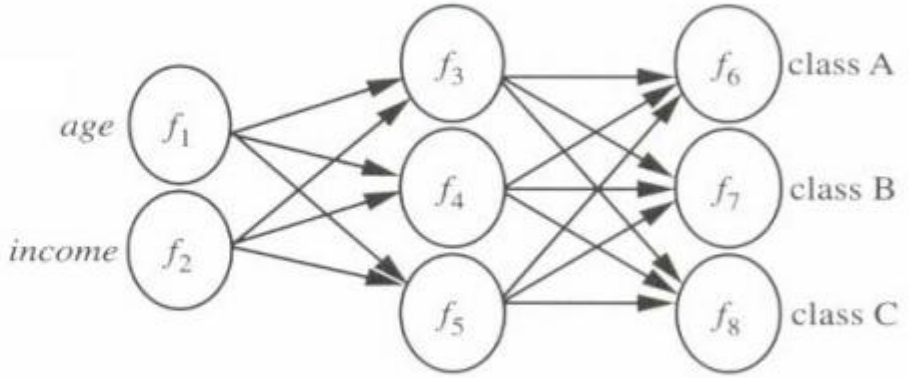
The set of classification rule model

# Data Mining functionality

- Classification and Prediction



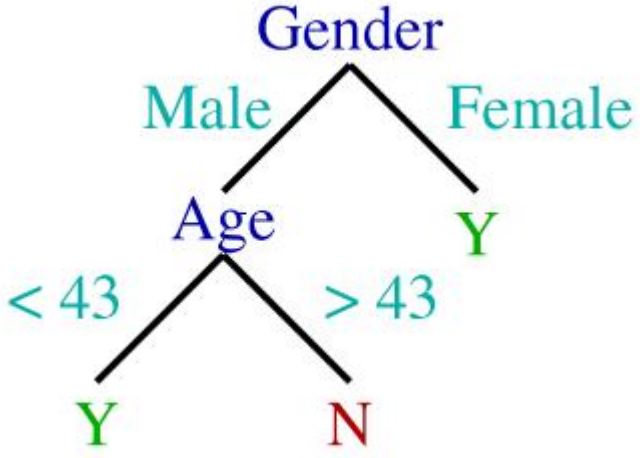

decision tree model




neural network model

# Decision tree → Classification

- วัตถุประสงค์ของ **classification** คือการสร้างโมเดล เพื่อสรุปข้อมูล และข้อค้นพบที่ได้มักเป็นข้อมูลที่ไม่เคยเห็นมาก่อน
- **Classification** เป็นการเรียนรู้แบบ **supervised**
- นอกจาก **decision tree** แล้วยังมี **neural networks ; logistic regression : support vector machines** เป็นประเภทเดียวกัน
- สิ่งที่ได้ของ **decision tree** คือ **flow-chart**
  - มี **node** จุดยอดภายใน แทนลักษณะประจำที่ไม่ใช่ **class**
  - มีกิ่งก้านแทนผลลัพธ์ของการทดสอบ
  - และใบแทน **class labels** หรือ **class distribution**



# Classification vs. Prediction

- **Classification**
  - เป็นวิธีการแยกข้อมูลออกเป็นกลุ่มตามลักษณะประจำเป้าหมาย หรือ **class** โดยมากใช้กับลักษณะประจำที่มีค่าไม่ต่อเนื่อง
  - ผลลัพธ์ที่ได้คือ ตัวแบบ **classifier** เพื่อนำไปใช้แยกประเภทของระเบียนข้อมูล ที่ไม่ทราบ **class**
- **Prediction**
  - เป็นวิธีการคำนวณหาค่าที่ต้องการทราบ เพื่อทำนายค่าของข้อมูล โดยมากใช้กับลักษณะประจำที่มีค่าต่อเนื่อง
  - ผลลัพธ์ที่ได้คือ ตัวแบบ **predictor** เพื่อนำไปใช้ประมาณค่าของระเบียนข้อมูล ที่สนใจว่าค่าที่ขาดหายไปจะเป็นเท่าไหร่ เช่น สมการ **multiple regression**

# Decision tree model

- การจัดจำแนกด้วย **decision model** เป็น **machine learning** จากกลุ่มตัวอย่างที่กำหนดให้
- **Decision model** ที่ได้อาจอยู่ในรูปของกฎ ต้นไม้ ตารางหรือเครือข่าย
- การประเมินความถูกต้องของ **model**
  - การวัดความถูกต้องของ **decision tree model** ใช้เทคนิค **train-test set** หรือ **train-validate test set** ซึ่ง **model** จะยอมรับได้ก็ต่อเมื่อตัวอย่างที่ทำนายจาก **test set** มีความถูกต้องผ่านเกณฑ์ที่กำหนด
  - บางครั้งเราใช้ **decision tree model** กับหลักการ **train-test set** แล้วผลออกมาอย่างไม่มีข้อผิดพลาด แต่เมื่อนำไปใช้กับ **test set** กลับได้ผลไม่ดี ปรากฏการณ์นี้เรียกว่าปัญหาการเข้ากันเกินไป **(overfitting problem)**
  - วิธีการหลีกเลี่ยงปัญหาดังกล่าว คือการใช้ข้อมูลอีกชุด **validate set** เพื่อให้ได้ตัวแบบที่นำไปใช้กับตัวอย่างในอนาคตได้ดี

# แนวคิดการสร้าง Decision tree

- ใช้หลักการละโมบ **(A greedy algorithm)** เพื่อหาแนวทางที่ดีที่สุด ที่มีอยู่
- สร้างต้นไม้ด้วยวิธี **top-down , recursive, divide-and-conquer**
  - เริ่มต้นทุกตัวอย่างที่ราก
  - ใช้กับลักษณะประจำที่ไม่ต่อเนื่อง **categorical**
  - แบ่งกั้นตัวอย่างตามค่าลักษณะประจำโดยการเรียกซ้ำ
  - ลักษณะประจำถูกเลือกจากลำดับของตัววัด เช่น **information gain**
- เงื่อนไขในการหยุดแบ่ง
  - ตัวอย่างทุกตัวมีค่า **class** เหมือนกันหมด
  - ไม่มีลักษณะประจำเหลือในการแบ่ง บอกค่า **class** โดยใช้ **majority voting**
  - ไม่มีตัวอย่างเหลือ ให้ใช้ค่า **class** ของจุดยอดที่อยู่เหนือขึ้นไป

# ตัววัดที่ใช้เลือกลักษณะประจำ

- Information gain (ID3)
  - ใช้กับลักษณะประจำที่เป็น categorical
  - ลักษณะประจำที่เป็นค่าต่อเนื่องให้แปลงเป็นค่าไม่ต่อเนื่องก่อน
- Gain ration (C4.5)
  - ได้จากค่า information gain หารด้วยค่าสรสนเทศของลักษณะประจำ
- Information gain (ID3/C4.5)
- เลือกลักษณะประจำที่มีค่า information gain สูงที่สุด
- พิจารณากลุ่มข้อมูลที่แบ่งเป็น 2 class คือ P หรือ N
  - จำนวนตัวอย่างใน class P คือ p ตัวและจำนวนตัวอย่างใน class N คือ n ตัว
  - ค่าสารสนเทศของกลุ่มข้อมูลคือค่าคาดคะเนที่กลุ่มตัวอย่าง ต้องใช้จำนวนบิตในการแยก class P และ N นิยามโดย

$$I(p,n) = -\frac{p}{p+n}\log_2\frac{p}{p+n} - \frac{n}{p+n}\log_2\frac{n}{p+n}$$

# การคำนวณค่า Information gain

กำหนด A คือลักษณะประจำที่แบ่ง S ออกเป็น v cells: $\{S_1, S_2, \ldots S_V\}$

ถ้า $S_i$ มีตัวอย่างจาก class P จำนวน $p_i$ และตัวอย่างจาก class N จำนวน ni, ค่า entropy หรือค่าคาดคะเนของข้อมูลที่แยกโดยการใช้ลักษณะประจำ A คือ

$$E(A) = \sum_{i=1}^{v} \frac{p_i + n_i}{p + n} I(p_i, n_i)$$

$$Gain(A) = I(p, n) - E(A)$$

- ค่า Information gain ที่ได้จากการแยกข้อมูลจากลักษณะประจำ A

# การเลี่ยงปัญหา Overfitting problem

- **Decision tree** ที่มีปัญหา **overfitting** มักเป็นต้นไม้ที่มีกิ่งก้านแตกไปมากมาย แต่ละกิ่งมีข้อมูลอยู่ปริมาณน้อย
- วิธีการเลี่ยงปัญหา **overfitting** ใน **decision tree** ทำได้สองลักษณะ
  - การตัดแต่งกิ่งระหว่างสร้างต้นไม้ : หยุดการสร้างต้นไม้เมื่อตัววัดในการแตกกิ่งมีค่าต่ำกว่าเกณฑ์ที่กำหนด เช่นจำนวนข้อมูลในจุดยอดน้อยจนเกินไป
  - การตัดแต่งกิ่งหลังสร้างต้นไม้ : การลดจำนวนกิ่ง กำจัดกิ่งโดยยังคงความถูกต้องของการจำแนกประเภทในระดับที่ยอมรับได้
    - วิธีการใช้วิธีแบ่ง **validation data** เพื่อใช้ทดสอบการตัดแต่งกิ่งเลือกต้นไม้ที่ดีที่สุด “**best pruned tree**” สำหรับข้อมูล **validation data**

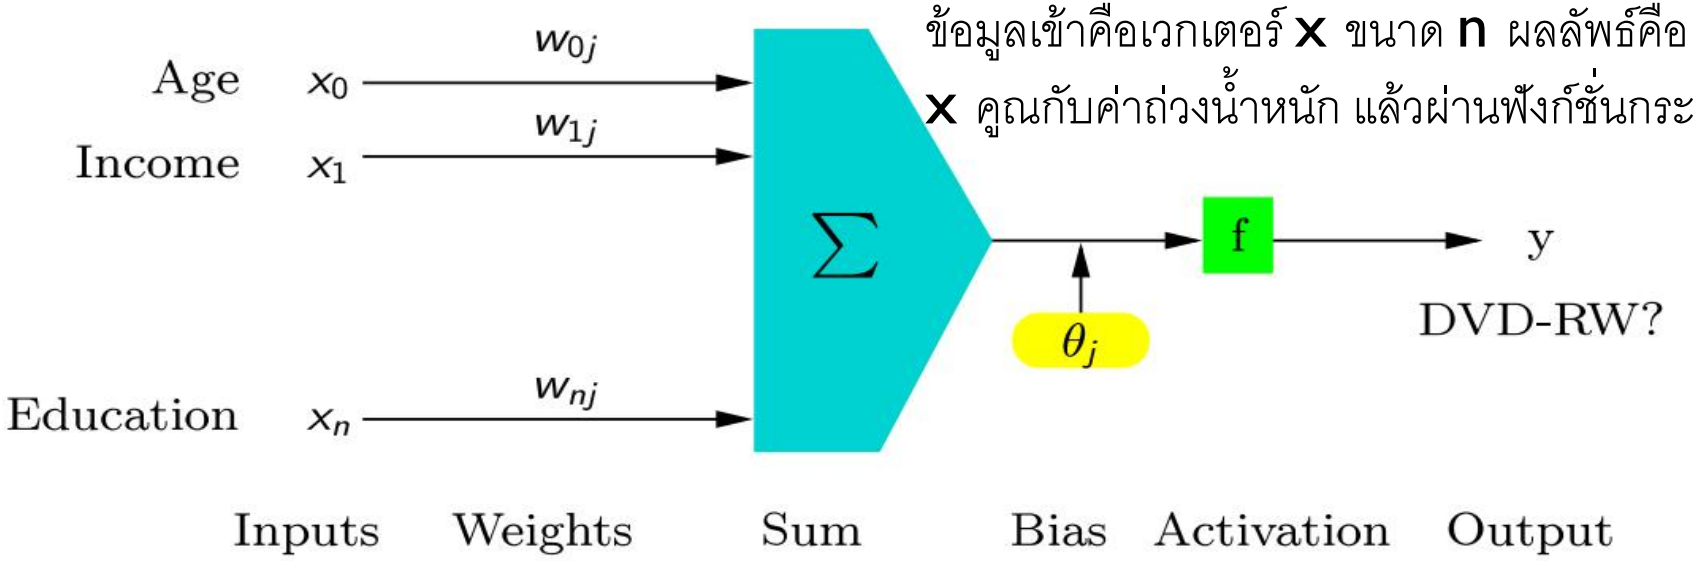
# ลักษณะข้อมูลที่ต้องการของการวิเคราะห์ Classification

หมายรวมถึง Decision Tree, Naïve Bayesian และ Neural Network

- การจัดจำแนกประเภท (Classification) เป็นการสร้าง model เพื่อใช้จำแนก records ที่พบในอนาคตว่าจัดอยู่ในประเภทใด
- ข้อมูลที่ใช้ต้องมีลักษณะประจำเป้าหมาย (Class) ที่มีค่าไม่ต่อเนื่อง ส่วนมากเป็น binary แต่ถ้าเป็นตัวแปร nominal มากกว่า 2 ค่าก็สามารถวิเคราะห์ข้อมูลได้
- บาง algorithm เช่น ID3 ต้องการลักษณะประจำนำเข้าที่มีค่าไม่ต่อเนื่องเท่านั้น และบาง algorithm เช่น Logistic regression ต้องการลักษณะประจำที่มีค่าต่อเนื่องเท่านั้น
- แต่ algorithm ในปัจจุบันสามารถใช้ได้ทั้งลักษณะประจำที่มีค่าไม่ต่อเนื่อง หรือค่าต่อเนื่องก็ได้ จึงได้รับความนิยมมากขึ้น

# Neural Networks

- เป็นแนวคิดที่เทียบเคียงกันระหว่างโครงสร้างข้อมูล กับการเรียนรู้ของระบบประสาทในสมอง
  - สมองมนุษย์มีเซลล์ประสาทจำนวนมาก ที่รับสัญญาณกระตุ้นแล้วตัดสินใจส่งสัญญาณแปรผลออกไป คล้ายๆ กับมามองดูว่าลักษณะเชิงประชากรศาสตร์ของลูกค้าเป็นแบบใด ก็จะมี **model** มาตัดสินใจให้ทราบว่า สินค้าที่ต้องการซื้อคืออะไร....
-




$$y = f(w_{0j}x_0 + w_{1j}x_1 + \ldots + w_{nj}x_n + \theta_j)$$

# Multi-Layer Perceptron

- Activation Functions

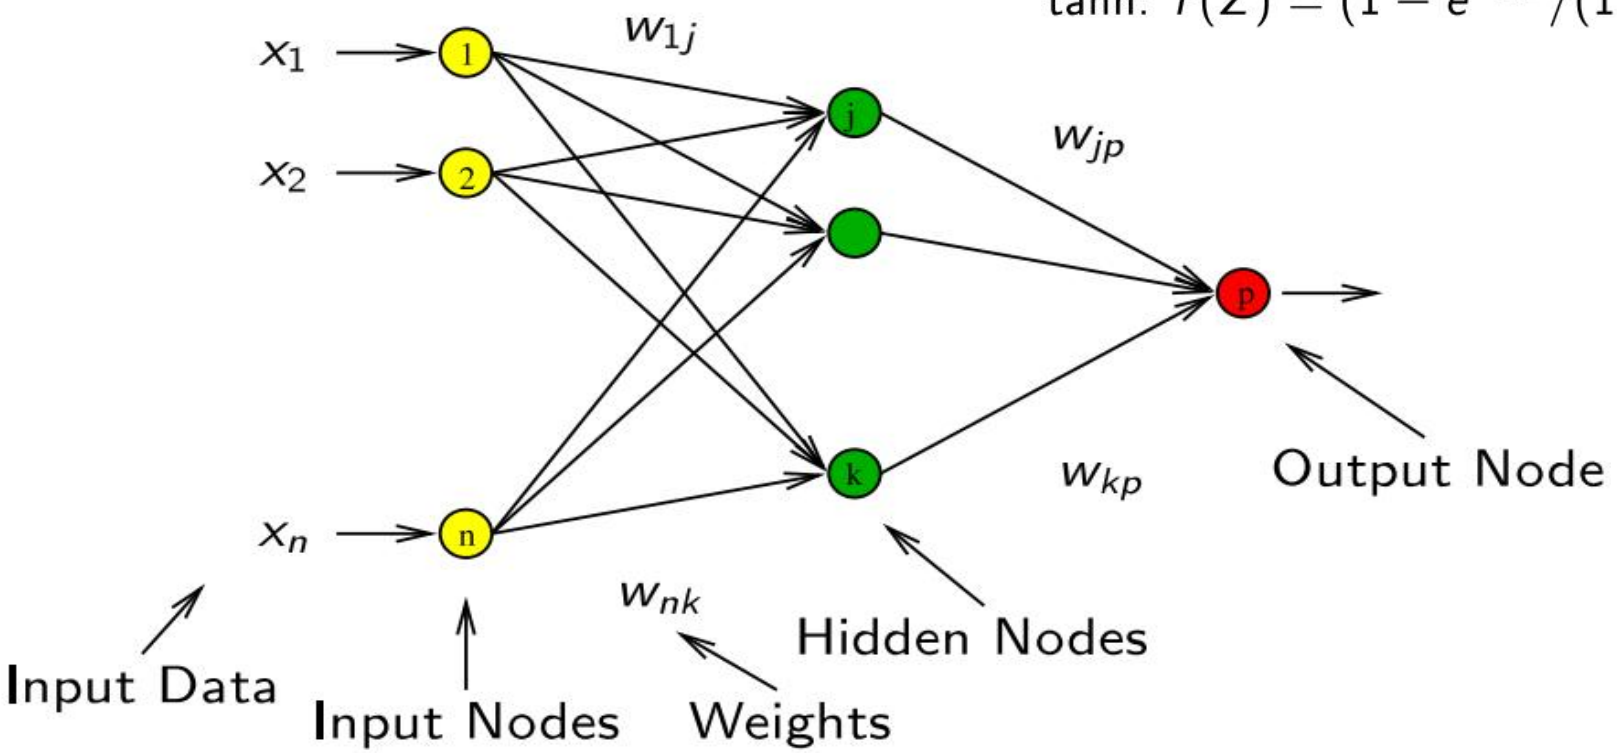
threshold

$Z > threshold : f(Z) = 1$

$Z \leq threshold : f(Z) = 0$

sigmoid: $f(Z) = 1/(1 + e^{-Z})$

tanh: $f(Z) = (1 - e^{-2Z}/(1 + e^{-2Z}))$



# การสร้าง Neural Networks

- สร้าง **network**
  - นำเข้าข้อมูล เลือกจำนวนของ **layers,** จำนวน **nodes** ในแต่ละ **layer**
- **Training the network** ด้วย **training data**
  - เริ่มกำหนดค่าถ่วงน้ำหนักอย่างสุ่ม
  - วนซ้ำกับชุดของตัวอย่างทีละรอบ **(Epoch)**
  - คำนวณหาผลลัพธ์ที่ได้จากการใช้ **network** โดยคำนวณแต่ละหนึ่งหน่วยสมอง **(neuron)** คำนวณค่าผลรวมถ่วงน้ำหนักของข้อมูลเข้าฟังก์ชั่นกระตุ้น **(activation)**
  - ถ้าค่าที่คำนวณผิดจากผลลัพธ์ที่ต้องการให้ปรับค่าถ่วงน้ำหนักให้เหมาะสม
  - ทำซ้ำจนกระทั่งครบตามเงื่อนไขการหยุด เช่น การเรียนรู้เริ่มไม่ดีขึ้น หรือทำซ้ำจนครบจำนวนการทำซ้ำสูงสุดที่กำหนด **(Max epochs)**

# การปรับปรุง Neural Networks ให้ดีขึ้น

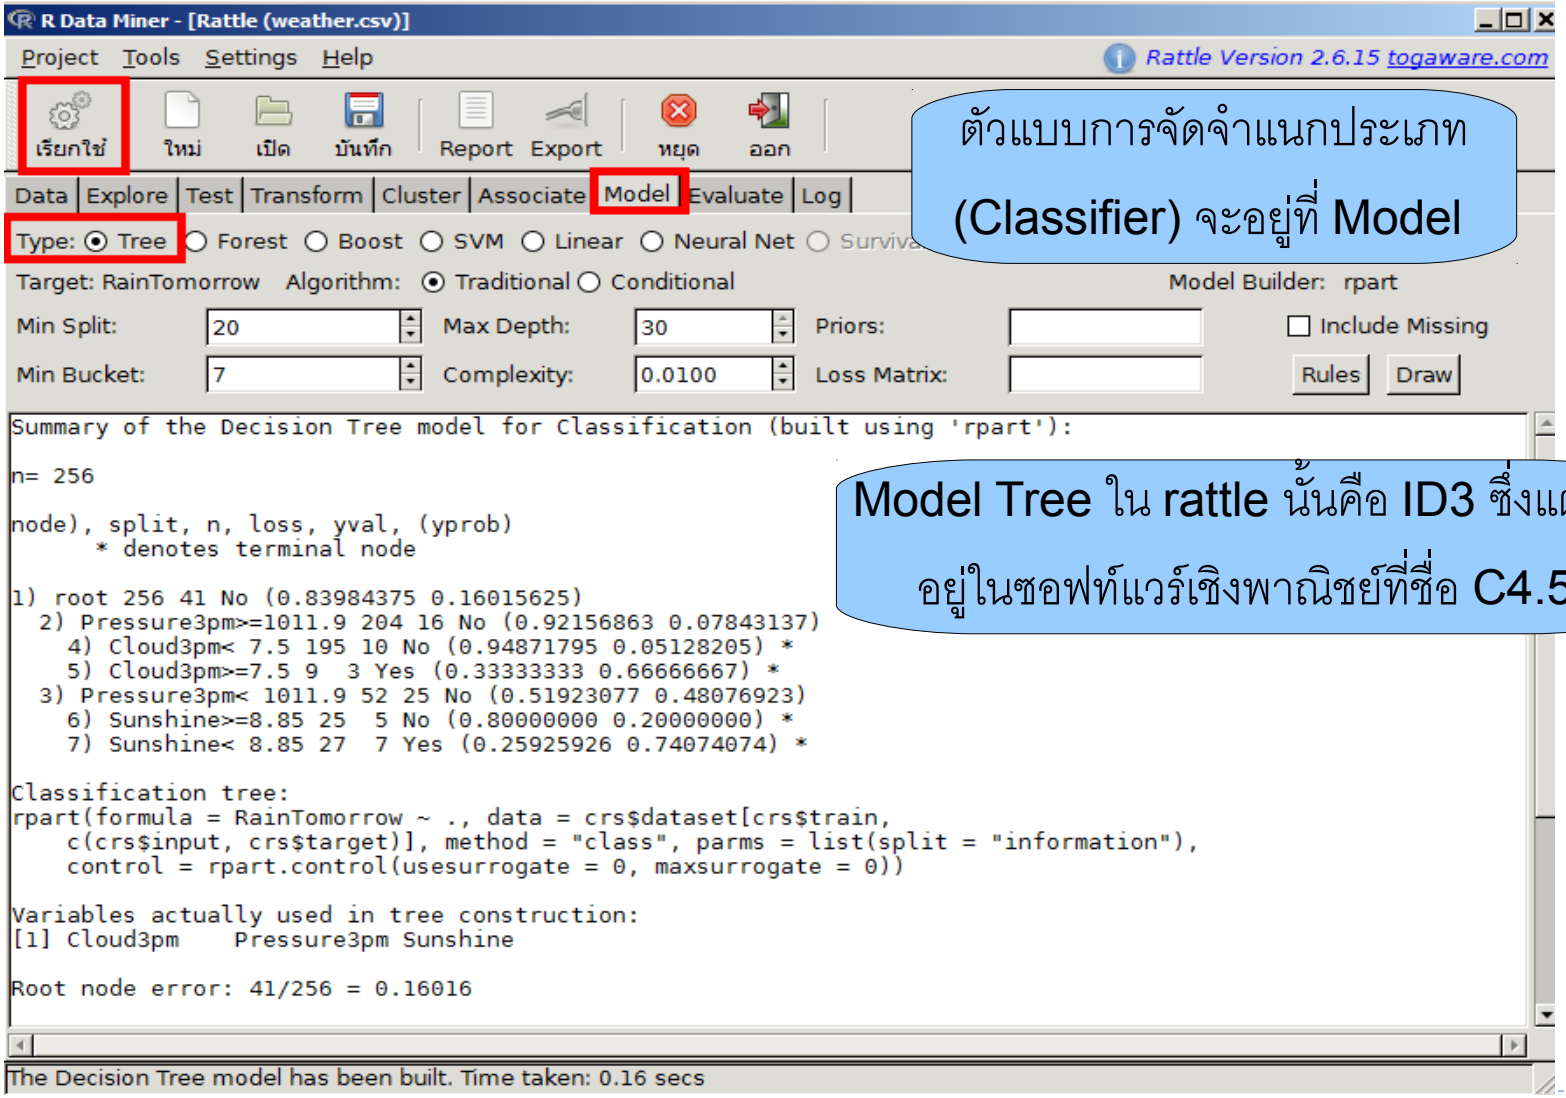
- กำจัดสายที่เชื่อมโยงระหว่างหนึ่ง **neuron** เพราะการใช้สายเชื่อมโยงทั้งหมดในเครือข่ายทำให้การคำนวณช้าลง กล่าวคือถ้าข้อมูลมีขนาด **N** และจำนวน **node** ใน **hidden layer** คือ **h** ซึ่งโยงไปจุดยอดผลลัพธ์ **m** ตัว เราต้องใช้ค่าถ่วงน้ำหนักทั้งหมด **h(m+N)** ค่า
- สังเกตว่าการมีจุดยอดใน **hidden layer** ที่มากจะทำให้การเรียนรู้นาน และยังก่อให้เกิดปัญหา **ovefitting problem** ด้วย

| | | |
|---|---|---|
| Inputs | $I_j$ | $= \sum_i w_{ij} O_i + \theta_j$ |
| Outputs | $O_j$ | $= \frac{1}{1+e^{-I_j}}$ |
| Output Error | $Err_j$ | $= O_j(1 - O_j)(T_j - O_j)$ |
| Node Errors | $Err_j$ | $= O_j(1 - O_j) \sum_k Err_k w_{jk}$ |
| Propagate | $w_{ij}$ | $= w_{ij} + l \times Err_j \times O_i$ |
| | $\theta_j$ | $= \theta_j + l \times Err_j$ |

# Neural Networks

- ข้อดี
  - การทำนายให้ผลแม่นยำกว่าวิธีทั่วไป
  - **Model** ที่ได้ยังคงใช้ได้ดี แม้ว่าข้อมูลที่ใช้มี **error** อยู่ด้วย
  - ผลลัพธ์ที่ต้องการเป็นได้ทั้ง ค่าต่อเนื่องหรือค่าไม่ต่อเนื่องก็ได้
  - การหาผลลัพธ์ทำได้รวดเร็ว หลังจากผ่านกรรมวิธีการเรียนรู้แล้ว
- ข้อเสีย
  - ใช้เวลา **training** นาน (หาค่าถ่วงน้ำหนักที่ดีที่สุดในการเรียนรู้)
  - ยากที่จะทำความเข้าใจเกี่ยวกับการเลือกพารามิเตอร์ที่เหมาะสม **(best topology)**
  - ยากที่จะทำความเข้าใจเกี่ยวกับ **learned function**

# Rattle Training 9. Classifier Models




ตัวแบบการจัดจำแนกประเภท (Classifier) จะอยู่ที่ Model

Model Tree ใน rattle นั้นคือ ID3 ซึ่งแต่เดิมอยู่ในซอฟท์แวร์เชิงพาณิชย์ที่ชื่อ C4.5

# Rattle Training 9. Classifier Models

- คุณภาพของ Model ที่ได้ดูได้จาก Root node error
- ส่วนขนาดของ cp จะเป็นตัวกำหนดขนาดของ decision tree ที่ optimal

```
Classification tree:
rpart(formula = RainTomorrow ~ ., data = crs$dataset[crs$train,
    c(crs$input, crs$target)], method = "class", parms = list(split = "information"),
    control = rpart.control(usesurrogate = 0, maxsurrogate = 0))

Variables actually used in tree construction:
[1] Cloud3pm    Pressure3pm Sunshine

Root node error: 41/256 = 0.16016

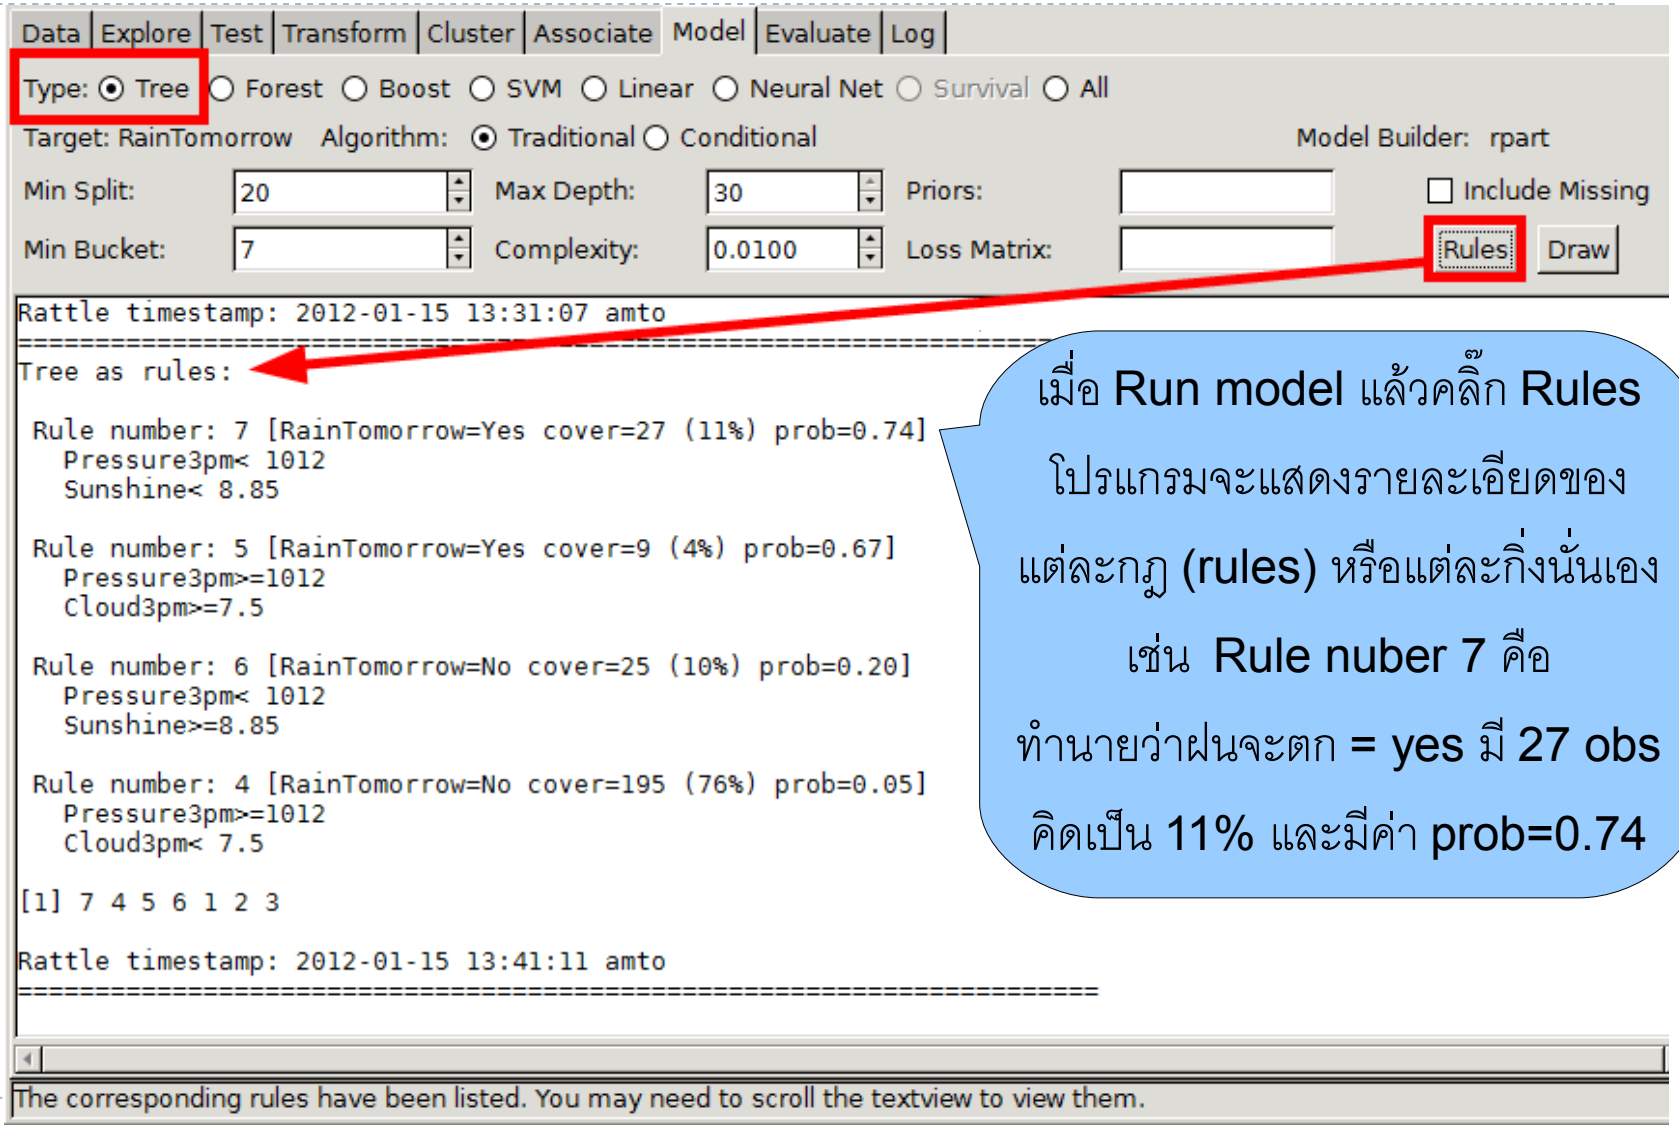
n= 256

        CP nsplit rel error  xerror    xstd
1 0.158537      0   1.00000 1.00000 0.14312
2 0.073171      2   0.68293 0.80488 0.13077
3 0.010000      3   0.60976 0.95122 0.14024

Time taken: 0.07 secs

Rattle timestamp: 2012-01-15 13:31:07 amto
=====================================================================
```

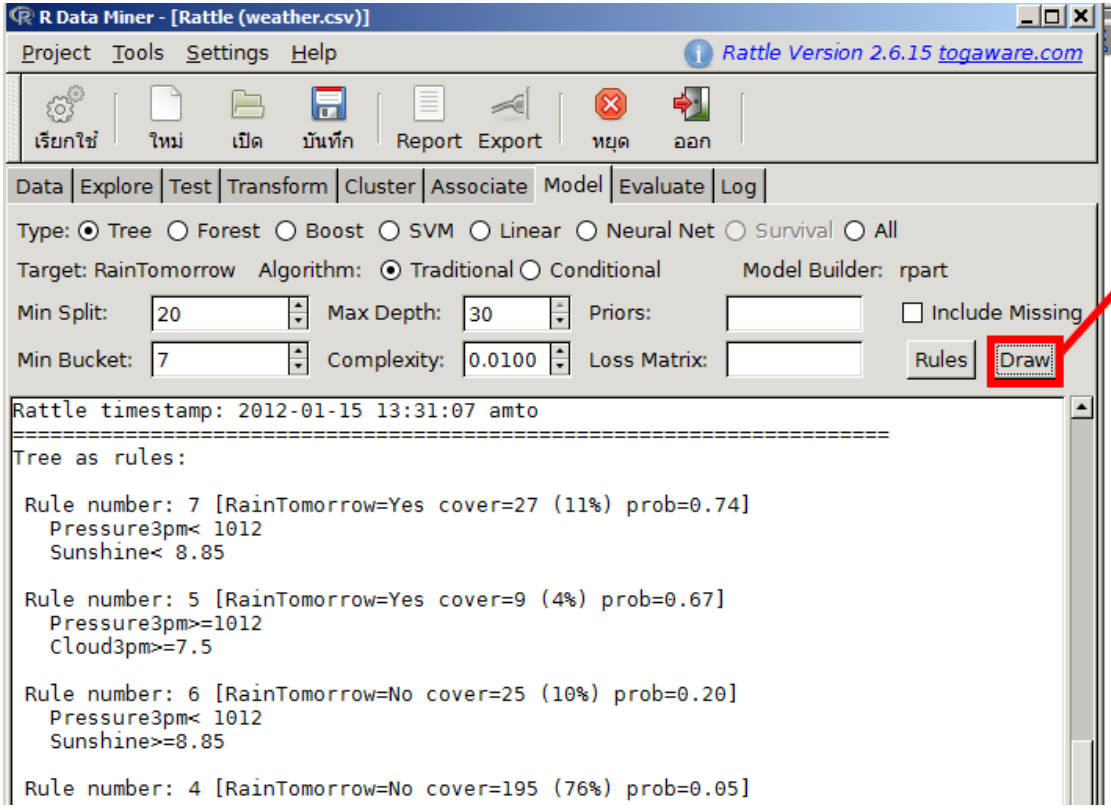
# Rattle Training 9. Classifier Models

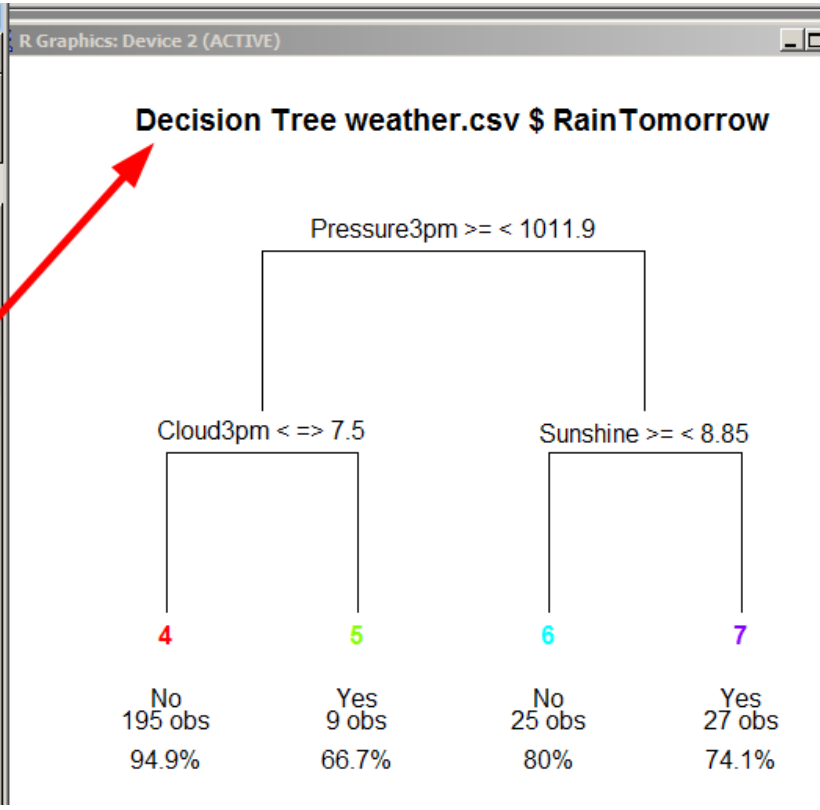



เมื่อ Run model แล้วคลิ๊ก Rules โปรแกรมจะแสดงรายละเอียดของแต่ละกฎ (rules) หรือแต่ละกิ่งนั่นเอง เช่น Rule nuber 7 คือ ทำนายว่าฝนจะตก = yes มี 27 obs คิดเป็น 11% และมีค่า prob=0.74

# Rattle Training 9. Classifier Models

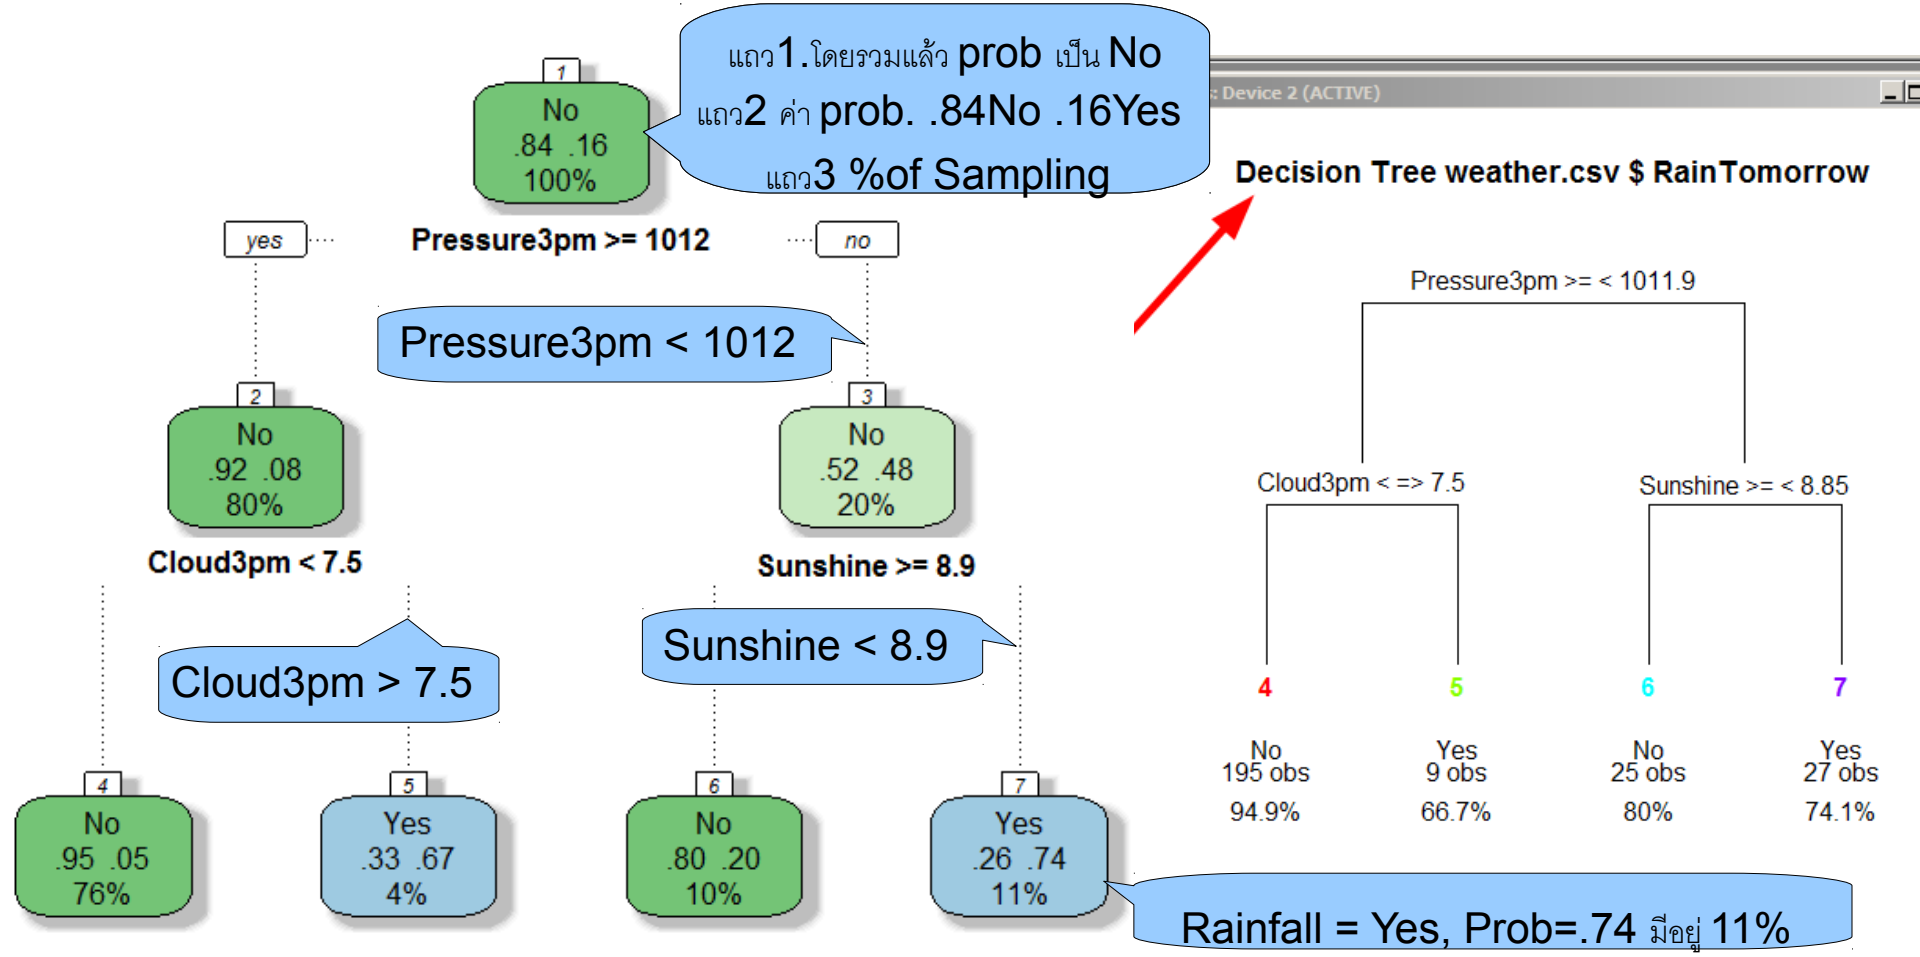
- คลิ๊กที่ **Draw** โปรแกรมจะแสดง **Decision Tree** ขึ้นมา



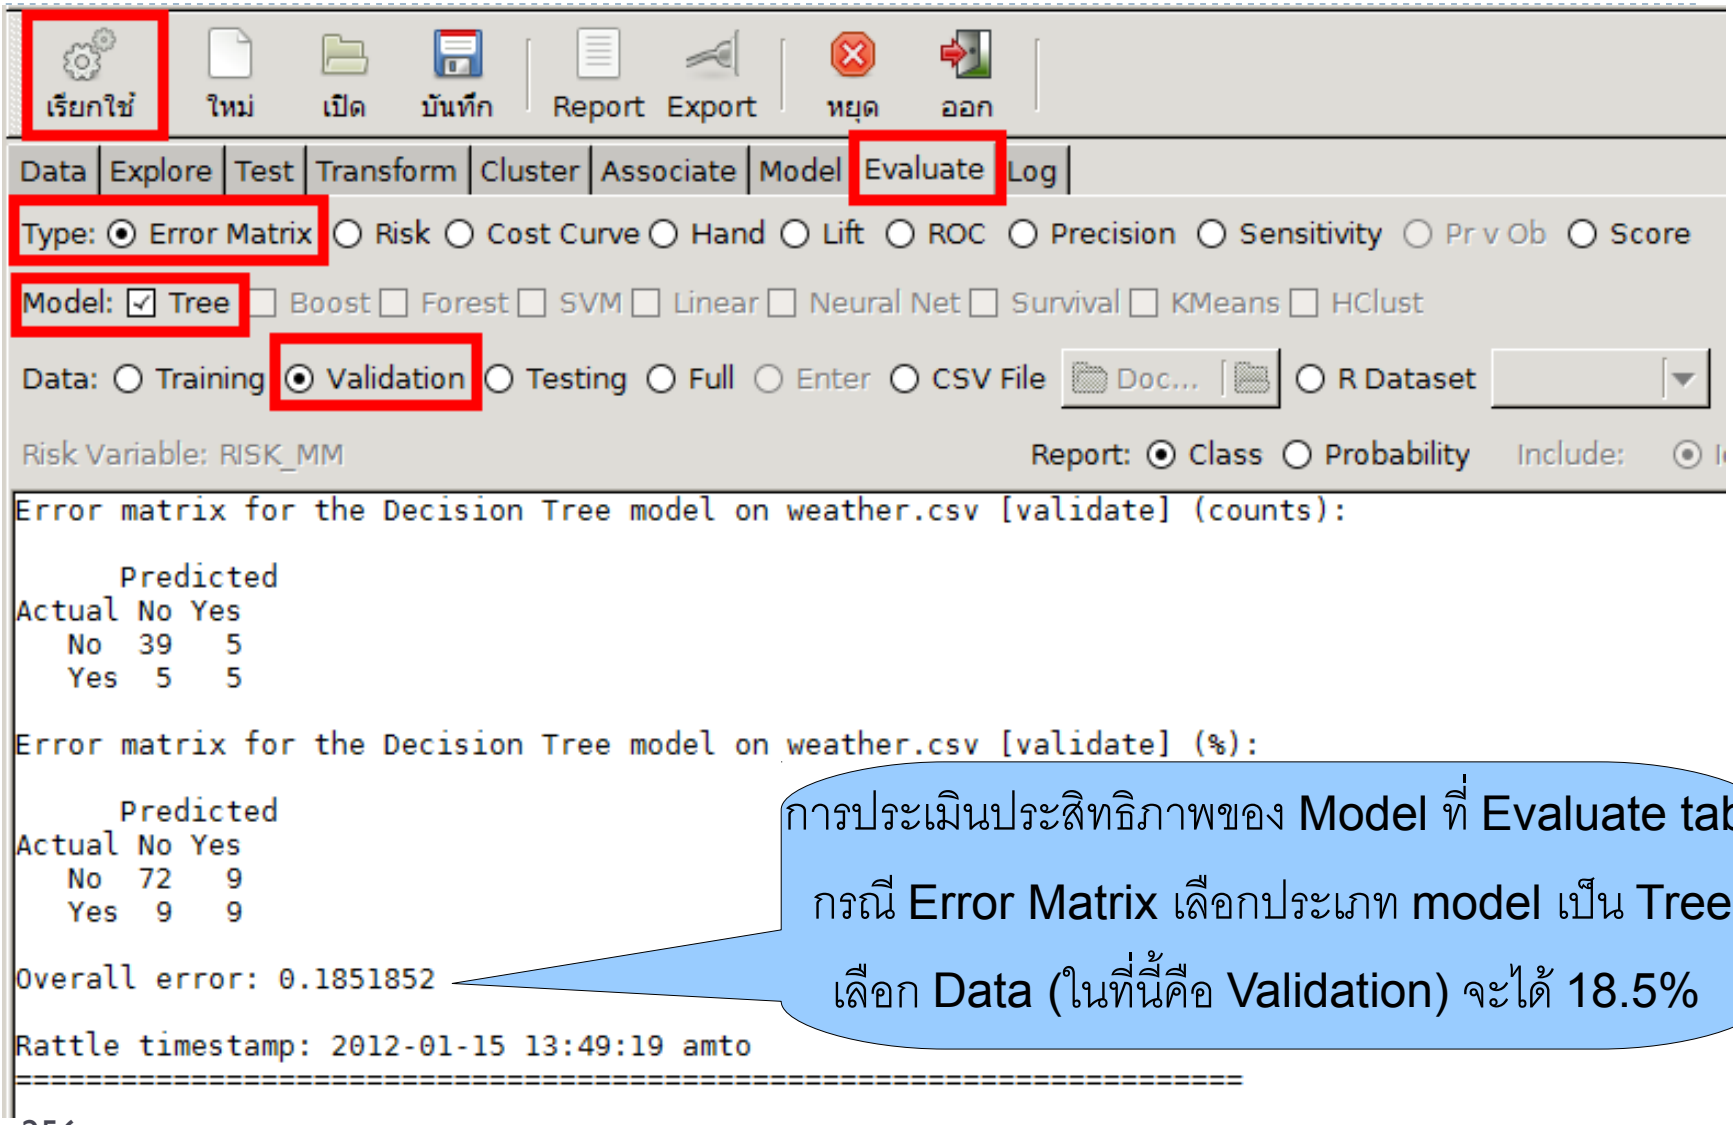



# Rattle Training 9. Classifier Models

- เปรียบเทียบเวอร์ชั่นใหม่-เก่า (กราฟที่แสดงมาจาก Testing)



# Rattle Training 9. Classifier Models



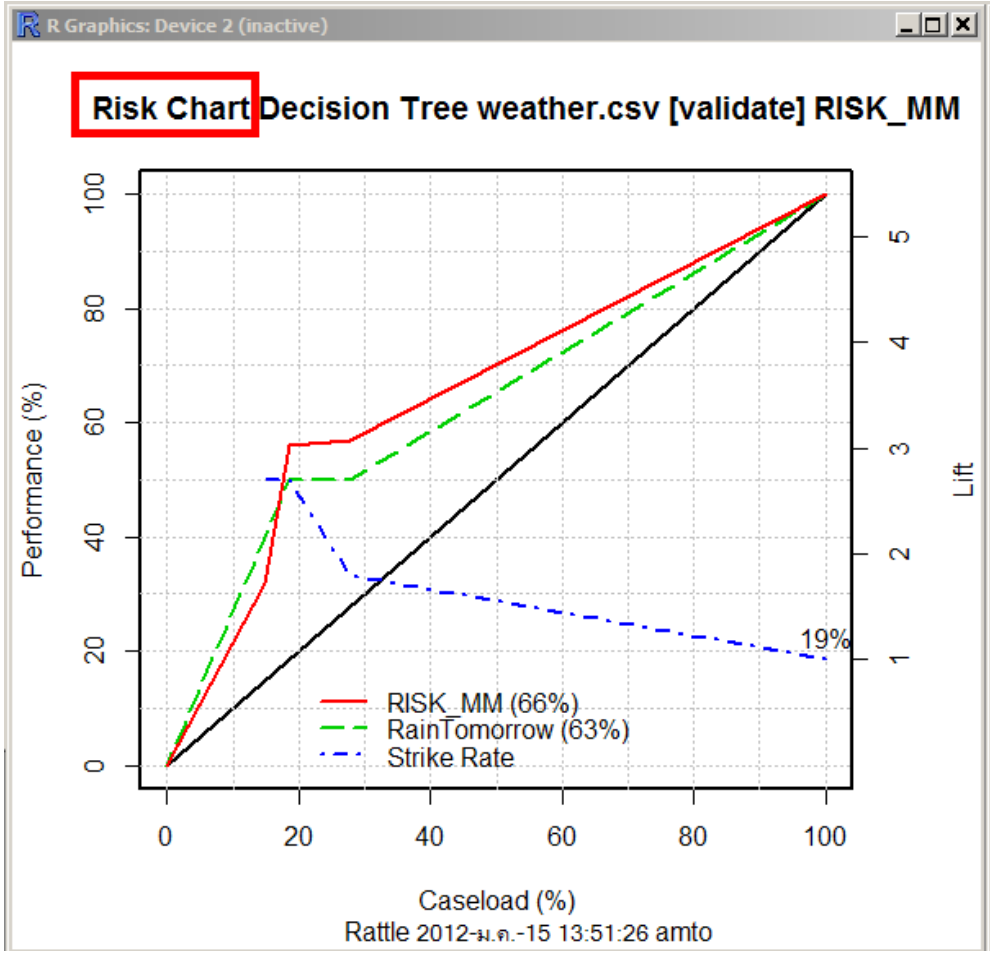

การประเมินประสิทธิภาพของ Model ที่ Evaluate tab.

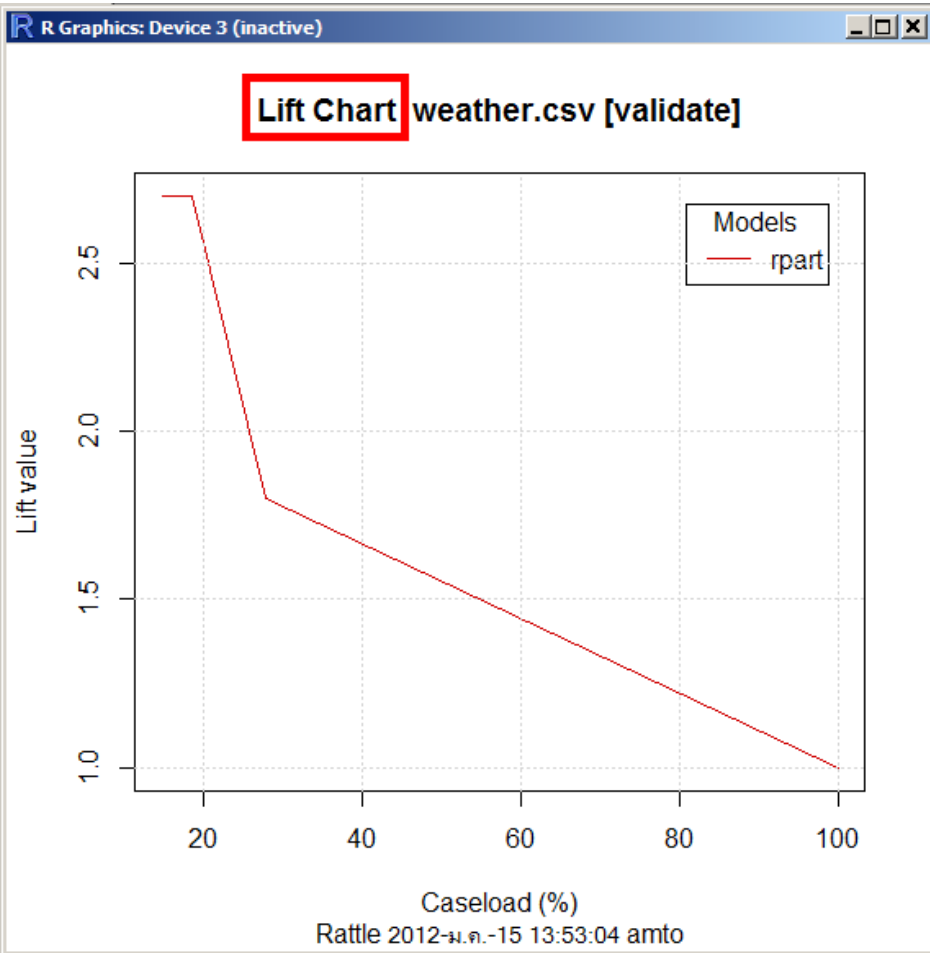
กรณี Error Matrix เลือกประเภท model เป็น Tree

เลือก Data (ในที่นี้คือ Validation) จะได้ 18.5%

# Rattle Training 9. Classifier Models

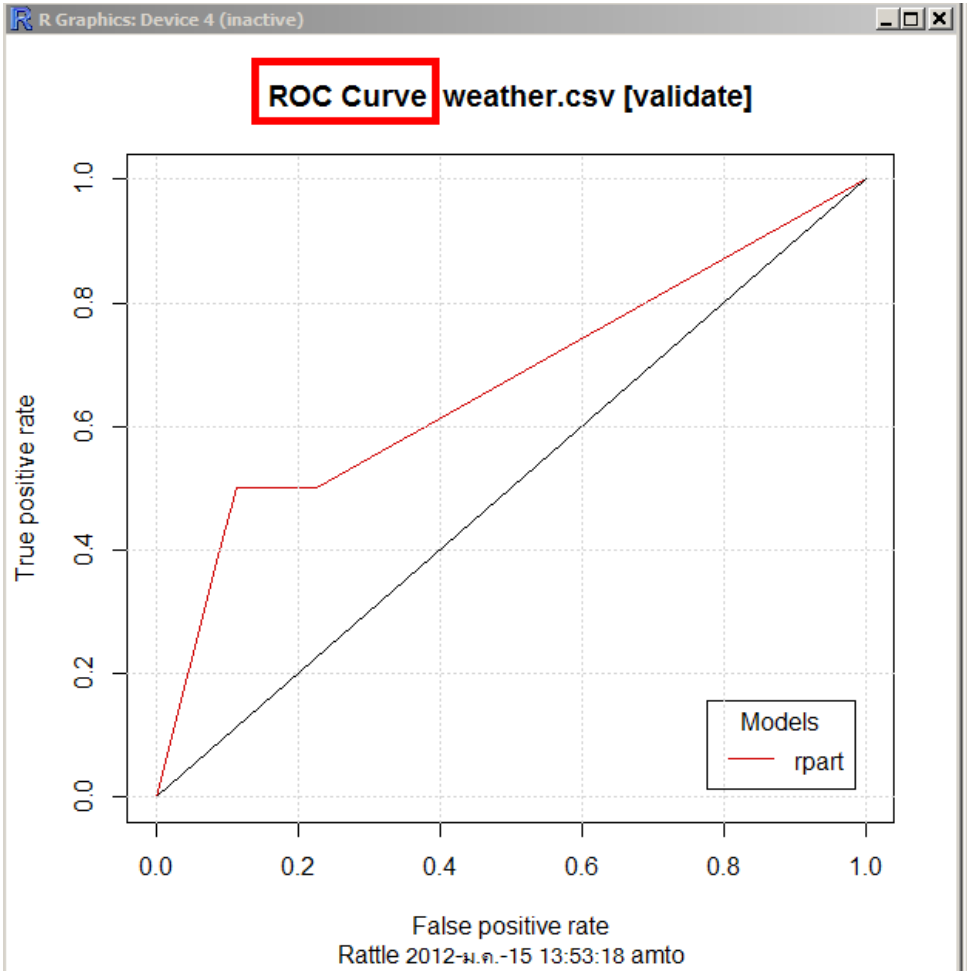
- เลือก **Risk & Lift Chart** (Rattle จะนำข้อมูลที่เราเลือกมาสร้างกราฟ)

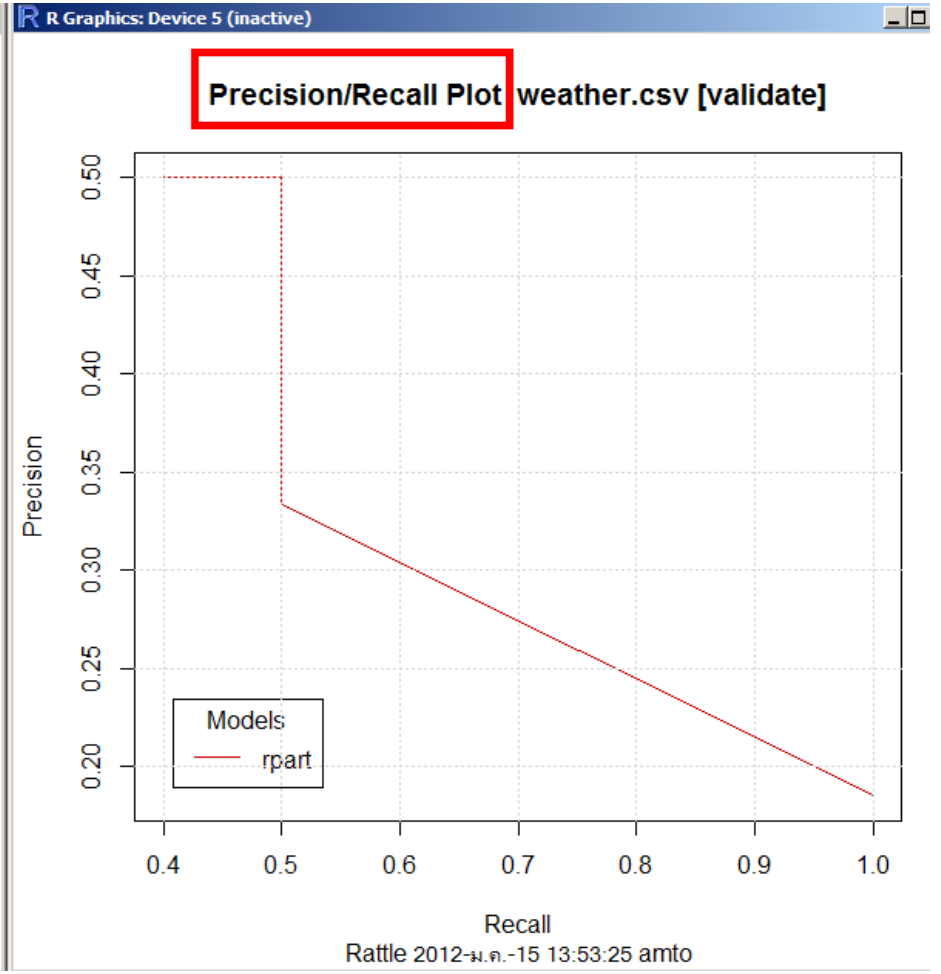


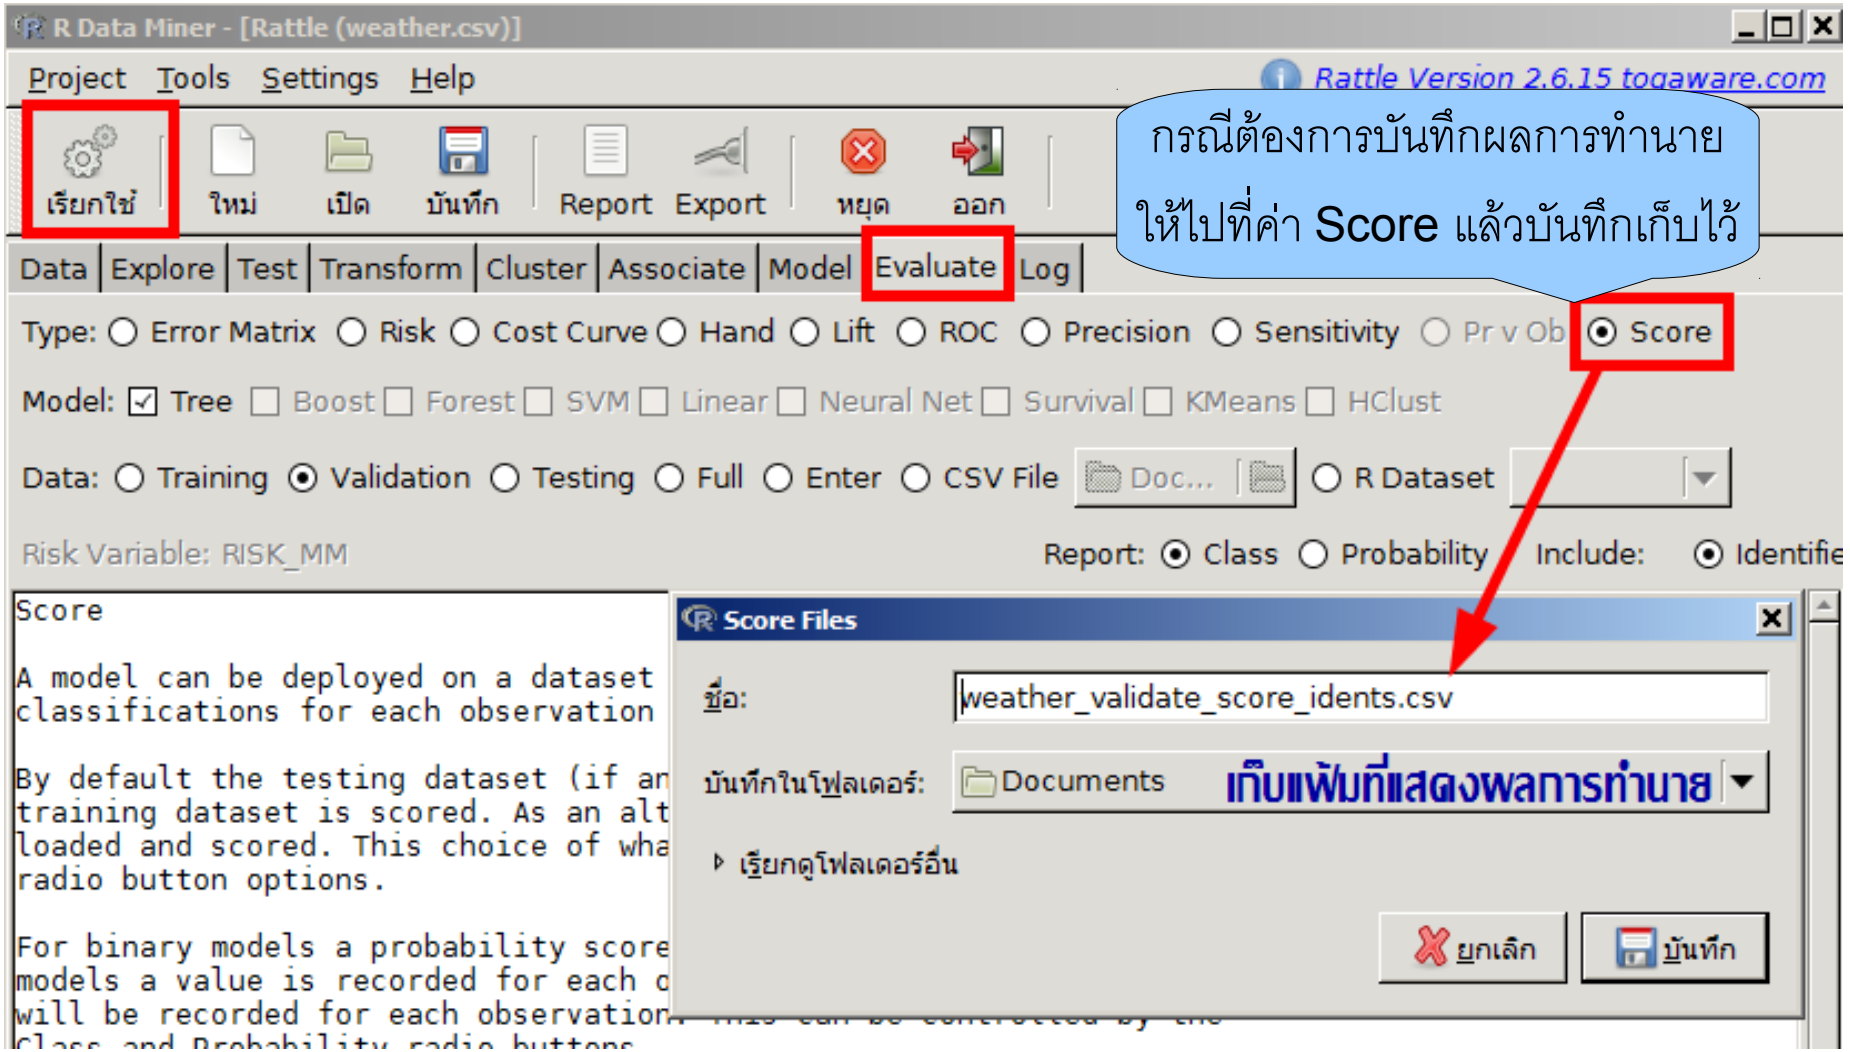
# Rattle Training 9. Classifier Models

- เลือก ROC & Precision/ Recall Plot.



# Rattle Training 9. Classifier Models

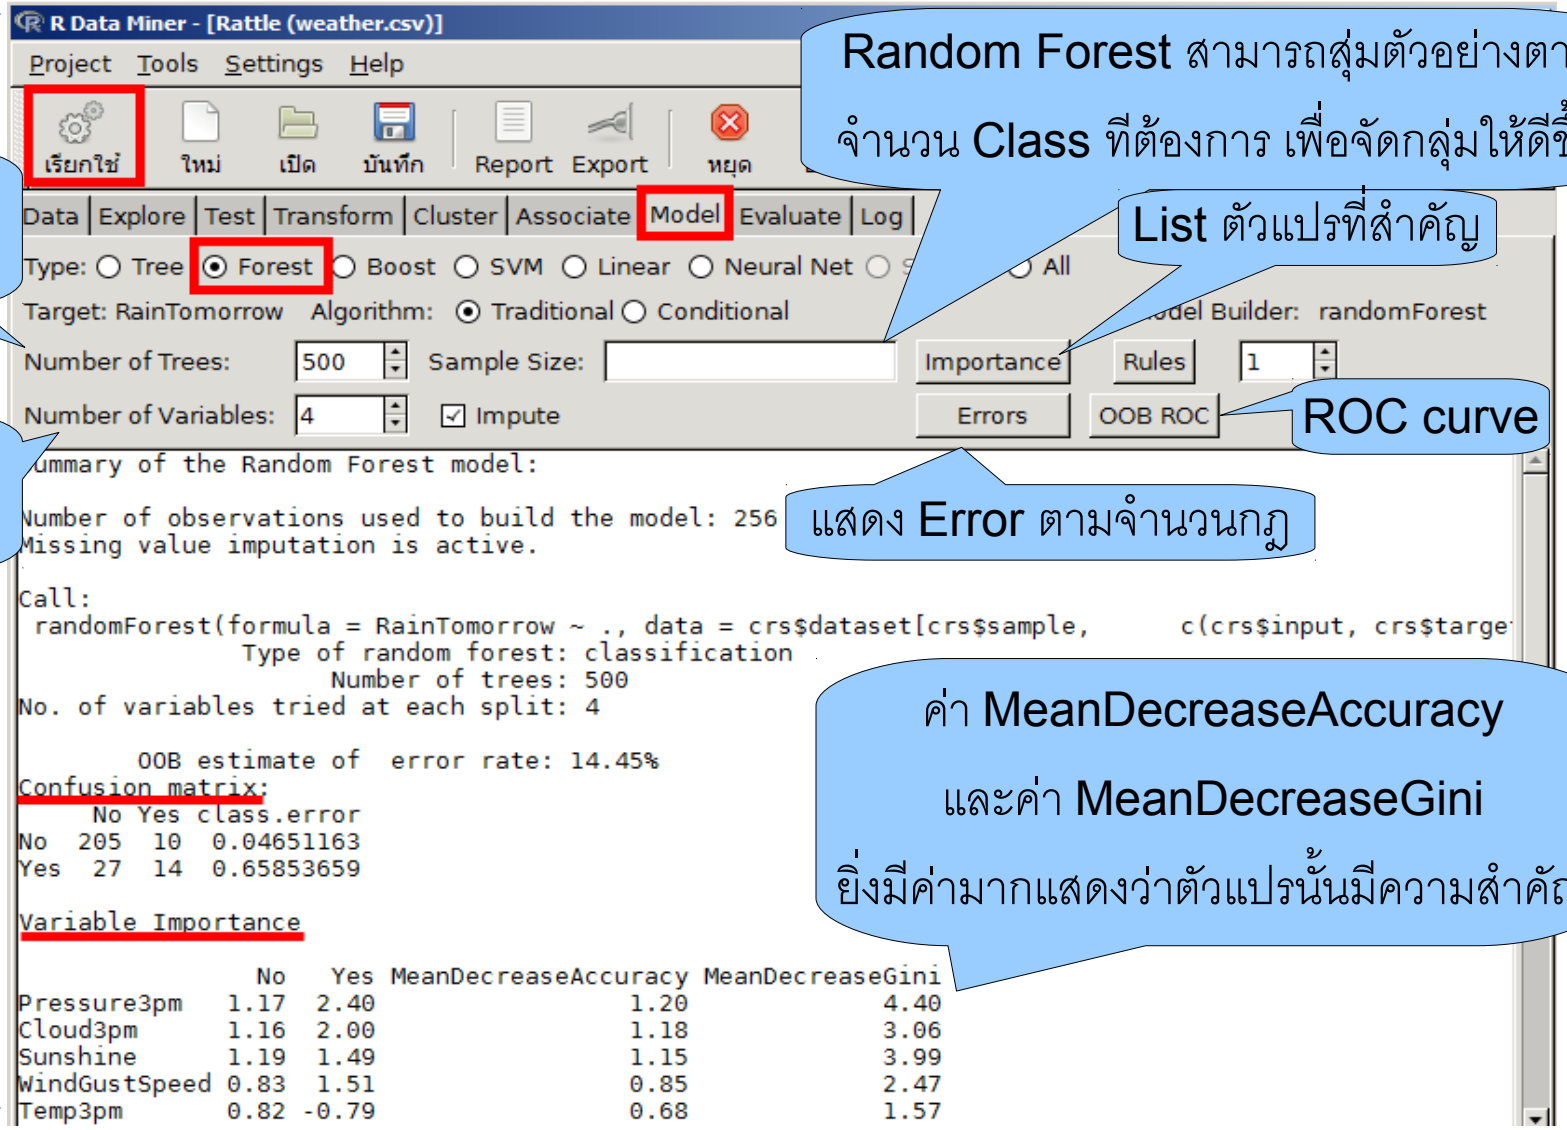


# Rattle Training 9. Classifier Models

Rattle ออกแบบมาให้เหมาะกับ Binary classification.

- สรุปเกี่ยวกับการปรับแต่ง Decision Tree
  - **Minimum Split** คือจำนวนต่ำสุดของ obs ที่จะเกิดขึ้นเป็น node (ถ้าข้อมูลที่ทดสอบมีแค่ 50 cases แต่กำหนดไป 51 โปรแกรมจะไม่สร้าง model
  - **Minimum Bucket Size** คือ จำนวนต่ำสุดของ obs ในแต่ละใบ (leaf node) โดยปกติควรตั้งค่า min bucket size ไว้ที่ 1/3 ของ Minimum Split
  - **Cp** ย่อมาจาก Complexity Parameter ซึ่งค่าดังกล่าวเราสามารถนำมาควบคุมขนาดของ decision tree ว่าจะมีขนาดเป็นเท่าไร จึงจะเป็นจุดที่เหมาะสม (optimal size) ค่าปริยายคือ 0.01 โดยค่า 0 หมายถึงกรณี unpruned นั่นคือ complete decision tree ซึ่งจะมีค่า maximum depth โดยทั่วไปกรณีค่า cp ต่ำๆ จะเรียนรู้ train ได้ดีเกินจริงหรือที่เราเรียกว่า Over-fitting ดังนั้นเราอาจปรับแต่งค่า cp สำหรับ tree size ที่เหมาะสม โดยพิจารณาดู xerror ควบคู่กัน เพื่อจะสามารถนำไปใช้ predict unseen data set ได้ดีขึ้น
  - **Priors** ใช้กำหนดสัดส่วนของ class ให้สะท้อนถึงสัดส่วนจริงๆ ใน population ซึ่งผลรวมต้องเท่ากับ 1 เช่น กรณีมี 3 class อาจกำหนดสัดส่วนเป็น 0.3,0.5,0.2 เป็นต้น
  - **Loss Matrix** ใช้เป็นตัว Weight ค่าผลลัพธ์การทำนาย class เช่น กรณีมีแค่ 2 class จะต้องใส่ 4 ค่า คือ 0,10,1,0 โดย 4 ตัวนี้แทนค่า (TN,FN,FP,TP)

# Rattle Training 9. Classifier Models




กำหนด จำนวน Tree

กำหนดจำนวน Variables

Random Forest สามารถสุ่มตัวอย่างตาม จำนวน Class ที่ต้องการ เพื่อจัดกลุ่มให้ดีขึ้น

List ตัวแปรที่สำคัญ

ROC curve

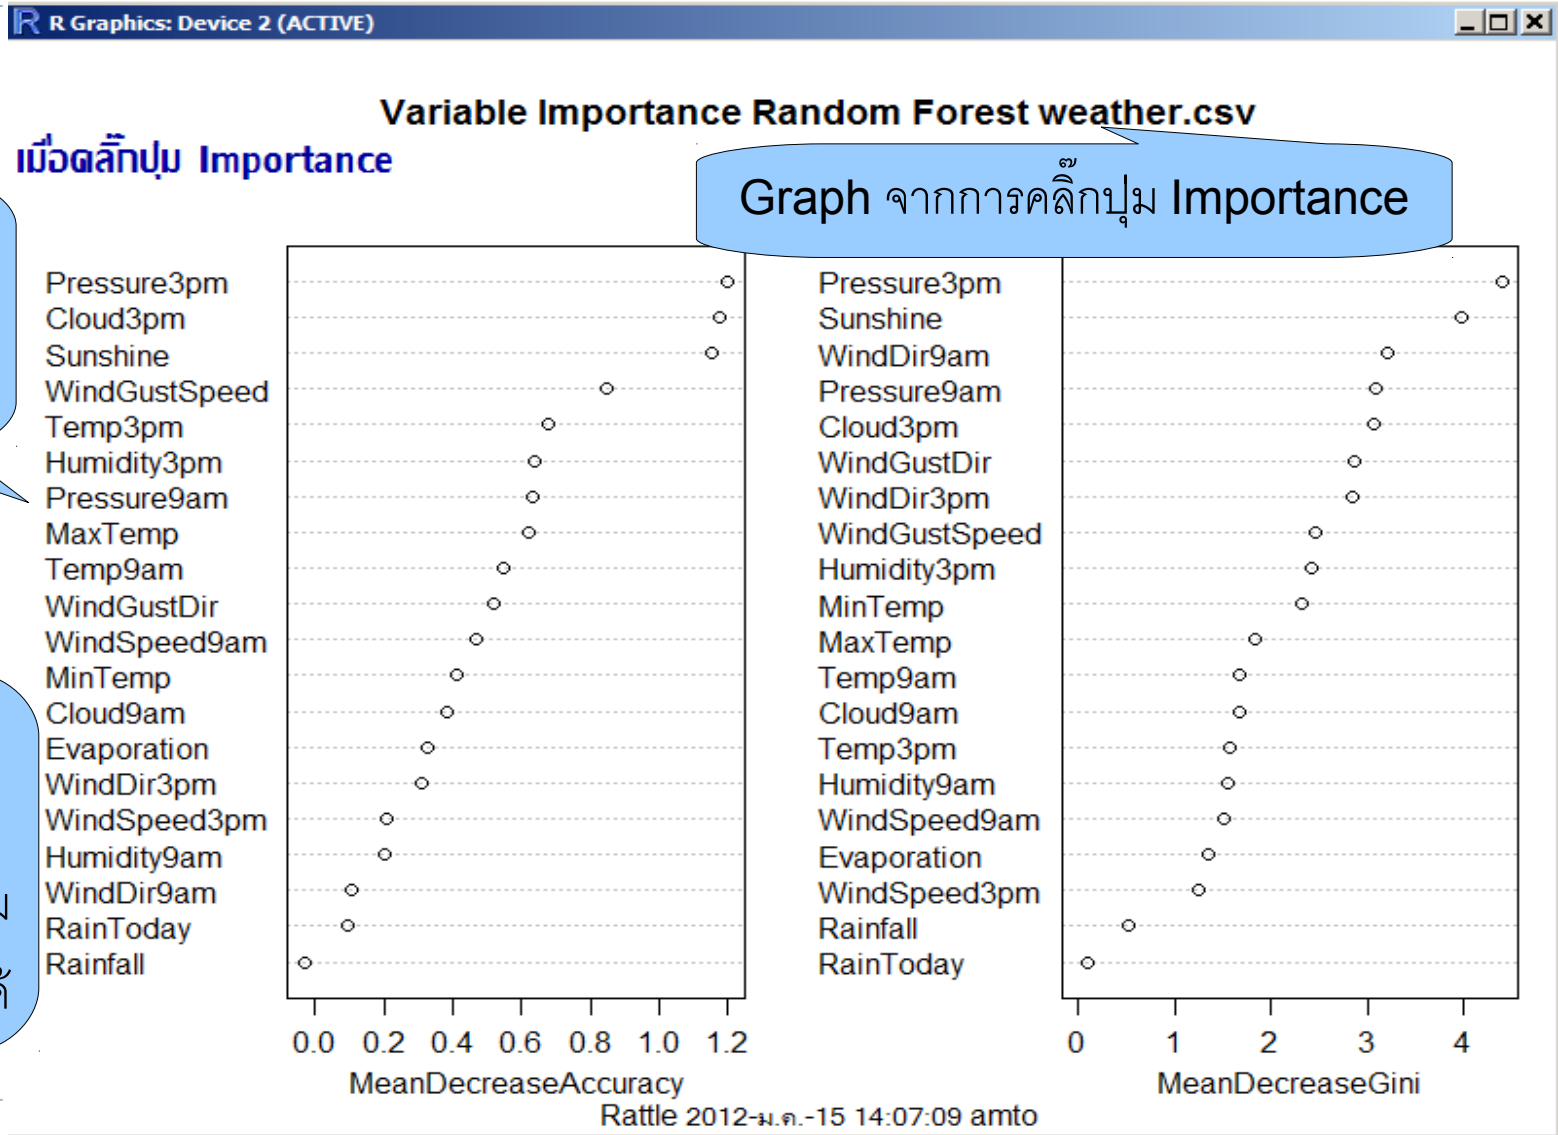
แสดง Error ตามจำนวนกฎ

ค่า MeanDecreaseAccuracy และค่า MeanDecreaseGini ยิ่งมีค่ามากแสดงว่าตัวแปรนั้นมีความสำคัญ

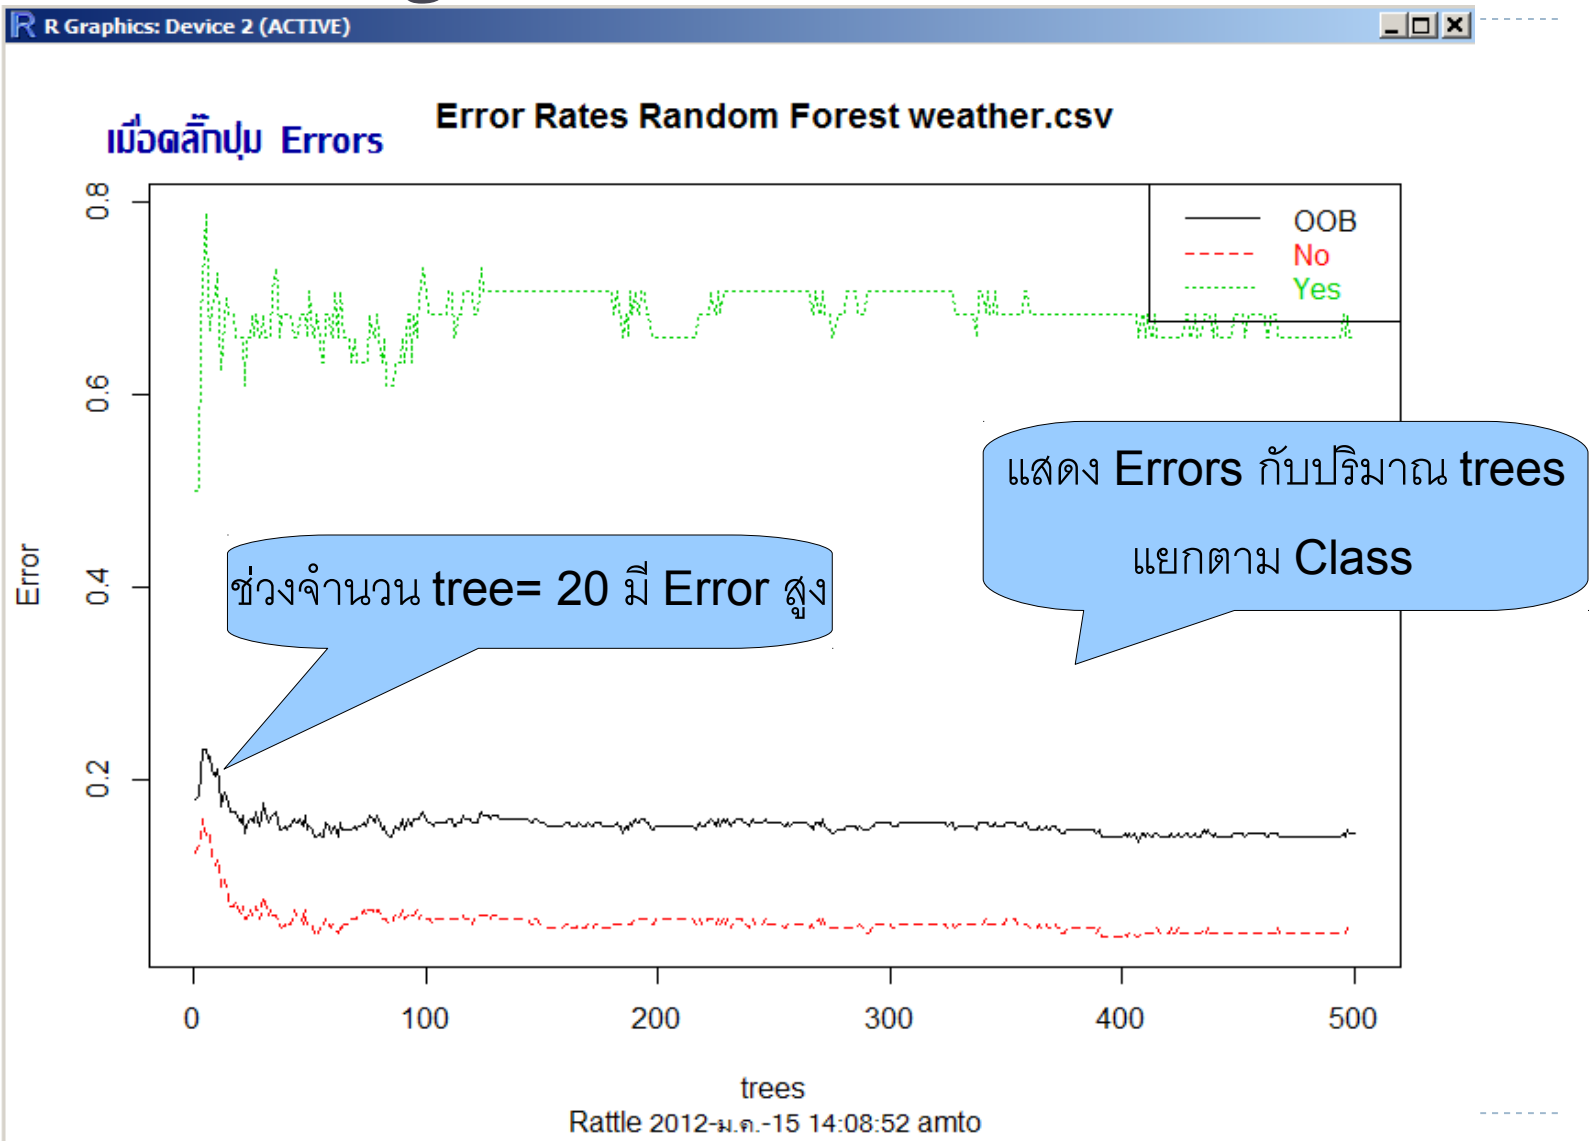
# Rattle Training 9. Classifier Models

2 Graph นี้ อาจแตกต่างกันบ้าง แต่พอเห็นตัวหลักๆ

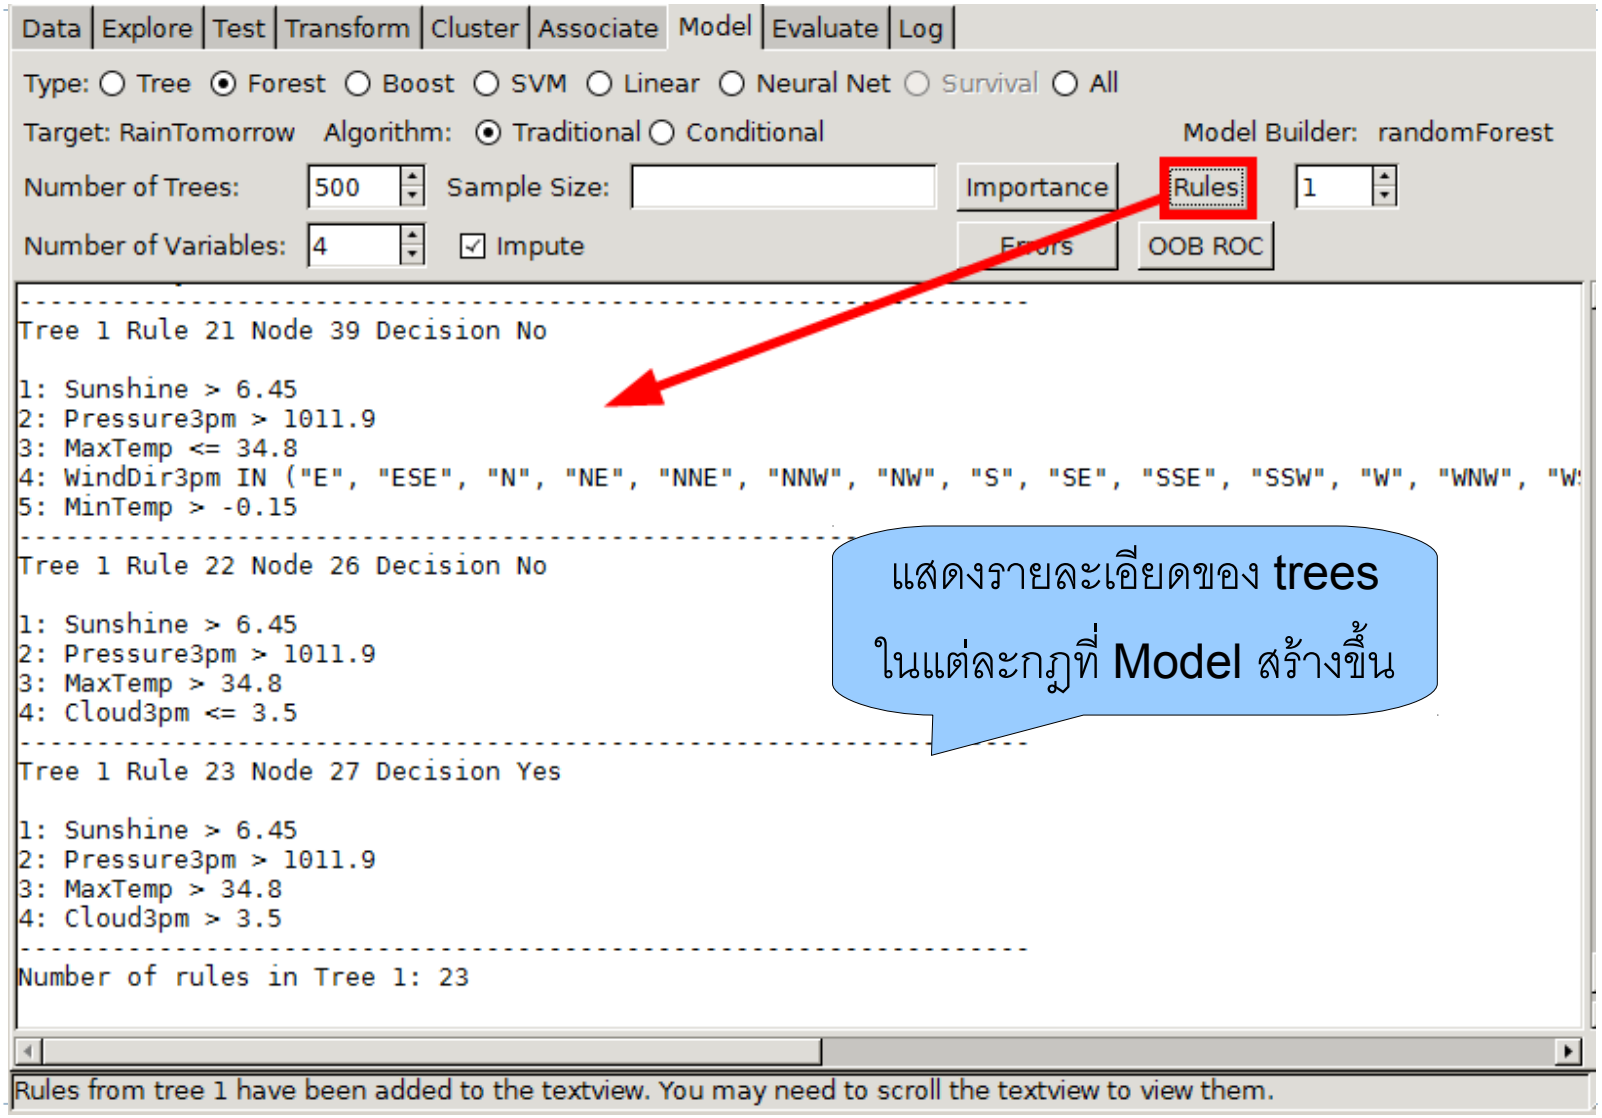
ความน่าสนใจอยู่ที่ การนำเอาตัวแปรเชิงปริมาณและกลุ่มมาสรุปอยู่ด้วยกันได้



# Rattle Training 9. Classifier Models

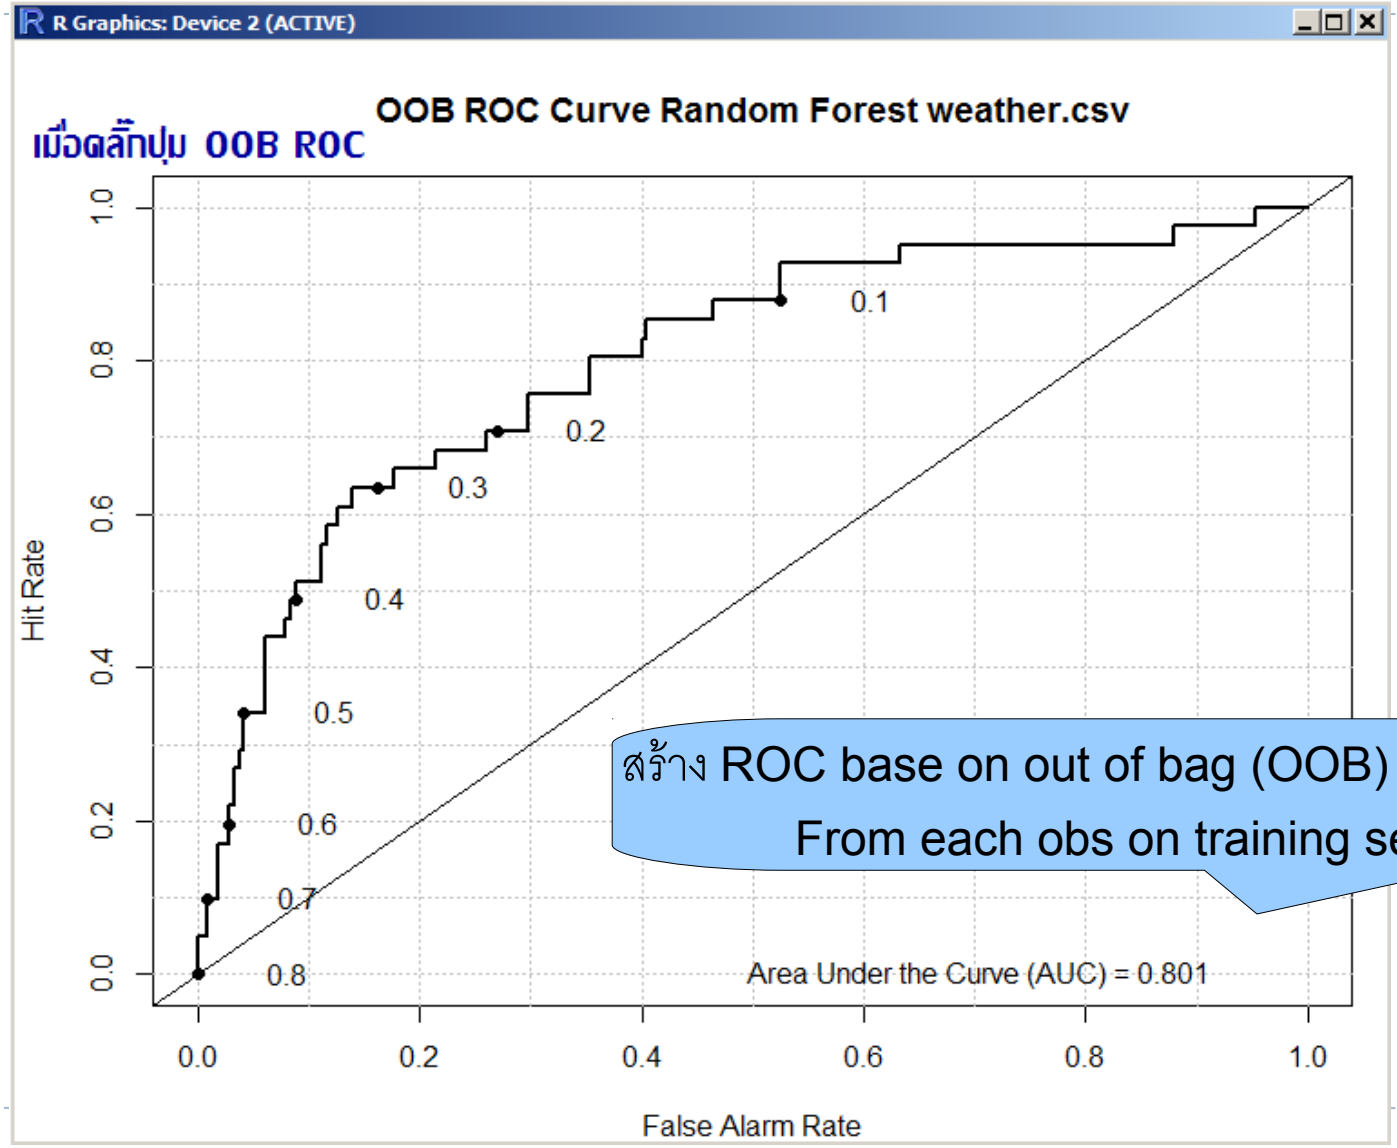


# Rattle Training 9. Classifier Models




แสดงรายละเอียดของ trees ในแต่ละกฎที่ Model สร้างขึ้น

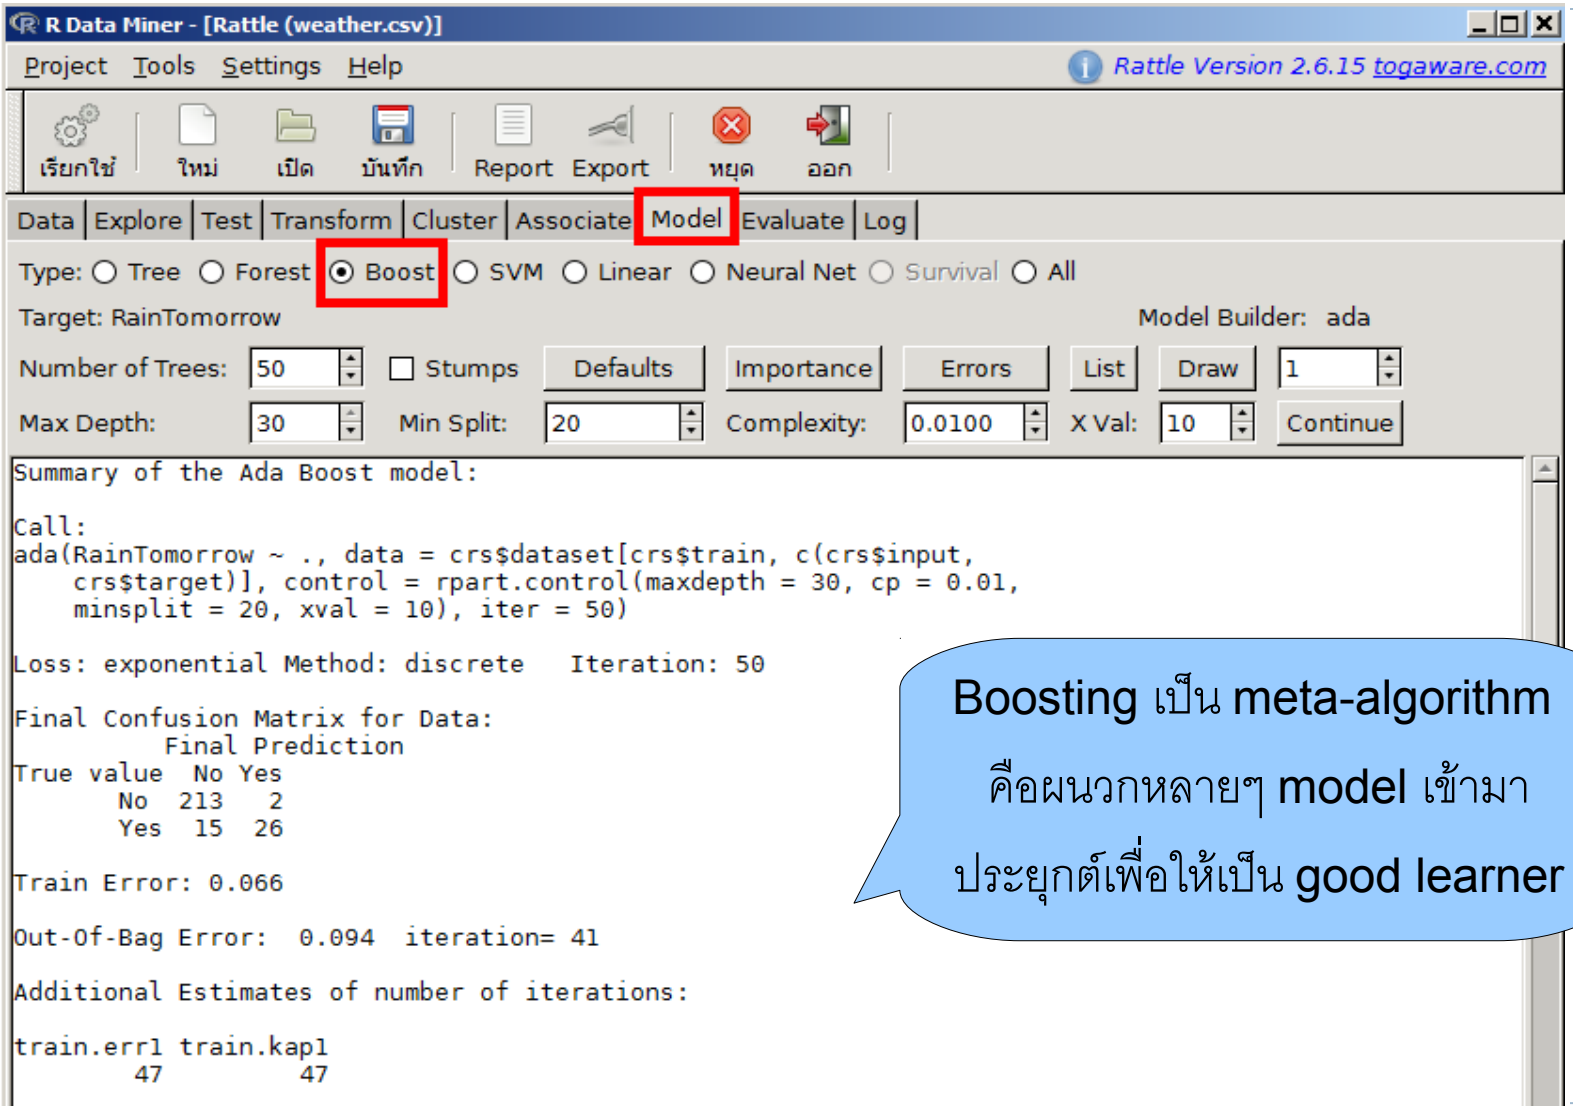
# Rattle Training 9. Classifier Models



# Rattle Training 9. Classifier Models

- สรุปเกี่ยวกับการปรับแต่ง Random Forest
  - **Number of Trees** คือจำนวน trees มี default = 500 แนะนำให้กำหนดขั้นต่ำที่ 100 เพราะยิ่งสร้างจำนวน trees ให้มากขึ้น model มีแนวโน้ม error ลดลง
  - **Number of Variables** คือจำนวนตัวแปรที่คัดเลือกเข้าไปสร้าง decision tree โดยทั่วไปค่าของจำนวนตัวแปรที่เหมาะสมคือ รากที่สองของจำนวนตัวแปรที่มีทั้งหมด
  - **Sample Size** การกำหนดกลุ่มตัวอย่างใน Random forest มีวัตถุประสงค์ ดังตัวอย่างต่อไปนี้ สมมุติในไฟล์ weather ซึ่งเป็น training set มี 5,000 obs. แต่มีข้อมูล rain tomorrow แค่ 500 obs. กรณีเช่นนี้ เราสามารถกำหนดให้มี rain & no rain เป็น 400,400 ก็จะทำให้ algorithm มีประสิทธิภาพขึ้น (มี probabilities)
  - **Variable Importance** เราสามารถกำหนดจำนวนตัวแปรที่สำคัญๆ เพื่อทำนายผลลัพธ์ ซึ่งพิจารณาได้จากค่า MeanDecreaseAccuracy, MeanDecreaseGini

# Rattle Training 9. Classifier Models




Boosting เป็น meta-algorithm คือผนวกหลายๆ model เข้ามาประยุกต์เพื่อให้เป็น good learner

# Rattle Training 9. Classifier Models

- **Boost** ใน **Rattle** ออกแบบมาให้ง่ายในการใช้งาน เราปรับแค่จำนวน **trees**

```
Variables actually used in tree construction:
 [1] "Cloud3pm"      "Cloud9am"      "Evaporation"   "Humidity3pm"
 [5] "Humidity9am"   "MaxTemp"       "MinTemp"       "Pressure3pm"
 [9] "Pressure9am"   "Rainfall"      "Sunshine"      "Temp3pm"
[13] "Temp9am"       "WindDir3pm"    "WindDir9am"    "WindGustDir"
[17] "WindGustSpeed" "WindSpeed3pm"  "WindSpeed9am"

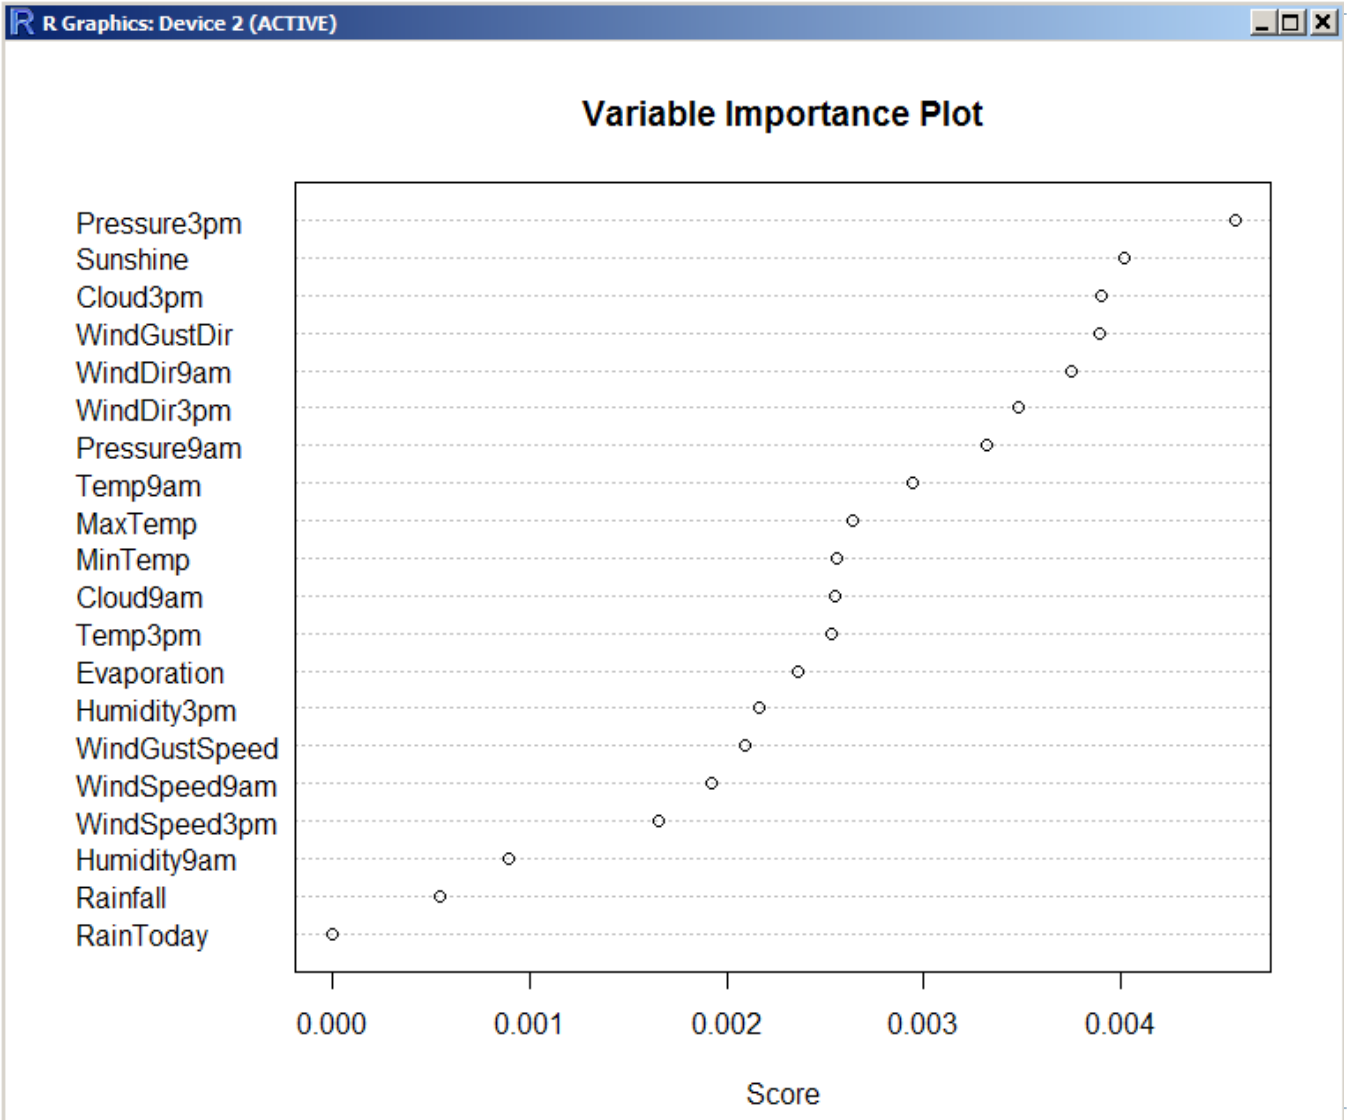
Frequency of variables actually used:

   WindDir9am    WindDir3pm      Sunshine   Pressure3pm   WindGustDir
           34            27            26            25            25
     Cloud3pm       MaxTemp      Temp9am WindGustSpeed      Cloud9am
           13             7             7             5             4
  Humidity3pm       MinTemp      Temp3pm  WindSpeed9am   Evaporation
            4             3             3             3             2
  Humidity9am  WindSpeed3pm   Pressure9am      Rainfall
            2             2             1             1

Time taken: 3.37 secs

Rattle timestamp: 2012-01-15 15:51:43 amto
==========================================================================
```

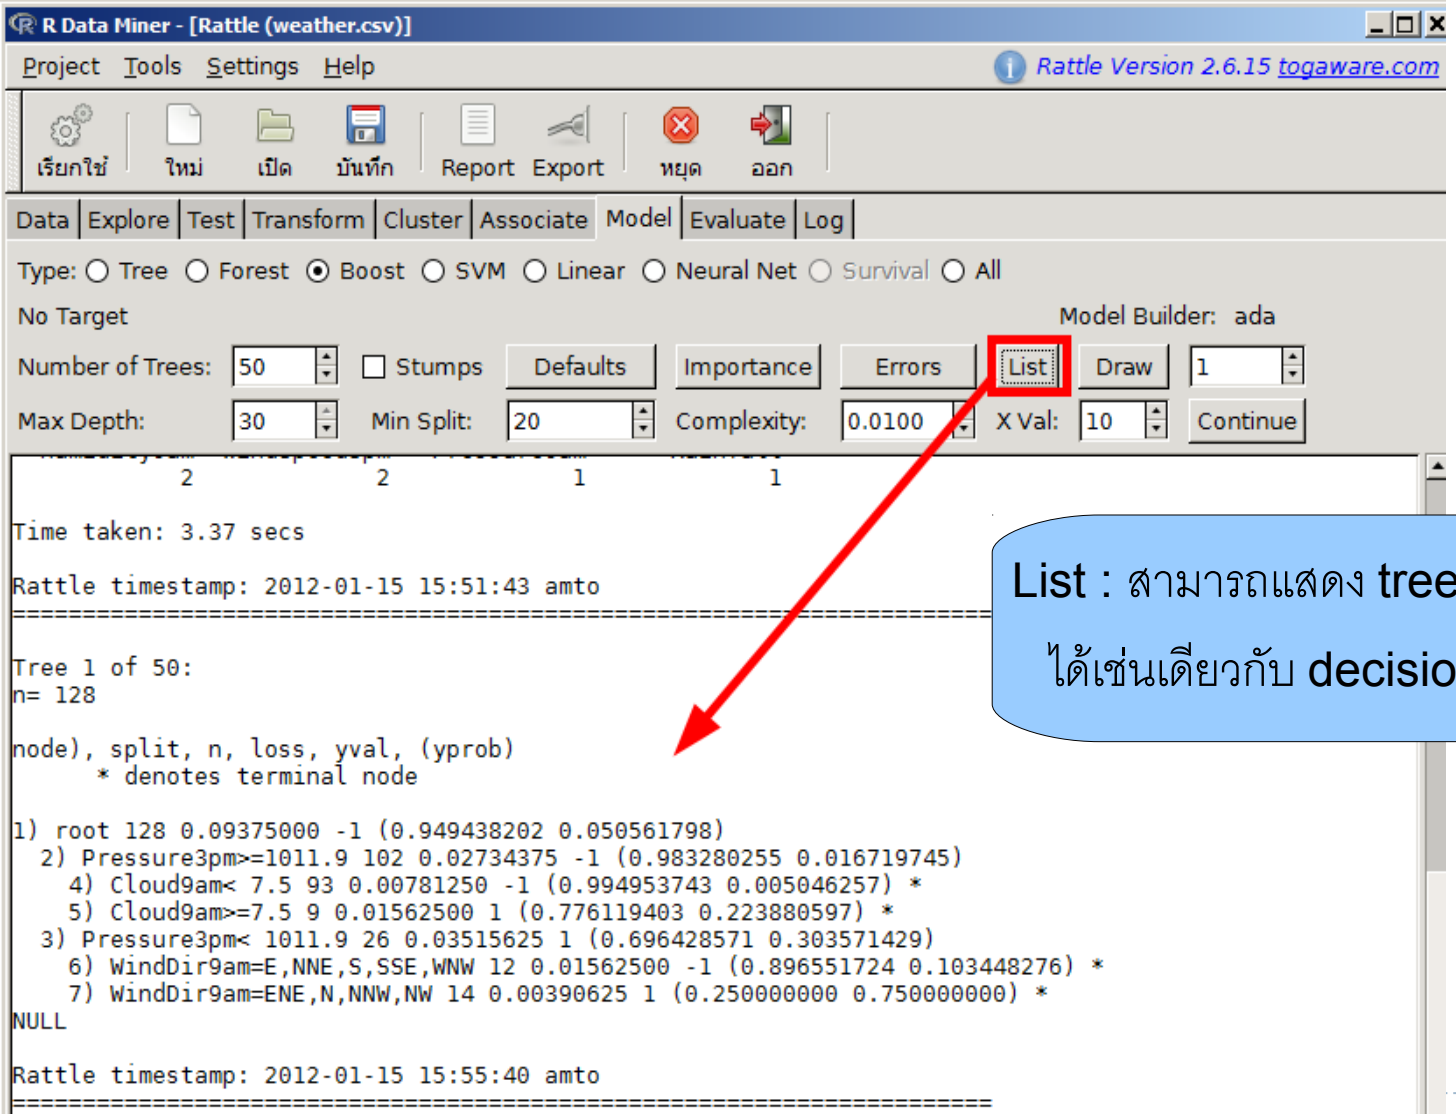
# Rattle Training 9. Classifier Models



# Rattle Training 9. Classifier Models

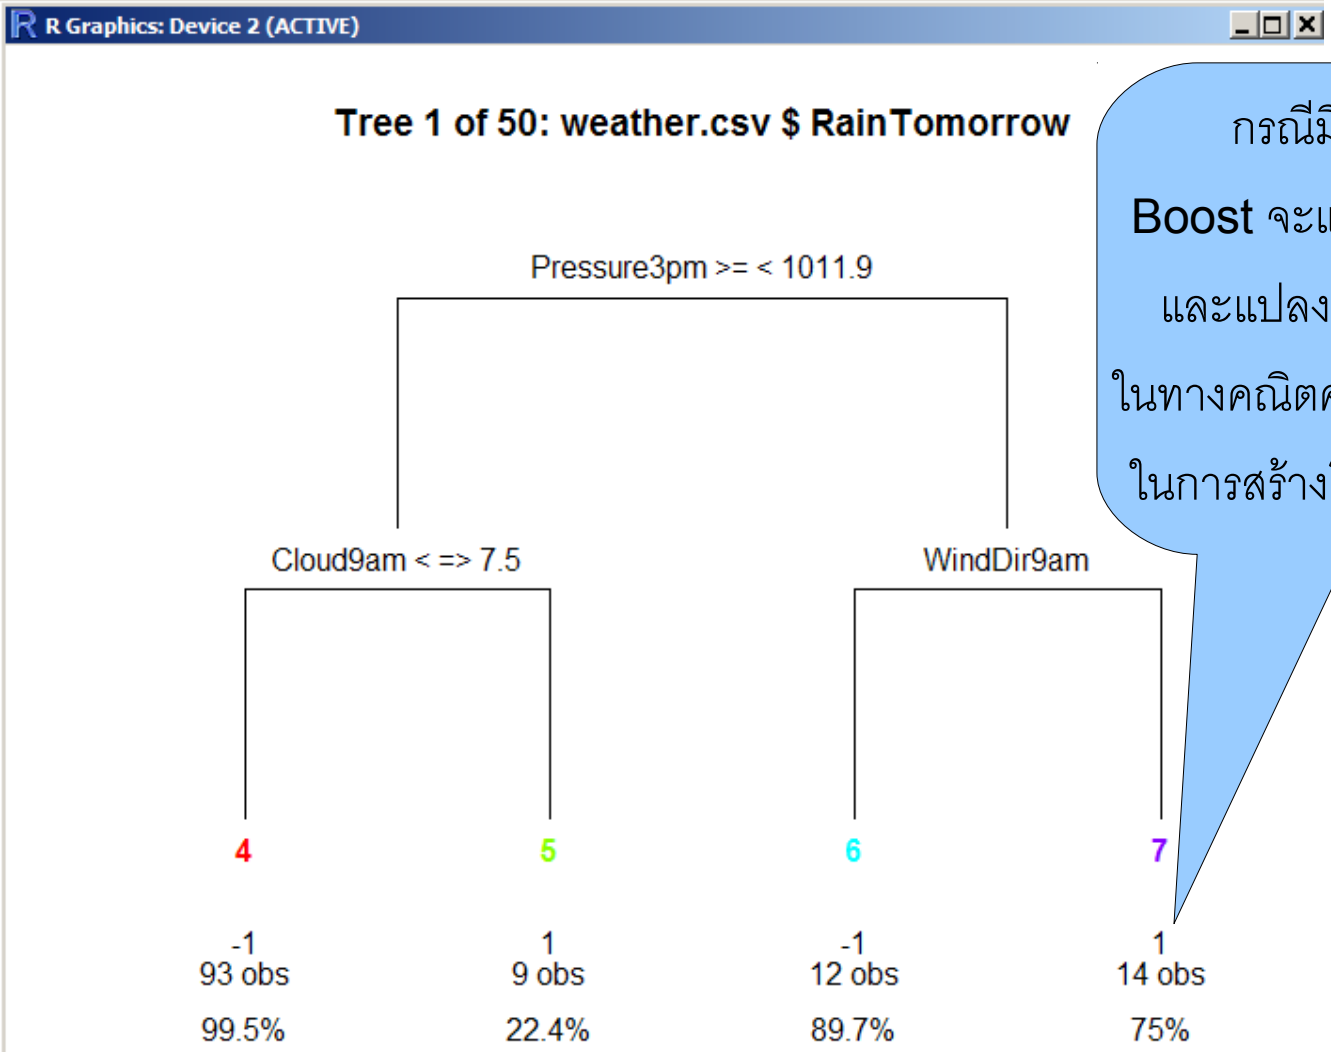


# Rattle Training 9. Classifier Models




List : สามารถแสดง tree & root ได้เช่นเดียวกับ decision tree

# Rattle Training 9. Classifier Models




กรณีมีแค่ 2 class

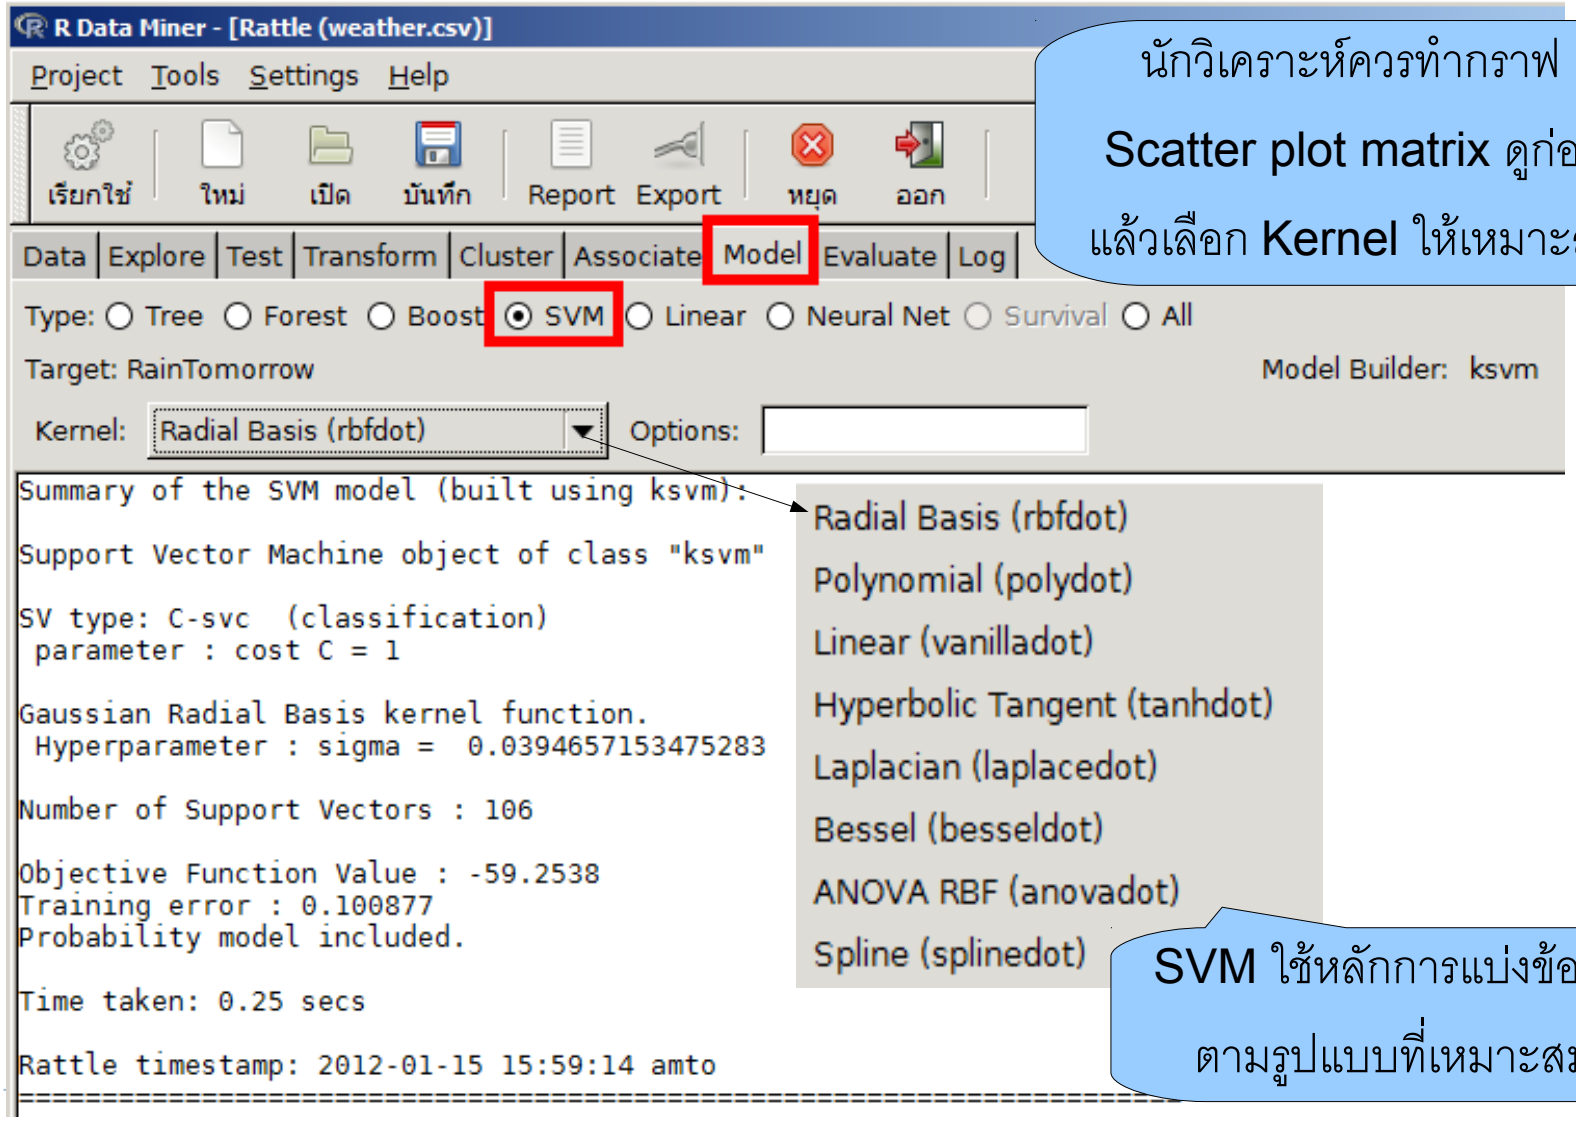
Boost จะแปลงค่า yes เป็น 1

และแปลงค่า no เป็น -1 ซึ่ง

ในทางคณิตศาสตร์ให้ความหมาย

ในการสร้างโมเดลได้ดีกว่า 0 /1

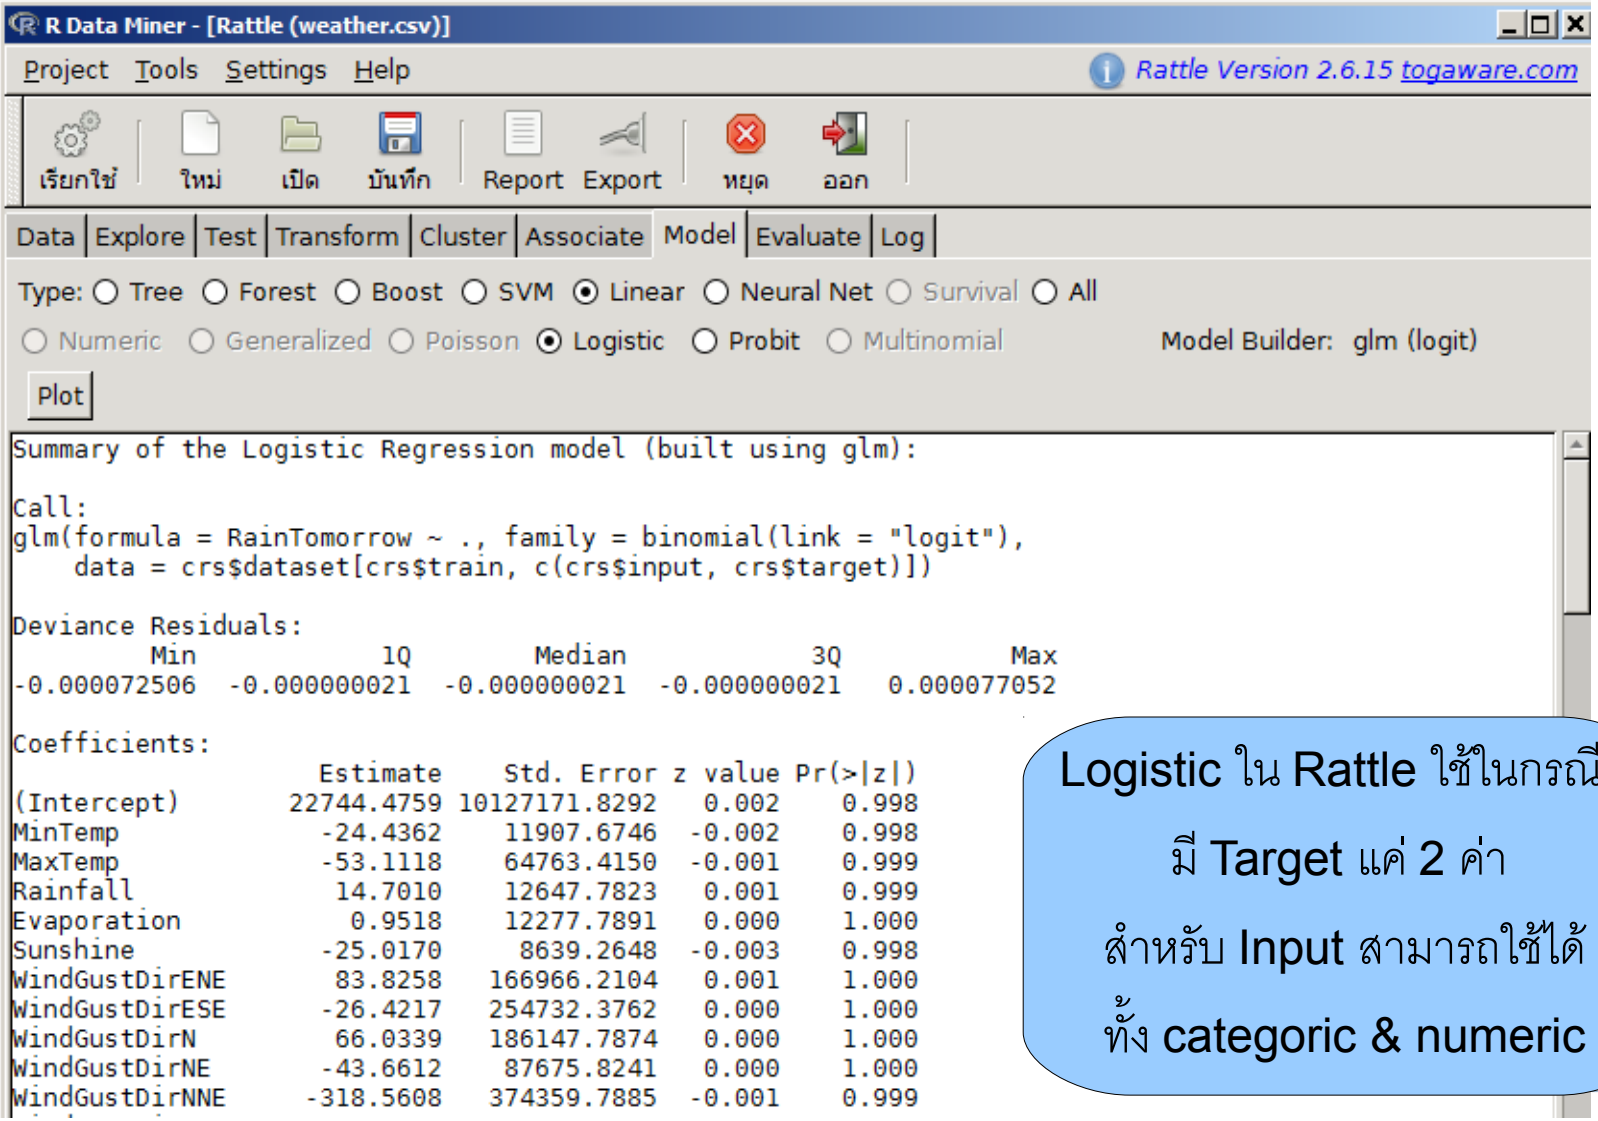
# Rattle Training 9. Classifier Models




นักวิเคราะห์ควรทำกราฟ Scatter plot matrix ดูก่อน แล้วเลือก Kernel ให้เหมาะสม

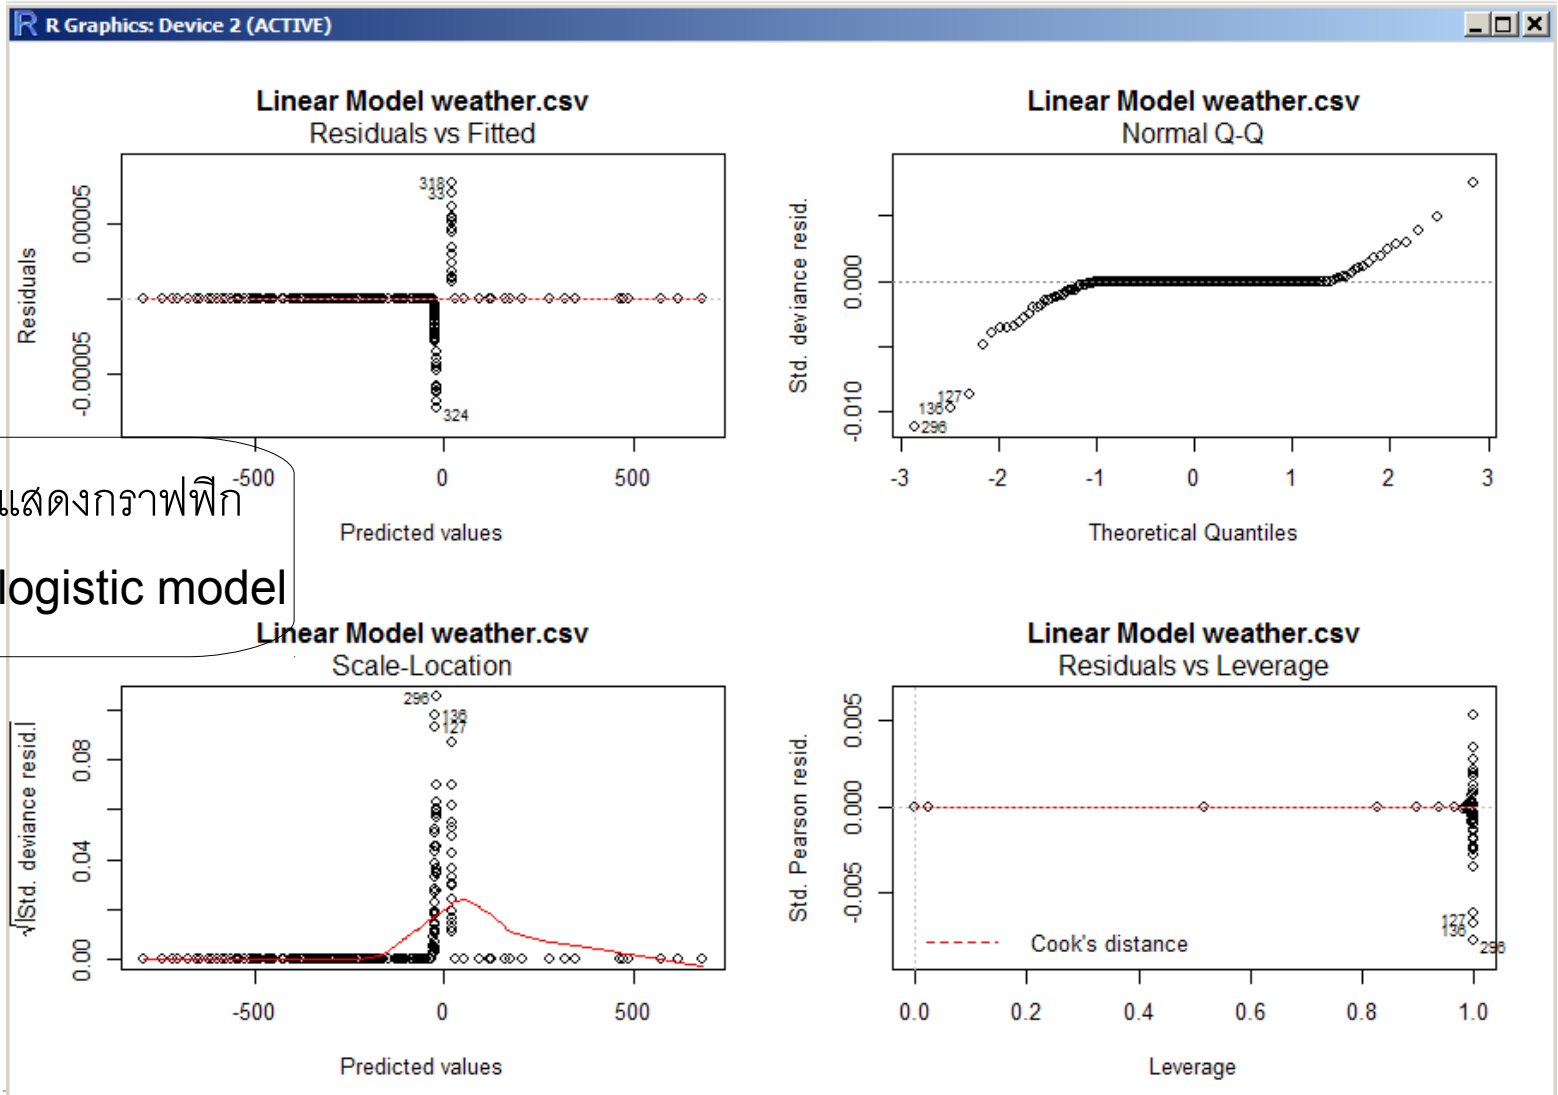
SVM ใช้หลักการแบ่งข้อมูลตามรูปแบบที่เหมาะสม

# Rattle Training 9. Classifier Models



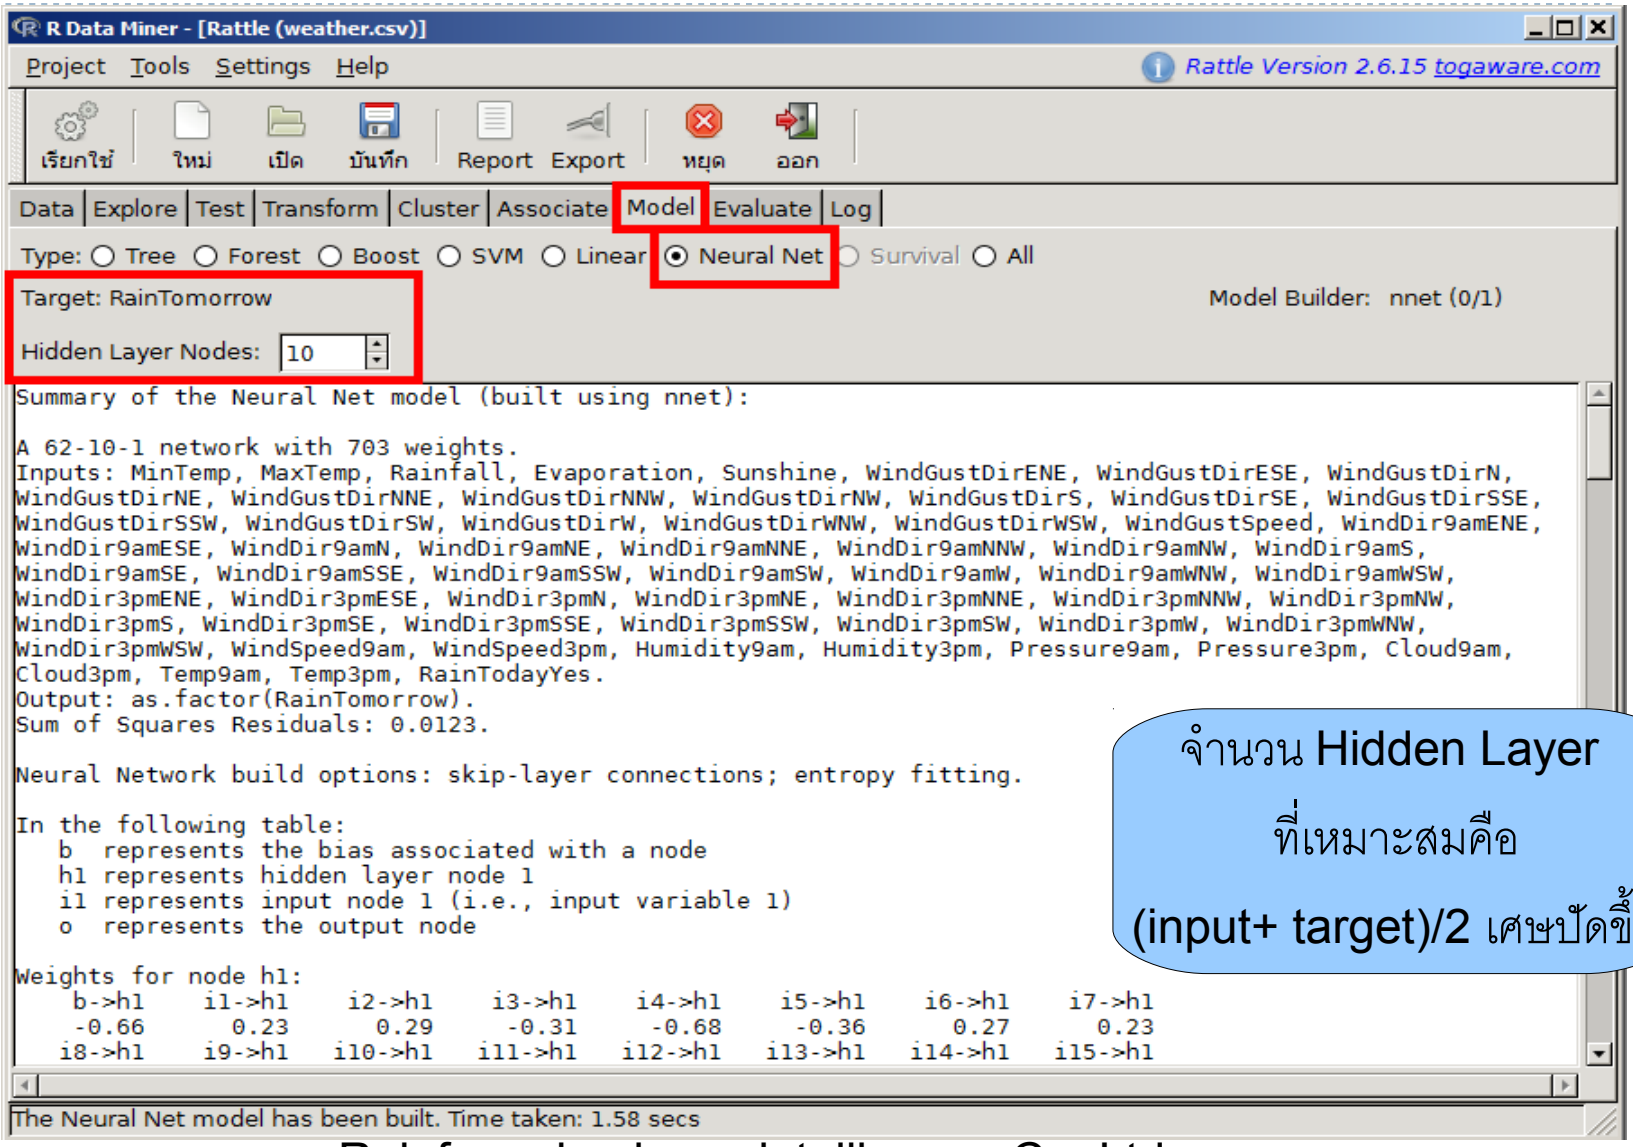

Logistic ใน Rattle ใช้ในกรณีที่มี Target แค่ 2 ค่า สำหรับ Input สามารถใช้ได้ทั้ง categoric & numeric

# Rattle Training 9. Classifier Models




เมื่อคลิ๊ก plot จะแสดงกราฟฟิกในการ diagnosis logistic model

# Rattle Training 9. Classifier Models




จำนวน Hidden Layer ที่เหมาะสมคือ (input+ target)/2 เศษปัดขึ้น

# 10.Evaluation

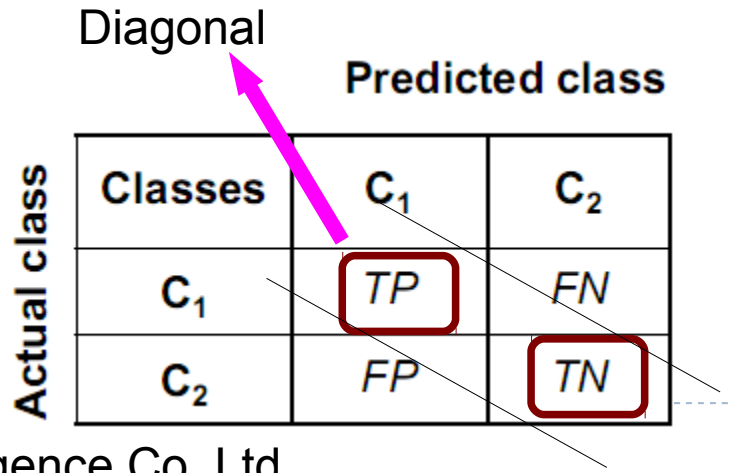
- Train & Test
  - Performance on training data → ไม่ได้ประเมินถึงข้อมูลที่ไม่เคยเจอ
  - บางครั้งผลการประเมินดีมาก เพราะ machine learning ได้เห็น training data มาก่อน
  - ถ้าจะประเมินให้มั่นใจได้ ✳ ต้องมี training data & testing data ที่มากพอ
- Cross valid (เหมาะสำหรับข้อมูลขนาดเล็ก)
  - 10-fold cross-validation → unlucky or lucky results
  - จะได้ผลที่ดีขึ้นเมื่อ ✳ repeated cross validation (เช่น ใน experimenter ของ weka)
  - Bootstrapping → sampling done with replacement to form a training dataset.

# Confusion matrix

- เป็นตารางที่มีขนาด **m x m** โดยที่ **m** คือจำนวนของ **class** เป้าหมาย
- มีจำนวนที่สอดคล้องกับสี่เงื่อนไข คือ **TP, FP, TN, FN**
  - TP (True positive) คือ จำนวนตัวอย่างที่ **model** ทำนายว่า **yes** และ **class** เป้าหมายเป็น **yes**
  - TN (True negative) คือ จำนวนตัวอย่างที่ **model** ทำนายว่า **no** และ **class** เป้าหมายเป็น **no**
  - FP (False positive) คือ จำนวนตัวอย่างที่ **model** ทำนายว่า **yes** และ **class** เป้าหมายเป็น **no**
  - FN (False negative) คือ จำนวนตัวอย่างที่ **model** ทำนายว่า **no** และ **class** เป้าหมายเป็น **yes**
- ใน **WEKA** จำนวนในแถวเป็นของ **class** เป้าหมายจริง ส่วนจำนวนในสดมภ์เป็นของ **Models** ที่ทำนาย

```
=== Confusion Matrix ===

 a b   <-- classified as
 2 3 | a = no
 4 5 | b = yes
```



# Rattle Training 10. Model Performance Evaluation.

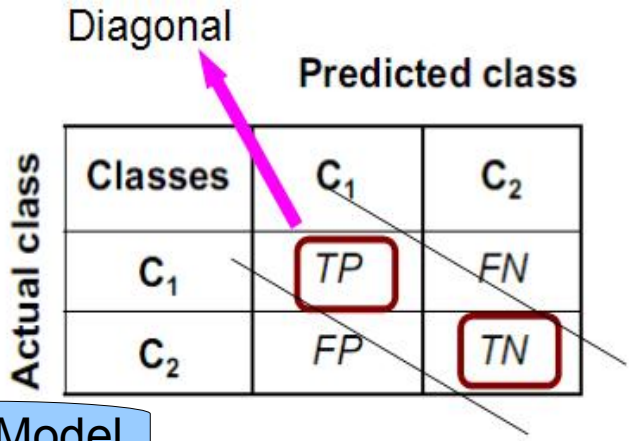
- ตัววัดหลักๆ ล้วนแต่พัฒนามาจากค่าในส่วนของ Confusion Matrix

$$TP + FN = P$$

$$TN + FP = N$$

```
=== Confusion Matrix ===

   a  b   <-- classified as
   2  3 | a = no
   4  5 | b = yes
```




Recall รู้จักกันในนามของ sensitivity ของ Model

$$FPrate = \frac{FP}{N} \qquad TPrate = \frac{TP}{P} = Recall \qquad Yrate = \frac{TP + FP}{P + N}$$

TPrate = Recall
แนวนอน:แม่นเพียงใด

$$Precision = \frac{TP}{TP + FP} \qquad Accuracy = \frac{TP + TN}{P + N}$$

Precision แนวดิ่ง
ดูความเที่ยงตรงของ tool

ส่วนการวัด TNrate = TN / N
รู้จักกันในชื่อของ specificity

# Rattle Training 10. Model Performance Evaluation.

- ในกรณีที่ข้อมูลมี **Class** มากกว่า **2** ค่าขึ้นไป
- จะคำนวนค่าต่างๆ แยกตาม **Class** (ดูตัวอย่างการคำนวนในหน้าถัดไป)

```
=== Detailed Accuracy By Class ===
TP Rate   FP Rate   Precision   Recall  F-Measure   Class
  0.8       0.053      0.8       0.8       0.8       soft
  0.25      0.1        0.333     0.25      0.286     hard
  0.8       0.444      0.75      0.8       0.774     none
=== Confusion Matrix ===
  a  b  c   <-- classified as
  4  0  1 |  a = soft
  0  1  3 |  b = hard
  1  2 12 |  c = none
```

# Rattle Training 10. Model Performance Evaluation.

Recall = TP / (TP + FN)

- Soft = 4 / (4 + (0 + 1)) = .8
- Hard = 1 / (1 + (0 + 3)) = .25
- None = 12 / (12 + (1 + 2)) = .8

Precision = TP / (TP + FP)

- Soft = 4 / (4 + (0 + 1)) = .8
- Hard = 1 / (1 + (0 + 2)) = .33
- None = 12 / (12 + (1 + 3)) = .75

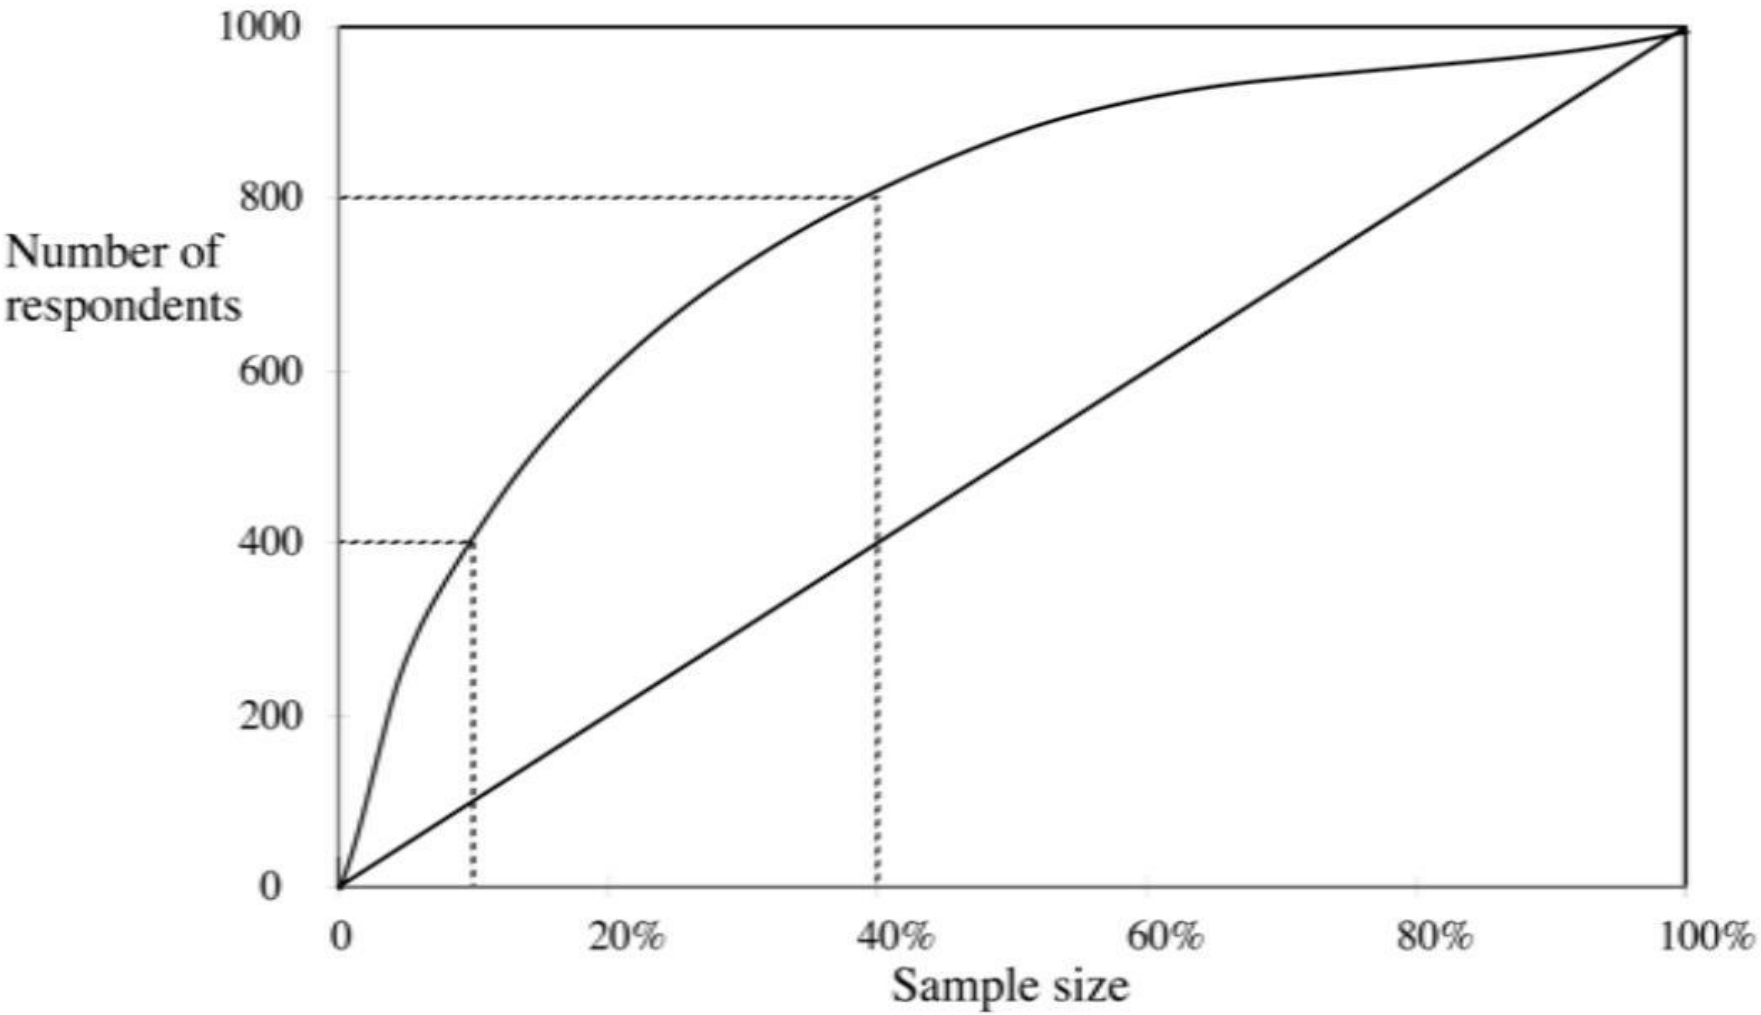
F-measure = 2TP / (2TP + FP + FN)

- Soft = 2 * 4 / ( 2*4 + (0 + 1) + (0 + 1)) = 8/10 = .8
- Hard = 2 * 1 / (2*1 + (0 + 2) + (0 + 3)) = 2 / 7= .286
- None = 2 * 12 / (2*12 + (1 + 3) + (1 + 2)) = 24 / 31 = .774

# Lift Charts

- ในทางปฏิบัติ เรามีค่าใช้จ่ายแฝงอยู่ (ค่าปฏิบัติการ)
- ต้องตัดสินใจโดยเปรียบเทียบจาก **possible scenarios**
- ตย.เช่น การทำโปรโมชั่นด้วยการส่งแผ่นพับทางไปรษณีย์ไป **1,000,000** ราย
  - กรณีที่ **1** ส่งไปทั้งหมด **1,000,000** ราย จากข้อมูลที่ผ่านมาพบว่ามีผู้ตอบกลับ **0.1%** (**1,000** ราย)
  - กรณีที่ **2** ส่งไปทั้งหมด **100,000** ราย ตัวแบบ **classifier predicts** ว่ามีผู้สนใจ **0.4%** (**400** ราย)
  - กรณีที่ **3** ส่งไปทั้งหมด **400,000** ราย ตัวแบบ **classifier predicts** ว่ามีผู้สนใจ **0.2%** (**800** ราย)
  - การเพิ่มขึ้นของ **response rate** คือ **Lift** (**0.4 / 0.1 = 4** ในกรณีที่ **2** เมื่อเทียบกับการส่งไปทั้งหมด)
- **Lift Charts** จะเปรียบเทียบให้เห็นสถานการณ์ต่าง ประกอบการตัดสินใจ

# Lift Charts

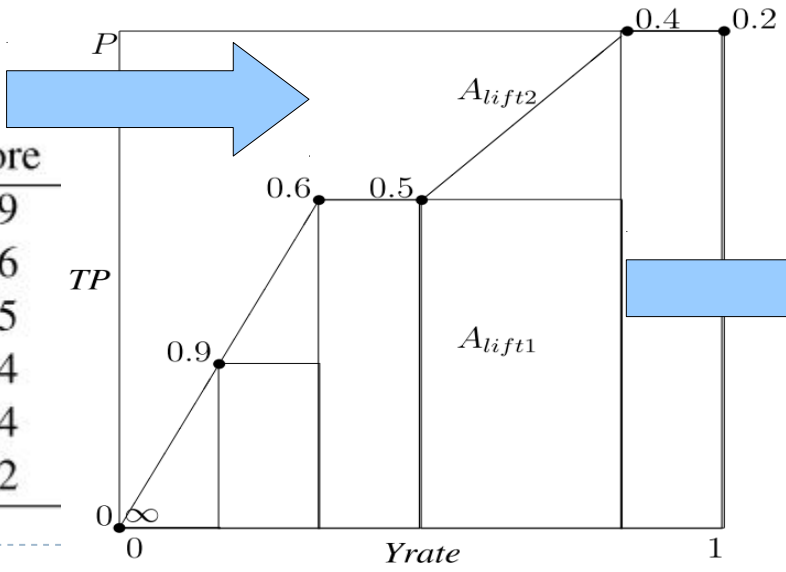

1000
800
600
400
200
0
Number of respondents
0
20%
40%
60%
80%
100%
Sample size

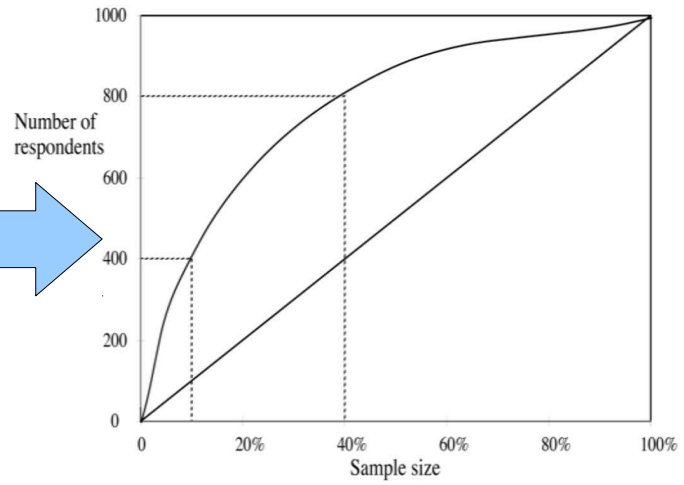
# Lift Charts

- ขั้นตอนการสร้าง **Lift charts** จะได้จากค่า **prob** การทำนายของ **classifier**
  - นำค่า **probability** ของ **class** เป้าหมายที่เราสนใจมาเรียงลำดับจากมากไปน้อย (เช่น คนที่จะซื้อสินค้าจากแผ่นพับ = yes)
  - เมื่อทายถูกลากเส้นขึ้นในแนวดิ่ง (Number of respondents)
  - ทายผิดลากเส้นในแนวนอน (Sample size)

given test set.

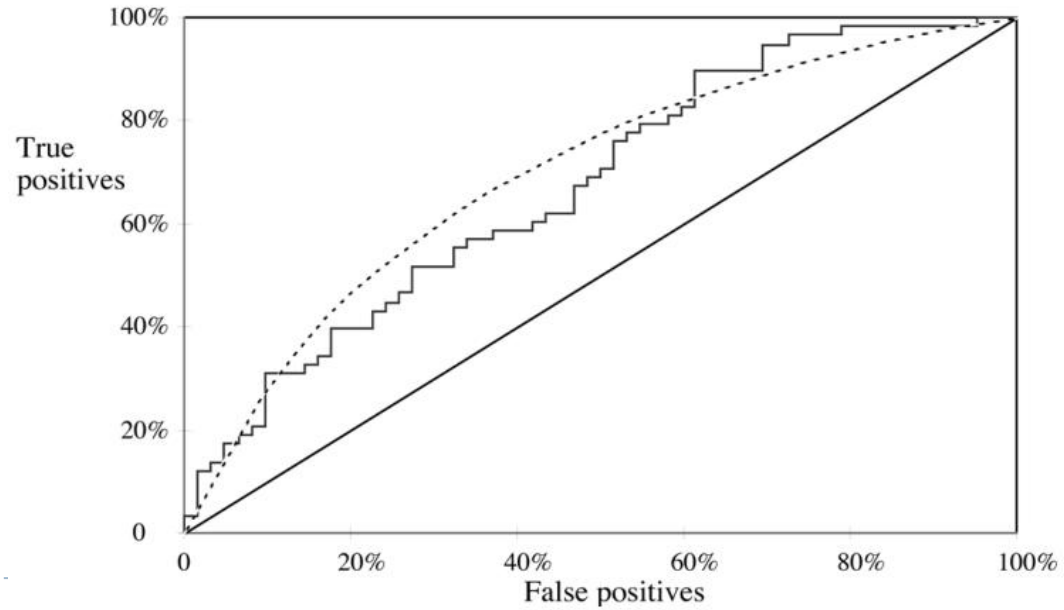
| Num | Class | Score |
|---|---|---|
| 1 | p | 0.9 |
| 2 | p | 0.6 |
| 3 | n | 0.5 |
| 4 | n | 0.4 |
| 5 | p | 0.4 |
| 6 | n | 0.2 |



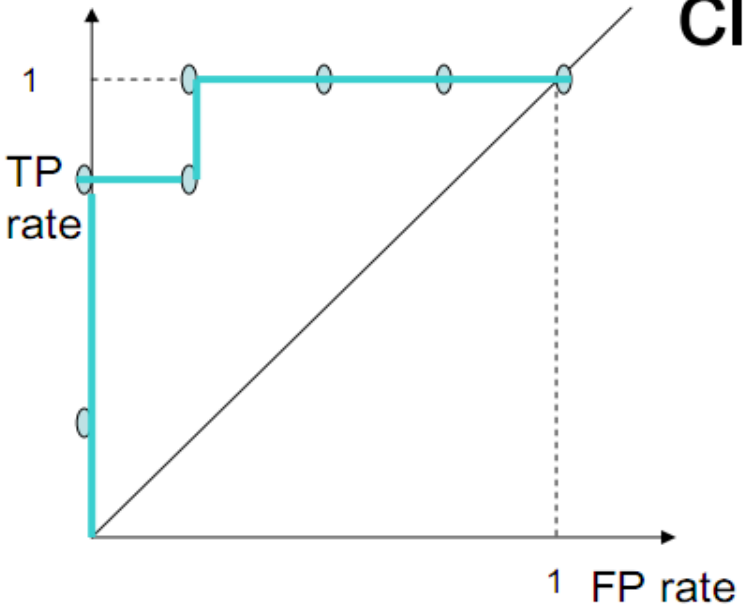
# ROC Curves

- คล้ายๆ กับ **Lift Charts**
  - แกน **y** แสดง **% of true positives** จากกลุ่มตัวอย่าง (ใน **lift charts** จะเป็นจำนวนของเป้าหมาย)
  - แกน **x** แสดง **% of false positives** จากกลุ่มตัวอย่าง (ใน **lift charts** จะเป็นจำนวน กลุ่มตัวอย่าง)
- **ROC Curves** ใช้ประเมินเปรียบเทียบ **classifiers** ที่ต่างกันบนชุดข้อมูลเดียวกัน
- **ROC Curves** ไม่ได้คำนึงถึง **class distribution & costs**



# Rattle Training 10. Model Performance Evaluation.

## ROC curve of a probabilistic classifier




For different threshold values we get different points in the ROC space

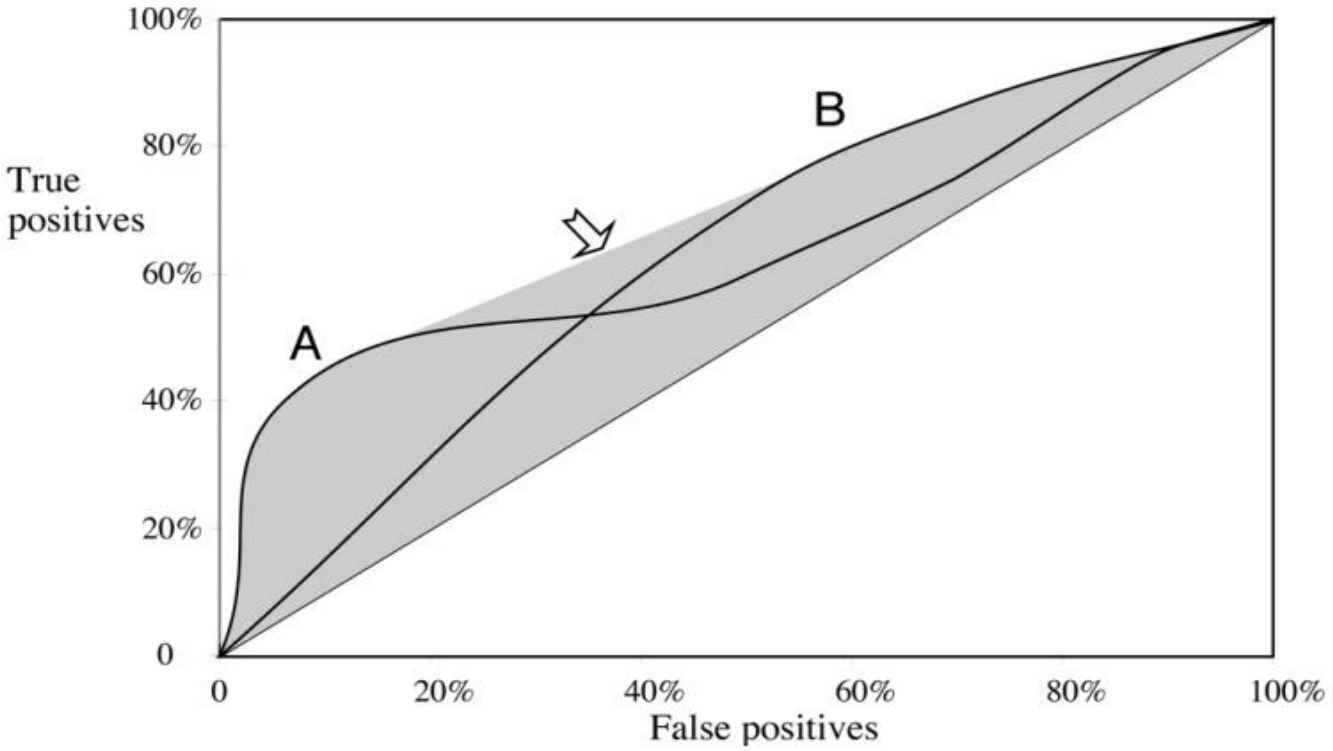
| Outlook | Temp | Windy | P(Y\|E) | Predicted class | Real class |
|---|---|---|---|---|---|
| overcast | mild | yes | 0.95 | YES | YES |
| rainy | mild | no | 0.80 | YES | YES |
| rainy | cool | yes | 0.60 | YES | NO |
| sunny | mild | no | 0.45 | YES | YES |
| sunny | cool | no | 0.40 | NO | NO |
| sunny | hot | no | 0.35 | NO | NO |
| sunny | hot | yes | 0.25 | NO | NO |

FP rate: FP/N=1/4=0.25

TP rate: TP/P=3/3=1.0, etc…

# ROC Curves

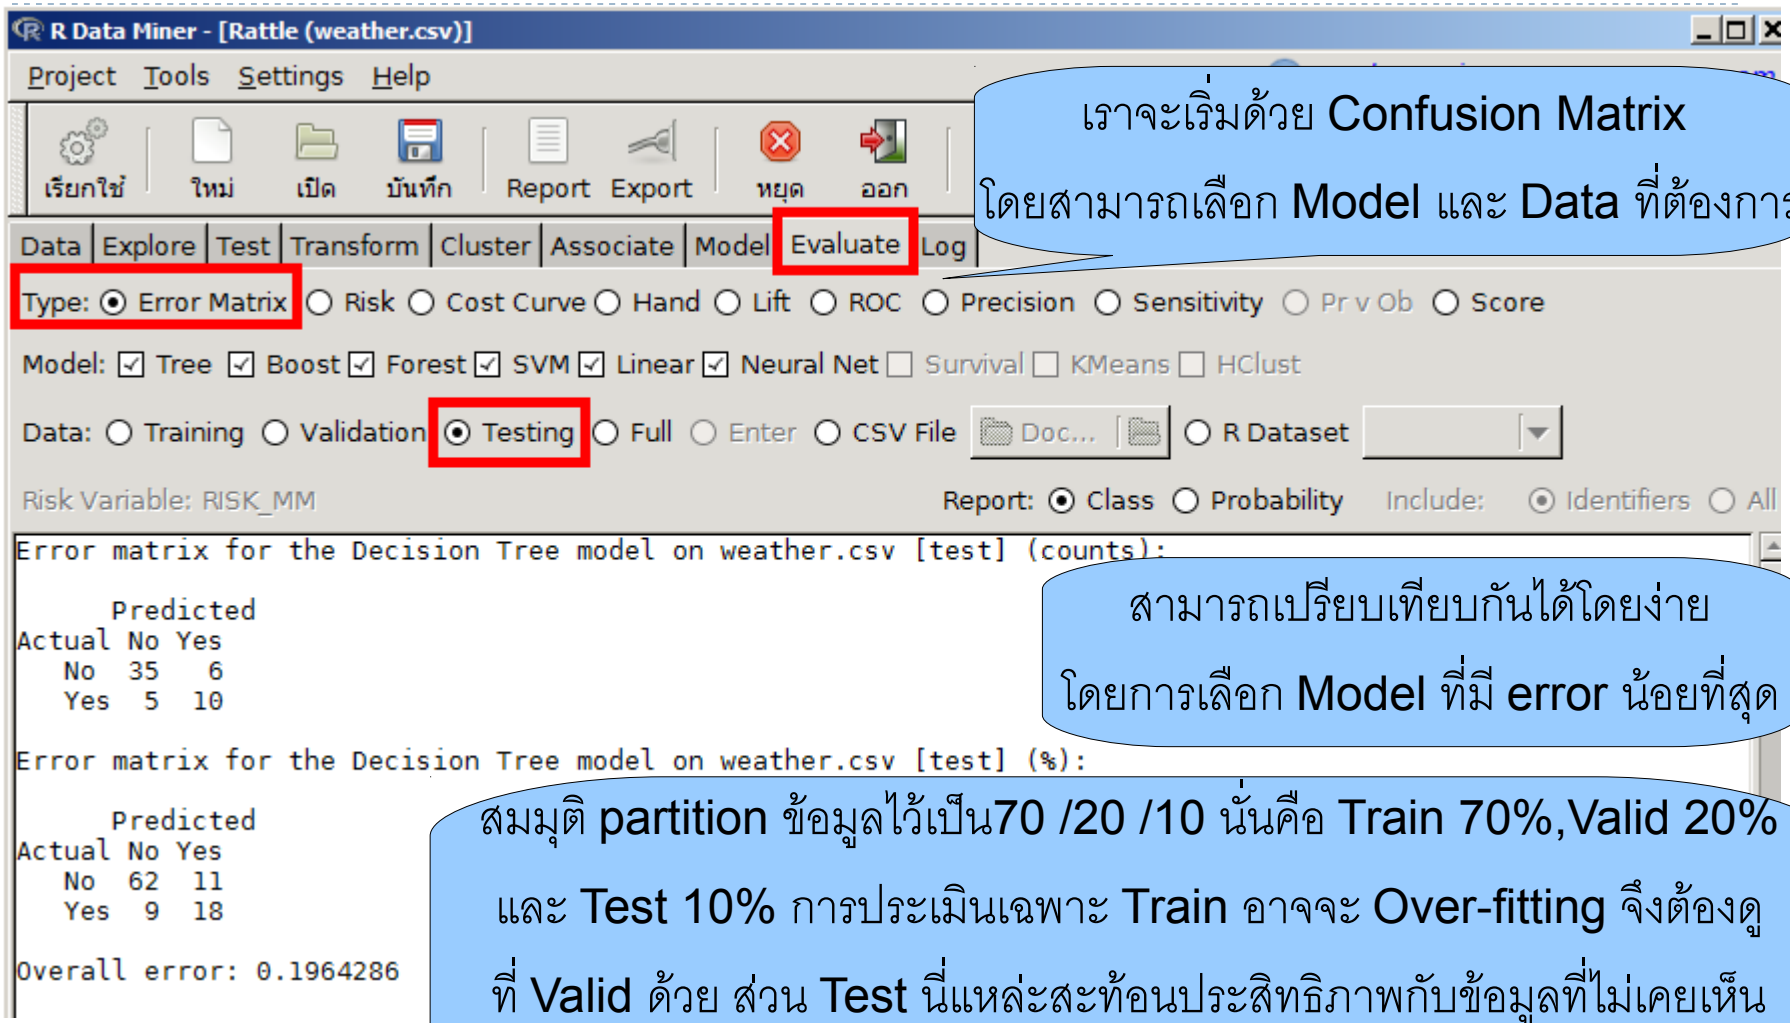
- การเปรียบเทียบ 2 method ด้วย ROC Curves ต้องมองภาพรวม เพราะ
- อย่างเช่น วิธี A อาจจะดูดีเมื่อพิจารณาจากกลุ่มตัวอย่างขนาดเล็ก
- วิธี B ได้ผลที่ดีกว่าเมื่อพิจารณาที่ช่วงกลุ่มตัวอย่างจำนวนที่มากขึ้น (ดูภาพด้านล่าง)



# Summery of Evaluating

| | Domain | Plot | Explanation |
|---|---|---|---|
| Lift chart | Marketing | TP<br>Subset size | TP<br>(TP+FP)/ (TP+FP+TN+FN) |
| ROC curve | Communications | TP rate<br>FP rate | TP/(TP+FN)<br>FP/(FP+TN) |
| Recall-precision curve | Information retrieval | Recall<br>Precision | TP/(TP+FN)<br>TP/(TP+FP) |

# Rattle Training 10. Model Performance Evaluation.




เราจะเริ่มด้วย Confusion Matrix โดยสามารถเลือก Model และ Data ที่ต้องการ

สามารถเปรียบเทียบกันได้โดยง่าย โดยการเลือก Model ที่มี error น้อยที่สุด

สมมุติ partition ข้อมูลไว้เป็น70 /20 /10 นั่นคือ Train 70%,Valid 20% และ Test 10% การประเมินเฉพาะ Train อาจจะ Over-fitting จึงต้องดูที่ Valid ด้วย ส่วน Test นี่แหล่ะสะท้อนประสิทธิภาพกับข้อมูลที่ไม่เคยเห็น แต่ถ้าเลือกใช้ Full ก็จะใช้ข้อมูลทั้ง 100% เพื่อเรียนรู้

# Rattle Training 10. Model Performance Evaluation.

Error matrix for the Decision Tree

| Actual | Predicted No | Predicted Yes |
|---|---|---|
| No | 35 | 6 |
| Yes | 5 | 10 |

Error matrix for the SVM

| Actual | Predicted No | Predicted Yes |
|---|---|---|
| No | 35 | 1 |
| Yes | 10 | 4 |

Error matrix for the Ada Boost

| Actual | Predicted No | Predicted Yes |
|---|---|---|
| No | 37 | 4 |
| Yes | 6 | 9 |

Error matrix for the Linear

| Actual | Predicted No | Predicted Yes |
|---|---|---|
| No | 26 | 10 |
| Yes | 4 | 10 |

Error matrix for the Random Forest

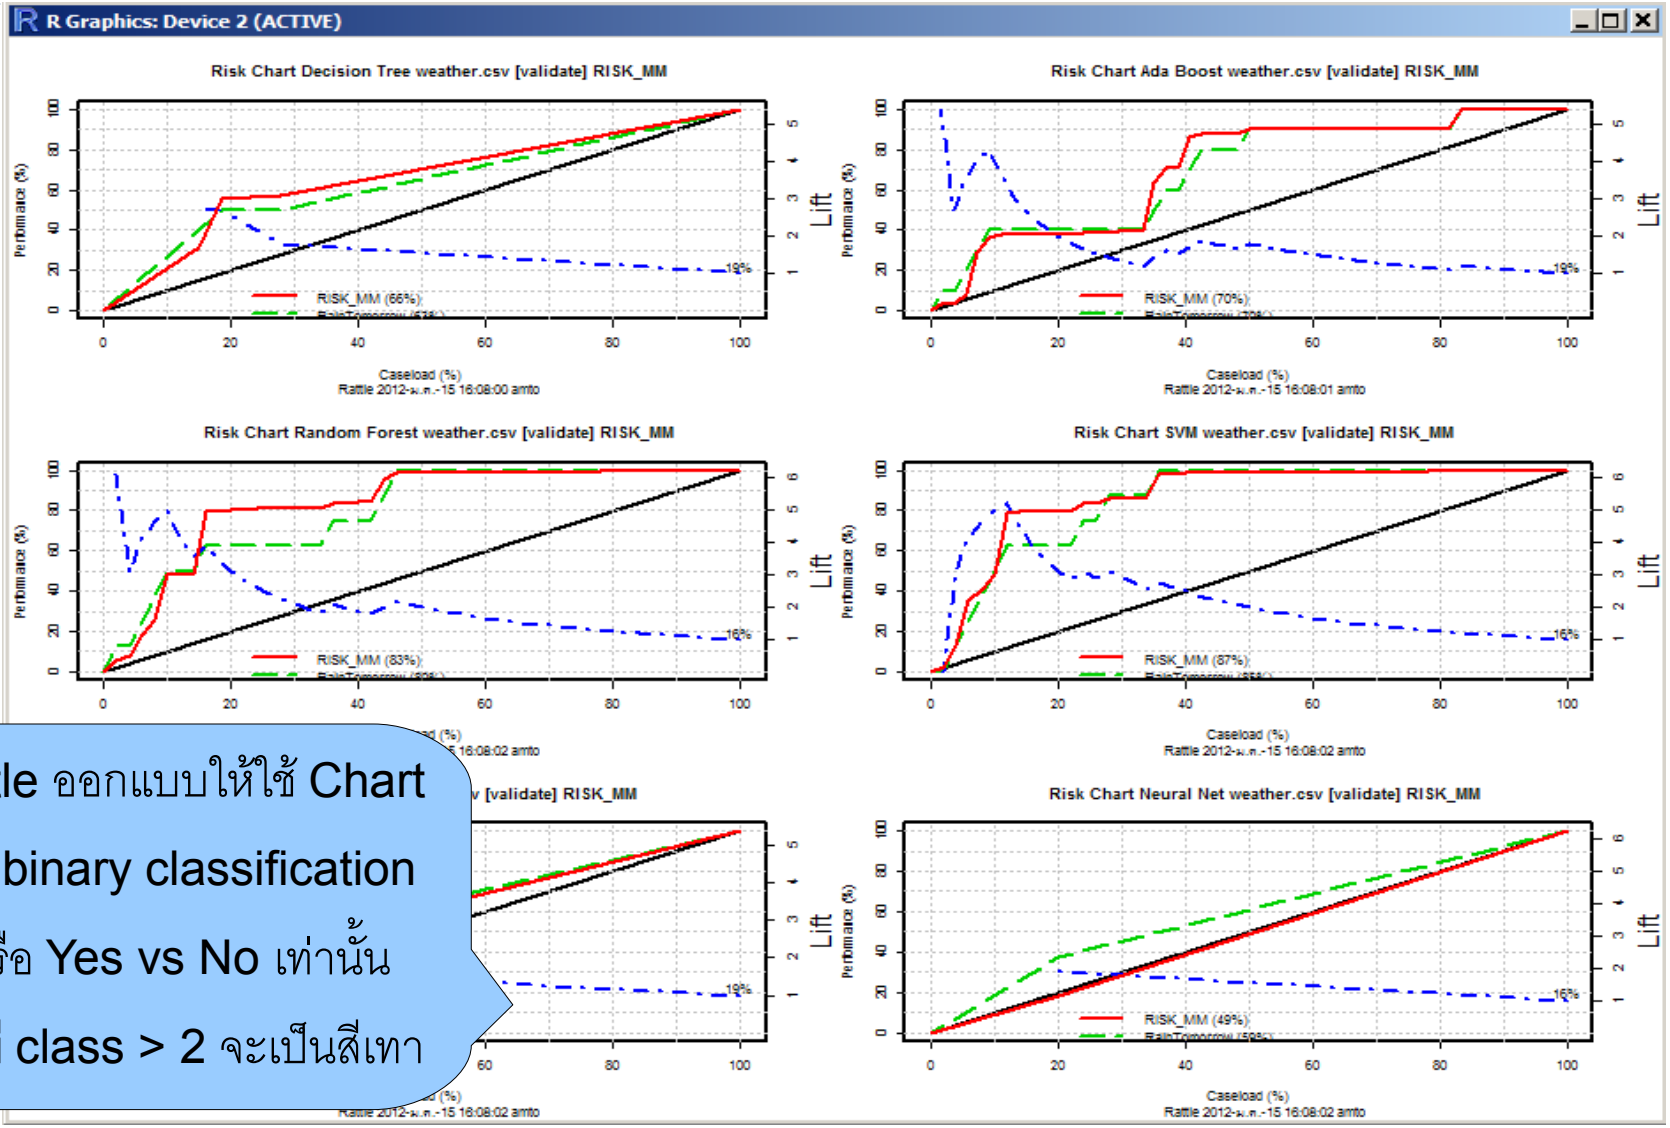
| Actual | Predicted No | Predicted Yes |
|---|---|---|
| No | 34 | 2 |
| Yes | 6 | 8 |

Error matrix for the Neural Net

| Actual | Predicted No | Predicted Yes |
|---|---|---|
| No | 29 | 7 |
| Yes | 6 | 8 |

Data ที่ใช้คือ Test set.

# Rattle Training 10. Model Performance Evaluation.




Rattle ออกแบบให้ใช้ Chart กับ binary classification หรือ Yes vs No เท่านั้น ถ้ามี class > 2 จะเป็นสีเทา

# Rattle Training 10. Model Performance Evaluation.

Data | Explore | Test | Transform | Cluster | Associate | Model | Evaluate | Log

Type: ○ Error Matrix ◉ Risk ○ Cost Curve ○ Hand ○ Lift ○ ROC ○ Precision ○ Sensitivity ○ Pr v Ob ○ Score

Model: ☐ Tree ☐ Boost ☑ Forest ☐ SVM ☐ Linear ☐ Neural Net ☐ Survival ☐ KMeans ☐ HClust

Data: ○ Training ◉ Validation ○ Testing ○ Full ○ Enter ○ CSV File Doc... ○ R Dataset

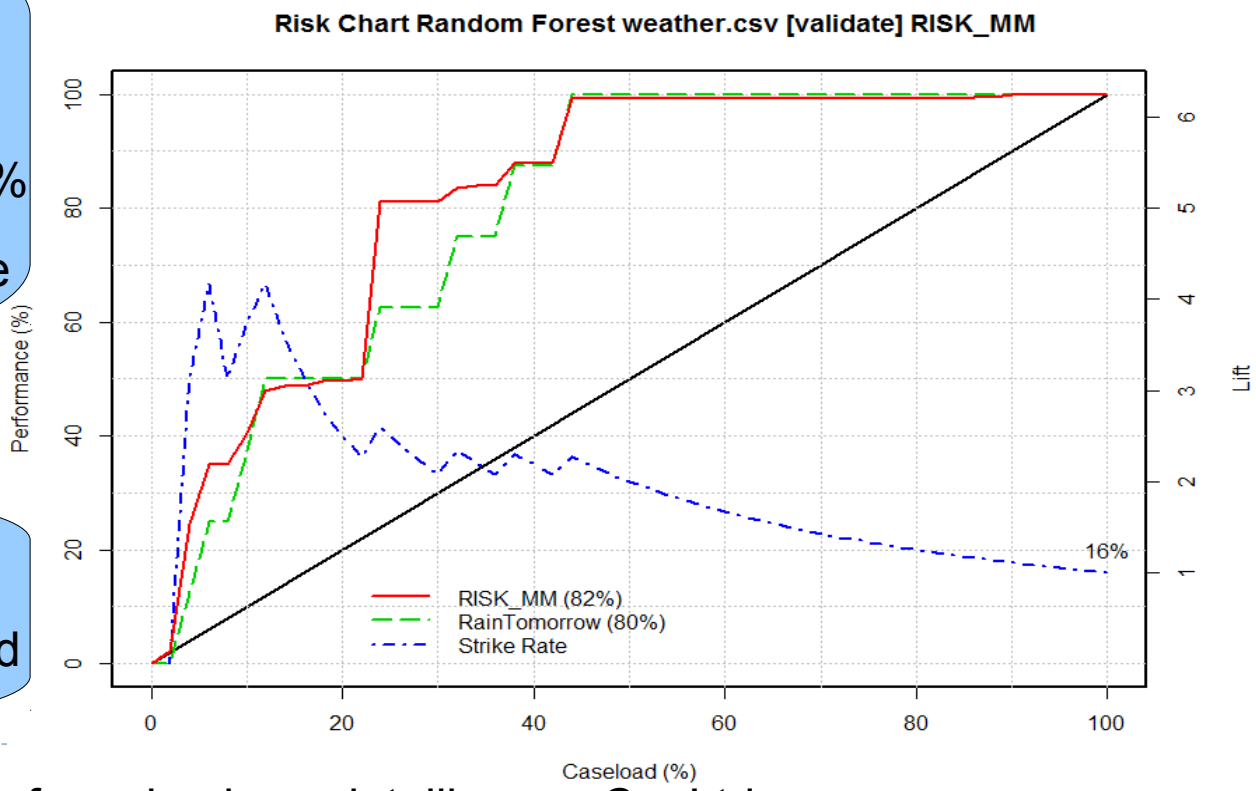
Risk Variable: RISK_MM Report: ◉ Class ○ Probability Include: ◉ Identifiers ○ Al

เส้นสีแดงคือค่าความเสี่ยง

เส้นสีเขียวคือ true respondent

เส้นสีดำแทนการสุ่มจึงถูกเพียง 50%

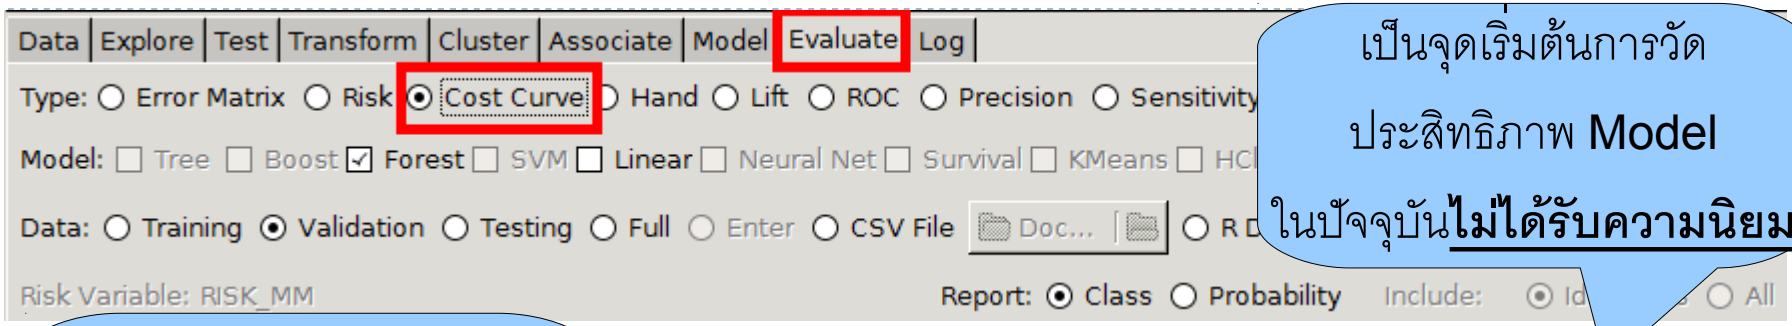
เส้นสีน้ำเงินคือ lift performance




จากกราฟนี้ความเสี่ยงเพิ่มขึ้น

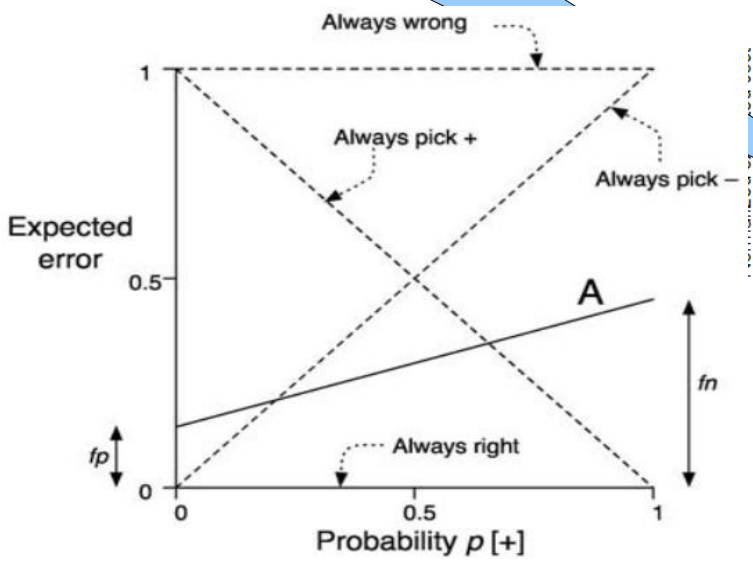
อย่างรวดเร็วที่ 20-30% caseload

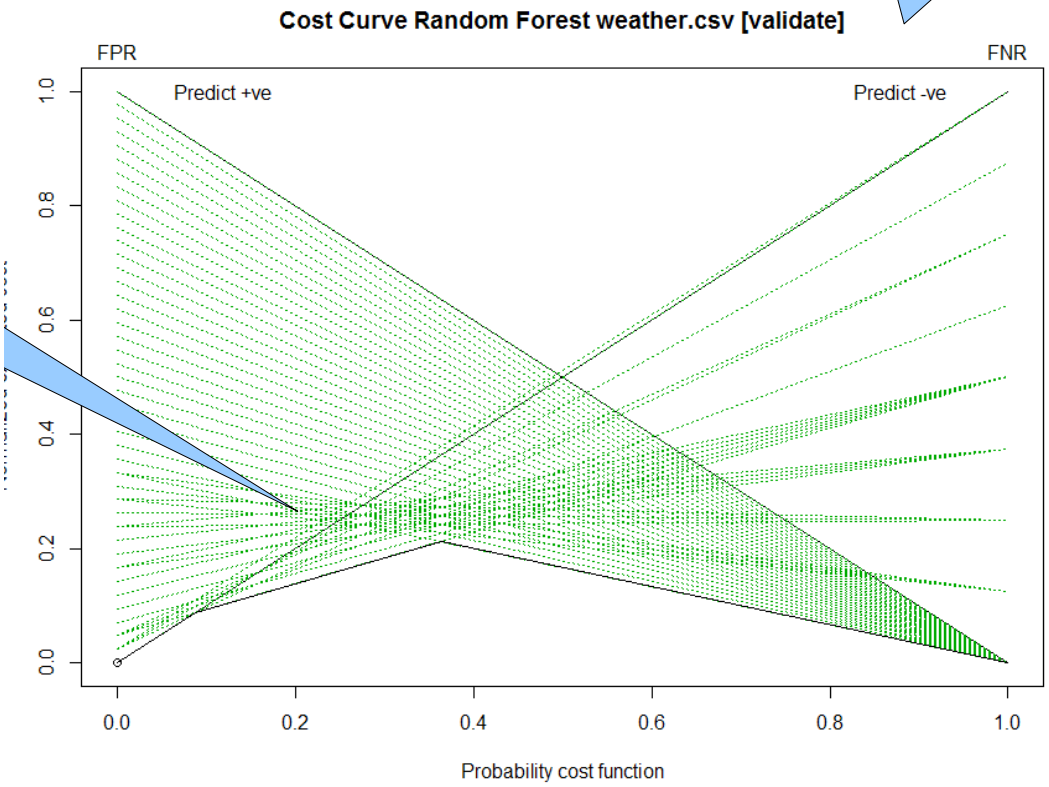
# Rattle Training 10. Model Performance Evaluation.




เป็นจุดเริ่มต้นการวัดประสิทธิภาพ Model ในปัจจุบัน**ไม่ได้รับความนิยม**

สังเกตความหนาแน่นของเส้นแบนเข้าสู่ศูนย์กลาง (Normal line :A)



# Rattle Training 10. Model Performance Evaluation.

Data | Explore | Test | Transform | Cluster | Associate | Model | Evaluate | Log

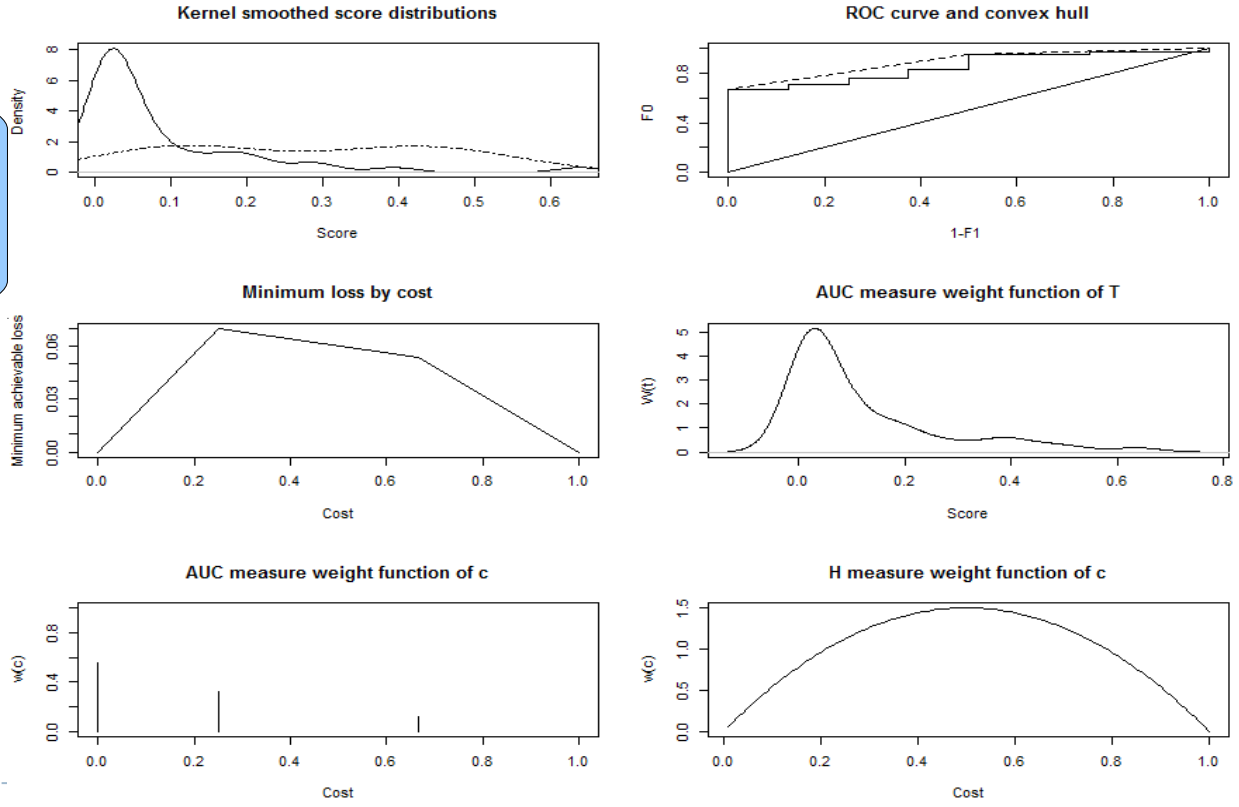
Type: ○ Error Matrix ○ Risk ○ Cost Curve ◉ Hand ○ Lift ○ ROC ○ Precision ○ Sensitivity ○ Pr v Ob ○ Score

Model: ☐ Tree ☐ Boost ☑ Forest ☐ SVM ☐ Linear ☐ Neural Net ☐ Survival ☐ KMeans ☐ HClust

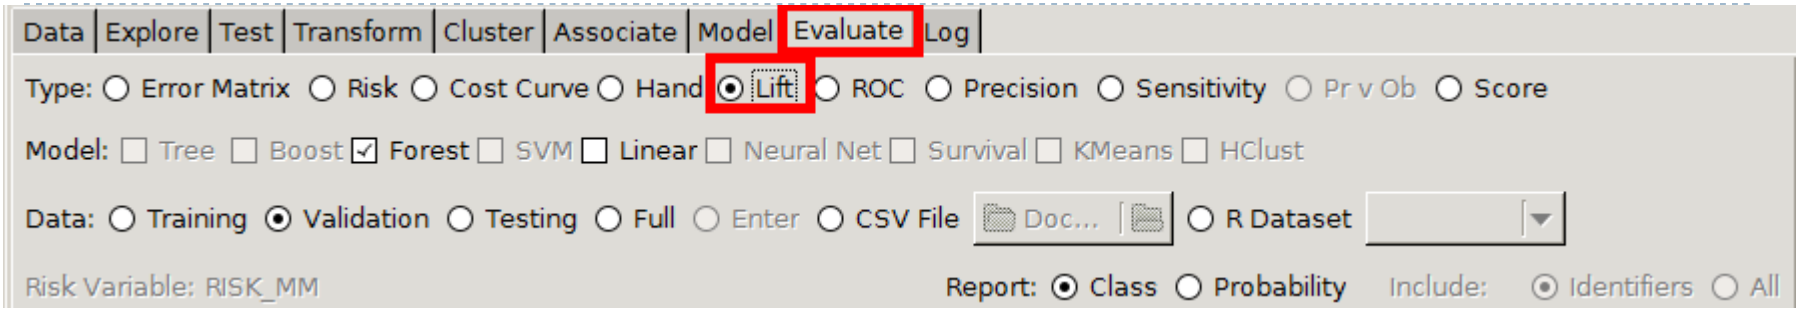
Data: ○ Training ◉ Validation ○ Testing ○ Full ○ Enter ○ CSV File Doc... ○ R Dataset

Risk Variable: RISK_MM  Report: ◉ Class ○ Probability  Include: ◉ Identifiers ○ All

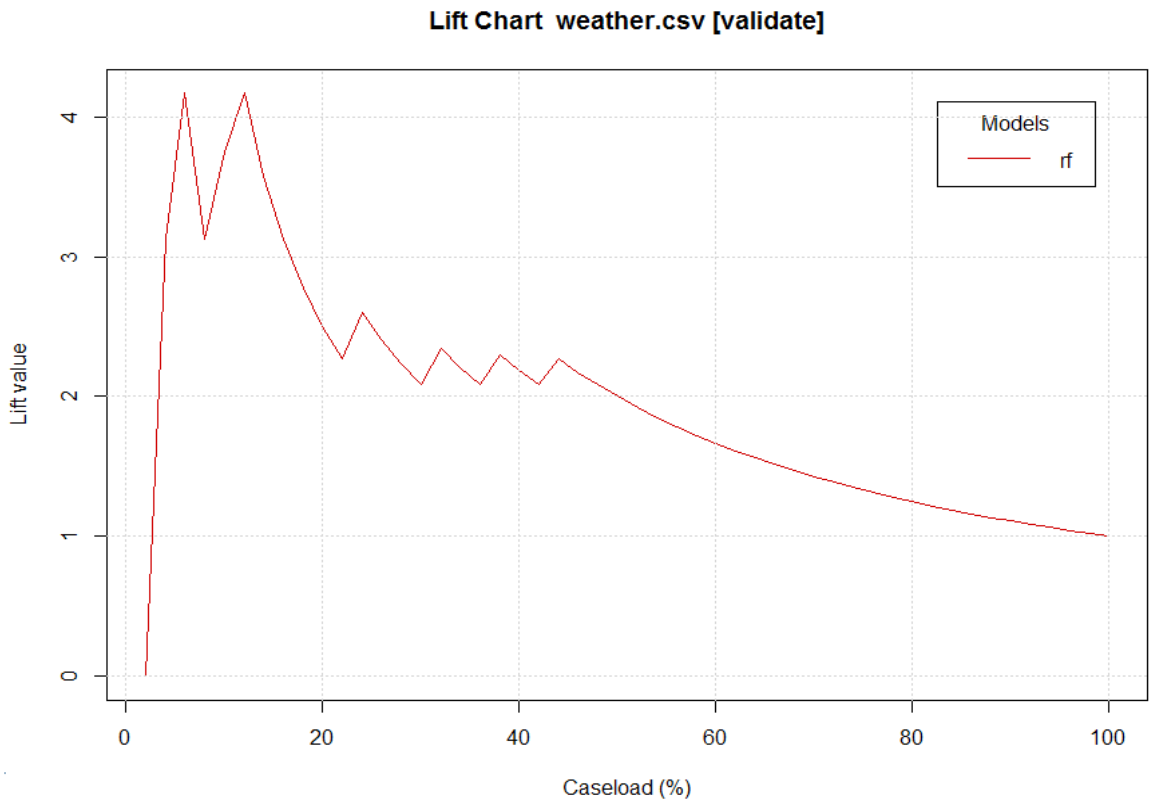
Hand chart นั้นเป็นเทคนิคการวัดทางสถิติ โดย David Hand



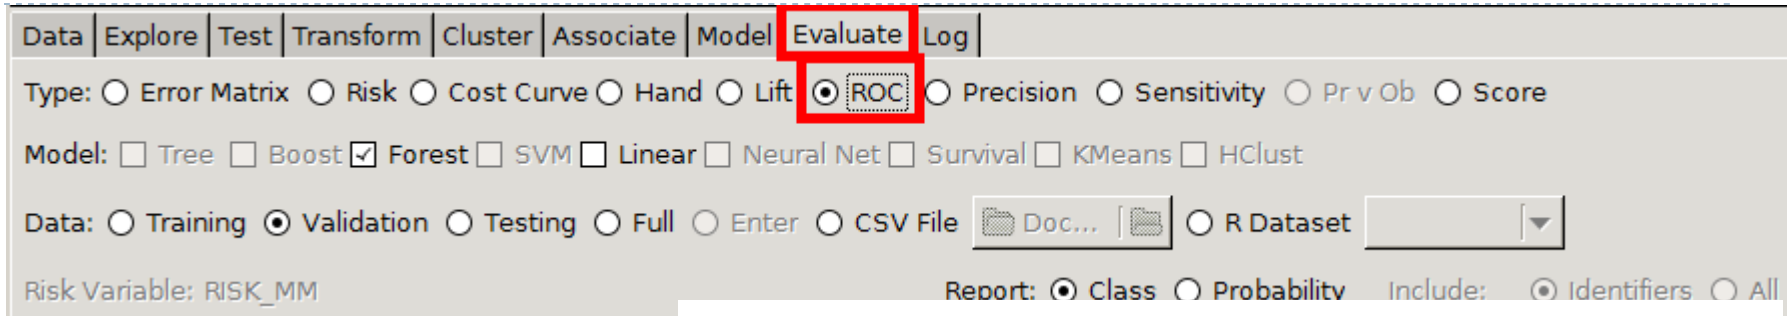
# Rattle Training 10. Model Performance Evaluation.




Lift Charts แสดงให้เห็นโอกาส และความเชื่อมั่นต่อ Classifiers ในแต่ละสถานการณ์ ใน Risk chart คือเส้น strike rate



# Rattle Training 10. Model Performance Evaluation.



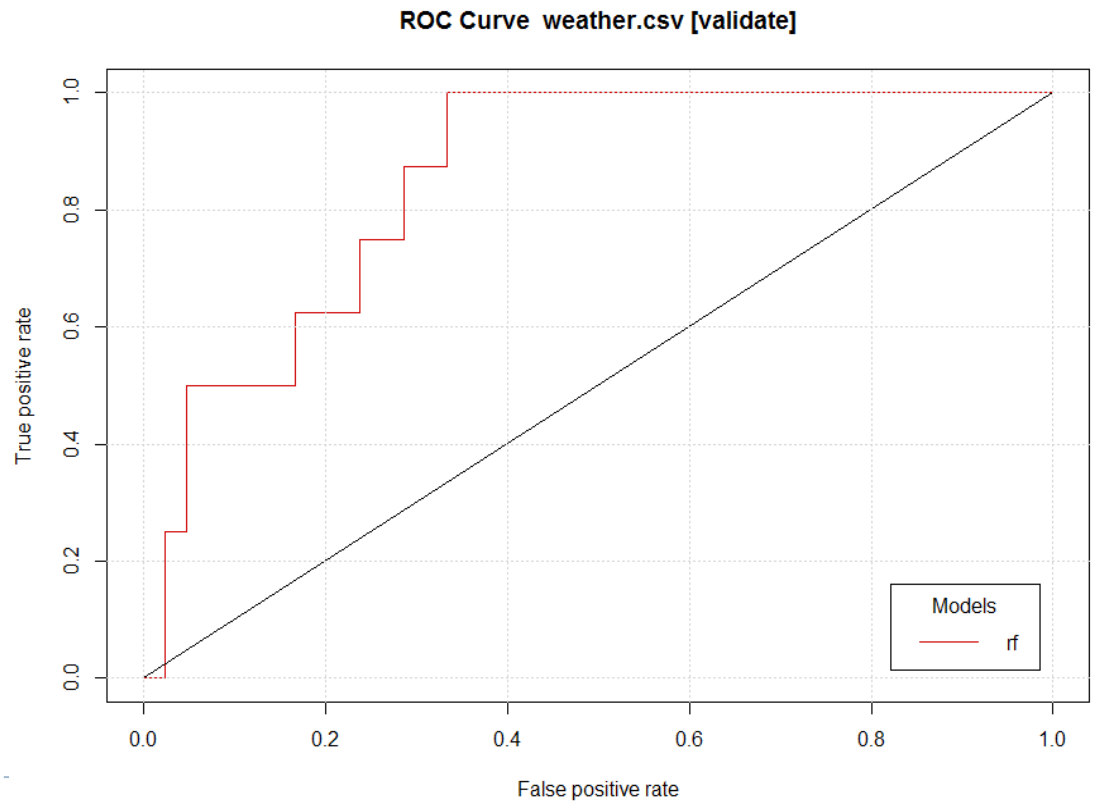

ROC Curve

-แกน y แสดง % of true positives

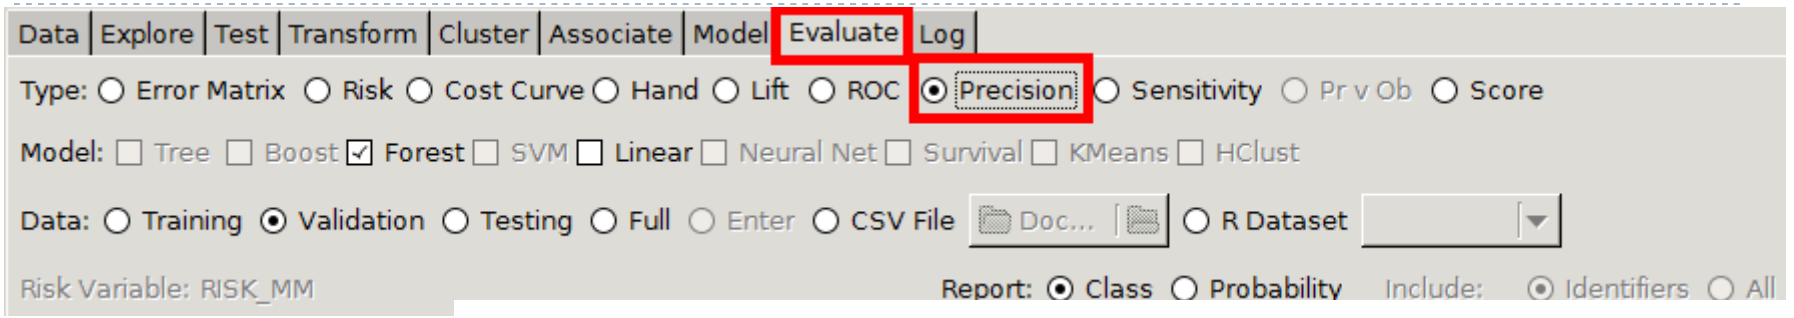
-แกน x แสดง % of false positives

-ROC ใช้ประเมินเปรียบเทียบ Classifiers ต่างกันบนข้อมูลเดียวกัน

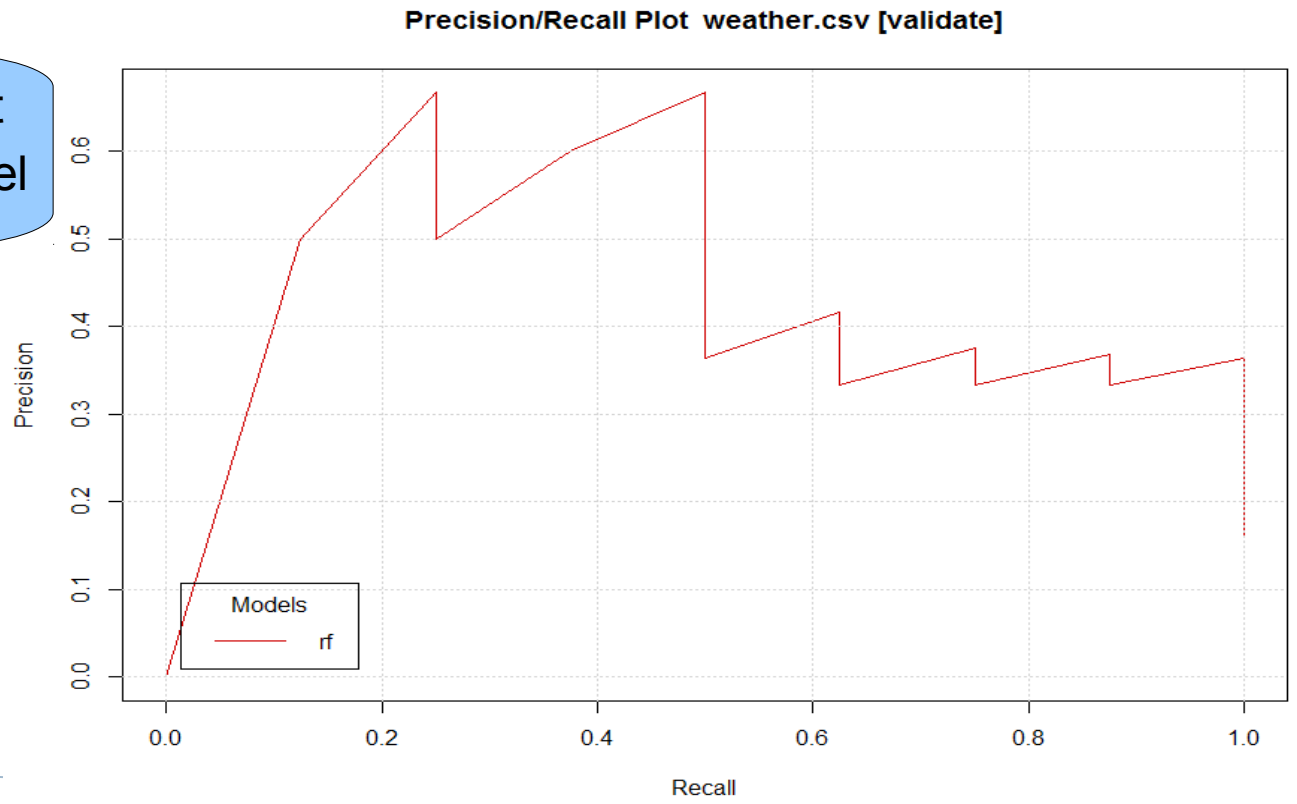
-ROC Curves ไม่ได้คำนึงถึง class distribution & costs



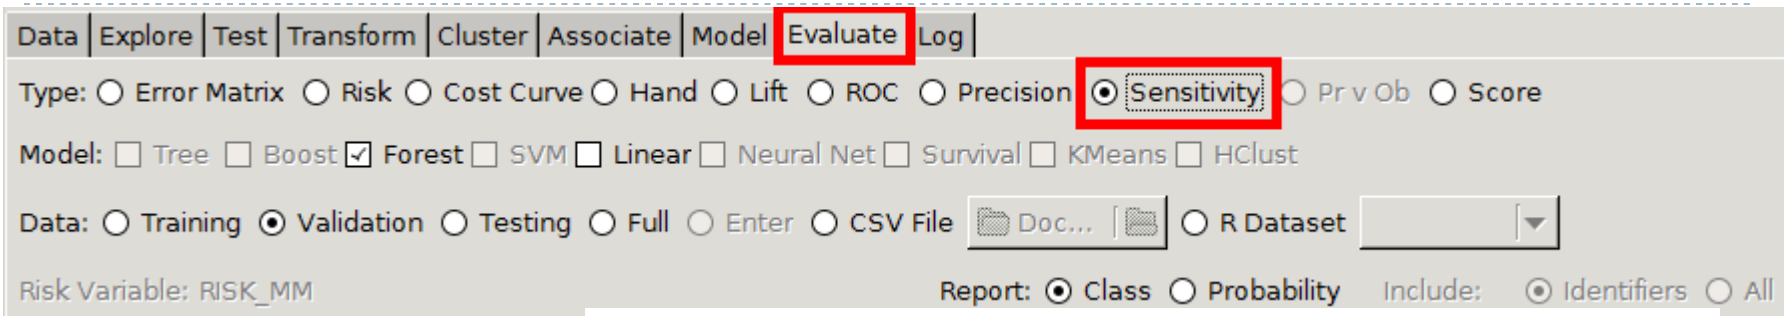
# Rattle Training 10. Model Performance Evaluation.



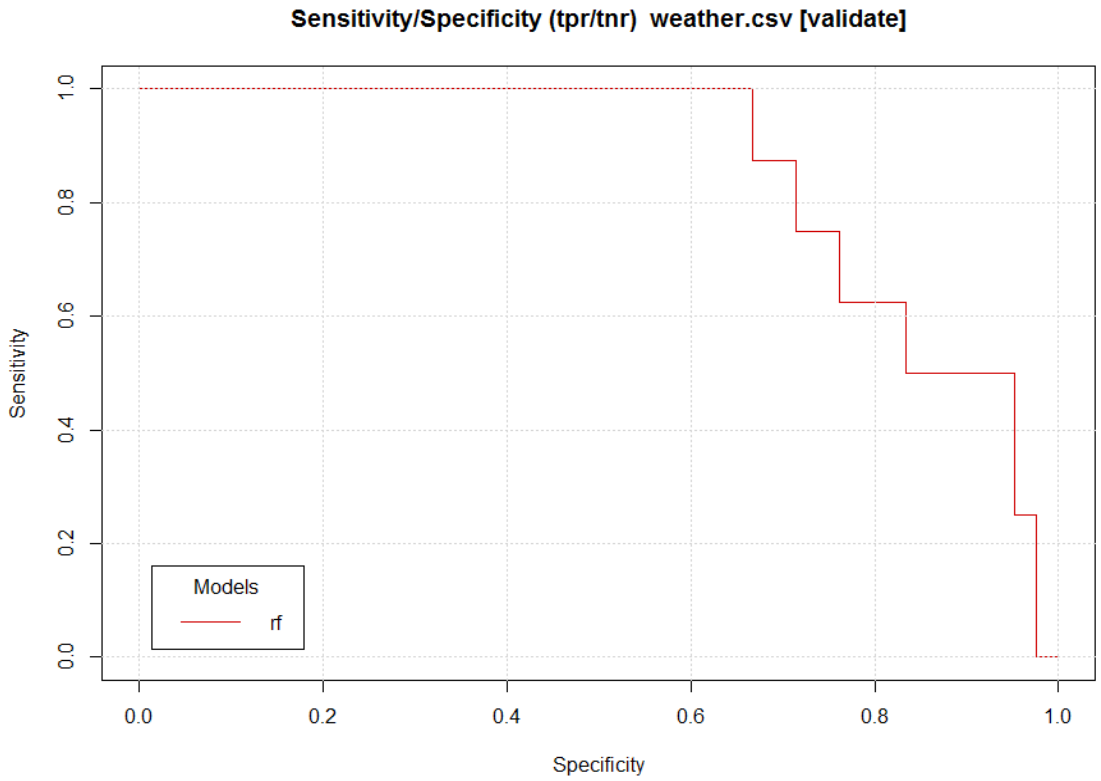

Precision /Recall chart
ใช้ประเมินคุณภาพของ Model



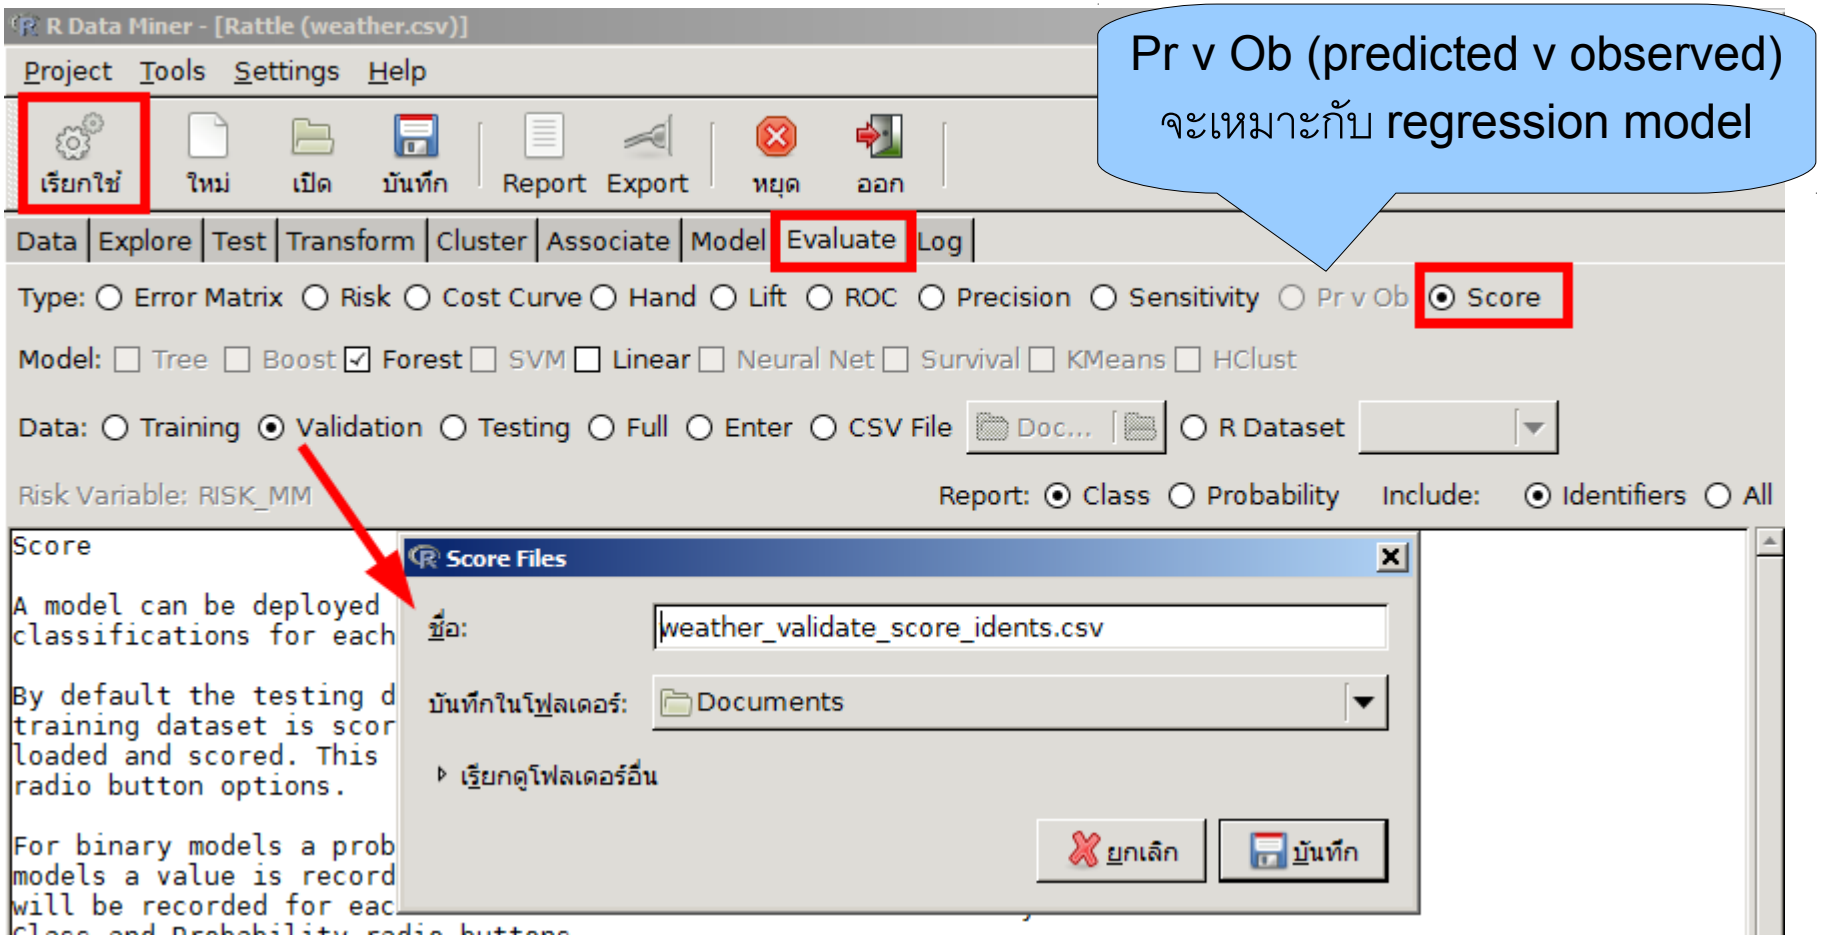
# Rattle Training 10. Model Performance Evaluation.




Sensitivity /Specificity
ก็คือ True Positive Rate
หารด้วย True Negative Rate



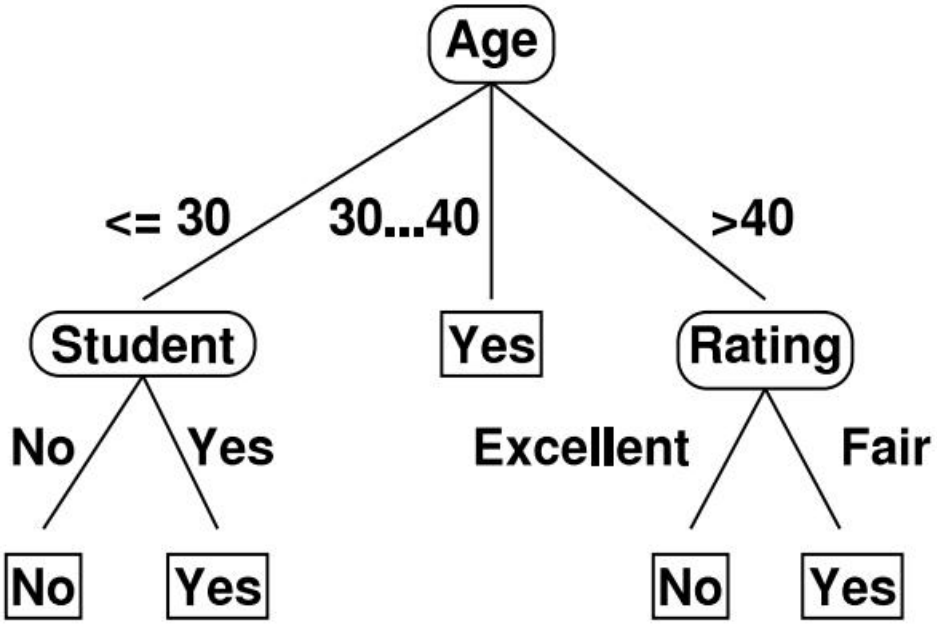
# Rattle Training 10. Model Performance Evaluation.



# Workshop1 : decision tree for Buys Computer

buying computer.csv

| Age | Income | Student | Credit | Buys |
|---|---|---|---|---|
| ≤ 30 | High | No | Fair | No |
| ≤ 30 | High | No | Excellent | Yes |
| 31 . . . 40 | High | No | Fair | Yes |
| > 40 | Medium | No | Fair | Yes |
| > 40 | Low | Yes | Fair | Yes |
| > 40 | Low | Yes | Excellent | No |
| 31 . . . 40 | Low | Yes | Excellent | Yes |
| ≤ 30 | Medium | No | Fair | No |
| ≤ 30 | Low | Yes | Fair | No |
| > 40 | Medium | Yes | Fair | Yes |
| ≤ 30 | Medium | Yes | Excellent | Yes |
| 31 . . . 40 | Medium | No | Excellent | Yes |
| 31 . . . 40 | High | Yes | Fair | Yes |
| > 40 | Medium | No | Excellent | No |

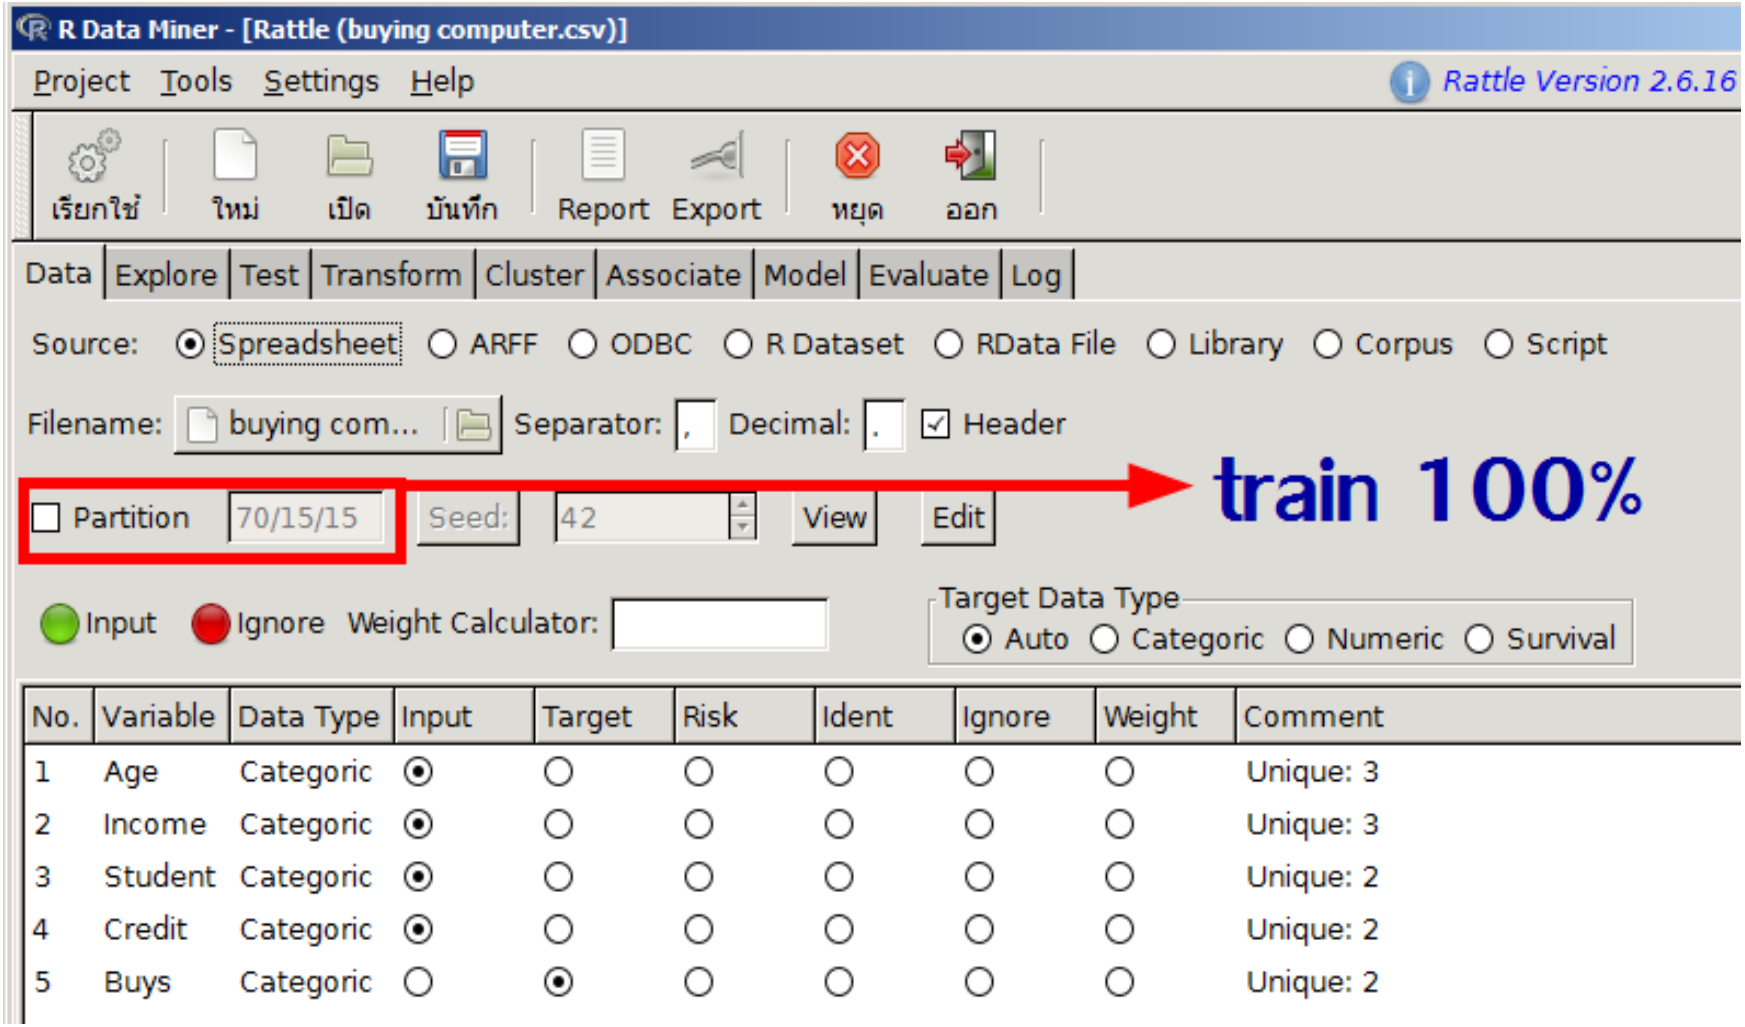



ใช้ Tree,Forest,SVM & Neural Net.

1.train ข้อมูล 100%

2.แบ่งข้อมูลเป็น train 60% และ test 40%

# Workshop 1. Hint.




| No. | Variable | Data Type | Input | Target | Risk | Ident | Ignore | Weight | Comment |
|---|---|---|---|---|---|---|---|---|---|
| 1 | Age | Categoric | ● | ○ | ○ | ○ | ○ | ○ | Unique: 3 |
| 2 | Income | Categoric | ● | ○ | ○ | ○ | ○ | ○ | Unique: 3 |
| 3 | Student | Categoric | ● | ○ | ○ | ○ | ○ | ○ | Unique: 2 |
| 4 | Credit | Categoric | ● | ○ | ○ | ○ | ○ | ○ | Unique: 2 |
| 5 | Buys | Categoric | ○ | ● | ○ | ○ | ○ | ○ | Unique: 2 |

# Workshop 1. Hint.

R Data Miner - [Rattle (buying computer.csv)]

Project Tools Settings Help

เรียกใช้ ใหม่ เปิด บันทึก Report Export หยุด

Data | Explore | Test | Transform | Cluster | Associate | Model

Type: Tree Forest Boost SVM Linear

Target: Buys Algorithm: Traditional Conditional

Min Split: 6 Max Depth: 30

Min Bucket: 2 Complexity: 0.010

```
Summary of the Decision Tree model for Classifica

n= 14

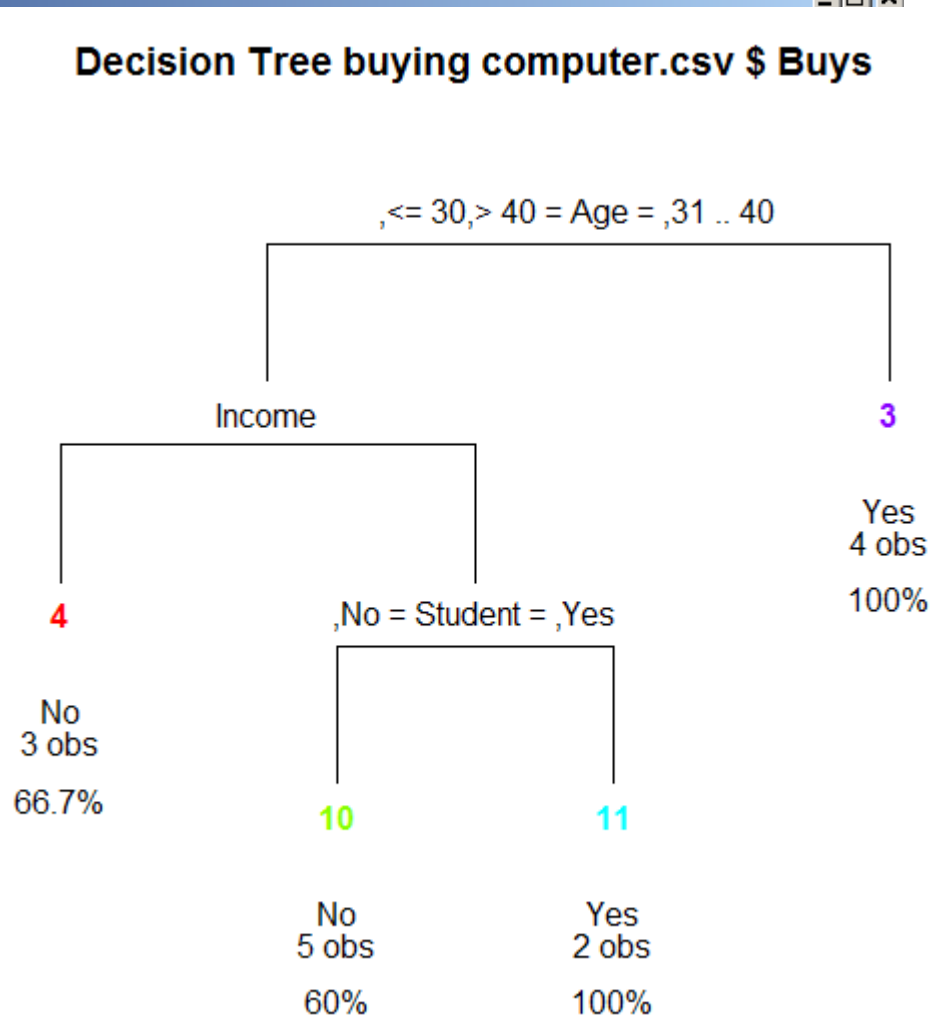
node), split, n, loss, yval, (yprob)
      * denotes terminal node

 1) root 14 5 Yes (0.3571429 0.6428571)
   2) Age=<= 30,> 40 10 5 No (0.5000000 0.5000000
     4) Income=Low 3 1 No (0.6666667 0.3333333) *
     5) Income=High,Medium 7 3 Yes (0.4285714 0.5
      10) Student=No 5 2 No (0.6000000 0.4000000)
      11) Student=Yes 2 0 Yes (0.0000000 1.000000
   3) Age=31 .. 40 4 0 Yes (0.0000000 1.0000000)

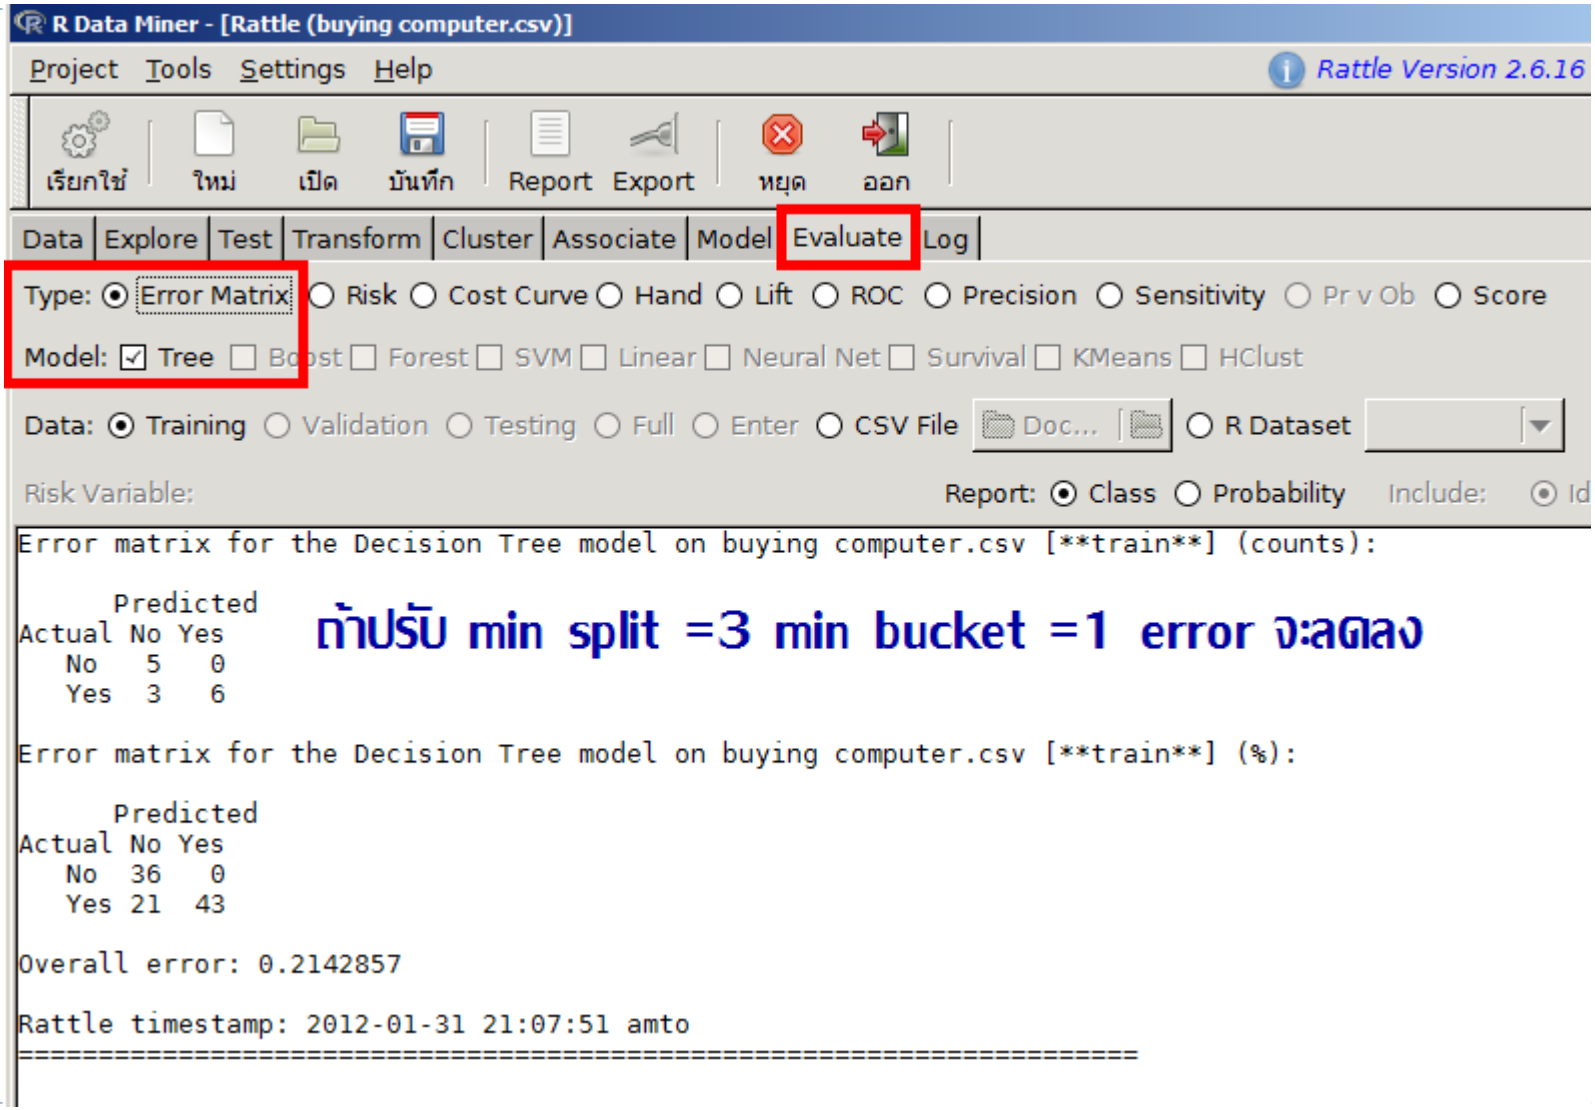
Classification tree:
rpart(formula = Buys ~ ., data = crs$dataset[, c(
    method = "class", parms = list(split = "infor
        minbucket = 2, usesurrogate = 0, maxsurro

Variables actually used in tree construction:
[1] Age     Income  Student

Root node error: 5/14 = 0.35714
```



# Workshop 1. Hint.



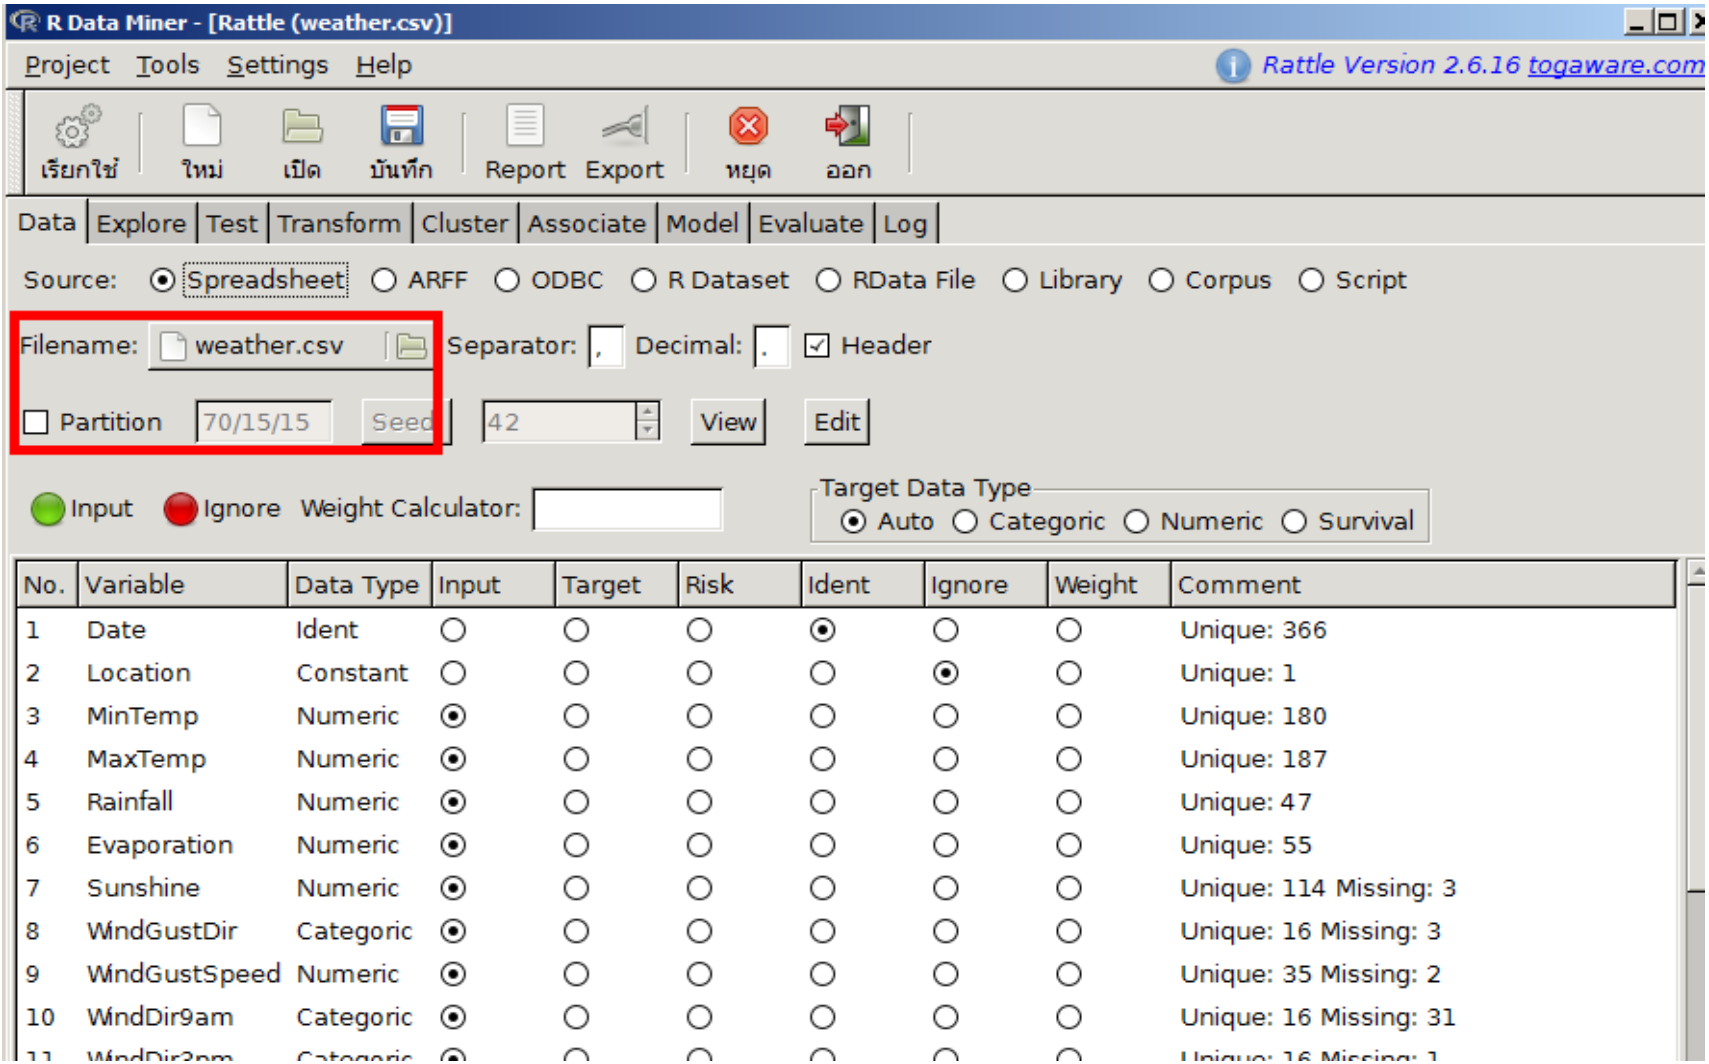
# Workshop 2.

- Workshop แบ่งเป็น 4 กลุ่ม
- กลุ่ม 1 : Boost
- กลุ่ม 2 : Random Forest
- กลุ่ม 3 : SVM
- กลุ่ม 4 : Neural Network

**เงื่อนไข ทดสอบกับ Test set เพื่อหาผู้ชนะ**

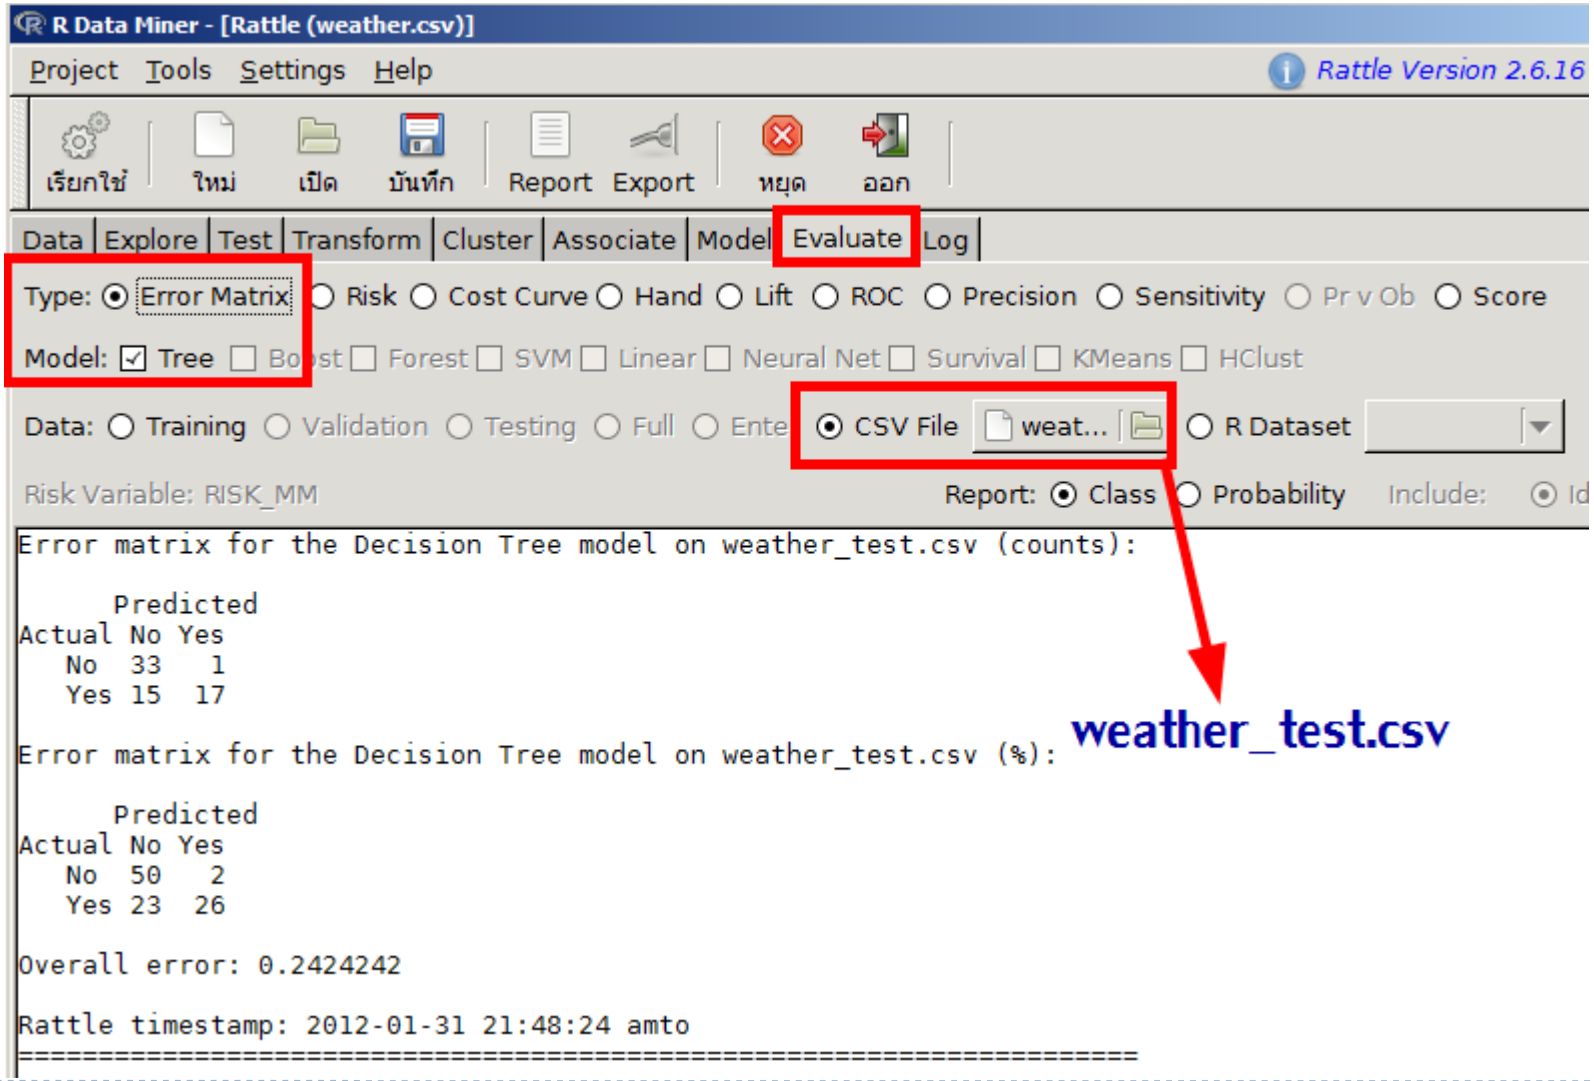
- 1.ใช้ไฟล์ weather.csv Test กับ weather_test.csv (use default seed)
- 2.ทดลองปรับแต่งค่าต่างๆ ตามกลุ่มแล้วหาผู้ชนะที่สามารถทำนายได้แม่นที่สุด
- 3.audit.Rdata แบ่ง Train 50% Test 50%

# Workshop 2. Hint.

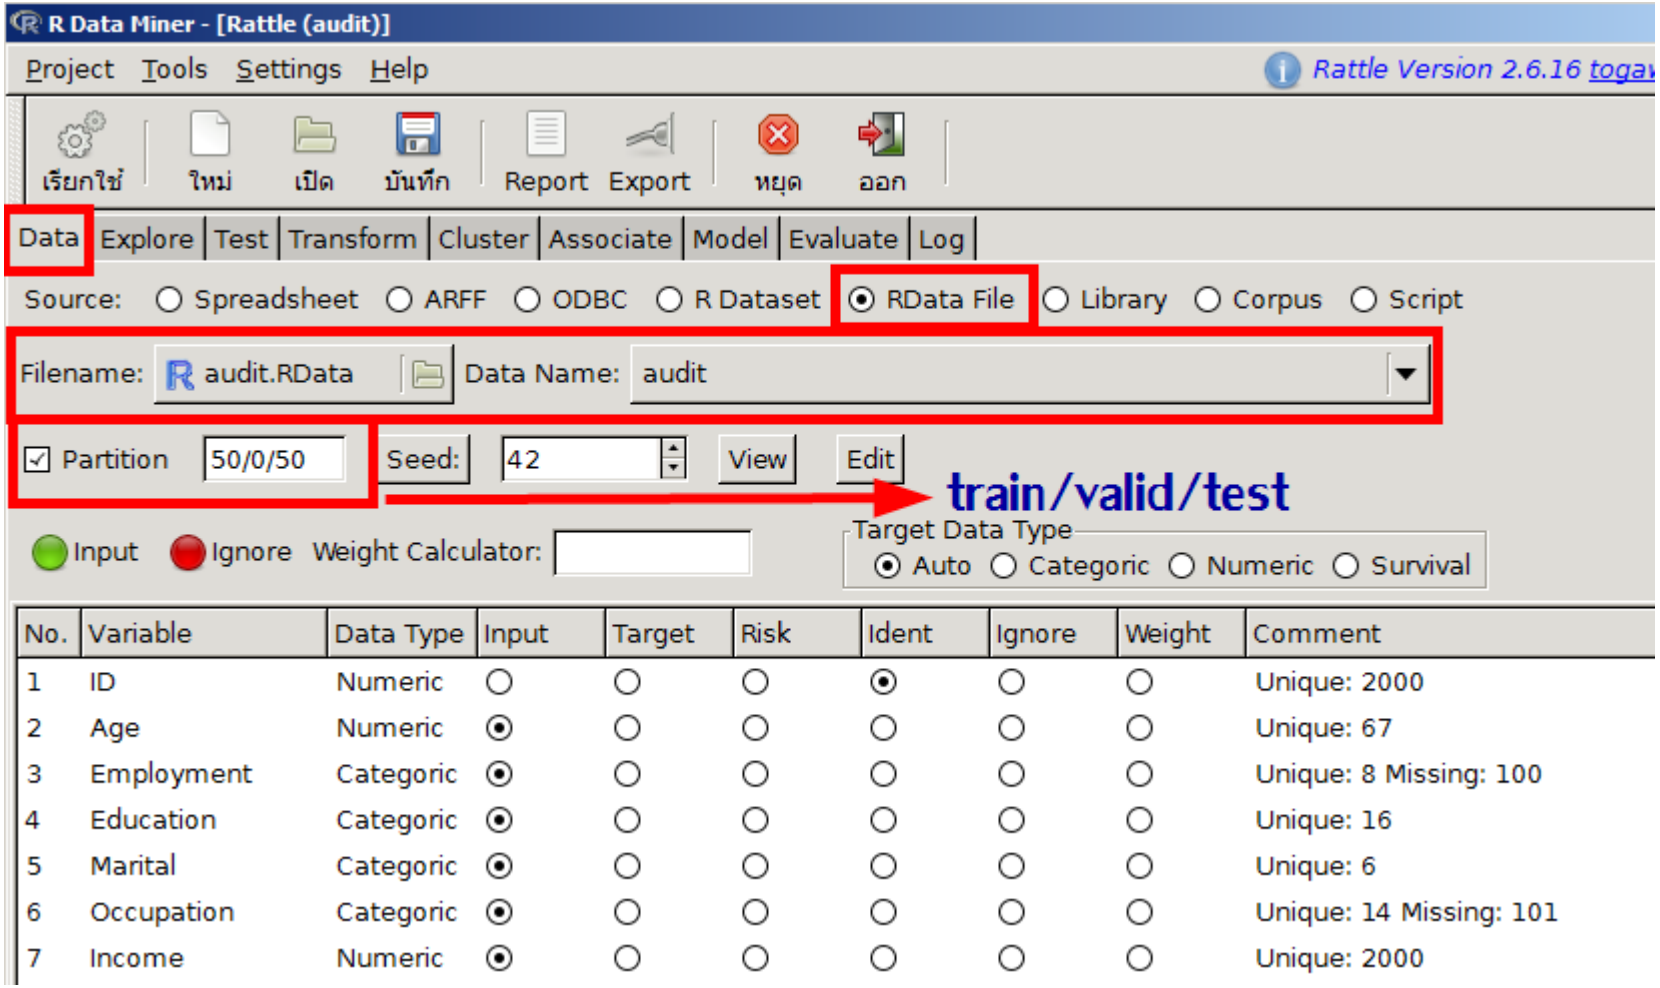



| No. | Variable | Data Type | Input | Target | Risk | Ident | Ignore | Weight | Comment |
|---|---|---|---|---|---|---|---|---|---|
| 1 | Date | Ident | ○ | ○ | ○ | ◉ | ○ | ○ | Unique: 366 |
| 2 | Location | Constant | ○ | ○ | ○ | ○ | ◉ | ○ | Unique: 1 |
| 3 | MinTemp | Numeric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 180 |
| 4 | MaxTemp | Numeric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 187 |
| 5 | Rainfall | Numeric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 47 |
| 6 | Evaporation | Numeric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 55 |
| 7 | Sunshine | Numeric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 114 Missing: 3 |
| 8 | WindGustDir | Categoric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 16 Missing: 3 |
| 9 | WindGustSpeed | Numeric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 35 Missing: 2 |
| 10 | WindDir9am | Categoric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 16 Missing: 31 |

# Workshop 2. Hint.

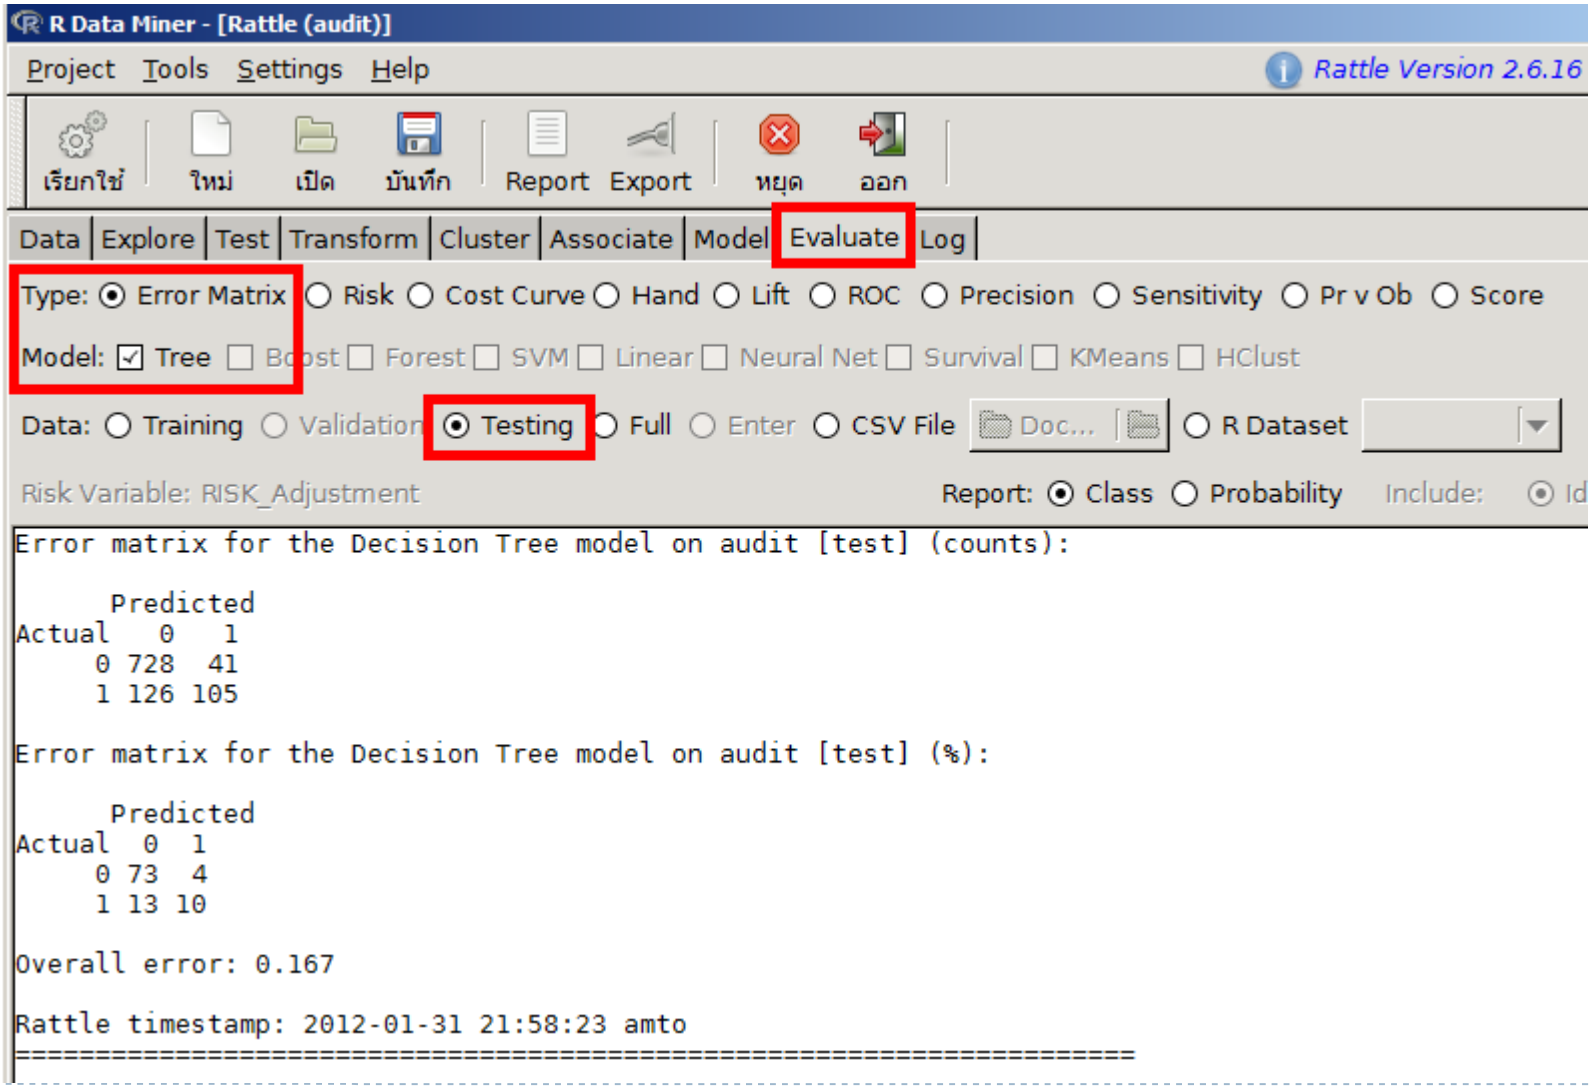


# Workshop 2. Hint.




| No. | Variable | Data Type | Input | Target | Risk | Ident | Ignore | Weight | Comment |
|---|---|---|---|---|---|---|---|---|---|
| 1 | ID | Numeric | ○ | ○ | ○ | ◉ | ○ | ○ | Unique: 2000 |
| 2 | Age | Numeric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 67 |
| 3 | Employment | Categoric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 8 Missing: 100 |
| 4 | Education | Categoric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 16 |
| 5 | Marital | Categoric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 6 |
| 6 | Occupation | Categoric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 14 Missing: 101 |
| 7 | Income | Numeric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 2000 |

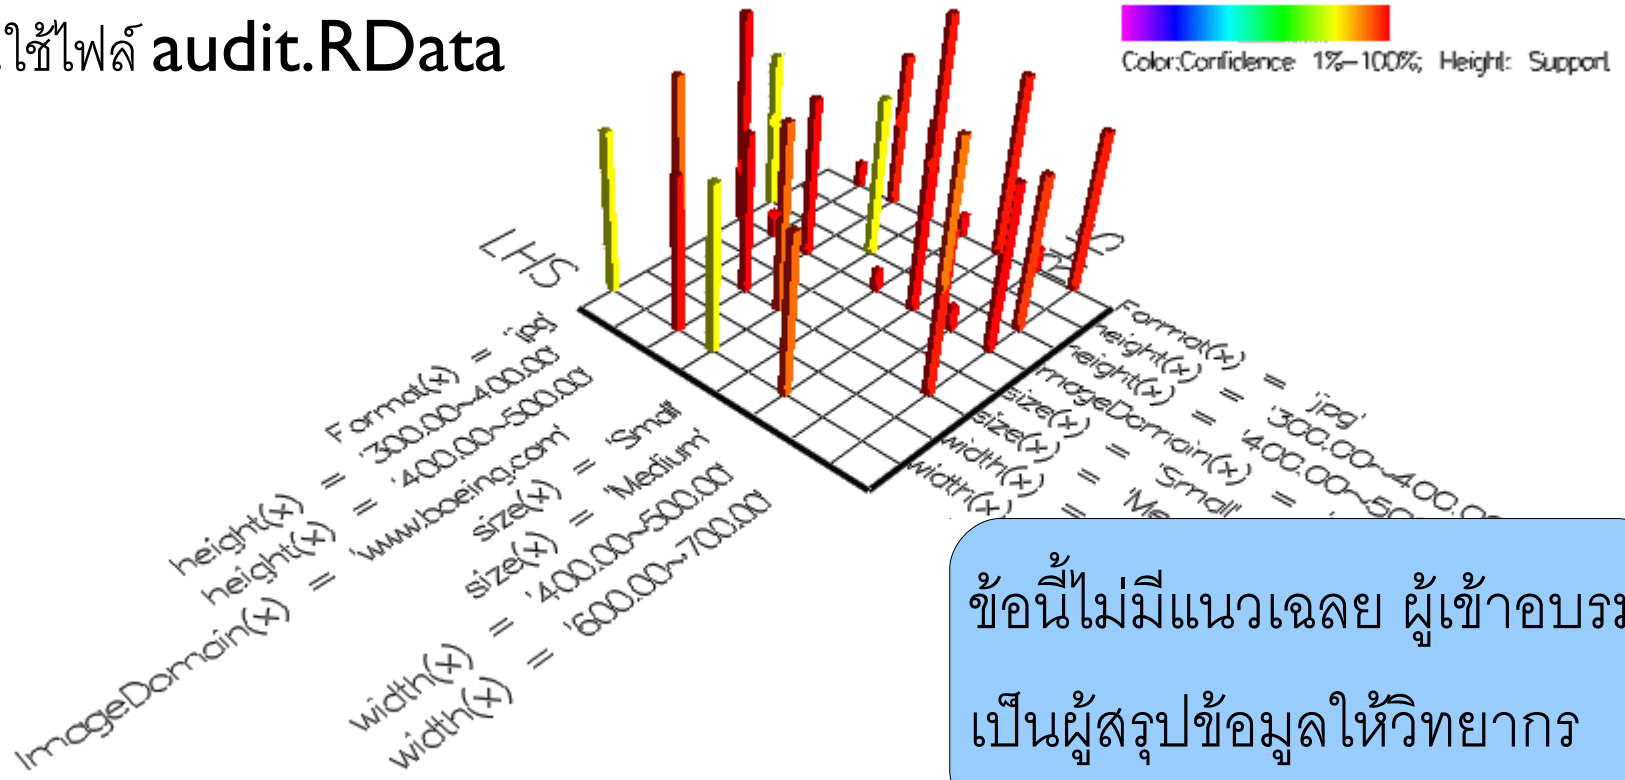
# Workshop 2. Hint.



# Workshop 3.

## ใช้ **Associate rule** ค้นหาความรู้จาก

- 1. weather.csv
- 2.ใช้ไฟล์ audit.RData




ข้อนี้ไม่มีแนวเฉลย ผู้เข้าอบรมเป็นผู้สรุปข้อมูลให้วิทยากร

# Workshop 4.

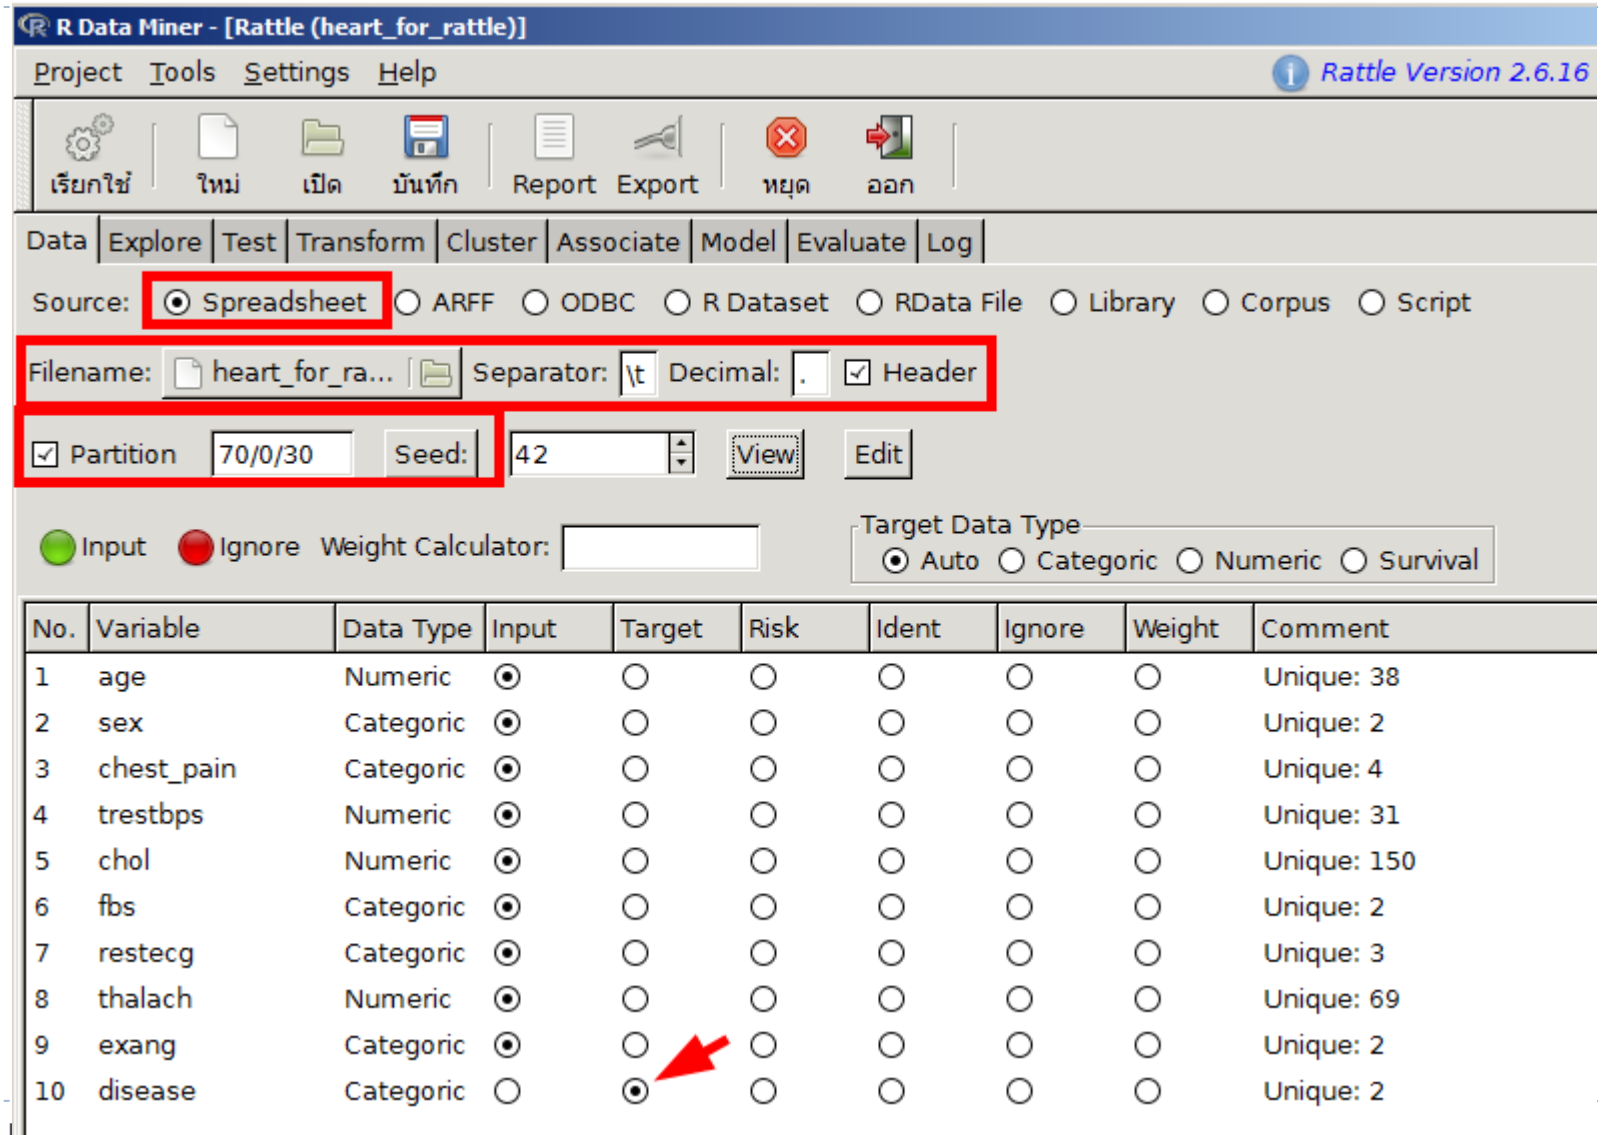
- 1.นำเข้าไฟล์ heart_for_rattle.txt เข้าสู่ Rattle
- 2.แบ่ง Partition ข้อมูลเป็น train 70 test 30 (disease=target)
- 3.สร้าง Box Plot & Histogram ของตัวแปร age & chol
- 4.สร้าง Mosaic of sex & restecg By disease
- 5.ใช้ Hierarchical Method: pearson ระบุว่าคู่ตัวแปรใดที่สัมพันธ์กัน
- 6.ใช้ค่า default ของ Decision tree สร้าง Model
- 7.ใช้ค่า default ของ Boost สร้าง Model
- 8.ใช้ค่า default ของ Random Forest สร้าง Model
- 9.เปรียบเทียบ Overall error จาก Confusion Matrix ของ 3 model
- 10.เปรียบเทียบ ROC ของทั้ง 3 model

# Workshop 4. Hint.

Rattle Dataset

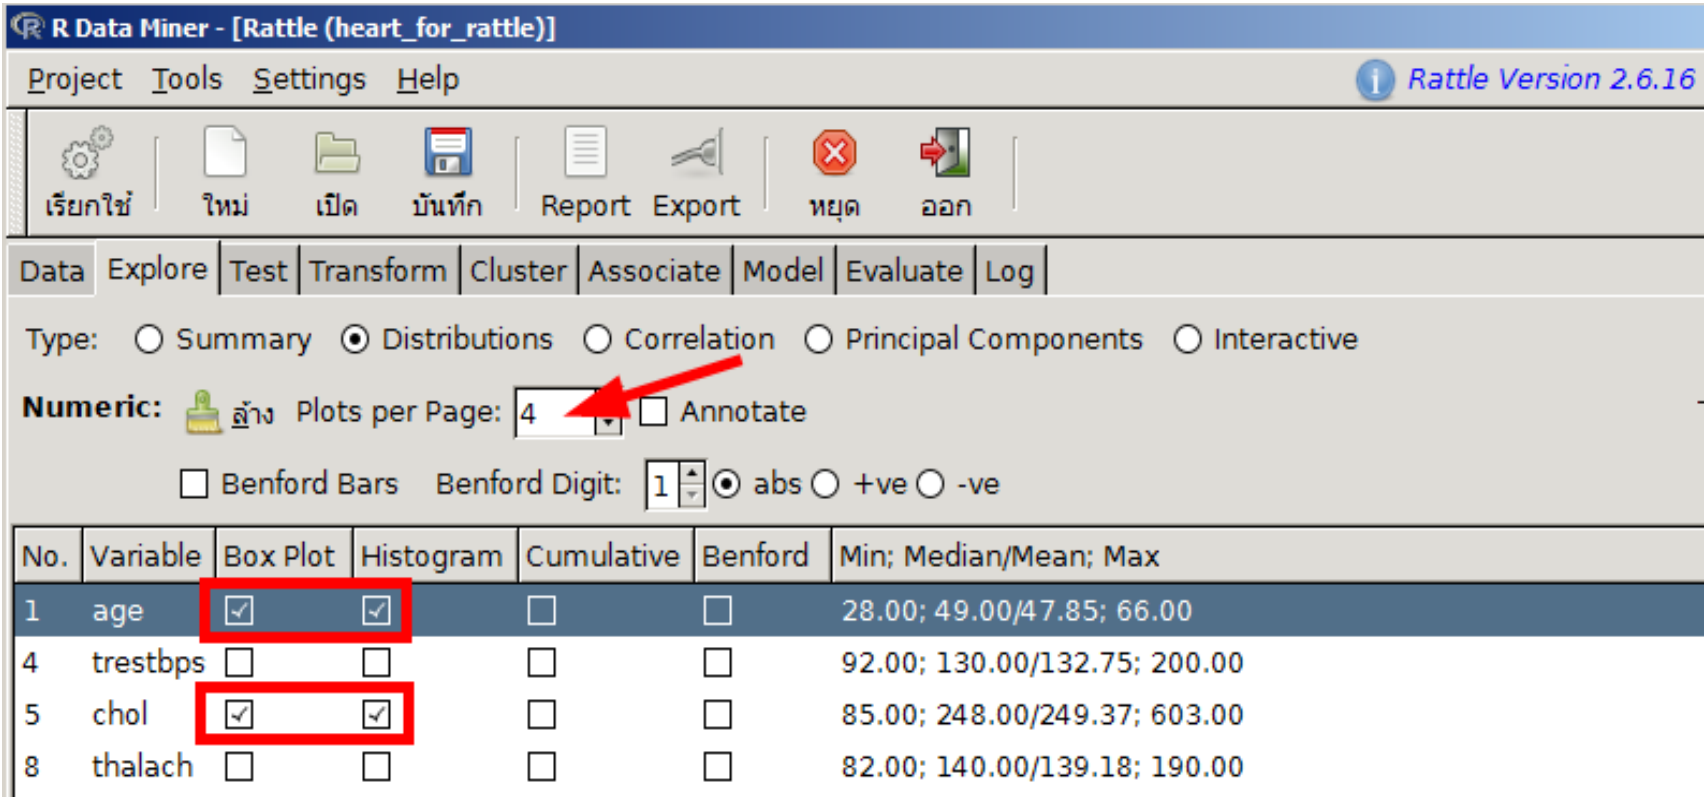
| Rattle Dataset | age | sex | chest_pa | trestbps | chol | fbs | restecg | thalach | exang | disease |
|---|---|---|---|---|---|---|---|---|---|---|
| 1 | 31 | male | asympt | 120 | 270 | f | normal | 153 | yes | positive |
| 2 | 33 | female | asympt | 100 | 246 | f | normal | 150 | yes | positive |
| 3 | 34 | male | p_angina | 140 | 156 | f | normal | 180 | no | positive |
| 4 | 35 | male | p_angina | 110 | 257 | f | normal | 140 | no | positive |
| 5 | 36 | male | p_angina | 120 | 267 | f | normal | 160 | no | positive |
| 6 | 37 | male | asympt | 140 | 207 | f | normal | 130 | yes | positive |
| 7 | 38 | male | asympt | 110 | 196 | f | normal | 166 | no | positive |
| 8 | 38 | male | asympt | 120 | 282 | f | normal | 170 | no | positive |
| 9 | 38 | male | asympt | 92 | 117 | f | normal | 134 | yes | positive |
| 10 | 41 | male | asympt | 110 | 289 | f | normal | 170 | no | positive |

# Workshop 4. Hint.

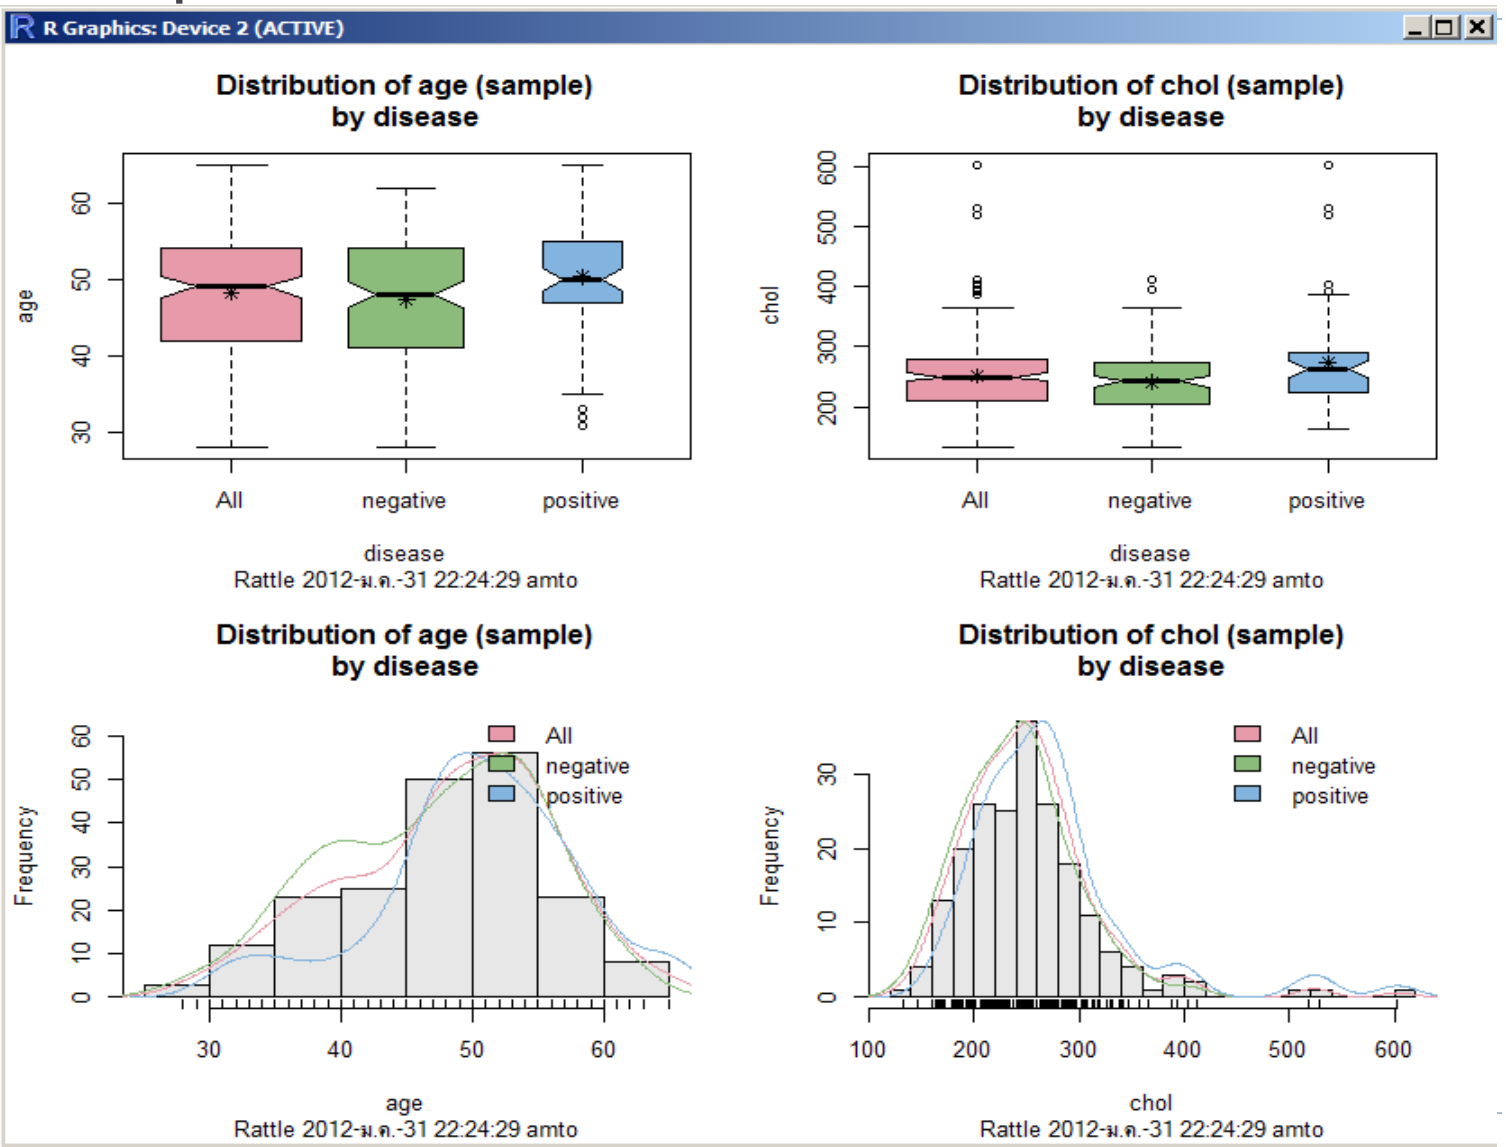



| No. | Variable | Data Type | Input | Target | Risk | Ident | Ignore | Weight | Comment |
|---|---|---|---|---|---|---|---|---|---|
| 1 | age | Numeric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 38 |
| 2 | sex | Categoric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 2 |
| 3 | chest_pain | Categoric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 4 |
| 4 | trestbps | Numeric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 31 |
| 5 | chol | Numeric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 150 |
| 6 | fbs | Categoric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 2 |
| 7 | restecg | Categoric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 3 |
| 8 | thalach | Numeric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 69 |
| 9 | exang | Categoric | ◉ | ○ | ○ | ○ | ○ | ○ | Unique: 2 |
| 10 | disease | Categoric | ○ | ◉ | ○ | ○ | ○ | ○ | Unique: 2 |

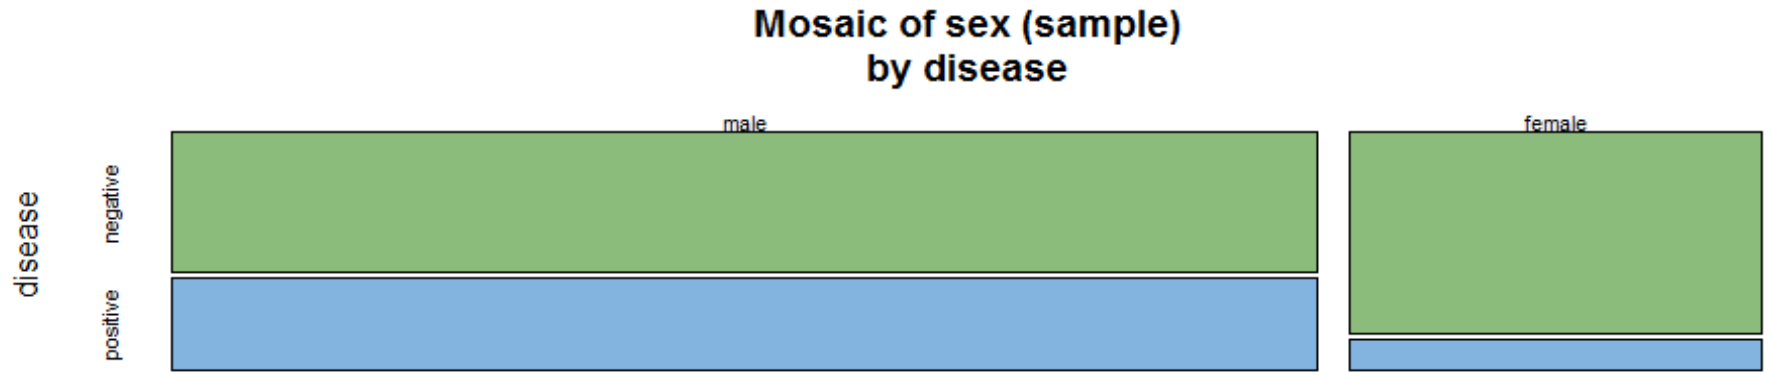
# Workshop 4. Hint.



# Workshop 4. Hint.

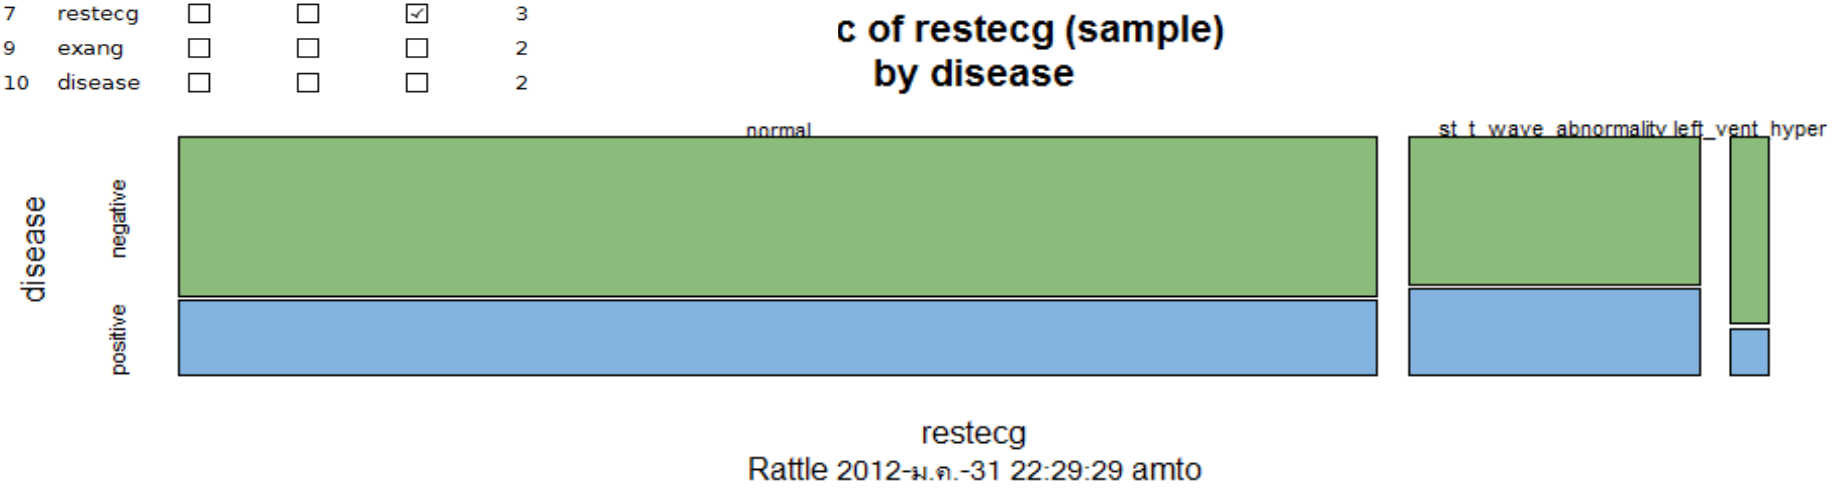


# Workshop 4. Hint.

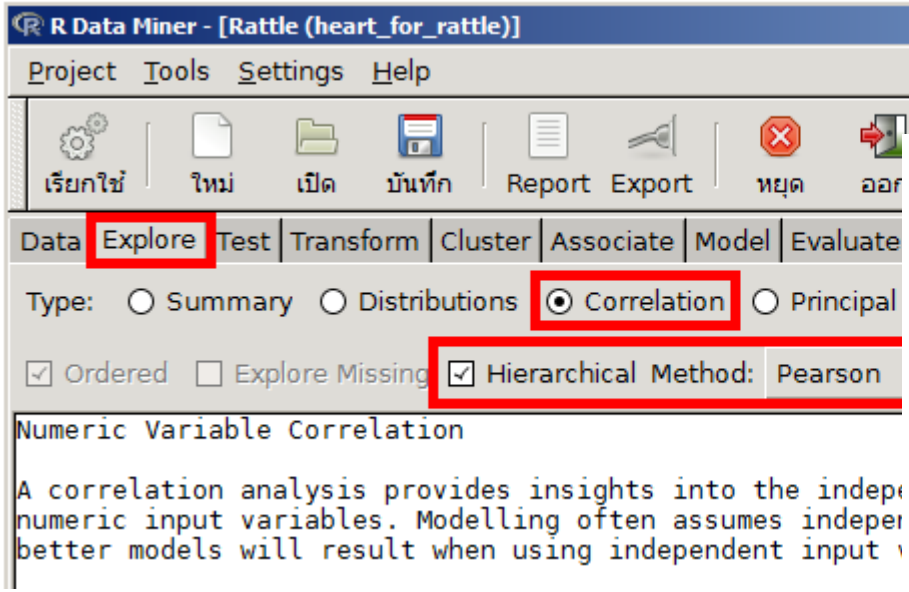


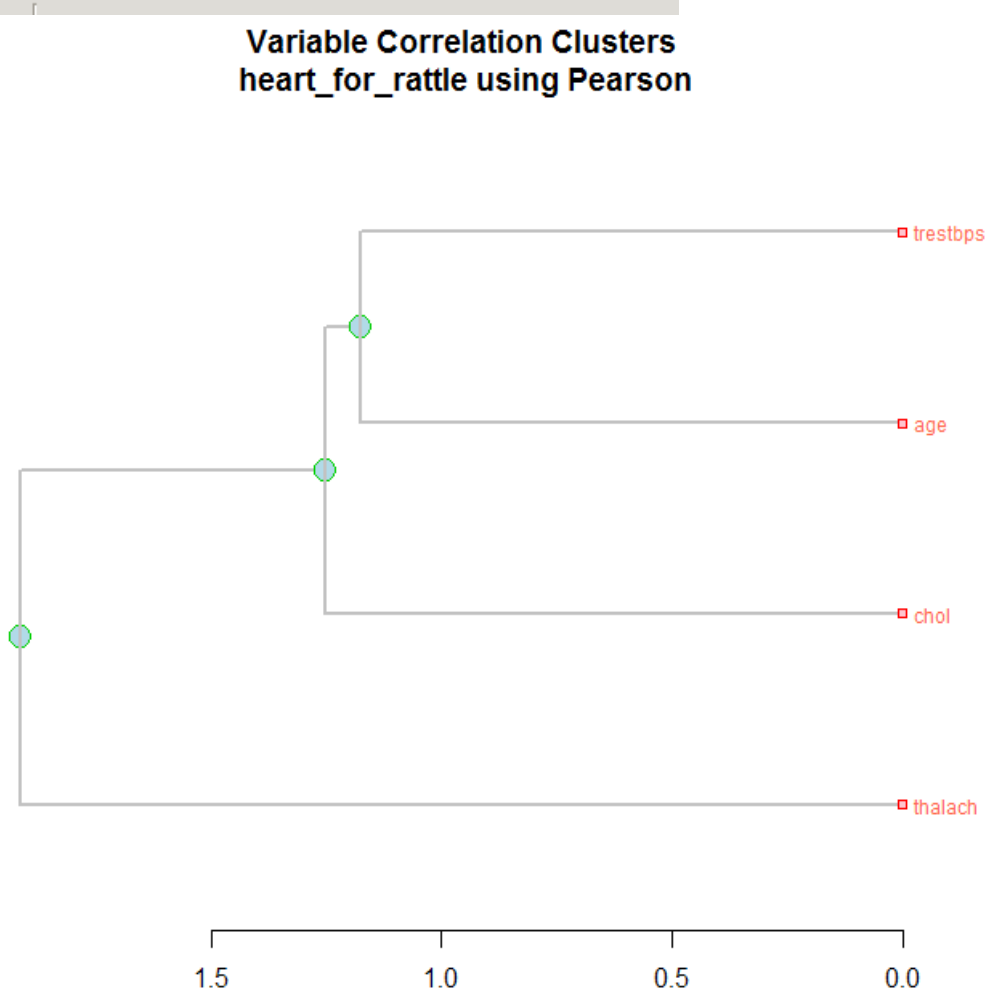

Categoric: ล้าง

| No. | Variable | Bar Plot | Dot Plot | Mosaic | Levels |
|---|---|---|---|---|---|
| 2 | sex | ☐ | ☐ | ☑ | 2 |
| 3 | chest_pain | ☐ | ☐ | ☐ | 4 |
| 6 | fbs | ☐ | ☐ | ☐ | 2 |
| 7 | restecg | ☐ | ☐ | ☑ | 3 |
| 9 | exang | ☐ | ☐ | ☐ | 2 |
| 10 | disease | ☐ | ☐ | ☐ | 2 |

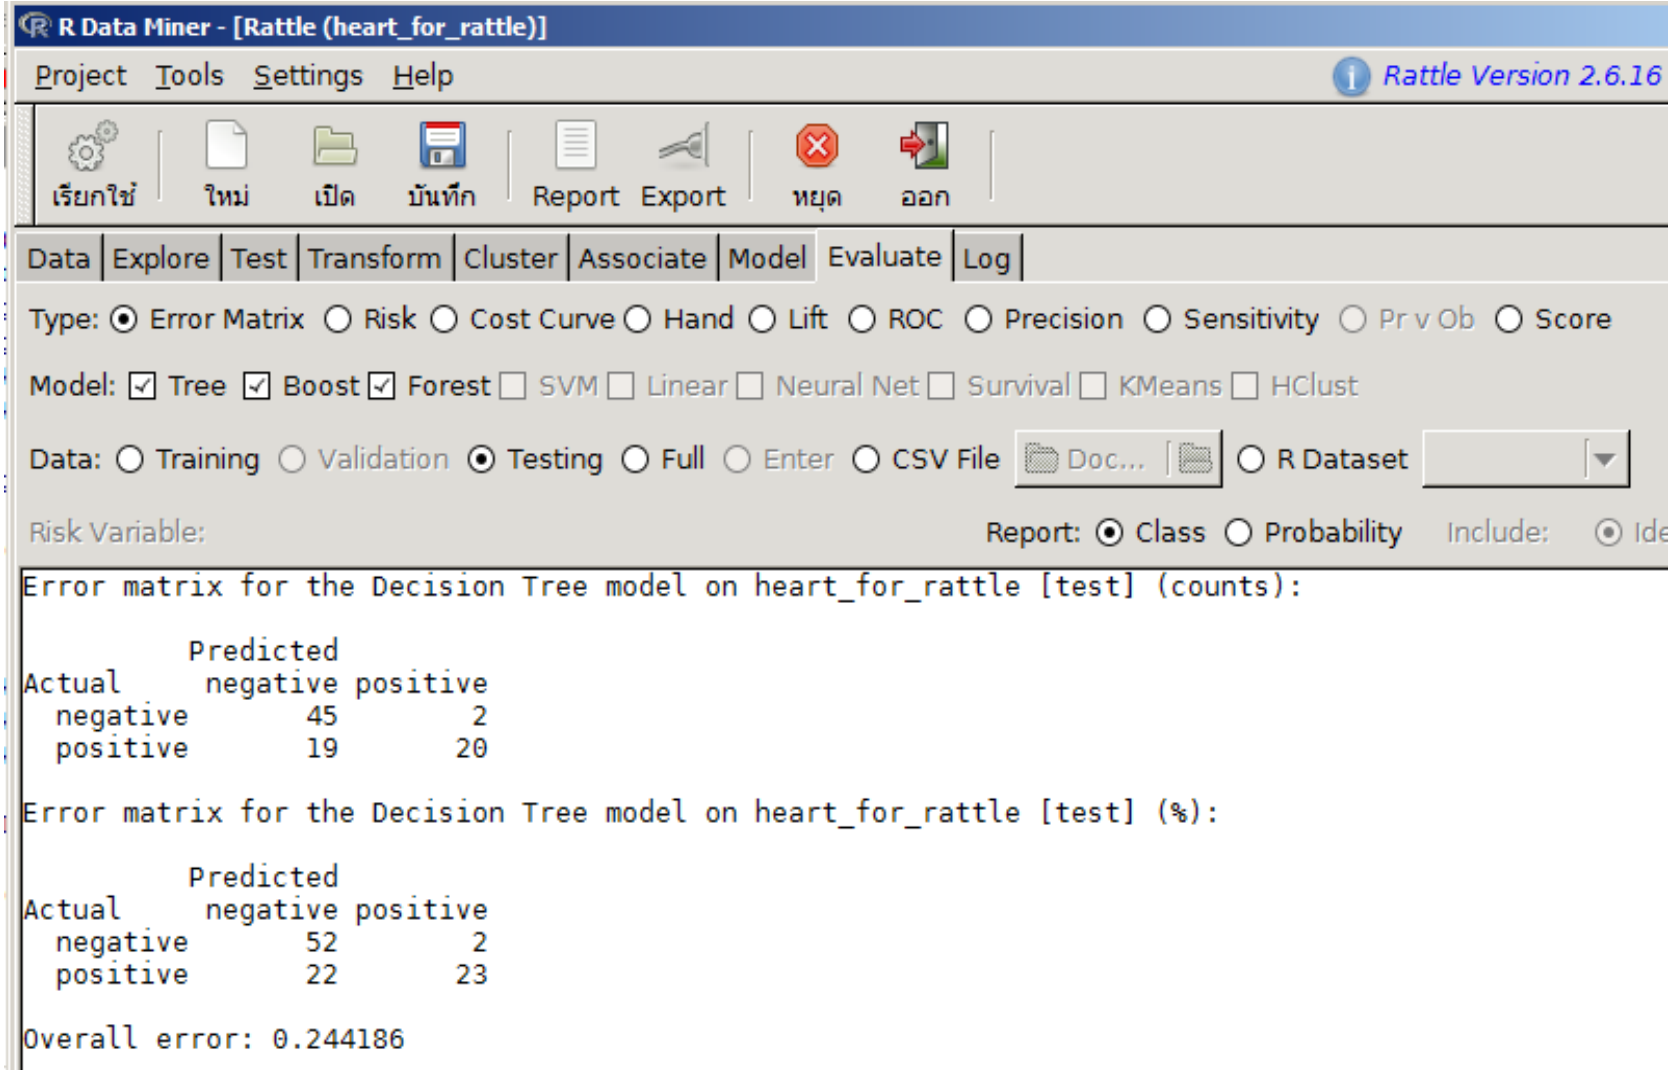


# Workshop 4. Hint.

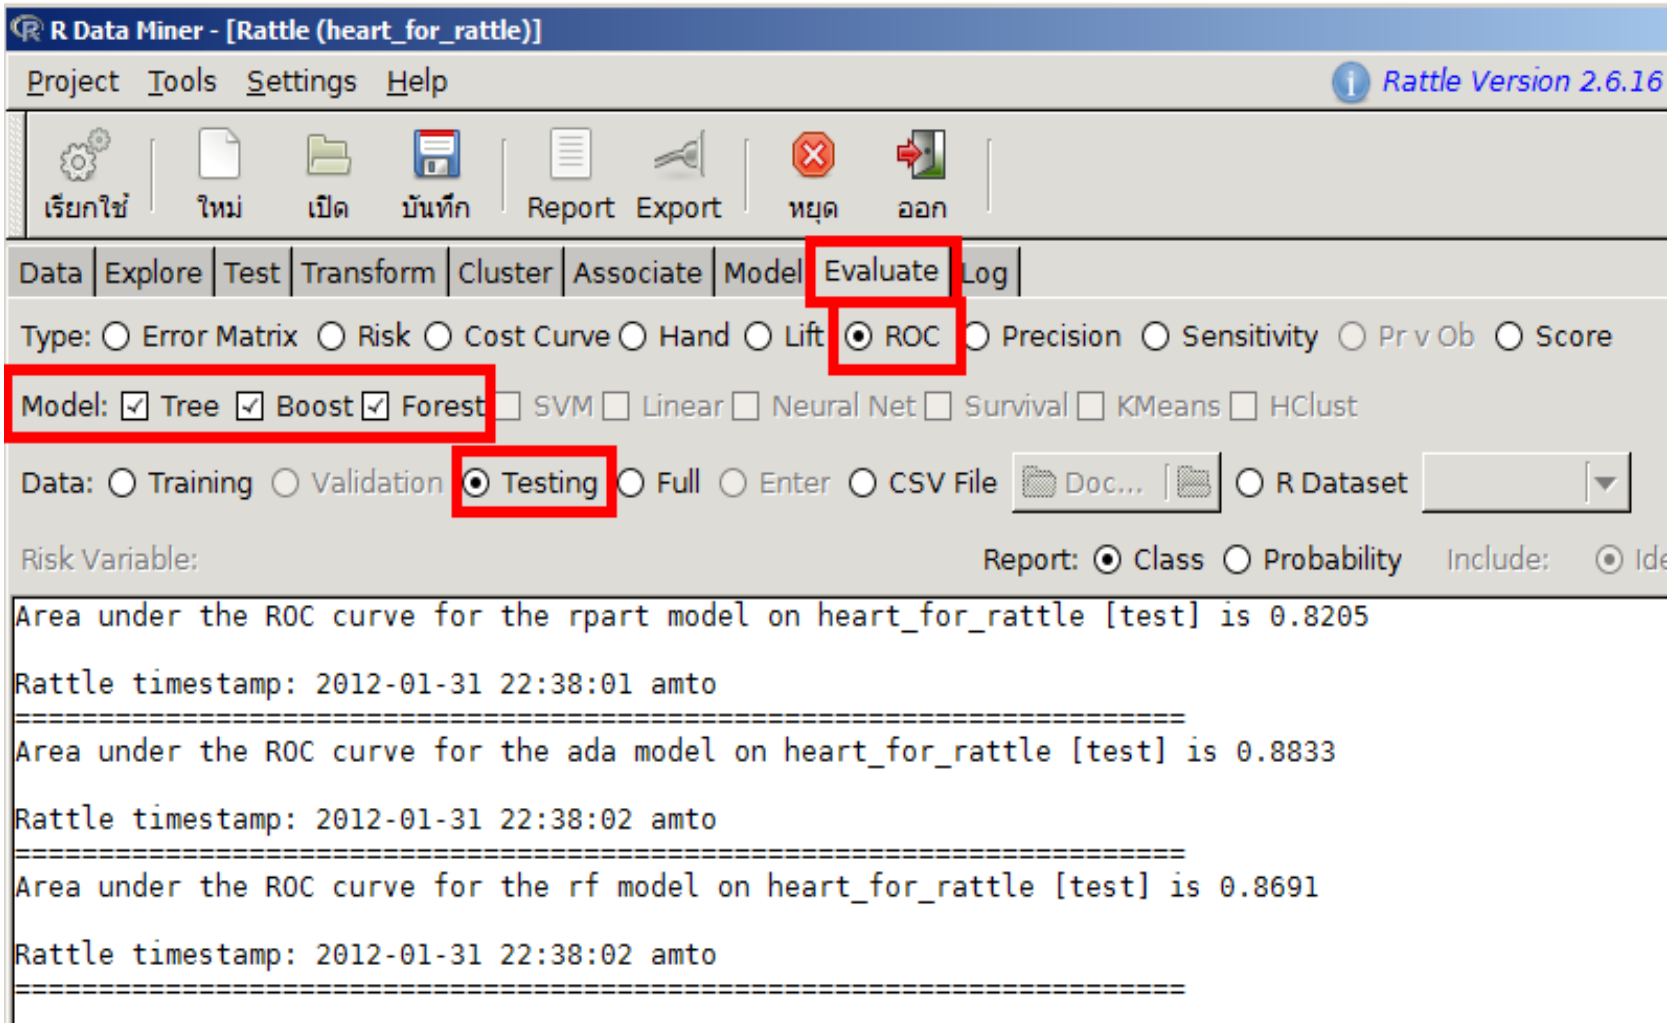


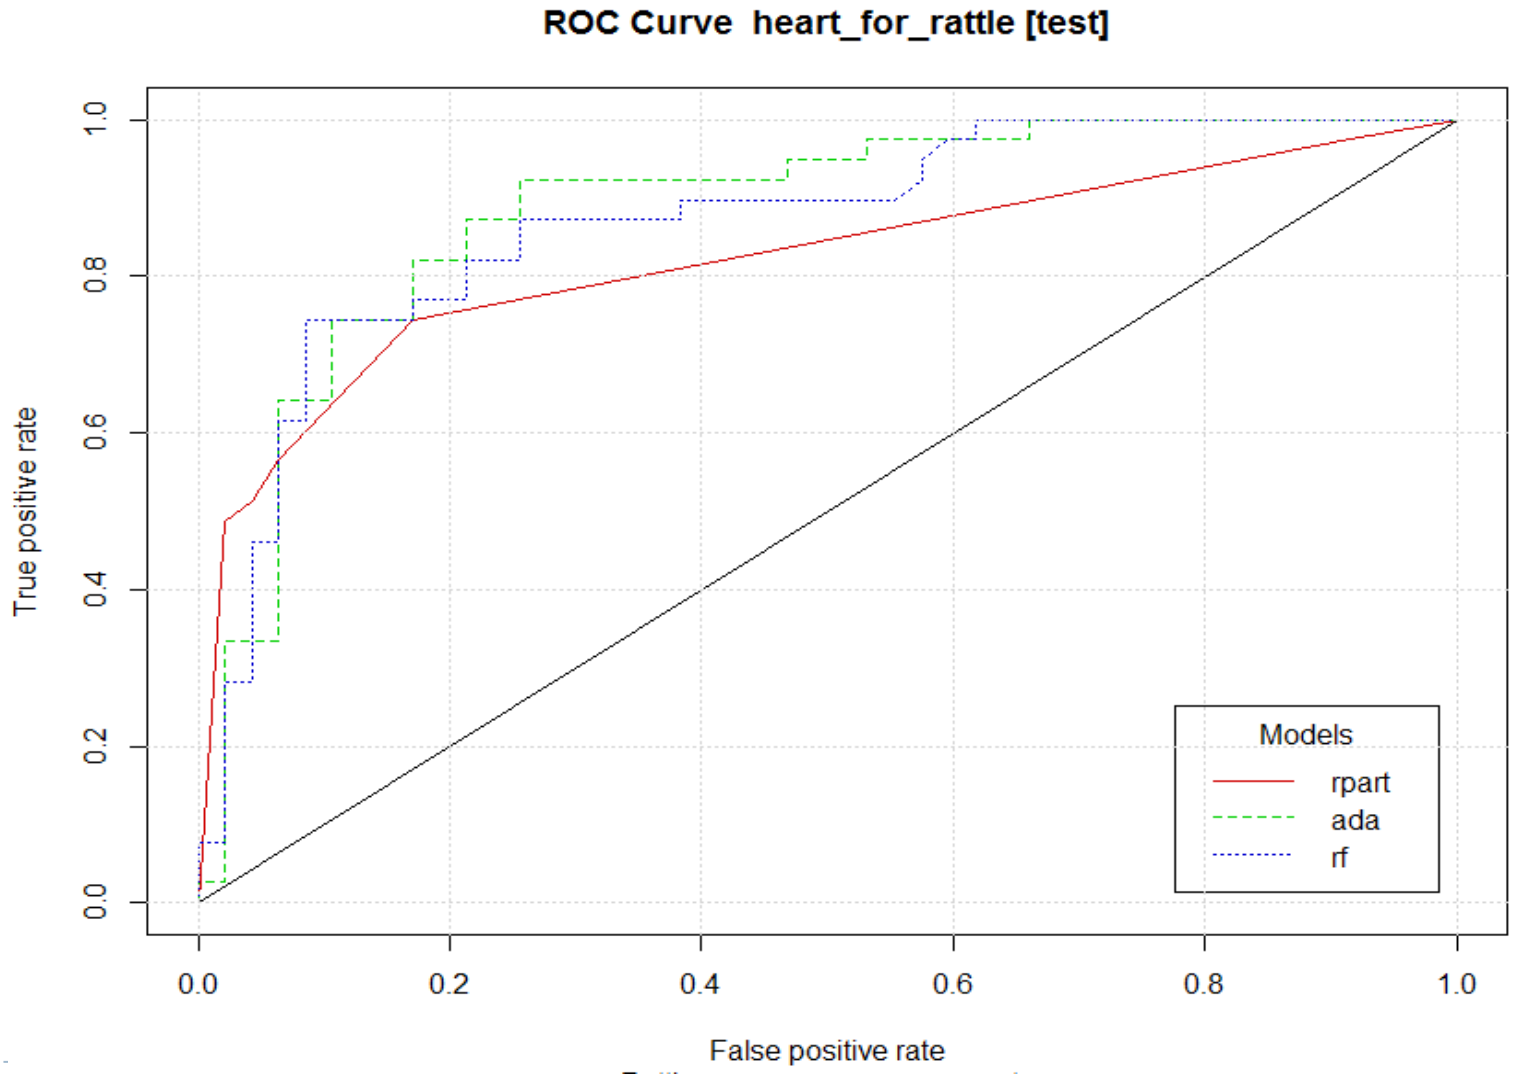
# Workshop 4. Hint.



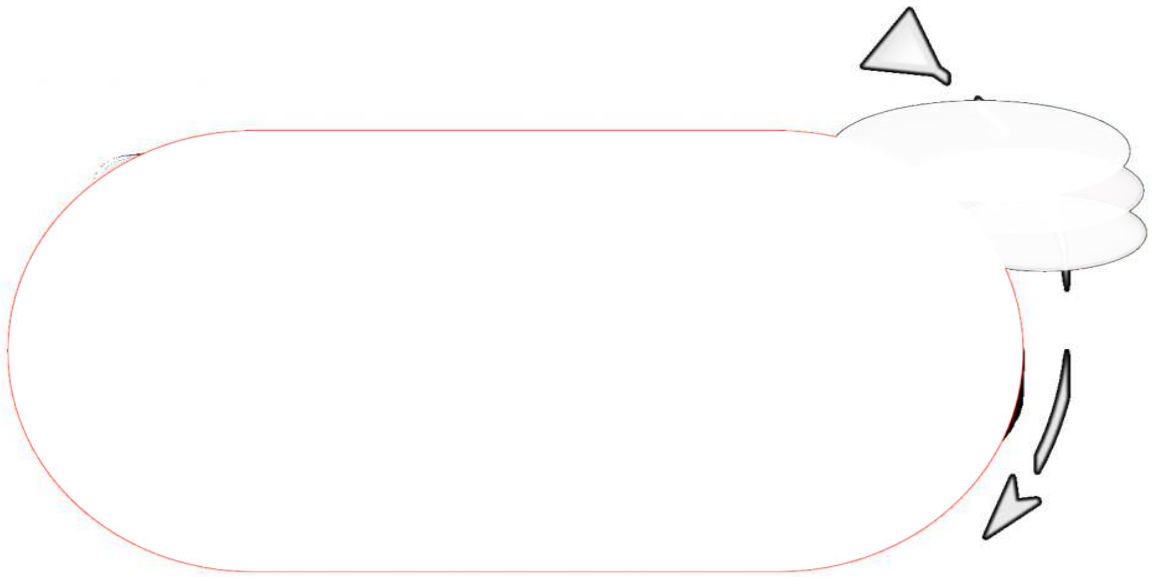
# Workshop 4. Hint.



# Workshop 4. Hint.



# จบการนำเสนอ



Data mining and statistic tools is the way to find knowledge and get wealthy!

Welcome to use R , Rattle, RapidMiner , KNIME,and WEKA
the world leading analytic open source software.

- www.reinforcebi.com
- info@reinforcebi.com
- 08 1491 0909